

Arbitrage

จากแนวคิดสู่การปฏิบัติ

Part V: Statistical Arbitrage (บท 18-21)

Pairs Trading, Mean Reversion, Factor Models, ML Overview

อ่านก่อน: Stat Arb สำหรับรายย่อย — ทำอะไรได้จริง และต้องระวังอะไร

เนื้อหา Part นี้สอน **คณิตศาสตร์และเครื่องมือที่รายย่อยทำได้จริง** (cointegration test, OU, Kalman — เขียน Python ฟรีได้ทั้งหมด) แต่ต้องแยกให้ออกระหว่าง "ทำได้" กับ "กำไรจริงหลังหักต้นทุน":

ทำได้ สร้าง/วิจัยโมเดล, เทรดคู่หุ้นใหญ่สภาพคล่องสูงด้วยทุนพอประมาณ, ใช้เป็นเครื่องมือ **เรียนรู้** market-neutral (พอร์ตที่ขึ้น/ลงตามตลาดไม่กระทบ)

ระวัง งานวิจัยเกือบทั้งหมดรายงานเป็นผลตอบแทน **ก่อนหักต้นทุน (gross)** และ **edge** (ความได้เปรียบที่ทำให้ชนะตลาด) เสื่อมลงต่อเนื่องหลังปี 2000

เกินกำลัง พอร์ต market-neutral หลายร้อยตัว, short หุ้นเล็ก/หา borrow (ยืมหุ้นมา short) ยาก, แข่ง execution กับ HFT

หลักฐานเรื่อง decay และต้นทุนอยู่ในกล่องของแต่ละบท + รายการอ้างอิงท้าย Part

บทที่ 18: Pairs Trading

Stat Arb เริ่มต้นจากแนวคิดง่ายๆ: "หุ้น 2 ตัวที่เคลื่อนไหวด้วยกัน → เมื่อแยกจากกัน → เข้าเทรด"

18.1 Correlation vs Cointegration

	Correlation	Cointegration
วัดอะไร	ทิศทางเหมือนกันไหม	ระยะห่างคงที่ไหม
ปัญหา	2 หุ้นอาจ drift ออกจากกันตลอดกาล	Spread กลับหาค่าเฉลี่ย
ตัวอย่าง	BTC กับ ETH: correlated แต่ ratio เปลี่ยนเรื่อยๆ	Coke vs Pepsi: spread mean-reverts
ใช้กับ Arb?	ไม่พอ!	ต้องใช้ตัวนี้!

Engle-Granger Cointegration Test^[13]

1. Regress A vs B: $A = \alpha + \beta \times B + \varepsilon$
2. ทดสอบ residuals (ε) ว่า stationary ไหม (ADF test)
3. ถ้า ε stationary → A กับ B cointegrated → **Spread = $\varepsilon = A - \alpha - \beta \times B$ จะ mean-revert!**

ข้อควรระวัง: ผล regress ไม่สมมาตร — regress A กับ B vs B กับ A ได้ β และผล ADF ต่างกัน ควรลองทั้งสองทิศ (หรือใช้ Johansen test)

18.2 Trading the Spread

$$\text{Spread} = \text{Price}_A - \beta \times \text{Price}_B$$


$$\text{Z-score} = (\text{Spread} - \text{Mean}) / \text{StdDev}$$

Entry: $Z > +2 \rightarrow$ Short Spread (Short A, Long $\beta \times B$)

Entry: $Z < -2 \rightarrow$ Long Spread (Long A, Short $\beta \times B$)

Exit: $Z \approx 0 \rightarrow$ Close ทั้งสองขา

Stop: $|Z| > 4 \rightarrow$ Cut loss (structural break?)



หลักฐานวิจัย: Pairs Trading ได้ผลจริงไหม?

งานวิจัยต้นฉบับปี 2006^[1] ใช้ distance method (formation 12 เดือน, เทรด 6 เดือน, เปิดที่ 2σ) บนหุ้นสหรัฐ ปี 1962–2002 พบผลตอบแทนส่วนเกิน **~11% ต่อปี (ก่อนหักต้นทุน)**

แต่การศึกษาต่อมาปี 2010^[2] แสดงว่ากำไร **เลื่อมลงชัดเจน**: top-20 pairs ได้ 0.86%/เดือน (1962–1988) → 0.37% (1989–2002) → **0.24% (2003–2009)** และงานปี 2012^[3] พบว่า **เมื่อหักค่าคอม + market impact + ค่า borrow แล้ว เหลือ ~0.30%/เดือน เฉพาะคู่ที่จับคู่ดีเท่านั้น** — คู่ทั่วไปต้นทุนกินกำไรเกือบหมด

ระวัง ค่าคอม \$0 ช่วยได้ แต่ **spread + slippage + ค่า borrow ฝั่ง short** คือต้นทุนจริงที่ยังอยู่ และโอกาสที่เหลื้อมักอยู่ในหุ้นเล็กที่ short ยาก — บทวิจารณ์รวมปี 2017^[4] สรุปว่าวิธี distance แบบง่ายเลื่อมไปนานแล้ว ส่วน cointegration มีพื้นฐานทฤษฎีแข็งแกร่งกว่า

ดูคำเตือนเรื่อง data-snooping และ short-sale constraints ในบทวิจารณ์ [4] — รายการอ้างอิง [1]–[4] ท้าย Part

บทที่ 19: Mean Reversion

19.1 Ornstein-Uhlenbeck Process

เปรียบเทียบ: "ยางยืด"

ลองนึกว่า spread ถูกผูกด้วยยางยืดกับค่าเฉลี่ย μ — ยิ่งดึงออกไกล ยิ่งถูกดึงกลับแรง

θ = ความแข็งของยาง (สูง = กลับเร็ว), σ = ลมที่พัดให้แกว่ง (noise)


$$dX = \theta(\mu - X)dt + \sigma dw$$

θ = speed of mean reversion (ยิ่งสูง ยิ่งกลับเร็ว)

μ = long-run mean (ค่าที่ดึงดูดกลับ)

σ = volatility

Half-life = $\ln(2) / \theta \leftarrow$ "นานแค่ไหนกว่า spread จะกลับครึ่งทาง"



ตัวอย่าง

ถ้า Half-life = 5 วัน → spread กลับครึ่งทางใน 5 วัน → ดีมาก trade ได้

ถ้า Half-life = 60 วัน → ช้าเกินไป → tie up capital นาน → อาจไม่คุ้ม

หลักฐานวิจัย: OU + Half-life ใช้กันจริง

โมเดล "ยางยืด" นี้ไม่ใช่แค่ทฤษฎี — มีอาชีพใช้จริง งานวิจัยปี 2010^[5] ใช้ OU จับ residual ของหุ้นหลังหักปัจจัย (PCA / sector ETF) บนตลาดสหรัฐ 1997–2007 ได้ **Sharpe ~1.44 (PCA)** แต่ **ลดเหลือ ~0.9 ช่วงปลาย (2003–2007)**

⚠ ตัวเลขนี้เป็น **gross** (ก่อนต้นทุน) + สมมติเทรดทั้ง universe รายวันและ short ได้ทุกตัว; 1.44 เป็นค่าช่วงต้น ไม่ใช่ค่าคงที่ที่คาดหวังได้ — ตอกย้ำธีม edge เลื่อมเหมือนบท 18

ทำได้ ส่วนคำนวณ (fit OU/half-life ด้วย AR(1)/OLS) ทำได้ 100% บน statsmodels — ไม่ต้อง short ไม่ต้องใช้ทุน ใช้กรอบคู่ที่ half-life สั้น (~5–30 วัน) ได้เลย แต่ **สั้นเกินไป (1–2 วัน) มักเป็น noise/bid-ask bounce** และยิ่งสั้นยิ่งเทรดถี่ = ต้นทุนสูง

19.2 Kalman Filter — Dynamic Hedge Ratio

ปัญหา: β (hedge ratio) เปลี่ยนตามเวลา → ใช้ rolling regression ไม่ดีพอ

Kalman Filter: อัปเดต β แบบ real-time ตามข้อมูลใหม่ → **adaptive pairs trading**

เปรียบเทียบง่ายๆ

Kalman = "ปรับ β ทีละนิดทุกวันตามข้อมูลใหม่" แทนที่จะคำนวณ β ใหม่หมดทั้งหน้าต่าง — เหมือนหมุนพวงมาลัยแก้ทีละนิด ไม่ใช่เลี้ยวกระชากทุกครั้งทีเจอโค้ง

หลักฐานวิจัย: Kalman ดีกว่า rolling regression อย่างไร

ตำราวิชาการปี 2025 (Cambridge)^[6] แสดงว่า hedge ratio จาก rolling regression **กว้างแรงและ noisy** (เช่น 0.6–1.2) ขณะที่ Kalman ให้ค่าที่ **นิ่งกว่าแต่ยังปรับตามได้** (เช่น 0.55–0.65) และตัด parameter "ความยาว window" ที่ต้องเดาออกไป

ทำได้ มีไลบรารีพร้อม (pykalman, statsmodels) — ส่วนการเทรดจริงยังติดข้อจำกัด short เหมือนทุกกลยุทธ์ long/short

19.3 Regime Detection

เมื่อไร Mean Reversion ใช้ไม่ได้?

Trending market → spread ไม่ mean-revert → **ขาดทุนต่อเนื่อง**

Structural break → cointegration หาย (M&A, sector change)

ต้องมี **regime detection**: ถ้าตลาดเปลี่ยน → หยุดเทรด pairs

บทที่ 20: Factor-Based Statistical Arbitrage

20.1 จาก Pairs สู่ Portfolio

เทรด 1 คู่ → diversify ด้วยหลายคู่ → สร้าง **portfolio ของ pairs trades**
 → single-pair risk ลดลง → more consistent returns

20.2 Factor Models

$$\text{Return}_i = \alpha_i + \beta_1 \times \text{Market} + \beta_2 \times \text{Size} + \beta_3 \times \text{Value} + \dots + \varepsilon_i$$

α (alpha) = ส่วนที่ model อธิบายไม่ได้ = **edge ที่เราหา!**

$\beta \times \text{Factor}$ = systematic risk → hedge ออกได้

20.3 Market-Neutral Portfolio

Portfolio beta = 0 (ตลาดขึ้น/ลงไม่กระทบ)

Long stocks ที่มี positive alpha + Short stocks ที่มี negative alpha

→ กำไรจาก alpha เท่านั้น ไม่ขึ้นกับทิศตลาด [Lv.4 Structured]

PCA Factors (จากเล่มคณิตศาสตร์ บท 8)

ใช้ Eigenvalues ของ Covariance Matrix → หา principal components

PC1 มักคล้าย market factor; PC ถัดๆ ไป อาจ สะท้อน sector/style แต่ไม่เสมอ และตีความยาก/ไม่นิ่ง

→ Hedge ที่ละ factor → เหลือแค่ alpha

⚠ ความจริงสำหรับรายย่อย: Market-Neutral เต็มรูปแบบ = เกินกำลัง

การถือพอร์ต long-short หลายสิบ-หลายร้อยตัวเพื่อให้ $\beta = 0$ ต้องใช้:

- **Short ได้ทุกตัว** — แต่หุ้นเล็กที่มี alpha สูงมักหา borrow ไม่ได้/ค่า borrow แพง (HTB 5–50%+/ปี)
- **ทุนมาก** — margin ทั้งสองขา + ต้องกระจายหลายตำแหน่งเพื่อลด single-pair risk
- **ข้อมูลคุณภาพสถาบัน** — point-in-time, survivorship-bias-free (CRSP/Compustat)

งานวิจัยปี 2010^[5] เองก็จำกัดเฉพาะหุ้นใหญ่ที่ borrow ได้ และผลตอบแทนที่รายงานเป็น gross — งานปี 2015–2025 ชี้ว่า edge ถูกบีบจากการแข่งขัน + ค่า borrow ที่ **สูงขึ้น**

ทำได้ เริ่มจากพอร์ต pairs ไม่กี่คู่ในหุ้นใหญ่/ETF สภาพคล่องสูง — เก็บ market-neutral หลายร้อยตัวไว้เป็น "ของสถาบัน"

บทที่ 21: Machine Learning ใน Stat Arb

21.1 Feature Engineering

สร้าง features จากข้อมูลดิบ: momentum, mean-reversion signals, vol ratios, order flow

21.2 Walk-Forward Cross-Validation

Time Series $\neq$ Regular Data!

ห้ามใช้ random K-fold $\rightarrow$ data leakage (ใช้อนาคตทำนายอดีต)

ต้องใช้ **Walk-Forward**: train on past $\rightarrow$ test on next period $\rightarrow$ roll forward

21.3 Overfitting — ศัตรูตัวฉกาจ

Backtest Sharpe สูงผิดปกติ (เช่น 4-5) $\rightarrow$ สันนิษฐานไว้ก่อนว่า overfit

Backtest Sharpe $\sim 1-2 \rightarrow$ "พอเป็นไปได้" $\rightarrow$ ต้องทดสอบ out-of-sample จริง

(ตัวเลข 5 vs 1.5 เป็น *rule of thumb* ไม่ใช่เกณฑ์ที่พิสูจน์ในงานวิจัย — ดูหลักฐานด้านล่าง)



หลักฐานวิจัย: ทำไม Backtest Sharpe ส่ายๆ ถึงหลอก

งานวิจัยปี 2014^[7] พิสูจน์ว่า แคมีข้อมูลรายวัน 5 ปี แล้วลองสัก ~45 กลยุทธ์ ก็คาดได้โดยเฉลี่ยว่าจะเจออย่างน้อย 1 ตัวที่ in-sample Sharpe = 1.0 ทั้งที่ out-of-sample ที่แท้จริง = 0 — Sharpe สูงสุดที่ "ฟลุค" ได้โตตาม $\sqrt{2 \cdot \ln N}$ ของจำนวนครั้งที่ลอง (N)

ทางแก้: **Deflated Sharpe Ratio**^[8] ปรับ Sharpe ตามจำนวนครั้งที่ลอง + ความยาวข้อมูล + skew/kurtosis ส่วนงานสำรวจ "factor zoo" 316+ ปัจจัย ปี 2016^[9] แนะนำว่าสัญญาณใหม่ควรผ่าน **t-stat > 3.0** ไม่ใช่ 2.0

ระวัง

การจูน parameter หลายๆ ค่าแล้วเก็บตัวที่ดีที่สุด = กระบวนการ overfit ตรงเป๊ะ — และเครื่องมือ retail มักไม่นับ N ให้ ทำให้ Sharpe ที่เห็น "มองโลกในแง่ดีเกินจริง" เสมอ



หลักฐานวิจัย: "Linear ชนะ Neural Net เสมอ" — จริงหรือไม่?

ไม่จริงตามที่เคยเชื่อ. งานวิจัยใหญ่ปี 2020^[10] (หุ้นสหรัฐ 1957–2016) พบว่า **neural net** ตื่นๆ และ **tree** ชนะ **linear** ใน **gross** — long-short Sharpe ≈ 1.35 (NN) เทียบ 0.61 (linear) [วัดแบบ value-weighted ทั้งคู่] เก่งจากการจับ **ปฏิสัมพันธ์ที่ไม่เป็นเส้นตรง**; ที่น่าสนใจคือ NN ตื่น (~3 ชั้น) ชนะ NN ลึก เพราะ finance noise สูง deep net จึง overfit

แต่หลังหักต้นทุน **edge** หด/หาย: งาน ML บน S&P 500 ปี 2017^[11] gross $>0.45\%$ /วัน เหลือ $\sim 0.25\%$ /วันหลังต้นทุน และงานปี 2023^[12] พบว่าความได้เปรียบของ ML หายไปเมื่อตัดหุ้นเล็ก/distressed และคิดต้นทุนจริง

แนวทางรายย่อย เริ่มจากโมเดลง่ายก่อน เทรดไม่ถี่ — ลดทั้ง overfitting และต้นทุน (สอดคล้องกับที่ NN ตื่นชนะ NN ลึก) รายย่อย *replicate* งานวิจัยได้ แต่เก็บกำไร gross หลังต้นทุนแทบไม่ได้; โมเดลซับซ้อน $\neq$ กำไรมากกว่าเสมอ

เรื่องจริง: Pairs Trading — Royal Dutch Shell A vs B (1907-2005)

Shell มีหุ้น 2 classes (Dutch=A, English=B) สัดส่วน 60:40 → ราคาควรเป็น 60:40 ตลอด
จริงๆ: ratio เปี่ยงเบน $\pm 15\%$ เป็นประจำ → pairs traders ทำกำไรหลายทศวรรษ
แต่ **LTCM ก็เทรดคู่นี้แล้วเจิบ** เพราะ ratio กว้างขึ้นก่อน converge → margin call
บทเรียน: Pairs ที่ดีที่สุดก็มี timing risk — ต้อง size ให้รอดถึงวัน converge

ลองคิดดู (บท 18-21)

1. หุ้น A กับ B มี correlation = 0.95 → ใช้ pairs trading ได้ไหม? ทำไม?
2. Spread มี half-life = 3 วัน vs 90 วัน → อันไหนดีกว่าสำหรับ pairs trading?

เฉลย: 1. Correlation สูงไม่พอ! ต้องทดสอบ cointegration — ถ้าไม่ cointegrated spread อาจ drift ไปเรื่อยๆ 2. 3 วันดีกว่ามาก — กลับเร็วกว่า tie up capital น้อยกว่า

สรุป Part V (บท 18-21) — Part 6/9 ✓

- ✓ **Pairs Trading**: Cointegration > Correlation, Z-score entry/exit
- ✓ **OU Process**: θ = speed, Half-life กำหนดว่าคุ้มไหม
- ✓ **Kalman Filter**: Dynamic hedge ratio
- ✓ **Factor Models**: alpha = edge, beta = hedge ออกได้
- ✓ **Market-Neutral**: Long alpha + Short alpha, beta = 0
- ✓ **ML**: Walk-Forward CV (ห้าม K-fold), Overfitting = ศัตรู (Deflated Sharpe, $t > 3$)
- ✓ **รายย่อย+ML**: เริ่มจากโมเดลง่าย (NN ตื้น>ลึก) — ของซับซ้อนชนะแค่ gross ต้นทุนกลืน edge
- ✓ **หลักฐาน decay**: pairs & stat-arb เสื่อมลงหลังปี 2000 — gross $\neq$ net
- ✓ **ทั้งหมดเป็น Lv.4 [Heuristic]** — ไม่ใช่ arb จริง มี statistical edge (และ edge บางลงเรื่อยๆ)



อ้างอิง (References) — Part V

งานวิจัย peer-reviewed ที่ใช้สนับสนุนกลองหลักฐานในบท 18–21 (citation/ปี/วารสาร ตรวจสอบแล้ว) — ใช้เป็นจุดเริ่มต้น ไม่ใช้คำแนะนำการลงทุน

1. Gatev, E., Goetzmann, W. N., & Rouwenhorst, K. G. (2006). "Pairs Trading: Performance of a Relative-Value Arbitrage Rule." *The Review of Financial Studies*, 19(3), 797–827. [link](#)
2. Do, B., & Faff, R. (2010). "Does Simple Pairs Trading Still Work?" *Financial Analysts Journal*, 66(4), 83–95. [link](#)
3. Do, B., & Faff, R. (2012). "Are Pairs Trading Profits Robust to Trading Costs?" *Journal of Financial Research*, 35(2), 261–287. [link](#)
4. Krauss, C. (2017). "Statistical Arbitrage Pairs Trading Strategies: Review and Outlook." *Journal of Economic Surveys*, 31(2), 513–545. [link](#)
5. Avellaneda, M., & Lee, J.-H. (2010). "Statistical Arbitrage in the US Equities Market." *Quantitative Finance*, 10(7), 761–782. [link](#)
6. Palomar, D. P. (2025). *Portfolio Optimization: Theory and Application*, Ch. 15 (Pairs Trading / Kalman). Cambridge University Press. [link](#)
7. Bailey, D., Borwein, J., López de Prado, M., & Zhu, Q. (2014). "Pseudo-Mathematics and Financial Charlatanism: The Effects of Backtest Overfitting on Out-of-Sample Performance." *Notices of the AMS*, 61(5), 458–471. [link](#)
8. Bailey, D., & López de Prado, M. (2014). "The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality." *The Journal of Portfolio Management*, 40(5), 94–107. [link](#)
9. Harvey, C. R., Liu, Y., & Zhu, H. (2016). "...and the Cross-Section of Expected Returns." *The Review of Financial Studies*, 29(1), 5–68. [link](#)
10. Gu, S., Kelly, B., & Xiu, D. (2020). "Empirical Asset Pricing via Machine Learning." *The Review of Financial Studies*, 33(5), 2223–2273. [link](#)
11. Krauss, C., Do, X. A., & Huck, N. (2017). "Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500." *European Journal of Operational Research*, 259(2), 689–702. [link](#)
12. Avramov, D., Cheng, S., & Metzker, L. (2023). "Machine Learning vs. Economic Restrictions: Evidence from Stock Return Predictability." *Management Science*, 69(5), 2587–2619. [link](#)
13. Engle, R. F., & Granger, C. W. J. (1987). "Co-integration and Error Correction: Representation, Estimation, and Testing." *Econometrica*, 55(2), 251–276. [link](#)

วิธีอ่านตัวเลขในงานวิจัยเหล่านี้: ผลตอบแทน ~11%/ปี ของ [1] และ Sharpe จาก [5], [10] เป็นค่า *ก่อนหักต้นทุน* (*gross*) และมักเป็น out-of-sample บนทั้ง universe — **ผลจริงหลังต้นทุนของรายย่อยจะต่ำกว่านี้มาก** ให้ใช้เป็น "เพดานบน" ไม่ใช่ค่าที่คาดหวังได้จริง; ส่วนเกณฑ์ "Sharpe 5 vs 1.5" เป็น rule of thumb ไม่ใช่ผลลัพธ์ใน [7]–[8]

จบ Part V

Part VI: Merger & Event Arbitrage