

คณิตศาสตร์สำหรับ Options

Mathematics for Options Trading

รากฐานคณิตศาสตร์ที่จำเป็นสำหรับการเข้าใจ Black-Scholes, Greeks, Volatility และ Statistical Arbitrage — เรียนรู้จากอุปมา สู่เหตุ-ผล สู่ตัวเลขจริง

7 ส่วน · 16 บท · ครอบคลุมตั้งแต่พื้นฐานจนถึง Monte Carlo

วิธีใช้หนังสือเล่มนี้

แนวทางการอ่าน 3 ชั้น

ทุกคนที่ใช้โครงสร้างเดียวกัน: อุปมา (Analogy) → เหตุ-ผล (Cause-Effect) → ตัวเลขจริง (Worked Numbers)

- ชั้น 1 — อุปมา 🔍: เชื่อมโยงกับชีวิตประจำวัน ก่อนเจอสูตร
- ชั้น 2 — เหตุ-ผล →: อธิบายว่า "ทำไม" สูตรถึงมีรูปแบบนั้น
- ชั้น 3 — ตัวเลขจริง 🧮: คำนวณตัวอย่างด้วยตัวเลขจริงจากตลาด

กล่องพิเศษ

- 🏛️ Quant/Trader's View: วิธีที่ practitioners ใช้ concept นี้จริงๆ บน trading desk
- ⚠️ Model Risk: ข้อจำกัดและสมมติฐานที่อาจทำให้ model พลาดในสถานการณ์จริง
- ✓ เชื่อมกับ Options: จุดเชื่อมต่อระหว่างคณิตศาสตร์กับ options pricing/trading

สารบัญ

ส่วนที่ I

เครื่องมือพื้นฐาน — "ภาษาที่ใช้พูดเรื่อง Options"

math-part1

บท 1 เครื่องมือพื้นฐาน — เปอร์เซ็นต์, ฟังก์ชัน, Slope, max(), Piecewise

บท 2 ฟิสิกณิตและสมการ — Put-Call Parity, Arbitrage Bounds, Synthetic Positions

บท 3 เลขยกกำลัง, ลอการิทึม, ดอกเบี้ย — e, ln, PV(K), Log Return

ส่วนที่ II

สถิติและความน่าจะเป็น — "วัดความไม่แน่นอน"

math-part2

บท 4 สถิติพื้นฐาน — Mean, Variance, σ (Volatility), Correlation

บท 5 ความน่าจะเป็น — Axioms, Bayes, Expected Value, Variance ของ r.v.

บท 6 Distributions — Binomial, Normal, Z-Score, Lognormal, CLT, Fat Tails

ส่วนที่ III

แคลคูลัส — "ภาษาของ Greeks"

math-part3

บท 7 แคลคูลัส — Limit, Derivative, Greeks ($\Delta, \Gamma, \Theta, \nu, \rho$), Integration, Taylor Series

ส่วนที่ IV

Linear Algebra + Regression — "จัดการหลายตัวแปร"

math-part4

บท 8 Linear Algebra — Vectors, Matrices, $w^T \Sigma w$, Inverse, Eigenvalues, PD Matrix

บท 9 Regression — OLS, Diagnostics, Multiple Regression, Multicollinearity, R^2 , Vol Surface

ส่วนที่ V

การหาค่าเหมาะที่สุด — "จัดพอร์ตอย่างเหมาะสม"

math-part5

บท 10 Linear Programming — Corner Points, Dual, Shadow Price, ILP

บท 11 Nonlinear Optimization — Gradient Descent, Lagrange, KKT, Convex, QP/Markowitz

ส่วนที่ VI

Time Series + Stochastic Calculus — "โลกที่สับสน"

math-part6

บท 12 Time Series — Autocorrelation, AR/MA/ARMA, EWMA, GARCH, Mean Reversion

บท 13 วิธีเชิงตัวเลข — Bisection, Newton-Raphson (IV Solver), Numerical Diff.

บท 14 Stochastic Processes — Random Walk, GBM, Brownian Motion, Ito's Lemma, BS PDE

ส่วนที่ VII

Black-Scholes ครบ + Monte Carlo — "สูตรจริง"

math-part7

บท 15 Black-Scholes ฉบับเต็ม — สูตร Call/Put, d_1/d_2 , Greeks ครบชุด, ข้อจำกัด

บท 16 Monte Carlo Simulation — GBM Paths, Asian Options, Variance Reduction, Control Variates

ภาคผนวก

สะพานสู่ Stat Arb + สูตรอ้างอิง + คำศัพท์

Appendices

Bridge จากคณิตศาสตร์สู่ Statistical Arbitrage — แผนที่เชื่อมบทเรียน

App A สูตรอ้างอิงฉบับย่อ — Formula Quick Reference

App B คำศัพท์ — Glossary (EN-TH)

แผนที่ความรู้ — Prerequisites

ก่อนอ่านเล่มนี้ต้องรู้

- คณิตศาสตร์ ม.ปลาย (ฟังก์ชัน, log, e)
- ความน่าจะเป็นพื้นฐาน
- Options คืออะไร (Call, Put, Strike)

หลังอ่านเล่มนี้จะได้

- อ่านสูตร Black-Scholes ออก
- เข้าใจ Greeks ทุกตัว
- ทำ Delta Hedging ได้
- implement IV Solver ได้

ต่อยอดไปยัง

- หนังสือ Statistical Arbitrage
- Options pricing models
- Quantitative finance courses
- Risk management (VaR, CVaR)

แผนการอ่าน — Reading Paths

เป้าหมาย	บทที่แนะนำ	เวลาโดยประมาณ
เข้าใจ Black-Scholes	1, 3, 6, 7 → บท 15	~8 ชม.
เข้าใจ Greeks ครบ	1, 3, 7 → บท 15 §15.3b	~5 ชม.
Volatility Modeling	4, 6 → บท 12 (GARCH)	~4 ชม.
Portfolio Optimization	4, 8 → บท 10, 11	~6 ชม.
Monte Carlo Pricing	6 → บท 14, 16	~4 ชม.
ครบทุกบท	บทที่ 1–16 ตามลำดับ	~40 ชม.

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part I: เครื่องมือพื้นฐาน — อ่านจบแล้วอ่าน Payoff Chart ได้ (v2)

บทที่ 1–3: ฟังก์ชัน · ความชัน · $\max()$ · พีชคณิต · ดอกเบี้ยทบต้น · $PV(K)$

เรียนแบบ 3 ชั้น: อุปมา → เหตุ → ผล → ตัวเลขจริง

บทที่ 1: เครื่องมือพื้นฐาน — "ภาษาที่ใช้พูดเรื่อง Options"

ก่อนจะเข้าใจ Options ได้ คุณต้องอ่าน "ภาษา" ที่ใช้พูดเรื่องนี้ให้ออกก่อน บทนี้สอนเครื่องมือคณิตศาสตร์พื้นฐานที่ปรากฏในทุกสูตรของ Options

1.1 เปอร์เซนต์และอัตราส่วน

 **อุปมา: ราคาของเปลี่ยน**

หุ้น ฿100 → ฿120 — ขึ้นไปกี่เปอร์เซ็นต์?

ได้กำไร ฿20 และ "ฐาน" คือ ฿100 → $\frac{20}{100} = 20\%$

ทำไมต้องหารด้วยราคาเก่า? เพราะเราอยากรู้ว่า "ขึ้น X% จากจุดเริ่ม" — ฐานคือที่ออกเดินทาง

$$\% \text{ Change} = \frac{\text{ค่าใหม่} - \text{ค่าเก่า}}{\text{ค่าเก่า}} \times 100$$

หาส่วนต่าง (ค่าใหม่-ค่าเก่า)

→

หารด้วยฐาน (ค่าเก่า)

→

คูณ 100 → เป็น %

กับดัก: ตก 50% แล้วขึ้น 50% ≠ กลับที่เดิม!


฿100 ตก 50% = ฿50 → ขึ้น 50% = ฿75 ← **ไม่ใช่ ฿100!**

ต้องขึ้น 100% จาก ฿50 (= ฿50 กำไร) ถึงจะกลับ ฿100

สาเหตุ: % ตอนขึ้นคิดจาก "ฐานที่เล็กลงแล้ว" — ฐานเปลี่ยน ผลลัพธ์จึงไม่สมมาตร

ราคาลดลง	ต้องขึ้นกลับ	เหตุผล
-10%	+11.1%	฿90 → ต้องขึ้น $10/90 = 11.1\%$
-25%	+33.3%	฿75 → ต้องขึ้น $25/75 = 33.3\%$
-50%	+100%	฿50 → ต้องขึ้น $50/50 = 100\%$
-75%	+300%	฿25 → ต้องขึ้น $75/25 = 300\%$
-90%	+900%	฿10 → ต้องขึ้น $90/10 = 900\%$

Loss Asymmetry: Drop vs Recovery Needed (e.g. -50% drop requires +100% to recover!)



Drop vs recovery needed — -50% requires +100% to recover

เชื่อมกับ Options — Log Return แก้ปัญหานี้

ความไม่สมมาตรนี้ทำให้วิเคราะห์ยาก → Options ใช้ **log return** แทน simple return

log return สมมาตร: ขึ้น 40.55% (log) แล้วลง 40.55% (log) กลับที่เดิมพอดี

จะเรียนละเอียดในบท 3.6

1.2 ฟังก์ชันและกราฟ

🔍 อุปมา: เครื่องทำกาแฟ

เครื่องทำกาแฟ: ใส่เมล็ดกาแฟ (input = x) → เครื่องบด (function = f) → ได้กาแฟ (output = $f(x)$)

กฎของฟังก์ชัน: เมล็ดเดียวกันได้รสเดียวกันเสมอ — ไม่มีวันใส่ Colombia Supremo แล้วได้ชาเขียว


ฟังก์ชันใน Options: ใส่ราคาหุ้น S (input) → payoff formula (function) → ได้กำไร/ขาดทุน (output)

$$f(x) = \text{”กลองดำ”} : \text{input } x \longrightarrow \text{output } f(x)$$

ทุก input มี output เดียว (แต่ output เดียวกันอาจมาจากหลาย input)

ตัวอย่าง: $f(x) = 2x - 100$

x (ราคาหุ้น)	$f(x) = 2x - 100$	จุดบนกราฟ	ความหมาย
0	-100	(0, -100)	ขาดทุน ฿100
50	0	(50, 0)	Break-even!
100	100	(100, 100)	กำไร ฿100



$f(x) = 2x - 100$: slope=2, break-even at $x=50$

เชื่อมกับ Options

Payoff(S) = $\max(0, S - K)$ – Premium คือฟังก์ชันที่รับ $S \rightarrow$ คืนกำไร/ขาดทุน
 ทุก Payoff Chart คือกราฟของฟังก์ชันนี้ เพียงแต่ $\max()$ ทำให้เส้นกราฟ "หักศอก"

1.3 เส้นตรงและความชัน (Slope)

🔍 อุปมา: ทางลาดจักรยาน

Slope = "ขึ้นเท่าไรต่อเดิน 1 เมตร" — ทางลาดชัน slope สูง ทางแบนราบ slope = 0

ใน Options: **slope ของ payoff chart คือ Delta**

Payoff ขึ้น ฿1 ต่อราคาหุ้นที่ขึ้น ฿1 $\rightarrow$ slope = +1 $\rightarrow$ Delta = 1.0

$$y = mx + b \quad m = \frac{\Delta y}{\Delta x} = \frac{y_2 - y_1}{x_2 - x_1}$$

ทำไม slope = $\Delta y / \Delta x$?


คิดแบบ "ถ้าเดินหน้า Δx หน่วย ขึ้นสูง Δy หน่วย"

ยิ่ง Δy มาก ต่อ Δx น้อย $\rightarrow$ slope ยิ่งชัน

ยิ่ง Δx มาก ต่อ Δy น้อย $\rightarrow$ slope ยิ่งราบ

อัตราส่วน $\Delta y / \Delta x$ วัด "ความชัน" ได้พอดี — ไม่ขึ้นกับว่าเดินไปเท่าไร

Slope	ความหมาย	ใน Options
$m = +1$	ขึ้น $\$1$ ต่อทุก $\$1$ ที่เพิ่ม	Long Call หลัง Strike (ถ้าไม่จำกัด)
$m = -1$	ลง $\$1$ ต่อทุก $\$1$ ที่เพิ่ม	Short Call หลัง Strike (ขาดทุนไม่จำกัด)
$m = 0$	แบนราบ ไม่เปลี่ยน	Payoff ก่อน Strike (flat zone)
$m = +0.5$	ขึ้น $\$0.50$ ต่อ $\$1$	Delta ≈ 0.5 (ATM option)



Slope $m = \Delta y / \Delta x$ — positive, zero, and negative slopes

เชื่อมกับ Options — Delta = Slope!

Long Call หลัง Strike: slope = +1 → ถ้าไรเพิ่ม B1 ต่อราคาขึ้น B1

Short Call หลัง Strike: slope = -1 → ขาดทุนเพิ่ม B1 ต่อราคาขึ้น B1

Delta ของ Option = slope ของ payoff curve ณ จุดนั้น (จะเรียนในบท 7)

1.4 ฟังก์ชัน max() — หัวใจของ Options Payoff

🔍 อุปมา: ประกันรถยนต์

ถ้ารถเกิดอุบัติเหตุ บริษัทประกันจ่าย = $\max(0, \text{ค่าซ่อม} - \text{ค่าเสียหายส่วนแรก})$

ถ้าค่าซ่อมน้อยกว่า deductible → ได้ 0 (คุ้มครองไม่เพียงพอ)

ถ้าค่าซ่อมเกิน deductible → ได้เงินชดเชย


Call Option Payoff = $\max(0, S - K)$ ทำงานเหมือนกัน:

ถ้า $S < K$ → ไม่ใช้สิทธิ์ → Payoff = 0

ถ้า $S > K$ → ใช้สิทธิ์ → Payoff = $S - K$

$$\max(a, b) = \text{ค่าที่มากกว่า} \quad \max(0, x) = \begin{cases} 0 & x \leq 0 \\ x & x > 0 \end{cases}$$

x	$\max(0, x)$	ความหมายใน Options
-20	0	S ต่ำกว่า K → ไม่ใช้สิทธิ์
0	0	จุดหักศอก ($S = K$, ATM)
+10	10	S สูงกว่า K 10 บาท → ใช้สิทธิ์
+25	25	S สูงกว่า K 25 บาท → กำไรยิ่งมาก



Long Call: $\max(0, S-K) - \text{Premium}$ | K=100, Premium=5

เชื่อมกับ Options

$\max(0, S - K) = \text{Intrinsic Value}$ ของ Call Option

จุดหักศอกในกราฟทุก options คือ "จุดที่ $\max()$ เปลี่ยนจาก 0 เป็น $S-K$ "

Long Call: $\max(0, S-K) - P$ | **Long Put:** $\max(0, K-S) - P$

1.5 ค่าสัมบูรณ์และการกลับเครื่องหมาย

🔍 อุปมา: กระจก

$-f(x)$ คือกราฟ $f(x)$ ที่สะท้อนผ่านกระจก (แกน x)

Long Call (ถ้าไม่จำกัด ขาดทุนจำกัด) → พลิก → Short Call (ถ้าจำกัด ขาดทุนไม่จำกัด)

ไม่ต้องจำรูปร่างของ Short position ใหม่ — แค่พลิกกราฟ Long position!


Long position = $f(S)$

→

Short position = $-f(S)$

→

พลิกผ่านแกน x ทุกจุด



Short Call = mirror of Long Call (zero-sum game)

1.6 Piecewise Functions — ฟังก์ชันแบ่งช่วง

🔍 อุปมา: อัตราค่าไฟฟ้า

ค่าไฟฟ้าในไทย: ใช้ไม่เกิน 150 หน่วย คิด ฿1.50/หน่วย


ใช้เกิน 150 หน่วย (ส่วนเกิน) คิด ฿2.50/หน่วย

— สูตรเปลี่ยนตามช่วง = Piecewise function!

Options ทุกกลยุทธ์มีรูปแบบนี้ เพราะ payoff เปลี่ยนรูปแบบเมื่อราคาหุ้นผ่าน Strike

ตัวอย่าง: Bull Call Spread ($K_1=90$, $K_2=110$, Net Premium=5)

$$\text{Payoff} = \begin{cases} -5 & S < 90 \\ S - 90 - 5 & 90 \leq S \leq 110 \\ 15 & S > 110 \end{cases}$$

Bull Call Spread $K_1=90$, $K_2=110$ — limited profit, limited loss

เชื่อมกับ Options

ทุกกลยุทธ์ Options เป็น piecewise linear function!

Long Call = 2 ช่วง | Spread = 3 ช่วง | Iron Condor = 5 ช่วง | Butterfly = 5 ช่วง

เข้าใจ piecewise = เข้าใจ payoff chart ทุกกลยุทธ์

1.7 สัญลักษณ์คณิตศาสตร์ที่ใช้บ่อย

สัญลักษณ์	ชื่อ	ความหมาย	ใน Options
Σ	Sigma	บวกทุกค่า	Payoff = Σ payoff ของแต่ละขา
Π	Pi product	คูณทุกค่า	$(1+r_1)(1+r_2)\dots(1+r_n)$
∂	partial	อนุพันธ์ย่อย	Delta = $\partial V / \partial S$
∞	infinity	อนันต์	Max Profit = ∞ (Long Call)
$\sqrt{}$	square root	รากที่สอง	$\sigma = \sqrt{\text{Var}}$, vol $\times \sqrt{T}$
Δ	Delta	การเปลี่ยนแปลง	ΔS = ราคาหุ้นเปลี่ยนไป
$\approx$	approximately	ประมาณ	$e \approx 2.71828$

สรุปบทที่ 1

- ✓ % change = ความเปลี่ยนแปลงสัมพัทธ์ — ตก 50% ต้องขึ้น 100% กลับ
- ✓ ฟังก์ชัน $f(x)$: input เดียวกัน output เดียวกันเสมอ
- ✓ Slope = Delta ของ payoff
- ✓ $\max(0, S-K)$ = ที่มาของกราฟหักศอก ทุก options
- ✓ Short = $-1 \times$ Long = พลิกกราฟ
- ✓ Piecewise = ทุกกลยุทธ์ Options

โจทย์ฝึกหัด บทที่ 1

ข้อ 1. หุ้น B200 ตก 40% แล้วขึ้น 30%

(ก) ราคาสุดท้ายคือเท่าไร? (ข) ต้องขึ้นอีกกี่ % จากราคาสุดท้ายเพื่อกลับ B200?

► ดูเฉลย

ข้อ 2. Long Put $K=100$, Premium=4

เขียนสูตร Payoff และหา (ก) Break-even (ข) Payoff ถ้า $S=85$ (ค) Payoff ถ้า $S=105$

► ดูเฉลย

ข้อ 3. Bull Call Spread: Long Call $K=90$ ($P=12$), Short Call $K=110$ ($P=4$)

(ก) Net Premium (ข) Max Profit (ค) Max Loss (ง) Break-even

► ดูเฉลย

บทที่ 2: พีชคณิตและสมการ — "จัดรูป Put-Call Parity ได้เอง"

Put-Call Parity คือสมการสำคัญที่สุดในโลก Options — ถ้าจัดรูปสมการได้ คุณจะสร้าง Synthetic Positions ได้ทุกแบบโดยไม่ต้องจำ

2.1 สมการเชิงเส้น — หา Break-even

🔍 อุปมา: ตาชั่ง

สมการ = ตาชั่งที่สมดุล — ทำอะไรข้างหนึ่ง ต้องทำเหมือนกันกับอีกข้าง
ถ้าเอา 3 ออกจากข้างซ้าย → ต้องเอา 3 ออกจากข้างขวาด้วย มิฉะนั้นตาชั่งเอียง

หา Break-even ของ Long Call: Payoff = 0

1 เริ่ม: $0 = \max(0, S - K) - P \rightarrow$ ที่ BE: $S > K$ ดังนั้น $\max(0, S - K) = S - K$

2 แทน: $0 = S - K - P$

3 ย้าย K และ P: $S = K + P$

4 ตัวอย่าง: $K=100, P=5 \rightarrow BE = 105$

2.2 Put-Call Parity — สมการที่ทรงพลังที่สุดใน Options

🔍 อุปมา: ความสมดุลของตลาด

ถ้า "Long Call + Bond" มีราคาต่างจาก "Long Put + Stock" → นักอาร์บิทราจจะซื้อตัวที่ถูก ขายตัวที่แพง จนราคาปรับเท่ากัน

ดังนั้น $C + PV(K) = P + S$ ต้องเป็นจริงเสมอ (ไม่งั้นกำไรฟรีจะเกิดขึ้น)

$$C + PV(K) = P + S \quad \Longleftrightarrow \quad C + Ke^{-rT} = P + S$$

🔍 ทำไมสมการถึงเป็นแบบนี้?

ฝั่งซ้าย ($C + PV(K)$): ซื้อ Call + ฝากเงิน $PV(K)$ ไว้ (ครบอายุได้ K พอดี)

ฝั่งขวา ($P + S$): ซื้อ Put + ซื้อหุ้น

ทั้งสองฝั่งมี **payoff** เดียวกัน เมื่อ option expire:

- ถ้า $S > K$: ฝั่งซ้าย Call = $S - K$, Bond = $K \rightarrow$ รวม S | ฝั่งขวา Put = 0 , หุ้น = $S \rightarrow$ รวม $S \checkmark$
- ถ้า $S < K$: ฝั่งซ้าย Call = 0 , Bond = $K \rightarrow$ รวม K | ฝั่งขวา Put = $K - S$, หุ้น = $S \rightarrow$ รวม $K \checkmark$

จากสมการเดียว จัดรูปใหม่ได้ทุก Synthetic Position:

ต้องการหา	จัดรูปสมการ	Synthetic Position
S	$S = C - P + PV(K)$	Long Stock = Long Call + Short Put + Bond
C	$C = P + S - PV(K)$	Long Call = Long Put + Long Stock - Bond
P	$P = C - S + PV(K)$	Long Put = Long Call + Short Stock + Bond
$PV(K)$	$PV(K) = P + S - C$	Bond = Long Put + Long Stock + Short Call

$$\begin{array}{|c|} \hline \mathbf{C + PV(K)} \\ \hline \text{Long Call + Bond} \\ \hline \end{array} = \begin{array}{|c|} \hline \mathbf{P + S} \\ \hline \text{Long Put + Stock} \\ \hline \end{array}$$

↓ จัดรูปใหม่ได้ ↓

$$\begin{array}{|c|} \hline \mathbf{S = C - P + PV(K)} \\ \hline \end{array}
 \begin{array}{|c|} \hline \mathbf{C = P + S - PV(K)} \\ \hline \end{array}
 \begin{array}{|c|} \hline \mathbf{P = C - S + PV(K)} \\ \hline \end{array}
 \begin{array}{|c|} \hline \mathbf{PV(K) = P + S - C} \\ \hline \end{array}$$

Synthetic Stock | Synthetic Call | Synthetic Put | Synthetic Bond

แผนภาพ: Put-Call Parity — Synthetic Positions ทั้ง 4 จาก $C - P = S - PV(K)$

เชื่อมกับ Options

ทุก Synthetic Position มาจากการย้ายข้างสมการ Put-Call Parity!

ไม่ต้องจำว่า Synthetic Stock ประกอบจากอะไร — แค่จัดรูปสมการก็ได้คำตอบ

2.3 ระบบสมการ — Zero-Cost Collar

ตัวอย่าง: หา Strike ของ Call ที่ทำให้ Zero-Cost Collar

ต้องการ Collar ราคา ฿0: ซื้อ Put K=95 ราคา ฿3

ต้องขาย Call ที่ Strike ไหนให้ได้ ฿3 พอดี?

→ ค้นหา Call Strike ที่มี Premium = ฿3 จาก options chain

(สมการ: $\text{Premium}(\text{Call ที่ } K_c) = \text{฿3}$)

วิธี Substitution:

$$\begin{cases} x + y = 10 \\ 2x - y = 5 \end{cases} \implies x = 5, y = 5$$

2.4 อสมการ — Arbitrage Bounds

กฎสำคัญ: คูณ/หารด้วยจำนวนลบ → กลับทิศเครื่องหมาย!

$-2x > 6 \rightarrow$ หารด้วย $-2 \rightarrow x < -3$ (เครื่องหมายกลับ!)

เชื่อมกับ Options — American Put-Call Parity เป็นอสมการ

$$S - K \leq C - P \leq S - K \cdot e^{-rT}$$

American Options สามารถ early exercise ได้ → equality กลายเป็น inequality

ถ้า $C - P$ ออกนอกช่วงนี้ → มี arbitrage!

สรุปบทที่ 2

- ✓ แก่สมการหา Break-even: Payoff = 0 → $S = K + P$ (Call) หรือ $K - P$ (Put)
- ✓ **Put-Call Parity: $C + PV(K) = P + S$** → จัดรูปได้ทุก Synthetic Position
- ✓ ระบบสมการ: หาค่าที่เหมาะสม (Zero-Cost Collar, Strike selection)
- ✓ อสมการ: Arbitrage bounds ของ American Options

โจทย์ฝึกหัด บทที่ 2

ข้อ 1. Long Straddle: Long Call K=100 (P=8) + Long Put K=100 (P=6)

(ก) Net Premium (ข) Break-even ด้านบน (ค) Break-even ด้านล่าง

► ดูเฉลย

ข้อ 2. Put-Call Parity: $S = \text{฿}500$, $C(K=500) = \text{฿}30$, $r = 4\%$, $T = 0.5$ ปี

(ก) $PV(K)$ (ข) ราคา Put ที่ถูกต้อง (ตาม PCP)

► ดูเฉลย

ข้อ 3. ต้องการ Synthetic Long Stock จาก Options เท่านั้น

บอกว่าต้องทำอะไรและแต่ละตำแหน่งมี payoff อย่างไร

► ดูเฉลย

บทที่ 3: เลขยกกำลัง ลอการิทึม ดอกเบี้ย — "เข้าใจ PV(K)"

ใน Put-Call Parity มีตัว $PV(K) = K \times e^{-rT}$ — ถ้าไม่เข้าใจ e, ln, ดอกเบี้ยทบต้น ก็อ่าน PV(K) ไม่ออก บทนี้ อธิบายทีละขั้น

3.1 เลขยกกำลัง (Exponents)

🔍 อุปมา: พับกระดาษ

พับกระดาษ 1 ครั้ง: หนา 2 เท่า $\rightarrow 2^1 = 2$

พับ 2 ครั้ง: 4 เท่า $\rightarrow 2^2 = 4$

พับ 10 ครั้ง: 1,024 เท่า $\rightarrow 2^{10} = 1,024$

พับ 42 ครั้ง: หนาเกินระยะทางจากโลกถึงดวงจันทร์ $\rightarrow$ growth แบบ exponential ทรงพลังมาก

กฎ	สูตร	ตัวอย่าง	ทำไม?
คูณฐานเดียวกัน	$a^m \times a^n = a^{m+n}$	$2^3 \times 2^4 = 2^7 = 128$	นับจำนวนคูณรวมกัน
หารฐานเดียวกัน	$a^m / a^n = a^{m-n}$	$2^5 / 2^2 = 2^3 = 8$	หักออกจำนวนคูณ
ยกกำลังซ้อน	$(a^m)^n = a^{mn}$	$(2^3)^2 = 2^6 = 64$	คูณ m, n ครั้ง
ยกกำลัง 0	$a^0 = 1$	$5^0 = 1$	$a^n / a^n = a^{n-n} = a^0 = 1$
ยกกำลังลบ	$a^{-n} = 1/a^n$	$2^{-3} = 1/8$	หมายถึง "หาร" n ครั้ง

เชื่อมกับ Options

$(1 + r)^n$ = ดอกเบี้ยทบต้น n ปี $\rightarrow e^{rT}$ = ดอกเบี้ยทบต้นแบบ continuous

e^{-rT} = "ลดค่า" ฝั่งตรงข้าม $\rightarrow PV(K) = K \times e^{-rT}$

3.2 Geometric Series — ดอกเบี้ยทบต้นหลายงวด

🔍 อุปมา: ออมทรัพย์รายปี

ฝากเงินปีละ ฿1,000 ดอกเบี้ย 5%/ปี — เงินแต่ละก้อนทบต้นต่างจำนวนปี:

ก้อนแรก (ฝากปีที่ 1) ทบต้น 5 ปี: $฿1,000 \times 1.05^5$

ก้อนที่ 2 (ฝากปีที่ 2) ทบต้น 4 ปี: $฿1,000 \times 1.05^4$

... รวมเป็น Geometric Series!

ปี	ฝาก	มูลค่ารวมปลายปี
1	฿1,000	$฿1,000 \times 1.05 = ฿1,050$
2	฿1,000	$(1,050 + 1,000) \times 1.05 = ฿2,153$
3	฿1,000	$(2,153 + 1,000) \times 1.05 = ฿3,310$
5	฿1,000	฿5,802 (ฝากรวม ฿5,000 แต่ได้ ฿5,802)

$$\text{Geometric Series} = a \cdot \frac{1 - r^n}{1 - r} \quad (r \neq 1)$$

3.3 ดอกเบี้ยทบต้น — ทำไมถึงมี e

🔍 อุปมา: ทบต้นถี่ขึ้นเรื่อยๆ

ฝาก ฿10,000 ดอกเบี้ย 10%/ปี แต่เปลี่ยนความถี่ทบต้น:


ทบต้นรายปี: $฿10,000 \times 1.1 = ฿11,000$

ทบต้นราย 6 เดือน: $฿10,000 \times (1 + 0.1/2)^2 = ฿11,025$

ทบต้นรายวัน: $฿10,000 \times (1 + 0.1/365)^{365} = ฿11,052$

ทบต้นทุกวินาที: $฿10,000 \times e^{0.1} = ฿11,052 \leftarrow$ ค่าสูงสุดที่เป็นไปได้!

วิธีทบต้น	สูตร	ผลลัพธ์ 10 ปี
เชิงเดียว	$10,000 \times (1 + 0.1 \times 10)$	฿20,000
ทบต้นรายปี	$10,000 \times (1.1)^{10}$	฿25,937
ทบต้นรายเดือน	$10,000 \times (1 + 0.1/12)^{120}$	฿27,070
Continuous (e^{rT})	$10,000 \times e^{0.1 \times 10}$	฿27,183 (ค่าสูงสุด)



$FV = PV \times e^{rT}$ — exponential compounding at different rates

3.4 จำนวน e — ที่มาจากดอกเบี้ย

🔍 ทำไม e ถึงเท่ากับ 2.71828...?

สมมติฝาก ฿1 ดอกเบี้ย 100%/ปี ถ้าทบต้น n ครั้งต่อปี:

$$FV = (1 + 1/n)^n$$

เมื่อ $n \rightarrow \infty$ (ทบต้นถี่ขึ้นเรื่อยๆ) ค่านี้ converge ไปที่ $e = 2.71828...$

e ไม่ใช่ตัวเลขลอยๆ — มันคือ "ขีดจำกัดของการทบต้นถี่ที่สุด"

n (ความถี่ทบต้น)	$(1 + 1/n)^n$	เข้าใจ e
1 (รายปี)	2.000000	
12 (รายเดือน)	2.613035	
365 (รายวัน)	2.714567	ใกล้มากแล้ว!
10,000	2.718146	
∞ (continuous)	$e = 2.718282...$	ค่าสูงสุด!

$$FV = PV \cdot e^{rT} \quad PV = FV \cdot e^{-rT}$$

เชื่อมกับ Options — PV(K) ใน Put-Call Parity!

$$PV(K) = K \times e^{-rT}$$

ตัวอย่าง: $K=100$, $r=5\%$, $T=1$ ปี

$$PV(K) = 100 \times e^{-0.05} = 100 \times 0.9512 = \text{฿}95.12$$

หมายถึง: ฝาก ฿95.12 วันนี้ที่ $r=5\% \rightarrow$ ครบ 1 ปีได้ ฿100 พอดี

3.5 ลอการิทึม — ฟังก์ชันย้อนกลับของ e

 **อุปมา: ย้อนเวลา**

$e^x = y$ คือ "เดินหน้า" — ใส่ x ได้ y

$\ln(y) = x$ คือ "ย้อนกลับ" — ใส่ y กลับมาได้ x

เหมือน: คูณ 3 $\rightarrow$ ย้อนกลับด้วยหาร 3

ยกกำลัง $e \rightarrow$ ย้อนกลับด้วย $\ln$

$$\ln(x) = y \iff e^y = x$$

$$\ln(a \cdot b) = \ln a + \ln b \quad \ln\left(\frac{a}{b}\right) = \ln a - \ln b \quad \ln(a^n) = n \ln a$$


 **ทำไมกฎ $\ln(axb) = \ln(a) + \ln(b)$ จึงเป็นจริง?**

ถ้า $\ln(a) = x$ และ $\ln(b) = y \rightarrow$ แปลว่า $a = e^x$ และ $b = e^y$

$a \times b = e^x \times e^y = e^{x+y}$ (กฎเลขยกกำลัง: คูณฐานเดียวกัน บวก exponent)

ดังนั้น $\ln(a \times b) = x + y = \ln(a) + \ln(b) \checkmark$

x	$\ln(x)$	ตรวจ $e^{\ln(x)} = x$
1	0	$e^0 = 1 \checkmark$
$e \approx 2.718$	1	$e^1 = e \checkmark$
10	2.303	$e^{2.303} \approx 10 \checkmark$
100	4.605	$e^{4.605} \approx 100 \checkmark$



$\ln(x)$ = inverse of e^x ; $\ln(S/K)$ = log return in Black-Scholes

3.6 Simple Return vs Log Return — ทำไม Options ใช้ $\ln$

🔍 อุปมา: การวัดระยะทาง

Simple return เหมือนวัดระยะทางจากจุดอ้างอิงแบบสัมบูรณ์ → ฐานเปลี่ยนทุกครั้ง
 Log return เหมือนวัดความเปลี่ยนแปลงใน "สเกล log" → บวกกันข้ามเวลาได้เลย

ตัวอย่างง่ายๆ: เดินหน้า 5 ก้าว แล้วถอยหลัง 5 ก้าว = กลับที่เดิม
 Log return ทำงานแบบนี้ได้ Simple return ทำไม่ได้!

$$R = \frac{S_1 - S_0}{S_0} \quad r = \ln\left(\frac{S_1}{S_0}\right) = \ln S_1 - \ln S_0$$

การเคลื่อนไหว	Simple Return	Log Return	ต่างกัน?
B100 → B110	+10.00%	+9.53%	ใกล้เคียง (ขยับน้อย)
B100 → B150	+50.00%	+40.55%	เริ่มต่าง
B100 → B200	+100.00%	+69.31%	ต่างมาก
B100 → B50	-50.00%	-69.31%	สมมาตรกับ +100%!

เหตุผลที่ 1: บวกกันข้ามเวลาได้

฿100 → ฿110 (+10%) → ฿99 (-10%) ≠ กลับที่เดิม! ได้ -1% (Simple return ผิด)

$\ln(110/100) + \ln(99/110) = \ln(99/100) = -1.005\%$ ← **ถูกต้อง**

$r(0 \rightarrow 2) = r(0 \rightarrow 1) + r(1 \rightarrow 2)$ ← Simple return ทำแบบนี้ไม่ได้

เหตุผลที่ 2: สมมาตร

Simple: ขึ้น 50% แล้วลง 50% = ฿75 ≠ ฿100 (asymmetric!)

Log: ขึ้น 40.55% (log) แล้วลง 40.55% (log) = กลับที่เดิมพอดี ✓

$\ln(200/100) = +69.31\%$ และ $\ln(50/100) = -69.31\%$ ← สมมาตรเป๊ะ

เหตุผลที่ 3: เป็น Normal Distribution ได้

Simple return มีขอบล่างที่ -100% → ไม่สมมาตร → ไม่เป็น Normal

Log return อยู่ใน $(-\infty, +\infty)$ → สมมาตร → **เป็น Normal Distribution ได้!**

→ log return ~ Normal → ราคาหุ้น ~ Lognormal (บทที่ 6)

เชื่อมกับ Options — ที่มาของ $\ln(S/K)$ ใน Black-Scholes

ใน d_1 ของ BS: $d_1 = [\ln(S/K) + (r + \sigma^2/2)T] / (\sigma\sqrt{T})$

$\ln(S/K)$ = log return จาก K ไป S = "ราคาหุ้น 'ห่าง' จาก Strike กี่หน่วย log"

นี่คือเหตุผลที่ Black-Scholes ใช้ $\ln$ ไม่ใช่ simple %

** Quant Desk: Log Return คือภาษากลางของ Vol Trading**

Traders รายงาน PnL ใน **log return** เพราะบวกข้ามวันได้ทันที:

$r_{\text{weekly}} = r_{\text{Mon}} + r_{\text{Tue}} + r_{\text{Wed}} + r_{\text{Thu}} + r_{\text{Fri}}$ — บวกตรงๆ ถูกเป๊ะ ไม่ต้องปรับ base

Historical vol (σ) = std ของ daily log returns $\times \sqrt{252}$ → annualize ด้วยหลัก square-root of time

ความสัมพันธ์นี้มาจากการที่ log returns เป็น Normal → variance $\propto T$ → $\sigma \propto \sqrt{T}$

3.7 Present Value & Future Value — สรุป

$$PV = FV \cdot e^{-rT} \quad FV = PV \cdot e^{rT}$$

r	T	e^{-rT}	PV ของ B100	ตีความ
2%	0.25 ปี	0.9950	฿99.50	ดอกเบี้ยต่ำ + เวลาสั้น = แทบไม่ discount
5%	1 ปี	0.9512	฿95.12	Strike ที่ K=100 มีมูลค่าวันนี้ = ฿95.12
10%	1 ปี	0.9048	฿90.48	ดอกเบี้ยสูง = discount มาก

⚠ Model Risk: r คงที่ใน BS — แต่โลกจริงมี Term Structure

BS ใช้ r เดียวตลอดอายุ option แต่ในตลาดจริง:

- **Yield curve ไม่ flat:** $r_{1\text{month}} \neq r_{1\text{year}} \neq r_{5\text{year}}$
 - **Rate เปลี่ยนทุกวัน** ตาม Fed/BOT policy → Rho risk
 - สำหรับ short-dated options (≤ 3 เดือน) error เล็กน้อย แต่ long-dated (≥ 1 ปี) Rho ใหญ่มาก
- แก้ไข: ใช้ forward rate ที่ตรงกับ maturity ของ option แทน overnight rate คงที่

เชื่อมกับ Options — อ่าน Put-Call Parity ออกครบแล้ว!

$$C + K \cdot e^{-rT} = P + S$$

- C = ราคา Call (บทที่ 1: ฟังก์ชัน + max)
- $K \cdot e^{-rT} = PV(K) =$ มูลค่าปัจจุบันของ Strike (บทนี้!)
- P = ราคา Put (บทที่ 1: การกลับเครื่องหมาย)
- S = ราคาหุ้น
- การจัดรูปสมการ → Synthetic Positions (บทที่ 2)

สรุปบทที่ 3

- ✓ เลขยกกำลัง: กฎ 5 ข้อ — e^{-rT} คือ "ลดค่า"
- ✓ ดอกเบี้ยทบต้น: ยิ่งถี่ยิ่งได้มาก → ซิดจำกัดคือ e^{rT}
- ✓ **e = 2.71828** มาจากดอกเบี้ยทบต้นไม่ใช่ตัวเลขลอยๆ
- ✓ $\ln(x)$: ย้อนกลับ e^x — กฎ $\ln(axb) = \ln(a) + \ln(b)$
- ✓ **Log return ดีกว่า simple return:** บวกได้, สมมาตร, เป็น Normal ได้
- ✓ **PV(K) = $K \cdot e^{-rT}$:** อ่าน Put-Call Parity ออกครบแล้ว!

โจทยฝึกหัด บทที่ 3

ข้อ 1. ฝาก ฿50,000 ที่ $r = 3\%$ ต่อปี Continuous Compounding
(ก) มูลค่า 2 ปี (ข) ต้องฝากกี่บาทวันนี้ เพื่อให้ได้ ฿60,000 ใน 3 ปี?

▶ ดูเฉลย

ข้อ 2. หุ้นราคา ฿100 → ฿85 → ฿95

(ก) Simple return ช่วงแรก (ข) Simple return รวม 2 ช่วง (ค) Log return รวม 2 ช่วง
(ง) ทำไม (ข) $\neq$ Simple return ช่วง 1 + ช่วง 2?

▶ ดูเฉลย

ข้อ 3. Black-Scholes: $S=฿105$, $K=฿100$, $r=5\%$, $T=0.5$, $\sigma=20\%$

คำนวณ $\ln(S/K)$ และ $(r + \sigma^2/2) \times T$ ซึ่งเป็น 2 ส่วนหลักของ d_1

▶ ดูเฉลย

จบ Part I

ตอนนี้คุณมีพื้นฐานเพียงพอที่จะไปอ่าน

"บทเรียน Payoff Chart Interactive" ได้แล้ว!

Part II: สถิติ ความน่าจะเป็น Distributions → เข้าใจ Volatility & Normal Distribution

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part II: สถิติ ความน่าจะเป็น และ Distributions (v2)

บทที่ 4-6: ค่ากลาง · Variance · Volatility · ความน่าจะเป็น · Normal · Lognormal

เรียนแบบ 3 ชั้น: อุปมา → เหตุ → ผล → ตัวเลขจริง

บทที่ 4: สถิติพื้นฐาน — "อ่านข้อมูลให้ออก"

Options คือการซื้อขาย "ความไม่แน่นอน" ถ้าไม่เข้าใจสถิติ ก็ไม่เข้าใจว่า options ราคาแพงหรือถูก บทนี้สร้างฐานตั้งแต่ต้น

4.1 ข้อมูลและการนำเสนอ — Histogram

🔍 อุปมา: ถ่ายรูปข้อมูล

ลองนึกว่าคุณมีผลตอบแทนรายวัน 250 วัน (1 ปีการค้า) — มองทีละตัวเลขไม่บอกอะไรเลย

Histogram เหมือน ถ่ายรูปข้อมูลจากมุมสูง — เห็นรูปร่างภาพรวมทันที:

"ผลตอบแทนกระจุกอยู่แถว 0% หรือกระจายกว้าง? มีหางยาวไหม?"

มีข้อมูล 250 จุด




แบ่งเป็นช่วงๆ



นับความถี่แต่ละช่วง



เห็นรูปร่าง distribution



Histogram of daily returns with normal fit (blue=gain, red=loss)

เชื่อมกับ Options

Histogram ของ daily returns มีรูปร่างคล้าย "ระฆัง" = **Normal Distribution** ที่ Black-Scholes ใช้
ถ้า histogram มีหางซ้ายยาว = ตลาดกลัว crash มาก = **Skew สูง** = OTM Puts แพง

4.2 ค่ากลาง — Mean, Median, Mode

🔍 อุปมา: เพื่อน 6 คนไปกินข้าว

เพื่อน 6 คนไปกินข้าว แต่ละคนจ่ายไปตาม "ผลตอบแทนรายวัน" ของหุ้นที่ถือ:

-5%, +2%, +8%, -1%, +3%, +50% (คนสุดท้ายโชคดีมากวันนั้น)

Mean = ถ้าเอาทุกอย่างมารวมกันแล้วหารเท่าๆ กัน → ได้คนละ **+9.5%** — แต่ไม่สะท้อนความจริงเลย!

Median = เรียงแล้วดูคนตรงกลาง → ได้ **+2.5%** — ตัวเลขนี้จริงกว่ามาก

ตัวอย่าง: Daily returns 6 วัน: **-5%, +2%, +8%, -1%, +3%, +50%**

ค่ากลาง	วิธีคำนวณ	ผลลัพธ์	จุดเด่น/จุดด้อย
Mean (ค่าเฉลี่ย)	$(-5+2+8-1+3+50) / 6$	+9.5%	ง่าย แต่ถูก outlier บิดเบือน
Median (มัธยฐาน)	เรียง: -5, -1, 2, 3, 8, 50 → กลาง = $(2+3)/2$	+2.5%	ทนต่อ outlier — ภาพจริงมากกว่า
Mode (ฐานนิยม)	ค่าที่ซ้ำบ่อยสุด	ไม่มี	ใช้กับ discrete data เท่านั้น

🔍 ทำไม Mean ถึงเขียนว่า $\Sigma x_i / n$?

Σx_i = รวมทุกค่า = "เอาของทุกคนมากองรวมกัน"

$/ n$ = หารจำนวนคน = "แบ่งให้เท่าๆ กัน"

สมการนี้ตอบว่า: "ถ้าแบ่งผลลัพธ์ให้เท่ากันทุกคน แต่ละคนจะได้เท่าไร?"

นั่นคือ Mean ตาม intuition พอดี

ระวัง: Outlier บิดเบือน Mean!

ค่า +50% ทำให้ Mean = 9.5% ซึ่ง **สูงกว่าทุกวันที่เหลือ**

ใน finance: ถ้า 1 วันใน 10 ปีกำไร 300% แต่วันอื่นๆ เฉลี่ย 0% → Mean ดูดีมาก แต่ Median $\approx 0\%$

→ ดู **Median** ควบคู่ Mean เสมอ

Weighted Average — ใช้กับ Portfolio

$$\text{Weighted Mean} = \Sigma(w_i \times x_i)$$

พอร์ต: หุ้น A (40%, return +5%) + หุ้น B (60%, return -2%)

$$\text{Portfolio Return} = 0.4 \times 5\% + 0.6 \times (-2\%) = 2.0\% - 1.2\% = +0.8\%$$

4.3 Variance และ Standard Deviation — "วัดความกระจาย"

🔍 **อุปมา: นักยิงธนู 2 คน**

นักยิงธนูสองคนยิง 5 ครั้ง เล็งเป้าตรงกลาง:

นักยิง A: ทุกลูกตกในวงแคบๆ รอบศูนย์กลาง (แม่นยำ)

นักยิง B: ลูกกระจายไปทั่วเป้า (ไม่แม่นยำ)

ทั้งคู่อาจมี **Mean ≈ 0** (เฉลี่ยแล้วเล็งถูกตรงกลาง) แต่ **Standard Deviation** ต่างกันมาก
SD คือตัววัด "ความกระจาย" นั้นเอง

วัดระยะห่างแต่ละจุดจาก Mean

→

ยกกำลัง 2 (ทำให้เป็นบวก)

→

หาค่าเฉลี่ย = Variance

→

$\sqrt{\text{Variance}}$ = Standard Deviation

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{n} \quad \sigma = \sqrt{\frac{\sum (x_i - \mu)^2}{n}}$$

หมายเหตุ: Population vs Sample Variance

สูตรนี้คือ **population variance** ($\div n$) ใช้เมื่อรู้ข้อมูลทั้งหมด — ใน finance จริงที่ใช้ข้อมูล historical (sample) ควรใช้ **sample variance** ($\div (n-1)$) แทน เพื่อให้ unbiased estimator ความแตกต่างน้อยมากเมื่อ $n \geq 30$

🔍 ทำไมต้องยกกำลัง 2? ทำไมไม่ใช้ $|x_i - \mu|$ ธรรมดา?

ปัญหาถ้าไม่ยกกำลัง 2: ค่าบวกและลบหักล้างกัน

เช่น ข้อมูล: +3%, -3% → ระยะห่างเฉลี่ย = $(3 + (-3)) / 2 = 0$ ← ผิด! ชัดเจนว่ามีความกระจาย

ทำไมไม่ใช้ $|x_i - \mu|$ (absolute value)? ทำได้ แต่ค่าสัมบูรณ์ไม่ smooth — ไม่มี derivative ที่ $x=0$

การ optimize และ calculus ยากกว่ามาก → นักคณิตศาสตร์เลือก $(x_i - \mu)^2$ แทน

ทำไมต้อง $\sqrt{\text{variance}}$ ตอนสุดท้าย?

ถ้าข้อมูลเป็น % → $(x_i - \mu)^2$ เป็น $\%^2$ → Variance มีหน่วย $\%^2$

$\sqrt{\text{Variance}}$ กลับมาเป็น % (หน่วยเดิม) → เปรียบเทียบกับ returns ได้โดยตรง

ตัวอย่างเปรียบเทียบ 2 หุ้น: μ ทั้งคู่ = 0%

หุ้น

returns: +1%, -1%, +2%, -2%

$$\sigma^2 = [(1-0)^2 + (-1-0)^2 + (2-0)^2 + (-2-0)^2] / 4 = [1+1+4+4] / 4 = 2.5 (\%^2)$$

$$\sigma = \sqrt{2.5} = 1.58\% \leftarrow \text{นี้}$$

หุ้น

returns: +10%, -8%, +12%, -14%

$$\sigma^2 = [(10)^2 + (-8)^2 + (12)^2 + (-14)^2] / 4 = [100+64+144+196] / 4 = 126 (\%^2)$$

$$\sigma = \sqrt{126} = 11.2\% \leftarrow \text{ผันผวนมาก!}$$


เชื่อมกับ Options — σ คือ Volatility!

Standard Deviation ของ daily returns = Historical Volatility (HV)

หุ้น B ($\sigma=11.2\%$ /วัน) มี options แพงกว่าหุ้น A ($\sigma=1.58\%$ /วัน) มาก

เพราะ "ความไม่แน่นอนสูงกว่า" = "โอกาสที่ option จะ expire มีค่า" สูงกว่า

ยิ่ง σ สูง → ราคา option แพงขึ้นทุกประเภท



Variance = average squared distance from mean (arrows show each $(x_i - \mu)$)

4.4 Percentile และ Quartile

🔍 อุปมา: ผลสอบ ONET

ถ้าคุณอยู่ที่ **Percentile 85** แปลว่า: นักเรียน 85% ทำคะแนนได้น้อยกว่าคุณ

ถ้าอยู่ที่ Percentile 5 แปลว่า: 95% ทำคะแนนได้มากกว่าคุณ ← กลุ่มที่แย่ที่สุด 5%

ใน finance: วันที่ "แย่ที่สุด 5%" คือ **VaR (Value at Risk) ที่ 95%**

Percentile	ชื่อ	ความหมาย	ใช้ใน Finance
P5	5th Percentile	มีแค่ 5% ที่ต่ำกว่านี้	VaR 95% (worst 5% days)
P25 (Q1)	Quartile 1	25% ของข้อมูลต่ำกว่านี้	ดู drawdown ช่วงล่าง
P50 (Q2)	Median	กึ่งกลาง	ผลตอบแทน "ทั่วไป"
P75 (Q3)	Quartile 3	75% ต่ำกว่านี้	ดู return ช่วงบน

เชื่อมกับ Options — VaR (Value at Risk)

VaR 95%, 1-day = P5 ของ daily returns

ตัวอย่าง: ถ้า VaR (95%, 1-day) = -3.2% บนพอร์ต ฿1 ล้าน

→ มีโอกาส 5% ที่จะเสีย $\geq$ ฿32,000 ในวันเดียว

→ นักวาง hedge ใช้ค่านี้ในการเลือก strike ของ protective put

4.5 Covariance และ Correlation

🔍 อุปมา: คนขายร่ม vs คนขายแวนกันแดด

วันฝนตก: คนขายร่มขายดี (+), คนขายแวนกันแดดขายไม่ดี (-)

วันแดดจัด: คนขายร่มขายไม่ดี (-), คนขายแวนกันแดดขายดี (+)

ยอดขายทั้งคู่ **สวนทางกันตลอด** → Correlation = -1

ถ้าถือหุ้นบริษัทร่มกับหุ้นบริษัทแวนกันแดด → พอร์ตนี้มาก = **diversification** ทำงาน!

$$\text{Cov}(X, Y) = \frac{\sum (x_i - \mu_x)(y_i - \mu_y)}{n} \quad \rho = \frac{\text{Cov}(X, Y)}{\sigma_x \cdot \sigma_y} \in [-1, +1]$$

🔍 ทำไม Correlation = Cov / ($\sigma_x \times \sigma_y$)?

Covariance มีปัญหา: ขนาดขึ้นอยู่กับหน่วยของข้อมูล

เช่น return เป็น % vs return เป็นสตางค์ → Cov ต่างกัน แต่ความสัมพันธ์จริงๆ เท่ากัน

การหาร $\sigma_x \times \sigma_y$ คือ **normalize (ปรับมาตรฐาน)** → ทำให้ผลลัพธ์อยู่ระหว่าง -1 ถึง +1
ตีความได้ทันที ไม่ขึ้นกับหน่วย

ρ	ความหมาย	ตัวอย่าง
+1.0	ขึ้น/ลงพร้อมกันเป๊ะ	หุ้น CPALL กับดัชนี SET50
+0.5	ขึ้น/ลงทิศเดียวกัน แต่ไม่ตาม	หุ้นไทย 2 ตัวในอุตสาหกรรมต่างกัน
0.0	ไม่สัมพันธ์กัน	หุ้นไทย กับราคาข้าวสาลีชิคาโก
-1.0	สวนทางกันเป๊ะ	คนขายร่ม กับ คนขายแวนกันแดด

เชื่อมกับ Options — Portfolio Variance

ยิ่ง ρ ต่ำ $\rightarrow$ diversification ลด risk ได้มากขึ้น

$$\text{Portfolio Variance} = \sum_i \sum_j w_i w_j \sigma_i \sigma_j \rho_{ij}$$

ถ้า $\rho = -1$: Var พอร์ตลดเป็นศูนย์ได้ (perfect hedge) $\rightarrow$ นี่คือหลักการของ options hedging!

⚠ Model Risk: Correlation พัง ตอน Stress — "Diversification หายไปเมื่อต้องการที่สุด"

Correlation ที่วัดในช่วงตลาดปกติ **ไม่ valid ตอน crisis**:

- ปี 2008: Correlation ระหว่าง asset classes ต่างๆ กระโดดขึ้นหา +1 พร้อมกัน (everything falls together)
 - Diversification ที่คำนวณด้วย $\rho = 0.3$ อาจกลายเป็น $\rho = 0.9$ ในวันที่ตลาดร่วง
 - ระวัง: $w^T \Sigma w$ ที่ใช้ historical Σ จะ underestimate tail risk ในสถานการณ์ stress
- แก้ไข: Stress test ด้วย correlation matrix จาก historical crisis periods (e.g., 2008, 2020 COVID)

สรุปบทที่ 4

- ✓ Histogram: ดูรูปร่างข้อมูลทั้งหมดในนัดเดียว
- ✓ Mean vs Median: Mean ถูก outlier บิดเบือน — ดูทั้งคู่
- ✓ σ (Standard Deviation) = Volatility — ยิ่งสูง options ยิ่งแพง
- ✓ Percentile $\rightarrow$ VaR $\rightarrow$ ช่วยเลือก strike ของ protective put
- ✓ Correlation $\rightarrow$ ยิ่งต่ำ diversification ยิ่งดี

โจทย์ฝึกหัด บทที่ 4

ข้อ 1. Returns 5 วัน: +2%, -1%, +4%, -3%, +3%

คำนวณ (ก) Mean (ข) Median (ค) Standard Deviation

► ดูเฉลย

ข้อ 2. หุ้น X มี $\sigma = 1\%$ /วัน, หุ้น Y มี $\sigma = 3\%$ /วัน

ราคา ATM Call ตัวไหนแพงกว่า และทำไม?

► ดูเฉลย

ข้อ 3. พอร์ต: หุ้น A (60%, $\sigma=20\%$) + หุ้น B (40%, $\sigma=15\%$) $\rho = +0.3$

คำนวณ Portfolio Standard Deviation

▶ ดูเฉลย

บทที่ 5: ความน่าจะเป็น — "วัดความไม่แน่นอน"

Options คือการ "ซื้อขายความน่าจะเป็น" ราคา call สะท้อนโอกาสที่หุ้นจะขึ้น ราคา put สะท้อนโอกาสที่จะลง — ถ้าไม่เข้าใจ probability ก็ไม่เข้าใจว่า options แพงหรือถูก

5.1 ความน่าจะเป็นพื้นฐาน

🔍 อุปมา: พยากรณ์อากาศ

กรมอุตุนิยมวิทยา บอก "70% ฝนตกพรุ่งนี้" — นี่ไม่ได้แปลว่าพรุ่งนี้ฝนตก 70% ของวัน แต่แปลว่า: ถ้าวันแบบนี้เกิดขึ้น 100 ครั้ง ฝนตกประมาณ 70 ครั้ง

ความน่าจะเป็นคือ "สัดส่วนในระยะยาว" ไม่ใช่คำทำนายแน่นอน 100%

$$0 \leq P(A) \leq 1 \quad P(A^c) = 1 - P(A)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad P(A \cap B) = P(A) \cdot P(B) \text{ (ถ้าอิสระ)}$$

ตัวอย่าง: Options Trade

ประเมินว่า $P(\text{หุ้นขึ้น} > 5\%) = 30\%$

$P(\text{หุ้นไม่ขึ้น} > 5\%) = 1 - 30\% = \mathbf{70\%}$ ← Call OTM expire ไร้ค่า

ถ้าวิเคราะห์ 2 หุ้น อิสระต่อกัน แต่ละตัว $P(\text{ขึ้น}) = 60\%$:

$P(\text{ทั้งคู่ขึ้น}) = 0.6 \times 0.6 = \mathbf{36\%}$

$P(\text{อย่างน้อย 1 ตัวขึ้น}) = 1 - P(\text{ทั้งคู่ไม่ขึ้น}) = 1 - 0.4 \times 0.4 = \mathbf{84\%}$

5.2 Combinations $C(n, k)$

🔍 อุปมา: เลือกนักฟุตบอล

เลือกกองหน้า 2 คนจากผู้เล่น 5 คน (ไม่สนว่าใครเป็นตัวจริง/สำรอง แค่ใครอยู่ในทีม)

$$C(5,2) = 5! / (2! \times 3!) = 120/12 = \mathbf{10 \text{ วิธี}}$$

ถ้าสนลำดับ (ตัวจริงคนไหน): Permutation = $5 \times 4 = 20$ วิธี

ไม่สนลำดับ: Combination = $20/2! = 10$ วิธี

$$\binom{n}{k} = C(n, k) = \frac{n!}{k! (n - k)!}$$

n	k	C(n,k)	ตัวอย่าง
5	2	10	เลือกหุ้น 2 ตัวจาก universe 5 ตัว
10	3	120	เลือก option 3 ตัวจาก 10 strike
4	2	6	วันขึ้น 2 วันจาก 4 วัน (Binomial Tree)

เชื่อมกับ Options — Binomial Tree

$C(n,k)$ คือหัวใจของ Binomial Distribution (บทถัดไป)

ใน **Binomial Option Pricing**: $C(4,2) = 6$ วิธีที่หุ้นจะขึ้น 2 ครั้งจาก 4 step

รวม payoff ทุก path $\times$ ความน่าจะเป็น $\rightarrow$ ราคา option

5.3 Conditional Probability และ Bayes' Theorem

🔍 อุปมา: ผล COVID Test

ก่อนตรวจ: $P(\text{ติดเชื้อ}) = 1\%$ (ความชุกในประชากร)

ตรวจได้ผล **Positive** (B) — ควรกังวลแค่ไหน?

สัณฐานตญาณบอกว่า "ติดเชื้อแน่เลย!" แต่ถ้า test มี False Positive rate 5%

ความจริง: $P(\text{ติดเชื้อ} | \text{ผล Positive}) \approx \mathbf{17\%}$ ไม่ใช่ 99%

Bayes ช่วยอัปเดตความเชื่อเมื่อได้ข้อมูลใหม่

$$P(A | B) = \frac{P(A \cap B)}{P(B)} \quad (\text{Bayes: } P(A | B) = \frac{P(B | A) P(A)}{P(B)})$$

🔍 ทำไม Bayes ถึงเขียนแบบนี้?

เริ่มจากนิยาม: $P(A|B) = P(A \text{ and } B) / P(B)$

และ: $P(B|A) = P(A \text{ and } B) / P(A)$

ดังนั้น: **$P(A \text{ and } B) = P(B|A) \times P(A)$**

แทนเข้าสมการแรก: $P(A|B) = P(B|A) \times P(A) / P(B) \leftarrow$ ได้ Bayes!

ตัวอย่าง: อัปเดตมุมมองหลังข่าวกำไร

ก่อนประกาศ (prior): $P(\text{หุ้นขึ้น}) = 50\%$ — ยังไม่มีข้อมูล เดา 50/50

ได้ข่าวกำไรดีกว่าคาด (likelihood): $P(\text{กำไรดี}|\text{หุ้นขึ้น}) = 70\%$, $P(\text{กำไรดี}|\text{หุ้นไม่ขึ้น}) = 20\%$

$P(\text{กำไรดี}) = 0.70 \times 0.50 + 0.20 \times 0.50 = 0.35 + 0.10 = 0.45$

$P(\text{หุ้นขึ้น} | \text{กำไรดี}) = 0.70 \times 0.50 / 0.45 = 0.35 / 0.45 \approx 78\%$ ← อัปเดตจาก 50% (prior) เป็น 78% (posterior)!

สังเกต: prior (50%), likelihood (70%), posterior (78%) เป็น **3 ค่าที่ต่างกัน** — สิ่งที่ผลักดันให้มุมมองขยับขึ้นมากคือ **likelihood ratio** $70\%/20\% = 3.5$ เท่า (ข่าวกำไรดี "ชี้" ไปทางหุ้นขึ้นแรง) ยิ่ง ratio สูง posterior ยิ่งเชยิบจาก prior มาก

5.4 Expected Value — "ค่าคาดหวัง"

🔍 อุปมา: เกมทอยเหรียญ

เกม: ทอยเหรียญ — หัวได้ +฿100, ก้อยเสีย -฿80

ควรเล่นไหม? ทอย 1,000 ครั้ง:

- หัว ~500 ครั้ง: ได้ $500 \times \text{฿}100 = +\text{฿}50,000$
- ก้อย ~500 ครั้ง: เสีย $500 \times \text{฿}80 = -\text{฿}40,000$
- กำไรสุทธิ: $+\text{฿}10,000 / 1,000 \text{ ครั้ง} = \text{+฿}10 \text{ ต่อครั้ง}$

นี่คือ Expected Value = +฿10 → ควรเล่น!

$$E[X] = \sum_i x_i P(x_i)$$

$$E[aX + b] = a E[X] + b \quad E[X + Y] = E[X] + E[Y] \text{ (เสมอ)}$$

🔍 ทำไม $E[X] = \sum x_i \times P(x_i)$?

คิดแบบ weighted average: แต่ละผลลัพธ์มีน้ำหนัก = ความน่าจะเป็น
ผลลัพธ์ที่เกิดบ่อย (P สูง) ควรมีน้ำหนักมาก
ผลลัพธ์ที่เกิดน้อย (P ต่ำ) ควรมีน้ำหนักน้อย

$E[X]$ คือ ค่าเฉลี่ยถ่วงน้ำหนักด้วย probability ไม่ใช่ค่าเฉลี่ยธรรมดา

เชื่อมกับ Options — Expected Payoff

ราคา Call Option = $e^{-rT} \times E^*[\max(0, S_T - K)]$

E^* = expected value ภายใต้ risk-neutral probability

= "ถ้า option expire วันนี้ 1,000 ครั้ง แต่ละครั้ง payoff เฉลี่ยเท่าไร" → นั่นคือราคา!

5.5 Variance ของตัวแปรสุ่ม

$$\text{Var}(X) = E[(X - \mu)^2] = E[X^2] - (E[X])^2$$

$$\text{Var}(aX + b) = a^2 \text{Var}(X) \quad \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$$

🔍 ทำไม $\text{Var}(aX + b) = a^2 \text{Var}(X)$?

b คือ "ขยับกราฟซ้าย/ขวา" — ไม่เปลี่ยนความกระจาย → Var ไม่เปลี่ยน

a คือ "ขยาย/ยุบ scale" — ถ้า scale กว้างขึ้น 2 เท่า ทุกระยะห่างกว้าง 2 เท่า

แต่ Var คิดจาก $(x_i - \mu)^2$ → ระยะห่างยกกำลัง 2 → Var เพิ่ม a^2 เท่า

เชื่อมกับ Options — Portfolio Variance

$$\text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y) + 2 \cdot \text{Cov}(X, Y)$$

ขยายเป็น n หุ่น: $\sigma^2_p = \mathbf{w}^T \Sigma \mathbf{w}$ (matrix form — บท 8)

ถ้า $\text{Cov} = 0$ (uncorrelated): Portfolio Var = $\text{Var}(X) + \text{Var}(Y)$ → diversification!

สรุปบทที่ 5

- ✓ Probability = "สัดส่วนในระยะยาว" ไม่ใช่คำทำนาย
- ✓ $C(n,k) \rightarrow$ จำนวน paths ใน Binomial Tree
- ✓ Bayes: อัปเดตความเชื่อจากข้อมูลใหม่ (กำไร, FOMC, ข่าว)
- ✓ $E[X] =$ weighted average ของผลลัพธ์ $\rightarrow$ ราคา option = E^* ของ payoff
- ✓ Var properties $\rightarrow$ เข้าใจ portfolio risk

โจทย์ฝึกหัด บทที่ 5

ข้อ 1. เกม: ทอยลูกเต๋า 1 ลูก

ถ้าออก 1-4: ได้ ฿20, ออก 5: ได้ ฿50, ออก 6: เสีย ฿60

(ก) คำนวณ $E[X]$ (ข) ควรเล่นไหม?

► ดูเฉลย

ข้อ 2. Call Option: หุ้นวันหมดอายุมีโอกาส 40% ขึ้น strike ที่ +฿10, 60% expire ไร้ค่า
ราคา call ควรเป็นเท่าไร? (ไม่คิด discount)

► ดูเฉลย

ข้อ 3. $P(\text{หุ้นขึ้น}) = 55\%$, $P(\text{IV ลด} | \text{หุ้นขึ้น}) = 70\%$, $P(\text{IV ลด} | \text{หุ้นไม่ขึ้น}) = 20\%$

ถ้ารู้อย่างนี้ IV ลด $\rightarrow P(\text{หุ้นขึ้น} | \text{IV ลด}) = ?$

► ดูเฉลย

บทที่ 6: Distributions — "รูปทรงของความไม่แน่นอน"

Distribution คือ "แผนที่" ของความน่าจะเป็น — บอกว่าค่าต่างๆ มีโอกาสเกิดมากน้อยแค่ไหน บทนี้สอน 4 distribution ที่สำคัญที่สุดใน options pricing

6.1 Binomial Distribution

🔍 อุปมา: ยิง penalty 5 ลูก

นักเตะมีโอกาสยิงได้ 70% ต่อลูก ยิง 5 ลูก
โอกาสยิงได้พอดี 3 ลูกคือเท่าไร?

- ต้องเลือกว่า **3 ลูกไหน** จาก 5 ที่จะได้ $\rightarrow C(5,3) = 10$ วิธี
- แต่ละวิธี: $P = (0.7)^3 \times (0.3)^2 = 0.343 \times 0.09 = 0.03087$
- $P(\text{ยิงได้ 3 จาก 5}) = 10 \times 0.03087 = \mathbf{30.87\%}$

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

🔍 ทำไมสูตรถึงเขียนแบบนี้?

$C(n,k)$ = จำนวนวิธีที่ k ครั้งจาก n ครั้งจะสำเร็จ (ลำดับไม่สำคัญ)


p^k = โอกาสสำเร็จ k ครั้ง (ทุกครั้งอิสระ $\rightarrow$ คูณกัน)

$(1 - p)^{n-k}$ = โอกาสล้มเหลว $n-k$ ครั้งที่เหลือ

รวม: "มีกี่วิธี" $\times$ "วิธีหนึ่งเป็นไปได้แค่ไหน" = ความน่าจะเป็นรวม

ตัวอย่าง: โยนเหรียญ ($p=0.5$) 4 ครั้ง

k (หัว)	C(4,k)	P(X=k)	เปอร์เซ็นต์
0	1	0.0625	6.25%
1	4	0.2500	25.0%
2	6	0.3750	37.5%
3	4	0.2500	25.0%
4	1	0.0625	6.25%



แผนภาพ: Binomial Distribution ($n=4, p=0.5$) — ความน่าจะเป็นแต่ละผลลัพธ์

เชื่อมกับ Options — Binomial Tree Pricing

ใน Cox-Ross-Rubinstein (CRR) model:

ราคาหุ้น step หนึ่ง ขึ้น u เท่า (prob p) หรือลง d เท่า (prob $1-p$) = Binomial!

n steps $\rightarrow n \rightarrow \infty \rightarrow$ **Binomial** $\rightarrow$ **Normal (CLT)** $\rightarrow$ ได้ Black-Scholes

6.2 Normal Distribution — หัวใจของ Black-Scholes

🔍 อุปมา: ส่วนสูงนักเรียน

วัดส่วนสูงนักเรียน 1,000 คน:

- ส่วนใหญ่สูง 165–170 cm (กลุ่มใหญ่กองอยู่ตรงกลาง)
- น้อยคนที่สูง 140 cm หรือ 200 cm (หางทั้งสองข้างบาง)
- กราฟออกมาเป็นรูประฆัง = **Normal Distribution**

Daily returns ของหุ้นก็มีรูปร่างคล้ายกัน — ส่วนใหญ่เปลี่ยนแปลงน้อย วันที่ขึ้น/ลงมากมายๆ ถึงเจอ

Normal Distribution กำหนดโดย 2 ค่า:

- μ (mean) = จุดศูนย์กลาง (ยอดระฆัง)
- σ (standard deviation) = ความกว้างของระฆัง

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

🔍 ทำไมสูตรถึงดูซับซ้อน? แยกเป็น 2 ส่วน

ส่วนที่ 1: $e^{-(x-\mu)^2/(2\sigma^2)}$ — "รูปร่างระฆัง"


- $(x-\mu)^2$ = ระยะห่างจาก mean ยกกำลัง 2 (เสมอ ≥ 0)
- ยิ่งห่างจาก mean $\rightarrow$ exponent ลบมาก $\rightarrow e^{-}$ ใหญ่มาก $\rightarrow$ ใกล้ 0 (หางบาง)
- $x = \mu$: exponent = 0 $\rightarrow e^0 = 1 \rightarrow$ **peak ที่ mean**
- σ ใหญ่ $\rightarrow 2\sigma^2$ ใหญ่ $\rightarrow e$ ลดลงช้า $\rightarrow$ **ระฆังกว้าง**

ส่วนที่ 2: $1/(\sigma\sqrt{2\pi})$ — "scaling factor"

- $\sqrt{2\pi} \approx 2.507$ มาจากการ integrate กราฟ Gaussian
- ทำให้พื้นที่ใต้กราฟทั้งหมด = 1 (นิยาม probability)

กฎ 68–95–99.7:

ช่วง	ครอบคลุม	ตัวอย่าง: หุ้น $\mu=0\%$, $\sigma=20\%$ /ปี
$\mu \pm 1\sigma$	68.3%	68% ของปี return อยู่ใน -20% ถึง $+20\%$
$\mu \pm 2\sigma$	95.4%	95% อยู่ใน -40% ถึง $+40\%$
$\mu \pm 3\sigma$	99.7%	99.7% อยู่ใน -60% ถึง $+60\%$



6.3 Z-Score และ Standard Normal $N(0,1)$

🔍 อุปมา: GPS พิกัดสัมพัทธ์

แทนที่จะบอกว่า "คุณอยู่ที่ latitude 13.756° N" (ตัวเลขสัมบูรณ์)
ลองบอกว่า "คุณอยู่ห่างจากศูนย์กลางเมือง 3.2 กม." (ตัวเลขสัมพัทธ์)

Z-score เหมือนกัน: แทนที่จะพูดถึงค่าดิบ x

บอกว่า " x ห่างจาก mean กี่ standard deviation" → เทียบข้ามหุ้น ข้าม market ได้ทันที

$$Z = \frac{x - \mu}{\sigma} \quad N(d) = P(Z \leq d) = \int_{-\infty}^d \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$

🔍 ทำไม $Z = (x - \mu)/\sigma$?

ลบ μ : ขยับ distribution ให้ mean = 0 (เหมือนเอา 0 ไว้ตรงกลาง)

หาร σ : scale ให้ standard deviation = 1 (มาตรฐานเดียวกัน)

ผล: ไม่ว่าข้อมูลจะมีหน่วยอะไร scale แค่ไหน → แปลงเป็น Z ได้เสมอ

$Z = -2$ แปลว่า "ต่ำกว่า mean 2 เท่าของ σ " ทุก distribution

d	$N(d)$	ความหมาย
-2.0	0.0228	มีแค่ 2.3% อยู่ต่ำกว่า -2σ
-1.0	0.1587	15.9% อยู่ต่ำกว่า -1σ
0.0	0.5000	50% พอดี (= median)
+1.0	0.8413	84.1% อยู่ต่ำกว่า $+1\sigma$
+2.0	0.9772	97.7% อยู่ต่ำกว่า $+2\sigma$

เชื่อมกับ Options — $N(d_1)$ และ $N(d_2)$ ใน Black-Scholes!

$$C = S_0 \times N(d_1) - K \times e^{-rT} \times N(d_2)$$

- $N(d_2)$ = ความน่าจะเป็นที่ option จะ expire ITM (ภายใต้ risk-neutral world)
- $N(d_1) = N(d_2)$ ที่ปรับด้วย delta → ใช้ hedge
- d_1, d_2 คือ Z-scores ที่รวม $\ln(S/K), r, \sigma, T$ เข้าด้วยกัน

พอรู้ Z-score → lookup ตาราง $N(d)$ → ได้ราคา option!

6.4 Lognormal Distribution — ทำไมราคาหุ้นไม่เป็น Normal

ปัญหา: Normal Distribution → ราคาหุ้นติดลบได้!

ถ้าราคาหุ้น $\sim \text{Normal}(500, 200^2)$ → มีโอกาส $\sim 0.6\%$ ที่ราคาจะ < 0

ราคาหุ้น -฿50 ไม่มีความหมายในโลกจริง (limited liability → ต่ำสุดคือ 0)

Normal ใช้กับราคาไม่ได้!

🔍 อุปมา: เงินทบต้น

ฝากเงิน ฿100 ทบต้นทุกวัน อัตราดอกเบี้ยรายวัน r :

วันที่ 1: $\text{฿}100 \times (1+r_1)$

วันที่ 2: $\text{฿}100 \times (1+r_1) \times (1+r_2)$


...

วันที่ n : $\text{฿}100 \times \prod(1+r_i) \approx \text{฿}100 \times e^{r_1+r_2+\dots+r_n}$

ผลคูณของ random variables → Lognormal! เพราะ $e^X > 0$ เสมอ

$$\ln(S) \sim \mathcal{N}(\mu, \sigma^2) \Rightarrow S \sim \text{Lognormal} \quad (S = e^{\ln S} > 0)$$

$$\text{Chain: } r = \ln(S_1/S_0) \sim \mathcal{N} \rightarrow S_1/S_0 = e^r \sim \text{Lognormal}$$

Normal distribution (can be negative) vs Lognormal (always ≥ 0)

สาย Chain: Log Return $\rightarrow$ Normal $\rightarrow$ ราคา $\rightarrow$ Lognormal

$$r = \ln(S_1/S_0) \sim \text{Normal} \rightarrow S_1 = S_0 \times e^r \sim \text{Lognormal}$$

Black-Scholes สมมติว่า log returns เป็น Normal Distribution

$\rightarrow$ ราคาหุ้นเป็น Lognormal $\rightarrow$ ราคาไม่ติดลบ ✓

 **Quant Desk: Lognormal เป็น Working Assumption — รู้ข้อจำกัดไว้ด้วย**

Lognormal ใช้กันทั่วไปใน derivatives pricing เพราะ:

- ราคาไม่ติดลบ (bounded below by 0) ✓
- มี closed-form solution สำหรับ Black-Scholes ✓
- Log returns additive ข้ามช่วงเวลา ✓

แต่ data จริงมี fat tails และ negative skew (\$6.6) — นั่นคือทำไมตลาดจึงให้ implied vol ที่ OTM Put > ATM (Volatility Skew)

6.5 Central Limit Theorem (CLT) — เวทมนตร์ของสถิติ

Central Limit Theorem

"ค่าเฉลี่ยของตัวอย่างจำนวนมาก $\rightarrow$ Normal Distribution เสมอ

ไม่ว่า distribution เดิมจะเป็นรูปร่างอะไรก็ตาม"

ต้องการแค่: (1) sample size ใหญ่พอ ($n \geq 30$ มักพอ) (2) variance มีอยู่จำกัด

Demo: ทอยลูกเต๋า

ทอย 1 ลูก: distribution สมมาตร (แต่ละหน้า 1/6) — ไม่ใช่ Normal เลย!

เฉลี่ย 2 ลูก: distribution เริ่มรูปสามเหลี่ยม (กลางนูน)

เฉลี่ย 10 ลูก: distribution คล้าย bell curve

เฉลี่ย 30 ลูก: Normal Distribution ชัดเจน!

ลูกเต๋ายังไม่ Normal เลย แต่ **ค่าเฉลี่ยของลูกเต๋ามากมาย ลูก $\rightarrow$ Normal = CLT**

เชื่อมกับ Options

- **Binomial $\rightarrow$ Normal (CLT):** เมื่อ $n \text{ steps} \rightarrow \infty \rightarrow$ ได้ Black-Scholes สูตร!
- Return รายวันอาจไม่ Normal แต่ return รายเดือน/ปี $\approx$ Normal (CLT)
- **Monte Carlo:** เฉลี่ย payoff จากล้าน simulations $\rightarrow$ converge หา $E[\text{payoff}]$ ได้แม่นยำ

6.6 Skewness และ Kurtosis — ตลาดจริงไม่ใช่ Normal

อุปมา: เงินเดือนในไทย (Skewness)

เงินเดือนคนไทยส่วนใหญ่ 15,000–30,000 บาท แต่มีมหาเศรษฐีไม่กี่คนรับ 10 ล้าน/เดือน

$\rightarrow$ กราฟ **เบ้ขวา (Positive Skew):** หางขวายาว, $\text{Mean} > \text{Median}$

ตลาดหุ้นกลับกัน: **เบ้ซ้าย (Negative Skew)**

วัน crash (−10%) เกิดบ่อยกว่าวัน rally (+10%) และรุนแรงกว่า

$\rightarrow$ หางซ้ายยาว = ผู้ถือหุ้นกลัวขาดทุนหนักกว่าที่ Normal ทำนาย

อุปมา: แผ่นดินไหว 100 ปีครั้ง (Kurtosis)


ถ้าตลาดเป็น Normal จริง: เหตุการณ์ 5σ (เช่น −40% ในวันเดียว) ควรเกิด 1 ในล้านล้านวัน

แต่ในความเป็นจริง: crash รุนแรงเกิดบ่อยกว่านั้นมาก (ทุก 10–20 ปี)

Fat Tails (Kurtosis สูง) = หางหนากว่า Normal

= เหตุการณ์สุดขั้วเกิดบ่อยกว่าที่ model ทำนาย

สมบัติ	Normal	ตลาดจริง	ผลกระทบต่อ Options
Skewness	0 (สมมาตร)	เบ้ซ้าย (negative)	Put OTM แพงกว่า Call OTM
Kurtosis	3 (mesokurtic)	>3 (fat tails)	Deep OTM options แพงกว่า BS



Real returns have heavier tails than Normal — OTM options are priced accordingly

เชื่อมกับ Options — Volatility Smile / Skew

ตลาด "รู้" ว่า Normal ไม่พอ → ราคา options สะท้อน fat tails จริงๆ

- OTM Puts แพงกว่า BS ทำนาย → **Volatility Skew** (IV ลดขณะ strike เพิ่ม)
- Deep OTM ทั้งสองด้านแพง → **Volatility Smile**

นี่คือเหตุผลที่ quant ต้อง "ซื้อ vol ที่ถูก ขาย vol ที่แพง" ไม่ใช่แค่ดู BS

สรุปบทที่ 6

- ✓ **Binomial**: $C(n,k) \times p^k \times (1-p)^{n-k}$ → สะพานสู่ Binomial Tree
- ✓ **Normal**: Bell curve, กฎ 68-95-99.7, สูตร 2 ส่วน (รูปร่าง + scaling)
- ✓ **Z-score** → **N(d)**: อ่าน $N(d_1)$, $N(d_2)$ ใน Black-Scholes ออกแล้ว!
- ✓ **Lognormal**: ราคาหุ้นต้อง ≥ 0 → log return Normal → ราคา Lognormal
- ✓ **CLT**: ค่าเฉลี่ยหลายๆ sample → Normal เสมอ → ทำไม BS ทำงานได้
- ✓ **Skew + Fat Tails**: ตลาดจริง $\neq$ Normal → Volatility Smile/Skew

โจทย์ฝึกหัด บทที่ 6

ข้อ 1. หุ่น $\mu = 0\%$, $\sigma = 25\%$ /ปี (ใช้กฎ 68-95-99.7)

(ก) โอกาสที่ return จะอยู่ใน -25% ถึง $+25\%$

(ข) โอกาสที่จะ ขาดทุนมากกว่า 50% /ปี

(ค) ถ้าซื้อ Put Strike -50% (deep OTM) ความน่าจะเป็นที่จะ ITM คือเท่าไร?

► ดูเฉลย

ข้อ 2. หุ้นราคา ฿100, $\sigma = 20\%$ /ปี, $T = 1$ ปี, $r = 3\%$

ในโมเดล Black-Scholes: $d_2 = [\ln(100/95) + (r - \sigma^2/2)T] / (\sigma\sqrt{T}) = [0.0513 + (0.03 - 0.02) \times 1] / (0.20 \times 1) = 0.0613 / 0.20 \approx 0.31$

$N(0.31) \approx 0.6217 \rightarrow$ ความน่าจะเป็นที่ Call ($K=95$) จะ expire ITM คือเท่าไร?

► ดูเฉลย

ข้อ 3. ตลาดหุ้นมี Negative Skew และ Fat Tails

ระหว่าง (ก) Short ATM Straddle กับ (ข) Short OTM Put — ตัวไหนเสี่ยงกว่าในโลกจริง? เพราะอะไร?

► ดูเฉลย

จบ Part II

ตอนนี้คุณเข้าใจ:

Volatility (σ), Normal Distribution, $N(d)$, Lognormal, Expected Value, Skew/Fat Tails

→ พร้อมอ่าน Greeks และ Black-Scholes อย่างลึกซึ้งแล้ว!

Part III: แคลคูลัส → เข้าใจ Greeks (Delta, Gamma, Theta, Vega) ทางคณิตศาสตร์

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part III: แคลคูลัส — ภาษาของ Greeks (v2)

บทที่ 7: Limit · Derivative · Chain · Product/Quotient · Partial · Real Greeks · Gamma · Integration ·

Expected Payoff · Taylor · Full P&L

เรียนแบบ 3 ชั้น: อุปมา → เหตุ → ผล → ตัวเลขจริง

บทที่ 7: แคลคูลัส — "ภาษาของ Greeks"

Greeks ทุกตัวคือ **อนุพันธ์ (derivatives)** ของราคา Option — ถ้าไม่รู้จักแคลคูลัส ก็ไม่เข้าใจว่า Delta, Gamma, Theta, Vega มาจากไหน บทนี้อธิบาย intuition ก่อนสูตร

7.1 Limit — แนวคิด "เข้าใกล้"

🔍 **อุปมา: วิ่งเข้าหาคำแพงครึ่งหนึ่งทุกครั้ง**

สมมติวิ่งเข้าหาคำแพงที่ระยะ 1 เมตร

ก้าวแรก: วิ่ง 0.5 เมตร → เหลือ 0.5 เมตร

ก้าวที่ 2: วิ่งอีก 0.25 เมตร → เหลือ 0.25 เมตร

ก้าวที่ 3: วิ่งอีก 0.125 เมตร → เหลือ 0.125 เมตร...

วิ่งไปกี่ก้าวก็ไม่ถึงกำแพง แต่ **เข้าใกล้ 1 เมตรมากขึ้นเรื่อยๆ** — นี่คือ Limit!

$\lim$ = "ค่าที่เข้าใกล้ แต่ไม่จำเป็นต้องถึง"

$$\lim_{x \rightarrow a} f(x) = L$$

ตัวอย่าง: $\lim_{h \rightarrow 0} [f(x+h) - f(x)] / h$

นี่คือ "อัตราการเปลี่ยนแปลง ถ้า h เล็กมากๆ" → นิยามของ Derivative!

เมื่อ h เข้าใกล้ 0 (แต่ไม่ถึง 0) → ค่า limit คืออัตราการเปลี่ยนแปลง ณ จุดนั้น

เชื่อมกับ Options — Delta ใช้แนวคิด Limit

Delta = "ถ้าราคาหุ้นเปลี่ยน ΔS นิดเดียว ราคา Option เปลี่ยน ΔV เท่าไหร่"

Delta = $\lim_{\Delta S \rightarrow 0} \Delta V / \Delta S$ = อัตราการเปลี่ยนแปลงทันที ไม่ใช่ค่าเฉลี่ย

7.2 Derivative — อัตราการเปลี่ยนแปลงทันที

🔍 อุปมา: มาตรการวัดความเร็วรถ

คุณขับรถจาก กทม. → เชียงใหม่ 700 กม. ใน 7 ชั่วโมง

ความเร็วเฉลี่ย = $700/7 = 100$ กม./ชม. (คล้าย slope ของเส้นตรง)

มาตรการวัดความเร็ว บอกความเร็ว "ตอนนี้" = 120 กม./ชม. (= Derivative ณ จุดนั้น)

Derivative = "ความเร็วทันที" ไม่ใช่ความเร็วเฉลี่ย

Delta = "อัตราการเปลี่ยน Option ตอนนี้" ณ ราคาหุ้นปัจจุบัน

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

(slope ของเส้นสัมผัส)

🔍 ทำไม Power Rule: $d/dx(x^n) = nx^{n-1}$?

ลองแทน $f(x) = x^2$:

$$f'(x) = \lim_{h \rightarrow 0} [(x+h)^2 - x^2] / h$$


$$= \lim_{h \rightarrow 0} [x^2 + 2xh + h^2 - x^2] / h$$

$$= \lim_{h \rightarrow 0} [2xh + h^2] / h$$

$$= \lim_{h \rightarrow 0} [2x + h] = 2x \checkmark (= nx^{n-1} \text{ เมื่อ } n=2)$$

$f(x)$	$f'(x)$	ทำไม?
x^n	nx^{n-1}	Power Rule (พิสูจน์ข้างต้น)
c (ค่าคงที่)	0	ไม่เปลี่ยนแปลง $\rightarrow$ slope = 0
$c \times f(x)$	$c \times f'(x)$	scale ทั้งกราฟ $\rightarrow$ slope $\times c$ ด้วย
$f(x) + g(x)$	$f'(x) + g'(x)$	slope รวม = slope แต่ละส่วนรวมกัน
e^x	e^x	← อนุพันธ์ของตัวเอง! (special property)
$\ln(x)$	$1/x$	ย้อนกลับจาก $d/dx(e^x) = e^x$

Derivative = Instantaneous Slope $f'(x) = \text{limit of } \Delta y / \Delta x \text{ as } \Delta x \rightarrow 0$



$f'(x)$ = instantaneous slope of tangent line at x

เชื่อมกับ Options — Delta!

Delta (Δ) = $\partial V / \partial S$ = derivative ของราคา Option เทียบกับราคาหุ้น
 = slope ของ payoff curve ณ จุดนั้น
 ATM Call: Delta $\approx 0.5 \rightarrow$ ราคาหุ้นขึ้น $\text{฿}1 \rightarrow$ Option ราคาขึ้น $\approx \text{฿}0.50$

7.3 อนุพันธ์ของ e^x — ทำไม e สำคัญที่สุด

🔍 อุปมา: แบคทีเรียที่โตตามขนาดตัวเอง

แบคทีเรีย 1,000 ตัว แบ่งตัวในอัตรา 10%/ชม. ต่อ "ตัวเอง"

ถ้ามี 1,000 ตัว $\rightarrow$ โตชั่วโมงนี้: 100 ตัว

ถ้ามี 5,000 ตัว $\rightarrow$ โตชั่วโมงนี้: 500 ตัว

"อัตราการเปลี่ยนแปลง = สัดส่วนของจำนวนปัจจุบัน"

นี่คือสมบัติ unique ของ e^x : $f'(x) = f(x) \rightarrow$ derivative = ตัวเอง!

$$\frac{d}{dx}(e^x) = e^x \quad \frac{d}{dx}(e^{ax}) = a e^{ax} \quad \frac{d}{dx}(e^{-rT}) = -r e^{-rT}$$

🔍 ทำไม $d/dx(e^x) = e^x$?

ใช้นิยาม limit:

$$d/dx(e^x) = \lim_{h \rightarrow 0} [e^{x+h} - e^x] / h$$

$$= \lim_{h \rightarrow 0} e^x \times [e^h - 1] / h$$

$$= e^x \times \lim_{h \rightarrow 0} [(e^h - 1) / h]$$

พิสูจน์ได้ว่า $\lim_{h \rightarrow 0} (e^h - 1)/h = 1 \rightarrow d/dx(e^x) = e^x \times 1 = e^x \checkmark$

7.4 Chain Rule — กฎลูกโซ่

🔍 อุปมา: แปลงสกุลเงินหลายชั้น

ถ้าอัตราแลกเปลี่ยน: 1 ดอลลาร์ = 36 บาท (rate = 36 บาท/ดอลลาร์)

และ: 1 บาท = 4 เยน (rate = 4 เยน/บาท)

แล้ว: 1 ดอลลาร์ = $36 \times 4 = 144$ เยน (rate = 144 เยน/ดอลลาร์)

Chain Rule คุณ "อัตรา" (rate) ของแต่ละชั้น ไม่ใช่คูณเปอร์เซ็นต์ — ถ้าดอลลาร์แข็งขึ้น dollar 1 หน่วย ทำให้บาทขยับ 36 หน่วย และบาท 1 หน่วยทำให้เยนขยับ 4 หน่วย → ดอลลาร์ขยับ 1 หน่วยทำให้เยนขยับ 36×4 หน่วย

Chain Rule: "อัตราการเปลี่ยนแปลงสุดท้าย = ผลคูณของอัตรา (slope) แต่ละชั้น"

$$y = f(g(x)) \implies \frac{dy}{dx} = f'(g(x)) \cdot g'(x)$$

ตัวอย่าง: หา dy/dT ของ $y = e^{-rT}$ (Discount Factor)

1 กำหนด $u = -rT \rightarrow y = e^u$

2 $dy/du = e^u$ (derivative ของ e^u)

3 $du/dT = -r$ (derivative ของ $-rT$ เทียบ T)

4 Chain Rule: $dy/dT = e^u \times (-r) = -r \times e^{-rT}$

แปลว่า: discount factor ลดลงเร็วแค่ไหน? $\rightarrow -r \times$ (ค่า discount ปัจจุบัน)

เปลี่ยน $T \rightarrow$ เปลี่ยน $u = -rT$ $\rightarrow$ เปลี่ยน $u \rightarrow$ เปลี่ยน e^u $\rightarrow$ รวม: $dy/dT = -r \cdot e^{-rT}$

เชื่อมกับ Options — Theta!

Theta = $-\partial C / \partial T$ = "Option ราคาตกลงเท่าไรต่อวัน" (time decay) โดย T = เวลาที่เหลือก่อน expire
 ใน BS: Theta ใช้ Chain Rule ผ่าน d_1, d_2 ที่เป็น function ของ t
 Chain Rule ยังเป็นพื้นฐานของ **Ito's Lemma** ที่ใช้ derive Black-Scholes

7.5 Product Rule & Quotient Rule — กฎผลคูณ-ผลหาร

🔍 อุปมา: พื้นที่สี่เหลี่ยมที่ทั้งกว้างและยาวเปลี่ยนพร้อมกัน

สี่เหลี่ยมผืนผ้ามีด้านกว้าง u และด้านยาว $v \rightarrow$ พื้นที่ = $u \cdot v$

ถ้าทั้งสองด้าน "ขยาย" พร้อมกันนิดเดียว พื้นที่เพิ่มจาก 2 ส่วน:

- ด้านกว้างขยาย (u') $\times$ ความยาวเดิม (v) $\rightarrow$ แถบเพิ่มด้านบน = $u' \cdot v$
- ด้านยาวขยาย (v') $\times$ ความกว้างเดิม (u) $\rightarrow$ แถบเพิ่มด้านข้าง = $u \cdot v'$

(มุมเล็กๆ ที่ขยายทั้ง 2 ด้าน $u' \cdot v'$ เล็กจนทิ้งได้เมื่อ $\Delta \rightarrow 0$)

$(uv)' = u'v + uv'$ — "เปลี่ยนตัวแรกค้างตัวหลัง บวก เปลี่ยนตัวหลังค้างตัวแรก"

$$(u \cdot v)' = u'v + uv' \quad \left(\frac{u}{v}\right)' = \frac{u'v - uv'}{v^2}$$

ตัวอย่าง: หา d/dS ของ $S \cdot N(d_1)$ (พจน์แรกของสูตร Black-Scholes Call)

เทอม $S \cdot N(d_1)$ เป็น "ผลคูณ" ของ $u = S$ และ $v = N(d_1)$ — ต้องใช้ Product Rule!

1 $u = S \rightarrow u' = du/dS = 1$

2 $v = N(d_1) \rightarrow v' = dv/dS = N'(d_1) \cdot (\partial d_1 / \partial S)$ (Chain Rule! เพราะ d_1 เป็น function ของ S)

3 Product Rule: $d/dS[S \cdot N(d_1)] = u'v + uv' = N(d_1) + S \cdot N'(d_1) \cdot (\partial d_1 / \partial S)$

นี่คือเหตุผลที่การ differentiate สูตร Black-Scholes ต้องใช้ Product Rule — ราคา Call มีเทอม $S \cdot N(d_1)$ ที่ทั้ง S และ $N(d_1)$ เปลี่ยนตาม S พร้อมกัน

เชื่อมกับ Options — พจน์ $S \cdot N'(d_1)$ ที่ "หายไป" อย่างมหัศจรรย์

เมื่อ differentiate สูตร Call ครบทุกเทอม จะได้เทอม $S \cdot N'(d_1) \cdot (\partial d_1 / \partial S)$ โผล่มา
แต่เทอมนี้ **หักล้าง (cancel)** กับเทอมที่มาจาก $K \cdot e^{-rT} \cdot N(d_2)$ พอดี
ทำให้ผลลัพธ์เหลือเพียง **Delta = $N(d_1)$** เกือบสวยงาม (ดูรายละเอียดใน §7.7)

7.6 Partial Derivatives — Greeks ทุกตัว

🔍 อุปมา: ความสุขขึ้นกับหลายปัจจัย

สมมติความสุข $H = f(\text{ห้องอุณหภูมิ } T, \text{ เพลง } V, \text{ แสง } L)$

"ถ้าอยากรู้ว่าอุณหภูมิมีผลแค่ไหน" → เปิดแอร์ แต่ค้างเพลงและแสงไว้ → วัด $\partial H / \partial T$

Partial Derivative = "เปลี่ยนตัวแปรเดียว ค้างตัวอื่น" = **Greeks ทุกตัว!**

$\frac{\partial f}{\partial x}$: ถือ y คงที่ แล้ว differentiate เทียบ x

ตัวอย่าง: $f(x, y) = x^2y + 3xy$

∂/

treat y เป็นคงที่: $\partial f / \partial x = 2xy + 3y$

∂/

treat x เป็นคงที่: $\partial f / \partial y = x^2 + 3x$

ราคา Option V ขึ้นกับหลายตัวแปร: $V(S, t, \sigma, r)$

Greek	สูตร	ความหมาย	เปลี่ยนอะไร ค้างอะไร
Δ Delta	$\partial V / \partial S$	Option เปลี่ยนเท่าไรต่อหุ้นขยับ B1	เปลี่ยน S , ค้าง t, σ, r
Θ Theta	$-\partial C / \partial T$	Option เปลี่ยนเท่าไรต่อวัน (T = time to expiry)	เปลี่ยน T , ค้าง S, σ, r
ν Vega	$\partial V / \partial \sigma$	Option เปลี่ยนเท่าไรต่อ σ เพิ่ม 1%	เปลี่ยน σ , ค้าง S, t, r
ρ Rho	$\partial V / \partial r$	Option เปลี่ยนเท่าไรต่อดอกเบี้ยเพิ่ม 1%	เปลี่ยน r , ค้าง S, t, σ

เชื่อมกับ Options — เข้าใจ Greeks ทุกตัวแล้ว!

Greeks ทุกตัวคือ "อัตราการเปลี่ยนแปลงของราคา Option เมื่อปรับตัวแปรทีละตัว"
ไม่ใช่ตัวเลขลอยๆ — แต่ล้วนมาจาก partial derivative ของสูตร Black-Scholes

7.7 Partial Derivative บนสูตร Black-Scholes จริง — The Real Greeks

🔍 อุปมา: เปิดฝากล่อง Black-Scholes ดูว่า Delta มาจากไหนจริงๆ

หนังสือส่วนใหญ่บอกแค่ "Delta = $N(d_1)$ " แล้วจบ — แต่ไม่บอกว่า **ทำไม**
สูตร Call มีตั้ง 2 เทอม ($S \cdot N(d_1)$ และ $K \cdot e^{-rT} \cdot N(d_2)$) ทั้งคู่ขึ้นกับ S
ตอน differentiate ควรได้เทอมยุ่งๆ เต็มไปหมด — แต่กลับเหลือแค่ $N(d_1)$ เกือบ
ความ "มหัศจรรย์" นี่คือการหักล้างของพจน์ ที่เราจะเปิดให้ดูในหัวข้อนี้

$$C = S N(d_1) - K e^{-rT} N(d_2)$$

$$\Delta = \frac{\partial C}{\partial S} = N(d_1)$$

← เหลือเท่านั้นเท่านั้น!

เหตุ → ผล: **ทำไม $\partial C / \partial S = N(d_1)$ เกือบๆ**

differentiate ทั้ง 2 เทอมเทียบ S (ใช้ Product Rule + Chain Rule จาก §7.5):

1 เทอม 1: $\partial / \partial S [S \cdot N(d_1)] = N(d_1) + S \cdot N'(d_1) \cdot (\partial d_1 / \partial S)$

2 เทอม 2: $\partial / \partial S [-K \cdot e^{-rT} \cdot N(d_2)] = -K \cdot e^{-rT} \cdot N'(d_2) \cdot (\partial d_2 / \partial S)$

3 เพราะ $d_2 = d_1 - \sigma \sqrt{T} \rightarrow \partial d_2 / \partial S = \partial d_1 / \partial S$ (ต่างกันแค่ค่าคงที่)

4 พิสูจน์ได้ว่า $S \cdot N'(d_1) = K \cdot e^{-rT} \cdot N'(d_2)$ พอดี (เอกลักษณ์ของ lognormal)

5 ดังนั้น 2 พจน์ที่มี N' เท่ากันและตรงข้าม → หักล้างกันหมด!

เหลือเพียง $\partial C / \partial S = N(d_1)$ — นี่คือ "ความมหัศจรรย์" ที่หนังสือส่วนใหญ่ข้ามไป

ตัวอย่างตัวเลขจริง: คำนวณ Delta ของ Call ATM

กำหนด $S=100$, $K=100$, $r=5\%$, $\sigma=25\%$, $T=1$ ปี

1 $d_1 = [\ln(S/K) + (r + \sigma^2/2) \cdot T] / (\sigma\sqrt{T}) = [\ln(1) + (0.05 + 0.03125) \cdot 1] / (0.25 \cdot 1) = 0.08125 / 0.25 = \mathbf{0.325}$

2 $\text{Delta} = N(d_1) = N(0.325) \approx \mathbf{0.627}$

3 ตีความ: หุ้นขยับขึ้น B1 (จาก B100 → B101) → ราคา Option ขยับขึ้น $\approx \mathbf{B0.627}$

$\text{Delta} = 0.627 > 0.5$ เพราะ drift $(r + \sigma^2/2)$ ดันให้ Call ATM เอนไปทาง ITM เล็กน้อย

Greeks ตัวอื่น = partial derivative ตัวอื่นของสูตรเดียวกัน

เมื่อเข้าใจว่า $\text{Delta} = \partial C / \partial S$ แล้ว Greeks ที่เหลือก็คือ partial derivative คนละตัว:

- **Gamma** = $\partial^2 C / \partial S^2 = \partial(\text{Delta}) / \partial S = N'(d_1) / (S \cdot \sigma \sqrt{T})$ — ความโค้ง (ดู §7.8)
- **Vega** = $\partial C / \partial \sigma = S \cdot N'(d_1) \cdot \sqrt{T}$ — ไวต่อความผันผวน
- **Theta** = $-\partial C / \partial T$ (เครื่องหมายลบ เพราะเวลาเหลือน้อยลง) — time decay
- **Rho** = $\partial C / \partial r = K \cdot T \cdot e^{-rT} \cdot N(d_2)$ — ไวต่อดอกเบี้ย

โจทย์ฝึก §7.7

Call: $S=50$, $K=50$, $r=4\%$, $\sigma=20\%$, $T=1$ ปี

(ก) คำนวณ d_1 (ข) หา $\text{Delta} = N(d_1)$ เมื่อกำหนด $N(0.3) \approx 0.618$ (ค) ถ้าหุ้นขยับ +B1 ราคา Option ขยับประมาณเท่าไร?

► ดูเฉลย

Quant Desk: Delta Hedging — ปรับพอร์ต ทุก ΔS ที่มีนัยสำคัญ

Market maker ที่ขาย options มักทำ **delta-neutral hedging** ทุกวัน:

- Short 1 Call (Delta = -0.6) → ซื้อหุ้น 0.6 หุ้น → net delta = 0
- เมื่อหุ้นขยับ delta เปลี่ยน → ต้อง rebalance → **Gamma $\neq 0$ ทำให้ต้อง rebalance บ่อย**
- ต้นทุน rebalancing = **Theta** ที่จ่าย (time value ที่ decay ทุกวัน)

กำไรของ market maker = Gamma P&L – Theta = ทำงานได้เมื่อ realized vol > IV ที่ขายไว้

7.8 อนุพันธ์อันดับสอง — Gamma

อุปมา: ความโค้งของถนน

ขับรถบนถนนตรง: Slope = ทิศทาง, Gamma = ความโค้ง

ถนนตรง: slope คงที่, Gamma = 0 (ไม่โค้ง)

ถนนเลี้ยว: slope เปลี่ยนตลอด, Gamma > 0 (โค้ง)

Gamma ของ Option = ความโค้งของ payoff curve

Gamma สูง = เส้น payoff โค้งมาก = Delta เปลี่ยนเร็ว = ต้อง re hedge บ่อย

$$\Gamma = \frac{\partial^2 V}{\partial S^2} = \frac{\partial(\Delta)}{\partial S}$$

"Delta เปลี่ยนเท่าไร เมื่อราคาหุ้นเปลี่ยน \$1"

ทำไมต้อง differentiate 2 ครั้ง?

Delta = $f'(S)$ = slope ณ จุดนั้น


Gamma = $f''(S)$ = slope ของ slope = "Delta เปลี่ยนเร็วแค่ไหน"

ตัวอย่าง: $f(x) = x^3$

$f'(x) = 3x^2$ (slope)

$f''(x) = 6x$ (slope เปลี่ยนเร็วแค่ไหน ณ x นั้น)

Gamma = Curvature of Option Price Curve Option value is convex — Gamma > 0 always



Gamma = curvature of option value curve; always positive (convex)

ทำไม Gamma สำคัญสำหรับ Trader?

- **Long Gamma** (ซื้อ options): ได้ประโยชน์เมื่อตลาดเคลื่อนไหวมาก — "กำไรจาก vol"
- **Short Gamma** (ขาย options): เสียเมื่อตลาดเคลื่อนไหวมาก — ต้อง re hedge ตลอด
- **Gamma สูงสุดที่ ATM**: Options ATM โค้งมากที่สุด = ไวต่อการเคลื่อนไหวของราคา

7.9 Integration — พื้นที่ใต้กราฟ

🔍 อุปมา: คิกระยะทางจากความเร็ว

ขับรถที่ 100 กม./ชม. เป็นเวลา 2 ชั่วโมง → ระยะทาง = $100 \times 2 = 200$ กม.

"ระยะทาง = พื้นที่ใต้กราฟ velocity vs time"

Integration คือการ "ย้อนกลับ" ของ derivative:

ถ้า derivative วัด "เปลี่ยนเร็วแค่ไหน" → integral สะสม "เปลี่ยนไปเท่าไรรวม"

$$\int x^n dx = \frac{x^{n+1}}{n+1} + C \quad \int e^x dx = e^x + C \quad \int \frac{1}{x} dx = \ln|x| + C$$

🔍 ทำไม $\int x^n dx = x^{n+1}/(n+1)$?

เพราะเราต้องการ $F(x)$ ที่ $F'(x) = x^n$

ลองดู: $d/dx[x^{n+1}/(n+1)] = (n+1)x^n/(n+1) = x^n \checkmark$

→ Antiderivative ของ x^n คือ $x^{n+1}/(n+1)$ นั่นเอง

เชื่อมกับ Options

- $N(d) = \text{CDF ของ Normal} = \int \text{bell curve} \rightarrow$ พื้นที่ใต้กราฟทางซ้ายของ d
- $E[X] = \int x \times f(x) dx$ (expected value ของ continuous distribution)
- ราคา Option = $\int \text{payoff} \times \text{probability density} = E^*[\text{payoff}]$ ที่ discount แล้ว

7.10 Integration หา Expected Payoff — ราคา Option = $\int \text{payoff} \times \text{density}$

🔍 อุปมา: รวมพื้นที่ใต้กราฟ $\text{payoff} \times \text{ความน่าจะเป็น} = \text{ราคายุติธรรม}$

ถ้าจะตั้งราคา "ลอตเตอรี่" ที่ยุติธรรม → คิดทุกผลลัพธ์ที่เป็นไปได้:

(เงินที่ได้ในผลลัพธ์นั้น) $\times$ (ความน่าจะเป็นของผลลัพธ์นั้น) แล้วรวมกันทุกผล

Option ก็เหมือนกัน: ราคายุติธรรม = รวม (payoff ของแต่ละราคาหุ้น) $\times$ (ความน่าจะเป็นที่หุ้นจบที่ราคานี้)

"รวมทุกผลลัพธ์ต่อเนื่อง" = **Integration** → แล้ว discount กลับมาเป็นมูลค่าวันนี้

$$C = e^{-rT} \int_0^\infty \max(0, S - K) \cdot f(S) dS$$

$f(S)$ = risk-neutral lognormal density; $\max(0, S - K)$ = payoff

ตัวอย่าง: ประมาณราคา Call แบบ discrete (แบ่ง bucket) — $K=100$, $r=5\%$, $T=1$

แทน integral ต่อเนื่องด้วยการแบ่งราคาหุ้นจบเป็น 5 bucket พร้อม risk-neutral probability (รวม = 1.00):

S (ราคาจบ)	payoff $f = \max(0, S-100)$	p (prob)	payoff $f \times p$
80	0	0.10	0.00
90	0	0.20	0.00
100	0	0.35	0.00
110	10	0.22	2.20
120	20	0.13	2.60
รวม		1.00	4.80

1 $\Sigma \text{payoff} \times p = 0 + 0 + 0 + 2.20 + 2.60 = \mathbf{B4.80}$ (= expected payoff ที่ควรกำหนด)

2 discount กลับมาวันนี้: $e^{-rT} = e^{-0.05} \approx 0.9512$

3 ราคา Call $\approx 4.80 \times 0.9512 \approx \mathbf{B4.57}$

นี่เป็นเพียงการประมาณหยาบด้วย 5 bucket — ถ้าใช้ bucket ละเอียดขึ้นเรื่อยๆ จนเป็น integral ต่อเนื่องกับ lognormal density จริง จะได้สูตร Black-Scholes แบบเป๊ะ

เชื่อมกับ Options

สูตร Black-Scholes ที่ดูน่ากลัว แท้จริงคือ **integral** ก้อนนี้ที่แก้ออกมาเป็น closed form $S \cdot N(d_1) - K \cdot e^{-rT} \cdot N(d_2)$ คือผลลัพธ์ของ $\int \max(0, S-K) \cdot f(S) dS$ เมื่อ f เป็น lognormal

โจทย์ฝึก §7.10

Put option, $K=100$, $r=0\%$ (เพื่อความง่าย, $e^{-rT}=1$). ใช้ราคาจบและ probability ชุดเดิม:

$S = 80, 90, 100, 110, 120$ กับ $p = 0.10, 0.20, 0.35, 0.22, 0.13$

payoff ของ Put = $\max(0, K - S)$. ประมาณราคา Put

► ดูเฉลย

7.11 Taylor Series — ประมาณค่าจาก Derivative

🔍 อุปมา: ประมาณค่าจากข้อมูลใกล้เคียง

คุณรู้ว่า ณ วันนี้ หุ้น B100, Delta=0.5, Gamma=0.03

ถ้าหุ้นขึ้นเป็น B102 (+B2) → Option ราคาเปลี่ยนเท่าไร?

ประมาณ: $\Delta V \approx 0.5 \times 2 + \frac{1}{2} \times 0.03 \times 2^2 = 1.0 + 0.06 = \text{+B1.06}$

(ดีกว่าแค่ Delta $\times \Delta S = \text{+B1.00}$ เพราะ Gamma ช่วย correct ความโค้ง)

$$f(x+h) \approx f(x) + f'(x)h + \frac{1}{2}f''(x)h^2$$

$$\Delta V \approx \Delta \cdot \Delta S + \frac{1}{2} \Gamma (\Delta S)^2$$

🔍 ทำไมสูตรถึงมีรูปแบบนี้?

term แรก $f(x+h) \approx f(x)$: ถ้า $h = 0 \rightarrow$ ไม่เปลี่ยน

+ $f'(x) \cdot h$: การประมาณเชิงเส้น (slope $\times$ ระยะทาง)

+ $\frac{1}{2}f''(x) \cdot h^2$: correction สำหรับความโค้ง (Gamma $\times \frac{1}{2} \times \Delta S^2$)

ยิ่งเพิ่ม term มาก ยิ่งแม่นยำขึ้น — แต่ 2 terms มักพอสำหรับ options risk

เชื่อมกับ Options — Delta-Gamma Approximation ใช้ทุกวัน!

$$\Delta V \approx \text{Delta} \times \Delta S + \frac{1}{2} \times \text{Gamma} \times (\Delta S)^2$$

ใช้ใน P&L estimation, risk limit checking, scenario analysis

ถ้า ΔS ใหญ่ (crash) → Gamma term สำคัญมาก! Short Gamma trader ระวัง

7.12 Multivariate Taylor & The Full Options P&L — สมการกำไร-ขาดทุนที่เทรดเดอร์ใช้จริง

🔍 อุปมา: ประมาณการเปลี่ยนแปลงราคา Option จากหลายปัจจัยพร้อมกัน

ใน §7.11 เราประมาณ ΔV จากการขยับของหุ้น (S) อย่างเดียว — แต่ในชีวิตจริง ภายในวันเดียวกัน มีหลายอย่างเปลี่ยนพร้อมกัน: หุ้นขยับ, เวลาเดินไป 1 วัน, ความผันผวนเปลี่ยน

Multivariate Taylor คือการ "บวกผลจากทุกปัจจัยเข้าด้วยกัน" — แต่ละ Greek คือ slope ของแต่ละแกน รวมทุก slope $\times$ ระยะที่ขยับ = ประมาณการเปลี่ยนแปลงราคา Option รวม

$$\Delta V \approx \underbrace{\Delta \cdot \Delta S}_{\text{directional}} + \underbrace{\frac{1}{2}\Gamma(\Delta S)^2}_{\text{convexity}} + \underbrace{\Theta \cdot \Delta t}_{\text{time decay}} + \underbrace{\nu \cdot \Delta \sigma}_{\text{vol P\&L}}$$

แต่ละเทอมหมายถึงอะไร

- **Delta $\cdot\Delta S$** — กำไร/ขาดทุนจากทิศทาง (หุ้นขึ้น/ลง) = directional P&L
- **$\frac{1}{2}\Gamma\cdot(\Delta S)^2$** — กำไรจากความโค้ง = convexity / gamma P&L (เป็นบวกเสมอถ้า long gamma ไม่ว่าหุ้นขึ้นหรือลง)
- **Theta $\cdot\Delta t$** — time decay = มูลค่าที่ลดตามเวลา (มักเป็นลบสำหรับคนถือ option)
- **Vega $\cdot\Delta\sigma$** — กำไร/ขาดทุนเมื่อความผันผวน (vol) เปลี่ยน = vol P&L

ตัวอย่างตัวเลขจริง: แยก P&L 1 วันของ position

Position: Delta=0.5, Gamma=0.03, Theta=-0.05/วัน, Vega=0.12 (ต่อ 1 vol point = 1%)
เหตุการณ์ในวันนั้น: หุ้นขยับ $\Delta S = +\$2$, เวลาเดิน $\Delta t = 1$ วัน, vol เพิ่ม $\Delta \sigma = +1\%$ ($= +0.01$)

1 $\Delta \cdot \Delta S = 0.5 \times 2 = \mathbf{+\$1.00}$ (directional)

2 $\frac{1}{2}\Gamma \cdot (\Delta S)^2 = 0.5 \times 0.03 \times 2^2 = 0.5 \times 0.03 \times 4 = \mathbf{+\$0.06}$ (convexity/gamma)

3 $\Theta \cdot \Delta t = -0.05 \times 1 = \mathbf{-\$0.05}$ (time decay)

4 $\text{Vega} \cdot \Delta \sigma = 0.12 \times 1 = \mathbf{+\$0.12}$ (Vega ใช้ convention "ต่อ 1 vol point" $\rightarrow$ vol +1% $\rightarrow$ คุณ 1)

5 รวม: $\Delta V \approx 1.00 + 0.06 - 0.05 + 0.12 = \mathbf{+\$1.13}$

$$\text{Delta} + \text{฿}1.00 + \text{Gamma} + \text{฿}0.06 + \text{Theta} - \text{฿}0.05 + \text{Vega} + \text{฿}0.12 = \Delta V + \text{฿}1.13$$

เชื่อมกับ Options — นี่คือวิธี attribute P&L รายวันของเทรดเดอร์จริง

คำถาม "ทำไมวันนี้กำไร/ขาดทุน?" ตอบได้ด้วยการแยกเป็นรายปัจจัย:

- กำไรเพราะเดตาที่ถูกต้อง (delta) หรือเพราะตลาดเหวี่ยงแรง (gamma)?
- ขาดทุนเพราะเวลาผ่านไป (theta) หรือเพราะ vol ตก (vega)?

การแตก P&L แบบนี้เรียกว่า **P&L attribution / Greeks explain** — ใช้ทุกวันบนโต๊ะเทรด

⚠ Model Risk: Taylor P&L ดีแค่ Small Move — ระวัง Gap/Jump

สมการ $\Delta V \approx \Delta \cdot \Delta S + \frac{1}{2} \Gamma (\Delta S)^2 + \Theta \cdot \Delta t + v \cdot \Delta \sigma$ ใช้ได้ดีเมื่อ ΔS เล็ก แต่:

- **Gap opening:** หุ่นเปิดตลาดต่าง -10% (หลังข่าวใหญ่กลางคืน) → Γ term underestimate P&L มาก
- **Vol jump:** $\Delta \sigma + 10$ vol points ใน 1 วัน (ช่วง Lehman / COVID) → $v \cdot \Delta \sigma$ อาจไม่เพียงพอ
- **Cross-gamma** ($\partial^2 V / \partial S \partial \sigma$) ถูก neglect — เมื่อหุ้นตก vol มักพุ่งขึ้นพร้อมกัน ปฏิสัมพันธ์นี้ไม่อยู่ในสมการ

สมการ

ใช้ full repricing (Monte Carlo หรือ binomial tree) เมื่อ $\Delta S > 2-3\%$

โจทย์ฝึก §7.12

Position: Delta=-0.4, Gamma=0.02, Theta=-0.03/วัน, Vega=0.10 (ต่อ 1 vol point)

ในวันนั้น: หุ่นขยับ $\Delta S = -\text{฿}3$, $\Delta t = 1$ วัน, vol ลด $\Delta \sigma = -2\%$ ($= -0.02$)

แตก ΔV เป็น 4 เทอม แล้วรวม

► ดูเฉลย

สรุปบทที่ 7

- ✓ Limit = "เข้าใกล้" → นิยามของ Derivative
- ✓ Derivative = slope ณ จุดนั้น (ไม่ใช่เฉลี่ย) = **Delta**
- ✓ $d/dx(e^x) = e^x$ ← อนุพันธ์ตัวเอง = ทำไม e^x ปรากฏทุกที่ใน finance
- ✓ Chain Rule = "ส่งต่อ" การเปลี่ยนแปลง → พื้นฐานของ Ito's Lemma
- ✓ **Product/Quotient Rule**: $(uv)' = u'v + uv'$ → ใช้ differentiate $S \cdot N(d_1)$
- ✓ **Partial Derivatives = Greeks** ทุกตัว: $\Delta \Theta \nu \rho$
- ✓ **The Real Greeks**: Delta = $N(d_1)$ เพราะพจน์ $S \cdot N'(d_1)$ หักล้างกันพอดี
- ✓ **อนุพันธ์อันดับ 2 = Gamma** = ความโค้ง → Long/Short Gamma
- ✓ Integration = ย้อนกลับ derivative → CDF, Expected Payoff
- ✓ **ราคา Option** = $e^{-rT} \cdot \int \max(0, S-K) \cdot f(S) dS$ = รวม payoff $\times$ density
- ✓ **Taylor**: $\Delta V \approx \text{Delta} \times \Delta S + \frac{1}{2} \text{Gamma} \times (\Delta S)^2$ = ใช้ทุกวัน
- ✓ **Full P&L**: $\Delta V \approx \text{Delta} \cdot \Delta S + \frac{1}{2} \Gamma \cdot (\Delta S)^2 + \text{Theta} \cdot \Delta t + \text{Vega} \cdot \Delta \sigma$ = P&L attribution

โจทย์ฝึกหัด บทที่ 7

ข้อ 1. $f(x) = 3x^4 - 2x^2 + 5x - 7$

คำนวณ (ก) $f'(x)$ (ข) $f''(x)$ (ค) $f'(2)$

► ดูเฉลย

ข้อ 2. Option: Delta = 0.45, Gamma = 0.025

ราคาหุ้นขึ้นจาก B100 → B104 (+B4)

(ก) ประมาณ ΔV ด้วย Delta เพียงอย่างเดียว

(ข) ประมาณ ΔV ด้วย Delta + Gamma (Taylor 2 terms)

(ค) Gamma correction มีผลเท่าไร?

► ดูเฉลย

ข้อ 3. สูตร Black-Scholes Call: $C = S \cdot N(d_1) - K \cdot e^{-rT} \cdot N(d_2)$

(ก) $\partial C / \partial S$ คืออะไร? (= Greek ตัวไหน)

(ข) $\partial C / \partial r$ มีค่าบวกหรือลบ? (= Greek ตัวไหน)

(ค) $\partial C / \partial t$ มีค่าบวกหรือลบ? (= Greek ตัวไหน และทำไม?)

► ดูเฉลย

จบ Part III

ตอนนี้คุณเข้าใจ **Greeks ทุกตัว** ในเชิงคณิตศาสตร์:

$$\text{Delta} = \partial V / \partial S \mid \text{Gamma} = \partial^2 V / \partial S^2 \mid \text{Theta} = -\partial C / \partial T \mid \text{Vega} = \partial V / \partial \sigma$$

Part IV: Linear Algebra & Regression → จัดการ Portfolio หลายตัวแปร

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part IV: Linear Algebra & Regression (v2)

บทที่ 8–9: Vectors · Matrices · Portfolio Variance · Eigenvalues · Regression · Beta

เรียนแบบ 3 ชั้น: อุปมา → เหตุ → ผล → ตัวเลขจริง

บทที่ 8: Linear Algebra — "จัดการหลายตัวแปรพร้อมกัน"

เมื่อ portfolio มีหุ้น 50 ตัว, Options 20 สัญญา จัดการทีละตัวไม่ไหว — **Matrix** ทำให้คำนวณ risk ทั้งหมดพร้อมกันได้ในสูตรเดียว

8.1 Vectors — รายการตัวเลขเรียงกัน

🔍 **อุปมา: รายการช้อปปิ้ง**

ไปซูเปอร์มาร์เก็ต ซื้อ: ข้าว 2 kg, ไก่ 1 kg, ผัก 0.5 kg

Vector ของปริมาณ = [2, 1, 0.5]

Vector ของราคา = [30, 80, 20] (บาท/kg)

ยอดรวม = $2 \times 30 + 1 \times 80 + 0.5 \times 20 = 60 + 80 + 10 = \text{฿}150$

นี่คือ **Dot Product** = $\sum (\text{ปริมาณ} \times \text{ราคา})$ — เป็นสูตรเดียวกับ Portfolio Return!

$$\mathbf{w} = [0.3, 0.5, 0.2] \quad \mathbf{r} = [0.05, -0.02, 0.08]$$

$$R_p = \mathbf{w} \cdot \mathbf{r} = \sum_i w_i r_i = 0.3(0.05) + 0.5(-0.02) + 0.2(0.08) = \mathbf{2.1\%}$$

🔍 **ทำไม Dot Product จึงเท่ากับ Portfolio Return?**

Portfolio Return = "ผลรวมของ return แต่ละหุ้น ถ่วงน้ำหนักด้วยสัดส่วนที่ถือ"

$= w_1 r_1 + w_2 r_2 + w_3 r_3 = \text{Dot Product } \mathbf{w} \cdot \mathbf{r}$

Dot Product คือ weighted sum — ตรงกับนิยาม portfolio return ทุกประการ

เชื่อมกับ Options — Portfolio Delta

ถือ Call K=100 จำนวน 2 contracts (Delta 0.6), Short Put K=95 จำนวน 1 contract (Delta -0.4)

Position vector = [2, -1], Delta vector = [0.6, -0.4]

Portfolio Delta = $2(0.6) + (-1)(-0.4) = 1.2 + 0.4 = \mathbf{1.6}$

8.2 Matrices — ตารางสัมพันธ์ระหว่างทุกคู่

🔍 อุปมา: ตารางระยะทางระหว่างเมือง

ลองนึกตารางระยะทาง กทม.-เชียงใหม่-ภูเก็ต-ขอนแก่น (4x4 table)

แต่ละช่อง $[i][j]$ = ระยะทางจากเมือง i ไปเมือง j

Diagonal = 0 (ห่างตัวเอง = 0), สมมาตร $[i][j] = [j][i]$

Correlation Matrix ทำงานเหมือนกัน:

$[i][j]$ = correlation ระหว่างหุ้น i กับหุ้น j , Diagonal = 1.0 (corr กับตัวเอง = 1)

$$\mathbf{C} = \begin{pmatrix} 1.0 & 0.7 & 0.2 \\ 0.7 & 1.0 & 0.3 \\ 0.2 & 0.3 & 1.0 \end{pmatrix} \begin{matrix} \leftarrow A \\ \leftarrow B \\ \leftarrow C \end{matrix}$$

Matrix Multiplication: $A(m \times n) \times B(n \times p) = C(m \times p)$

🔍 ทำไม Matrix คุณแบบนี้?

แต่ละ entry ของผลลัพธ์ $C[i][j]$ = Dot Product ของแถว i ของ A กับคอลัมน์ j ของ B

เหมือนถามว่า "แถว i มองเห็น' คอลัมน์ j แค่ไหน"

เป็น generalization ของ dot product สู่ multi-dimensional calculation

เชื่อมกับ Options — Covariance Matrix

Covariance Matrix (Σ) เก็บ σ^2 ทุกตัว + $\text{Cov}(i,j)$ ทุกคู่ในตารางเดียว

ใช้คำนวณ Portfolio Variance ของหุ้น/Options ที่ตัวก็ได้ในสูตรเดียว

8.3 Portfolio Variance ในรูป Matrix — $\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w}$

🔍 อุปมา: ผสมสีทาบ้าน

ผสมสีแดง 60% + สีนํ้าเงิน 40% — ความเข้มของสีผสม ขึ้นกับ:

1. ความเข้มของแต่ละสี (variance ของแต่ละหุ้น)
2. ว่าสีผสมกันเป็นยังไง (covariance ระหว่างหุ้น)

ถ้าสีสองสีผสมกันได้ดี → สีผสมสว่าง (diversification ดี)

ถ้าสีสองสีตีกัน → สีผสมมืด (diversification ไม่ช่วย)

$$\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w}$$

🔍 ทำไม $w^T \Sigma w$?

ขยาย $\text{Var}(w_1 X_1 + w_2 X_2) = w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 + 2w_1 w_2 \text{Cov}(X_1, X_2)$

เขียนเป็น matrix: $[w_1 \ w_2] \times [\sigma_1^2 \ \text{Cov}; \ \text{Cov} \ \sigma_2^2] \times [w_1; w_2] = w^T \Sigma w$ ✓

สูตร matrix form compact กว่า และขยายเป็น n หุ่นได้ทันทีโดยไม่ต้องเขียนใหม่

ตัวอย่าง: หุ่น 2 ตัว, $w = [0.6, 0.4]$

1 Covariance Matrix: $\Sigma = [0.04 \ 0.01; 0.01 \ 0.09]$

($\sigma_1 = 20\% \rightarrow \sigma_1^2 = 0.04$, $\sigma_2 = 30\% \rightarrow \sigma_2^2 = 0.09$, $\text{Cov} = 0.01$)

2 $\Sigma w = [0.04 \times 0.6 + 0.01 \times 0.4; 0.01 \times 0.6 + 0.09 \times 0.4] = [0.028; 0.042]$

3 $w^T (\Sigma w) = 0.6 \times 0.028 + 0.4 \times 0.042 = 0.0168 + 0.0168 = \mathbf{0.0336}$

4 $\sigma_p = \sqrt{0.0336} = \mathbf{18.3\%}$ (ต่ำกว่า $\sigma_1=20\%$ และ $\sigma_2=30\%$ ทั้งคู่!)

สังเกต: Diversification ทำงาน!

$\sigma_1=20\%$, $\sigma_2=30\%$ แต่ Portfolio $\sigma=18.3\%$ — ต่ำกว่าทั้งคู่!

เพราะ Covariance ต่ำ (0.01) → หุ่นไม่ได้เคลื่อนไหวพร้อมกันตลอด

ถ้า $\text{Cov} = 0$: $\sigma_p = \sqrt{(0.6^2 \times 0.04 + 0.4^2 \times 0.09)} = \sqrt{(0.0144 + 0.0144)} = 17.0\%$ (ต่ำกว่าอีก)



Quant Desk: $w^T \Sigma w$ ใช้ทุกวันใน Risk Parity และ Vol Targeting

นอกจาก Markowitz min-variance แล้ว quant funds ใช้ $w^T \Sigma w$ เพื่อ:

- **Risk Parity:** จัด w ให้แต่ละสินทรัพย์ contribute risk เท่ากัน (แทนที่จะให้ weight เท่ากัน)
- **Vol Targeting:** scale w ทั้งพอร์ตให้ $\sqrt{w^T \Sigma w} = \text{target_vol} = 10\%$ ต่อปีเสมอ
- **Greeks aggregation:** delta vector $\times \Sigma \times$ delta vector = portfolio P&L variance จาก factor moves

Σ matrix ต้อง update ทุกวัน — ใช้ EWMA หรือ DCC (Dynamic Conditional Correlation) แทน sample Σ คงที่

8.4 Matrix Inverse & การแก้ระบบ $Ax=b$ — เมทริกซ์ผกผัน

🔍 อุปมา: การ "หาร" ของเมทริกซ์

ในตัวเลขรรวมดา ถ้า $5x = 20$ เราหารด้วย 5 $\rightarrow x = 20/5 = 4$

แต่เมทริกซ์ "หาร" ตรง ๆ ไม่ได้ — เราใช้การ คูณด้วย inverse (A^{-1}) แทน:

ถ้า $Ax = b \rightarrow x = A^{-1}b$ (เหมือน $x = b \div A$)

ประโยชน์: แก่ระบบสมการหลายตัวแปรพร้อมกัน — แทนที่จะแก้ทีละสมการ เขียนเป็น $Ax=b$ แล้วคูณ A^{-1} ครั้งเดียวจบ

$$A^{-1}A = I \quad A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}, \quad \det(A) = ad - bc$$

$$A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

ตัวอย่างคำนวณ: หา inverse ของ $A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$

1 หา determinant: $\det = ad - bc = (2)(3) - (1)(1) = 6 - 1 = 5 (\neq 0 \rightarrow \text{invertible})$

2 สลับ diagonal และใส่ลบ: $[d \ -b; -c \ a] = \begin{bmatrix} 3 & -1 \\ -1 & 2 \end{bmatrix}$

3 หารด้วย det: $A^{-1} = 1/5 \times \begin{bmatrix} 3 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 0.6 & -0.2 \\ -0.2 & 0.4 \end{bmatrix}$

4 ตรวจสอบ $A^{-1}A = I$:

แถว 1: $(0.6 \times 2 + -0.2 \times 1), (0.6 \times 1 + -0.2 \times 3) = (1.2 - 0.2), (0.6 - 0.6) = (1, 0)$

แถว 2: $(-0.2 \times 2 + 0.4 \times 1), (-0.2 \times 1 + 0.4 \times 3) = (-0.4 + 0.4), (-0.2 + 1.2) = (0, 1)$

$\rightarrow \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I \checkmark$

เชื่อมกับ Portfolio — ทำไม inverse จึงสำคัญ

- **Markowitz optimal weights:** น้ำหนัก portfolio ที่ดีที่สุด w^* ต้องใช้ Σ^{-1} (inverse ของ covariance matrix) — $w^* \propto \Sigma^{-1}\mu$
- **Regression:** สูตร OLS $\beta = (X^T X)^{-1} X^T y$ ก็ต้อง invert matrix ($X^T X$)

ระวัง singular matrix: ถ้า $\det = 0 \rightarrow$ matrix ไม่มี inverse $\rightarrow$ ไม่มีคำตอบเดียวที่แน่นอน

สาเหตุในโลกจริง: ข้อมูลซ้ำซ้อน/collinear (เช่น สองหุ้นเคลื่อนไหวเหมือนกันเป๊ะ $\rho=1$) $\rightarrow$ แถวหนึ่ง "เล่าเรื่องเดียวกัน" กับอีกแถว $\rightarrow$ ระบบแยกไม่ออก

โจทย์ฝึก §8.4

ฝึก. หา inverse ของ $A = \begin{bmatrix} 4 & 3 \\ 2 & 1 \end{bmatrix}$ (ถ้ามี) แล้วตรวจว่า $\det \neq 0$ หรือไม่

► ดูเฉลย

8.5 Eigenvalues — ทิศทางหลักของข้อมูล

🔍 **อุปมา:** รูปร่างของก้อนเมฆ

ก้อนเมฆมีรูปร่างรี ยาวไปทางทิศตะวันออก-ตะวันตก

Eigenvector หลัก = ทิศทาง E-W (ที่ขยายออกมากที่สุด)

Eigenvalue = ขนาดที่ขยาย (ยาวแค่ไหน)

Covariance matrix ของ portfolio ก็มี "รูปร่าง" — Eigenvalue บอกว่ามิติไหนสำคัญ

$$A\mathbf{v} = \lambda\mathbf{v} \quad \mathbf{v} = \text{eigenvector}, \lambda = \text{eigenvalue}$$

ตัวอย่างคำนวณ: หา eigenvalues ของ $\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$

1 ตั้ง characteristic equation: $\det(\Sigma - \lambda I) = 0$
 $\Sigma - \lambda I = \begin{bmatrix} 4-\lambda & 2 \\ 2 & 3-\lambda \end{bmatrix}$

2 หา determinant = 0: $(4-\lambda)(3-\lambda) - (2)(2) = 0$
 $= 12 - 4\lambda - 3\lambda + \lambda^2 - 4 = \lambda^2 - 7\lambda + 8 = 0$

3 แก้สมการกำลังสอง: $\lambda = (7 \pm \sqrt{49-32})/2 = (7 \pm \sqrt{17})/2$
 $\sqrt{17} \approx 4.123 \rightarrow \lambda_1 = (7+4.123)/2 \approx \mathbf{5.56}, \lambda_2 = (7-4.123)/2 \approx \mathbf{1.44}$

4 หา eigenvector ของ $\lambda_1 \approx 5.56$: แก้ $(\Sigma - \lambda_1 I)v = 0$
 $(4 - 5.56)v_1 + 2v_2 = 0 \rightarrow -1.56 v_1 + 2 v_2 = 0 \rightarrow v_2 = 0.78 v_1$
 เลือก $v_1 = 1 \rightarrow \mathbf{v \approx [1, 0.78]}$ (ทิศทางหลักที่ข้อมูลกระจายมากที่สุด)

PCA Demo — Variance Explained จาก eigenvalue

สัดส่วน variance ที่ PC แต่ละตัวอธิบาย = $\lambda_i / \Sigma \lambda$

จากตัวอย่าง: $\lambda_1 + \lambda_2 = 5.56 + 1.44 = 7$ (= trace = 4+3 ตามคาด)

- PC1: $\lambda_1/(\lambda_1 + \lambda_2) = 5.56/7 \approx \mathbf{79\%}$ ← PC แรกอธิบาย 79% ของ variance ทั้งหมด!
- PC2: $\lambda_2/(\lambda_1 + \lambda_2) = 1.44/7 \approx 21\%$

เชื่อมกับ Vol Surface: นำตรรกะ λ -ratio นี้ไปใช้กับ covariance matrix ของ IV ทั้ง surface:

- PC1 = parallel shift (level) — IV ทั้ง surface ขึ้น/ลงพร้อมกัน (eigenvalue ใหญ่สุด)
- PC2 = slope/skew — ปลายหนึ่งขึ้น อีกปลายลง
- PC3 = curvature — กลางโป่ง/บุ๋ม

ผลรวม $\lambda_1 + \lambda_2 + \lambda_3$ มักได้ $\approx 99\%$ ของ $\Sigma \lambda \rightarrow$ "3 PC อธิบาย $\sim 99\%$ " — ตอนนี้คำกล่าวนี้นี้มีที่มาชัดเจนแล้วจาก สัดส่วน eigenvalue

โจทย์ฝึก §8.5

ฝึก. หา eigenvalues ของ $\Sigma = \begin{bmatrix} 5 & 1 \\ 1 & 5 \end{bmatrix}$

► ดูเฉลย

เชื่อมกับ Options — PCA ลด Dimension

PCA (Principal Component Analysis) ใช้ eigenvalues ของ Σ :

- **Yield Curve**: 3 PC แรกอธิบาย 99% (level, slope, curvature)
- **Volatility Surface**: ลด dimension จาก 100+ strikes/expiry เหลือ 5–10 factors
- **Eigenvalue ใหญ่** = ทิศทางที่ข้อมูลกระจายมาก = risk factor สำคัญ

8.6 Positive Definite — Covariance Matrix ต้อง Valid

ทำไม Covariance Matrix ต้อง Positive Semi-Definite?

$\sigma^2_p = \mathbf{w}^T \Sigma \mathbf{w}$ ต้อง ≥ 0 เสมอ (variance เป็นลบไม่ได้ในโลกจริง!)

ถ้าสร้าง correlation matrix จากข้อมูลผิดพลาด อาจได้ matrix ที่ $\mathbf{x}^T \mathbf{A} \mathbf{x} < 0$ สำหรับบาง $\mathbf{x}$

→ แปลว่า "portfolio บางชุดมี variance ลบ" → **เป็นไปได้ไม่ได้!** → ต้อง fix matrix ก่อนใช้

สรุปบทที่ 8

- ✓ Vector = รายการตัวเลข, Dot Product = weighted sum = Portfolio Return
- ✓ Matrix = ตารางสัมพันธ์ทุกคู่ → Covariance Matrix
- ✓ $\sigma^2_p = \mathbf{w}^T \Sigma \mathbf{w}$ = สูตร Portfolio Variance ที่ใช้ได้กับ n หุ้นทันที
- ✓ Eigenvalues → PCA → ลด dimension ของ yield curve / vol surface
- ✓ Covariance Matrix ต้อง PSD → variance ไม่ติดลบ

บทที่ 9: Regression & Curve Fitting — "หา Beta และ Vol Surface"

Regression = "หาเส้นที่ fit ข้อมูลที่ดีที่สุด" — ใช้หา Beta ของหุ้น, Hedge Ratio, และ fit Volatility Surface

9.1 Simple Linear Regression

🔍 อุปมา: เส้นที่ผ่านกลุ่มจุด

มีจุดข้อมูล 100 จุด (return ตลาด vs return หุ้น) — กระจายไปทั่ว
เราอยากหาเส้นตรงที่ "ใกล้จุดทุกจุดมากที่สุด"

"ใกล้ที่สุด" = ผลรวมของ (ระยะห่างแนวตั้ง)² น้อยที่สุด (Least Squares)
เส้นนั้นคือ Regression Line: $y = \alpha + \beta x$

มีข้อมูล (x_i, y_i)

→

หา $\beta = \text{Cov}(X, Y) / \text{Var}(X)$

→

หา $\alpha = \bar{y} - \beta \bar{x}$

→

ได้เส้นที่ minimize error²

$$\beta = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \quad \alpha = \bar{y} - \beta \bar{x}$$


$$\min_{\alpha, \beta} \sum_i (y_i - \alpha - \beta x_i)^2 \quad (\text{OLS})$$

🔍 ทำไม $\beta = \text{Cov}(X, Y) / \text{Var}(X)$?

เราอยากหา β ที่ minimize $\sum (y - \alpha - \beta x)^2$ → ทำ derivative เทียบ β แล้ว set = 0

$$\partial / \partial \beta [\sum (y - \alpha - \beta x)^2] = -2 \sum x(y - \alpha - \beta x) = 0$$

แก้ออกมาได้: $\beta = \sum (x_i - \bar{x})(y_i - \bar{y}) / \sum (x_i - \bar{x})^2 = \text{Cov}(X, Y) / \text{Var}(X) \checkmark$



OLS regression: $\beta = \text{Cov}(X,Y)/\text{Var}(X) = \text{slope of regression line}$

เชื่อมกับ Options — Beta และ Hedge Ratio

Beta ของหุ้น = slope ของ regression: $\text{return หุ้น} = \alpha + \beta \times \text{return ตลาด}$

$\beta = 1.5 \rightarrow$ หุ้นผันผวนมากกว่าตลาด 1.5 เท่า

Options Hedge Ratio: ถ้า regress การเปลี่ยนแปลงราคา option (ΔV) บนการเปลี่ยนแปลงราคา underlying (ΔS) เฉพาะช่วงสั้น ๆ (ΔS เล็ก) slope ที่ได้ $\approx$ **Delta** — แต่ระวัง: ถ้า ΔS ใหญ่ slope จะเพี้ยนเพราะ Gamma (Delta เปลี่ยน) และ Vega (σ เปลี่ยน) เข้ามาแทรก ดังนั้น regression slope ให้ delta แค่ *local* ไม่เท่ากับ analytic delta = $\partial V / \partial S$ เป๊ะ

9.2 Regression Diagnostics & Standard Errors — ตรวจสอบสุขภาพโมเดล

🔍 อุปมา: ตรวจสอบสุขภาพหลัง fit เส้น

fit เส้น regression เสร็จ แล้วได้ β สวย ๆ — อย่าเพิ่งเชื่อ!

เหมือนหมอที่ต้อง "ตรวจสอบสุขภาพ" คนไข้ก่อนบอกว่าหายดี เราต้องตรวจ **residuals** (ส่วนที่โมเดลทายพลาด) ก่อน

ถ้า residuals "สุขภาพดี" (สุ่มกระจายไม่มีแบบแผน) $\rightarrow$ เชื่อโมเดลได้

ถ้า residuals มี pattern $\rightarrow$ โมเดลมีปัญหาซ่อนอยู่

$$e_i = y_i - \hat{y}_i \quad (\text{residual} = \text{จริง} - \text{ทาย})$$

plot e_i vs $x \rightarrow$ ควรเป็น random scatter รอบศูนย์ (ไม่มีรูปทรง)

Heteroskedasticity — ความแปรปรวนไม่คงที่

ถ้า การกระจายของ residual โตขึ้นตาม x (เล็กตอน x น้อย, บานออกตอน x มาก เป็นรูปกรวย) $\rightarrow$ variance ไม่คงที่ = heteroskedasticity

เหตุ $\rightarrow$ ผล: β ยัง unbiased (ค่าเฉลี่ยยังถูก) แต่ standard error ผิด $\rightarrow$ t-stat และ confidence interval เชื่อไม่ได้

พบบ่อยมากใน financial returns เพราะ volatility clustering (ช่วงตลาดผันผวน residual ใหญ่, ช่วงสงบ residual เล็ก)

Autocorrelation — residual สัมพันธ์กันข้ามเวลา

ถ้า residual วันนี้ทำนาย residual พรุ่งนี้ได้ (correlated over time) $\rightarrow$ ละเมิดสมมติฐานว่า error เป็นอิสระ

ตรวจด้วย Durbin-Watson statistic (ค่าใกล้ 2 = ไม่มี autocorrelation; ใกล้ 0 = บวก; ใกล้ 4 = ลบ)
พบทั่วไปใน time-series returns $\rightarrow$ standard error ต่ำเกินจริง $\rightarrow$ คิดว่า β significant ทั้งที่จริงไม่

$$se(\beta) = \frac{\sigma_{\text{resid}}}{\sqrt{n} \sigma_x} \quad t = \frac{\beta}{se(\beta)} \quad \Rightarrow \quad |t| > 2 \Rightarrow \beta \text{ significant (95\%)}$$

ตัวอย่างคำนวณ: β significant ไหม?

สมมติได้ $\beta = 1.5$, $se(\beta) = 0.3$

t-stat = $\beta / se(\beta) = 1.5 / 0.3 = 5.0$

$|t| = 5 > 2 \rightarrow$ **significant!** β แตกต่างจาก 0 อย่างมีนัยสำคัญ — เชื่อได้ว่าหุ้นมี exposure กับตลาดจริง

โจทย์ฝึก §9.2

ฝึก. regression ให้ $\beta = 0.8$, $se(\beta) = 0.5$ — β นี้ significant หรือไม่?

► ดูเฉลย

⚠ Model Risk: Data Snooping — In-sample ดีไม่ได้แปลว่า Out-of-sample ดี

การ fit regression กับ financial data เจอกับดักหลายอย่าง:

- **Overfitting:** R^2 สูงใน in-sample แต่พัง out-of-sample เพราะ model จำ noise ไปด้วย
- **Multiple testing:** ลอง signal 100 ตัว — ปกติ 5 ตัวจะ significant ด้วยแค่โชค ($\alpha=5\%$)
- **Survivorship bias:** data มีเฉพาะบริษัทที่ยังอยู่ → β ที่ได้ bias ขึ้น
- **Look-ahead bias:** ใช้ข้อมูลที่รู้แล้วตอน "จำลองอดีต" → performance สวยเกินจริง

แนวทาง: Walk-forward validation, Cross-validation, Bonferroni correction สำหรับ multiple signals

9.3 Multiple Regression — หลายปัจจัยพร้อมกัน

🔍 อุปมา: ราคาบ้านขึ้นกับหลายปัจจัย

ราคาบ้าน = $\alpha + \beta_1(\text{พื้นที่ } m^2) + \beta_2(\text{ห้องนอน}) + \beta_3(\text{ระยะจาก BTS})$

ถ้าวิ่ง regression นี้ → รู้ว่า "พื้นที่เพิ่ม 1 m^2 เพิ่มราคาเท่าไร โดยคำนึงปัจจัยอื่น"

ใน Finance: return หุ้น = $\alpha + \beta_1(\text{market}) + \beta_2(\text{size}) + \beta_3(\text{value}) + \varepsilon$

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_n x_n + \varepsilon \quad \mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \quad (\text{OLS})$$

เชื่อมกับ Options — Fama-French Factor Model

Return = $\beta_1(\text{Market}) + \beta_2(\text{SMB}) + \beta_3(\text{HML}) + \alpha$

- Hedge Market risk ด้วย Index futures (β_1)
- Hedge Size risk ด้วย Small-cap vs Large-cap spread (β_2)
- ไม่ต้อง hedge ทีละหุ้น → hedge 3 factors ครอบ portfolio ทั้งหมด

9.4 Multicollinearity — ตัวแปรซ้ำซ้อน

🔍 อุปมา: พยานสองคนเล่าเรื่องเดียวกัน

ถ้ามีพยาน 2 คนในศาล แต่ทั้งคู่ **เล่าเรื่องเดียวกันเป๊ะ** — ผู้พิพากษาแยกไม่ออกว่าหลักฐานมาจากใคร "ทำ" จริง

factor model ก็เหมือนกัน: ถ้าสองปัจจัยเล่าเรื่องเดียวกัน (correlated สูง) โมเดล แยกไม่ออกว่าใคร ทำให้ **return เปลี่ยน** → β ของแต่ละตัว **ไม่เสถียร** (กระโดดไปมา)

เหตุ → ผล

factors correlated สูง → $\det(X^T X) \approx 0 \rightarrow (X^T X)^{-1}$ ระเบิด → $\text{Var}(\hat{\beta})$ มหาศาล → เปลี่ยนข้อมูลนิดเดียว $\hat{\beta}$ พลิกเครื่องหมาย

Detection — VIF (Variance Inflation Factor)

วิธีตรวจ: regress ปัจจัย j กับปัจจัยที่เหลือ ได้ R^2_j แล้วคำนวณ

$$\text{VIF}_j = 1 / (1 - R^2_j)$$

- ถ้าปัจจัย j ทำนายไม่ได้จากตัวอื่น ($R^2_j \approx 0$) → $\text{VIF} \approx 1$ (ดีไม่ซ้ำซ้อน)
- ถ้าปัจจัย j ถูกตัวอื่นทำนายได้เกือบหมด ($R^2_j = 0.9$) → $\text{VIF} = 1/(1-0.9) = 10$

กฎ: $\text{VIF} > 10$ → มีปัญหา multicollinearity ชัดเจน

อีกวิธี: ดู **correlation matrix** ของ **factors** โดยตรง — ถ้าคู่ไหน $|p| > 0.8$ ให้ระวัง

วิธีแก้ — ตัด/รวม หรือใช้ PCA (เชื่อมกับบทที่ 8)

- **Drop:** ทิ้งปัจจัยซ้ำซ้อนตัวหนึ่งทิ้งไป (เก็บตัวที่ตีความง่ายกว่า)
- **Combine:** รวมสองปัจจัยที่ซ้ำเป็นตัวเดียว (เช่น เฉลี่ย value score)
- **PCA:** แปลง factors ที่ correlated เป็น principal components ที่ **orthogonal** (ตั้งฉาก **ไม่ correlated**) โดยสร้าง — ตรงนี้ผูกกลับไป §8.5 eigenvector ของ covariance matrix factors → กำจัดความซ้ำซ้อนได้ที่ราก

โจทย์ฝึก §9.4

ฝึก. regress ปัจจัย HML กับปัจจัยอื่น ๆ ได้ $R^2 = 0.95$ — VIF เท่าไหร่ และมีปัญหา multicollinearity ไหม?

► ดูเฉลย

9.5 R^2 — วัดความดีของ Model

🔍 อุปมา: พยากรณ์อากาศ

ถ้าพยากรณ์อากาศ "แม่นยำ" 80% $\rightarrow R^2 = 0.80$

ถ้าแม่นยำแค่ 20% $\rightarrow R^2 = 0.20$

R^2 = "model อธิบายความแปรปรวนของข้อมูลได้กี่ %" "

$R^2 = 1.0$: predict ได้แม่นยำขนาดนั้นคงไม่มีในโลก finance

$R^2 = 0.30$ สำหรับ daily stock return ถือว่าดีมากแล้ว!

$$R^2 = 1 - \frac{SS_{\text{residual}}}{SS_{\text{total}}}$$

R^2	ความหมาย	ตัวอย่างใน Finance
0.90–1.0	ดีมาก	Bond yield vs maturity (yield curve fit)
0.50–0.90	พอใช้ได้	Beta regression ของหุ้น large-cap
0.10–0.50	อ่อนแต่ยังมีประโยชน์	Vol smile fit ด้วยสูตร simple
<0.10	แย่มาก	ปัจจัยอื่นสำคัญกว่า หรือ noise มาก

9.6 Curve Fitting — Fit Volatility Surface

🔍 อุปมา: วาดเส้นโค้งผ่านจุดข้อมูล

Volatility Smile: IV ของ options หลาย Strike ไม่เป็นเส้นตรง — มีรูปร่างเป็นรอยยิ้ม/เอียง
เราอยาก fit สูตรผ่านจุดข้อมูลเหล่านั้น เพื่อ interpolate IV ของ Strike กลางๆ

Simple: $\sigma(K) = a + bK + cK^2$ (polynomial degree 2)

Advanced: SVI, SABR model

$$\sigma(K, T) = a_0 + a_1K + a_2K^2 + a_3T + a_4KT + \dots$$

Overfitting — กับดักของ Curve Fitting

Degree 2: $\sigma(K)$ smooth, interpolate ได้ดี

Degree 10: ผ่านทุกจุดพอดี แต่ระหว่างจุด "กลม" หรือ "พุ่ง" ขึ้นผิดปกติ

กฎ: ใช้ model ที่ง่ายที่สุดที่อธิบายข้อมูลได้ดีพอ — R^2 เพิ่มขึ้นน้อยมากเมื่อเพิ่ม degree → หยุด

เชื่อมกับ Options — Vol Surface Fitting

Market makers ใช้ SVI/SABR fit IV surface จาก quoted prices

→ ได้สูตร $\sigma(K, T)$ ที่ smooth → interpolate IV ของ strike ที่ไม่มีใน chain

→ ใช้ price exotic options, calibrate hedging

สรุปบทที่ 9

- ✓ Simple Regression: $y = \alpha + \beta x$, $\beta = \text{Cov}/\text{Var}$ → **Beta ของหุ้น**
- ✓ Multiple Regression: Factor Models → hedge หลาย risk factor พร้อมกัน
- ✓ R^2 = สัดส่วนที่ model อธิบายได้ — R^2 สูงไม่ได้แปลว่าดีเสมอ (overfitting)
- ✓ Curve Fitting → fit Volatility Smile/Surface

โจทย์ฝึกหัด Part IV

ข้อ 1. Portfolio 3 assets: $w = [0.5, 0.3, 0.2]$, returns = $[8\%, -2\%, 5\%]$

คำนวณ Portfolio Return ด้วย Dot Product

► ดูเฉลย

ข้อ 2. หุ้น 2 ตัว: $w = [0.7, 0.3]$, $\sigma_1 = 25\%$, $\sigma_2 = 15\%$, $\rho = 0.4$

คำนวณ Portfolio Standard Deviation

► ดูเฉลย

ข้อ 3. ข้อมูล 5 ปี: Return ตลาด = $[10\%, -5\%, 8\%, -3\%, 12\%]$, Return หุ้น = $[15\%, -8\%, 12\%, -4\%, 18\%]$

ประมาณ Beta ของหุ้น (ใช้ข้อมูล 5 จุด)

► ดูเฉลย

จบ Part IV

ตอนนี้คุณจัดการ Portfolio หลายสินทรัพย์ด้วย Matrix ได้แล้ว!

Part V: Optimization → หาน้ำหนัก Portfolio ที่ดีที่สุด

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part V: Optimization — หาคำตอบที่ดีที่สุด

บทที่ 10-11: Linear Programming, Simplex, Dual, Integer LP,
Gradient Descent, Lagrange, Convex Optimization, QP

บทที่ 10: Linear Programming

อุปมา: ร้านขนมที่มีส่วนผสมจำกัด

สมมติเปิดร้านขนม ทำได้ 2 อย่าง: **ขนมปัง A** (กำไร 8 บาท) และ **ขนมปัง B** (กำไร 5 บาท)

แต่มีข้อจำกัด: แป้ง 20 ถ้วย (A ใช้ 5 ถ้วย, B ใช้ 2 ถ้วย) และ เวลา 5 ชั่วโมง (แต่ละชิ้น 1 ชั่วโมง)

คำถาม: ทำ A กี่ชิ้น B กี่ชิ้น *จึงจะกำไรมากที่สุด?* — นี่คือ Linear Programming!

ทรัพยากรจำกัด

→

ตั้ง Constraints

→

เขียน Objective

→

หาจุด Optimal

LP = หาค่า maximum/minimum ของฟังก์ชันเชิงเส้น ภายใต้เงื่อนไข (constraints) ที่เป็นเชิงเส้น

10.1 แนวคิดและการตั้งโจทย์

$$\begin{aligned} \text{Maximize} \quad & z = c_1x_1 + c_2x_2 \\ \text{subject to} \quad & a_{11}x_1 + a_{12}x_2 \leq b_1 \\ & a_{21}x_1 + a_{22}x_2 \leq b_2 \\ & x_1, x_2 \geq 0 \end{aligned}$$

ทำไมสมการถึงเขียนแบบนี้?

c_1, c_2 = "กำไรต่อหน่วย" ของแต่ละตัวเลือก → เป้าหมายคือ maximize ผลรวม

a, b = "ส่วนผสมที่ใช้" vs "ส่วนผสมที่มี" → ข้อจำกัดทางกายภาพ


ทุก constraint เป็น "เส้นตรง" → ทำให้ feasible region เป็น "รูปหลายเหลี่ยม" → คำตอบอยู่ที่มุม!

ตัวอย่าง: จัดพอร์ต Options**Maximize** Expected Payoff = $8x_1 + 5x_2$ $(x_1 = \text{จำนวน Call } K=100, x_2 = \text{จำนวน Call } K=110)$ **Subject to:**Premium: $5x_1 + 2x_2 \leq 20$ (budget ฿20)Risk: $x_1 + x_2 \leq 5$ (ไม่เกิน 5 สัญญา) $x_1, x_2 \geq 0$ **10.2 Graphical Method****อุปมา: แผนที่ที่มีรั้วกัน**

นึกภาพแผนที่ 2 มิติ Constraint แต่ละข้อคือ "รั้ว" ที่กั้น พื้นที่ที่เหลือ (ข้างใน) คือ **Feasible Region** — บริเวณที่ทำได้จริง

Objective Function คือ "เส้นระดับความสูง" ที่ขนานกัน → เลื่อนเส้นออกไปเรื่อยๆ จนชนรั้ว → จุดนั้นคือ optimal!

สำหรับ 2 ตัวแปร แก้ได้ด้วยกราฟ: วาด constraints → หา feasible region → เช็ก corner points

LP feasible region with corner points; optimal at $(10/3, 5/3)$ **Corner Point Theorem**

คำตอบ optimal ของ LP อยู่ที่มุม (corner) ของ feasible region เสมอ!

ดังนั้นเช็คแค่ทุก corner → เลือกค่า z สูงสุด

1 หา **corner points** จากจุดตัดของ constraints:

- (0,0) — origin
- (0,5) — constraint 2 ตัด y-axis: $x_1=0 \rightarrow x_2=5$
- (10/3, 5/3) — constraints 1 และ 2 ตัดกัน: แก่ระบบ $5x_1+2x_2=20$, $x_1+x_2=5$
- (4,0) — constraint 1 ตัด x-axis: $x_2=0 \rightarrow 5x_1=20 \rightarrow x_1=4$

2 คำนวณ z ที่แต่ละ **corner**:

- $z(0,0) = 8(0)+5(0) = 0$
- $z(0,5) = 8(0)+5(5) = 25$
- $z(10/3, 5/3) = 8(10/3)+5(5/3) = 80/3+25/3 = 105/3 = 35 \leftarrow \text{Maximum!}$
- $z(4,0) = 8(4)+5(0) = 32$

3 สรุป: ซื้อ Call K=100 จำนวน 3.33 สัญญา + Call K=110 จำนวน 1.67 สัญญา $\rightarrow$ Payoff = ฿35

10.3 Simplex Method

อุปมา: เดินป่าในความมืด หาจุดสูงสุด

ลองนึกถึงการเดินป่าตอนกลางคืน มองไม่เห็นทิวทัศน์ทั้งหมด แต่ *รู้สึกได้* ว่าทิศไหนลาดขึ้นชัน

วิธี Simplex: ยืนอยู่ที่มุมหนึ่ง $\rightarrow$ มองไปมุมใกล้ๆ $\rightarrow$ เดินไปมุมที่สูงกว่า $\rightarrow$ ทำซ้ำจนไม่มีมุมที่สูงกว่า

ไม่ต้องสำรวจทุกมุม! ในทางปฏิบัติ Simplex เร็วมากแม้มีหลายร้อยตัวแปร

เมื่อมีหลายตัวแปร (ใช้กราฟไม่ได้) ใช้ **Simplex Algorithm**:

1. เริ่มที่ corner หนึ่ง (มักเป็นจุด origin)
2. มองไปรอบๆ ว่า corner ไหนดีกว่า (ดู "reduced cost")
3. เดินไปที่ corner ที่ดีขึ้นมากที่สุด (pivot)
4. ทำซ้ำจนไม่มี corner ที่ดีกว่า $\rightarrow$ **optimal!**

Corner Point Theorem

$\rightarrow$

คำตอบอยู่ที่มุม

$\rightarrow$

เดินจากมุมสู่มุมที่ดีขึ้น

$\rightarrow$

หยุดเมื่อไม่มีมุมดีกว่า

$\rightarrow$

Optimal!

Simplex ไม่ต้องจำขั้นตอน แค่เข้าใจหลักการ

"เดินไปตาม edge ของ feasible region จาก corner สู่ corner ที่ดีขึ้นเรื่อยๆ"
 ในทางปฏิบัติใช้ software (Excel Solver, Python scipy.optimize.linprog)

10.4 Dual Problem & Shadow Price

อุปมา: "ถ้าได้วัตถุดิบเพิ่ม 1 หน่วย กำไรเพิ่มเท่าไร?"

เจ้าของร้านขนมถามว่า "ถ้าซื้อแป้งเพิ่ม 1 ถ้วย (ราคา ฿?) กำไรจะเพิ่มขึ้นเท่าไร?" — นั่นคือ Shadow Price!

Shadow Price = "ราคาเงา" ของ constraint — บอกว่า constraint ไหน "แพง" ที่สุด ควรไปผ่อนคลายก่อน

ทุก LP (Primal) มีคู่ (Dual) — ให้มุมมองเพิ่มเติม:

$$\text{Primal: } \max \mathbf{c}^T \mathbf{x} \text{ s.t. } \mathbf{Ax} \leq \mathbf{b}, \mathbf{x} \geq 0$$

$$\text{Dual: } \min \mathbf{b}^T \mathbf{y} \text{ s.t. } \mathbf{A}^T \mathbf{y} \geq \mathbf{c}, \mathbf{y} \geq 0 \quad \Rightarrow \quad \text{Strong Duality: ค่าเท่ากันที่ optimal}$$

ทำไม Dual มีอยู่?

Primal ถามว่า "จัด resource ยังไงให้ได้กำไรสูงสุด?"

Dual ถามว่า "resource แต่ละอย่างมีมูลค่าเท่าไร?" (y^* = shadow prices)

Strong Duality: ทั้งสองคำถามมีคำตอบที่สอดคล้องกันที่ optimal → สามารถใช้ Dual แทน Primal ได้เมื่อสะดวกกว่า

Shadow Price (y^*) = "ถ้าเพิ่ม resource (b) อีก 1 หน่วย ค่า objective จะเพิ่มเท่าไร?"

- 1 จากตัวอย่าง Options: ที่ optimal (10/3, 5/3) — budget constraint: $5x_1 + 2x_2 = 20$ (active)
- 2 Shadow price ของ budget constraint = ฿1/บาท budget (จาก Dual: $y_1 = 1, y_2 = 3$)
- 3 ถ้า budget เพิ่มจาก ฿20 → ฿21 → Expected Payoff เพิ่มจาก ฿35 → ฿36
- 4 ถ้า risk constraint active: shadow price บอกว่า "การเพิ่ม 1 สัญญา" มีมูลค่าเท่าไร

เชื่อมกับ Options

Shadow Price ของ budget constraint = "ถ้ามีเงินเพิ่มอีก \$1 expected payoff จะเพิ่มเท่าไร?"
ใช้ตัดสินใจว่าควร "ขยาย budget" หรือ "ลด risk limit" — constraint ไหน "แพง" กว่า



Trading Desk: Shadow Price = "ราคา" ของ Risk Limit แต่ละข้อ

Fund manager ที่มี position limits ใช้ Dual / Shadow Price เพื่อ:

- **VaR constraint:** shadow price = "ถ้าเพิ่ม VaR limit \$1M → PnL potential เพิ่มเท่าไร?"
- **Capital constraint:** "margin ที่ต้องวาง \$1M มีค่า opportunity cost เท่าไร?"
- **Concentration limit:** "ถ้า sector limit ถูก relax 1% → เพิ่ม return ได้เท่าไร?"

Shadow price เป็นเครื่องมือช่วย **argue กับ risk manager** ว่า limit ไหนควรปรับก่อน

10.5 Sensitivity Analysis

ถ้า parameter เปลี่ยน คำตอบเปลี่ยนไหม? — สำคัญเพราะ input มักไม่แน่นอน

- **Coefficient ใน objective เปลี่ยน:** ถ้า expected payoff ของ Call เปลี่ยน → basis ยังเหมือนเดิมไหม? (มี "allowable range")
- **RHS ของ constraint เปลี่ยน:** ถ้า budget เพิ่ม → ใช้ shadow price คำนวณได้ทันที (ดูราบที่อยู่ใน range)

Sensitivity ใน Options Trading

Greeks ของ Options ก็คือ sensitivity analysis! Delta = sensitivity ของ option price ต่อ S, Vega = sensitivity ต่อ σ

Simplex sensitivity = sensitivity ของ optimal solution ต่อ parameters ของโจทย์ LP

10.6 Integer Linear Programming (ILP)

อุปมา: ซื้อตัวเครื่องบินครึ่งใบไม่ได้

LP อาจตอบว่า "ควรซื้อ 3.7 สัญญา" — แต่สัญญา Options ซื้อเป็นจำนวนเต็มเท่านั้น! (1 contract = 100 shares)

ILP แก้ปัญหานี้โดยบังคับให้ตัวแปรเป็นจำนวนเต็ม

ILP = LP ที่ตัวแปรต้องเป็นจำนวนเต็ม

$$\max \mathbf{c}^T \mathbf{x} \text{ s.t. } A\mathbf{x} \leq \mathbf{b}, \mathbf{x} \geq 0, \mathbf{x} \in \mathbb{Z}^n$$

แก้ LP Relaxation

→

ตัวแปรไม่เต็ม?

→

Branch ($x \leq 3$ หรือ $x \geq 4$)

→

แก้ใหม่แต่ละ branch

→

Integer Solution

ILP ยากกว่า LP มาก!

LP แก้ได้ใน polynomial time แต่ ILP เป็น NP-hard → ไม่มี algorithm ที่เร็วเสมอ

วิธีแก้: **Branch and Bound** — แก้ LP relaxation ก่อน แล้ว branch ที่ตัวแปรที่ไม่เป็นจำนวนเต็ม

เชื่อมกับ Options

Options ซื้อเป็น **สัญญา** (1 contract = 100 หุ้น) → ต้องเป็นจำนวนเต็ม!

ตัวอย่าง: เลือก combination ของ option contracts ที่ maximize payoff-to-risk ภายใต้ budget constraint → ILP problem

บทที่ 11: Nonlinear Optimization

อุปมา: โลกจริงไม่ใช่เส้นตรง

Portfolio risk ไม่ใช่ linear — เพิ่ม 2 เท่าของสินทรัพย์ไม่ได้เพิ่ม risk 2 เท่า (เพราะ diversification!)

Nonlinear optimization จัดการกับฟังก์ชันที่ "โค้ง" — อย่าง Portfolio Variance = $w^T \Sigma w$ ซึ่งเป็น *quadratic* (โค้งพาราโบลา)

โลกจริงไม่เป็นเส้นตรง — Portfolio Optimization ของ Markowitz เป็น **Quadratic** ไม่ใช่ Linear

11.1 Unconstrained Optimization

หา min/max ของ $f(x)$ โดยไม่มี constraints:

$$f'(x^*) = 0 \quad \begin{cases} f''(x^*) > 0 & \Rightarrow \text{minimum} \\ f''(x^*) < 0 & \Rightarrow \text{maximum} \end{cases}$$

ทำไม $f'=0$ คือ optimal?

ถ้า slope $\neq 0$ หมายความว่าเดินไปอีกนิดจะ "ดีขึ้น" → ยังไม่ optimal!

ที่ optimal จริง: ทุกทิศทางจาก x^* จะ "แย่ลง" → slope ต้องเป็น 0 (หรือ gradient = 0 สำหรับหลายตัวแปร)

11.2 Gradient Descent — "เดินลงเขา"

อุปมา: ตาบอด ลงเขาในหมอก

ลองนึกถึงการลงเขาตอนหมอกลง มองไม่เห็นทาง แต่รู้สึกได้ว่าทิศไหน "ลาดชันลงมากที่สุด"

วิธี Gradient Descent: คำนวณทิศที่ "ชันขึ้น" (gradient) แล้วเดินสวนทาง → ลงเร็วที่สุด

ขนาดก้าว (α = learning rate): เล็กเกินไป = ช้า, ใหญ่เกินไป = กระโดดข้ามหุบเขา!

$$x_{n+1} = x_n - \alpha \nabla f(x_n)$$


α = learning rate (ขนาดก้าว), ∇f = gradient (ทิศที่ f เพิ่มขึ้นเร็วสุด) → เดินสวนทาง = ลดเร็วสุด

คำนวณ ∇f (gradient) →เดินสวนทาง ($-\alpha \nabla f$) →Update x →

ทำซ้ำ →

 $|\nabla f| \approx 0 \rightarrow$ หยุด

- 1 โจทย์: Minimize $f(x) = x^2$ โดยใช้ Gradient Descent, $\alpha=0.3$, เริ่มที่ $x_0=4$
- 2 $f'(x) = 2x$ (gradient)
- 3 Iteration 1: $x_1 = 4 - 0.3 \times (2 \times 4) = 4 - 2.4 = \mathbf{1.6}$
- 4 Iteration 2: $x_2 = 1.6 - 0.3 \times (2 \times 1.6) = 1.6 - 0.96 = \mathbf{0.64}$
- 5 Iteration 3: $x_3 = 0.64 - 0.3 \times (2 \times 0.64) = 0.64 - 0.384 = \mathbf{0.256}$
- 6 เข้าใกล้ 0 (คำตอบจริง) ทุก iteration! หลังหลาย iteration $\rightarrow x \rightarrow 0$



Gradient descent on quadratic bowl — each step moves opposite to gradient

เชื่อมกับ Options

ใช้ Gradient Descent สำหรับ:

- **Model Calibration:** หา parameters ที่ทำให้ model price $\approx$ market price
- **Volatility Surface Fitting:** minimize ผลต่างระหว่าง model vol vs market vol

11.3 Lagrange Multipliers — Optimization ที่มี Constraints

อุปมา: เดินบนถนน (constraint) หาจุดที่สูงสุด

ถ้าต้องเดินอยู่บนถนน (constraint $g=0$) แต่อยากหาจุดที่ "สูงที่สุด" (maximize f)

จุด optimal คือจุดที่ "ทิศทางขึ้นสูง" ชี้ *ตั้งฉากกับถนน* — ถ้าไม่ตั้งฉาก แปลว่าเดินต่อบนถนนแล้วจะสูงขึ้นได้อีก!

Lagrange Multiplier (λ) = อัตราส่วนระหว่าง gradient ของ f กับ gradient ของ g ที่จุด optimal

หา min/max ของ $f(x)$ ภายใต้เงื่อนไข $g(x) = 0$:

$$\mathcal{L}(x, \lambda) = f(x) - \lambda g(x) \quad \frac{\partial \mathcal{L}}{\partial x} = 0, \quad \frac{\partial \mathcal{L}}{\partial \lambda} = 0$$

$$\nabla f = \lambda \nabla g \quad (\text{gradients parallel at optimum})$$

- 1 **Markowitz Problem:** Minimize $\sigma^2_p = w^T \Sigma w$ s.t. $w^T \mu = r^*$ (target) และ $w^T 1 = 1$
- 2 Lagrangian: $L = w^T \Sigma w - \lambda_1(w^T \mu - r^*) - \lambda_2(w^T 1 - 1)$
- 3 $\partial L / \partial w = 0 \rightarrow 2 \Sigma w - \lambda_1 \mu - \lambda_2 1 = 0 \rightarrow w^* = \Sigma^{-1}(\lambda_1 \mu + \lambda_2 1) / 2$
- 4 ปรับ λ_1, λ_2 ให้ตรงกับ constraints $\rightarrow$ ได้ efficient portfolio!
- 5 ทำสำหรับ r^* ต่างๆ $\rightarrow$ ได้ **Efficient Frontier** (เส้นโค้ง risk vs return)

เชื่อมกับ Options — Markowitz Portfolio Optimization!

Minimize Portfolio Risk: $\sigma^2_p = w^T \Sigma w$

Subject to: $w^T \mu = \text{target return}, w^T 1 = 1$

ใช้ Lagrange: $L = w^T \Sigma w - \lambda_1(w^T \mu - r^*) - \lambda_2(w^T 1 - 1)$

$\rightarrow$ หา **Efficient Frontier** (เส้นโค้งของ risk vs return ที่ดีที่สุด)

11.4 KKT Conditions — Optimization ที่มี Inequality Constraints

อุปมา: Lagrange แก่ "ต้องอยู่บนเส้น" แต่ชีวิตจริงคือ "ห้ามเกินเพดาน" 🔍

Lagrange จัดการได้แค่ constraint แบบ **equality** ($g=0$) — เหมือนบังคับว่า "ต้องเดินอยู่บนถนนเส้นนี้เป๊ะๆ"

แต่ชีวิตจริงของพอร์ตคือ constraint แบบ **inequality**: "ห้าม short" ($w \geq 0$), "ห้าม position เกิน 10%" ($w \leq 0.1$) — เป็น "เพดาน" และ "พื้น" ไม่ใช่เส้นเดียว

KKT (Karush-Kuhn-Tucker) = Lagrange เวอร์ชันที่รับ inequality ได้ — กฎเกณฑ์สำคัญสู่การจัดพอร์ต option จริงๆ

หา min ของ $f(x)$ ภายใต้เงื่อนไข inequality $g_i(x) \leq 0$ — เงื่อนไข KKT มี 4 ข้อ:

$$\min f(\mathbf{x}) \quad \text{s.t.} \quad g_i(\mathbf{x}) \leq 0$$

1. Stationarity: $\nabla f + \sum_i \mu_i \nabla g_i = 0$
2. Primal feasibility: $g_i(\mathbf{x}) \leq 0$
3. Dual feasibility: $\mu_i \geq 0$
4. Complementary slackness: $\mu_i \cdot g_i(\mathbf{x}) = 0$

หัวใจของ KKT คือ Complementary Slackness

ข้อ 4 ($\mu_i \cdot g_i = 0$) บอกว่าแต่ละ constraint ต้องอยู่ในสถานะใดสถานะหนึ่งเท่านั้น:

- **Active (binding):** $g_i=0$ และ $\mu_i>0 \rightarrow$ constraint "กีด" — เราชนเพดาน/พื้นพอดี เช่น โดนพื้น no-short ($w=0$) ดึงไว้ทำให้ μ มีค่า (shadow price > 0)
- **Inactive (slack):** $g_i<0$ และ $\mu_i=0 \rightarrow$ constraint "ไม่กีด" — เรายังห่างจากเพดาน constraint นี้จึงไม่มีผล ($\mu=0$)

พูดอีกอย่าง: ถ้า constraint ไม่ binding มันก็ไม่มี shadow price — μ จะเป็น 0 โดยอัตโนมัติ นี่คือโอเคเดียวที่ทำให้ KKT จัดการ inequality ได้

ตัวอย่าง: Minimize $f(w)=w^2$ s.t. $w \geq 1$

เขียน constraint ในรูป $g_i \leq 0$: $w \geq 1 \iff g(w) = 1-w \leq 0$

สังเกตก่อน: ถ้าไม่มี constraint จุด min ของ w^2 คือ $w=0$ — แต่ $w=0$ ละเมิด $w \geq 1$! ดังนั้น constraint ต้อง "กีด"

เขียนเงื่อนไข KKT:

- Stationarity: $2w + \mu(-1) = 0 \rightarrow 2w - \mu = 0$
- Complementary slackness: $\mu(1-w) = 0$

ลองเคส constraint active ($1-w=0 \rightarrow w=1$):

จาก stationarity: $\mu = 2w = 2(1) = 2 \rightarrow \mu=2 > 0 \checkmark$ (dual feasibility ผ่าน)

เช็ค primal: $w=1 \geq 1 \checkmark \rightarrow$ ทุกเงื่อนไขผ่าน $\rightarrow$ คำตอบ $w^* = 1, \mu = 2$

ตีความ $\mu=2$ เป็น shadow price: ถ้าผ่อน constraint จาก $w \geq 1$ เป็น $w \geq 0.9$ (ขยับพื้นลง 0.1) ค่า f จะลดลงประมาณ $\mu \times 0.1 = 2 \times 0.1 = 0.2$

(ตรวจสอบ: $f(1)=1, f(0.9)=0.81 \rightarrow$ ลดลง $0.19 \approx 0.2 \checkmark$)

เชื่อมกับ Options — Long-Only Markowitz

Markowitz แบบ long-only คือ: Minimize $w^T \Sigma w$ s.t. $\Sigma w = 1$ AND $w \geq 0$

constraint $\Sigma w = 1$ เป็น equality (ใช้ Lagrange λ) แต่ constraint $w \geq 0$ เป็น inequality — ต้องใช้ KKT (μ_i) จัดการ

กลไก: สินทรัพย์ที่ "อยาก" ได้น้ำหนักติดลบ (model อยาก short) จะโดน complementary slackness ตรึงไว้ที่ $w=0$ (active constraint, $\mu > 0$) ส่วนสินทรัพย์ที่เหลือมี $w > 0$ (inactive, $\mu=0$) ก็แก้ระบบ equality ตามปกติ

นี่คือเหตุผลที่ optimizer จริงใช้ Quadratic Programming (QP) ที่มี KKT ไม่ใช่ Lagrange ล้วนๆ — เพราะ Lagrange จัดการ "ห้าม short" ไม่ได้

⚠ **Model Risk: GIGO — Markowitz ดีแค่เท่ากับ Input ที่ป้อนเข้าไป**

"Garbage In, Garbage Out" — optimizer หา optimal solution ของ problem ที่ถูกตั้ง ไม่ใช่ problem จริง:

- **Expected return (μ):** ประมาณยากที่สุด — error เล็กน้อยทำ weight เปลี่ยนมาก (error maximization)
- **Covariance Σ :** unstable — Σ ปีที่แล้วอาจไม่ valid ปีนี้ โดยเฉพาะตอน regime change
- **Constraints ต้องสมเหตุสมผล:** KKT หา optimal ของ constraints ที่กำหนด — ถ้า constraints ผิด optimal ก็ผิด

แนวทางปฏิบัติ: Black-Litterman model (blend prior + views), cap weight ไม่เกิน 20%, rebalance ทุก quarter

11.5 Convex Optimization

อุปมา: ชาม vs อาน

Convex function = รูปชาม → มีก้นชามเดียว ไม่ว่าเริ่มจากจุดไหน Gradient Descent จะหาค้นหาเจอ

Non-convex = รูปอาน (saddle) หรือภูมิประเทศขรุขระ → มีหลายหุบเขา อาจติดอยู่ที่ "หุบเขาเล็ก" ที่ไม่ใช่ที่ดีที่สุด

ข่าวดีสำหรับ Quant: Portfolio optimization (Markowitz) เป็น **convex**!

ทำไม Convex สำคัญ?

- Convex → มี **minimum เดียว (global)** → Gradient Descent จะหาเจอเสมอ ไม่ว่าเริ่มจากไหน
- Non-convex → มีหลาย local minimum → อาจติดอยู่ที่จุดที่ไม่ใช่ global minimum
- การตรวจสอบ: f convex $\iff$ Hessian (matrix of second derivatives) เป็น PSD

ข่าวดี: Portfolio optimization (Markowitz) เป็น **convex**! → มีคำตอบเดียวที่ดีที่สุด

ข่าวร้าย: Calibration ของบาง model (เช่น Stochastic Volatility) เป็น **non-convex** → ต้องใช้เทคนิคพิเศษ

11.6 Quadratic Programming (QP)

ทำไม QP ถึงเป็น "ขั้นพิเศษ" ของ Nonlinear Optimization?

QP = objective เป็น quadratic (โด่งพาราโบลา) + constraints เป็น linear

นี่คือ "จุดกึ่งกลาง": ยากกว่า LP (เพราะ objective ไม่เส้นตรง) แต่ง่ายกว่า nonlinear ทั่วไป (เพราะ convex)

ข้อดี: มี solver ที่เร็วและแม่นยำ — แก้ Markowitz ได้ใน milliseconds!

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{c}^T \mathbf{x} \quad \text{s.t. } \mathbf{A} \mathbf{x} \leq \mathbf{b}$$

$\mathbf{Q} = 2\Sigma$ (Covariance)

→

objective = $\mathbf{w}^T \Sigma \mathbf{w}$

→

constraints = budget + return

→

QP Solver

→

Efficient Portfolio!

เชื่อมกับ Options

Mean-Variance Optimization ของ Markowitz เป็น QP พอดี!

$\mathbf{Q} = 2\Sigma$ (covariance matrix), $\mathbf{c} = 0$ หรือ $-\mu$

ใช้ QP solver ใน Python (cvxpy, scipy) แก้ได้ในเสี้ยววินาที → optimal portfolio weights!

- 1 ตัวอย่าง QP 2 สินทรัพย์: หน้า 4, $\Sigma = \begin{bmatrix} 0.04 & 0.01 \\ 0.01 & 0.09 \end{bmatrix}$, $\mu = [0.10, 0.15]$
- 2 Minimize $\mathbf{w}^T \Sigma \mathbf{w} = w_1^2(0.04) + 2w_1w_2(0.01) + w_2^2(0.09)$
- 3 Subject to: $w_1 + w_2 = 1$, $0.10w_1 + 0.15w_2 = 0.12$ (target return)
- 4 จาก constraints: $w_2 = 0.4$, $w_1 = 0.6$ (แก้ระบบเส้นตรง)
- 5 $\sigma_p^2 = 0.36(0.04) + 2(0.24)(0.01) + 0.16(0.09) = 0.0144 + 0.0048 + 0.0144 = \mathbf{0.0336}$
- 6 $\sigma_p = \sqrt{0.0336} \approx \mathbf{18.3\%}$ ← portfolio risk ที่ optimal สำหรับ return 12%

แบบฝึกหัด Part V

โจทย์ 1: หา Optimal Solution ด้วย Corner Points

Maximize $z = 3x_1 + 2x_2$

Subject to: $2x_1 + x_2 \leq 10$, $x_1 + 2x_2 \leq 8$, $x_1, x_2 \geq 0$

หาทุก corner points และบอกว่า optimal solution คืออะไร?

► ดูเฉลย

โจทย์ 2: Shadow Price และ Sensitivity

จากตัวอย่าง Options ในบทเรียน (Maximize $8x_1 + 5x_2$ s.t. $5x_1 + 2x_2 \leq 20$, $x_1 + x_2 \leq 5$)

คำตอบ optimal คือ $x_1 = 10/3$, $x_2 = 5/3$, $z = 35$

ถ้า budget เพิ่มขึ้น B21 (จาก B20) คาดว่า Expected Payoff จะเป็นเท่าไร? (shadow price = 1)

► ดูเฉลย

โจทย์ 3: Gradient Descent Iterations

กำหนด $f(x) = x^2 + 4x + 5$, $\alpha = 0.1$, เริ่มที่ $x_0 = 3$

คำนวณ 3 iterations ของ Gradient Descent แล้วบอกว่าเข้าใกล้คำตอบจริงไหม?

► ดูเฉลย

โจทย์ 4: KKT Conditions กับ Inequality Constraint

Minimize $f(x) = (x-3)^2$ subject to $x \leq 2$

ใช้เงื่อนไข KKT หา x^* และ μ พร้อมบอกว่า constraint active หรือ inactive?

► ดูเฉลย

สรุป Part V

- ✓ LP: Objective + Constraints → Simplex → Optimal ที่มุม feasible region
- ✓ Dual: Shadow Price = มูลค่าของ constraint — constraint ไหน "แพง" ที่สุด?
- ✓ ILP: ตัวแปรจำนวนเต็ม → Branch & Bound (ใช้สำหรับ option contracts)
- ✓ Gradient Descent → เดินลงเขา → Model Calibration, Vol Surface Fitting
- ✓ Lagrange → Markowitz Portfolio Optimization → Efficient Frontier
- ✓ KKT → จัดการ inequality (ห้าม short $w \geq 0$, position limit) → Long-Only Markowitz
- ✓ Convex → มีคำตอบเดียว (global) ไม่ติด local minimum
- ✓ QP = Mean-Variance Optimization → แก้ด้วย cvxpy ใน milliseconds

จบ Part V

Part VI: Time Series, Numerical Methods & Stochastic Calculus

→ Forecast Volatility, IV Solver, ที่มาของ BS

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part VI: Time Series, Numerical Methods & Stochastic Calculus

บทที่ 12-14: AR/MA/ARMA, GARCH, IV Solver, Brownian Motion, Ito's Lemma, การพิสูจน์ BS PDE

อ่านจบ → forecast volatility + พิสูจน์ที่มาของ Black-Scholes ได้เอง



บทที่ 12: Time Series & Volatility Forecasting

อุปมา: นักพยากรณ์อากาศที่พยากรณ์ "ความแปรปรวน" ไม่ใช่ "อุณหภูมิ"

นักพยากรณ์อากาศไม่ได้แค่บอกว่า "พรุ่งนี้ร้อน/เย็น" — เขายังบอก "พรุ่งนี้ฝนฟ้าคะนองมาก" (ความแปรปรวนสูง)

เช่นเดียวกัน Volatility Forecasting ไม่ได้ทำนายว่าราคาจะขึ้นหรือลง แต่ทำนายว่า **"ราคาจะผันผวนมากแค่ไหน"**

ใน Options Trading: ซื้อ Straddle ก่อนตลาดผันผวน ขาย Straddle เมื่อตลาดเงียบ — ไม่จำเป็นต้องรู้ทิศทาง!

Volatility ไม่คงที่ — มันเปลี่ยนแปลงตลอดเวลา ถ้า forecast ได้ = ได้เปรียบในการเทรด Options

12.1 แนวคิด Time Series

ข้อมูลที่เรียงตามเวลา: ราคาหุ้นรายวัน, daily returns, implied volatility

- **Trend:** ทิศทางระยะยาว (ขึ้น/ลง/นิ่ง)
- **Stationarity:** สมบัติไม่เปลี่ยนแปลงตามเวลา (mean, variance คงที่)

สำคัญ: วิเคราะห์ Returns ไม่ใช่ราคา!

ราคาหุ้น = **non-stationary** (มี trend ขึ้นตลอด) แต่ **returns** = stationary (เฉลี่ย ≈ 0 , variance $\approx$ คงที่)

ถ้าวิเคราะห์ราคาโดยตรง = เหมือนหาค่าเฉลี่ยส่วนสูงของเด็กที่กำลังโต — ค่าเฉลี่ยเปลี่ยนแปลงตลอดเวลา ไม่มีประโยชน์!

12.2 Autocorrelation — Volatility Clustering

อุปมา: ความนิยมของเพลง "เมื่อวานฮิต วันนี้ก็ยังฮิตอยู่"


Autocorrelation วัดว่า "ข้อมูลวันนี้สัมพันธ์กับข้อมูลเมื่อวานแค่ไหน?"

สำหรับ Returns: เกือบ 0 (ทิศทางพรุ่งนี้ทำนายไม่ได้จากวันนี้)

สำหรับ $|Returns|$ หรือ $Returns^2$: **สูงมาก!** — วันที่ผันผวนมักตามด้วยวันที่ผันผวน

$$\rho(k) = \text{Corr}(r_t, r_{t-k})$$

ข้อมูล	Autocorrelation	ความหมาย
returns (r_t)	≈ 0	ทำนายทิศทางไม่ได้ (Efficient Market)
$ returns $ หรือ r^2_t	สูง! ($\sim 0.2-0.4$)	วันที่ผันผวนมากมักตามด้วยวันผันผวนมาก



เชื่อมกับ Options

Volatility Clustering: ความผันผวนมักมาเป็น "กลุ่ม" — ช่วงที่ตลาดกลัว σ สูงนาน
นี่คือเหตุผลที่ GARCH model ทำงานได้ดี เพราะจำลอง clustering นี้

12.3 AR / MA / ARMA Models & Realized Volatility

อุปมา: "วันนี้ขึ้นกับเมื่อวาน" vs "วันนี้ขึ้นกับ shock เมื่อวาน"

AR (Autoregressive): วันนี้ขึ้นกับ *ค่าเมื่อวาน* — เหมือนโมเมนตัมของลูกตุ้ม: ถ้าเมื่อวานสูง วันนี้ก็มักสูงตาม (persistent) หรือดีดกลับสู่ค่าเฉลี่ย (mean-reversion)

MA (Moving Average): วันนี้ขึ้นกับ *shock (เซอร์ไพรส์) เมื่อวาน* — เหมือนเสียงสะท้อนของข่าว: ข่าวช็อกเมื่อวานยังดังก้องมาถึงวันนี้

ทั้งสองคือ "หน่วยความจำ" ของ time series แต่จำกันคนละอย่าง: AR จำ *ค่า*, MA จำ *shock*

AR(1) — Autoregressive order 1: ค่าวันนี้เป็นฟังก์ชันเชิงเส้นของค่าเมื่อวาน + shock ใหม่

$$x_t = c + \phi x_{t-1} + \varepsilon_t$$

$|\phi| < 1 \rightarrow$ stationary + mean-reverting ($\bar{x} = c/(1 - \phi)$); $\phi \approx 1 \rightarrow$ persistent

φ บอกอะไร?

$\phi = 0.9 \rightarrow$ ค่าเมื่อวานส่งต่อมา 90% ทุกวัน $\rightarrow$ series เคลื่อนช้า ต่อเนื่องยาว (เหมือน IV ที่ค่อยๆ ลดลง หลัง crash)

$\phi = 0.1 \rightarrow$ ค่าเมื่อวานแทบไม่มีผล $\rightarrow$ series กระโดดไปมาเร็ว เกือบเป็น white noise

$\phi < 0 \rightarrow$ ดีดสลับขึ้นลง (oscillation) — วันนี้สูง พรุ่งนี้มักต่ำ

MA(1) — Moving Average order 1: ค่าวันนี้เป็น shock วันนี้ + เศษของ shock เมื่อวาน

$$x_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$$

ARMA(1,1) — รวมทั้งสอง: วันนี้ขึ้นกับ ทั้งค่าเมื่อวาน และ shock เมื่อวาน

$$x_t = c + \underbrace{\phi x_{t-1}}_{\text{AR}} + \varepsilon_t + \underbrace{\theta \varepsilon_{t-1}}_{\text{MA}}$$

Lineage: AR $\rightarrow$ ARCH $\rightarrow$ GARCH (วางบริบทให้บท 12.5)

เทคนิค AR/MA ข้างบนใช้กับ ระดับ (level) ของ series แต่ในการเงินเราสนใจ **ความแปรปรวน (variance)** มากกว่า — เลยเอาแนวคิดเดียวกันมาใช้กับ variance:

- **ARCH** = จำลอง variance วันนี้เป็น **AR บน squared-returns เมื่อวาน** (σ_t^2 ขึ้นกับ $r_{t-1}^2, r_{t-2}^2, \dots$)
- **GARCH** = เพิ่ม **MA term บน variance เมื่อวาน** เข้าไป (σ_t^2 ขึ้นกับ σ_{t-1}^2 ด้วย)

ดังนั้น **GARCH(1,1)** คือโครงสร้าง **ARMA(1,1) บน variance** นั่นเอง! — $\alpha \times r_{t-1}^2$ คือ "AR/ARCH part" และ $\beta \times \sigma_{t-1}^2$ คือ "MA/persistence part" นี่คือเหตุผลที่ GARCH (บท 12.5) จับ volatility clustering ได้

Realized Volatility (RV) — วัด vol จริงจากข้อมูล intraday:

แทนที่จะใช้ โมเดลทำนาย σ เราวัด σ ที่ เกิดขึ้นจริงภายในวัน จาก return ย่อยๆ (เช่น ทุก 5 นาที) แล้วรวมกำลังสอง

$$RV = \sqrt{\sum_i r_i^2} \quad (\text{intraday intervals, model-free})$$

ตัวอย่าง: Realized Volatility จาก 4 intraday returns

โจทย์: วันหนึ่งมี intraday returns 4 ช่วง: +0.5%, -0.3%, +0.4%, -0.6%

ขั้น 1 — ยกกำลังสองแต่ละตัว:

$$(0.005)^2 = 0.000025$$

$$(-0.003)^2 = 0.000009$$

$$(0.004)^2 = 0.000016$$

$$(-0.006)^2 = 0.000036$$

ขั้น 2 — รวม: $\sum r_i^2 = 0.000025 + 0.000009 + 0.000016 + 0.000036 = 0.000086$ **ขั้น 3 — RV รายวัน: $RV = \sqrt{0.000086} \approx 0.0093 = 0.93\%/วัน$** **ขั้น 4 — annualize $\times \sqrt{252}$: $0.93\% \times \sqrt{252} \approx 0.93\% \times 15.87 \approx 14.8\%/ปี$**

สำคัญ: RV เป็น **model-free estimate** ของ vol ที่เกิดขึ้น แล้ว (backward-looking, ใช้ข้อมูลจริง ไม่ต้องสมมติโมเดล) ส่วน GARCH เป็น **forecast** ของ vol *วันพรุ่งนี้* (forward-looking) — เทรตเดอร์มักเทียบ RV (จริง) กับ IV (ตลาดคาด) และ GARCH (โมเดลคาด) เพื่อหา edge

โจทย์: Realized Volatility

วันหนึ่งมี intraday returns 3 ช่วง: -0.8%, +0.6%, +0.4%

คำนวณ RV รายวัน แล้ว annualize ด้วย $\sqrt{252}$ — ได้ vol รายปีเท่าไร?

► ดูเฉลย

12.4 Moving Average & EWMA

อุปมา: คะแนนความนิยมแบบ "ใหม่กว่า = น้ำหนักมากกว่า"

Simple MA ให้น้ำหนักเท่ากันทุกวัน เหมือนนับคะแนนโหวตทุกคนเท่ากัน

EWMA ให้น้ำหนักวันล่าสุดมากกว่า เหมือน "คะแนนใหม่สำคัญกว่าคะแนนเก่า"

$\lambda=0.94$ หมายความว่า: ข้อมูล 1 เดือนที่แล้วมีน้ำหนักเหลือ $(0.94)^{20} \approx 29\%$ เท่านั้น

Simple MA Volatility: $\sigma = \text{std}(\text{returns ใน window } n \text{ วัน})$

$$\sigma_{\text{SMA}}^2 = \frac{1}{n} \sum_{i=1}^n r_{t-i}^2 \quad (\mu \approx 0)$$

EWMA (Exponentially Weighted): ให้น้ำหนักข้อมูลล่าสุดมากกว่า

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2 \quad \lambda = 0.94 \text{ (RiskMetrics)}$$


ทำไม EWMA ถึงเขียนแบบนี้?

Expand ออกมา: $\sigma_t^2 = (1-\lambda)[r_{t-1}^2 + \lambda r_{t-2}^2 + \lambda^2 r_{t-3}^2 + \dots] = \text{weighted average ของ } r^2 \text{ ทั้งหมด}$

น้ำหนักของวันที่ k วันก่อน $= (1-\lambda)\lambda^k \rightarrow$ ลดลง exponentially $\rightarrow$ วันเก่าๆ มีผลน้อยมาก

ข้อดีสำคัญ: Update ง่ายมาก! ต้องจำแค่ σ^2 เมื่อวาน + r เมื่อวาน

- 1 โจทย์: $\lambda=0.94$, $\sigma_{t-1}^2 = 0.0025$ ($\sigma=5\%$), $r_{t-1} = -3\% = -0.03$
- 2 $r_{t-1}^2 = (-0.03)^2 = 0.0009$
- 3 $\sigma_t^2 = 0.94 \times 0.0025 + 0.06 \times 0.0009$
- 4 $= 0.002350 + 0.000054 = \mathbf{0.002404}$
- 5 $\sigma_t = \sqrt{0.002404} \approx \mathbf{4.90\%}$ ลดลงนิดเดียวจาก 5% เพราะ $r^2=0.09\% < \sigma^2=0.25\%$



EWMA ($\lambda=0.94$) reacts faster to volatility spikes than SMA-10

12.5 GARCH Model

อุปมา: นักพยากรณ์ที่จำ "ข่าวเมื่อวาน" + "ความแปรปรวนสะสม"

GARCH บอกว่า volatility วันนี้ขึ้นกับ 2 ปัจจัย:

1. **ข่าวเมื่อวาน** (r_{t-1}^2): ถ้าตลาดร่วงแรงเมื่อวาน → ความกังวลสูง
2. **Volatility เมื่อวาน** (σ_{t-1}^2): Volatility มี "inertia" — สูงแล้วมักจะยังคงสูงอยู่

$\alpha + \beta < 1 \rightarrow$ ในระยะยาว volatility กลับสู่ค่าเฉลี่ย $\omega/(1-\alpha-\beta)$

$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2 \quad \alpha + \beta < 1$$

ω = baseline, α = news impact, β = persistence; long-run $\sigma = \sqrt{\omega/(1-\alpha-\beta)}$

$$\omega \text{ (baseline)} + \alpha \times r_{t-1}^2 \text{ (ข่าว)} + \beta \times \sigma_{t-1}^2 \text{ (inertia)} = \sigma_t^2 \text{ (forecast)}$$

- 1 **GARCH(1,1) ตัวอย่าง:** $\omega=0.000002$, $\alpha=0.10$, $\beta=0.85$
- 2 $r_{t-1} = -2\% = -0.02$, $\sigma_{t-1}^2 = 0.0004$ ($\sigma=2\%$)
- 3 $r_{t-1}^2 = 0.0004$
- 4 $\sigma_t^2 = 0.000002 + 0.10 \times 0.0004 + 0.85 \times 0.0004$
- 5 $= 0.000002 + 0.000040 + 0.000340 = \mathbf{0.000382}$
- 6 $\sigma_t = \sqrt{0.000382} \approx \mathbf{1.95\%}$ (ลดลงจาก 2% เล็กน้อย เพราะ $r^2 = \sigma^2$ พอดี)
- 7 Long-run $\sigma = \sqrt{\omega/(1-\alpha-\beta)} = \sqrt{0.000002/0.05} = \sqrt{0.00004} = \mathbf{0.63\%/วัน \approx 10\%/ปี}$

เชื่อมกับ Options

- **Forecast σ** → เทียบกับ Implied Volatility (IV) ของตลาด
- ถ้า GARCH forecast < IV → options "แพงเกินไป" → อาจ **sell options**
- ถ้า GARCH forecast > IV → options "ถูกเกินไป" → อาจ **buy options**
- **BS สมมติ σ คงที่** ← ผิด! GARCH บอกว่า σ เปลี่ยนตลอดเวลา

⚠ **Model Risk: GARCH ใช้ Historical — ไม่รู้จัก Regime Change**

GARCH มีจุดอ่อนสำคัญในการใช้งานจริง:

- **Regime shift:** GARCH calibrate กับ low-vol period จะ underestimate vol ใน high-vol regime ใหม่ (เช่น COVID breakout ปี 2020)
- **Overfitting ช่วงสงบ:** $\alpha + \beta \rightarrow 1$ ใน calm markets $\rightarrow$ Integrated GARCH $\rightarrow$ ไม่มี mean reversion $\rightarrow$ forecast vol ไม่กลับ
- **Asymmetry (Leverage Effect):** basic GARCH ไม่จับ "ตลาดลงแล้ว vol ขึ้นมากกว่าตลาดขึ้น" — ต้องใช้ GJR-GARCH หรือ EGARCH

แนวทาง: monitor μ drift, refit monthly, ใช้ Markov-switching GARCH ถ้า regime ชัดเจน

12.6 Mean Reversion

อุปมา: ยางยืดที่ดึงกลับสู่จุดกึ่งกลาง

Volatility ไม่วิ่งไปเรื่อยๆ มีแรงดึงกลับสู่ค่าเฉลี่ยระยะยาว (long-run volatility)

เหมือนยางยืด: ยิ่งดึงออกห่าง แรงดึงกลับยิ่งแรง

กฎ: $\alpha + \beta < 1 \rightarrow$ มี mean reversion; $\alpha + \beta = 1 \rightarrow$ ไม่มี mean reversion (IGARCH — ไม่เสถียร)

เชื่อมกับ Options

- ถ้า IV สูงมาก (เช่น หลัง market crash) $\rightarrow$ มักจะลดลง $\rightarrow$ **sell high IV**
- Long-term $\sigma \approx \sqrt{(\omega/(1 - \alpha - \beta))}$ จาก GARCH $\rightarrow$ ใช้เป็น "anchor" ว่า IV ควรอยู่แถวไหน

บทที่ 13: วิธีเชิงตัวเลข — IV Solver

อุปมา: หาคำตอบที่ "สมการปิด" ไม่มี

ถ้าตลาดบอกว่า Call มีราคา \$7.50 แต่ Black-Scholes สูตรให้ราคาเป็น σ → หา σ ที่ทำให้ราคา = \$7.50

ปัญหา: ไม่มีสูตร "ย้อนกลับ" Black-Scholes แบบ closed-form → ต้องลองแล้วปรับ

วิธีเชิงตัวเลข = "การลองแบบฉลาด" ที่ converge หาคำตอบได้เร็ว

บางสมการแก้แบบ closed-form ไม่ได้ — ต้องใช้คอมพิวเตอร์หาคำตอบ ตัวอย่างสำคัญที่สุด: หา **Implied Volatility**

13.1 Bisection Method — "เกมทายตัวเลข"

อุปมา: เกมทาย "สูงไป/ต่ำไป"

ถ้าเพื่อนคิดตัวเลข 1-100 ไว้ในใจ กลยุทธ์ที่ดีที่สุดคือเดา 50 ก่อน

ถ้า "สูงไป" → เดา 25 ถัดไป; ถ้า "ต่ำไป" → เดา 75

ทำซ้ำ → ทุกครั้งช่วยให้แคบลงครึ่งหนึ่ง → หาเจอใน 7 ครั้งเสมอ ($\log_2(100) \approx 7$)

ถ้ารู้คำตอบอยู่ระหว่าง a กับ b → ลอง midpoint → ดูว่าคำตอบอยู่ครึ่งซ้ายหรือขวา → แบ่งครึ่งอีก

1. เลือก a, b ที่ $f(a) \cdot f(b) < 0$
2. $m = (a + b)/2$
3. ถ้า $f(m) \cdot f(a) < 0 \rightarrow b = m$ มิฉะนั้น $a = m$
4. ทำซ้ำจนกว่า $|b - a| < \varepsilon$

รอบ	a	b	$m = (a+b)/2$	$f(m) = BS(m) - 7.5$	ช่วงใหม่
1	0.05	1.00	0.525	+3.2 (สูงไป)	[0.05, 0.525]
2	0.05	0.525	0.288	+0.8 (สูงไป)	[0.05, 0.288]
3	0.05	0.288	0.169	-0.5 (ต่ำไป)	[0.169, 0.288]
4	0.169	0.288	0.228	+0.1 (สูงไป)	[0.169, 0.228]
...	→ converge ไปที่ $\sigma \approx 0.20$ (IV = 20%)				

13.2 Newton-Raphson Method — เร็วกว่า!

อุปมา: ลงเขาโดยใช้แผนที่ความลาดชัน ไม่ใช่แค่ลองผิดลองถูก

Bisection: ลองครึ่งละครึ่ง — ช้า แต่แน่นอน

Newton-Raphson: ใช้ slope (derivative) ของฟังก์ชัน เพื่อ "คาด" ว่าคำตอบอยู่ตรงไหน

เหมือนลากเส้นสัมผัส (tangent) จากจุดที่อยู่ → เส้นสัมผัสตัดแกน x ที่ไหน → ลองจุดนั้น

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

$$\sigma_{n+1} = \sigma_n - \frac{C_{BS}(\sigma_n) - C_{mkt}}{V(\sigma_n)} \quad (\text{IV solver, Vega} = \partial C / \partial \sigma)$$


ทำไม Vega ถึงเป็น derivative ที่ใช้?

Vega = $\partial V / \partial \sigma$ = อัตราการเปลี่ยนแปลงของราคา option ต่อการเปลี่ยน σ 1 หน่วย

Newton-Raphson ต้องการ $f'(\sigma) = d(\text{BS price})/d\sigma = \text{Vega}$ นั่นเอง!

ข้อดี: BS Vega มีสูตร closed-form → คำนวณเร็ว → Newton-Raphson converge ใน 3-5 รอบ!

- 1 **IV Solver:** Market price = ฿7.50, $S=100$, $K=100$, $T=0.25$, $r=5\%$
- 2 เดาเริ่มต้น: $\sigma_0 = 0.30$ (30%)
- 3 คำนวณ $BS(0.30) = ฿8.20$ (แพงเกินไป ฿0.70)
- 4 $Vega(0.30) = ฿20$ (ราคาเปลี่ยน ฿20 ต่อการเปลี่ยน σ 1 หน่วย)
- 5 $\sigma_1 = 0.30 - (8.20 - 7.50)/20 = 0.30 - 0.035 = \mathbf{0.265 \text{ (26.5%)}}$
- 6 $BS(0.265) \approx ฿7.52 \rightarrow$ error เล็กมาก $\rightarrow$ 1 iteration อีกรอบ $\rightarrow \sigma \approx \mathbf{0.264 = IV \text{ 26.4\%}}$



แผนภาพ: Newton-Raphson หา Implied Volatility — แต่ละ iteration เข้าใกล้ σ^* ที่แก้สมการ $BS(\sigma) = C_{mkt}$

เชื่อมกับ Options — IV Solver

Newton-Raphson ใช้ **Vega** เป็น derivative $\rightarrow$ converge ใน 3-5 รอบ!

ทุกครั้งที่คุณเห็น "IV = 25%" บนหน้าจอ Bloomberg — เบื้องหลังคือ Newton-Raphson กำลังทำงาน

Quant Desk: IV Solver ทำงานตลอดเวลา — Vol Surface คือ "ราคากลาง" ของตลาด

ในทุก derivatives desk Newton-Raphson IV solver runs continuously:

- **Real-time IV:** Bloomberg feed market prices $\rightarrow$ solve IV ทุก tick $\rightarrow$ build vol surface
 - **Relative value:** เปรียบเทียบ model vol vs market IV $\rightarrow$ ชื้อ "ถูก" ขาย "แพง"
 - **Greeks from surface:** Delta/Gamma คำนวณจาก Vol Surface (sticky-delta vs sticky-strike)
- IV solver ที่ดีต้อง robust: handle deep OTM options ($Vega \rightarrow 0 \rightarrow$ Newton แกว่ง) — ใช้ Bisection fallback

13.3 Numerical Differentiation

ทำไมต้องคำนวณ derivative เชิงตัวเลข?

BS model มีสูตร closed-form สำหรับ Greeks แต่ model อื่นๆ (Local Vol, Stochastic Vol) ไม่มี

แนวคิด: Delta = "ถ้า S เพิ่ม $h \rightarrow V$ เพิ่มเท่าไร?" $\rightarrow$ หาค่า $h \rightarrow$ ได้ approximate derivative

$$f'(x) \approx \frac{f(x+h) - f(x-h)}{2h} \quad (\text{central difference})$$

เชื่อมกับ Options

คำนวณ Greeks จาก pricing model ที่ไม่มีสูตร closed-form:

Delta $\approx [V(S+h) - V(S-h)] / (2h)$ ใช้ $h = \$0.01$ หรือ $\$0.001$

Gamma $\approx [V(S+h) - 2V(S) + V(S-h)] / h^2$ (second derivative)

บทที่ 14: Stochastic Processes & Ito's Lemma

อุปมา: ฝุ่นละอองในน้ำ — ราคาหุ้นก็เคลื่อนที่แบบสุ่มเช่นกัน

Robert Brown ค้นพบ "Brownian Motion" ในปี 1827 โดยมองกล้องจุลทรรศน์ดูละอองเรณูในน้ำ — มันเคลื่อนที่สุ่มตลอดเวลา


Einstein อธิบายในปี 1905 ว่าเกิดจากโมเลกุลน้ำชนทุกทิศทาง

Bachelier (1900) ใช้ Brownian Motion อธิบายราคาหุ้นเป็นคนแรก — ก่อน Einstein อีก!

บทนี้คือ "ยอดเขา" ของเล่ม — เข้าใจบทนี้ = เข้าใจที่มาของ Black-Scholes

14.1 Random Walk & Binomial Tree

Random Walk: ทุก step ราคาขึ้น (+1) หรือลง (-1) ด้วยโอกาส 50/50



Monte Carlo GBM paths — each run gives different $S(T)$; average = option price

Binomial Tree: ราคาขึ้น u หรือลง d ในแต่ละ step

$$u = e^{\sigma\sqrt{\Delta t}}, \quad d = e^{-\sigma\sqrt{\Delta t}} = 1/u, \quad p^* = \frac{e^{r\Delta t} - d}{u - d}$$

ทำไม $u = e^{(\sigma\sqrt{\Delta t})}$?

ต้องการให้ u, d สอดคล้องกับ volatility σ ของหุ้น

เงื่อนไข: Variance ใน 1 step = $\sigma^2\Delta t \rightarrow p(1-p)(u-d)^2 \approx \sigma^2\Delta t$

การเลือก $u=e^{(\sigma\sqrt{\Delta t})}$ ทำให้เงื่อนไขนี้สอดคล้อง **โดยประมาณ (to first order ใน Δt)** — ไม่ใช่เป๊ะ
สำหรับ Δt จำกัด แต่ error เล็กลงเรื่อย ๆ เมื่อ $\Delta t \rightarrow 0$ และ $u \times d = 1$ (recombining tree!) ทำให้ tree พับ
กลับได้ ลดจำนวน node

- 1 **Binomial ตัวอย่าง:** $S=100, K=100, \sigma=20\%, r=5\%, T=1\text{ปี}, n=1\text{ step}$
- 2 $\Delta t=1, u=e^{(0.2 \times 1)}=1.2214, d=1/u=0.8187$
- 3 $p^* = (e^{(0.05 \times 1)} - 0.8187) / (1.2214 - 0.8187) = (1.0513 - 0.8187) / 0.4027 = 0.578$
- 4 $S(u)=122.14, S(d)=81.87$; Payoff Call: $C(u)=\max(22.14, 0)=22.14, C(d)=0$
- 5 $C = e^{(-0.05 \times 1)} \times [0.578 \times 22.14 + 0.422 \times 0] = 0.9512 \times 12.80 = \text{฿}12.18$

เชื่อมกับ Options — Binomial Option Pricing

1. สร้าง tree ราคาหุ้น n steps
 2. คำนวณ payoff ที่ปลาย tree (วันหมดอายุ)
 3. ย้อนกลับทีละ step: $V = e^{-r\Delta t} \times [p^* \times V(\text{up}) + (1-p^*) \times V(\text{down})]$
 4. ค่าที่ node แรก = **ราคา Option!**
- เมื่อ $n \rightarrow \infty \rightarrow$ converge สู่ **Black-Scholes price**

14.2 Risk-Neutral Pricing

อุปมา: ประกันภัย — ราคาไม่ขึ้นกับว่าคุณจะเกิดอุบัติเหตุหรือไม่

บริษัทประกัน define ราคากรมธรรม์จาก "expected payout" โดยไม่ต้องรู้ว่าคุณ "โชคดี" หรือ "โชคร้าย"

Risk-neutral pricing ทำแบบเดียวกัน: คำนวณ "expected option payoff" ในโลก risk-neutral

เหตุผลที่ใช้ได้: เราสามารถ *replicate* option payoff ด้วย stock + bond $\rightarrow$ ราคาต้อง = cost of replication

หลักการสำคัญที่สุดใน Derivatives Pricing

เราสามารถ price option ได้โดย **ไม่ต้องรู้ว่าหุ้นจะขึ้นหรือลง!**

ทำได้โดยใช้ "โลก risk-neutral" ที่สมมติว่า:

- ทุกสินทรัพย์มี expected return = risk-free rate (r)
- ใช้ probability p^* (ไม่ใช่ real probability p)
- **Option Price** = $e^{-rT} \times E^*[Payoff]$

ทำไมใช้ได้? — No-Arbitrage Argument

เพราะเราสามารถ **replicate** payoff ของ option ได้ด้วย stock + bond (hedging)

ดังนั้นราคาของ option ต้อง = ต้นทุนของ replicating portfolio

ต้นทุนนี้ **ไม่ขึ้นกับว่าหุ้นจะขึ้นหรือลง** → ไม่ต้องรู้ real probability!

14.3 Brownian Motion

Brownian Motion $W(t)$ = continuous limit ของ random walk สมบัติ:

- $W(0) = 0$ (เริ่มที่ 0)
- Independent increments: $W(t_2) - W(t_1)$ ไม่ขึ้นกับ $W(t_1) - W(t_0)$
- $W(t_2) - W(t_1) \sim \text{Normal}(0, t_2 - t_1)$ → ยิ่งเวลานาน *variance* ยิ่งมาก (ไม่ใช่ standard deviation)
- Continuous paths — ไม่กระโดด

ทำไม $\text{Variance} \propto t$ ไม่ใช่ $\text{Std} \propto t$?

random walk n steps: แต่ละ step ± 1 → หลัง n steps, $\text{std} = \sqrt{n}$ (จาก CLT)

ถ้า 1 ปี = n steps, 1 วัน = 1 step → $\text{std}(\text{yearly}) = \sqrt{252} \times \text{std}(\text{daily})$

นี่คือเหตุผลที่เราคูณ σ ด้วย $\sqrt{T}$ ไม่ใช่ T เมื่อ scale ตามเวลา!

14.4 Geometric Brownian Motion (GBM)

อุปมา: เรือในทะเลเคลื่อน

ราคาหุ้น = เรือที่ลอยในทะเล:

- **Drift (μdt)** = กระแสน้ำ: ดันเรือไปทิศหนึ่งอย่างสม่ำเสมอ
- **Volatility (σdW)** = คลื่น: สุ่มขึ้นลง ยิ่งคลื่นแรง (σ สูง) เรือก็โคลงมาก

ทำไม "Geometric"? เพราะคลื่นใหญ่เล็กสัมพันธ์กับ *ขนาดของเรือ* — หุ้น ฿1000 ขยับ ฿20 ไม่เหมือนหุ้น ฿10 ขยับ ฿0.20

$$\frac{dS}{S} = \mu dt + \sigma dW$$

อ่านว่า: "% การเปลี่ยนแปลงราคา = drift + สุ่ม"

- μdt = drift $\times$ เวลา $\rightarrow$ deterministic (คาดเดาได้)
- σdW = volatility $\times$ Brownian shock $\rightarrow$ stochastic (สุ่ม)

ทำไม Geometric? $\rightarrow$ ราคาเป็น Lognormal!

เพราะ dS/S (% change) เป็น normal ไม่ใช่ dS (absolute change)

$\rightarrow$ ราคา S เป็น **Lognormal** (เชื่อมกับบท 6.4!) $\rightarrow$ ราคา > 0 เสมอ — ไม่สามารถติดลบได้!

14.5 Ito's Lemma — "Chain Rule ของโลกสุ่ม"

Chain Rule ธรรมดา vs Ito's Lemma — ต่างกันอะไร?

Chain Rule ปกติ: ถ้า $V = V(S, t)$ และ S เปลี่ยนไป $dS \rightarrow dV = (\partial V / \partial t) dt + (\partial V / \partial S) dS$

แต่ในโลกสุ่ม: S ขยับแบบ Brownian Motion $\rightarrow dS$ มีความ "ผันผวน" ในตัวเอง

ผลลัพธ์: $(dS)^2 \neq 0$ แต่ $= \sigma^2 S^2 dt \rightarrow$ ต้องบวก "ค่าแก้" $\frac{1}{2} \Gamma (dS)^2$ เพิ่มเข้าไป!

ถ้า S เป็น stochastic process และ $V(S, t)$ เป็นฟังก์ชันของ S :

$$dV = \frac{\partial V}{\partial t} dt + \frac{\partial V}{\partial S} dS + \frac{1}{2} \frac{\partial^2 V}{\partial S^2} (dS)^2$$

$$dS/S = \mu dt + \sigma dW$$

$\rightarrow$

$$(dW)^2 = dt$$

$\rightarrow$

$$(dS)^2 = \sigma^2 S^2 dt$$

$\rightarrow$

ไม่ตัดทิ้งได้!

$\rightarrow$

$$\text{บวก } \frac{1}{2} \Gamma \sigma^2 S^2 dt$$

ทำไมมี term $\frac{1}{2}(\partial^2 V / \partial S^2)(dS)^2$ พิเศษ?

ในโลกปกติ $(dt)^2 \approx 0$ ตัดทิ้งได้ แต่ในโลกสุ่ม $(dW)^2 = dt \neq 0!$

ดังนั้น $(dS)^2 = (\mu S dt + \sigma S dW)^2 \approx \sigma^2 S^2 dt$ (เอา dt^2 และ $dt \times dW$ ออก เพราะเล็กกว่า dt)

นี่คือเหตุผลว่าทำไม **Gamma** สำคัญ — มันเป็น "ค่าแก้" ที่โลกสุ่มบังคับให้ใส่

- 1 ตัวอย่าง Ito: หา $d(\ln S)$ เมื่อ $dS/S = \mu dt + \sigma dW$
- 2 ตั้ง $V = \ln(S)$, $\partial V / \partial t = 0$, $\partial V / \partial S = 1/S$, $\partial^2 V / \partial S^2 = -1/S^2$
- 3 $dV = 0 \cdot dt + (1/S)dS + \frac{1}{2}(-1/S^2)(dS)^2$
- 4 $= (1/S)(\mu S dt + \sigma S dW) + \frac{1}{2}(-1/S^2)(\sigma^2 S^2 dt)$
- 5 $= \mu dt + \sigma dW - \frac{1}{2}\sigma^2 dt = (\mu - \frac{1}{2}\sigma^2)dt + \sigma dW$
- 6 นี่คือ "log return ของ GBM" $\rightarrow$ Normal distribution $\rightarrow S$ เป็น Lognormal!

14.6 การพิสูจน์ Black-Scholes PDE (5 ขั้นตอน)

อุปมา: สร้าง portfolio ที่ "ไร้ความเสี่ยง" $\rightarrow$ ต้องโตเท่า risk-free rate

ลองสร้างกระเป๋าลงทุนจาก option + หุ้น ในสัดส่วนที่ "หักล้าง" ความผันผวนของกันและกันออกหมด $\rightarrow$ กลายเป็น portfolio ที่ **ไร้ความเสี่ยง** (ไม่ว่าหุ้นขึ้นหรือลง ค่ามันก็เท่าเดิม)

เหตุ $\rightarrow$ ผล: ถ้าอะไรไร้ความเสี่ยง มันต้องให้ผลตอบแทนเท่ากับเงินฝากปลอดภัย (risk-free rate r) เป๊ะ — **ไม่ฉันมี arbitrage!** (ถ้าโตเร็วกว่า r ก็กู้เงิน r มาซื้อฟรีๆ; ถ้าช้ากว่า r ก็ short มันแล้วเอาเงินไปฝาก)

เงื่อนไขนี้แหละบีบให้ราคา option ต้องเป็นค่าใดค่าหนึ่งเท่านั้น $\rightarrow$ ออกมาเป็น PDE

เราจะ พิสูจน์ PDE ที่ละขั้น โดยใช้ Ito's Lemma (บท 14.5) + no-arbitrage:

- 1 สร้าง portfolio: long 1 option (มูลค่า V) + short Δ หุ้น (มูลค่า $\Delta \cdot S$)

$$\Pi = V - \Delta \cdot S$$

เป้าหมาย: เลือก Δ ให้ portfolio นี้ไร้ความเสี่ยง

- 2 หา $d\Pi$ ด้วย Ito's Lemma: จากบท 14.5, dV ของ $V(S,t)$ คือ

$$dV = \left(\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt + \frac{\partial V}{\partial S} dS$$

(term dt มารวมจาก $\partial V/\partial t$ กับ Ito-correction $\frac{1}{2}\sigma^2 S^2 \partial^2 V/\partial S^2$ ส่วน dS คูณ $\partial V/\partial S$) ดังนั้น

$$d\Pi = dV - \Delta dS = \left(\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt + \left(\frac{\partial V}{\partial S} - \Delta \right) dS$$

- 3 กำจัด randomness: ตัว random ทั้งหมดอยู่ใน dS (เพราะ $dS = \mu S \cdot dt + \sigma S \cdot dW$ มี dW สุ่ม) เลือก

$$\Delta = \partial V / \partial S \text{ (Delta hedge)}$$

→ term $(\partial V/\partial S - \Delta)dS = 0$ → **dS หายไปทั้งหมด!** เหลือแต่ส่วน deterministic:

$$d\Pi = \left(\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt$$

ตอนนี้ $d\Pi$ ไม่มี dW แล้ว → portfolio **ไร้ความเสี่ยง** ในช่วงเวลา dt

- 4 **No-arbitrage**: portfolio ที่ไร้ความเสี่ยง ต้องโตด้วยอัตรา r เท่านั้น คือ $d\Pi = r \cdot \Pi \cdot dt$ จับสองฝั่งของ $d\Pi$ มาเท่ากัน (และแทน $\Pi = V - \Delta \cdot S = V - S \cdot \partial V/\partial S$):

$$\left(\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} \right) dt = r \left(V - S \frac{\partial V}{\partial S} \right) dt$$

- 5 **จัดรูป**: หาร dt ทั้ง แล้วย้ายทุก term มาฝั่งซ้าย → ได้ **Black-Scholes PDE**:

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0$$

แก่นของการพิสูจน์: Delta Hedging กำจัด Randomness

หัวใจอยู่ที่ **ขั้น 3**: เลือก $\Delta = \partial V / \partial S$ ทำให้ตัวสุ่ม (dS / dW) หายไปหมด $\rightarrow$ portfolio ไร้ความเสี่ยง

ผลที่ตามมาทั้งนี้: PDE ที่ได้ **ไม่มี μ (drift จริงของหุ้น) เลย!** ราคา option ถูกบังคับโดย no-arbitrage ล้วนๆ — ไม่สนว่าหุ้นจะ "มีแนวโน้มขึ้น" แค่ไหน

นี่คือเหตุผลที่ **risk-neutral pricing (บท 14.2) ใช้ได้**: ในเมื่อ μ หายไป เราจะแทน μ ด้วยอะไรก็ได้ที่สะดวก — เลยเลือก $\mu = r$ (โลก risk-neutral) แล้วราคาที่ได้ก็ยังถูกต้อง

PDE นี้ไม่มี μ — มีแค่ r และ σ

สังเกตว่าตัวแปรในสมการมีแค่ r (risk-free rate) และ σ (volatility) — ไม่มี μ (expected return จริงของหุ้น)

PDE เพียงอย่างเดียวยังบอกราคา option ไม่ได้ ต้องใส่ **boundary / terminal condition** ด้วย สำหรับ European Call:

$$V(S, T) = \max(0, S - K) \quad (\text{payoff ตอนหมดอายุ})$$

แก้ PDE ตัวนี้พร้อม condition นี้ $\rightarrow$ จะได้ **สูตร Black-Scholes** (จะประกอบเต็มที่ใน Part 7)

โจทย์: Terminal Condition + ระบุ Greek ของแต่ละ term

(ก) European Call มี strike $K = \text{฿}100$ ตอนหมดอายุ ถ้า $S = \text{฿}120$ payoff เท่าไหร่? ถ้า $S = \text{฿}80$ ล่ะ? — ตรงกับ $V(S, T) = \max(0, S - K)$ ไหม?

(ข) ใน PDE: $\partial V / \partial t + \frac{1}{2} \sigma^2 S^2 \cdot \partial^2 V / \partial S^2 + rS \cdot \partial V / \partial S - rV = 0$ — term ไหนคือ "Theta" และ term ไหนเกี่ยวกับ "Gamma"?

► ดูเฉลย

14.7 Black-Scholes PDE — ดีความเป็น Greeks

ที่มาของ BS PDE — Hedging Argument

สร้าง portfolio: Long 1 option + Short Δ หุ้น $\rightarrow$ portfolio นี้ "ไม่มีความเสี่ยง" (delta neutral)

Portfolio ไม่มีความเสี่ยง $\rightarrow$ ต้องได้ผลตอบแทน = risk-free rate (ไม่จึ่งมี arbitrage!)

นำหลักการนี้ + Ito's Lemma $\rightarrow$ ได้ PDE ที่ทุก option ต้องสอดคล้อง

ใช้ Ito's Lemma + hedging argument $\rightarrow$ ได้สมการ:

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0$$

แต่ละ term คือ Greek:

Term	Greek	ความหมาย
$\partial V / \partial t$	Theta (Θ)	Time decay — ราคา option ลดตามเวลา
$\frac{1}{2}\sigma^2 S^2 (\partial^2 V / \partial S^2)$	$\frac{1}{2}\sigma^2 S^2 \times$ Gamma (Γ)	Convexity benefit จาก volatility
$rS(\partial V / \partial S)$	$rS \times$ Delta (Δ)	Cost of carry ของหุ้นที่ hedge
$-rV$	—	Discounting — ต้นทุนการถือ option

Greeks Balance! Theta vs Gamma Trade-off

$$\Theta + \frac{1}{2}\sigma^2 S^2 \Gamma + rS\Delta = rV$$

หมายความว่า: Time decay (Theta) **ถูก offset** ด้วย Convexity gain (Gamma term)

สำหรับ Long Option: Theta เป็นลบ (จ่าย time decay) แต่ Gamma term เป็นบวก (ได้ convexity benefit)

ไม่มี "free lunch" — ได้ Gamma ต้องจ่าย Theta

- 1 **ตรวจสอบ BS PDE:** Call ATM, $S=K=100$, $\sigma=20\%$, $r=5\%$, $T=0.5$ ปี
- 2 คำนวณ $d_1=(0.035)/(0.2 \times \sqrt{0.5})=0.247$; Greek จริง: $\Delta=N(d_1) \approx 0.60$, $\Gamma \approx 0.027/\text{฿}$, $\Theta \approx -\text{฿}8.1/\text{ปี}$, $V \approx \text{฿}6.89$
- 3 Theta term: -8.1
- 4 Gamma term: $\frac{1}{2} \times 0.04 \times 10000 \times 0.027 = \frac{1}{2} \times 10.8 = +5.4$
- 5 $r\Delta$ term: $0.05 \times 100 \times 0.60 = +3.0$
- 6 rV : $0.05 \times 6.89 = 0.34$
- 7 $\text{LHS} = -8.1 + 5.4 + 3.0 = +0.30 \approx rV = 0.34 \checkmark$ (ใกล้มาก ต่างกันเพราะปัดทศนิยม)

แบบฝึกหัด Part VI

โจทย์ 1: EWMA Volatility Update

กำหนด $\lambda = 0.94$, $\sigma^2_{t-1} = 0.0009$ ($\sigma = 3\%$), $r_{t-1} = +4\% = 0.04$

คำนวณ σ^2_t และ σ_t ด้วย EWMA — volatility เพิ่มขึ้นหรือลด?

► ดูเฉลย

โจทย์ 2: Newton-Raphson IV Solver — 1 Step

Market price ของ Call = ฿5.00

$\sigma_0 = 0.25$ (25%), $BS(0.25) = ฿5.80$, $Vega(0.25) = ฿25$

คำนวณ σ_1 ด้วย Newton-Raphson แล้วตรวจว่าเข้าใกล้ IV ใหม่?

► ดูเฉลย

โจทย์ 3: Ito's Lemma — หา dV

กำหนด $V = S^2$ (portfolio value proportional to S squared)

ราคาหุ้น: $dS = \mu S dt + \sigma S dW$ (GBM)

ใช้ Ito's Lemma หา dV — มี term พิเศษอะไรเพิ่มมาบ้าง?

► ดูเฉลย

สรุป Part VI

- ✓ Autocorrelation → Volatility Clustering — r^2 มี autocorrelation สูง
- ✓ AR/MA/ARMA: AR จำค่าเมื่อวาน, MA จำ shock เมื่อวาน → GARCH = ARMA บน variance!
- ✓ Realized Vol: $RV = \sqrt{\sum r_t^2}$ → model-free (จริง) vs GARCH (forecast)
- ✓ EWMA: $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1-\lambda)r_{t-1}^2$ → น้ำหนักข้อมูลล่าสุดมากกว่า
- ✓ GARCH: $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$ → News Impact + Persistence
- ✓ Mean Reversion → Long-run $\sigma = \sqrt{\omega/(1-\alpha-\beta)}$
- ✓ Bisection: แบ่งครึ่งทุกครั้งรอบ → IV Solver ช้าแต่แน่นอน
- ✓ Newton-Raphson: $\sigma(n+1) = \sigma(n) - (BS - Mkt)/Vega$ → IV Solver เร็ว
- ✓ Random Walk → Binomial Tree → Option Pricing (p^* = risk-neutral prob)
- ✓ Risk-Neutral: Price = $e^{-rT} \times E^*[Payoff]$ — ไม่ต้องรู้ทิศทางหุ้น!
- ✓ GBM: $dS/S = \mu dt + \sigma dW$ → Lognormal price
- ✓ Ito's Lemma: $dV = \Theta dt + \Delta dS + \frac{1}{2}\Gamma(dS)^2$ → $(dW)^2 = dt$ เป็น key!
- ✓ พิสูจน์ BS PDE (5 ขั้นตอน): delta hedge กำจัด randomness → PDE ไม่มี μ !
- ✓ BS PDE: $\Theta + \frac{1}{2}\sigma^2 S^2 \Gamma + rS\Delta = rV$ — Theta-Gamma Trade-off!

จบ Part VI

Part VII: ประมวลรวม → อ่าน Black-Scholes ออกทุกตัว + Monte Carlo

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part VII: ประมวลรวม — อ่าน Black-Scholes ออก + Monte Carlo

บทที่ 15-16: ไล่สูตร BS ทีละตัว, พิสูจน์ Put-Call Parity,
Monte Carlo Simulation, Exotic Options

บทที่ 15: ทุกอย่างรวมกัน — "อ่าน Black-Scholes ออก"

อุปมา: อ่านแผนที่สมบัติที่แต่ละสัญลักษณ์มีความหมาย

ครั้งแรกที่เห็น BS formula มันดูเหมือนรหัสลับ — $N(d_1)$, $\sigma\sqrt{T}$, e^{-rT} ...

แต่ตอนนี้ ทุกตัวอักษรมีบทที่มาจากที่คุณเรียนมาแล้ว:

e^{-rT} = บท 3 | $N(d)$ = บท 6 | σ = บท 4 | $\sqrt{T}$ = บท 14 | $\sigma^2/2$ = Ito บท 14

บทนี้คือ "อ่านแผนที่" — ใส่ทีละตัวแล้วชี้ว่ามาจากไหน และ หมายความว่าอะไรในเชิงเศรษฐกิจ

ถึงเวลาพิสูจน์ว่าคุณเข้าใจจริง — ใส่สูตร BS ทีละตัวแล้วชี้ว่าแต่ละส่วนมาจากบทไหน

15.1 สูตร Black-Scholes ฉบับเต็ม

$$C = S_0 N(d_1) - K e^{-rT} N(d_2)$$

$$P = K e^{-rT} N(-d_2) - S_0 N(-d_1)$$

$$d_1 = \frac{\ln(S_0/K) + (r + \sigma^2/2)T}{\sigma\sqrt{T}} \quad d_2 = d_1 - \sigma\sqrt{T}$$

อ่านสูตร $C = SN(d_1) - Ke^{-rT}N(d_2)$ ใหม่ให้ออก

$SN(d_1)$ = "มูลค่าที่คาดว่าจะได้รับจากหุ้น" — ถ้า option ถูก exercise, ได้หุ้นมูลค่า S แต่มีโอกาส $N(d_1)$ ที่จะ exercise (ปรับ delta)

$Ke^{-rT}N(d_2)$ = "PV ของต้นทุนที่คาดว่าจะจ่าย" — ต้องจ่าย K เมื่อ exercise, discount กลับ (e^{-rT}), คูณด้วยโอกาส exercise $N(d_2)$

C = "สิ่งที่ได้" - "สิ่งที่จ่าย" = มูลค่าสุทธิของสิทธินี้

Trader's View: ตลาด Quote ด้วย Implied Vol — ไม่ใช่ราคา

ในตลาด options จริง ผู้ค้ามักไม่ quote "ราคา ฿12.29" — แต่ quote "**IV = 25%**":

- เหตุผล: IV เปรียบเทียบได้ข้าม strike และ maturity ที่ — ฿12.29 สำหรับ Call เดือนหน้ากับ ฿12.29 Call 3 เดือนบอกอะไรไม่ได้
- **BS เป็น translation layer:** Vol → Price (สำหรับ quote) และ Price → Vol (สำหรับ mark-to-market)
- IV = 25% แปลว่า "ตลาดคาด annualized 1σ move = 25%" — ใช้เปรียบเทียบกับ realized vol เพื่อหา edge

15.2 ไล่ทีละตัว — มาจากบทไหน?

ส่วนประกอบ	ความหมาย	เรียนในบทที่
S_0	ราคาหุ้นปัจจุบัน	บท 1: ตัวแปรในฟังก์ชัน
K	Strike Price	บท 1: $\max(0, S-K)$
e^{-rT}	Discount factor (PV)	บท 3: Continuous compounding
$K \times e^{-rT}$	PV(K) ใน Put-Call Parity	บท 3: Present Value
$N(d)$	CDF ของ Normal Distribution	บท 6: Normal, Z-score, CDF
$N(d_1)$	$\approx P(\text{expire ITM})$ ปรับด้วย delta	บท 6: CDF + บท 7: Delta
$N(d_2)$	$\approx P(\text{exercise})$ ใน risk-neutral world	บท 14: Risk-Neutral Pricing
$\ln(S_0/K)$	Log moneyness	บท 3: $\ln$, log return
σ	Volatility (Std Dev ของ log returns)	บท 4: σ + บท 6: Lognormal
$\sigma\sqrt{T}$	Volatility scaled ด้วยเวลา	บท 14: Brownian Motion (variance $\propto T$)
$r + \sigma^2/2$	Drift ใน risk-neutral world	บท 14: GBM + Ito's correction
$\sigma^2/2$	Ito's correction term	บท 14: Ito's Lemma

$$\boxed{S_0 \times N(d_1)} - \boxed{K \cdot e^{-rT} \times N(d_2)}$$

มูลค่าที่ได้รับ (delta-weighted) ต้นทุนที่คาดว่าจะจ่าย (PV)

= C (ราคา Call)

"สิ่งที่คาดว่าจะได้" - "สิ่งที่คาดว่าจะจ่าย" = มูลค่าสุทธิ

$$S_0 = \text{บท 1} \mid N(d_1) = \text{บท 6+7}$$

$$K \cdot e^{-rT} = \text{บท 3} \mid N(d_2) = \text{บท 6+14}$$

$$d_1, d_2 = \ln(\text{บท 3}) + \sigma(\text{บท 4}) + \sqrt{T}(\text{บท 14}) + \sigma^2/2 (\text{Ito, บท 14})$$

แผนภาพ: โครงสร้างสูตร Black-Scholes — แต่ละส่วนมาจากบทไหนของ Math book

15.2b $N(d_1)$ vs $N(d_2)$ — ต่างกันอย่างไร?

ทำไมต้องมีทั้ง d_1 และ d_2 ?

$N(d_2)$ = ความน่าจะเป็นที่ $S(T) > K$ ในโลก risk-neutral = "โอกาสที่จะ exercise"

$N(d_1)$ = $N(d_2)$ ที่ปรับด้วย "ขนาดที่ได้รับ" → Delta = $N(d_1)$ (ถ้า S สูงขึ้น option ได้เท่าไร)

ความต่าง: $d_1 = d_2 + \sigma\sqrt{T} \rightarrow \sigma\sqrt{T}$ คือ Ito correction! (จากบท 14: $d(\ln S) = (\mu - \sigma^2/2)dt + \sigma dW$)

เหมือนถามว่า "จะ exercise ไหม?" ($N(d_2)$) vs "ถ้า exercise แล้วได้เท่าไร?" ($N(d_1) \times S$)

- 1 คำนวณ d_1, d_2 : $S=100, K=100, r=5\%, \sigma=25\%, T=1$ ปี
- 2 $\ln(S/K) = \ln(100/100) = \ln(1) = 0$ (ATM!)
- 3 $d_1 = [0 + (0.05 + 0.03125) \times 1] / (0.25 \times 1) = 0.08125 / 0.25 = \mathbf{0.325}$
- 4 $d_2 = 0.325 - 0.25 = \mathbf{0.075}$
- 5 $N(d_1) = N(0.325) \approx 0.627, N(d_2) = N(0.075) \approx 0.530$
- 6 $Ke^{-rT} = 100 \times e^{-0.05} = 100 \times 0.9512 = \text{฿}95.12$
- 7 $C = 100 \times 0.627 - 95.12 \times 0.530 = 62.70 - 50.41 = \mathbf{\text{฿}12.29}$

15.3 พิสูจน์ Put-Call Parity จาก BS

ทำไมต้องพิสูจน์ PCP จาก BS?

เราเรียน PCP ในบท 2 จาก "เหตุผลทางการเงิน" (no-arbitrage)

ถ้า BS ถูกต้อง → ต้องสอดคล้องกับ PCP โดยอัตโนมัติ

การพิสูจน์นี้แสดงว่า BS มีความสอดคล้องภายในเอง — ไม่ใช่สูตรที่ "สุ่มมา"

$$C - P = S_0[N(d_1) + N(-d_1)] - Ke^{-rT}[N(d_2) + N(-d_2)] = S_0 - Ke^{-rT}$$

$$\implies C + Ke^{-rT} = P + S_0 \quad \checkmark \text{ Put-Call Parity}$$

Normal CDF

→

$N(x) + N(-x) = 1$

→

$C - P = S - Ke^{-rT}$

→

PCP พิสูจน์แล้ว!

ทุกอย่างเชื่อมกัน!

Put-Call Parity (บท 2) ← มาจาก BS formula ← มาจาก Ito's Lemma (บท 14) ← มาจาก Chain Rule (บท 7) + Brownian Motion (บท 14) ← มาจาก Normal Distribution (บท 6) ← มาจาก e, ln (บท 3)

15.3b กรีกทั้งห้าในรูป Closed-Form (ตารางกรีกครบชุด)

อุปมา: มาตรวัดบนแผงหน้าปัดรถ 🔍

เรารู้ราคา option (C) แล้ว — แต่ราคานั้น *ขยับ* เมื่อปัจจัยรอบตัวขยับ: หุ้นขึ้น/ลง, เวลาเดิน, σ เปลี่ยน, r เปลี่ยน

กรีกแต่ละตัว = **อนุพันธ์ของราคา option เทียบกับปัจจัยหนึ่ง** — วัดว่าราคาขยับแค่ไหนเมื่อปัจจัยนั้นขยับทีละหน่วย

เหมือนมาตรวัดบนรถ: มาตรวัดความเร็ว (Δ), มาตรวัดความเร่ง (Γ), เกจน้ำมันที่ลดลงตามเวลา (Θ) — แต่ละอันบอก "ราคาตอบสนองอย่างไร" ต่อปัจจัยคนละตัว

ข้อดี: ทุกตัวมี *สูตรปิด (closed-form)* — แค่หาอนุพันธ์ของ $C = SN(d_1) - Ke^{-rT}N(d_2)$ เทียบกับแต่ละปัจจัย

ตารางต่อไปนี้เป็นกรีกของ **Call** (ϕ = PDF ของ standard normal, N = CDF):

Greek	นิยาม	สูตร (Call)	ความหมาย
Delta (Δ)	$\partial C / \partial S$	$N(d_1)$	ราคาขยับต่อ ฿1 ของหุ้น
Gamma (Γ)	$\partial^2 C / \partial S^2$	$\varphi(d_1) / (S \cdot \sigma \cdot \sqrt{T})$	Delta ขยับเร็วแค่ไหน
Vega (v)	$\partial C / \partial \sigma$	$S \cdot \varphi(d_1) \cdot \sqrt{T}$	ราคาขยับต่อ 1% ของ σ
Theta (Θ)	$-\partial C / \partial T$	$-S \cdot \varphi(d_1) \cdot \sigma / (2\sqrt{T}) - rK \cdot e^{-rT} \cdot N(d_2)$	time decay ต่อวัน (T = time to expiry)
Rho (ρ)	$\partial C / \partial r$	$K \cdot T \cdot e^{-rT} \cdot N(d_2)$	ราคาขยับต่อ 1% ของ r

d_1 , φ มาจากไหน?

$\varphi(x) = (1/\sqrt{2\pi}) \cdot e^{-x^2/2}$ คือ **ความหนาแน่น** (density) ที่จุด x — ไม่ใช่ความน่าจะเป็นสะสม $N(x)$ (บท 6)

ทุกสูตรกรีกมีแต่ $N(d)$ และ $\varphi(d)$ เท่านั้น — ไม่ต้องมีสูตรลึกลับเพิ่ม เพราะมันคืออนุพันธ์ของ $N(d_1)$, $N(d_2)$ ที่เรามีอยู่แล้ว

ตัวอย่างคำนวณ: กรีกของ Call ที่ ATM

ใช้ตัวเลขชุดเดิม: $S=100$, $K=100$, $r=5\%$, $\sigma=25\%$, $T=1$ ปี $\rightarrow d_1=0.325$, $d_2=0.075$

ค่าที่ต้องใช้: $\varphi(0.325) \approx 0.378$, $N(0.325) \approx 0.627$, $N(0.075) \approx 0.530$

- 1 Delta** = $N(d_1) = N(0.325) = \mathbf{0.627} \rightarrow$ หุ้นขึ้น ฿1 ราคา option ขึ้นประมาณ ฿0.63
- 2 Gamma** = $\varphi(d_1) / (S \cdot \sigma \cdot \sqrt{T}) = 0.378 / (100 \times 0.25 \times 1) = 0.378 / 25 = \mathbf{0.0151}$
- 3 Vega** = $S \cdot \varphi(d_1) \cdot \sqrt{T} = 100 \times 0.378 \times 1 = \mathbf{37.8}$ (per 1.00 vol) $\rightarrow \div 100 = \mathbf{0.378}$ ต่อ **1% vol**
- 4 Theta** = $-S \cdot \varphi(d_1) \cdot \sigma / (2\sqrt{T}) - rK \cdot e^{-rT} \cdot N(d_2) = -(100 \times 0.378 \times 0.25 / 2) - (0.05 \times 100 \times 0.9512 \times 0.530) \approx -4.725 - 2.521 = \mathbf{-7.25}$ ต่อปี ($\div 365 \approx -\text{฿0.020}$ ต่อวัน)
- 5 Rho** = $K \cdot T \cdot e^{-rT} \cdot N(d_2) = 100 \times 1 \times 0.9512 \times 0.530 \approx \mathbf{50.4}$ (per 1.00) $\rightarrow \div 100 = \mathbf{0.504}$ ต่อ **1% ของ r**

ข้อตกลงเรื่องหน่วย (conventions) — ระวังให้ดี!

Vega: สูตรให้ค่าต่อ vol = 1.00 (คือ 100%) — เทรดเดอร์มัก quote ต่อ 1% vol → หารด้วย 100 (37.8 → 0.378)

Theta: สูตรให้ค่าต่อปี — มัก quote เป็น time decay ต่อวัน → หารด้วย 365 (วันปฏิทิน) หรือ **252** (วันทำการ — เป็น convention ที่ใช้บน Bloomberg/Reuters)

Rho: เช่นเดียวกับ Vega มัก quote ต่อ 1% ของ r → หารด้วย 100

กรีกของ Put — ได้ฟรีจาก Put-Call Parity

เพราะ $P = C - S + Ke^{-rT}$ (PCP, บท 2) อนุพันธ์ของ Put ต่างจาก Call แค่พจน์ที่ไม่ใช่ฟังก์ชันของ $N(d)$:

Delta_put = $N(d_1) - 1$ (เป็นลบเสมอ — Put ได้กำไรเมื่อหุ้นลง)

Gamma_put = Gamma_call (เท่ากันทุกประการ)

Vega_put = Vega_call (เท่ากัน — vol สูงดีต่อทั้งสองฝั่ง)

Theta_put = $\text{Theta_call} + rKe^{-rT}$ (พจน์ discount กลับเครื่องหมาย)

Rho_put = $-K \cdot T \cdot e^{-rT} \cdot N(-d_2)$ (เป็นลบ — Put เสียมูลค่าเมื่อ r ขึ้น)

โจทย์: Gamma และ Vega ของ Call

ใช้ $S=100, K=100, r=5\%, \sigma=25\%, T=1, \phi(d_1)=\phi(0.325)\approx 0.378$

(ก) คำนวณ Gamma (ข) คำนวณ Vega ต่อ 1% vol (ค) ถ้า σ เพิ่มขึ้นจาก 25% → 26% ราคา option ขึ้นประมาณเท่าไร?

► ดูเฉลย

15.4 ข้อจำกัดของ BS — สิ่งที่ต้องรู้**ทำไม BS ยังใช้กันอยู่ทั้งๆ ที่ผิด?**

BS ใช้สมมติฐานที่ผิดจากความเป็นจริงหลายข้อ แต่ยังเป็น "ภาษากลาง" ของตลาด

Traders quote ด้วย Implied Volatility (IV) แทนราคา — ซึ่งใช้ BS เป็น translation layer

"All models are wrong, but some are useful" — ต้องรู้ว่า BS ผิดตรงไหน เพื่อจะได้ hedge ความผิดพลาดนั้น

สมมติฐาน BS	ความเป็นจริง	ผลกระทบ
σ คงที่	σ เปลี่ยนตลอด (บท 12 GARCH)	Volatility Smile/Skew — IV ต่างกันตาม K
Log returns เป็น Normal	Fat tails (บท 6.6)	Underestimate tail risk — OTM options ถูกเกินไปใน BS
ไม่มี jumps	ราคากระโดดได้ (gap opening)	Deep OTM options มีราคาต่ำเกินไป
Trading ต่อเนื่อง	ตลาดปิด/เปิด	Overnight risk ไม่ถูก model
ไม่มี transaction costs	มี commissions, bid-ask spread	Hedging ไม่ perfect ในทางปฏิบัติ

Volatility Smile — หลักฐานว่า BS ไม่สมบูรณ์

ถ้า BS ถูกต้อง → IV ควรเท่ากันทุก Strike (σ คงที่)

แต่ในตลาดจริง: IV ของ OTM Put > ATM > OTM Call → เป็น "รอยยิ้ม" (Smile)

หรือ IV(OTM Put) >> IV(ATM) แบบเฉียง → เป็น "Skew"

Skew แสดงว่าตลาดกลัว downside มากกว่าที่ BS คาด (fat left tail)

15.5 ข้อสมมติที่ต้องจำให้ขึ้นใจ — European-only + ไม่มีปันผล

สี่ข้อสมมติที่ทำให้ BS ใช้ "ตรง ๆ" ไม่ได้เสมอไป

(1) **European exercise เท่านั้น** — สูตร BS ใช้กับ *American option* ตรง ๆ ไม่ได้เพราะ American exercise เมื่อไหร่ก็ได้ก่อนหมดอายุ โดยเฉพาะ American put อาจ *คุ้มที่จะ exercise ก่อนกำหนด* (เอาเงิน K มาลงทุนต่อได้ดอกเบี้ย) → ต้องใช้ binomial tree หรือ MC แทน

(2) **ไม่มี dividend** — สูตรเดิมสมมติหุ้นไม่จ่ายปันผล ถ้าหุ้นจ่ายปันผลแบบ yield q ต้องใช้สูตรปรับ: แทน S ด้วย $S e^{-qT}$ (ราคาหุ้นถูกหักด้วย PV ของปันผลที่จะจ่าย)

(3) **r และ σ คงที่** — ในความเป็นจริง σ เปลี่ยนตลอด (เห็นได้จาก volatility smile/skew ข้างบน) และ r ก็ขยับตามตลาดพันธบัตร

(4) **ซื้อขายต่อเนื่อง ไม่มี transaction cost** — การ hedge แบบ delta จริงต้องปรับพอร์ตเป็นช่วง ๆ และมี commission + bid-ask spread → hedge ไม่ perfect

$$C = S e^{-qT} N(d_1) - K e^{-rT} N(d_2) \quad d_1 = \frac{\ln(S/K) + (r - q + \sigma^2/2)T}{\sigma \sqrt{T}}$$

⚠ **Model Risk: "All Models Are Wrong" — รู้ว่า BS ผิดตรงไหน แล้วหาประโยชน์จากจุดนั้น**

BS ยังเป็น benchmark ของตลาด แต่ต้องใช้พร้อมกับความเข้าใจข้อจำกัด:

- **Vol Smile/Skew** = หลักฐานชัดเจนที่สุดว่า lognormal ไม่พอ — OTM Put แพงกว่า BS predict
- **Vanna/Volga**: second-order vol Greeks ที่ BS ไม่ model — market makers hedge ด้วย

Stochastic Vol

- **ใช้ BS ถูกวิธี**: quote ใน IV, hedge delta + gamma daily, เข้าใจ smile เพื่อ carry/spread trade
- "เก่งกว่าคนอื่น ไม่ใช่ใช้ model ที่ถูกกว่า — แต่รู้ว่า model ผิดตรงไหน แล้วหาประโยชน์จากจุดนั้น"

บทที่ 16: Monte Carlo Simulation — "จำลองอนาคต 10,000 ครั้ง"

อุปมา: บริษัทประกันชีวิตกับนักสถิติ

บริษัทประกันไม่รู้ว่าคุณจะตายปีไหน แต่รู้ว่า "ถ้ามีลูกค้า 100,000 คน คนอายุ 40 ปีเฉลี่ยจะตายเมื่ออายุ 75"

Monte Carlo คิดแบบเดียวกัน: ไม่รู้ว่าหุ้นจะขึ้นหรือลง แต่รู้ว่า "ถ้าจำลอง 100,000 paths ตาม GBM จะได้ payoff เฉลี่ยเท่าไร"

Law of Large Numbers รับรอง: ยิ่งจำลองมาก ค่าเฉลี่ยยิ่งใกล้ค่าจริง

เมื่อไม่มีสูตร closed-form (exotic options, complex strategies) → จำลองราคาหุ้นหลายๆ ครั้ง แล้วเฉลี่ย

16.1 แนวคิดและสูตร Monte Carlo

1. สุ่ม $Z \sim \mathcal{N}(0, 1)$ จำนวน N ครั้ง
2. $S_T = S_0 \exp\left[\left(r - \frac{\sigma^2}{2}\right)T + \sigma\sqrt{T} Z\right]$
3. $\text{Payoff}_i = \max(0, S_T^{(i)} - K)$
4. $C = e^{-rT} \overline{\text{Payoff}}$

ทำไมสูตร $S(T)$ ถึงเขียนแบบนี้?

จากบท 14: $d(\ln S) = (\mu - \sigma^2/2)dt + \sigma dW$ (Ito's result)

Integrate ตั้งแต่ 0 ถึง T: $\ln(S(T)/S_0) = (\mu - \sigma^2/2)T + \sigma\sqrt{T} \times Z$


Exponentiate: $S(T) = S_0 \times \exp((\mu - \sigma^2/2)T + \sigma\sqrt{T} \times Z)$

ในโลก risk-neutral: $\mu = r \rightarrow$ ใช้ r แทน μ ใน simulation!

- 1 MC ตัวอย่าง: $S=100$, $K=100$, $r=5\%$, $\sigma=25\%$, $T=1$ ปี
- 2 สุ่ม $Z_1=1.2$, $Z_2=-0.5$, $Z_3=0.8$ (3 paths ตัวอย่าง)
- 3 $(r-\sigma^2/2)T = (0.05-0.03125)\times 1 = 0.01875$, $\sigma\sqrt{T} = 0.25$
- 4 Path 1: $S(1) = 100 \times \exp(0.01875 + 0.25 \times 1.2) = 100 \times \exp(0.3188) = 100 \times 1.375 = \text{฿}137.5$
- 5 Path 2: $S(1) = 100 \times \exp(0.01875 + 0.25 \times (-0.5)) = 100 \times \exp(-0.1063) = 100 \times 0.899 = \text{฿}89.9$
- 6 Path 3: $S(1) = 100 \times \exp(0.01875 + 0.25 \times 0.8) = 100 \times \exp(0.2188) = 100 \times 1.245 = \text{฿}124.5$
- 7 Payoffs: $\max(37.5, 0)=37.5$, $\max(-10.1, 0)=0$, $\max(24.5, 0)=24.5$
- 8 Average = $(37.5+0+24.5)/3 = 20.67$, discount: $20.67 \times e^{-0.05} = \text{฿}19.65$ (แค่ 3 paths — ต้องการมากกว่านี้!)
- 9 ทำซ้ำ 100,000 paths $\rightarrow$ average $\rightarrow$ BS price $\approx \text{฿}12.34$

⚠ ทำไม 3-path ตัวอย่างให้ ฿19.65 สูงกว่าค่าจริง ฿12.34?

Z ที่สุ่มมา (1.2, -0.5, 0.8) มีค่าเฉลี่ย = +0.5 ซึ่ง **เอนขึ้น** — ตามทฤษฎี Z ควรมีค่าเฉลี่ย ≈ 0 เมื่อ sample เยอะพอ ด้วย path น้อย ค่าเฉลี่ย sample เพี้ยนจาก 0 ได้มาก ทำให้ราคาประเมินเพี้ยน นี่คือเหตุผลที่ต้องใช้ paths เยอะ (standard error ลดลงตาม $1/\sqrt{N}$)



Monte Carlo GBM paths — each run gives different $S(T)$; average = option price

16.2 เปรียบเทียบ MC กับ BS

วิธีและ N	ราคา Call (B)	ข้อสังเกต
BS Formula (exact)	12.336	เร็ว 0.001 ms
MC 1,000 paths	12.5 ± 0.8	Error สูง
MC 10,000 paths	12.38 ± 0.25	ดีขึ้น 3x
MC 100,000 paths	12.34 ± 0.08	พอใช้งานจริง
MC 1,000,000 paths	12.336 ± 0.025	แม่นยำมาก

N paths

→

Error $\propto 1/\sqrt{N}$

→

10x paths → 3.16x แม่น

→

Law of Large Numbers

สังเกต: ยิ่ง paths มาก ยิ่งแม่นยำ (error $\propto 1/\sqrt{N}$)

100,000 paths → error ≈ 0.08 — ดีพอสำหรับการเทรดจริง

ข้อดีของ MC: ใช้ได้กับทุก option ไม่ว่าจะซับซ้อนแค่ไหน — ไม่ต้องมีสูตร closed-form

16.3 Exotic Options — ที่ BS แก่ไม่ได้

อุปมา: ประกันที่จ่ายตามค่าเฉลี่ยความเสียหาย ไม่ใช่ความเสียหายสุดท้าย

Vanilla Call: Payoff = $\max(0, S(T) - K)$ → ขึ้นกับแค่ราคาวันสุดท้าย

Asian Option: Payoff = $\max(0, \text{avg}(S) - K)$ → ขึ้นกับราคา เฉลี่ยตลอดทาง

Barrier Option: หกค่าถ้าราคาแตะ "รั้ว" → ขึ้นกับ เส้นทางทั้งหมด

BS ไม่รู้เรื่อง "เส้นทาง" — แค่รู้จุดเริ่มและจุดจบ → ต้องใช้ MC ที่ simulate ทุก step

Exotic Option	Payoff	ทำไมต้อง MC?
Asian Option	$\max(0, \text{avg}(S) - K)$	Payoff ขึ้นกับราคาเฉลี่ยตลอดทาง
Barrier Option	หมดค่าถ้าราคาแตะ barrier	ขึ้นกับเส้นทางทั้งหมด
Lookback Option	$\max(0, \max(S) - K)$	Payoff ขึ้นกับราคาสูงสุดตลอดทาง
Basket Option	$\max(0, \text{avg}(S_1, S_2, \dots) - K)$	ขึ้นกับหลายสินทรัพย์พร้อมกัน

- 1 Asian Call MC: $S=100, K=100, \sigma=25\%, r=5\%, T=1$ ปี, 12 monthly steps
- 2 สุ่ม Z ทั้งหมด 12 ค่า ต่อ 1 path: $Z = [-0.3, 0.5, 1.1, -0.8, 0.2, \dots]$
- 3 คำนวณ $S(t)$ ทุกเดือน: $S(1)=100 \times \exp(\dots), S(2)=S(1) \times \exp(\dots), \dots$
- 4 $\text{avg}(S) = (S(1)+S(2)+\dots+S(12))/12 =$ สมมติ ฿108.5
- 5 $\text{Payoff} = \max(108.5 - 100, 0) =$ ฿8.5
- 6 ทำซ้ำ 100,000 paths → เฉลี่ย payoff → discount → Asian price
- 7 Asian price < Vanilla price เพราะ $\text{avg}(S)$ ผันผวนน้อยกว่า $S(T)$ เดียวๆ

ทุก option price ได้ด้วย MC เพียงแค่:

1. จำลอง price paths (อาจต้องหลายสินทรัพย์, หลายช่วงเวลา)
2. คำนวณ payoff ตาม definition ของ exotic option นั้นๆ
3. เฉลี่ย แล้ว discount กลับ

ไม่ต้องมีสูตร closed-form — นี่คือพลังของ Monte Carlo!

16.4 Variance Reduction

อุปมา: แบ่งการสำรวจ ไม่ใช่แค่สุ่มทั้งหมด

ถ้าต้องสำรวจความคิดเห็น 100 คน จาก 4 กลุ่ม — สุ่มสัมภาษณ์ 100 คน อาจได้กลุ่มหนึ่งมากเกินไป

Stratified sampling: สำรวจ 25 คน จากแต่ละกลุ่ม → แม่นกว่า ใช้คนเท่ากัน

Antithetic Variates เป็นแนวคิดเดียวกัน: สุ่ม Z แล้วใช้ $-Z$ ด้วย → ครอบคลุมทั้ง "ขาขึ้น" และ "ขาลง" ในคู่เดียว

ทำให้ MC แม่นขึ้นโดยไม่ต้องเพิ่ม paths:

เทคนิค	วิธีการ	ผลลัพธ์
Antithetic Variates	ถ้าสุ่ม $Z \rightarrow$ ใช้ $-Z$ ด้วย (คู่สมมาตร)	ลด variance ~50% ฟรี!
Control Variates	ใช้ option ที่มี closed-form เป็น "ตัวควบคุม"	ลด error มาก

16.4b Standard Error — วัดความแม่นยำของ MC

อุปมา: โพลสำรวจที่มี "ค่าความคลาดเคลื่อน $\pm 3\%$ "

MC ให้ราคาประมาณ — แต่ *ประมาณแค่ไหน?* เหมือนโพลที่บอก " $45\% \pm 3\%$ " เราต้องรู้ความคลาดเคลื่อนถึงจะใช้ตัวเลขได้

Standard Error (SE) คือ " $\text{ค่า} \pm$ " ของ MC: มันบอกว่าคุณค่าเฉลี่ยที่ได้น่าจะห่างจากค่าจริงเท่าไร

สูตร SE และตัวอย่างคำนวณ

$$SE = \frac{\sigma_{\text{payoff}}}{\sqrt{N}}$$

σ_{payoff} = ส่วนเบี่ยงเบนมาตรฐานของ payoff ข้าม paths, N = จำนวน paths

- 1 สมมติ std ของ payoff = ฿15, $N = 10,000$
- 2 $SE = 15 / \sqrt{10,000} = 15 / 100 = \mathbf{฿0.15}$
- 3 $95\% \text{ CI} = \text{estimate} \pm 1.96 \times SE = \text{estimate} \pm 1.96 \times 0.15 = \mathbf{\pm ฿0.29}$
- 4 อยากให้ SE ลดครึ่ง (฿0.15 $\rightarrow$ ฿0.075)? ต้องใช้ **paths เพิ่ม 4x** (40,000) — เพราะ $SE \propto 1/\sqrt{N}$

16.4c Antithetic Variates — สุ่ม Z แล้วใช้ $-Z$

วิธีการและตัวอย่าง

สำหรับทุก Z ที่สุ่มมา ให้ใช้ $-Z$ สร้างอีก path หนึ่งด้วย → สองเส้นทางนี้ *สหสัมพันธ์เป็นลบ* (ตัวหนึ่งขึ้น อีกตัวลง) ค่าเฉลี่ยของคู่จึงผันผวนน้อยลง

- 1 สุ่ม $Z = +1.2 \rightarrow S_+ = 100 \times \exp(0.01875 + 0.25 \times 1.2) = \$137.5 \rightarrow \text{payoff} = \37.5
- 2 ใช้คู่ $-Z = -1.2 \rightarrow S_- = 100 \times \exp(0.01875 + 0.25 \times (-1.2)) = 100 \times \exp(-0.281) = \$75.5 \rightarrow \text{payoff} = \0
- 3 ค่าเฉลี่ยของคู่ $= (37.5 + 0)/2 = \mathbf{\$18.75}$ — เมื่อ path หนึ่งสุดโต่งขึ้น อีก path ดิ่งกลับลง → ค่าเฉลี่ยเสถียรกว่าการสุ่มอิสระสองครั้ง
- 4 ผลทั่วไป: ลด variance ได้ราว **~50%** ฟรี โดยไม่ต้องเพิ่มจำนวนการสุ่ม Z

16.4d Control Variates — ยืมราคาที่เราแน่ มาแก้ค่าที่ไม่รู้

ใช้ option ที่รู้ราคาแน่ ๆ มาแก้ MC ของ option ที่ยาก

สมมติเราอยาก price **Asian option** (ไม่มี closed-form) แต่ **vanilla option** เรารู้ราคาจริงจาก BS แน่แน่นอน → เอามาช่วยแก้ค่า:

$$Y^* = Y_{\text{Asian}, \text{MC}} - \beta (Y_{\text{Vanilla}, \text{MC}} - Y_{\text{Vanilla}, \text{BS}})$$

พจน์ในวงเล็บ $(Y_{\text{vanilla}, \text{MC}} - Y_{\text{vanilla}, \text{BS}})$ คือ **ความผิดพลาดของ MC บน vanilla** — และเรารู้มันเป๊ะ เพราะรู้ราคา BS จริง

ถ้า MC รอบนี้ประเมิน vanilla สูงไป → มันก็มักประเมิน Asian สูงไปด้วย (สหสัมพันธ์กัน) → เราจึง *ลบ error นั้นทิ้ง* ออกจากค่า Asian

β คือสัมประสิทธิ์ที่ปรับให้เหมาะสม (มักได้จาก regression ของ Y_{asian} กับ Y_{vanilla}) → ลด variance ได้ถึง **80–90%** เมื่อสองตัวสหสัมพันธ์สูง

ระวัง: variance reduction หด "ค่าคงที่" ไม่ใช่ "อัตรา"

การ converge ของ MC ยังคงเป็น **$1/\sqrt{N}$ เสมอ** — เทคนิคพวกนี้ทำให้ค่าคงที่ข้างหน้า (σ_{payoff}) เล็กลง ไม่ได้เปลี่ยนเลขชี้กำลัง

ดังนั้นถ้าอยากแม่นยำขึ้น 10x คุณยังต้องใช้ paths **เพิ่ม 100x** อยู่ดี — เว้นแต่จะลด variance ลงด้วยเทคนิคข้างต้น (ซึ่งแค่ขยับเส้นกราฟลง ไม่ได้ทำให้มันชันขึ้น)

โจทย์: Standard Error และ Confidence Interval

MC ประเมินราคา Call ได้ ฿12.34 จาก $N = 40,000$ paths โดยมี std ของ payoff = ฿18

(ก) คำนวณ SE (ข) หา 95% CI (ค) ถ้าอยากให้ $SE = ฿0.045$ ต้องใช้กี่ paths?

► ดูเฉลย

แบบฝึกหัด Part VII

โจทย์ 1: คำนวณ BS Call ด้วยมือ

กำหนด $S=100$, $K=105$, $r=4\%$, $\sigma=20\%$, $T=0.5$ ปี

$d_1 = [\ln(100/105) + (0.04+0.02) \times 0.5] / (0.2 \times \sqrt{0.5}) = ?$

คำนวณ d_1 , d_2 , แล้วหา C โดยใช้ $N(-0.13) \approx 0.448$, $N(-0.28) \approx 0.390$

► ดูเฉลย

โจทย์ 2: Asian Option MC (3 Paths)

ให้ $S=100$, $K=100$, monthly steps, $e^{-rT} = 0.95$ (ประมาณ)

Path A: ราคาเดือน 1-12 เฉลี่ย ฿112

Path B: ราคาเฉลี่ย ฿95

Path C: ราคาเฉลี่ย ฿103

คำนวณ Asian Call price จาก 3 paths นี้

► ดูเฉลย

โจทย์ 3: Volatility Smile — BS ตีความอะไร?

สังเกตว่า IV ของ Options บน SET50 เป็นดังนี้:

Strike (K)	90	95	100	105	110
IV (%)	35%	30%	25%	28%	32%

ถ้า BS ถูกต้อง IV ควรเป็นเท่าไร? Pattern นี้บอกว่าตลาดกลัวอะไร?

► ดูเฉลย

ภาคผนวก: แผนที่ความรู้ทั้งหมด

Part	บท	เรียนอะไร	ใช้ทำอะไรใน Options
I	1	ฟังก์ชัน, max, slope, piecewise	อ่าน Payoff Chart ออก
	2	พีชคณิต, จัดรูปสมการ	Put-Call Parity, Synthetic
	3	e, ln, ดอกเบี้ยทบต้น	PV(K), log return
II	4	Mean, σ , correlation	Volatility, VaR, Portfolio Risk
	5	ความน่าจะเป็น, E[X]	Expected Payoff, Bayes
	6	Normal, Lognormal, CLT	N(d) ใน BS, Vol Smile
III	7	Derivatives, ∂ , $\int$, Taylor	Greeks ทุกตัว, Δ - Γ approx
IV	8	Vectors, Matrices, Eigen	Portfolio Var = $w^T \Sigma w$, PCA
	9	Regression, R^2 , Fitting	Beta, Hedge Ratio, Vol Surface
V	10	LP, Simplex, Dual, ILP	Optimal strategy selection
	11	Gradient, Lagrange, QP	Markowitz, Calibration
VI	12	Time Series, GARCH	Forecast σ , Mean Reversion
	13	Bisection, Newton	IV Solver, Numerical Greeks
	14	BM, GBM, Ito, BS PDE	ที่มาของ BS, $\Theta + \frac{1}{2}\sigma^2 S^2 \Gamma + rS\Delta = rV$
VII	15	BS formula breakdown	อ่านทุกตัวออก!
	16	Monte Carlo	Price ทุก option ได้

บท 1-3 (เครื่องมือ)

→

บท 4-6 (สถิติ+prob)

→

บท 7 (calculus)

→

บท 14 (Ito)

→

Black-Scholes!

จบเล่ม! ตอนนี้คุณมีพื้นฐานคณิตศาสตร์ครบสำหรับ:

- ✓ อ่านบทเรียน Payoff Chart ทั้งหมด (ตั้งแต่พื้นฐาน → Greeks → Advanced Strategies)
- ✓ เข้าใจ Black-Scholes ทุกตัว — ไม่ใช่แค่ใช้เป็น แต่รู้ว่า มาจากไหน
- ✓ Forecast Volatility ด้วย GARCH → เทียบ IV → หาจังหวะ buy/sell options
- ✓ จัดการ Portfolio ด้วย Linear Algebra + Markowitz QP Optimization
- ✓ Price Exotic Options ด้วย Monte Carlo ไม่ว่าจะซับซ้อนแค่ไหน
- ✓ พร้อมเรียนต่อในระดับ Advanced Quant

จบ Part VII — จบทั้งเล่ม!

คณิตศาสตร์พื้นฐานสำหรับ Options Trading & Quantitative Finance

16 บท | 7 Parts | จากศูนย์สู่ Black-Scholes

Bridge Chapter

จากคณิตศาสตร์สู่ Statistical Arbitrage

From Math Tools → How They Appear in the Stat Arb Book

บทนี้เชื่อมโยงแต่ละเครื่องมือทางคณิตศาสตร์กับบทเฉพาะใน Statistical Arbitrage book (25 บท, Ch 0–24) — เพื่อให้เห็นว่า "ใช้ตรงไหน" ก่อนอ่านต่อ

ทำไมต้องมี Bridge Chapter?

Stat Arb book มีโจทย์เดียว: สร้าง **Synthetic Process** จากสองราคา แล้วเทรดบน mean-reversion ของ spread — แต่เบื้องหลังนั้นเต็มไปด้วยคณิตศาสตร์จากทั้ง 7 Part

แผนที่หนังสือ Stat Arb (25 บท)

กลุ่ม	บท	หัวข้อ
Foundations	Ch 0–2	Intro, Synthetic Process, Stochastic Calculus
Spread Models	Ch 3–6	OU Process, Hedge Ratio β , Cointegration, Hurst/ADF
Vol & Regime	Ch 7–9	GARCH, Jump-Diffusion, Regime-Switching
Signal & Execution	Ch 10–14	Z-score, State Machine, Position Sizing, Perpetual Basis, Cross-venue
Advanced Strategies	Ch 15–22	Kalman β , Multi-leg, Commodity, Options Overlay, Cost, Risk, CFD, Options Arb
Capstone	Ch 23–24	Kalman+t-dist, Case Studies (LTCM, Quant Quake)

Part I: Algebra & Functions → Stat Arb

§1: Log Return & % Change

Log Return

$$r_t = \ln(P_t/P_{t-1})$$

→

Ch 1 (Synthetic Process): spread $\varepsilon = \ln(P_A) - \beta \cdot \ln(P_B)$
 สร้างจาก log price โดยตรง

Ch 4 (Hedge Ratio β): OLS regression ทำบน log prices
 เพื่อหา β

Ch 7 (GARCH): GARCH ประมาณ vol จาก daily log returns
 ของ spread residuals

§3: Option Payoff — $\max(S-K, 0)$

Call Payoff

$$\max(S_T - K, 0)$$

→

Ch 18 (Options Overlay): PCP deviation เป็น signal —
 ต้องเข้าใจ payoff structure ก่อน

Ch 22 (Options Stat Arb): IV skew arb ใช้ Risk Reversal
 = Call payoff – Put payoff

§4: Put-Call Parity (PCP)

PCP

$$C - P = S - Ke^{-rT}$$

→

Ch 18 §18.1–18.2: PCP deviation ε_{pcp} คือ spread signal
 ใหม่ใน Stat Arb framework

Ch 18 §18.3: BTC options บน Deribit — ตัวอย่าง PCP
 violation จริง

Ch 22 §22.2: Box Spread Stat Arb — ε_{box} สร้างจาก PCP
 ทั้งสองฝั่ง

§2: Compound Growth & Cost of Carry

Cost of Carry

$$F = Se^{rT}$$

→

Ch 17 (Commodity Basis): Fair Basis = $F - S \cdot e^{rT}$ —
 cost of carry model สำหรับ Futures spread

Ch 13 (Perpetual Basis): funding rate ใน crypto perp
 สอดคล้องกับ cost of carry

Part II: Statistics & Probability → Stat Arb

§3–4: Mean, Variance, Rolling Statistics

Sample Variance

$$s^2 = \frac{1}{n-1} \sum (r_i - \bar{r})^2$$

→

Ch 7 (GARCH): constant $\sigma \equiv$ rolling variance — GARCH ปรับปรุงสิ่งนี้ให้ time-varying

Ch 10 (Z-score): standard $Z = (\varepsilon - \mu)/\sigma$ — พื้นฐานของ trading signal

Ch 12 (Position Sizing): σ ของ spread ใช้ใน Kelly criterion เพื่อกำหนดขนาด position

§5: Normal Distribution & Z-score

Z-score

$$Z = (\varepsilon_t - \mu)/\sigma$$

→

Ch 10 §10.1–10.4: Standard Z-score → Robust Z-score (MAD) → Rolling Z-score — 3 variants

Ch 3 (OU Process): stationary distribution ของ OU เป็น Normal — band = $\mu \pm 2\sigma$

Ch 11 (State Machine): Z-score threshold เป็น trigger condition สำหรับ entry/exit

§6: Fat Tails & Non-Normal Returns

Excess Kurtosis

$$\kappa - 3 > 0$$

→

Ch 8 (Jump-Diffusion): fat tails ใน crypto spread = jumps — ต้องใช้ Merton/Kou model

Ch 20 §20.4 (Risk): Black Swan scenarios — Normal VaR understates จริง

Ch 23 §23.5–23.8: t-distribution แทน Normal สำหรับ crypto residuals — critical values ต่างกัน

⚠ Model Risk: Normal Z-score ใน Crypto

Crypto spread residuals มี excess kurtosis สูงกว่า equity มาก (kurtosis > 10 เป็นเรื่องปกติ) — $Z = 2$ ใน Normal แปลว่า 5% chance แต่ใน t-dist (df=5) แปลว่า ~10% ดังนั้น Ch 23 แนะนำให้ใช้ t-distribution สำหรับ crypto

Part III: Calculus & Greeks → Stat Arb

§7–8: Greeks ใน Options Overlay

$$\text{Delta } \Delta = \partial C / \partial S$$

Ch 18 §18.6: delta hedge ของ options spread ใน PCP arb

Ch 22 §22.3: IV skew arb ใช้ delta-neutral Risk Reversal

$$\text{Vega } \mathcal{V} = \partial C / \partial \sigma$$

Ch 22 §22.5: Vol Risk Premium = IV – RV — เมื่อ vega ของ position > 0

Ch 22 §22.4: IV Skew Arb ระหว่าง Deribit ↔ Bybit

$$\text{Theta } \Theta = \partial C / \partial t$$

Ch 22 §22.6: friction & breakeven — theta decay คือต้นทุนของ long option position

$$\text{Gamma } \Gamma = \partial^2 C / \partial S^2$$

Ch 18 §18.6: gamma ของ options spread ทำให้ delta ต้องถูก re hedge เมื่อ S เคลื่อน

§7: Derivative คือ Rate of Change — ใช้ใน Calibration

Newton-Raphson

$$\sigma_{n+1} = \sigma_n - \frac{C_{BS}(\sigma_n) - C_{mkt}}{Vega(\sigma_n)}$$

→

Ch 22 §22.1: สร้าง IV surface จาก market option prices — Newton-Raphson solve implied vol

Ch 18 §18.4: IV Surface Arbitrage ต้องใช้ IV ที่ accurate จาก Newton-Raphson

Part IV: Linear Algebra & Regression → Stat Arb

§8: OLS Regression — หัวใจของ Hedge Ratio

OLS Beta

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

→

Ch 4 §4.2 (Hedge Ratio β): OLS คือ method หลักในการหา β ของ spread

Ch 1 §1.3: β คือ entry ratio — ซื้อ 1 unit A ต้องขาย β units B

Ch 4 §4.4: lookback window ส่งผลต่อ β — OLS ด้วย window ต่างกันให้ β ต่างกัน

§8: Residuals = Spread = Synthetic Process

Spread

$$\varepsilon_t = P_A - \hat{\beta}P_B - \hat{\alpha}$$

→

Ch 1 §1.2: ε คือ synthetic process — สิ่งที่เราเทรดจริงๆ

Ch 5 §5.2 (Cointegration): Engle-Granger test เช็ค stationarity ของ residuals จาก OLS

Ch 7 (GARCH): GARCH ประมาณ vol ของ ε residuals ไม่ใช่ raw prices

§9: Covariance Matrix — Multi-leg Portfolio

Portfolio Var

$$\sigma_p^2 = \mathbf{w}^\top \Sigma \mathbf{w}$$

→

Ch 16 §16.2 (Multi-leg): Covariance Matrix ของ Spreads — สร้าง Σ ระหว่าง spread pairs

Ch 16 §16.3: Mean-Variance Allocation ใช้ $\mathbf{w}^\top \Sigma \mathbf{w}$ เพื่อหา optimal weights

Ch 20 §20.3 (Risk): VaR/CVaR ของ spread position สร้างจาก Σ

Part V: Optimization → Stat Arb

§11: Kelly Criterion — Position Sizing

$$\text{Kelly} \\ f^* = \mu / \sigma^2$$

→

Ch 12 §12.1 (Position Sizing): Kelly criterion พื้นฐาน — $f^* = \text{edge}/\text{variance}$

Ch 12 §12.2: Half-life Scaling ปรับ Kelly ตาม OU speed of reversion

Ch 12 §12.3: Jump-adjusted Kelly ลด f^* เมื่อ detect jump risk

§11: Mean-Variance Optimization — Multi-leg Allocation

$$\text{MVO} \\ \max \mu^\top \mathbf{w} - \frac{\lambda}{2} \mathbf{w}^\top \Sigma \mathbf{w}$$

→

Ch 16 §16.3 (Multi-leg): Mean-Variance Allocation ระหว่าง spreads หลายคู่

Ch 20 §20.2 (Risk Mgmt): drawdown constraint เป็น LP constraint เพิ่มเติมใน optimization

§10: LP Constraints — Risk Limits

$$\text{LP} \\ \max \mathbf{c}^\top \mathbf{x}, \quad A\mathbf{x} \leq \mathbf{b}$$

→

Ch 20 §20.2 (Risk Mgmt): max drawdown limit, max single-spread exposure เป็น linear constraints

Ch 19 §19.7 (Cost Analysis): minimum viable σ_{stat} — breakeven analysis เป็น LP feasibility check

Quant Insight: Kelly ใน Stat Arb

Kelly ทฤษฎีบอก $f^* = \mu / \sigma^2$ แต่ใน Ch 12 ต้องปรับด้วย: (1) half-life ของ OU — reversion ช้า = ลด f , (2) jump risk — crypto มี funding rate war ทำให้ spread กระโดดทันที, (3) max drawdown constraint — Kelly เต็มมักใช้ leverage มากเกินไปสำหรับ live trading

Part VI: Time Series & Stochastic Calculus → Stat Arb

§14: GBM & SDE — รากฐานของ OU

GBM

$$dS = \mu S dt + \sigma S dW_t$$

→

Ch 2 §2.1–2.3 (Stochastic Calculus): Brownian Motion, dW , SDE — เบื้องหลัง GBM

Ch 2 §2.5: preview ว่า OU Process คือ mean-reverting SDE ต่างจาก GBM ตรงไหน

§14: Ito's Lemma — ขั้นตอนสู่ OU Solution

Ito's Lemma

$$df = \frac{\partial f}{\partial t} dt + \frac{\partial f}{\partial S} dS + \frac{1}{2} \frac{\partial^2 f}{\partial S^2} (dS)^2$$

→

Ch 2 §2.4: Ito's Lemma เป็น chain rule สำหรับ stochastic world — ใช้หา $d\varepsilon$ จาก OU SDE

Ch 3 §3.2 (OU): solution $\varepsilon_t = \theta + (\varepsilon_0 - \theta)e^{-\kappa t} + \dots$ มาจาก Ito ที่ apply กับ OU SDE

§12: GARCH — Vol-Adjusted Z-score

GARCH(1,1)

$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$$

→

Ch 7 §7.2–7.3 (GARCH on Residuals): GARCH ประมาณ σ_t ของ spread residuals แล้วสร้าง GARCH Z-score = ε_t / σ_t

Ch 7 §7.4: when to use GARCH vs constant σ — ถ้า spread vol volatile ใช้ GARCH

Ch 7 §7.6: estimate ω, α, β_G จากข้อมูลจริงด้วย MLE

§13: OU Process — แกนหลักของ Stat Arb ทั้งเล่ม

OU SDE

$$d\varepsilon = \kappa(\theta - \varepsilon) dt + \sigma dW$$

→

Ch 3 §3.1–3.6: parameters κ (speed), θ (mean), σ (vol) — calibration จาก AR(1) regression

Ch 3 §3.3: Half-life = $\ln(2)/\kappa$ — ตัวเลขสำคัญที่สุดสำหรับ trader

Ch 9 (Regime-Switching): 3-state Markov — κ, θ, σ ต่างกันในแต่ละ regime

Ch 8 (Jump-Diffusion): OU + Poisson jumps — จัดการ fat tail ใน crypto

 Quant Insight: OU คือ mean-reverting SDE

OU ต่างจาก GBM ตรงที่มี drift term $\kappa(\theta - x)$ ที่ "ดึง" x กลับหาค่าเฉลี่ย θ เสมอ — ยิ่ง x ห่างจาก θ มาก drift กลับยิ่งแรง นี่คือ mathematical guarantee ของ mean reversion ที่ทำให้ Stat Arb มีกำไร

Part VII: Black-Scholes & Monte Carlo → Stat Arb

§15: Black-Scholes — IV Surface

BS Call

$$C = SN(d_1) - Ke^{-rT}N(d_2)$$

→

Ch 18 §18.1 (Options Overlay): BS เป็น pricing model สำหรับ PCP arbitrage

Ch 22 §22.1: IV surface สร้างโดย invert BS ด้วย Newton-Raphson ทุก strike

Ch 22 §22.4: Cross-venue IV Stat Arb — IV(Deribit) vs IV(Bybit) ควร converge

§16: Greeks & Delta Hedge

Delta-neutral

$$\text{Portfolio} = \text{Option} - \Delta \cdot S$$

→

Ch 18 §18.6 (Options Overlay): delta hedge options spread เพื่อ isolate IV arb signal

Ch 22 §22.3: IV Skew Arb ใช้ delta-neutral Risk Reversal — long call + short put ด้วย equal delta

§17: Monte Carlo — Scenario Generation

MC Simulation

$$S_T = S_0 e^{(r - \sigma^2/2)T + \sigma\sqrt{T}Z}$$

→

Ch 20 §20.4 (Risk Mgmt): Black Swan scenarios — simulate extreme spread paths

Ch 24 §24.1–24.3 (Case Studies): LTCM, Quant Quake — ทำความเข้าใจว่า model พังอย่างไรด้วย scenario thinking

Ch 8 §8.3 (Jump-Diffusion): Merton model = GBM + Poisson jumps — MC simulate paths ที่มี jump

⚠ Model Risk: BS ใน Crypto Options

BS สมมติ constant σ แต่ BTC options มี IV smile ชัดมาก (OTM puts แพงกว่า ATM) — นั่นคือเหตุผลที่ Ch 22 trade IV skew ไม่ใช่แค่ level และ Ch 23 ใช้ t-distribution แทน Normal สำหรับ residual modeling

Reverse Lookup: Stat Arb Chapter → Math Background

Stat Arb Chapter	หัวข้อ	Math Parts ที่ต้องการ
Ch 0	Introduction	—
Ch 1	Synthetic Process ($\varepsilon = P_A - \beta \cdot P_B$)	Part I (log return), Part IV (OLS β , residuals)
Ch 2	Stochastic Calculus (BM, Ito, SDE)	Part VI (GBM, Ito's Lemma, dW)
Ch 3	OU Process (κ, θ, σ , half-life, AR(1))	Part VI (OU SDE, stochastic processes)
Ch 4	Hedge Ratio β (OLS, Kalman, lookback)	Part IV (OLS regression)
Ch 5	Cointegration (Engle-Granger, Johansen, VECM)	Part IV (regression, residuals), Part VI (stationarity)
Ch 6	Hurst Exponent & Stationarity (ADF, KPSS)	Part II (statistics, variance), Part VI (time series)
Ch 7	GARCH on Residuals	Part II (variance), Part VI (GARCH, EWMA)
Ch 8	Jump-Diffusion OU	Part II (fat tails), Part VI (OU, GBM)
Ch 9	Regime-Switching OU (3-state Markov)	Part VI (OU process, stochastic)
Ch 10	Z-score & Robust Statistics (MAD)	Part II (mean, variance, Z-score, robust stats)
Ch 11	Entry/Exit State Machine	Part II (Z-score thresholds)
Ch 12	Position Sizing (Kelly, half-life)	Part II (variance), Part V (Kelly = optimization), Part VI (half-life from OU)
Ch 13	Perpetual Basis (Funding Rate, crypto)	Part I (compound growth, cost of carry)
Ch 14	Cross-venue Execution	—
Ch 15	Dynamic β via Kalman Filter	Part IV (OLS β as state), Part V (optimization)
Ch 16	Multi-leg Portfolio (MVO, Σ)	Part IV (covariance matrix), Part V (MVO)
Ch 17	Commodity Basis (Calendar Spread)	Part I (cost of carry, e^{rT})

Stat Arb Chapter	หัวข้อ	Math Parts ที่ต้องการ
Ch 18	Options Overlay (PCP, IV Surface, Delta Hedge)	Part I (PCP), Part III (Greeks), Part VII (BS, delta hedge)
Ch 19	Cost Analysis & Edge	Part I (% change), Part II (breakeven statistics)
Ch 20	Risk Management (VaR, Drawdown)	Part II (fat tails, distributions), Part IV (Σ), Part V (LP constraints)
Ch 21	Spot $\leftrightarrow$ CFD Swap Arb (MT5)	Part I (cost of carry)
Ch 22	Options-Based Stat Arb (IV Skew, Vol Risk Premium)	Part III (Greeks, Vega), Part VII (BS, IV, MC)
Ch 23	Kalman Filter & t-Distribution	Part II (fat tails, t-dist), Part IV (OLS $\rightarrow$ Kalman state)
Ch 24	Case Studies (LTCM, Quant Quake, Amaranth)	Part II (correlation breakdown), Part VII (MC scenario)

Core Pipeline: จาก Raw Price → Stat Arb Trade

1 Data — แปลง raw prices เป็น log prices

Math: Part I §1 $\ln P_t$ | SA: Ch 1

2 Hedge Ratio — OLS regression หา β และ construct spread ε

Math: Part IV §8 OLS | SA: Ch 4 → Ch 1

3 Stationarity Test — ADF/KPSS/Hurst เช็คว่า ε mean-reverts

Math: Part VI (stationarity), Part II (variance) | SA: Ch 5–6

4 OU Calibration — หา κ, θ, σ และคำนวณ half-life

Math: Part VI §13 OU SDE | SA: Ch 3

5 Vol Model — GARCH หรือ rolling σ สร้าง vol-adjusted Z-score

Math: Part VI §12 GARCH, Part II §3 variance | SA: Ch 7, Ch 10

6 Regime Filter — Hamilton filter เทรดเฉพาะ Normal Regime

Math: Part VI (stochastic processes) | SA: Ch 9

7 Signal & State Machine — $Z > \text{threshold} \rightarrow \text{entry}, Z \rightarrow 0 \rightarrow \text{exit}$

Math: Part II §5 Z-score | SA: Ch 10–11

8 Position Sizing — Kelly ปรับด้วย half-life และ jump risk

Math: Part V §11 Kelly, Part VI §13 half-life | SA: Ch 12

9 Risk Check — VaR/CVaR, drawdown limit, Black Swan

Math: Part II (fat tails), Part IV (Σ) | SA: Ch 20

Bridge Chapter — คณิตศาสตร์สำหรับ Options & Statistical Arbitrage

Formula Quick Reference

สูตรอ้างอิงฉบับย่อ — คณิตศาสตร์สำหรับ Options

ครอบคลุมบทที่ 1-16 | ใช้เป็น cheat sheet ขณะอ่าน

ส่วนที่ I — เครื่องมือพื้นฐาน (บท 1-3)

% Change และ Asymmetry

% Change

$$\% \Delta = \frac{\text{ใหม่} - \text{เก่า}}{\text{เก่า}} \times 100$$

Recovery needed after $-x\%$

$$r = \frac{x}{100 - x} \times 100\%$$

e.g. ลด 50% → ต้องขึ้น 100%

Logarithm และ e

$$\ln(ab) = \ln a + \ln b \quad \ln(a^n) = n \ln a$$

Log Return

$$r = \ln\left(\frac{S_1}{S_0}\right) = \ln S_1 - \ln S_0$$

บวกข้ามเวลาได้, สมมาตร, เป็น Normal ได้

Options Payoff

$$\text{Long Call} = \max(0, S - K) - C$$

$$\text{Long Put} = \max(0, K - S) - P$$

Put-Call Parity

$$C + Ke^{-rT} = P + S$$

Present Value / Future Value

$$PV = FV \cdot e^{-rT} \quad FV = PV \cdot e^{rT}$$

PV ใน Put-Call Parity

$$PV(K) = Ke^{-rT}$$

ส่วนที่ II — สถิติและความน่าจะเป็น (บท 4–6)

Variance และ Volatility

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{n} \quad \sigma = \sqrt{\sigma^2}$$

Annualized Vol

$$\sigma_{\text{annual}} = \sigma_{\text{daily}} \times \sqrt{252}$$

Covariance / Correlation

$$\text{Cov}(X, Y) = \frac{\sum (x_i - \mu_x)(y_i - \mu_y)}{n}$$

$$\rho = \frac{\text{Cov}(X, Y)}{\sigma_x \sigma_y} \in [-1, +1]$$

Expected Value

$$E[X] = \sum_i x_i P(x_i)$$

$$\text{Var}(X) = E[X^2] - (E[X])^2$$

Probability

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Conditional / Bayes

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B|A)P(A)}{P(B)}$$

Combinations

$$C(n, k) = \binom{n}{k} = \frac{n!}{k! (n - k)!}$$

Distributions

Binomial

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

Normal PDF

$$f(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Z-Score / CDF

$$Z = \frac{x - \mu}{\sigma} \quad N(d) = P(Z \leq d)$$

Lognormal

$$\ln(S) \sim \mathcal{N}(\mu, \sigma^2) \Rightarrow S \sim \text{Lognormal}$$

ส่วนที่ III — แคลคูลัส (บท 7)

Derivatives

$$\frac{d}{dx}(x^n) = nx^{n-1} \qquad \frac{d}{dx}(e^{ax}) = ae^{ax}$$

$$\frac{d}{dx}[\ln(x)] = \frac{1}{x} \qquad \frac{d}{dx}[f \cdot g] = f'g + fg'$$

Integration

$$\int x^n dx = \frac{x^{n+1}}{n+1} + C \qquad \int e^x dx = e^x + C$$

Option price as integral

$$C = e^{-rT} \int_0^\infty \max(0, S - K) \cdot f(S) dS$$

Greeks (Partial Derivatives of C)

Greek	Formula	Meaning
Δ	$\partial C / \partial S = N(d_1)$	Rate vs S
Γ	$\partial^2 C / \partial S^2$	Curvature
Θ	$-\partial C / \partial T$	Time decay
ν	$\partial C / \partial \sigma$	Vol sensitivity
ρ	$\partial C / \partial r$	Rate sensitivity

Taylor Expansion (P&L Attribution)

$$\Delta V \approx \Delta \cdot \Delta S + \frac{1}{2} \Gamma (\Delta S)^2 + \Theta \cdot \Delta t + \nu \cdot \Delta \sigma$$

Directional + Convexity + Time Decay + Vol P&L

ส่วนที่ IV — Linear Algebra + Regression (บท 8–9)

Portfolio Variance

$$\sigma_p^2 = \mathbf{w}^\top \Sigma \mathbf{w}$$

$\mathbf{w}$ = weight vector, Σ = covariance matrix

2-Asset

$$\sigma_p^2 = w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 + 2w_1 w_2 \text{Cov}_{12}$$

Matrix Inverse (2x2)

$$A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

OLS Regression

$$\beta = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

Matrix OLS

$$\hat{\beta} = (X^\top X)^{-1} X^\top \mathbf{y}$$

t-statistic

$$t = \frac{\hat{\beta}}{\text{se}(\hat{\beta})} \quad |t| > 2 \Rightarrow \text{significant}$$

R^2 (Goodness of Fit)

$$R^2 = 1 - \frac{\text{SS}_{\text{res}}}{\text{SS}_{\text{tot}}} \in [0, 1]$$

ส่วนที่ V — Optimization (บท 10–11)

Linear Programming

$$\max \mathbf{c}^\top \mathbf{x} \text{ s.t. } A\mathbf{x} \leq \mathbf{b}, \mathbf{x} \geq 0$$

Optimal always at a corner point of feasible region

Gradient Descent

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \alpha \nabla f(\mathbf{x}_n)$$

α = learning rate, converges for convex f

Lagrange Multipliers

$$\mathcal{L}(x, \lambda) = f(x) - \lambda g(x)$$

Markowitz (equality form)

$$\min \mathbf{w}^\top \Sigma \mathbf{w} \text{ s.t. } \mathbf{1}^\top \mathbf{w} = 1, \boldsymbol{\mu}^\top \mathbf{w} = r^*$$

KKT Conditions

1. Stationarity: $\nabla f + \sum \mu_i \nabla g_i = 0$

2. Primal feasibility: $g_i(\mathbf{x}) \leq 0$

3. Dual feasibility: $\mu_i \geq 0$

4. Complementary slackness: $\mu_i \cdot g_i = 0$

ส่วนที่ VI — Time Series + Stochastic Calculus (บท 12–14)

Volatility Models

EWMA

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$$

GARCH(1,1)

$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$$

$\alpha + \beta < 1 \rightarrow$ mean reversion; long-run $\sigma = \sqrt{\omega / (1 - \alpha - \beta)}$

Newton-Raphson IV Solver

$$\sigma_{n+1} = \sigma_n - \frac{C_{BS}(\sigma_n) - C_{mkt}}{\mathcal{V}(\sigma_n)}$$

Vega = $\partial C / \partial \sigma$; converge in 3–5 iterations

Stochastic Processes

GBM (Geometric Brownian Motion)

$$dS = \mu S dt + \sigma S dW_t$$

Ito's Lemma

$$df = \frac{\partial f}{\partial t} dt + \frac{\partial f}{\partial S} dS + \frac{1}{2} \frac{\partial^2 f}{\partial S^2} (dS)^2$$

$(dW)^2 = dt$ (Ito correction)

Black-Scholes PDE

$$\frac{\partial V}{\partial t} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0$$

Theta + Gamma P&L + Delta P&L = risk-free return

ส่วนที่ VII — Black-Scholes + Monte Carlo (บท 15–16)

Black-Scholes Call / Put

$$C = S_0 N(d_1) - K e^{-rT} N(d_2)$$

$$P = K e^{-rT} N(-d_2) - S_0 N(-d_1)$$

$$d_1 = \frac{\ln(S_0/K) + (r + \sigma^2/2)T}{\sigma\sqrt{T}} \quad d_2 = d_1 - \sigma\sqrt{T}$$

BS with Dividends (Merton)

$$C = S e^{-qT} N(d_1) - K e^{-rT} N(d_2)$$

replace S with $S e^{-qT}$; d_1 uses $(r-q+\sigma^2/2)$

Greeks (Closed Form)

Greek	Call	Put
Δ	$N(d_1)$	$N(d_1) - 1$
Γ	$N'(d_1)/(S\sigma\sqrt{T})$	
ν	$S\sqrt{T} N'(d_1)$	
Θ	$-\frac{SN'(d_1)\sigma}{2\sqrt{T}} - rKe^{-rT}N(d_2)$	similar $+rKe^{-rT}N(-d_2)$
ρ	$Ke^{-rT}N(d_2)$	$-Ke^{-rT}N(-d_2)$

Monte Carlo Pricing

GBM discrete simulation

$$S_{t+\Delta t} = S_t \exp\left[\left(r - \frac{\sigma^2}{2}\right)\Delta t + \sigma\sqrt{\Delta t} Z\right]$$

$Z \sim N(0,1)$ i.i.d.

MC option price

$$\hat{C} = e^{-rT} \frac{1}{N} \sum_{i=1}^N \max(0, S_T^{(i)} - K)$$

Standard Error

$$SE = \frac{\hat{\sigma}_{\text{payoff}}}{\sqrt{N}}$$

4x paths $\rightarrow$ 2x precision ($SE \propto 1/\sqrt{N}$)

Control Variates

$$Y^* = Y_{\text{Asian}} - \hat{\beta}(Y_{\text{Vanilla,MC}} - Y_{\text{Vanilla,BS}})$$

Glossary — คำศัพท์

คณิตศาสตร์สำหรับ Options | English-Thai Reference

เรียงตามหัวข้อ | ครอบคลุมบทที่ 1-16



A — เครื่องมือพื้นฐาน

อัตราผลตอบแทน Return

การเปลี่ยนแปลงของมูลค่า: Simple return $R = (S_1 - S_0)/S_0$ หรือ Log return $r = \ln(S_1/S_0)$

→ บท 1, 3

ผลตอบแทนแบบ log Log Return

$r = \ln(S_1/S_0)$ — สมมาตร, บวกข้ามเวลาได้, เป็น Normal Distribution ได้

→ บท 3.6

มูลค่าปัจจุบัน Present Value (PV)

$PV = FV \cdot e^{-rT}$ — มูลค่าวันนี้ของเงินอนาคต โดย discount ด้วย rate r

→ บท 3.7

ฟังก์ชัน max max() function

$\max(a,b)$ = ค่าที่มากกว่า — หัวใจของ options payoff: $\max(0, S-K)$

→ บท 1.4

ความเท่าเทียมของ Put-Call Put-Call Parity (PCP)

$C + Ke^{-rT} = P + S$ — ความสัมพันธ์ no-arbitrage ระหว่าง Call, Put, หุ้น, Bond

→ บท 2.2

ฟังก์ชันแบ่งช่วง Piecewise Function

ฟังก์ชันที่มีสูตรต่างกันในแต่ละช่วงของ input — ใช้แทน options strategy ทุกประเภท

→ บท 1.6

e (ฐานธรรมชาติ) Euler's number $e \approx 2.718$

ฐานของดอกเบี้ยทบต้นแบบต่อเนื่อง — เป็น "ค่าคงที่" ที่พบทุกที่ใน finance

→ บท 3.4

ลอการิทึมธรรมชาติ Natural Log (ln)

$\ln(x) = y \iff e^y = x$ — inverse ของ e^x ; ใช้คำนวณ log return และใน d_1, d_2 ของ BS

→ บท 3.5

B — สถิติและความน่าจะเป็น

ค่าเฉลี่ย Mean (μ)

ค่ากลางของข้อมูล: $\mu = \sum x_i/n$ — ใช้เป็น drift ของ GBM
→ บท 4.2

ความแปรปรวน Variance (σ^2)

$\sigma^2 = E[(X - \mu)^2]$ — วัดการกระจาย; variance $\propto T$ (เพิ่มตามเวลา)
→ บท 4.3

ความผันผวน Volatility (σ)

σ = std ของ log returns — annualize ด้วย $\sigma_{\text{annual}} = \sigma_{\text{daily}} \times \sqrt{252}$
→ บท 4.3

ความแปรปรวนร่วม Covariance

$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$ — วัดทิศทาง
การเคลื่อนไหวร่วม
→ บท 4.5

สหสัมพันธ์ Correlation (ρ)

$\rho = \text{Cov}/(\sigma_X \sigma_Y) \in [-1, +1]$ — ยิ่งต่ำ
diversification ยิ่งดี
→ บท 4.5

การแจกแจงปกติ Normal Distribution

Bell curve $N(\mu, \sigma^2)$ — BS สมมติว่า log returns เป็น
Normal
→ บท 6.2

Z-score / คะแนนมาตรฐาน Z-Score

$Z = (x - \mu)/\sigma$ — แปลงข้อมูลเป็น standard units; ใช้
ใน $N(d_1), N(d_2)$
→ บท 6.3

การแจกแจงลอกลอนอร์มอล Lognormal Distribution

$\ln(S) \sim \text{Normal} \rightarrow S \sim \text{Lognormal}$ — ราคาหุ้นไม่ติดลบ,
เหมาะกับ BS
→ บท 6.4

หางอ้วน Fat Tails / Leptokurtosis

ตลาดจริงมี extreme events บ่อยกว่า Normal คาด —
ทำให้ OTM options แพงกว่า BS
→ บท 6.6

ทฤษฎีบทลิมิตกลาง Central Limit Theorem (CLT)

ค่าเฉลี่ยของตัวอย่างใหญ่ $\rightarrow$ Normal ไม่ว่า population จะ
มีรูปร่างใด — รองรับ Black-Scholes
→ บท 6.5

C — แคลคูลัส

อนุพันธ์ Derivative

slope ณ จุด = อัตราการเปลี่ยนแปลงทันที: $f'(x) = \lim_{h \rightarrow 0} [f(x+h) - f(x)]/h$

→ บท 7.2

อนุพันธ์ย่อย Partial Derivative

$\partial f / \partial x$ = rate of change กับ x โดย hold ตัวแปรอื่นคงที่ — Greeks ทุกตัวคือ partial derivative ของ C

→ บท 7.6

Delta (Δ) Delta

$\Delta = \partial C / \partial S = N(d_1)$ — อัตราการเปลี่ยนแปลงราคา option ต่อการเปลี่ยน S 1 หน่วย

→ บท 7.7

Gamma (Γ) Gamma

$\Gamma = \partial^2 C / \partial S^2 = \partial \Delta / \partial S$ — ความโค้งของ option; เป็นบวกเสมอ

→ บท 7.8

Theta (Θ) Theta / Time Decay

$\Theta = -\partial C / \partial T$ — มูลค่าที่ลดลงตามเวลา (เป็นลบสำหรับ long option)

→ บท 7.6

Vega (ν) Vega

$\nu = \partial C / \partial \sigma = S \sqrt{T} N'(d_1)$ — ความไวต่อการเปลี่ยน volatility

→ บท 7.6

อนุกรมเทย์เลอร์ Taylor Series

ประมาณ $\Delta V \approx \Delta \cdot \Delta S + \frac{1}{2} \Gamma (\Delta S)^2 + \Theta \cdot \Delta t + \nu \cdot \Delta \sigma$ — ใช้ P&L attribution บน trading desk ทุกวัน

→ บท 7.12

D — Linear Algebra + Optimization

Matrix Covariance Covariance Matrix (Σ)

Matrix ที่เก็บ variance บน diagonal และ covariance นอก diagonal — ต้อง Positive Semi-Definite

→ บท 8.2–8.3

ความแปรปรวนพอร์ต Portfolio Variance ($w^T \Sigma w$)

วัด risk รวมของพอร์ต — ยิ่ง correlation ต่ำ $w^T \Sigma w$ ยิ่งเล็ก (diversification)

→ บท 8.3

ค่าเฉพาะ / เวกเตอร์เฉพาะ Eigenvalue / Eigenvector

$Av = \lambda v$ — eigenvectors = ทิศทางหลักของข้อมูล (PCA), eigenvalues = variance ตามทิศทางนั้น

→ บท 8.5

OLS (กำลังสองน้อยสุด) Ordinary Least Squares

$\hat{\beta} = (X^T X)^{-1} X^T y$ — minimize sum of squared residuals

→ บท 9.1

Beta (ตลาด) Market Beta (β)

$\beta = \text{Cov}(r_{\text{stock}}, r_{\text{mkt}}) / \text{Var}(r_{\text{mkt}})$ — systematic risk, slope ของ regression

→ บท 9.1

Lagrange Multiplier Lagrange Multiplier (λ)

เทคนิค optimize $f(x)$ ภายใต้ constraint $g(x)=0$ — λ = shadow price ของ constraint

→ บท 11.3

เงื่อนไข KKT KKT Conditions

Lagrange สำหรับ inequality constraints — ใช้ใน Markowitz long-only portfolio

→ บท 11.4

E — Time Series + Stochastic Calculus

EWMA (ค่าเฉลี่ยเคลื่อนที่แบบถ่วงน้ำหนัก)

หน้า) **Exponentially Weighted Moving Average**

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2 - \lambda = 0.94 \text{ (RiskMetrics daily)}$$

→ บท 12.4

GARCH **Generalized ARCH**

$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2 - \text{forecast vol พร้อม mean reversion}$$

→ บท 12.5

Implied Volatility (IV) **Implied Volatility**

σ ที่ทำให้ $BS(\sigma) = \text{ราคาตลาด}$ — solve ด้วย Newton-Raphson; ตลาด quote ใน IV

→ บท 13.2

Vol Smile / Skew **Volatility Smile / Skew**

IV $\neq$ ค่าเดียวกันทุก strike — หลักฐานว่า fat tails มีจริง และ BS ไม่ครอบคลุมทุกกรณี

→ บท 15.4

GBM (Geometric Brownian Motion) **Geometric Brownian Motion**

$$dS = \mu S dt + \sigma S dW - \text{สมมติฐานของ Black-Scholes สำหรับการเคลื่อนที่ของราคา}$$

→ บท 14.4

Ito's Lemma **Ito's Lemma**

Chain rule สำหรับ stochastic processes — ใช้พิสูจน์ว่า $\ln(S) \sim \text{Normal}$; รากฐานของ BS PDE

→ บท 14.5

Brownian Motion / Wiener Process **Brownian Motion (W_t)**

Random walk ต่อเนื่อง: $dW = \varepsilon \sqrt{dt}$, $\varepsilon \sim N(0,1)$ — $\text{Var}(W_T) = T$ (variance $\propto$ time)

→ บท 14.3

F — Black-Scholes + Monte Carlo

สูตร Black-Scholes [Black-Scholes Formula](#)

$C = S_0 N(d_1) - K e^{-rT} N(d_2)$ — ราคา European Call ภายใต้สมมติ lognormal, constant σ

→ บท 15.1

$N(d_1)$, $N(d_2)$ [Risk-Neutral Probabilities](#)

$N(d_2) = P(S_T > K \mid \text{risk-neutral})$; $N(d_1) = N(d_2)$ ปรับ Ito — ทั้งคู่เป็น CDF ของ Normal

→ บท 15.2b

Monte Carlo Simulation [Monte Carlo](#)

จำลอง $S(T)$ หลาย paths → เปลี่ยน payoff → discount → ราคา option ใช้กับ exotic options

→ บท 16.1

Standard Error ของ MC [Standard Error \(SE\)](#)

$SE = \sigma_{\text{payoff}} / \sqrt{N}$ — ลด SE 2 เท่า ต้องเพิ่ม paths 4 เท่า

→ บท 16.4b

Control Variates [Control Variates](#)

ใช้ราคาที่รู้แน่ (vanilla BS) ปรับ MC estimate → ลด variance ได้ 70–90%

→ บท 16.4d

Antithetic Variates [Antithetic Variates](#)

ใช้ $(Z, -Z)$ คู่กัน — 2 paths ต่อการสุ่ม 1 ครั้ง ลด SE ได้โดยไม่เพิ่ม random draws

→ บท 16.4c

Risk-Neutral Pricing [Risk-Neutral Measure \(Q\)](#)

ตั้งราคา option ราวกับว่าทุกคน risk-neutral — ใช้ $p^* = (e^{r\Delta t} - d)/(u - d)$ ใน binomial tree

→ บท 14.2

BS PDE [Black-Scholes Partial Differential Equation](#)

$\Theta + \frac{1}{2}\sigma^2 S^2 \Gamma + rS\Delta - rV = 0$ — Theta + Gamma P&L = risk-free return

→ บท 14.6–14.7

G — Statistical Arbitrage Key Terms

Cointegration [Cointegration](#)

สองซีรีส์ที่ non-stationary แต่ linear combination ของมัน stationary — เช่น $P_A - \beta \cdot P_B = \varepsilon$ ที่ mean-reverts
Engle-Granger test: ADF บน residuals ε

→ SA Ch 5

Ornstein-Uhlenbeck (OU) [OU Process](#)

$d\varepsilon = \kappa(\theta - \varepsilon)dt + \sigma dW$ — mean-reverting SDE; κ = speed, θ = mean, σ = vol ใช้เป็น model หลักของ spread ใน Stat Arb

→ SA Ch 3 | Math Part VI

ครึ่งชีวิต [Half-life](#)

เวลาที่ spread กลับสู่ครึ่งหนึ่งของระยะห่างจาก mean:
 $HL = \ln 2 / \kappa$ — ถ้า HL สั้น = mean reversion เร็ว = เทรดได้บ่อยกว่า

→ SA Ch 3.3

Spread / Hedge Ratio [Spread & Hedge Ratio \$\beta\$](#)

Spread = $P_A - \beta \cdot P_B$; Hedge Ratio β = จำนวน units ของ B ที่ต้องขาย/ซื้อต่อ 1 unit ของ A หา β ด้วย OLS regression

→ SA Ch 1, 4

VaR / CVaR [Value at Risk / Conditional VaR](#)

VaR($\alpha\%$): loss ที่จะไม่เกินด้วยความน่าจะเป็น $\alpha\%$ CVaR = $E[\text{loss} | \text{loss} > \text{VaR}]$ — วัด tail risk ได้ดีกว่า VaR เพราะ average ไม่แค่ threshold

→ SA Ch 20.3 | Math Part II

Sharpe Ratio / Info Ratio [Sharpe / Information Ratio](#)

Sharpe = $(\mu - r_f) / \sigma$ — ผลตอบแทนส่วนเกินต่อความเสี่ยง 1 หน่วย; Information Ratio = $\alpha / \sigma_{\text{tracking}}$ — ใช้ประเมิน strategy quality

→ SA Ch 19

Regime / Regime-Switching [Regime-Switching](#)

ตลาดมีหลาย "สภาวะ" (regime) — Normal, Trending, Stressed — แต่ละ regime มี κ, σ ต่างกัน Hamilton Filter ตรวจ regime ด้วย Hidden Markov Model

→ SA Ch 9

ADF Test [Augmented Dickey-Fuller Test](#)

ทดสอบ stationarity: H_0 = unit root (non-stationary); ถ้า p-value < 0.05 = reject H_0 = series stationary = mean-reverting

→ SA Ch 5.2, 6.3 | Math Part VI