

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part IV: Linear Algebra & Regression (v2)

บทที่ 8–9: Vectors · Matrices · Portfolio Variance · Eigenvalues · Regression · Beta

เรียนแบบ 3 ชั้น: อุปมา → เหตุ → ผล → ตัวเลขจริง

บทที่ 8: Linear Algebra — "จัดการหลายตัวแปรพร้อมกัน"

เมื่อ portfolio มีหุ้น 50 ตัว, Options 20 สัญญา จัดการทีละตัวไม่ไหว — **Matrix** ทำให้คำนวณ risk ทั้งหมดพร้อมกันได้ในสูตรเดียว

8.1 Vectors — รายการตัวเลขเรียงกัน

🔍 **อุปมา: รายการช้อปปิ้ง**

ไปซูเปอร์มาร์เก็ต ซื้อ: ข้าว 2 kg, ไก่ 1 kg, ผัก 0.5 kg

Vector ของปริมาณ = [2, 1, 0.5]

Vector ของราคา = [30, 80, 20] (บาท/kg)

ยอดรวม = $2 \times 30 + 1 \times 80 + 0.5 \times 20 = 60 + 80 + 10 = \text{฿}150$

นี่คือ **Dot Product** = $\sum (\text{ปริมาณ} \times \text{ราคา})$ — เป็นสูตรเดียวกับ Portfolio Return!

$$\mathbf{w} = [0.3, 0.5, 0.2] \quad \mathbf{r} = [0.05, -0.02, 0.08]$$

$$R_p = \mathbf{w} \cdot \mathbf{r} = \sum_i w_i r_i = 0.3(0.05) + 0.5(-0.02) + 0.2(0.08) = \mathbf{2.1\%}$$

🔍 **ทำไม Dot Product จึงเท่ากับ Portfolio Return?**

Portfolio Return = "ผลรวมของ return แต่ละหุ้น ถ่วงน้ำหนักด้วยสัดส่วนที่ถือ"

$= w_1 r_1 + w_2 r_2 + w_3 r_3 = \text{Dot Product } \mathbf{w} \cdot \mathbf{r}$

Dot Product คือ weighted sum — ตรงกับนิยาม portfolio return ทุกประการ

เชื่อมกับ Options — Portfolio Delta

ถือ Call K=100 จำนวน 2 contracts (Delta 0.6), Short Put K=95 จำนวน 1 contract (Delta -0.4)

Position vector = [2, -1], Delta vector = [0.6, -0.4]

Portfolio Delta = $2(0.6) + (-1)(-0.4) = 1.2 + 0.4 = \mathbf{1.6}$

8.2 Matrices — ตารางสัมพันธ์ระหว่างทุกคู่

🔍 อุปมา: ตารางระยะทางระหว่างเมือง

ลองนึกตารางระยะทาง กทม.-เชียงใหม่-ภูเก็ต-ขอนแก่น (4x4 table)

แต่ละช่อง $[i][j]$ = ระยะทางจากเมือง i ไปเมือง j

Diagonal = 0 (ห่างตัวเอง = 0), สมมาตร $[i][j] = [j][i]$

Correlation Matrix ทำงานเหมือนกัน:

$[i][j]$ = correlation ระหว่างหุ้น i กับหุ้น j , Diagonal = 1.0 (corr กับตัวเอง = 1)

$$\mathbf{C} = \begin{pmatrix} 1.0 & 0.7 & 0.2 \\ 0.7 & 1.0 & 0.3 \\ 0.2 & 0.3 & 1.0 \end{pmatrix} \begin{matrix} \leftarrow A \\ \leftarrow B \\ \leftarrow C \end{matrix}$$

Matrix Multiplication: $A(m \times n) \times B(n \times p) = C(m \times p)$

🔍 ทำไม Matrix คุณแบบนี้?

แต่ละ entry ของผลลัพธ์ $C[i][j]$ = Dot Product ของแถว i ของ A กับคอลัมน์ j ของ B

เหมือนถามว่า "แถว i มองเห็น' คอลัมน์ j แค่ไหน"

เป็น generalization ของ dot product สู่ multi-dimensional calculation

เชื่อมกับ Options — Covariance Matrix

Covariance Matrix (Σ) เก็บ σ^2 ทุกตัว + $\text{Cov}(i,j)$ ทุกคู่ในตารางเดียว

ใช้คำนวณ Portfolio Variance ของหุ้น/Options ที่ตัวก็ได้ในสูตรเดียว

8.3 Portfolio Variance ในรูป Matrix — $\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w}$

🔍 อุปมา: ผสมสีทาบ้าน

ผสมสีแดง 60% + สีน้ำเงิน 40% — ความเข้มของสีผสม ขึ้นกับ:

1. ความเข้มของแต่ละสี (variance ของแต่ละหุ้น)
2. ว่าสีผสมกันเป็นยังไง (covariance ระหว่างหุ้น)

ถ้าสีสองสีผสมกันได้ดี → สีผสมสว่าง (diversification ดี)

ถ้าสีสองสีตีกัน → สีผสมมืด (diversification ไม่ช่วย)

$$\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w}$$

🔍 ทำไม $w^T \Sigma w$?

ขยาย $\text{Var}(w_1 X_1 + w_2 X_2) = w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 + 2w_1 w_2 \text{Cov}(X_1, X_2)$

เขียนเป็น matrix: $[w_1 \ w_2] \times [\sigma_1^2 \ \text{Cov}; \ \text{Cov} \ \sigma_2^2] \times [w_1; w_2] = w^T \Sigma w$ ✓

สูตร matrix form compact กว่า และขยายเป็น n หุ่นได้ทันทีโดยไม่ต้องเขียนใหม่

ตัวอย่าง: หุ่น 2 ตัว, $w = [0.6, 0.4]$

1 Covariance Matrix: $\Sigma = [0.04 \ 0.01; 0.01 \ 0.09]$

($\sigma_1 = 20\% \rightarrow \sigma_1^2 = 0.04$, $\sigma_2 = 30\% \rightarrow \sigma_2^2 = 0.09$, $\text{Cov} = 0.01$)

2 $\Sigma w = [0.04 \times 0.6 + 0.01 \times 0.4; 0.01 \times 0.6 + 0.09 \times 0.4] = [0.028; 0.042]$

3 $w^T (\Sigma w) = 0.6 \times 0.028 + 0.4 \times 0.042 = 0.0168 + 0.0168 = \mathbf{0.0336}$

4 $\sigma_p = \sqrt{0.0336} = \mathbf{18.3\%}$ (ต่ำกว่า $\sigma_1=20\%$ และ $\sigma_2=30\%$ ทั้งคู่!)

สังเกต: Diversification ทำงาน!

$\sigma_1=20\%$, $\sigma_2=30\%$ แต่ Portfolio $\sigma=18.3\%$ — ต่ำกว่าทั้งคู่!

เพราะ Covariance ต่ำ (0.01) → หุ่นไม่ได้เคลื่อนไหวพร้อมกันตลอด

ถ้า $\text{Cov} = 0$: $\sigma_p = \sqrt{(0.6^2 \times 0.04 + 0.4^2 \times 0.09)} = \sqrt{(0.0144 + 0.0144)} = 17.0\%$ (ต่ำกว่าอีก)



Quant Desk: $w^T \Sigma w$ ใช้ทุกวันใน Risk Parity และ Vol Targeting

นอกจาก Markowitz min-variance แล้ว quant funds ใช้ $w^T \Sigma w$ เพื่อ:

- **Risk Parity:** จัด w ให้แต่ละสินทรัพย์ contribute risk เท่ากัน (แทนที่จะให้ weight เท่ากัน)
- **Vol Targeting:** scale w ทั้งพอร์ตให้ $\sqrt{w^T \Sigma w} = \text{target_vol} = 10\%$ ต่อปีเสมอ
- **Greeks aggregation:** delta vector $\times \Sigma \times$ delta vector = portfolio P&L variance จาก factor moves

Σ matrix ต้อง update ทุกวัน — ใช้ EWMA หรือ DCC (Dynamic Conditional Correlation) แทน sample Σ คงที่

8.4 Matrix Inverse & การแก้ระบบ $Ax=b$ — เมทริกซ์ผกผัน

🔍 อุปมา: การ "หาร" ของเมทริกซ์

ในตัวเลขรรวม ถ้า $5x = 20$ เราหารด้วย 5 $\rightarrow x = 20/5 = 4$

แต่เมทริกซ์ "หาร" ตรง ๆ ไม่ได้ — เราใช้การ คูณด้วย inverse (A^{-1}) แทน:

ถ้า $Ax = b \rightarrow x = A^{-1}b$ (เหมือน $x = b \div A$)

ประโยชน์: แก่ระบบสมการหลายตัวแปรพร้อมกัน — แทนที่จะแก้ทีละสมการ เขียนเป็น $Ax=b$ แล้วคูณ A^{-1} ครั้งเดียวจบ

$$A^{-1}A = I \quad A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}, \quad \det(A) = ad - bc$$

$$A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

ตัวอย่างคำนวณ: หา inverse ของ $A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$

1 หา determinant: $\det = ad - bc = (2)(3) - (1)(1) = 6 - 1 = 5 (\neq 0 \rightarrow \text{invertible})$

2 สลับ diagonal และใส่ลบ: $[d \ -b; -c \ a] = \begin{bmatrix} 3 & -1 \\ -1 & 2 \end{bmatrix}$

3 หารด้วย det: $A^{-1} = 1/5 \times \begin{bmatrix} 3 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 0.6 & -0.2 \\ -0.2 & 0.4 \end{bmatrix}$

4 ตรวจสอบ $A^{-1}A = I$:

แถว 1: $(0.6 \times 2 + -0.2 \times 1), (0.6 \times 1 + -0.2 \times 3) = (1.2 - 0.2), (0.6 - 0.6) = (1, 0)$

แถว 2: $(-0.2 \times 2 + 0.4 \times 1), (-0.2 \times 1 + 0.4 \times 3) = (-0.4 + 0.4), (-0.2 + 1.2) = (0, 1)$

$\rightarrow \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I \checkmark$

เชื่อมกับ Portfolio — ทำไม inverse จึงสำคัญ

- **Markowitz optimal weights:** น้ำหนัก portfolio ที่ดีที่สุด w^* ต้องใช้ Σ^{-1} (inverse ของ covariance matrix) — $w^* \propto \Sigma^{-1}\mu$
- **Regression:** สูตร OLS $\beta = (X^T X)^{-1} X^T y$ ก็ต้อง invert matrix ($X^T X$)

ระวัง singular matrix: ถ้า $\det = 0 \rightarrow$ matrix ไม่มี inverse $\rightarrow$ ไม่มีคำตอบเดียวที่แน่นอน

สาเหตุในโลกจริง: ข้อมูลซ้ำซ้อน/collinear (เช่น สองหุ้นเคลื่อนไหวเหมือนกันเป๊ะ $\rho=1$) $\rightarrow$ แถวหนึ่ง "เล่าเรื่องเดียวกัน" กับอีกแถว $\rightarrow$ ระบบแยกไม่ออก

โจทย์ฝึก §8.4

ฝึก. หา inverse ของ $A = \begin{bmatrix} 4 & 3 \\ 2 & 1 \end{bmatrix}$ (ถ้ามี) แล้วตรวจว่า $\det \neq 0$ หรือไม่

► ดูเฉลย

8.5 Eigenvalues — ทิศทางหลักของข้อมูล

🔍 **อุปมา:** รูปร่างของก้อนเมฆ

ก้อนเมฆมีรูปร่างรี ยาวไปทางทิศตะวันออก-ตะวันตก

Eigenvector หลัก = ทิศทาง E-W (ที่ขยายออกมากที่สุด)

Eigenvalue = ขนาดที่ขยาย (ยาวแค่ไหน)

Covariance matrix ของ portfolio ก็มี "รูปร่าง" — Eigenvalue บอกว่ามิติไหนสำคัญ

$$A\mathbf{v} = \lambda\mathbf{v} \quad \mathbf{v} = \text{eigenvector}, \lambda = \text{eigenvalue}$$

ตัวอย่างคำนวณ: หา eigenvalues ของ $\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$

1 ตั้ง characteristic equation: $\det(\Sigma - \lambda I) = 0$
 $\Sigma - \lambda I = \begin{bmatrix} 4-\lambda & 2 \\ 2 & 3-\lambda \end{bmatrix}$

2 หา determinant = 0: $(4-\lambda)(3-\lambda) - (2)(2) = 0$
 $= 12 - 4\lambda - 3\lambda + \lambda^2 - 4 = \lambda^2 - 7\lambda + 8 = 0$

3 แก้สมการกำลังสอง: $\lambda = (7 \pm \sqrt{49-32})/2 = (7 \pm \sqrt{17})/2$
 $\sqrt{17} \approx 4.123 \rightarrow \lambda_1 = (7+4.123)/2 \approx \mathbf{5.56}, \lambda_2 = (7-4.123)/2 \approx \mathbf{1.44}$

4 หา eigenvector ของ $\lambda_1 \approx 5.56$: แก้ $(\Sigma - \lambda_1 I)v = 0$
 $(4 - 5.56)v_1 + 2v_2 = 0 \rightarrow -1.56 v_1 + 2 v_2 = 0 \rightarrow v_2 = 0.78 v_1$
 เลือก $v_1 = 1 \rightarrow \mathbf{v \approx [1, 0.78]}$ (ทิศทางหลักที่ข้อมูลกระจายมากที่สุด)

PCA Demo — Variance Explained จาก eigenvalue

สัดส่วน variance ที่ PC แต่ละตัวอธิบาย = $\lambda_i / \Sigma \lambda$

จากตัวอย่าง: $\lambda_1 + \lambda_2 = 5.56 + 1.44 = 7$ (= trace = 4+3 ตามคาด)

- PC1: $\lambda_1/(\lambda_1 + \lambda_2) = 5.56/7 \approx \mathbf{79\%}$ ← PC แรกอธิบาย 79% ของ variance ทั้งหมด!
- PC2: $\lambda_2/(\lambda_1 + \lambda_2) = 1.44/7 \approx 21\%$

เชื่อมกับ Vol Surface: นำตรรกะ λ -ratio นี้ไปใช้กับ covariance matrix ของ IV ทั้ง surface:

- PC1 = parallel shift (level) — IV ทั้ง surface ขึ้น/ลงพร้อมกัน (eigenvalue ใหญ่สุด)
- PC2 = slope/skew — ปลายหนึ่งขึ้น อีกปลายลง
- PC3 = curvature — กลางโป่ง/บุ๋ม

ผลรวม $\lambda_1 + \lambda_2 + \lambda_3$ มักได้ $\approx 99\%$ ของ $\Sigma \lambda \rightarrow$ "3 PC อธิบาย $\sim 99\%$ " — ตอนนี้คำกล่าวนี้นี้มีที่มาชัดเจนแล้วจาก สัดส่วน eigenvalue

โจทย์ฝึก §8.5

ฝึก. หา eigenvalues ของ $\Sigma = \begin{bmatrix} 5 & 1 \\ 1 & 5 \end{bmatrix}$

► ดูเฉลย

เชื่อมกับ Options — PCA ลด Dimension

PCA (Principal Component Analysis) ใช้ eigenvalues ของ Σ :

- **Yield Curve**: 3 PC แรกอธิบาย 99% (level, slope, curvature)
- **Volatility Surface**: ลด dimension จาก 100+ strikes/expiry เหลือ 5–10 factors
- **Eigenvalue ใหญ่** = ทิศทางที่ข้อมูลกระจายมาก = risk factor สำคัญ

8.6 Positive Definite — Covariance Matrix ต้อง Valid

ทำไม Covariance Matrix ต้อง Positive Semi-Definite?

$\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w}$ ต้อง ≥ 0 เสมอ (variance เป็นลบไม่ได้ในโลกจริง!)

ถ้าสร้าง correlation matrix จากข้อมูลผิดพลาด อาจได้ matrix ที่ $\mathbf{x}^T \mathbf{A} \mathbf{x} < 0$ สำหรับบาง $\mathbf{x}$

→ แปลว่า "portfolio บางชุดมี variance ลบ" → **เป็นไปได้ไม่ได้!** → ต้อง fix matrix ก่อนใช้

สรุปบทที่ 8

- ✓ Vector = รายการตัวเลข, Dot Product = weighted sum = Portfolio Return
- ✓ Matrix = ตารางสัมพันธ์ทุกคู่ → Covariance Matrix
- ✓ $\sigma_p^2 = \mathbf{w}^T \Sigma \mathbf{w}$ = สูตร Portfolio Variance ที่ใช้ได้กับ n หุ้นทันที
- ✓ Eigenvalues → PCA → ลด dimension ของ yield curve / vol surface
- ✓ Covariance Matrix ต้อง PSD → variance ไม่ติดลบ

บทที่ 9: Regression & Curve Fitting — "หา Beta และ Vol Surface"

Regression = "หาเส้นที่ fit ข้อมูลดีที่สุด" — ใช้หา Beta ของหุ้น, Hedge Ratio, และ fit Volatility Surface

9.1 Simple Linear Regression

🔍 อุปมา: เส้นที่ผ่านกลุ่มจุด

มีจุดข้อมูล 100 จุด (return ตลาด vs return หุ้น) — กระจายไปทั่ว
เราอยากหาเส้นตรงที่ "ใกล้จุดทุกจุดมากที่สุด"

"ใกล้ที่สุด" = ผลรวมของ (ระยะห่างแนวตั้ง)² น้อยที่สุด (Least Squares)
เส้นนั้นคือ Regression Line: $y = \alpha + \beta x$

มีข้อมูล (x_i, y_i)

→

หา $\beta = \text{Cov}(X, Y) / \text{Var}(X)$

→

หา $\alpha = \bar{y} - \beta \bar{x}$

→

ได้เส้นที่ minimize error²

$$\beta = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \quad \alpha = \bar{y} - \beta \bar{x}$$


$$\min_{\alpha, \beta} \sum_i (y_i - \alpha - \beta x_i)^2 \quad (\text{OLS})$$

🔍 ทำไม $\beta = \text{Cov}(X, Y) / \text{Var}(X)$?

เราอยากหา β ที่ minimize $\sum (y - \alpha - \beta x)^2$ → ทำ derivative เทียบ β แล้ว set = 0

$$\partial / \partial \beta [\sum (y - \alpha - \beta x)^2] = -2 \sum x(y - \alpha - \beta x) = 0$$

แก้ออกมาได้: $\beta = \sum (x_i - \bar{x})(y_i - \bar{y}) / \sum (x_i - \bar{x})^2 = \text{Cov}(X, Y) / \text{Var}(X) \checkmark$



OLS regression: $\beta = \text{Cov}(X,Y)/\text{Var}(X) = \text{slope of regression line}$

เชื่อมกับ Options — Beta และ Hedge Ratio

Beta ของหุ้น = slope ของ regression: $\text{return หุ้น} = \alpha + \beta \times \text{return ตลาด}$

$\beta = 1.5 \rightarrow$ หุ้นผันผวนมากกว่าตลาด 1.5 เท่า

Options Hedge Ratio: ถ้า regress การเปลี่ยนแปลงราคา option (ΔV) บนการเปลี่ยนแปลงราคา underlying (ΔS) เฉพาะช่วงสั้น ๆ (ΔS เล็ก) slope ที่ได้ $\approx$ **Delta** — แต่ระวัง: ถ้า ΔS ใหญ่ slope จะเพี้ยนเพราะ Gamma (Delta เปลี่ยน) และ Vega (σ เปลี่ยน) เข้ามาแทรก ดังนั้น regression slope ให้ delta แค่ *local* ไม่เท่ากับ analytic delta = $\partial V / \partial S$ เป๊ะ

9.2 Regression Diagnostics & Standard Errors — ตรวจสอบสุขภาพโมเดล

🔍 อุปมา: ตรวจสอบสุขภาพหลัง fit เส้น

fit เส้น regression เสร็จ แล้วได้ β สวย ๆ — อย่าเพิ่งเชื่อ!

เหมือนหมอที่ต้อง "ตรวจสอบสุขภาพ" คนไข้ก่อนบอกว่าหายดี เราต้องตรวจ **residuals** (ส่วนที่โมเดลทายพลาด) ก่อน

ถ้า residuals "สุขภาพดี" (สุ่มกระจายไม่มีแบบแผน) $\rightarrow$ เชื่อโมเดลได้

ถ้า residuals มี pattern $\rightarrow$ โมเดลมีปัญหาซ่อนอยู่

$$e_i = y_i - \hat{y}_i \quad (\text{residual} = \text{จริง} - \text{ทาย})$$

plot e_i vs $x \rightarrow$ ควรเป็น random scatter รอบศูนย์ (ไม่มีรูปทรง)

Heteroskedasticity — ความแปรปรวนไม่คงที่

ถ้า การกระจายของ residual โตขึ้นตาม x (เล็กตอน x น้อย, บานออกตอน x มาก เป็นรูปกรวย) $\rightarrow$ variance ไม่คงที่ = heteroskedasticity

เหตุ $\rightarrow$ ผล: β ยัง unbiased (ค่าเฉลี่ยยังถูก) แต่ standard error ผิด $\rightarrow$ t-stat และ confidence interval เชื่อไม่ได้

พบบ่อยมากใน financial returns เพราะ volatility clustering (ช่วงตลาดผันผวน residual ใหญ่, ช่วงสงบ residual เล็ก)

Autocorrelation — residual สัมพันธ์กันข้ามเวลา

ถ้า residual วันนี้ทำนาย residual พรุ่งนี้ได้ (correlated over time) $\rightarrow$ ละเมิดสมมติฐานว่า error เป็นอิสระ

ตรวจด้วย Durbin-Watson statistic (ค่าใกล้ 2 = ไม่มี autocorrelation; ใกล้ 0 = บวก; ใกล้ 4 = ลบ)
พบทั่วไปใน time-series returns $\rightarrow$ standard error ต่ำเกินจริง $\rightarrow$ คิดว่า β significant ทั้งที่จริงไม่

$$se(\beta) = \frac{\sigma_{\text{resid}}}{\sqrt{n} \sigma_x} \quad t = \frac{\beta}{se(\beta)} \quad \Rightarrow \quad |t| > 2 \Rightarrow \beta \text{ significant (95\%)}$$

ตัวอย่างคำนวณ: β significant ไหม?

สมมติได้ $\beta = 1.5$, $se(\beta) = 0.3$

t-stat = $\beta / se(\beta) = 1.5 / 0.3 = 5.0$

$|t| = 5 > 2 \rightarrow$ **significant!** β แตกต่างจาก 0 อย่างมีนัยสำคัญ — เชื่อได้ว่าหุ้นมี exposure กับตลาดจริง

โจทย์ฝึก §9.2

ฝึก. regression ให้ $\beta = 0.8$, $se(\beta) = 0.5$ — β นี้ significant หรือไม่?

► ดูเฉลย

⚠ Model Risk: Data Snooping — In-sample ดีไม่ได้แปลว่า Out-of-sample ดี

การ fit regression กับ financial data เจอกับดักหลายอย่าง:

- **Overfitting:** R^2 สูงใน in-sample แต่พัง out-of-sample เพราะ model จำ noise ไปด้วย
- **Multiple testing:** ลอง signal 100 ตัว — ปกติ 5 ตัวจะ significant ด้วยแค่โชค ($\alpha=5\%$)
- **Survivorship bias:** data มีเฉพาะบริษัทที่ยังอยู่ → β ที่ได้ bias ขึ้น
- **Look-ahead bias:** ใช้ข้อมูลที่รู้แล้วตอน "จำลองอดีต" → performance สวยเกินจริง

แนวทาง: Walk-forward validation, Cross-validation, Bonferroni correction สำหรับ multiple signals

9.3 Multiple Regression — หลายปัจจัยพร้อมกัน

🔍 อุปมา: ราคาบ้านขึ้นกับหลายปัจจัย

ราคาบ้าน = $\alpha + \beta_1(\text{พื้นที่ } m^2) + \beta_2(\text{ห้องนอน}) + \beta_3(\text{ระยะจาก BTS})$

ถ้าวิ่ง regression นี้ → รู้ว่า "พื้นที่เพิ่ม 1 m^2 เพิ่มราคาเท่าไร โดยคำนึงปัจจัยอื่น"

ใน Finance: return หุ้น = $\alpha + \beta_1(\text{market}) + \beta_2(\text{size}) + \beta_3(\text{value}) + \varepsilon$

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n + \varepsilon \quad \mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \quad (\text{OLS})$$

เชื่อมกับ Options — Fama-French Factor Model

Return = $\beta_1(\text{Market}) + \beta_2(\text{SMB}) + \beta_3(\text{HML}) + \alpha$

- Hedge Market risk ด้วย Index futures (β_1)
- Hedge Size risk ด้วย Small-cap vs Large-cap spread (β_2)
- ไม่ต้อง hedge ทีละหุ้น → hedge 3 factors ครอบ portfolio ทั้งหมด

9.4 Multicollinearity — ตัวแปรซ้ำซ้อน

🔍 อุปมา: พยานสองคนเล่าเรื่องเดียวกัน

ถ้ามีพยาน 2 คนในศาล แต่ทั้งคู่ **เล่าเรื่องเดียวกันเป๊ะ** — ผู้พิพากษาแยกไม่ออกว่าหลักฐานมาจากใคร "ทำ" จริง

factor model ก็เหมือนกัน: ถ้าสองปัจจัยเล่าเรื่องเดียวกัน (correlated สูง) โมเดล แยกไม่ออกว่าใคร **ทำให้ return เปลี่ยน** → β ของแต่ละตัว **ไม่เสถียร** (กระโดดไปมา)

เหตุ → ผล

factors correlated สูง → $\det(X^T X) \approx 0 \rightarrow (X^T X)^{-1}$ ระเบิด → $\text{Var}(\hat{\beta})$ มหาศาล → เปลี่ยนข้อมูลนิดเดียว $\hat{\beta}$ พลิกเครื่องหมาย

Detection — VIF (Variance Inflation Factor)

วิธีตรวจ: regress ปัจจัย j กับปัจจัยที่เหลือ ได้ R^2_j แล้วคำนวณ

$$\text{VIF}_j = 1 / (1 - R^2_j)$$

- ถ้าปัจจัย j ทำนายไม่ได้จากตัวอื่น ($R^2_j \approx 0$) → $\text{VIF} \approx 1$ (ดีไม่ซ้ำซ้อน)
- ถ้าปัจจัย j ถูกตัวอื่นทำนายได้เกือบหมด ($R^2_j = 0.9$) → $\text{VIF} = 1/(1-0.9) = 10$

กฎ: $\text{VIF} > 10$ → มีปัญหา multicollinearity ชัดเจน

อีกวิธี: ดู **correlation matrix** ของ **factors** โดยตรง — ถ้าคู่ไหน $|p| > 0.8$ ให้ระวัง

วิธีแก้ — ตัด/รวม หรือใช้ PCA (เชื่อมกับบทที่ 8)

- **Drop:** ทิ้งปัจจัยซ้ำซ้อนตัวหนึ่งทิ้งไป (เก็บตัวที่ตีความง่ายกว่า)
- **Combine:** รวมสองปัจจัยที่ซ้ำเป็นตัวเดียว (เช่น เฉลี่ย value score)
- **PCA:** แปลง factors ที่ correlated เป็น principal components ที่ **orthogonal** (ตั้งฉาก **ไม่ correlated**) โดยสร้าง — ตรงนี้ผูกกลับไป §8.5 eigenvector ของ covariance matrix factors → กำจัดความซ้ำซ้อนได้ที่ราก

โจทย์ฝึก §9.4

ฝึก. regress ปัจจัย HML กับปัจจัยอื่น ๆ ได้ $R^2 = 0.95$ — VIF เท่าไหร่ และมีปัญหา multicollinearity ไหม?

► ดูเฉลย

9.5 R^2 — วัดความดีของ Model

🔍 อุปมา: พยากรณ์อากาศ

ถ้าพยากรณ์อากาศ "แม่นยำ" 80% $\rightarrow R^2 = 0.80$

ถ้าแม่นยำแค่ 20% $\rightarrow R^2 = 0.20$

R^2 = "model อธิบายความแปรปรวนของข้อมูลได้กี่ %"

$R^2 = 1.0$: predict ได้แม่นยำขนาดนั้นคงไม่มีในโลก finance

$R^2 = 0.30$ สำหรับ daily stock return ถือว่าดีมากแล้ว!

$$R^2 = 1 - \frac{SS_{\text{residual}}}{SS_{\text{total}}}$$

R^2	ความหมาย	ตัวอย่างใน Finance
0.90–1.0	ดีมาก	Bond yield vs maturity (yield curve fit)
0.50–0.90	พอใช้ได้	Beta regression ของหุ้น large-cap
0.10–0.50	อ่อนแต่ยังมีประโยชน์	Vol smile fit ด้วยสูตร simple
<0.10	แย่มาก	ปัจจัยอื่นสำคัญกว่า หรือ noise มาก

9.6 Curve Fitting — Fit Volatility Surface

🔍 อุปมา: วาดเส้นโค้งผ่านจุดข้อมูล

Volatility Smile: IV ของ options หลาย Strike ไม่เป็นเส้นตรง — มีรูปร่างเป็นรอยยิ้ม/เอียง
เราอยาก fit สูตรผ่านจุดข้อมูลเหล่านั้น เพื่อ interpolate IV ของ Strike กลางๆ

Simple: $\sigma(K) = a + bK + cK^2$ (polynomial degree 2)

Advanced: SVI, SABR model

$$\sigma(K, T) = a_0 + a_1K + a_2K^2 + a_3T + a_4KT + \dots$$

Overfitting — กับดักของ Curve Fitting

Degree 2: $\sigma(K)$ smooth, interpolate ได้ดี

Degree 10: ผ่านทุกจุดพอดี แต่ระหว่างจุด "กลม" หรือ "พุ่ง" ขึ้นผิดปกติ

กฎ: ใช้ model ที่ง่ายที่สุดที่อธิบายข้อมูลได้ดีพอ — R^2 เพิ่มขึ้นน้อยมากเมื่อเพิ่ม degree → หยุด

เชื่อมกับ Options — Vol Surface Fitting

Market makers ใช้ SVI/SABR fit IV surface จาก quoted prices

→ ได้สูตร $\sigma(K, T)$ ที่ smooth → interpolate IV ของ strike ที่ไม่มีใน chain

→ ใช้ price exotic options, calibrate hedging

สรุปบทที่ 9

- ✓ Simple Regression: $y = \alpha + \beta x$, $\beta = \text{Cov}/\text{Var}$ → **Beta ของหุ้น**
- ✓ Multiple Regression: Factor Models → hedge หลาย risk factor พร้อมกัน
- ✓ R^2 = สัดส่วนที่ model อธิบายได้ — R^2 สูงไม่ได้แปลว่าดีเสมอ (overfitting)
- ✓ Curve Fitting → fit Volatility Smile/Surface

โจทย์ฝึกหัด Part IV

ข้อ 1. Portfolio 3 assets: $w = [0.5, 0.3, 0.2]$, returns = $[8\%, -2\%, 5\%]$

คำนวณ Portfolio Return ด้วย Dot Product

► ดูเฉลย

ข้อ 2. หุ้น 2 ตัว: $w = [0.7, 0.3]$, $\sigma_1 = 25\%$, $\sigma_2 = 15\%$, $\rho = 0.4$

คำนวณ Portfolio Standard Deviation

► ดูเฉลย

ข้อ 3. ข้อมูล 5 ปี: Return ตลาด = $[10\%, -5\%, 8\%, -3\%, 12\%]$, Return หุ้น = $[15\%, -8\%, 12\%, -4\%, 18\%]$

ประมาณ Beta ของหุ้น (ใช้ข้อมูล 5 จุด)

► ดูเฉลย

จบ Part IV

ตอนนี้คุณจัดการ Portfolio หลายสินทรัพย์ด้วย Matrix ได้แล้ว!

Part V: Optimization → หาน้ำหนัก Portfolio ที่ดีที่สุด