

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part V: Optimization — หาคำตอบที่ดีที่สุด

บทที่ 10-11: Linear Programming, Simplex, Dual, Integer LP,
Gradient Descent, Lagrange, Convex Optimization, QP

บทที่ 10: Linear Programming

อุปมา: ร้านขนมที่มีส่วนผสมจำกัด

สมมติเปิดร้านขนม ทำได้ 2 อย่าง: **ขนมปัง A** (กำไร 8 บาท) และ **ขนมปัง B** (กำไร 5 บาท)

แต่มีข้อจำกัด: แป้ง 20 ถ้วย (A ใช้ 5 ถ้วย, B ใช้ 2 ถ้วย) และ เวลา 5 ชั่วโมง (แต่ละชิ้น 1 ชั่วโมง)

คำถาม: ทำ A กี่ชิ้น B กี่ชิ้น *จึงจะกำไรมากที่สุด?* — นี่คือ Linear Programming!

ทรัพยากรจำกัด

→

ตั้ง Constraints

→

เขียน Objective

→

หาค่า Optimal

LP = หาค่า maximum/minimum ของฟังก์ชันเชิงเส้น ภายใต้เงื่อนไข (constraints) ที่เป็นเชิงเส้น

10.1 แนวคิดและการตั้งโจทย์

Maximize $z = c_1x_1 + c_2x_2$ (Objective Function)

Subject to:

$a_{11}x_1 + a_{12}x_2 \leq b_1$ (Constraint 1: ทรัพยากร 1)

$a_{21}x_1 + a_{22}x_2 \leq b_2$ (Constraint 2: ทรัพยากร 2)

$x_1, x_2 \geq 0$ (Non-negativity: ซื้อไม่ได้ติดลบ)

ทำไมสมการถึงเขียนแบบนี้?

c_1, c_2 = "กำไรต่อหน่วย" ของแต่ละตัวเลือก → เป้าหมายคือ maximize ผลรวม

a, b = "ส่วนผสมที่ใช้" vs "ส่วนผสมที่มี" → ข้อจำกัดทางกายภาพ


ทุก constraint เป็น "เส้นตรง" → ทำให้ feasible region เป็น "รูปหลายเหลี่ยม" → คำตอบอยู่ที่มุม!

ตัวอย่าง: จัดพอร์ต Options**Maximize** Expected Payoff = $8x_1 + 5x_2$ $(x_1 = \text{จำนวน Call } K=100, x_2 = \text{จำนวน Call } K=110)$ **Subject to:**Premium: $5x_1 + 2x_2 \leq 20$ (budget ฿20)Risk: $x_1 + x_2 \leq 5$ (ไม่เกิน 5 สัญญา) $x_1, x_2 \geq 0$ **10.2 Graphical Method****อุปมา: แผนที่ที่มีรั้วกัน**

นึกภาพแผนที่ 2 มิติ Constraint แต่ละข้อคือ "รั้ว" ที่กั้น พื้นที่ที่เหลือ (ข้างใน) คือ **Feasible Region** — บริเวณที่ทำได้จริง

Objective Function คือ "เส้นระดับความสูง" ที่ขนานกัน → เลื่อนเส้นออกไปเรื่อยๆ จนชนรั้ว → จุดนั้นคือ optimal!

สำหรับ 2 ตัวแปร แก้ได้ด้วยกราฟ: วาด constraints → หา feasible region → เช็ค corner points



Corner Point Theorem

คำตอบ optimal ของ LP อยู่ที่มุม (corner) ของ feasible region เสมอ!

ดังนั้นเช็คแค่ทุก corner → เลือกค่า z สูงสุด

1 หา corner points จากจุดตัดของ constraints:

- $(0,0)$ — origin
- $(0,5)$ — constraint 2 ตัด y-axis: $x_1=0 \rightarrow x_2=5$
- $(10/3, 5/3)$ — constraints 1 และ 2 ตัดกัน: แก้ระบบ $5x_1+2x_2=20$, $x_1+x_2=5$
- $(4,0)$ — constraint 1 ตัด x-axis: $x_2=0 \rightarrow 5x_1=20 \rightarrow x_1=4$

2 คำนวณ z ที่แต่ละ corner:

- $z(0,0) = 8(0)+5(0) = 0$
- $z(0,5) = 8(0)+5(5) = 25$
- $z(10/3, 5/3) = 8(10/3)+5(5/3) = 80/3+25/3 = 105/3 = 35 \leftarrow \text{Maximum!}$
- $z(4,0) = 8(4)+5(0) = 32$

3 สรุป: ซื้อ Call $K=100$ จำนวน 3.33 สัญญา + Call $K=110$ จำนวน 1.67 สัญญา → Payoff = ฿35

10.3 Simplex Method

อุปมา: เดินป่าในความมืด หาจุดสูงสุด

ลองนึกถึงการเดินป่าตอนกลางคืน มองไม่เห็นทิวทัศน์ทั้งหมด แต่ *รู้สึกได้* ว่าทิศไหนลาดขึ้นชัน

วิธี Simplex: ยืนอยู่ทีมนึง → มองไปมุมใกล้ๆ → เดินไปมุมที่สูงกว่า → ทำซ้ำจนไม่มีมุมที่สูงกว่า

ไม่ต้องสำรวจทุกมุม! ในทางปฏิบัติ Simplex เร็วมากแม้มีหลายร้อยตัวแปร

เมื่อมีหลายตัวแปร (ใช้กราฟไม่ได้) ใช้ **Simplex Algorithm**:

1. เริ่มที่ corner หนึ่ง (มักเป็นจุด origin)
2. มองไปรอบๆ ว่า corner ไหนดีกว่า (ดู "reduced cost")
3. เดินไปที่ corner ที่ดีขึ้นมากที่สุด (pivot)
4. ทำซ้ำจนไม่มี corner ที่ดีกว่า → **optimal!**

Corner Point Theorem

→

คำตอบอยู่ที่มุม

→

เดินจากมุมสู่มุมที่ดีขึ้น

→

หยุดเมื่อไม่มีมุมดีกว่า

→

Optimal!

Simplex ไม่ต้องจำขั้นตอน แค่เข้าใจหลักการ

"เดินไปตาม edge ของ feasible region จาก corner สู่ corner ที่ดีขึ้นเรื่อยๆ"

ในทางปฏิบัติใช้ software (Excel Solver, Python scipy.optimize.linprog)

10.4 Dual Problem & Shadow Price

อุปมา: "ถ้าได้วัตถุดิบเพิ่ม 1 หน่วย กำไรเพิ่มเท่าไร?"

เจ้าของร้านขนมถามว่า "ถ้าซื้อแป้งเพิ่ม 1 ถ้วย (ราคา ฿?) กำไรจะเพิ่มขึ้นเท่าไร?" — นั่นคือ Shadow Price!

Shadow Price = "ราคาเงา" ของ constraint — บอกว่า constraint ไหน "แพง" ที่สุด ควรไปผ่อน คลายก่อน

ทุก LP (Primal) มีคู่ (Dual) — ให้มุมมองเพิ่มเติม:

Primal: $\text{Max } c^T x \text{ s.t. } Ax \leq b, x \geq 0$ **Dual:** $\text{Min } b^T y \text{ s.t. } A^T y \geq c, y \geq 0$ **Weak Duality:** ค่า Dual $\geq$ ค่า Primal เสมอ**Strong Duality:** ที่ optimal ค่าเท่ากัน!**ทำไม Dual มีอยู่?**

Primal ถามว่า "จัด resource ยังไงให้ได้กำไรสูงสุด?"

Dual ถามว่า "resource แต่ละอย่างมี มูลค่า เท่าไร?" (y^* = shadow prices)

Strong Duality: ทั้งสองคำถามมีคำตอบที่สอดคล้องกันที่ optimal → สามารถใช้ Dual แทน Primal ได้เมื่อสะดวกกว่า

Shadow Price (y^*) = "ถ้าเพิ่ม resource (b) อีก 1 หน่วย ค่า objective จะเพิ่มเท่าไร?"

- 1 จากตัวอย่าง Options: ที่ optimal (10/3, 5/3) — budget constraint: $5x_1 + 2x_2 = 20$ (active)
- 2 Shadow price ของ budget constraint $\approx$ ฿1.4/บาท budget
- 3 ถ้า budget เพิ่มจาก ฿20 $\rightarrow$ ฿21 $\rightarrow$ Expected Payoff เพิ่มจาก ฿35 $\rightarrow$ ฿36.4
- 4 ถ้า risk constraint active: shadow price บอกว่า "การเพิ่ม 1 สัญญา" มีมูลค่าเท่าไร

เชื่อมกับ Options

Shadow Price ของ budget constraint = "ถ้ามีเงินเพิ่มอีก ฿1 expected payoff จะเพิ่มเท่าไร?"
ใช้ตัดสินใจว่าควร "ขยาย budget" หรือ "ลด risk limit" — constraint ไหน "แพง" กว่า

10.5 Sensitivity Analysis

ถ้า parameter เปลี่ยน คำตอบเปลี่ยนไหม? — สำคัญเพราะ input มักไม่แน่นอน

- **Coefficient ใน objective เปลี่ยน:** ถ้า expected payoff ของ Call เปลี่ยน $\rightarrow$ basis ยังเหมือนเดิมไหม? (มี "allowable range")
- **RHS ของ constraint เปลี่ยน:** ถ้า budget เพิ่ม $\rightarrow$ ใช้ shadow price คำนวณได้ทันที (ทราบที่อยู่ใน range)

Sensitivity ใน Options Trading

Greeks ของ Options ก็คือ sensitivity analysis! Delta = sensitivity ของ option price ต่อ S, Vega = sensitivity ต่อ σ

Simplex sensitivity = sensitivity ของ optimal solution ต่อ parameters ของโจทย์ LP

10.6 Integer Linear Programming (ILP)

อุปมา: ซื้อตัวเครื่องบินครึ่งใบไม่ได้

LP อาจตอบว่า "ควรซื้อ 3.7 สัญญา" — แต่สัญญา Options ซื้อเป็นจำนวนเต็มเท่านั้น! (1 contract = 100 shares)

ILP แก้ปัญหานี้โดยบังคับให้ตัวแปรเป็นจำนวนเต็ม

ILP = LP ที่ตัวแปรต้องเป็นจำนวนเต็ม

$$\text{Max } c^T x \quad \text{s.t. } Ax \leq b, \quad x \geq 0, \quad x \in \mathbb{Z} \text{ (integers)}$$

แก้ LP Relaxation

→

ตัวแปรไม่เต็ม?

→

Branch ($x \leq 3$ หรือ $x \geq 4$)

→

แก้ใหม่แต่ละ branch

→

Integer Solution

ILP ยากกว่า LP มาก!

LP แก้ได้ใน polynomial time แต่ ILP เป็น NP-hard → ไม่มี algorithm ที่เร็วเสมอ

วิธีแก้: **Branch and Bound** — แก้ LP relaxation ก่อน แล้ว branch ที่ตัวแปรที่ไม่เป็นจำนวนเต็ม

เชื่อมกับ Options

Options ซื้อเป็น **สัญญา** (1 contract = 100 หุ้น) → ต้องเป็นจำนวนเต็ม!

ตัวอย่าง: เลือก combination ของ option contracts ที่ maximize payoff-to-risk ภายใต้ budget constraint → ILP problem

บทที่ 11: Nonlinear Optimization

อุปมา: โลกจริงไม่ใช่เส้นตรง

Portfolio risk ไม่ใช่ linear — เพิ่ม 2 เท่าของสินทรัพย์ ไม่ได้เพิ่ม risk 2 เท่า (เพราะ diversification!)

Nonlinear optimization จัดการกับฟังก์ชันที่ "โค้ง" — อย่าง Portfolio Variance = $w^T \Sigma w$ ซึ่งเป็น *quadratic* (โค้งพาราโบลา)

โลกจริงไม่เป็นเส้นตรง — Portfolio Optimization ของ Markowitz เป็น **Quadratic** ไม่ใช่ Linear

11.1 Unconstrained Optimization

หา min/max ของ $f(x)$ โดยไม่มี constraints:

เงื่อนไขจำเป็น: $f'(x^*) = 0$ (slope = 0 ที่จุด optimal)

เงื่อนไขเพียงพอ:

$f''(x^*) > 0 \rightarrow \text{minimum}$ (โค้งขึ้น "สาม")

$f''(x^*) < 0 \rightarrow \text{maximum}$ (โค้งลง "อาน")

ทำไม $f'=0$ คือ optimal?

ถ้า slope $\neq 0$ หมายความว่าเดินไปอีกนิดจะ "ดีขึ้น" $\rightarrow$ ยังไม่ optimal!

ที่ optimal จริง: ทุกทิศทางจาก x^* จะ "แย่ลง" $\rightarrow$ slope ต้องเป็น 0 (หรือ gradient = 0 สำหรับหลายตัวแปร)

11.2 Gradient Descent — "เดินลงเขา"

อุปมา: ตาบอด ลงเขาในหมอก

ลองนึกถึงการลงเขาดอนหมอกลง มองไม่เห็นทาง แต่รู้สึกได้ว่าทิศไหน "ลาดชันลงมากที่สุด"

วิธี Gradient Descent: คำนวณทิศที่ "ชันขึ้น" (gradient) แล้วเดินสวนทาง $\rightarrow$ ลงเร็วที่สุด

ขนาดก้าว (α = learning rate): เล็กเกินไป = ช้า, ใหญ่เกินไป = กระโดดข้ามหุบเขา!

$$x(t+1) = x(t) - \alpha \times \nabla f(x(t))$$

α = learning rate (ขนาดก้าว)

∇f = gradient (ทิศทางที่ f เพิ่มขึ้นเร็วที่สุด) → เดินสวนทาง = ลดเร็วที่สุด

คำนวณ ∇f (gradient)

→

เดินสวนทาง ($-\alpha \nabla f$)

→

Update x


→

ทำซ้ำ

→

$|\nabla f| \approx 0 \rightarrow$ หยุด

- 1 โจทย์: Minimize $f(x) = x^2$ โดยใช้ Gradient Descent, $\alpha=0.3$, เริ่มที่ $x_0=4$
- 2 $f'(x) = 2x$ (gradient)
- 3 Iteration 1: $x_1 = 4 - 0.3 \times (2 \times 4) = 4 - 2.4 = \mathbf{1.6}$
- 4 Iteration 2: $x_2 = 1.6 - 0.3 \times (2 \times 1.6) = 1.6 - 0.96 = \mathbf{0.64}$
- 5 Iteration 3: $x_3 = 0.64 - 0.3 \times (2 \times 0.64) = 0.64 - 0.384 = \mathbf{0.256}$
- 6 เข้าใกล้ 0 (คำตอบจริง) ทุก iteration! หลังหลาย iteration $\rightarrow x \rightarrow 0$



เชื่อมกับ Options

ใช้ Gradient Descent สำหรับ:

- **Model Calibration:** หา parameters ที่ทำให้ model price $\approx$ market price
- **Volatility Surface Fitting:** minimize ผลต่างระหว่าง model vol vs market vol

11.3 Lagrange Multipliers — Optimization ที่มี Constraints

อุปมา: เดินบนถนน (constraint) หาจุดที่สูงสุด

ถ้าต้องเดินอยู่บนถนน (constraint $g=0$) แต่อยากหาจุดที่ "สูงที่สุด" (maximize f)

จุด optimal คือจุดที่ "ทิศทางขึ้นสูง" ซึ่ง *ตั้งฉากกับถนน* — ถ้าไม่ตั้งฉาก แปลว่าเดินต่อบนถนนแล้วจะสูงขึ้นได้อีก!

Lagrange Multiplier (λ) = อัตราส่วนระหว่าง gradient ของ f กับ gradient ของ g ที่จุด optimal

หา min/max ของ $f(x)$ ภายใต้เงื่อนไข $g(x) = 0$:

สร้าง Lagrangian: $L(x, \lambda) = f(x) - \lambda \times g(x)$

แก้: $\partial L / \partial x = 0$ และ $\partial L / \partial \lambda = 0$ ($= g(x) = 0$)

เงื่อนไข: $\nabla f = \lambda \nabla g$ (gradient ขนานกัน!)

λ = Lagrange multiplier = "ถ้าผ่อน constraint อีกนิด objective เปลี่ยนเท่าไร"

- 1 **Markowitz Problem:** Minimize $\sigma^2_p = w^T \Sigma w$ s.t. $w^T \mu = r^*$ (target) และ $w^T 1 = 1$
- 2 Lagrangian: $L = w^T \Sigma w - \lambda_1(w^T \mu - r^*) - \lambda_2(w^T 1 - 1)$
- 3 $\partial L / \partial w = 0 \rightarrow 2 \Sigma w - \lambda_1 \mu - \lambda_2 1 = 0 \rightarrow w^* = \Sigma^{-1}(\lambda_1 \mu + \lambda_2 1) / 2$
- 4 ปรับ λ_1, λ_2 ให้ตรงกับ constraints $\rightarrow$ ได้ efficient portfolio!
- 5 ทำสำหรับ r^* ต่างๆ $\rightarrow$ ได้ **Efficient Frontier** (เส้นโค้ง risk vs return)

เชื่อมกับ Options — Markowitz Portfolio Optimization!

Minimize Portfolio Risk: $\sigma^2_p = w^T \Sigma w$

Subject to: $w^T \mu = \text{target return}$, $w^T 1 = 1$

ใช้ Lagrange: $L = w^T \Sigma w - \lambda_1(w^T \mu - r^*) - \lambda_2(w^T 1 - 1)$

$\rightarrow$ หา **Efficient Frontier** (เส้นโค้งของ risk vs return ที่ดีที่สุด)

11.4 Convex Optimization

อุปมา: ชาม vs อาน

Convex function = รูปชาม → มีก้นชามเดียว ไม่ว่าเริ่มจากจุดไหน Gradient Descent จะหาค้น
ชามเจอ

Non-convex = รูปอาน (saddle) หรือภูมิประเทศขรุขระ → มีหลายหุบเขา อาจติดอยู่ที่ "หุบเขาเล็ก"
ที่ไม่ใช่ที่ดีที่สุด

ข่าวดีสำหรับ Quant: Portfolio optimization (Markowitz) เป็น **convex**!

ทำไม Convex สำคัญ?

- Convex → มี **minimum เดียว (global)** → Gradient Descent จะหาเจอเสมอ ไม่ว่าเริ่มจากไหน
- Non-convex → มีหลาย local minimum → อาจติดอยู่ที่จุดที่ไม่ใช่ global minimum
- การตรวจสอบ: f convex $\iff$ Hessian (matrix of second derivatives) เป็น PSD

ข่าวดี: Portfolio optimization (Markowitz) เป็น **convex**! → มีคำตอบเดียวที่ดีที่สุด

ข่าวร้าย: Calibration ของบาง model (เช่น Stochastic Volatility) เป็น **non-convex** → ต้องใช้เทคนิคพิเศษ

11.5 Quadratic Programming (QP)

ทำไม QP ถึงเป็น "ชั้นพิเศษ" ของ Nonlinear Optimization?

QP = objective เป็น quadratic (โด้งพาราโบลา) + constraints เป็น linear

นี่คือ "จุดกึ่งกลาง": ยากกว่า LP (เพราะ objective ไม่เส้นตรง) แต่ง่ายกว่า nonlinear ทั่วไป (เพราะ convex)

ข้อดี: มี solver ที่เร็วและแม่นยำ — แก่ Markowitz ได้ใน milliseconds!

Minimize $\frac{1}{2}x^T Q x + c^T x$

Subject to: $Ax \leq b$

$Q = 2\Sigma$ (Covariance)

→

objective = $w^T \Sigma w$

→

constraints = budget + return

→

QP Solver

→

Efficient Portfolio!

เชื่อมกับ Options

Mean-Variance Optimization ของ Markowitz เป็น QP พอดี!

$Q = 2\Sigma$ (covariance matrix), $c = 0$ หรือ $-\mu$

ใช้ QP solver ใน Python (cvxpy, scipy) แก้ได้ในเสี้ยววินาที → optimal portfolio weights!

- 1 ตัวอย่าง QP 2 สินทรัพย์: หน้า 4, $\Sigma = \begin{bmatrix} 0.04 & 0.01 \\ 0.01 & 0.09 \end{bmatrix}$, $\mu = [0.10, 0.15]$
- 2 Minimize $w^T \Sigma w = w_1^2(0.04) + 2w_1w_2(0.01) + w_2^2(0.09)$
- 3 Subject to: $w_1 + w_2 = 1$, $0.10w_1 + 0.15w_2 = 0.12$ (target return)
- 4 จาก constraints: $w_2 = 0.4$, $w_1 = 0.6$ (แก้ระบบเส้นตรง)
- 5 $\sigma_p^2 = 0.36(0.04) + 2(0.24)(0.01) + 0.16(0.09) = 0.0144 + 0.0048 + 0.0144 = \mathbf{0.0336}$
- 6 $\sigma_p = \sqrt{0.0336} \approx \mathbf{18.3\%}$ ← portfolio risk ที่ optimal สำหรับ return 12%

แบบฝึกหัด Part V

โจทย์ 1: หา Optimal Solution ด้วย Corner Points

Maximize $z = 3x_1 + 2x_2$

Subject to: $2x_1 + x_2 \leq 10$, $x_1 + 2x_2 \leq 8$, $x_1, x_2 \geq 0$

หาทุก corner points และบอกว่า optimal solution คืออะไร?

▶ ดูเฉลย

โจทย์ 2: Shadow Price และ Sensitivity

จากตัวอย่าง Options ในบทเรียน (Maximize $8x_1 + 5x_2$ s.t. $5x_1 + 2x_2 \leq 20$, $x_1 + x_2 \leq 5$)

คำตอบ optimal คือ $x_1 = 10/3$, $x_2 = 5/3$, $z = 35$

ถ้า budget เพิ่มขึ้น ฿21 (จาก ฿20) คาดว่า Expected Payoff จะเป็นเท่าไร? (ใช้ shadow price ≈ 1.4)

▶ ดูเฉลย

โจทย์ 3: Gradient Descent Iterations

กำหนด $f(x) = x^2 + 4x + 5$, $\alpha = 0.1$, เริ่มที่ $x_0 = 3$

คำนวณ 3 iterations ของ Gradient Descent แล้วบอกว่าเข้าใกล้คำตอบจริงไหม?

▶ ดูเฉลย

สรุป Part V

- ✓ LP: Objective + Constraints → Simplex → Optimal ที่มุม feasible region
- ✓ Dual: Shadow Price = มูลค่าของ constraint — constraint ไหน "แพง" ที่สุด?
- ✓ ILP: ตัวแปรจำนวนเต็ม → Branch & Bound (ใช้สำหรับ option contracts)
- ✓ Gradient Descent → เดินลงเขา → Model Calibration, Vol Surface Fitting
- ✓ Lagrange → Markowitz Portfolio Optimization → Efficient Frontier
- ✓ Convex → มีคำตอบเดียว (global) ไม่ติด local minimum
- ✓ QP = Mean-Variance Optimization → แก่ด้วย cvxpy ใน milliseconds

จบ Part V

Part VI: Time Series, Numerical Methods & Stochastic Calculus

→ Forecast Volatility, IV Solver, ที่มาของ BS