

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part V: Optimization — หาคำตอบที่ดีที่สุด

บทที่ 10-11: Linear Programming, Simplex, Dual, Integer LP,
Gradient Descent, Lagrange, Convex Optimization, QP

บทที่ 10: Linear Programming

LP = หาค่า maximum/minimum ของฟังก์ชันเชิงเส้น ภายใต้เงื่อนไข (constraints) ที่เป็นเชิงเส้น

10.1 แนวคิดและการตั้งโจทย์

Maximize $z = c_1x_1 + c_2x_2$ (Objective Function)

Subject to:

$a_{11}x_1 + a_{12}x_2 \leq b_1$ (Constraint 1)

$a_{21}x_1 + a_{22}x_2 \leq b_2$ (Constraint 2)

$x_1, x_2 \geq 0$ (Non-negativity)

ตัวอย่าง: จัดพอร์ต Options

Maximize Expected Payoff = $8x_1 + 5x_2$

(x_1 = จำนวน Call K=100, x_2 = จำนวน Call K=110)

Subject to:


Premium: $5x_1 + 2x_2 \leq 20$ (budget ฿20)

Risk: $x_1 + x_2 \leq 5$ (ไม่เกิน 5 สัญญา)

$x_1, x_2 \geq 0$

10.2 Graphical Method

สำหรับ 2 ตัวแปร แก้ได้ด้วยกราฟ: วาด constraints → หา feasible region → เช็ค corner points



Corner Point Theorem

คำตอบ optimal ของ LP อยู่ที่มุม (corner) ของ feasible region เสมอ!

ดังนั้นเช็คแค่ทุก corner → เลือกค่า z สูงสุด

10.3 Simplex Method

เมื่อมีหลายตัวแปร (ใช้กราฟไม่ได้) ใช้ **Simplex Algorithm**:

1. เริ่มที่ corner หนึ่ง (มักเป็นจุด origin)
2. มองไปรอบๆ ว่า corner ไหนดีกว่า
3. เดินไปที่ corner ที่ดีขึ้นมากที่สุด (pivot)
4. ทำซ้ำจนไม่มี corner ที่ดีกว่า → **optimal!**

Simplex ไม่ต้องจำขั้นตอน แค่เข้าใจหลักการ

"เดินไปตาม edge ของ feasible region จาก corner สู่ corner ที่ดีขึ้นเรื่อยๆ"

ในทางปฏิบัติใช้ software (Excel Solver, Python `scipy.optimize.linprog`)

10.4 Dual Problem & Shadow Price

ทุก LP (Primal) มีคู่ (Dual) — ให้มุมมองเพิ่มเติม:

Primal: $\text{Max } c^T x \text{ s.t. } Ax \leq b, x \geq 0$

Dual: $\text{Min } b^T y \text{ s.t. } A^T y \geq c, y \geq 0$

Weak Duality: ค่า Dual $\geq$ ค่า Primal เสมอ

Strong Duality: ที่ optimal ค่าเท่ากัน!

Shadow Price (y^*) = "ถ้าเพิ่ม resource (b) อีก 1 หน่วย ค่า objective จะเพิ่มเท่าไร?"

เชื่อมกับ Options

Shadow Price ของ budget constraint = "ถ้ามีเงินเพิ่มอีก ฿1 expected payoff จะเพิ่มเท่าไร?"
ใช้ตัดสินใจว่าควร "ขยาย budget" หรือ "ลด risk limit"

10.5 Sensitivity Analysis

ถ้า parameter เปลี่ยน คำตอบเปลี่ยนไหม?

- **Coefficient ใน objective เปลี่ยน:** ถ้า expected payoff ของ Call เปลี่ยน $\rightarrow$ basis ยังเหมือนเดิมไหม?
- **RHS ของ constraint เปลี่ยน:** ถ้า budget เพิ่ม $\rightarrow$ ใช้ shadow price คำนวณ

10.6 Integer Linear Programming (ILP)

ปัญหา: LP ตอบว่า "ซื้อ Call 2.7 สัญญา" $\leftarrow$ ซื้อ 0.7 สัญญาไม่ได้!

ILP = LP ที่ตัวแปรต้องเป็นจำนวนเต็ม

$$\text{Max } c^T x \quad \text{s.t. } Ax \leq b, x \geq 0, x \in \mathbb{Z} \text{ (integers)}$$

ILP ยากกว่า LP มาก!

LP แก้ได้ใน polynomial time แต่ ILP เป็น NP-hard $\rightarrow$ ไม่มี algorithm ที่เร็วเสมอ

วิธีแก้: **Branch and Bound** — แก้ LP relaxation ก่อน แล้ว branch ที่ตัวแปรที่ไม่เป็นจำนวนเต็ม

เชื่อมกับ Options

Options ซื้อเป็น **สัญญา** (1 contract = 100 หุ้น) → ต้องเป็นจำนวนเต็ม!

ตัวอย่าง: เลือก combination ของ option contracts ที่ maximize payoff-to-risk ภายใต้ budget constraint → ILP problem

บทที่ 11: Nonlinear Optimization

โลกจริงไม่เป็นเส้นตรง — Portfolio Optimization ของ Markowitz เป็น **Quadratic** ไม่ใช่ Linear

11.1 Unconstrained Optimization

หา min/max ของ $f(x)$ โดยไม่มี constraints:

เงื่อนไขจำเป็น: $f'(x^*) = 0$ (slope = 0 ที่จุด optimal)

เงื่อนไขเพียงพอ:

$f''(x^*) > 0 \rightarrow \text{minimum}$ (โค้งขึ้น)

$f''(x^*) < 0 \rightarrow \text{maximum}$ (โค้งลง)


11.2 Gradient Descent — "เดินลงเขา"

เมื่อมีหลายตัวแปรและหาคำตอบ closed-form ไม่ได้ $\rightarrow$ ใช้ algorithm เดินทีละก้าว:

$$x(t+1) = x(t) - \alpha \times \nabla f(x(t))$$

α = learning rate (ขนาดก้าว)

∇f = gradient (ทิศทางที่ f เพิ่มขึ้นเร็วที่สุด) $\rightarrow$ เดินสวนทาง = ลดเร็วที่สุด



เชื่อมกับ Options

ใช้ Gradient Descent สำหรับ:

- **Model Calibration:** หา parameters ที่ทำให้ model price $\approx$ market price
- **Volatility Surface Fitting:** minimize ผลต่างระหว่าง model vol vs market vol

11.3 Lagrange Multipliers — Optimization ที่มี Constraints

หา min/max ของ $f(x)$ ภายใต้เงื่อนไข $g(x) = 0$:

สร้าง Lagrangian: $L(x, \lambda) = f(x) - \lambda \times g(x)$

แก้: $\partial L / \partial x = 0$ และ $\partial L / \partial \lambda = 0$ ($= g(x) = 0$)

λ = Lagrange multiplier = "ถ้าผ่อน constraint อีกนิด objective เปลี่ยนเท่าไร" (คล้าย shadow price ใน LP!)

เชื่อมกับ Options — Markowitz Portfolio Optimization!

Minimize Portfolio Risk: $\sigma^2_p = w^T \Sigma w$

Subject to: $w^T \mu = \text{target return}$, $w^T 1 = 1$

ใช้ Lagrange: $L = w^T \Sigma w - \lambda_1(w^T \mu - r^*) - \lambda_2(w^T 1 - 1)$

→ หา **Efficient Frontier** (เส้นโค้งของ risk vs return ที่ดีที่สุด)

11.4 Convex Optimization

Convex problem: minimize $f(x)$ ที่เป็น convex function, ภายใต้ convex constraints

ทำไม Convex สำคัญ?

- Convex → มี **minimum เดียว** → Gradient Descent จะหาเจอเสมอ
- Non-convex → มีหลาย local minimum → อาจติดอยู่ที่จุดที่ไม่ใช่ global minimum

ข้อดี: Portfolio optimization (Markowitz) เป็น **convex!** → มีคำตอบเดียวที่ดีที่สุด

ข้อร้าย: Calibration ของบาง model (เช่น Stochastic Volatility) เป็น **non-convex** → ต้องใช้เทคนิคพิเศษ

11.5 Quadratic Programming (QP)

Minimize $\frac{1}{2}x^T Qx + c^T x$

Subject to: $Ax \leq b$

เชื่อมกับ Options

Mean-Variance Optimization ของ Markowitz เป็น QP พอดี!

$Q = 2\Sigma$ (covariance matrix), $c = 0$ หรือ $-\mu$

ใช้ QP solver ใน Python (cvxpy, scipy) แก้ได้ในเสี้ยววินาที

สรุป Part V

- ✓ LP: Objective + Constraints → Simplex → Optimal
- ✓ Dual: Shadow Price = ค่าของ constraint
- ✓ ILP: ตัวแปรจำนวนเต็ม → Branch & Bound
- ✓ Gradient Descent → Model Calibration
- ✓ **Lagrange → Markowitz Portfolio Optimization**
- ✓ Convex → มีคำตอบเดียว, Non-convex → ระวัง local minimum
- ✓ **QP = Mean-Variance Optimization**

จบ Part V

Part VI: Time Series, Numerical Methods & Stochastic Calculus

→ Forecast Volatility, IV Solver, ที่มาของ BS