

คณิตศาสตร์พื้นฐาน สำหรับ Options Trading

Part VI: Time Series, Numerical Methods & Stochastic Calculus

บทที่ 12-14: GARCH, IV Solver, Brownian Motion, Ito's Lemma, BS PDE

อ่านจบ → forecast volatility + เข้าใจที่มาของ Black-Scholes

บทที่ 12: Time Series & Volatility Forecasting

อุปมา: นักพยากรณ์อากาศที่พยากรณ์ "ความแปรปรวน" ไม่ใช่ "อุณหภูมิ"

นักพยากรณ์อากาศไม่ได้แค่บอกว่า "พรุ่งนี้ร้อน/เย็น" — เขายังบอก "พรุ่งนี้ฝนฟ้าคะนองมาก" (ความแปรปรวนสูง)

เช่นเดียวกัน Volatility Forecasting ไม่ได้ทำนายว่าราคาจะขึ้นหรือลง แต่ทำนายว่า "**ราคาจะผันผวนมากแค่ไหน**"

ใน Options Trading: ซื้อ Straddle ก่อนตลาดผันผวน ขาย Straddle เมื่อตลาดเงียบ — ไม่จำเป็นต้องรู้ทิศทาง!

Volatility ไม่คงที่ — มันเปลี่ยนแปลงตลอดเวลา ถ้า forecast ได้ = ได้เปรียบในการเทรด Options

12.1 แนวคิด Time Series

ข้อมูลที่เรียงตามเวลา: ราคาหุ้นรายวัน, daily returns, implied volatility

- **Trend:** ทิศทางระยะยาว (ขึ้น/ลง/นิ่ง)
- **Stationarity:** สมบัติไม่เปลี่ยนแปลงตามเวลา (mean, variance คงที่)

สำคัญ: วิเคราะห์ Returns ไม่ใช่ราคา!

ราคาหุ้น = **non-stationary** (มี trend ขึ้นตลอด) แต่ **returns** = stationary (เฉลี่ย ≈ 0 , variance $\approx$ คงที่)

ถ้าวิเคราะห์ราคาโดยตรง = เหมือนหาค่าเฉลี่ยส่วนสูงของเด็กที่กำลังโต — ค่าเฉลี่ยเปลี่ยนแปลงตลอดเวลา ไม่มีประโยชน์!

12.2 Autocorrelation — Volatility Clustering

อุปมา: ความนิยมของเพลง "เมื่อวานฮิต วันนี้มียังฮิตอยู่"


Autocorrelation วัดว่า "ข้อมูลวันนี้สัมพันธ์กับข้อมูลเมื่อวานแค่ไหน?"

สำหรับ Returns: เกือบ 0 (ทิศทางพรงนี้ทำนายไม่ได้จากรันนี้)

สำหรับ |Returns| หรือ Returns²: **สูงมาก!** — วันที่ผันผวนมักตามด้วยวันที่ผันผวน

$$\rho(k) = \text{Corr}(r_t, r_{t-k}) = \text{"return วันนี้สัมพันธ์กับ return k วันก่อนไหม?"}$$

ข้อมูล	Autocorrelation	ความหมาย
returns (r_t)	≈ 0	ทำนายทิศทางไม่ได้ (Efficient Market)
returns หรือ r_t^2	สูง! (~0.2-0.4)	วันที่ผันผวนมากมักตามด้วยวันผันผวนมาก



เชื่อมกับ Options

Volatility Clustering: ความผันผวนมักมาเป็น "กลุ่ม" — ช่วงที่ตลาดกลัว σ สูงนาน
นี่คือเหตุผลที่ GARCH model ทำงานได้ดี เพราะจำลอง clustering นี้

12.3 Moving Average & EWMA

อุปมา: คะแนนความนิยมแบบ "ใหม่กว่า = น้ำหนักมากกว่า"

Simple MA ให้น้ำหนักเท่ากันทุกวัน เหมือนนับคะแนนโหวตทุกคนเท่ากัน

EWMA ให้น้ำหนักวันล่าสุดมากกว่า เหมือน "คะแนนใหม่สำคัญกว่าคะแนนเก่า"

$\lambda=0.94$ หมายความว่า: ข้อมูล 1 เดือนที่แล้วมีน้ำหนักเหลือ $(0.94)^{20} \approx 29\%$ เท่านั้น

Simple MA Volatility: $\sigma = \text{std}(\text{returns ใน window } n \text{ วัน})$

$$\sigma^2_{\text{SMA}} = (1/n) \sum r^2_{t-i} \quad (\text{สมมติ } \mu \approx 0)$$

EWMA (Exponentially Weighted): ให้น้ำหนักข้อมูลล่าสุดมากกว่า

$$\sigma^2_t = \lambda \times \sigma^2_{t-1} + (1-\lambda) \times r^2_{t-1}$$

λ = decay factor (RiskMetrics ใช้ $\lambda = 0.94$)


ทำไม EWMA ถึงเขียนแบบนี้?

Expand ออกมา: $\sigma^2_t = (1-\lambda)[r^2_{t-1} + \lambda r^2_{t-2} + \lambda^2 r^2_{t-3} + \dots]$ = weighted average ของ r^2 ทั้งหมด

น้ำหนักของวันที่ k วันก่อน = $(1-\lambda)\lambda^k \rightarrow$ ลดลง exponentially $\rightarrow$ วันเก่าๆ มีผลน้อยมาก

ข้อดีสำคัญ: Update ง่ายมาก! ต้องจำแค่ σ^2 เมื่อวาน + r เมื่อวาน

- 1 โจทย์: $\lambda=0.94$, $\sigma^2_{t-1} = 0.0025$ ($\sigma=5\%$), $r_{t-1} = -3\% = -0.03$
- 2 $r^2_{t-1} = (-0.03)^2 = 0.0009$
- 3 $\sigma^2_t = 0.94 \times 0.0025 + 0.06 \times 0.0009$
- 4 $= 0.002350 + 0.000054 = \mathbf{0.002404}$
- 5 $\sigma_t = \sqrt{0.002404} \approx \mathbf{4.90\%}$ ลดลงนิดเดียวจาก 5% เพราะ $r^2=0.09\% < \sigma^2=0.25\%$



12.4 GARCH Model

อุปมา: นักพยากรณ์ที่จำ "ข่าวเมื่อวาน" + "ความแปรปรวนสะสม"

GARCH บอกว่า volatility วันนี้ขึ้นกับ 2 ปัจจัย:

1. **ข่าวเมื่อวาน** (r_{t-1}^2): ถ้าตลาดร่วงแรงเมื่อวาน → ความกังวลสูง
2. **Volatility เมื่อวาน** (σ_{t-1}^2): Volatility มี "inertia" — สูงแล้วมักยังคงสูงอยู่

$\alpha + \beta < 1 \rightarrow$ ในระยะยาว volatility กลับสู่ค่าเฉลี่ย $\omega/(1-\alpha-\beta)$

$$\sigma_t^2 = \omega + \alpha \times r_{t-1}^2 + \beta \times \sigma_{t-1}^2$$

ω = baseline variance (long-run variance component)

α = "ข่าวเมื่อวานส่งผลแค่ไหน" (news impact) ← sensitivity ต่อ shock

β = "volatility เมื่อวานส่งต่อแค่ไหน" (persistence)

$\alpha + \beta < 1 \rightarrow$ volatility mean-reverts! (ไม่ระเบิดออกไปเรื่อยๆ)

$$\omega \text{ (baseline)} + \alpha \times r_{t-1}^2 \text{ (ข่าว)} + \beta \times \sigma_{t-1}^2 \text{ (inertia)} = \sigma_t^2 \text{ (forecast)}$$

- 1 **GARCH(1,1) ตัวอย่าง:** $\omega=0.000002$, $\alpha=0.10$, $\beta=0.85$
- 2 $r_{t-1} = -2\% = -0.02$, $\sigma_{t-1}^2 = 0.0004$ ($\sigma=2\%$)
- 3 $r_{t-1}^2 = 0.0004$
- 4 $\sigma_t^2 = 0.000002 + 0.10 \times 0.0004 + 0.85 \times 0.0004$
- 5 $= 0.000002 + 0.000040 + 0.000340 = \mathbf{0.000382}$
- 6 $\sigma_t = \sqrt{0.000382} \approx \mathbf{1.95\%}$ (ลดลงจาก 2% เล็กน้อย เพราะ $r^2 = \sigma^2$ พอดี)
- 7 Long-run $\sigma = \sqrt{(\omega/(1-\alpha-\beta))} = \sqrt{(0.000002/0.05)} = \sqrt{0.00004} = \mathbf{0.63\%/วัน} \approx \mathbf{10\%/ปี}$

เชื่อมกับ Options

- **Forecast σ** → เทียบกับ Implied Volatility (IV) ของตลาด
- ถ้า GARCH forecast $<$ IV → options "แพงเกินไป" → อาจ **sell options**
- ถ้า GARCH forecast $>$ IV → options "ถูกเกินไป" → อาจ **buy options**
- **BS สมมติ σ คงที่** ← ผิด! GARCH บอกว่า σ เปลี่ยนตลอดเวลา

12.5 Mean Reversion

อุปมา: ยางยืดที่ดึงกลับสู่จุดกึ่งกลาง

Volatility ไม่วิ่งไปเรื่อยๆ มีแรงดึงกลับสู่ค่าเฉลี่ยระยะยาว (long-run volatility)

เหมือนยางยืด: ยิ่งดึงออกห่าง แรงดึงกลับยิ่งแรง

กฎ: $\alpha + \beta < 1 \rightarrow$ มี mean reversion; $\alpha + \beta = 1 \rightarrow$ ไม่มี mean reversion (IGARCH — ไม่เสถียร)

เชื่อมกับ Options

- ถ้า IV สูงมาก (เช่น หลัง market crash) $\rightarrow$ มักจะลดลง $\rightarrow$ **sell high IV**
- Long-term $\sigma \approx \sqrt{\omega/(1 - \alpha - \beta)}$ จาก GARCH $\rightarrow$ ใช้เป็น "anchor" ว่า IV ควรอยู่แถวไหน

บทที่ 13: วิธีเชิงตัวเลข — IV Solver

อุปมา: หาคำตอบที่ "สมการปิด" ไม่มี

ถ้าตลาดบอกว่า Call มีราคา ฿7.50 แต่ Black-Scholes สูตรให้ราคาเป็น σ → หา σ ที่ทำให้ราคา = ฿7.50

ปัญหา: ไม่มีสูตร "ย้อนกลับ" Black-Scholes แบบ closed-form → ต้องลองแล้วปรับ

วิธีเชิงตัวเลข = "การลองแบบฉลาด" ที่ converge หาคำตอบได้เร็ว

บางสมการแก้แบบ closed-form ไม่ได้ — ต้องใช้คอมพิวเตอร์หาคำตอบ ตัวอย่างสำคัญที่สุด: หา **Implied Volatility**

13.1 Bisection Method — "เกมทายตัวเลข"

อุปมา: เกมทาย "สูงไป/ต่ำไป"

ถ้าเพื่อนคิดตัวเลข 1-100 ไว้ในใจ กลยุทธ์ที่ดีที่สุดคือเดา 50 ก่อน

ถ้า "สูงไป" → เดา 25 ถัดไป; ถ้า "ต่ำไป" → เดา 75

ทำซ้ำ → ทุกครั้งช่วยให้แคบลงครึ่งหนึ่ง → หาเจอใน 7 ครั้งเสมอ ($\log_2(100) \approx 7$)

ถ้ารู้คำตอบอยู่ระหว่าง a กับ b → ลอง midpoint → ดูว่าคำตอบอยู่ครึ่งซ้ายหรือขวา → แบ่งครึ่งอีก

1. เลือก a, b ที่ $f(a) \times f(b) < 0$ (คนละเครื่องหมาย = คำตอบอยู่ระหว่าง)
2. $m = (a+b)/2$
3. ถ้า $f(m) \times f(a) < 0 \rightarrow b = m$, มิฉะนั้น $a = m$
4. ทำซ้ำจนกว่า $|b-a| < \text{tolerance}$

รอบ	a	b	m = (a+b)/2	f(m) = BS(m) - \$7.5	ช่วงใหม่
1	0.05	1.00	0.525	+3.2 (สูงไป)	[0.05, 0.525]
2	0.05	0.525	0.288	+0.8 (สูงไป)	[0.05, 0.288]
3	0.05	0.288	0.169	-0.5 (ต่ำไป)	[0.169, 0.288]
4	0.169	0.288	0.228	+0.1 (สูงไป)	[0.169, 0.228]
...	→ converge ไปที่ $\sigma \approx 0.20$ (IV = 20%)				

13.2 Newton-Raphson Method — เร็วกว่า!

อุปมา: ลงเขาโดยใช้แผนที่ความลาดชัน ไม่ใช่แค่ลองผิดลองถูก

Bisection: ลองครึ่งละครึ่ง — ช้า แต่แน่นอน

Newton-Raphson: ใช้ slope (derivative) ของฟังก์ชัน เพื่อ "คาด" ว่าคำตอบอยู่ตรงไหน

เหมือนลากเส้นสัมผัส (tangent) จากจุดที่อยู่ → เส้นสัมผัสตัดแกน x ที่ไหน → ลองจุดนั้น

$$x(n+1) = x(n) - f(x(n)) / f'(x(n))$$

สำหรับ IV Solver:

$$f(\sigma) = \text{BS_Price}(\sigma) - \text{Market_Price} \quad (\text{ต้องการให้} = 0)$$

$$f'(\sigma) = \text{Vega} \quad (\text{derivative ของราคาเทียบกับ } \sigma)$$

$$\sigma(n+1) = \sigma(n) - (\text{BS_Price}(\sigma(n)) - \text{Market_Price}) / \text{Vega}(\sigma(n))$$


ทำไม Vega ถึงเป็น derivative ที่ใช้?

Vega = $\partial V / \partial \sigma$ = อัตราการเปลี่ยนแปลงของราคา option ต่อการเปลี่ยน σ 1 หน่วย

Newton-Raphson ต้องการ $f'(\sigma) = d(\text{BS price})/d\sigma = \text{Vega}$ นั่นเอง!

ข้อดี: BS Vega มีสูตร closed-form → คำนวณเร็ว → Newton-Raphson converge ใน 3-5 รอบ!

- 1 **IV Solver:** Market price = ฿7.50, $S=100$, $K=100$, $T=0.25$, $r=5\%$
- 2 เดาเริ่มต้น: $\sigma_0 = 0.30$ (30%)
- 3 คำนวณ $BS(0.30) = \text{฿}8.20$ (แพงเกินไป ฿0.70)
- 4 $Vega(0.30) = \text{฿}20$ (ราคาเปลี่ยน ฿20 ต่อการเปลี่ยน σ 1 หน่วย)
- 5 $\sigma_1 = 0.30 - (8.20 - 7.50)/20 = 0.30 - 0.035 = \mathbf{0.265 \text{ (26.5%)}}$
- 6 $BS(0.265) \approx \text{฿}7.52 \rightarrow$ error เล็กมาก $\rightarrow$ 1 iteration อีกรอบ $\rightarrow \sigma \approx \mathbf{0.264 = IV \text{ 26.4\%}}$



เชื่อมกับ Options — IV Solver

Newton-Raphson ใช้ **Vega** เป็น derivative $\rightarrow$ converge ใน 3-5 รอบ!

ทุกครั้งที่คุณเห็น "IV = 25%" บนหน้าจอ Bloomberg — เบื้องหลังคือ Newton-Raphson กำลังทำงาน

13.3 Numerical Differentiation

ทำไมต้องคำนวณ derivative เชิงตัวเลข?

BS model มีสูตร closed-form สำหรับ Greeks แต่ model อื่นๆ (Local Vol, Stochastic Vol) ไม่มี

แนวคิด: Delta = "ถ้า S เพิ่ม $h \rightarrow V$ เพิ่มเท่าไร?" $\rightarrow$ หาค่า $h \rightarrow$ ได้ approximate derivative

$$f'(x) \approx [f(x+h) - f(x-h)] / (2h) \quad (\text{central difference} - \text{แม่นยำกว่า forward difference})$$

เชื่อมกับ Options

คำนวณ Greeks จาก pricing model ที่ไม่มีสูตร closed-form:

Delta $\approx [V(S+h) - V(S-h)] / (2h)$ ใช้ $h = \$0.01$ หรือ $\$0.001$

Gamma $\approx [V(S+h) - 2V(S) + V(S-h)] / h^2$ (second derivative)

บทที่ 14: Stochastic Processes & Ito's Lemma

อุปมา: ฝุ่นละอองในน้ำ — ราคาหุ้นก็เคลื่อนที่แบบสุ่มเช่นกัน

Robert Brown ค้นพบ "Brownian Motion" ในปี 1827 โดยมองกล้องจุลทรรศน์ดูละอองเรณูในน้ำ — มันเคลื่อนที่สุ่มตลอดเวลา


Einstein อธิบายในปี 1905 ว่าเกิดจากโมเลกุลน้ำชนทุกทิศทาง

Bachelier (1900) ใช้ Brownian Motion อธิบายราคาหุ้นเป็นคนแรก — ก่อน Einstein อีก!

บทนี้คือ "ยอดเขา" ของเล่ม — เข้าใจบทนี้ = เข้าใจที่มาของ Black-Scholes

14.1 Random Walk & Binomial Tree

Random Walk: ทุก step ราคาขึ้น (+1) หรือลง (-1) ด้วยโอกาส 50/50



Binomial Tree: ราคาขึ้น u หรือลง d ในแต่ละ step

$$u = e^{\sigma\sqrt{\Delta t}} \text{ (up factor)}$$

$$d = e^{-\sigma\sqrt{\Delta t}} = 1/u \text{ (down factor)}$$

$$p^* = (e^{r\Delta t} - d) / (u - d) \quad \leftarrow \text{risk-neutral probability}$$

ทำไม $u = e^{(\sigma\sqrt{\Delta t})}$?

ต้องการให้ u, d สอดคล้องกับ volatility σ ของหุ้น

เงื่อนไข: Variance ใน 1 step = $\sigma^2\Delta t \rightarrow p(1-p)(u-d)^2 = \sigma^2\Delta t$

การเลือก $u=e^{(\sigma\sqrt{\Delta t})}$ ทำให้เงื่อนไขนี้สอดคล้อง และ $u \times d = 1$ (recombining tree!)

- 1 **Binomial ตัวอย่าง:** $S=100, K=100, \sigma=20\%, r=5\%, T=1\text{ปี}, n=1\text{ step}$
- 2 $\Delta t=1, u=e^{(0.2 \times 1)}=1.2214, d=1/u=0.8187$
- 3 $p^* = (e^{(0.05 \times 1)} - 0.8187) / (1.2214 - 0.8187) = (1.0513 - 0.8187) / 0.4027 = 0.578$
- 4 $S(u)=122.14, S(d)=81.87$; Payoff Call: $C(u)=\max(22.14, 0)=22.14, C(d)=0$
- 5 $C = e^{(-0.05 \times 1)} \times [0.578 \times 22.14 + 0.422 \times 0] = 0.9512 \times 12.80 = \text{฿}12.18$

เชื่อมกับ Options — Binomial Option Pricing

1. สร้าง tree ราคาหุ้น n steps
 2. คำนวณ payoff ที่ปลาย tree (วันหมดอายุ)
 3. ย้อนกลับทีละ step: $V = e^{-r\Delta t} \times [p^* \times V(\text{up}) + (1-p^*) \times V(\text{down})]$
 4. ค่าที่ node แรก = **ราคา Option!**
- เมื่อ $n \rightarrow \infty \rightarrow$ converge สู่ **Black-Scholes price**

14.2 Risk-Neutral Pricing

อุปมา: ประกันภัย — ราคาไม่ขึ้นกับว่าคุณจะเกิดอุบัติเหตุหรือไม่

บริษัทประกัน define ราคากรมธรรม์จาก "expected payout" โดยไม่ต้องรู้ว่าคุณ "โชคดี" หรือ "โชคร้าย"

Risk-neutral pricing ทำแบบเดียวกัน: คำนวณ "expected option payoff" ในโลก risk-neutral

เหตุผลที่ใช้ได้: เราสามารถ *replicate* option payoff ด้วย stock + bond $\rightarrow$ ราคาต้อง = cost of replication

หลักการสำคัญที่สุดใน Derivatives Pricing

เราสามารถ price option ได้โดย **ไม่ต้องรู้ว่าหุ้นจะขึ้นหรือลง!**

ทำได้โดยใช้ "โลก risk-neutral" ที่สมมติว่า:

- ทุกสินทรัพย์มี expected return = risk-free rate (r)
- ใช้ probability p^* (ไม่ใช่ real probability p)
- **Option Price** = $e^{-rT} \times E^*[Payoff]$

ทำไมใช้ได้? — No-Arbitrage Argument

เพราะเราสามารถ **replicate** payoff ของ option ได้ด้วย stock + bond (hedging)

ดังนั้นราคาของ option ต้อง = ต้นทุนของ replicating portfolio

ต้นทุนนี้ **ไม่ขึ้นกับว่าหุ้นจะขึ้นหรือลง** → ไม่ต้องรู้ real probability!

14.3 Brownian Motion

Brownian Motion $W(t)$ = continuous limit ของ random walk สมบัติ:

- $W(0) = 0$ (เริ่มที่ 0)
- Independent increments: $W(t_2) - W(t_1)$ ไม่ขึ้นกับ $W(t_1) - W(t_0)$
- $W(t_2) - W(t_1) \sim \text{Normal}(0, t_2 - t_1)$ → ยิ่งเวลานาน *variance* ยิ่งมาก (ไม่ใช่ standard deviation)
- Continuous paths — ไม่กระโดด

ทำไม Variance $\propto t$ ไม่ใช่ Std $\propto t$?

random walk n steps: แต่ละ step ± 1 → หลัง n steps, std = $\sqrt{n}$ (จาก CLT)

ถ้า 1 ปี = n steps, 1 วัน = 1 step → std(yearly) = $\sqrt{252} \times \text{std(daily)}$

นี่คือเหตุผลที่เราคูณ σ ด้วย $\sqrt{T}$ ไม่ใช่ T เมื่อ scale ตามเวลา!

14.4 Geometric Brownian Motion (GBM)

อุปมา: เรือในทะเลคลื่น

ราคาหุ้น = เรือที่ลอยในทะเล:

- **Drift (μdt)** = กระแสน้ำ: ดันเรือไปทิศหนึ่งอย่างสม่ำเสมอ
- **Volatility (σdW)** = คลื่น: สุ่มขึ้นลง ยิ่งคลื่นแรง (σ สูง) เรือก็โคลงมาก

ทำไม "Geometric"? เพราะคลื่นใหญ่เล็กสัมพันธ์กับ *ขนาดของเรือ* — หุ้น \$1000 ขยับ \$20 ไม่เหมือนหุ้น \$10 ขยับ \$0.20

$$dS/S = \mu dt + \sigma dW$$

อ่านว่า: "% การเปลี่ยนแปลงราคา = drift + สุ่ม"

- μdt = drift $\times$ เวลา $\rightarrow$ deterministic (คาดเดาได้)
- σdW = volatility $\times$ Brownian shock $\rightarrow$ stochastic (สุ่ม)

ทำไม Geometric? $\rightarrow$ ราคาเป็น Lognormal!

เพราะ dS/S (% change) เป็น normal ไม่ใช่ dS (absolute change)

$\rightarrow$ ราคา S เป็น **Lognormal** (เชื่อมกับบท 6.4!) $\rightarrow$ ราคา > 0 เสมอ — ไม่สามารถติดลบได้!

14.5 Ito's Lemma — "Chain Rule ของโลกสุ่ม"

Chain Rule ธรรมดา vs Ito's Lemma — ต่างกันอะไร?

Chain Rule ปกติ: ถ้า $V = V(S,t)$ และ S เปลี่ยนไป $dS \rightarrow dV = (\partial V/\partial t)dt + (\partial V/\partial S)dS$

แต่ในโลกสุ่ม: S ขยับแบบ Brownian Motion $\rightarrow dS$ มีความ "ผันผวน" ในตัวเอง

ผลลัพธ์: $(dS)^2 \neq 0$ แต่ $= \sigma^2 S^2 dt \rightarrow$ ต้องบวก "ค่าแก้" $\frac{1}{2}\Gamma(dS)^2$ เพิ่มเข้าไป!

ถ้า S เป็น stochastic process และ $V(S,t)$ เป็นฟังก์ชันของ S :

$$dV = (\partial V/\partial t)dt + (\partial V/\partial S)dS + \frac{1}{2}(\partial^2 V/\partial S^2)(dS)^2$$

$$dS/S = \mu dt + \sigma dW$$

$\rightarrow$

$$(dW)^2 = dt$$

$\rightarrow$

$$(dS)^2 = \sigma^2 S^2 dt$$

$\rightarrow$

ไม่ตัดทิ้งได้!

$\rightarrow$

บวก $\frac{1}{2}\sigma^2 S^2 dt$ ทำไมมี term $\frac{1}{2}(\partial^2 V/\partial S^2)(dS)^2$ พิเศษ?ในโลกปกติ $(dt)^2 \approx 0$ ตัดทิ้งได้ แต่ในโลกสุ่ม $(dW)^2 = dt \neq 0!$ ดังนั้น $(dS)^2 = (\mu S dt + \sigma S dW)^2 \approx \sigma^2 S^2 dt$ (เอา dt^2 และ $dt \times dW$ ออก เพราะเล็กกว่า dt)นี่คือเหตุผลว่าทำไม **Gamma** สำคัญ — มันเป็น "ค่าแก้ม" ที่โลกสุ่มบังคับให้ใส่

- 1 ตัวอย่าง Ito: หา $d(\ln S)$ เมื่อ $dS/S = \mu dt + \sigma dW$
- 2 ตั้ง $V = \ln(S)$, $\partial V/\partial t = 0$, $\partial V/\partial S = 1/S$, $\partial^2 V/\partial S^2 = -1/S^2$
- 3 $dV = 0 \cdot dt + (1/S)dS + \frac{1}{2}(-1/S^2)(dS)^2$
- 4 $= (1/S)(\mu S dt + \sigma S dW) + \frac{1}{2}(-1/S^2)(\sigma^2 S^2 dt)$
- 5 $= \mu dt + \sigma dW - \frac{1}{2}\sigma^2 dt = (\mu - \frac{1}{2}\sigma^2)dt + \sigma dW$
- 6 นี่คือ "log return ของ GBM" → Normal distribution → S เป็น Lognormal!

14.6 Black-Scholes PDE

ที่มาของ BS PDE — Hedging Argument

สร้าง portfolio: Long 1 option + Short Δ หุ้น → portfolio นี้ "ไม่มีความเสี่ยง" (delta neutral)

Portfolio ไม่มีความเสี่ยง → ต้องได้ผลตอบแทน = risk-free rate (ไม่จันมี arbitrage!)

นำหลักการนี้ + Ito's Lemma → ได้ PDE ที่ทุก option ต้องสอดคล้อง

ใช้ Ito's Lemma + hedging argument → ได้สมการ:

$$\partial V/\partial t + \frac{1}{2}\sigma^2 S^2 (\partial^2 V/\partial S^2) + rS(\partial V/\partial S) - rV = 0$$

แต่ละ term คือ Greek:

Term	Greek	ความหมาย
$\partial V / \partial t$	Theta (Θ)	Time decay — ราคา option ลดตามเวลา
$\frac{1}{2}\sigma^2 S^2 (\partial^2 V / \partial S^2)$	$\frac{1}{2}\sigma^2 S^2 \times$ Gamma (Γ)	Convexity benefit จาก volatility
$rS(\partial V / \partial S)$	$rS \times$ Delta (Δ)	Cost of carry ของหุ้นที่ hedge
$-rV$	—	Discounting — ต้นทุนการถือ option

Greeks Balance! Theta vs Gamma Trade-off

$$\Theta + \frac{1}{2}\sigma^2 S^2 \Gamma + rS\Delta = rV$$

หมายความว่า: Time decay (Theta) **ถูก offset** ด้วย Convexity gain (Gamma term)

สำหรับ Long Option: Theta เป็นลบ (จ่าย time decay) แต่ Gamma term เป็นบวก (ได้ convexity benefit)

ไม่มี "free lunch" — ได้ Gamma ต้องจ่าย Theta

- 1 **ตรวจสอบ BS PDE:** Call ATM, $S=100$, $\sigma=20\%$, $r=5\%$, $T=0.5$ ปี
- 2 $\Delta \approx 0.55$, $\Gamma \approx 0.025/\text{฿}$, $\Theta \approx -\text{฿}4.5/\text{ปี}$, $V \approx \text{฿}8.0$
- 3 Theta term: -4.5
- 4 Gamma term: $\frac{1}{2} \times 0.04 \times 10000 \times 0.025 = \frac{1}{2} \times 10 = +5.0$
- 5 $rS\Delta$ term: $0.05 \times 100 \times 0.55 = +2.75$
- 6 rV : $0.05 \times 8.0 = 0.40$
- 7 $-4.5 + 5.0 + 2.75 \approx 3.25 \approx 0.40$ (ไม่เท่ากันเป๊ะเพราะ approximate) ✓ ทิศทางถูก!

แบบฝึกหัด Part VI

โจทย์ 1: EWMA Volatility Update

กำหนด $\lambda = 0.94$, $\sigma_{t-1}^2 = 0.0009$ ($\sigma = 3\%$), $r_{t-1} = +4\% = 0.04$

คำนวณ σ_t^2 และ σ_t ด้วย EWMA — volatility เพิ่มขึ้นหรือลด?

▶ ดูเฉลย

โจทย์ 2: Newton-Raphson IV Solver — 1 Step

Market price ของ Call = ฿5.00

$\sigma_0 = 0.25$ (25%), $BS(0.25) = ฿5.80$, $Vega(0.25) = ฿25$

คำนวณ σ_1 ด้วย Newton-Raphson แล้วตรวจว่าเข้าใกล้ IV ใหม่?

▶ ดูเฉลย

โจทย์ 3: Ito's Lemma — หา dV

กำหนด $V = S^2$ (portfolio value proportional to S squared)

ราคาหุ้น: $dS = \mu S dt + \sigma S dW$ (GBM)

ใช้ Ito's Lemma หา dV — มี term พิเศษอะไรเพิ่มมาบ้าง?

▶ ดูเฉลย

สรุป Part VI

- ✓ Autocorrelation → Volatility Clustering — r^2 มี autocorrelation สูง
- ✓ EWMA: $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1-\lambda)r_{t-1}^2 \rightarrow$ น้ำหนักข้อมูลล่าสุดมากกว่า
- ✓ GARCH: $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2 \rightarrow$ News Impact + Persistence
- ✓ Mean Reversion → Long-run $\sigma = \sqrt{(\omega/(1-\alpha-\beta))}$
- ✓ Bisection: แบ่งครึ่งทีละรอบ → IV Solver ช้าแต่แน่นอน
- ✓ **Newton-Raphson: $\sigma(n+1) = \sigma(n) - (BS-Mkt)/Vega \rightarrow$ IV Solver เร็ว**
- ✓ Random Walk → Binomial Tree → Option Pricing (p^* = risk-neutral prob)
- ✓ **Risk-Neutral: Price = $e^{-rT} \times E^*[Payoff]$ — ไม่ต้องรู้ทิศทางหุ้น!**
- ✓ GBM: $dS/S = \mu dt + \sigma dW \rightarrow$ Lognormal price
- ✓ **Ito's Lemma: $dV = \Theta dt + \Delta dS + \frac{1}{2}\Gamma(dS)^2 \rightarrow (dW)^2=dt$ เป็น key!**
- ✓ **BS PDE: $\Theta + \frac{1}{2}\sigma^2 S^2 \Gamma + rS\Delta = rV$ — Theta-Gamma Trade-off!**

จบ Part VI

Part VII: ประมวลรวม → อ่าน Black-Scholes ออกทุกตัว + Monte Carlo