

อ่านกระดาน Reading the Book

Order Flow & Microstructure สำหรับรายย่อย — ฉบับรวมเล่ม 20 ตอน

เลนส์ execution ของซีรีส์ · เทรด "ตรงไหน / เมื่อไหร่ / ต้นทุนจริงเท่าไหร่"

6 องค์ + ภาคเครื่องมือ · ตัวอย่างคริปโต (Binance/Bybit L2 ฟรี)



สารบัญ

1. Part 0 — กระดานคืออะไร
2. Part 1 — กายวิภาคของคิว
3. Part 2 — 3 เหตุการณ์ที่ขยับกระดาน
4. Part 3 — Bid-Ask Spread แยกส่วน
5. Part 4 — กระดานเชื่อถือได้แค่ไหน
6. ภาคทบทวน — สถิติพื้นฐาน
7. Part 5 — Order Book Imbalance (OBI)
8. Part 6 — ทำไม Market Order สำคัญ
9. Part 7 — OFI & Price Impact
10. Part 8 — VPIN ความเป็นพิษของ flow
11. Part 9 — Market Making พื้นฐาน
12. Part 10 — Optimal Market Making
13. Part 11 — ลงมือจริงในคริปโต
14. Part 12 — Grid Trading
15. Part 13 — Statistical Arbitrage ด้วย OFI
16. Part 14 — Cross-Exchange Arbitrage
17. Part โบนัส — เครื่องจักรอ่านกระดาน
18. บทปิด — อ่านกระดานจริง 1 รอบ
19. องค์กร VI · EX-1 — Execution & Implementation Shortfall
20. องค์กร VI · EX-2 — Almgren-Chriss & ตารางการทยอยส่ง
21. องค์กร VI · EX-3 — ลงมือจริงรายย่อยคริปโต

อ่านกระดาน

Reading the Book

Part 0: กระดานคืออะไร — "ราคา" จริง ๆ มาจากไหน

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์
อ่านจบแล้วเข้าใจ bid / ask / spread / mid และอ่านกระดานคริปโตเป็น

Part 0 — กระดานคืออะไร

✖ อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > ตัดสินใจเข้า-ออก > ต่อยอด/คุมเสี่ยง

🎯 อ่านจบ Part นี้คุณจะได้

- เข้าใจว่า "ราคา" บนจอจริง ๆ มาจากการ **จับคู่คำสั่งซื้อขาย** ในกระดาน ไม่ใช่ตัวเลขลอย ๆ
- แยก bid / ask / spread / mid ออกจากกัน และอ่านค่าจากกระดานจริงได้
- รู้ว่า "ไม่มีราคาเดียว" — มีราคาที่ซื้อได้ (ask) กับราคาที่ขายได้ (bid) เสมอ
- แยก order-driven market (คริปโต/หุ้น) กับ quote-driven market (มี dealer ขานราคา)

📖 "Market Microstructure" คืออะไร — และทำไมทั้งเล่มนี้คือมัน


Market microstructure = สาขาที่ศึกษาว่า "ราคาเกิดขึ้นได้ยังไงจริง ๆ" ในระดับจุลภาค คือกลไกการจับคู่คำสั่งซื้อขายในกระดาน ต่างจากการวิเคราะห์แบบ macro/ปัจจัยพื้นฐาน (ที่ถามว่า "ราคา ควรเป็นเท่าไร") — microstructure ถามว่า "ระหว่างที่ราคาขยับ เกิดอะไรในกระดาน ใครซื้อใครขาย และเราเข้า-ออกยังไงให้ต้นทุนต่ำ เสี่ยงโดนเอาเปรียบ"

ทั้งเล่มนี้คือ microstructure ฉบับปฏิบัติสำหรับรายย่อย — รากฐานวิชาการมาจาก Glosten-Milgrom, Kyle, O'Hara แต่เล่าด้วยภาษาและตัวอย่างคริปโตที่ลงมือทำได้จริง

เริ่มจากร้านทอง

ลองนึกถึงร้านทองในตลาด — หน้าร้านเขียน **2 ราคาเสมอ**: ราคาที่ร้าน "รับซื้อ" จากคุณ (ต่ำกว่า) กับราคาที่ร้าน "ขายให้" คุณ (สูงกว่า) ส่วนต่างนั้นคือกำไรของร้าน

กระดานเทรด (order book) ก็คือร้านทองที่มีคนนับพันมายื่นเสนอราคาพร้อมกัน — และคุณเลือกได้ว่าจะเป็น "คนตั้งป้ายราคา" หรือ "คนเดินเข้าไปรับราคา"



กระดานคือบัญชีคำสั่งที่ยังไม่ถูกจับคู่

ทุกคนส่ง "ความตั้งใจจะซื้อ/ขาย" เข้ามา ระบบเรียงไว้เป็นกระดาน:

- **ฝั่งซื้อ (bids)** — คนอยากซื้อ เรียงจากราคาแพงสุดเข้าหาถึงกลาง (สีเขียว)
- **ฝั่งขาย (asks / offers)** — คนอยากขาย เรียงจากราคาถูกสุดเข้าหาถึงกลาง (สีแดง)



ภาพ 0.1 · กระดาน LOB (เทมเพลตแม่ของทั้งเล่ม) — เป็นภาพ *schematic* เพื่อสื่อแนวคิด ความสูงของแท่งไม่ใช่โปรไฟล์ depth จริง

ศัพท์ที่ต้องจำ

ศัพท์	ความหมาย
Best bid	ราคาซื้อที่แพงสุด (เขียวที่ใกล้กึ่งกลางสุด) = 59,997
Best ask	ราคาขายที่ถูกสุด (แดงที่ใกล้กึ่งกลางสุด) = 60,003
Spread	ช่องว่างระหว่างสองฝั่ง = "ค่าผ่านทาง" เข้า-ออกทันที = 6
Mid	จุดกึ่งกลาง = ราคาอ้างอิงที่ยุติธรรมสุด (แต่เทรดที่ราคานี้จริง ๆ ไม่ได้)

$\text{Spread} = \text{BestAsk} - \text{BestBid} = 60,003 - 59,997 = 6 \text{ USDT}$

$\text{Mid Price} = (\text{BestAsk} + \text{BestBid})/2 = (60,003 + 59,997)/2 = 60,000$


$\text{Spread (bps)} = \text{Spread} / \text{Mid} \times 10,000 = 6 / 60,000 \times 10,000 = 1.0 \text{ bps}$

⚠ กับดักมือใหม่ — "ราคาเดียว" ที่ไม่มีจริง

มือใหม่มักคิดว่า "ราคา BTC ตอนนี้ = 60,000" เป็นตัวเลขเดียว — **ผิด!** ถ้าจะ "ซื้อทันที" คุณจ่าย best ask (60,003) ถ้าจะ "ขายทันที" คุณได้ best bid (59,997) ตัวเลข 60,000 ที่เว็บแสดงมักเป็น last trade หรือ mid ซึ่งคุณเทรดที่ราคานี้ไม่ได้ — การเอา last price ไปคิดกำไรแล้วลืม spread ทำให้ตอนปิดจริงขาดทุนกว่าที่คิด

Order-driven vs Quote-driven

คริปโตเป็น order-driven แท้ ๆ — ไม่มี dealer กลาง ทุกคน (รวมคุณ) ช่วยกันสร้างกระดาน ส่วนตลาดแบบเก่าบางที่เป็น quote-driven มี dealer คอยขานราคาให้



📄 งานวิจัยรองรับ

Glosten & Milgrom (1985) วางรากฐานว่า "spread มีอยู่เพราะผู้ตั้งราคาไม่รู้ว่าคนที่มาเทรดมีข้อมูลลับหรือไม่" — ราคาสองฝั่งจึงเป็นกลไกป้องกันตัวของตลาด ไม่ใช่แค่ค่าธรรมเนียม (จะลงลึกใน Part 3 เรื่ององค์ประกอบของ spread)

🔗 เชื่อมโยงเล่มอื่น


Mid price ที่เรียนตรงนี้คือ "underlying price" เดียวกับที่ใช้คำนวณ payoff ในเล่ม **Payoff Mastery (pm)** — เวลาคิดกำไรขาดทุนจริง อย่าลืมว่าราคาเข้า-ออกไม่ใช่ mid แต่เป็น ask/bid (ต้นทุน spread กินกำไรจริง)

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

เปิด Binance หน้า BTC/USDT order book ดู best bid และ best ask จดค่า แล้วคำนวณ **spread (USDT)** และ **spread (bps)** ด้วยมือ จากนั้นทำซ้ำกับเหรียญเล็ก (อันดับ 100+) แล้วเทียบว่า spread (bps) ต่างกันแค่ไหน — คุณจะเห็นทันทีว่าเหรียญเล็ก "ค่าผ่านทาง" แพงกว่ามาก

ภาพรวม: เล่มนี้จะพาคุณเดินทางยังไง

ทั้งเล่มร้อยเป็น **เส้นเดียว 4 ด่าน** — ทุกตอนจะมีแถบ 🚫 บอกว่าคุณอยู่ด่านไหน และมีกล่อง "🎯 กับเคสของเรา" (เข้า long BTC ด้วย \$5,000) ให้เห็นการใช้จริง จนจบที่บท "อ่านกระดานจริง 1 รอบ" ที่รวมทุกอย่างเป็น workflow เดียว:



ภาพ 0.4 · เส้นทางทั้งเล่ม — จบที่บท "อ่านกระดานจริง 1 รอบ" ที่รวมทุกอย่าง

ส่งต่อ → Part 1: ภาวะวิกฤตของคิว — ทำไม "อยู่ต้นคิว" ถึงมีค่าเป็นเงิน

อ่านกระดาน

Reading the Book

Part 1: กายวิภาคของคิว — ทำไม "อยู่ต้นคิว" ถึงมีค่าเป็นเงิน

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์

เจาะลึกราคาเดียวว่ามีคิวซ่อนอยู่ — price-time priority, tick, depth และมูลค่าของการได้ยืนต้นคิว



 [อ่านกระดาน](#) > [รู้ใครกดดัน & เชื่อได้แค่ไหน](#) > [ตัดสินใจเข้า-ออก](#) > [ต่อยอด/คุมเสี่ยง](#)

Part 1 — กายวิภาคของคิว

🔗 ต่อจากตอนก่อน

เพิ่งรู้มา: Part 0 วางนิยาม microstructure — กระดาน (order book) คือสนามที่คำสั่งซื้อขายมาเจอกัน

- **ตอนนี้จะเติม:** ชุมเข้าไปใน "ราคาเดียว" บนกระดาน ว่าจริง ๆ เป็นคิวของหลายคนเรียงกัน และทำไม "อยู่ต้นคิว" จึงมีมูลค่าเป็นเงิน

🎯 อ่านจบ Part นี้คุณจะได้

- เห็นว่า "ราคาหนึ่งราคา" บนกระดานจริง ๆ เป็น **คิวของคำสั่งหลายคน** ไม่ใช่ตัวเลขก้อนเดียว
- เข้าใจกฎจัดลำดับ **price-time priority (FIFO)** — ราคาดีกว่าได้ก่อน ราคาเท่ากันใครมาก่อนได้ก่อน
- อ่าน **tick size** และ **depth** (ความลึกหลายชั้น) ออกจากกระดานได้
- เข้าใจ **queue value** — ทำไมการ "อยู่ต้นคิว" จึงแปลว่าได้ fill ก่อนและมีมูลค่าเป็นเงิน

เริ่มจากคิวซื้อ iPhone รุ่นใหม่

ตอน iPhone รุ่นใหม่เปิดขาย คนไปต่อแถวหน้าร้านตั้งแต่ตี 4 — **ทุกคนยอมจ่ายราคาป้ายเท่ากัน** แต่ "ใครได้เครื่องก่อน" ขึ้นกับตำแหน่งในแถว คนที่มาก่อนยืนต้นแถว ได้ของชัวร์ คนท้ายแถวอาจอดถ้าของหมด

กระดานเทรดก็มีแถวแบบนี้ในทุกราคา — ที่ราคา 59,997 อาจมีคนตั้งซื้อรออยู่ 50 คน เรียงตามเวลาที่ส่งคำสั่งเข้ามา เมื่อมีคนขายทันที (market sell) เข้ามา "ตัดของ" คนต้นแถวได้ขายของก่อนเสมอ



ในหนึ่งราคา มี "คิว" ซ่อนอยู่


กระดานที่เราเห็นแบบสรุปจะบอกแค่ "ที่ราคา 59,997 มี 12 BTC รออยู่" — แต่ 12 BTC นั้นจริง ๆ คือคำสั่งของหลายคนเรียงต่อกัน เช่น 3 + 5 + 1 + 2 + 1 ตามลำดับเวลา ระบบจับคู่จะ "กิน" จากหัวคิวเสมอ

ราคา 59,997 (best bid): [3 BTC][5 BTC][1 BTC][2 BTC][1 BTC] รวม = 12 BTC

หัวคิว —————> ท้ายคิว

market sell 4 BTC เข้ามา → กิน [3] หมด + กิน 1 จาก [5] → เหลือ [4][1][2][1] = 8 BTC

Zoom-in: คิวที่ราคา 59,997




ภาพ 1.1 · คิวภายในหนึ่งราคา (zoom-in)

กฎจัดลำดับ: Price-Time Priority (FIFO)

ระบบจับคู่ของกระดาน (matching engine) ใช้กฎ 2 ชั้นในการเลือกจะให้ใครได้ fill ก่อน:

- Price priority (ราคาก่อน):** ฝั่งซื้อ ราคาแพงกว่าได้ก่อน · ฝั่งขาย ราคาถูกกว่าได้ก่อน — เพราะเป็นราคาที่ "ตึงตูด" คู่ค้ามากที่สุด
- Time priority (เวลาเป็นตัวตัดสินเมื่อราคาเท่ากัน):** ที่ราคาเดียวกัน ใครส่งคำสั่งมาก่อนอยู่ต้นคิวก่อน = FIFO (First In, First Out)



ภาพ 1.2 · ผังตัดสินใจ price-time priority

📌 ข้อสังเกต — ไม่ใช่ทุกตลาดใช้ FIFO ล้วน

คริปโตสโตนส่วนใหญ่ (Binance/Bybit) ใช้ **price-time priority (FIFO)** ตรง ๆ แต่ตลาดอนุพันธ์บางแห่งใช้ **pro-rata** (แบ่ง fill ตามสัดส่วนขนาด ไม่ใช่ตามเวลา) ในเล่มนี้เรายึด FIFO เป็นหลักเพราะเป็นกติกาของกระดานคริปโตที่รายย่อยเจอจริง

Tick size และ Depth


Tick size คือ "ขั้นต่ำสุด" ที่ราคาขยับได้ — เช่น BTC/USDT อาจมี tick = 0.1 USDT แปลว่าราคาไปได้ทีละ 60,000.0 → 60,000.1 → 60,000.2 ไม่มีราคาแทรกกลาง tick เล็ก = ราคาละเอียด คิวกระจายหลายชั้น · tick ใหญ่ = ราคาหยาบ คิวอัดแน่นในไม่กี่ชั้น (สำคัญมากใน Part 5 เรื่อง large-tick)

Depth คือปริมาณที่รออยู่ "ลึกลงไป" จาก best หลายชั้นราคา ไม่ใช่แค่ชั้นบนสุด — กระดานที่ลึกลงหมายถึงรับแรงซื้อขายก่อนใหญ่ได้โดยราคาไม่กระเด็น

$Queue(P) = \Sigma$ ปริมาณของทุกคำสั่งที่ตั้งอยู่ที่ราคา P

$Depth(N) = \Sigma$ ปริมาณรวมของ N ชั้นราคาแรกนับจาก best (ทั้งฝั่ง)

ตัวอย่าง bid 5 ชั้น (ตามภาพ 1.3): 7 + 11 + 15 + 9 + 12 → Depth(5) ฝั่งซื้อ = 54 BTC



ภาพ 1.3 · Depth profile 5 ชั้น (ต่อยอดเทมเพลตแม่กระดาน LOB)

Queue Value — ทำไมดันคิวจึงมีค่าเป็นเงิน


คำสั่ง limit ที่อยู่ดันคิวได้เปรียบ 2 อย่าง: (1) **ได้ fill ก่อน** เมื่อมี taker เข้ามา และ (2) **โอกาสถูก fill สูงกว่า** เพราะ taker อาจไม่ลืกวพอจะถึงคิวหลัง ความน่าจะเป็นที่ "เราจะได้ fill" ขึ้นกับว่ามี volume ฝั่งตรงข้าม

มากกว่าปริมาณที่อยู่ หน้าเรา หรือไม่

Q_ahead = ปริมาณทั้งหมดที่อยู่ "หน้าเรา" ในคิวเดียวกัน

เราได้ fill ก็ต่อเมื่อ: ปริมาณ taker ที่เข้ามาเกินคิวนี้ $> Q_ahead$

ยิ่ง Q_ahead น้อย (อยู่ต้นคิว) $\rightarrow P(\text{fill})$ สูง $\cdot$ ต้องรอ adverse move น้อยลง



ต้อง market sell $> 12 \text{ BTC}$ คิวถึงจะถึง "YOU" แล้วได้ fill

ถ้าราคาวิ่งหนีก่อน 12 BTC ถูกกินหมด $\rightarrow$ คำสั่งค้าง (queue risk)

ภาพ 1.4 $\cdot$ Queue value & queue risk — Q_ahead หน้าเราต้องถูกกินก่อนเราถึงได้ fill

นี่คือ "ราคาที่จ่ายไม่เห็น" ของการเป็น maker: ถ้ามาช้า Q_ahead เยอะ คุณอาจต้องรอนาน และระหว่างรอราคาอาจวิ่งหนี ทำให้คำสั่งไม่ได้ fill เลย — เรื่องนี้คือหัวใจของ market making ใน Part 9–11

⚠ กีบดักมือใหม่ — "ตั้ง limit แล้วชัวร์"

มือใหม่ชอบคิดว่า "ตั้ง limit ที่ราคานี้ เดี๋ยวก็โดน fill แน่ ๆ" — **ผิด!** limit order ไม่การันตี fill มันการันตีแค่ "ราคา" ที่จะได้ ถ้าได้ fill คุณยังต้องรอนาน Q_ahead หน้าคุณถูกกินหมดก่อน ถ้าราคาวิ่งหนีไปก่อนคำสั่งคุณค้างเติ่ง นี่คือ **queue risk** — ความเสี่ยงที่มือใหม่มองข้ามตลอด แล้วงงว่าทำไม "ตั้งราคาดีแล้วไม่ติด"

📄 งานวิจัยรองรับ

งานสาย queue dynamics เช่น **Lu & Abergel (2018)** และ **Queue-Reactive Hawkes (arXiv 1901.08938)** ชี้ว่าพฤติกรรมของคิวไม่ได้สุ่มแบบไร้ความจำ — อัตราการเติม/ถอน/กินคิวขึ้นกับ "สภาพคิวปัจจุบัน" เอง (queue-reactive) และ **Importance of Order Sizes (arXiv 2405.18594)** เน้นว่า "ขนาด" ของแต่ละคำสั่งในคิวมีผลต่อการพยากรณ์ ไม่ใช่แค่ปริมาณรวม — ตอกย้ำว่า Q_ahead เป็นตัวแปรจริงที่วัดได้

🔗 เชื่อมโยงเล่มอื่น

Queue value และ Q_ahead ที่เรียนตรงนี้เป็นรากฐานของ **market making (Part 9–11)** — รายได้ของ MM คือ "ครึ่ง spread" ที่ได้จากการอยู่ในคิวแล้วถูก fill ส่วน queue risk เชื่อมตรงไปยังการคิด P&L และ inventory ในเล่ม **Payoff Mastery (pm)** เพราะคำสั่งที่ไม่ได้ fill = position ที่ไม่เกิด = แผนเทรดพัง

🎯 กับเคสของเรา

เราอยากเข้า long BTC/USDT \$5,000 ให้ได้ราคาดีโดยวาง limit — แต่ limit ที่เราวางจะไปต่อ "ท้ายคิว" ของราคานั้น ถ้าราคาวิ่งขึ้นก่อนที่ taker จะกินมาถึงเรา เราก็ **ไม่ได้ fill** เลย นี่คือ queue risk ที่ต้องชั่งก่อนตัดสินใจวางคิวสักแค่ไหน

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

สมัคร WebSocket stream ของ Binance ช่องทาง **btcusdt@depth** (diff depth) แล้วบันทึกปริมาณที่ best bid เป็นเวลา 10 วินาที สังเกตว่าตัวเลขขยับขึ้นลงตลอดจาก limit เข้า/cancel/market กิน ลองเดาว่าถ้าคุณวาง limit เพิ่ม 0.01 BTC ตอนนี้ Q_ahead ของคุณจะเป็นเท่าไร และต้องมี market sell เข้ามาที่ BTC คุณถึงจะได้ fill

ส่งต่อ → รู้แล้วว่าในหนึ่งราคามีคิว แล้ว อะไรที่ทำให้คิวและกระดานขยับได้บ้าง? Part 2 ตอบด้วย 3 เหตุการณ์เดียว — Limit / Cancel / Market — และทำไมไม่ใหญ่ถึง walk the book

อ่านกระดาน

Reading the Book

Part 2: 3 เหตุการณ์ที่ขยับกระดาน — Limit / Cancel / Market

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์

เติม-เอาออก-หยิบของ: maker vs taker, walk the book, slippage และเมื่อไหร่ควรใช้คำสั่งแบบไหน

 [อ่านกระดาน](#) > [รู้ใครกดดัน & เชื่อได้แค่ไหน](#) > [ตัดสินใจเข้า-ออก](#) > [ต่อยอด/คุมเสี่ยง](#)

Part 2 — 3 เหตุการณ์ที่ขยับกระดาน

ต่อจากตอนก่อน

เพ็ญรู้มา: ในหนึ่งราคามี "คิว" ของหลายคนเรียงกัน และอยู่ต้นคิว = ได้ fill ก่อน · **ตอนนี้จะเติม:** คิวและกระดานทั้งใบขยับได้ด้วย 3 เหตุการณ์เดียว — เติม (Limit) / เอาออก (Cancel) / หยิบ (Market) — พร้อมต้นทุนจริงเวลาไม่ใหญ่ walk the book

อ่านจบ Part นี้คุณจะได้

- รู้ว่ามี 3 เหตุการณ์เดียวเท่านั้นที่ทำให้กระดานเปลี่ยน: Limit (เติม) / Cancel (เอาออก) / Market (หยิบ)
- แยก **maker (ให้สภาพคล่อง)** ออกจาก **taker (กินสภาพคล่อง)** และรู้ว่าใครจ่าย spread
- เข้าใจ **walk the book** — ทำไมออเดอร์ก้อนใหญ่จึง "ไต่" กินหลายชั้นจนได้ราคาแยลง (slippage)
- เลือกได้ว่า **เมื่อไหร่ควรใช้ limit เมื่อไหร่ควรใช้ market** (มีตารางสรุปครบ)


เริ่มจากชั้นวางของในซูเปอร์

นึกถึงชั้นวางสินค้าในซูเปอร์มาร์เก็ต มีแค่ 3 อย่างที่ทำให้ของบนชั้นเปลี่ยน:

- **พนักงานเติมของ = Limit order** — เอาของมาวางเพิ่ม (ให้สภาพคล่อง / provide)
- **พนักงานที่เคยเอาของมาวางบนชั้น เปลี่ยนใจกลับเข้าคลัง → ของบนชั้นหายไป = Cancel** — ถอน limit ของตัวเองออก (ลดสภาพคล่อง)
- **ลูกค้าหยิบของใส่ตะกร้าจ่ายเงิน = Market order** — กินของออกจากชั้นทันที (consume)

ทุกการเคลื่อนไหวบนกระดาน — ทุก ๆ ตัวเลขที่กระพริบ — สรุปได้เป็นหนึ่งใน 3 เหตุการณ์นี้เสมอ

มีแค่ 3 อย่างที่ขยับกระดาน




Limit/Cancel = ขยับ "ของที่รออยู่" · Market = ทำให้เกิดการเทรดจริง

เหตุการณ์ที่ 1-3 ทำงานยังไงบนกระดาน

มาดูผลของแต่ละเหตุการณ์ที่ best ask = 60,003 (มี 5 BTC รออยู่):


- **Limit (เดิม):** มีคนตั้งขายเพิ่มที่ 60,003 อีก 3 BTC → ฝั่ง ask หนาขึ้น (5→8) ราคายังไม่ขยับ
- **Cancel (เอาออก):** เจ้าของ 5 BTC ถอนคำสั่งคืน → ชั้น 60,003 ว่าง best ask เลื่อนไปชั้นถัดไป (เช่น 60,005) spread กว้างขึ้น
- **Market (หยิบ):** มี market buy 5 BTC → กิน 60,003 หหมด เกิดการเทรดจริง best ask เลื่อนขึ้น



ภาพ 2.1 · กระดานก่อน/หลัง 3 เหตุการณ์ (ต่อยอดเทมเพลตแม่)

Maker vs Taker — ใครให้ ใครกิน

หัวใจคือ "ใครทำให้เกิดการเทรด": คนที่ **ตั้งรอ** ในกระดาน (limit) คือ **maker** เพราะเป็นคนสร้างสภาพคล่องไว้ให้ ส่วนคนที่ **ยิงเข้าไปกิน** คำสั่งที่รออยู่ (market) คือ **taker** taker เป็นฝ่ายจ่าย spread และมักโดนคิด fee สูงกว่า



ภาพ 2.2 · Maker vs Taker

🔑 กล่องสรุปหัวใจ — Maker / Taker / Market Order: ใช้อันไหนเมื่อไหร่

มิติ	Limit (Maker)	Market Order (Taker)
ทำอะไร	วางคำสั่งรอที่ราคาที่เราเลือก	สั่งซื้อ/ขายทันทีที่ราคาดีที่สุดที่มี
บทบาทสภาพคล่อง	ให้ (provide) เดิมของเข้ากระดาน	กิน (consume) หยิบของออก
ค่าธรรมเนียม	maker fee ต่ำ / บางที่ได้ rebate	taker fee สูงกว่า + จ่าย spread
ความเร็ว/ความแน่นอน	อาจไม่ได้ fill (queue risk)	fill ทันที (แต่เสี่ยง slippage)
ความเสี่ยงหลัก	adverse selection (โดนคนรู้ข้อมูลกิน)	slippage / walk the book
เหมาะเมื่อ	ไม่รีบ, อยากได้ราคาดี, เป็น MM/grid	รีบ, ต้องการความแน่นอน, ปิดด่วน/hedge
"มีข้อมูล" ใหม่	สัญญาณอ่อน (ตั้งรอ ยกเลิกฟรี)	informative (ยอมจ่ายเพื่อได้ทันที → Part 6)

หมายเหตุ: Cancel เป็นเหตุการณ์ที่สาม (ถอน limit ออก = ลดสภาพคล่อง ไม่มีเงินเปลี่ยนมือ) — ไม่ใช่ maker/taker แต่เป็นส่วนหนึ่งของ event flow ที่ขยับกระดาน · **post-only** (Part 11) = limit order ที่ยกเลิกอัตโนมัติถ้าจะกลายเป็น taker → การ์ันตีเป็น maker เสมอ

Walk the Book และ Slippage

เมื่อ market order ใหญ่กว่าปริมาณที่ best level จะรับได้ มันจะ "ไต่" (walk) กินชั้นถัดไป ๆ ที่ราคาแยลงเรื่อย ๆ — ราคาเฉลี่ยที่ได้จริงจึงแย่กว่า best ask ส่วนต่างนั้นคือ **slippage**


สมมติคุณ market buy 10 BTC แต่ ask แต่ละชั้นมีไม่พอ:

ชั้น ask: 60,003 × 4 BTC | 60,005 × 3 BTC | 60,010 × 3 BTC

$$\begin{aligned}
 \text{AvgFill} &= \Sigma(p \cdot q) / \Sigma q \\
 &= (60,003 \times 4 + 60,005 \times 3 + 60,010 \times 3) / 10 \\
 &= 600,057 / 10 = 60,005.7 \text{ USDT}
 \end{aligned}$$

$$\text{Slippage} = \text{AvgFill} - \text{BestAsk} = 60,005.7 - 60,003 = 2.7 \text{ USDT/BTC}$$

Walk the Book — market buy 10 BTC ได้ขึ้น



ภาพ 2.3 · Walk the book & slippage

⚠ กับดักมือใหม่ — market order บนเหรียญบาง

บนเหรียญใหญ่อย่าง BTC กระดานลึก market buy เล็ก ๆ แทบไม่มี slippage — มือใหม่จึงชินมือกด market ตลอด แต่พอไปเทรด **เหรียญเล็กที่กระดานบาง** market order ก้อนเดียวกัน "ไต่" กินหลายชั้น **ต้นราคาตัวเอง** ขึ้นไป 1–5% ในวินาทีเดียว แล้วตอนขายก็เจอ slippage กลับทางอีกรอบ — กลายเป็นว่าจ่ายค่า spread + slippage น้นกว่ากำไรที่หวัง ก่อนกด market บนเหรียญเล็กให้ดู depth ก่อนเสมอ หรือใช้ limit แทน

📄 งานวิจัยรองรับ

การจำแนกว่าเทรดแต่ละครั้งเป็น "ฝั่งกินซื้อ" หรือ "ฝั่งกินขาย" (aggressor side) มีรากจาก **Lee & Ready (1991)** ซึ่งเป็นมาตรฐานการตีป้าย trade ส่วนความสัมพันธ์ระหว่าง market order (taker flow) กับการเคลื่อนไหวของราคา จะถูกขยายเป็นเชิงปริมาณใน Part 6 (Delta/CVD) และ Part 7 (price impact, Kyle's λ) — market order ไม่ใช่แค่ "วิธีซื้อ" แต่เป็น **สัญญาณ** ว่าใครยอมจ่ายเพื่อความเร็ว

🔗 เชื่อมโยงเล่มอื่น

Slippage และ effective price ที่เรียนตรงนี้คือ "ต้นทุนจริงของการ execute" ที่เล่ม **arb** ต้องหักออกก่อนสรุปว่ามีกำไร arbitrage จริงไหม (สะพานสู่ Part 14) ส่วนการเลือก maker/taker เชื่อมตรงไป **pm** เพราะค่าธรรมเนียมและ spread กินเข้าไปใน payoff ของทุกไม้

🎯 กับเคสของเรา

ถ้าเราตัดสินใจกด **market buy \$5,000** เพื่อเข้า long ทันที ไม้นี้จะ walk the book ก็ขึ้น และเสีย **slippage** เท่าไรเทียบ best ask? บนกระดาน BTC ที่ลึกอาจแทบไม่รู้สึกละ — แต่ตัวเลขนี้คือต้นทุนจริงที่ต้องคิดก่อนเลือกระหว่าง market (เร็ว/เสีย slippage) กับ limit (รอ/เสี่ยงไม่ติด)

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

ดึง order book L2 ของ BTC/USDT จาก REST /api/v3/depth (Binance) มา 20 ชั้น แล้วคำนวณด้วยมือว่า ถ้าคุณ **market buy มูลค่า 5,000 USD** จะกินกี่ชั้น ราคาเฉลี่ย (AvgFill) เท่าไร และ **slippage** ที่ USDT/bps เทียบกับ best ask จากนั้นทำซ้ำกับเหรียญอันดับ 100+ ที่กระดานบาง แล้วดูว่า slippage ต่างกันกี่เท่า

ส่งต่อ → taker จ่าย "spread" ทุกครั้ง — แต่ช่องว่างสองฝั่งนั้นมาจากต้นทุนอะไรบ้าง และทำไมบางช่วงถึงกว้างขึ้น? Part 3 แยก spread ออกเป็น 3 ก้อนต้นทุน

อ่านกระดาน

Reading the Book

Part 3: Bid-Ask Spread แยกส่วน — ช่องว่างสองฝั่งมาจากต้นทุนอะไร

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์

3 ก้อนต้นทุนของ spread (processing + inventory + adverse selection) และปัจจัยที่ทำให้กว้าง/แคบ

 อ่านกระดาน > [รู้ใครกดต้น & เชื่อได้แค่ไหน](#) > ตัดสินใจเข้า-ออก > ต่อยอด/คุมเสี่ยง

Part 3 — Bid-Ask Spread แยกส่วน

🔗 ต่อจากตอนก่อน

เพ็ญรัฐมา: taker เป็นฝ่ายจ่าย spread และไม้ใหญ่ walk the book เสีย slippage · **ตอนนี้จะเดิม:** เปิดดูว่า spread ที่จ่ายนั้นมาจาก 3 ก้อนต้นทุน (processing + inventory + adverse selection) และเริ่ม"อ่านใจ MM" ว่ากว้าง/แคบช่วงไหนแปลว่าอะไร — ก้าวแรกของด้าน "รู้ใครกดดัน"


🎯 อ่านจบ Part นี้คุณจะได้

- เห็นว่า spread ไม่ใช่ "ค่าธรรมเนียมลอย ๆ" แต่ประกอบจาก **3 ก้อนต้นทุน** ที่อธิบายได้
- แยก order-processing cost / inventory cost / **adverse-selection cost** ออกจากกัน
- รู้ปัจจัยที่ทำให้ spread **กว้างหรือแคบ**: tick, volatility, volume, การแข่งขัน MM, เวลา/ข่าว
- คำนวณ **effective spread** เพื่อวัดต้นทุนจริงที่เทรดเดอร์จ่าย ไม่ใช่แค่ spread ที่เห็นบนจอ

เริ่มจากร้านแลกเงินสนามบิน

ร้านแลกเงินในสนามบินตั้ง spread กว้างมาก — รับซื้อ USD ถูก ขายแพง ส่วนต่างเยอะกว่าร้านในเมืองหลายเท่า ทำไม? เพราะร้านมี **ต้นทุน 3 อย่าง** ซ่อนอยู่: ค่าดำเนินงาน (เช่าที่แพง พนักงาน) + ความเสี่ยงถือเงินสกุลที่ค่าผันผวน + ความเสี่ยงที่ "ลูกค้าบางคนรู้ว่าค่าเงินกำลังจะวิ่ง" แล้วมาแลกก่อน

Market maker ในกระดานคริปโตก็คือร้านแลกเงินนี้ — spread ที่เขาตั้งคือผลรวมของต้นทุน 3 ก้อนเดียวกัน ยิ่งสถานการณ์เสี่ยง spread ยิ่งกว้างเพื่อชดเชย



3 ก้อนต้นทุนของ Spread

ทฤษฎี microstructure แยก spread ออกเป็น 3 องค์ประกอบ:

1. **Order-processing cost (ค่าดำเนินงาน):** ต้นทุนพื้นฐานของการทำธุรกิจ MM — โครงสร้างพื้นฐาน, ค่าธรรมเนียม, เทคโนโลยี เป็นก้อนคงที่ที่สุด
2. **Inventory cost (ความเสี่ยงสต็อก):** เมื่อ MM ถูก fill สะสม position ค้างไว้ เขาแบกความเสี่ยงราคา ถ้าผันผวนสูง (volatility) เขาต้องกาง spread กว้างขึ้นเพื่อชดเชย
3. **Adverse-selection cost (ความเสี่ยงโดนคนรู้ข้อมูลเกิน):** ก้อนสำคัญที่สุดในเชิงทฤษฎี — MM ไม่รู้ว่าคนที่มา কিন-ขาย มีข้อมูลลับหรือไม่ ถ้าโดน "informed trader" กินบ่อย ๆ MM ขาดทุนเป็นระบบ จึงต้องกาง spread เพื่อ (มาจาก Glosten-Milgrom 1985)


$\text{Spread} = \text{Processing} + \text{Inventory} + \text{AdverseSelection}$

$\text{Effective Spread} = 2 \times |P_{\text{trade}} - \text{Mid}| \leftarrow$ ต้นทุนจริงต่อการเทรด 1 ครั้ง

ตัวอย่าง: market buy ได้ราคา 60,003 ขณะ mid = 60,000

$\text{EffSpread} = 2 \times |60,003 - 60,000| = 6 \text{ USDT}$

อย่าให้ชัด: **quoted spread** คือช่องว่าง best ask – best bid ที่ *เห็นบนจอ* (ค่าที่ "ป้ายบอก") ส่วน **effective spread** คือต้นทุน ที่ *จ่ายจริง* วัดจากราคา fill เทียบ mid — รวม slippage เมื่อออเดอร์ walk the book ไปกินหลายชั้น จึงมักกว้างกว่า quoted spread โดยเฉพาะออเดอร์ก้อนใหญ่หรือกระดานบาง




ภาพ 3.1 · Stacked bar — 3 ก้อนต้นทุนของ spread


ปัจจัยที่ทำให้ spread กว้างหรือแคบ

ปัจจัย	spread กว้างขึ้นเมื่อ	spread แคบลงเมื่อ
Tick size	tick ใหญ่ (ราคาขยับหยาบ spread ต่ำสุด = 1 tick)	tick เล็ก (ราคาละเอียด แข่งกันได้)
Volatility	ผันผวนสูง (inventory risk พุง)	ตลาดนิ่ง
Volume / สภาพคล่อง	ปริมาณซื้อขายน้อย (เหรียญเล็ก)	ปริมาณมาก (BTC/ETH)
การแข่งขัน MM	มี MM น้อยราย ผูกขาด	MM แข่งกันบีบ spread
เวลา / ข่าว	ใกล้ข่าว, ตลาดเจียบบอกเวลา, ความไม่แน่นอนสูง	ช่วงสภาพคล่องสูง ไม่มีข่าวค้าง

ตลาดลึก/นิ่ง → spread แคบ



บาง/ผันผวน → spread กว้าง



ภาพ 3.2 · Spread กว้าง vs แคบ 2 สถานการณ์ (ต่อยอดเทมเพลตแม่)

อ่านกระดาน: "เห็นแบบนี้ = อาจหมายถึง"

การแยก 3 ก้อนต้นทุนมีค่าเมื่อเอามาแปลผลตรงหน้าจอก็ได้จริง — เห็น spread ขยับแล้วเดาได้ว่า MM กำลัง"คิดอะไร" และเราควรทำอะไร:

เห็นบนกระดาน	อาจหมายถึง	เราควรทำ
spread กว้างขึ้นกะทันหัน (ก่อน adv-sel/inventory พอง)	MM ระวังข้อมูลลับ/ความผันผวน — กางเพื่อโดน informed กิน มักก่อน/ระหว่างข่าว	เลี่ยงเข้าไม้ taker ตอนนี้ ต้นทุนเข้า-ออกแพง รอ spread หุบ
spread กว้างเรื้อรัง (ทุกชั้นบาง)	สภาพคล่องต่ำ/MM น้อยราย (เหรียญเล็ก, นอกเวลา)	ลดขนาดไม้ หรือใช้ limit ทยอย เข้า อย่างถืด market ก้อนใหญ่
spread แคบมากและนิ่ง	MM แข่งกันบีบ ตลาดลึก ความไม่แน่นอนต่ำ	ต้นทุนเข้า-ออกถูก เป็นจังหวะ ที่ taker เสีย spread น้อยสุด
effective spread > quoted มาก	ไม่เรากำลัง walk the book (กระดานบาง/ไม้ใหญ่เกินชั้น best)	แตกไม้ให้เล็กลง หรือยอมรอ depth เดิมก่อน

🕒 หมายเหตุ — Intraday U-shape (spread/vol รูปตัว U ตลอดวัน)

ในตลาดดั้งเดิม spread และ volatility มัก **โค้งเป็นตัว U ภายในวัน** — กว้าง/ผันผวนสูงตอนเปิดตลาด (ข้อมูลค้างคืนถูกย่อย) แคบลงช่วงกลางวัน แล้วกว้างอีกตอนใกล้ปิด คริปโตเทรด 24/7 ไม่มีระฆังเปิด-ปิด แต่ยังมี **เหล็กร่องรอย U** ตามคาบสภาพคล่องของศูนย์กลางการเงินใหญ่ (เอเชีย/ยุโรป/สหรัฐทับซ้อน) และพองชัดรอบ **เวลาข่าวสหรัฐ** (CPI/FOMC) — เป็นเหตุผลเชิงโครงสร้างว่าทำไม "ช่วงเวลา" จึงเป็นปัจจัยหนึ่งของ spread (โยง stylized facts ใน §8.5)

Informed vs Noise Trader — ที่มาของ adverse selection

ทำไมก่อน adverse selection ถึงสำคัญที่สุด? เพราะ MM ต้องตั้งราคาทั้งที่ **ไม่รู้ว่าจะมีคนมากินเป็นใคร**:

- **Noise trader:** เทรดด้วยเหตุผลสุ่ม (ปาร์ปอร์ต, sentiment) — MM กิน spread จากคนกลุ่มนี้ได้กำไร
- **Informed trader:** รู้ว่าราคากำลังจะวิ่ง มากินฝั่งเดียว — MM ที่ขายให้เขาจะ "ขาดทุนทันที" เพราะราคาวิ่งตามหลัง

MM กาง spread เพื่อให้ "กำไรจาก noise" ชดเชย "ขาดทุนจาก informed" ได้พอดี — นี่คือหัวใจของ Glosten-Milgrom



ภาพ 3.3 · Informed vs noise trader

⚠ กับดักมือใหม่ — เทรดเหรียญเล็กช่วงตลาดเจียบ

มือใหม่เห็นเหรียญเล็กราคาวิ่งแรงตอนดึก (ตลาด US ปิด) แล้วกระโดดเข้า — ช่วงเจียบ MM ถอนตัว spread พองเป็น 10–50 bps คุณจ่ายค่า spread มหาศาลแค่ "เข้า-ออก" ก่อนจะคิดเรื่องทิศทางด้วยซ้ำ ยิ่งถ้าเทรดบ่อย ต้นทุน spread สะสมกินกำไรหมด — spread บนจอคือ "ภาษีเข้า-ออก" ที่ต้องคิดก่อนทุกไม้ ไม่ใช่ดูแค่ราคาเป้าหมาย

📄 งานวิจัยรองรับ

Glosten & Milgrom (1985) พิสูจน์ว่า spread เกิดจาก adverse selection แม้ MM ไม่มีต้นทุนดำเนินการเลยก็ตาม ส่วน **Stoll** และงานสลาย spread decomposition ต่อมาแยกวัด 3 องค์ประกอบเชิงประจักษ์ได้ — ในคริปโต โครงสร้าง fee/rebate ของ Binance/Bybit ก็มีผลโดยตรงต่อ spread ที่ MM ยอมตั้ง

🔍 ต้องเช็คก่อนใช้จริง

โครงสร้าง **fee/rebate** ของ Binance/Bybit เปลี่ยนตามโปรโมชั่นและ VIP tier เสมอ ตัวเลขในเล่มนี้เป็นตัวอย่างเชิงแนวคิด — ก่อนคิด spread/ต้นทุนจริง ให้เปิดหน้า fee schedule ปัจจุบันของ exchange ที่ใช้

🔗 เชื่อมโยงเล่มอื่น

ก่อน **adverse selection** คือสะพานตรงสู่ Part 6 (market order = informative) และ Part 9–11 (market making — MM ต้องบริหารก่อนนี้ไม่ให้ขาดทุน) ส่วน effective spread คือ "ต้นทุนเข้า-ออกจริง" ที่เล่ม **pm** และ **arb** ต้องหักก่อนสรุปกำไรทุกครั้ง

🎯 กับเคสของเรา

ก่อนเข้า long BTC \$5,000 ให้ดูก่อนว่า spread กำลัง"พอง"อยู่ไหม — ถ้าอยู่ช่วง **ข่าว (CPI/FOMC) หรือดึก/นอกเวลา** spread กว้าง = จ่าย"ภาษีเข้า-ออก"แพงเกินจำเป็น ควร **เลี่ยงเข้าไม้ตอนนั้น** แล้วรอช่วงสภาพคล่องสูงที่ spread หุบ

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

เก็บ best bid/ask ของ BTC/USDT ทุก ๆ นาทีเป็นเวลา 24 ชั่วโมง (ผ่าน REST /api/v3/ticker/bookTicker) แล้ว plot **spread (bps)** ราย 24 ชม. เทียบกับเวลาข่าวเศรษฐกิจสหรัฐ (เช่น CPI, FOMC) คุณจะเห็น spread "พอง" ขึ้นชัดในช่วงก่อน/หลังข่าว และช่วงตลาดเจียบ — ลองทำซ้ำกับเหรียญเล็กเทียบกัน

ส่งต่อ → รู้ต้นทุนของ spread แล้ว — แต่ของที่เห็น"บนกระดาน"เชื่อได้แค่ไหน และนานแค่ไหน? Part 4 แยกคลื่นจริงออกจากฟองหลวง (spoof) และอ่านพฤติกรรม MM ตอนถอน quote

อ่านกระดาน

Reading the Book

Part 4: กระดานเชื่อถือได้แค่ไหน / นานแค่ไหน

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์

คลื่นจริง vs ฟองหลวง: signal horizon, depth-at-touch vs deep, spoofing/fleeting liquidity, resiliency

 อ่านกระดาน > [รู้ใครกดต้น & เชื้อได้แค่ไหน](#) > ตัดสินใจเข้า-ออก > ต่อยอด/คุมเสี่ยง

Part 4 — กระดานเชื่อได้แค่ไหน / นานแค่ไหน

🔗 ต่อจากตอนก่อน

เพ็ญรู้มา: spread กว้าง/แคบสะท้อนว่า MM ระวัง adverse selection แคไหน · **ตอนนี้จะเดิม:** ของที่เห็น"บนกระดานเชื่อได้แค่ไหน/นานแค่ไหน — สัญญาณอายุสั้น, ของจริง (at-touch) vs ของลวง (spoof/deep) และอ่านพฤติกรรม MM ตอน **ถอน quote**


🎯 อ่านจบ Part นี้คุณจะได้

- รู้ว่าสัญญาณจากกระดานมี **อายุสั้น (วินาที)** — signal horizon ไม่ใช่ทิศทางรายชั่วโมง
- แยก **depth-at-touch (สภาพคล่องที่ best)** ออกจาก deep liquidity (ลึกลงไป) และรู้ว่าอันไหนเชื่อได้กว่า
- จับสัญญาณ **spoofing / fleeting liquidity (สภาพคล่องลวง)** — ออเดอร์ลวงที่ตั้งไว้หลอกแล้วถอน
- เข้าใจ **resiliency** — กระดานเต็มตัวเองกลับเร็วแค่ไหนหลังถูกออเดอร์ใหญ่กิน

เริ่มจากผิวน้ำทะเล


มองผิวน้ำทะเลจากชายฝั่ง คุณเห็นทั้ง **คลื่นจริง** (พลังงานเคลื่อนเข้าหาฝั่งจริง ๆ) ปนกับ **ฟองและระลอกลวง** (ผุดขึ้นแล้วหายในวินาที) — กระดานก็เหมือนกัน บางก้อนคือความตั้งใจซื้อขายจริง บางก้อนเป็นแค่ "ฟอง" ที่ตั้งไว้หลอกแล้วถอนทันทีที่ราคาใกล้แตะ

คนอ่านกระดานเก่งไม่ได้เชื่อทุกอย่างที่เห็น แต่รู้ว่า **อะไรคือคลื่นจริง อะไรคือฟอง และฟองนั้นอยู่ได้นานแค่ไหน**



มิติ 1: Signal Horizon — สัญญาณอายุสั้น


ข้อมูลจากกระดาน (เช่น imbalance) ทำนายราคาได้ดี แต่ **ในกรอบเวลาสั้นมาก** — ระดับวินาทีถึงหลักนาที ไม่ใช่ชั่วโมงหรือวัน ยิ่งทอดเวลาออกไป พลังพยากรณ์ยิ่งสลายตัวเร็ว (decay) เพราะกระดานถูกเขียนทับด้วยเหตุการณ์ใหม่ตลอด



ภาพ 4.1 · Signal horizon (แกนเวลา log) — พลังพยากรณ์สลายตามเวลา

มิติ 2: Depth-at-touch vs Deep

สภาพคล่องที่ **best level (at-touch)** คือของที่ "พร้อมโดนเทรดทันที" — เปลี่ยนแปลงเร็ว สะท้อนแรงจริงระยะสั้น ส่วนสภาพคล่อง **ลึกลงไป (deep)** มักเป็นออเดอร์ที่ตั้งห่าง ๆ ไว้ ซึ่ง **เชื่อถือได้น้อยกว่า** เพราะเจ้าของมีเวลาถอนก่อนราคาแตะ — "กำแพง" ใหญ่ที่อยู่ลึกจึงมักเป็นเป้าของ spoofing



ภาพ 4.2a · Depth-at-touch vs deep (ต่อยอดเทมเพลตแม่ LOB)

มิติ 3: Spoofing / Fleeting Liquidity

Spoofing คือการตั้งออเดอร์ก้อนใหญ่ไว้ (มักลึกห่าง best) เพื่อ "หลอก" ให้คนอื่นคิดว่ามีแรงรับ/แรงต้านจริงแล้ว **ถอน (cancel) ทิ้งที่ที่ราคาใกล้จะแตะ** — เป็นการสร้างภาพลวงโดยไม่ตั้งใจให้ถูก fill จริง ส่วน **fleeting liquidity** คือออเดอร์อายุสั้นมากที่หลุดและหายตลอดเวลา

ธงเตือน spoof — สังเกต 3 อย่างพร้อมกัน


- ก่อนใหญ่ผิดปกติ เมื่อเทียบกับ depth ปกติของเหรียญนั้น
- ตั้งห่าง best (ไม่ยอมเข้าใกล้จุดที่จะโดน fill จริง)
- cancel ทันทีเมื่อราคาเข้าใกล้ — ก่อนหายก่อนถูกแตะเสมอ



ภาพ 4.2b · Spoof 3 เฟรม (ต่อยอดเทมเพลตแม่ LOB)

มิติ 4: Resiliency — กระดานเต็มตัวกลับเร็วแค่ไหน

Resiliency คือความสามารถของกระดานในการ "เต็มสภาพคล่องกลับ" หลังถูกออเดอร์ใหญ่กินไป กระดานที่ resilient สูง: ถูกกินแล้ว MM เติม limit กลับมาภายในเสี้ยววินาทีที่ spread หุบกลับเร็ว = เชื่อถือได้ ส่วนกระดานที่ resilient ต่ำ: ถูกกินแล้วช่องว่างค้างนาน = เปราะ เสี่ยงราคากระชาก



ภาพ 4.3 · Resiliency timeline

อ่านกระดาน: "เห็นแบบนี้ = อาจหมายถึง" (คิวหาย / เต็มกลับ)

4 มิติข้างบนใช้จริงได้เมื่อเอามาแปลพฤติกรรม "คิวหาย" และ "เต็มกลับ" ตรงหน้าจอ:

เห็นบนกระดาน	อาจหมายถึง	เราควรทำ
กำแพงลิกหายทันทีที่ราคาเข้าใกล้ (ไม่เคยถูกแตะ)	spoo / fleeting — ตั้งหลอกแล้ว ถอน ไม่ตั้งใจให้ fill	อย่าใช้เป็นแนวรับ/ต้าน ดูที่ depth- at-touch แทน
คิวที่ best หายแล้วเดิมกลับเร็ว (เสียวินาที)	resilient สูง — MM ยังอยู่ มั่นใจ สภาพคล่องจริง	เชื่อถือได้กว่า เข้าไม่ได้ราคานิ่งกว่า
ถูกกินแล้วช่องว่างค้างนาน ไม่มี ใครเติม	resilient ต่ำ — MM ถอนตัว เสี่ยง ราคากระชาก	ระวัง slippage หนัก เสี่ยงไม่ใหญ่ จนกว่า depth กลับ
quote สองฝั่งบางลง/หายพร้อมกัน	MM กำลังหลบความเสี่ยง (ก่อน ข่าว/toxic flow)	ชะลอเข้า รอจน MM กลับมาตั้ง quote


อ่านพฤติกรรม Market Maker ถอน quote

"คิวหาย" ไม่ได้แปลว่า spoof เสมอไป — บ่อยครั้งคือ MM ถอน quote จริงด้วยเหตุผลบริหารความเสี่ยง การแยกให้ออกว่า MM ถอนแบบไหนช่วยให้เราอ่านเจตนาได้ถูก แทนที่จะตื่นตูมว่าโดนหลอกทุกครั้ง:

🧠 MM ถอน quote — แยก 3 กรณี (ต่างจาก spoof)

- ถอน 2 ฝั่งพร้อมกัน (bid+ask): MM หลบความเสี่ยง — มักก่อนข่าวสำคัญ หรือเมื่อ "toxic flow" (โดน informed ไล่กินจนเริ่มขาดทุน) เขาถอนเพื่อหยุดเลือดไหล spread พองทั้งสองฝั่ง
- ถอนฝั่งเดียว (เช่น ถอน ask เหลือ bid): MM เอียงมุมมอง / สะสม inventory — ไม่อยากขายเพิ่ม (คิดว่าราคาจะขึ้น) หรือถือ position ฝั่งหนึ่งมากจนปรับ quote ให้เอียง
- ต่างจาก spoof: spoof คือ ตั้งก้อนใหญ่ไว้หลอก (มักลิก หาง best) แล้วถอนเมื่อราคาจะแตะ โดยไม่เคยตั้งใจให้ fill — เป็นการ สร้าง fleeting liquidity (สภาพคล่องลวง) ไม่ใช่การ ถอนของจริงเพื่อบริหารความเสี่ยง

เทียบ 3 กรณี: MM ถอน quote vs spoof



①② = ถอน "ของจริง" บริหารเสี่ยง · ③ = ตั้ง "ของลวง" ไม่เคยตั้งใจ fill

ภาพ 4.4 · MM ถอน quote 2 ฝั่ง / ฝั่งเดียว เทียบกับ spoof

$OBI = (BidVol - AskVol) / (BidVol + AskVol) \leftarrow$ สเกล $-1..+1$, กลาง = 0 (ฟรีวิว – รายละเอียดเต็มใน Part 5)

ธงเตือน spoof: ก้อนใหญ่ + ตั้งห่าง best + cancel เมื่อราคาเข้าใกล้
→ OBI ที่คำนวณจากก้อน spoof เป็น "สัญญาณลวง" ใช้ทำนายไม่ได้

⚠ กัดมือใหม่ — เชื่อ "กำแพง" เป็นแนวรับจริง

มือใหม่เห็นก้อน bid ใหญ่ ๆ ที่ราคาหนึ่งแล้วคิดว่า "นี่แนวรับแข็ง ราคาลงไม่หลุดแน่" แล้วเข้าซื้อตาม — แต่ถ้านั่นคือ spoof พอราคาวิ่งลงมาใกล้ กำแพงหายวับ ราคาทะลุลงต่อ คุณติดดอย นักเทรดที่ตั้ง spoof ตั้งใจให้คุณคิดแบบนี้พอดี — อย่าเชื่อก้อนใหญ่ที่อยู่ลึกและไม่เคยถูกแตะ ดูที่ depth-at-touch และพฤติกรรม cancel เป็นหลัก

📄 งานวิจัยรองรับ

งานสาย microstructure ยืนยันว่า order-book imbalance ทำนายทิศ mid ระยะสั้นได้ (เช่น **Gould & Bonart 2015** สำหรับ queue imbalance) แต่ **พลังพยากรณ์เสื่อมตามเวลาเร็ว** และ **cancel/spoof สร้างสัญญาณลวงได้** — ตอกย้ำว่ากระดานเป็น indicator "อายุสั้น" ที่ต้องใช้คู่ risk management ไม่ใช่ระบบเบ็ดเสร็จ (รายละเอียด OBI เต็มใน Part 5)

🔗 เชื่อมโยงเล่มอื่น

มิติทั้ง 4 ที่นี่เป็น "เครื่องกรองความน่าเชื่อถือ" ก่อนเข้าสู่การอ่าน flow จริงใน Part 5 (OBI — ภาพนิ่งที่ spoof หลอกได้), Part 6 (market order = informative) และ Part 7 (OFI) ส่วนแนวคิด "สัญญาณอายุสั้น + ต้องคู่ risk management" เชื่อมตรงไปยัง mindset ในเล่ม **eye**

🎯 กับเคสของเรา

ก่อนเข้า long BTC \$5,000 เราเห็น "กำแพง bid" ก้อนใหญ่ใต้ราคา — เชื่อเป็นแนวรับแล้วเข้าซื้อตามได้ไหม? เช็คก่อน: มันอยู่ลึกห่าง best และหายทุกครั้งที่ราคาเข้าใกล้หรือเปล่า (= spoof, อย่าเชื่อ) หรือเป็น depth-at-touch ที่ resilient เติมกลับจริง (= เชื่อได้กว่า) — อย่าวางแผนเข้าโดยอิงกำแพงที่อาจหายวับ

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

เปิด WebSocket btcusdt@depth หรือเหรียญสภาพคล่องปานกลาง บันทึก order book ต่อเนื่อง แล้วลอง **จับออเดอร์ก้อนใหญ่ที่หายไปก่อนที่จะราคาจะแตะ** — จดเวลาที่มันปรากฏ ระยะห่างจาก best และเวลาที่มันถูก cancel ถ้าก่อนหน้านี้หายทุกครั้งที่เราจะเข้าใกล้ คุณเพิ่งจับ spoof ได้ด้วยตาตัวเอง ลองนับดูว่าใน 1 ชั่วโมงเจอกี่ครั้ง

ส่งต่อ → จบองค์ I (อ่านกระดานเป็น) แล้ว — กรองของจริง/ของลงได้แล้ว ทีนี้ "ฝั่งไหนหนักกว่ากัน" วัดเป็นตัวเลขยังไง? Part 5 เปิดตัวด้วย Order Book Imbalance (OBI) — ภาพนิ่งที่ spoof หลอกได้ ต้องอ่านคู่ Part นี้

อ่านกระดาน Reading the Book

ภาคทบทวน: สถิติพื้นฐานสำหรับ Order Flow

Order Flow & Microstructure สำหรับรายย่อย · ภาคเครื่องมือ

mean · median · mode · variance · SD · z-score · t-score · normal & t-distribution

แนะนำอ่านก่อน Part 5–11 ถ้าสถิติยังไม่แน่น



ภาคทบทวน — สถิติพื้นฐานที่ Order Flow ต้องใช้

🔗 [อ่านกระดาน \(เครื่องมือ\)](#) > [รู้ใครกดดัน & เชื่อได้แค่ไหน](#) > [ตัดสินใจเข้า-ออก](#) > [ต่อยอด/คุมเสี่ยง](#)

🔗 ต่อจากตอนก่อน

เพ็ญรู้มา: Part 0–4 อ่านกระดานเป็น (bid/ask, คิว, เหตุการณ์, spread, ความน่าเชื่อถือ) · **ตอนนี้จะเดิม:** เครื่องมือสถิติที่ Part 5–11 ต้องใช้ (σ , z-score, normal/t, fat tails) — เดิมตรงนี้ก่อนลุยองค์ "อ่าน Flow"

🎯 อ่านจบภาคนี้คุณจะได้

- สรุป "กองตัวเลข" จากกระดาน (ขนาดออเดอร์ / spread / OFI) ด้วย **ค่ากลาง** (mean, median, mode) ได้ถูกตัว
- วัด "ความผันผวน/ความกระจาย" ด้วย **variance & SD (σ)** — ตัวเดียวกับ σ ใน Avellaneda-Stoikov
- เทียบว่าค่าตอนนี้ "ผิดปกติแค่ไหน" ด้วย **z-score** — รากฐานของการ normalize OFI
- เข้าใจ **normal vs t-distribution** และรู้ว่าทำไม "คริปโตทางหนา" จึงสำคัญต่อการประเมินความเสี่ยง

ทำไม order flow trader ต้องรู้สถิติ

กระดานคือ "กระแสดัชนี" มหาศาล — trade หลายพันไม้ต่อวินาที, ขนาดออเดอร์, spread, OFI ที่แกว่งตลอด สถิติคือเครื่องมือ **3 อย่าง**: (1) **สรุป** กองตัวเลขเป็นค่าเดียว, (2) **วัดความกระจาย** ว่าเหวี่ยงแค่ไหน, (3) **เทียบ** ว่าค่าที่เห็นตอนนี้ "ปกติหรือผิดปกติ" ทุกอย่างในเล่มนี้ (OFI, VPIN, Kyle's λ , A-S) ตั้งอยู่บน 4 กลุ่มนี้

1. ค่ากลาง — Mean / Median / Mode

Mean (μ หรือ $\bar{x}$) = $(\sum x_i) / n$ ← ผลรวมหารจำนวน "ค่าเฉลี่ย"


(Σ = "บวกค่าทุกตัวเข้าด้วยกัน", n = จำนวนข้อมูล)

Median = ค่าตรงกลางเมื่อเรียงน้อย→มาก (ทนต่อค่าสุดโต่ง)

Mode = ค่าที่พบ "บ่อยที่สุด"

ตัวอย่างขนาด market order 5 ไม้ (BTC): 0.10, 0.15, 0.10, 0.20, 5.00 (ไม้สุดท้ายคือวาฟ)

Mean = $(0.10+0.15+0.10+0.20+5.00)/5 = 5.55/5 = 1.11 \text{ BTC}$ ← ถูกวาฟดึงสูงเกินจริง
 Median = เรียง $[0.10, 0.10, 0.15, 0.20, 5.00]$ → ตัวกลาง = **0.15 BTC** ← สะท้อน "ไม่ทั่วไป" ดีกว่า
 Mode = 0.10 (พบ 2 ครั้ง) ← ขนาดยอดนิยม (มักเป็นเลขกลม)



ภาพ S.1 · ข้อมูลเบ้ขวา (right-skewed) — วาฟไม่ก๊อไม่ดึง Mean ออกไปขวา

📌 ใช้ใน order flow ยังไง

ขนาดออเดอร์/ปริมาณในคริปโต **เบ้ขวาเสมอ** (วาฟทำให้มีหางขวายาว) → ใช้ **median** อธิบาย "ไม่ทั่วไป" ดีกว่า mean ส่วน **mode** ช่วยจับ "เลขกลมยอดนิยม" (0.1, 0.5, 1 BTC) ที่มักเป็นจุดวางออเดอร์ของคน — ส่วน **mean** เหมาะกับค่าที่สมมาตร เช่น mid-price ระยะสั้น (microprice = mean ถ่วงน้ำหนัก!)

2. ความกระจาย — Variance & Standard Deviation (σ)

ค่ากลางบอก "อยู่ตรงไหน" แต่ไม่บอก "เหวี่ยงแค่ไหน" — นั่นคือหน้าที่ของ variance (σ^2) และ SD (σ)

Variance (population) $\sigma^2 = \sum (x_i - \mu)^2 / N$

Variance (sample) $s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$ ← ใช้ $n-1$ เมื่อเป็น "ตัวอย่าง"

Standard Deviation $\sigma = \sqrt{\text{variance}}$ ← หน่วยเดียวกับข้อมูล

ประชากร (population) = มีข้อมูลครบทุกตัว → หารด้วย N · **ตัวอย่าง (sample)** = สุ่มมาแค่บางส่วน → หารด้วย $n-1$ (ชดเชยไม่ให้เกิดความกระจายต่ำเกินไป) ในทางปฏิบัติเรามักมีแค่ "ตัวอย่าง" จึงใช้ $n-1$

SD ใหญ่ = ข้อมูลเหวี่ยงมาก (ผันผวนสูง); SD เล็ก = เกาะกลุ่มใกล้ค่าเฉลี่ย

🔗 σ ตัวนี้คือตัวเดียวกับในเล่ม

σ (volatility) คือหัวใจของ **Avellaneda-Stoikov** (Part 10): reservation price $r = s - q \cdot \gamma \cdot \sigma^2 \cdot (T-t)$ โดย q = inventory ที่ถืออยู่, γ = ระดับความกลัวความเสี่ยง — ยิ่งราคา SD สูง (ผันผวน) MM ยิ่งกาง spread กว้าง $\cdot \sigma$ ยิ่งโผล่เป็นตัวหารใน z-score (หัวข้อถัดไป)

3. Z-score — "ค่านี้ผิดปกติกี่ SD"

z-score แปลงค่าดิบให้เป็น "ห่างจากค่าเฉลี่ยกี่เท่าของ SD" — ทำให้เทียบข้ามสกุล/ข้ามเหรียญได้

$z = (x - \mu) / \sigma$ $z=0$ คือค่าเฉลี่ยพอดี $\cdot z=+2$ คือสูงกว่าเฉลี่ย 2 SD (ค่อนข้างสูง ~2% บนสุด)

ตัวอย่าง: spread ปกติของ BTC เฉลี่ย $\mu=6$, $\sigma=1.5$ ตอนนี้ spread พุ่งเป็น 12


$z = (12 - 6) / 1.5 = +4.0 \rightarrow$ สูงกว่าค่าเฉลี่ยจน percentile $> 99.99\%$ (one-tailed) = ผิดปกตินัก = สัญญาณข่าว/สภาพคล่องหด

✅ z-score คือหัวใจของการ "normalize"

ใน Part 7 เรา **stationarize OFI** ก่อน regression — วิธีหนึ่งคือทำ z-score (หักค่าเฉลี่ยทิ้ง หาด้วย SD กลิ้ง) เพื่อให้ OFI เทียบข้ามช่วงเวลา/เหรียญได้ $\cdot$ ใช้จับ "OBI/spread/CVD ผิดปกติ" ด้วย (เช่น $z > 2$ = เหตุการณ์หายาก ควรสนใจ)

4. Normal Distribution — เส้นโค้งระฆัง & กฎ 68-95-99.7

การแจกแจงปกติคือเส้นโค้งระฆังสมมาตรรอบ μ ภายใต้นormal: ~68% ของข้อมูลอยู่ใน $\pm 1\sigma$, ~95% ใน $\pm 2\sigma$, ~99.7% ใน $\pm 3\sigma$




ภาพ S.2 · เส้นโค้งปกติ + กฎ 68-95-99.7 — $z=+2$ ตรงกับขอบ $\pm 2\sigma$ (ครอบคลุม 95%)

📌 ใช้ใน order flow ยังไง

VPIN (Part 8) ใช้ **normal CDF (Φ)** ใน bulk volume classification: $V_{\text{buy}} = V \cdot \Phi(\Delta P / \sigma)$ — **Φ (CDF) = พื้นที่ใต้โค้งสะสม = ความน่าจะเป็นที่จะได้ค่าน้อยกว่าค่านี้** จึงแปลงการเปลี่ยนราคาเป็น "สัดส่วนที่น่าจะเป็นฝั่งซื้อ" · **หมายเหตุ:** σ ในสูตรนี้คือ SD ของ "การเปลี่ยนราคาต่อ bucket" — คนละตัวกับ σ volatility ของ A-S

5. T-distribution & T-score — โลกจริง "หางหนา"

t-distribution หน้าตาเหมือนระฆัง แต่ **หางหนากว่า normal** (peak ต่ำกว่า แลกกกับปลายสองข้างที่หนากว่า — พื้นที่ใต้กราฟยังรวมได้ 1 เท่ากัน) ใช้เมื่อ **ไม่รู้ σ จริง** (ต้องประมาณจากข้อมูล) หรือ **กลุ่มตัวอย่างเล็ก** ยิ่ง degrees of freedom ($df = n-1$) มาก t ยิ่งเข้าใกล้ normal



ภาพ S.3 · t-distribution หางหนากว่า normal — ตรงกับพฤติกรรมราคาคริปโต

T-score ใช้ทดสอบว่า "ค่าเฉลี่ยตัวอย่างต่างจากค่าอ้างอิงอย่างมีนัยหรือเป็นแค่บังเอิญ":

$$t = (\bar{x} - \mu_0) / (s / \sqrt{n}) \quad df = n - 1$$

$|t|$ มาก (เช่น $> \sim 2$) → ต่างอย่างมีนัยสำคัญ (ไม่น่าใช่บังเอิญ)

📌 ใช้ใน order flow ยังไง

ตอน regress $\Delta P = \lambda \cdot OFI$ (Kyle's λ , Part 7) ค่า **t-stat ของ λ** บอกว่าความสัมพันธ์ "มีจริง" หรือบังเอิญ (มักดู $|t| > 2$) — ในงาน order flow ข้อมูล n มักใหญ่มาก (หลายพันจุด) ที่ยังใช้ t เพราะ **"ไม่รู้ σ จริง ต้องประมาณจาก residual"** ไม่ใช่เพราะ n เล็ก · และ **fat tails** คือเหตุผลว่าทำไมต้องระวัง: คริปโตมีวันที่ราคากระชาก $\pm 10\%$ ซึ่ง normal บอกว่า "แทบเป็นไปไม่ได้" แต่เกิดจริงบ่อย — เชื่อมโดยตรงกับ VPIN/toxicity (Part 8) และ inventory risk ของ MM (Part 9–11)

! กับดักมือใหม่

- สมมติทุกอย่างเป็น **normal**: ราคาคริปโตทางหนา การใช้ normal จะ **ประเมิน tail risk ต่ำเกินจริง** — เหตุการณ์ "3σ" เกิดบ่อยกว่าที่คิดมาก
- ใช้ **mean** กับข้อมูลเบ้: วาฟไม่ก็ไม้ทำให้ mean ขนาดออเดอร์เพี้ยน → ใช้ **median**
- **z-score / t สูง ≠ กำไร**: มันบอกว่า "ผิดปกติ/มีนัยทางสถิติ" ไม่ได้บอกทิศหรือว่าหักต้นทุนแล้วคุ้ม

สรุป — สถิติแต่ละตัวใช้ใน Part ไหน

สถิติ	บอกอะไร	ใช้ใน Part
Mean (ถ่วงน้ำหนัก)	ค่ากลาง / microprice	0, 11
Median / Mode	ขนาดออเดอร์ "ทั่วไป" / เลขยอดนิยม	2, 6
Variance / SD (σ)	ความผันผวน	3 (spread), 10 (A-S)
Z-score	normalize / จับค่าผิดปกติ	7 (OFI), 4 (spread/OBI)
Normal + CDF (Φ)	ความน่าจะเป็น / bulk classification	8 (VPIN)
t-score / t-dist	นัยสำคัญ regression / fat tails	7 (λ), 8, 9–11 (tail risk)

🔗 เชื่อมโยงเล่มอื่น

ภาคนี้คือเวอร์ชันย่อที่ปรับให้เข้ากับ order flow — คำว่า "regression" ที่โผล่ในหัวข้อ t ($\Delta P = \lambda \cdot \text{OFI}$) คือ **linear regression / OLS** ซึ่งมีพื้นฐานเต็ม (พร้อมการพิสูจน์ + ตัวอย่าง) ในซีรีส์ **math (คณิตศาสตร์สำหรับ Options)** ที่ z-score/normal ใช้ร่วมกันได้ทันที

👉 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

1. ดึง trade 200 ไม้ล่าสุดของ BTC/USDT (aggTrade) เก็บ "ขนาด" — คำนวณ mean, median, mode เทียบกัน → ดูว่าวาฟถึง mean ห่างจาก median แค่ไหน (เบ้ขวา)
2. เก็บ spread ทุก 1 วินาที 5 นาที — คำนวณ μ, σ แล้วหา z-score ของ spread ล่าสุด ถ้า $z > 2$ แปลว่าผิดปกติ
3. เก็บผลตอบแทนราย 1 นาที 1 วัน — พล็อต histogram เทียบเส้น normal ดูว่า "ทางหนา" จริงไหม (มีไม้สุดโต่งเกินที่ normal คาด)

มีเครื่องมือสถิติครบแล้ว → กลับไปลุย Part 5 (OBI) ถึง Part 11 (Market Making) ได้เต็มที่ →

อ่านกระดาน

Reading the Book

Part 5: Order Book Imbalance (OBI) — ผังไหนหนัก (ภาพนิ่ง)

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์
เริ่มต้นองค์ "อ่าน Flow": static(OBI) → flow(OFI) → toxicity(VPIN)

 อ่านกระดาน > [รู้ใครกดต้น & เชื่อได้แค่ไหน](#) > ตัดสินใจเข้า-ออก > ต่อยอด/คุมเสี่ยง

Part 5 — Order Book Imbalance

🔗 ต่อจากตอนก่อน

เพ็ญรู้มา: Part 4 สอนอ่าน "กำแพง" depth ฝั่ง bid/ask และระวัง spoof — ของที่ตั้งรออาจถูกถอนได้ .

ตอนนี้จะเดิม: ย่อทั้งกระดานให้เป็นตัวเลขเดียว (OBI) ที่บอกว่า "ฝั่งไหนหนัก" ณ วินาทีนี้ แต่ยังเป็นภาพนิ่งที่ถูกหลอกได้เหมือนกำแพงใน Part 4


🎯 อ่านจบ Part นี้คุณจะได้

- คำนวณ **OBI (Order Book Imbalance)** เป็น และเข้าใจว่ามันบอก "ฝั่งไหนหนัก" ในกระดาน ณ วินาทีนี้
- แยกสเกล 2 แบบ: **-1..+1** (กลาง=0) กับ **0..1** (กลาง=0.5) และแปลงไปมาได้
- เข้าใจคำเตือนหัวใจ: **OBI คือภาพนิ่ง (state) ไม่ใช่ flow** — บอกของที่ "ตั้งรออยู่" ไม่ใช่ของที่ "กำลังลงมือ"
- รู้ว่ามันทำนายทิศ mid ถัดไปได้ ($R^2 \sim 65\%$ ในบางตลาด) แต่ horizon สั้นมากและถูก spoof หลอกได้

นับหัวคนชักเย่อ — ยืนอยู่ $\neq$ ลงมือ

นึกถึงเกม **ชักเย่อ**: เชือกเส้นเดียว สองทีมยืนคนละข้าง คุณนับหัวคนได้ว่าฝั่งซ้าย 8 คน ฝั่งขวา 3 คน — ฝั่งซ้าย "หนัก" กว่า เชือก *น่าจะ* ถูกดึงไปทางซ้าย

OBI ก็คือการนับหัวคนชักเย่อบนกระดาน — ฝั่ง bid มีปริมาณรออยู่เท่าไร เทียบกับฝั่ง ask แต่ระวัง! **"ยืนถือเชือก"** ไม่เท่ากับ **"ออกแรงดึงจริง"** คนยืนเฉย ๆ อาจปล่อยมือ (cancel) เมื่อไรก็ได้ นี่คือเหตุผลว่าทำไม OBI เป็นแค่ภาพนิ่ง



$$OBI = (8-3)/(8+3) = +0.45 \rightarrow \text{เอียงฝั่งซื้อ}$$

นิยาม OBI — สองสเกลที่ต้องไม่สับสน

OBI วัด **ความไม่สมดุลของปริมาณ** ระหว่างฝั่งซื้อกับฝั่งขาย ในศัพท์เทรดเดอร์เรียกว่า **"Volume Imbalance"** ส่วนในงานวิชาการเรียก **queue imbalance** — เป็นตัวเดียวกัน

สเกล $-1..+1$ (กลาง = 0) ← ใช้ตัวนี้เป็นมาตรฐานทั้งเล่ม

$$\text{OBI} = (V_{\text{bid}} - V_{\text{ask}}) / (V_{\text{bid}} + V_{\text{ask}})$$

$$\text{ตัวอย่าง: } V_{\text{bid}}=8, V_{\text{ask}}=3 \rightarrow \text{OBI} = (8-3)/(8+3) = +0.45$$

สเกล $0..1$ (กลาง = 0.5) ← บาง paper/เครื่องมือใช้แบบนี้

$$\text{Imbalance} = V_{\text{bid}} / (V_{\text{bid}} + V_{\text{ask}}) = 8/11 = 0.73$$

$$\text{แปลงกันได้: } \text{OBI} = 2 \times \text{Imbalance} - 1 \quad (0.73 \rightarrow 2 \times 0.73 - 1 = +0.45)$$

ค่า OBI ($-1..+1$)	ความหมาย	ทิศที่ "น่าจะ" ไป
+1.0	มีแต่ฝั่ง bid (ask ว่าง)	กดดันขึ้นแรง
+0.4 ถึง +0.9	ฝั่งซื้อหนักกว่า	เอียงขึ้น
~0	สมดุล	ไม่ชัด
-0.4 ถึง -0.9	ฝั่งขายหนักกว่า	เอียงลง
-1.0	มีแต่ฝั่ง ask (bid ว่าง)	กดดันลงแรง


OBI หลายชั้น (multi-level)

OBI ที่ใช้แค่ **best bid/ask** (ชั้นบนสุด) ไรที่สุดแต่ก็ผันผวนที่สุด เราถ่วงน้ำหนักหลายชั้นเพื่อให้ภาพนิ่งขึ้น:

$$\text{OBI}_N = (\sum w_k \cdot V_{\text{bid},k} - \sum w_k \cdot V_{\text{ask},k}) / (\sum w_k \cdot V_{\text{bid},k} + \sum w_k \cdot V_{\text{ask},k})$$

$k = 1..N$ (ชั้นที่ k จาก best เข้าไป), w_k = น้ำหนัก (มักให้ชั้นลึกน้อยลง)


เช่น $w_k = 1/k$ หรือ $\exp(-k) \rightarrow$ ชั้น best มีน้ำหนักมากที่สุด



ภาพ 5.1 · มวลฝั่ง bid (เขียว) มากกว่า ask (แดง) → OBI เป็นบวก

OBI = ภาพนิ่ง (state) ไม่ใช่ flow

นี่คือใจความที่ต้องฝังไว้ก่อนข้าม Part 7: OBI ถ่าย "snapshot" ของกระดาน ณ วินาทีนี้ มันบอกว่า ใครยืนถือเชือกอยู่บ้าง ไม่ได้บอกว่า เชือกกำลังขยับไปทางไหน เมื่อมีคน cancel หรือยิง market order เข้ามา ภาพนิ่งก็เปลี่ยนทันที — แต่ OBI ตัวเดิมไม่ได้จับ "การเปลี่ยน" นั้น มันแค่ถ่ายรูปใหม่



ภาพ 5.2 · แยกสองแผน — OBI (ล่าง) มักนำ mid (บน) แต่ที่จุด cancel (จุดแดง) OBI พุ่งบวกสวนทางกับ mid ที่เกิดจริง = สัญญาณลวง

⚠️ กับดักมือใหม่ — "OBI บวก = ชันแน่นาที่หน้า"

OBI ทำนายได้แค่ระดับ **วินาที** ไม่ใช่วินาทีหรือชั่วโมง! horizon ของมันสั้นมาก เพราะกระดานเปลี่ยนตลอด ยิ่งกว่านั้น **spoofer** วางกำแพง bid ปลอม ๆ ให้ OBI ดูบวก หลอกให้คุณซื้อ แล้วยกเลิกก่อนราคาแตะ (ดู Part 4) — เห็น OBI บวกแล้วเปิด long ค้างข้ามคืนคือเข้าใจผิดเรื่อง horizon

📄 งานวิจัยรองรับ — และข้อควรระวังเรื่องตัวเลข

Gould & Bonart (2015, arXiv:1512.03492) แสดงว่า queue imbalance (= OBI) ทำนายทิศ mid-price **หนึ่งก้าวถัดไป (one-tick-ahead)** ได้ดี โดยเฉพาะหุ้น *large-tick* (tick ใหญ่เทียบราคา คิวยาว) ตัวเลขที่มักอ้างกันว่า OBI อธิบายการขยับ mid ได้ $R^2 \sim 65\%$ นั้น **ขึ้นกับตลาด/timeframe/วิธี calibration** อย่างมาก — large-tick crypto อาจสูง แต่ small-tick หรือ timeframe ยาวจะต่ำลงมาก อย่ายึดเลขนี้เป็นค่าคงที่

🔗 เชื่อมโยงเล่มอื่น

OBI เป็น "ภาพนิ่ง" — **Part 7 (OFI)** จะยกระดับเป็น "วิดีโอการเปลี่ยน" และเปลี่ยนจากการ *เดาความสัมพันธ์* เป็นการ **วัดด้วยสมการถดถอย (regression)** ที่ความชัน (slope) = Kyle's λ ตรงนี้คือจุดที่เล่ม **math** (regression / PCA) เข้ามาเชื่อมเต็มตัว ส่วน **Part 6** จะอธิบายว่าทำไม market order (ของที่ "ลงมือจริง") ถึงมีข้อมูลมากกว่า depth ที่ "แค่ยืนรอ"

🎯 กับเคสของเรา

กลับมาที่เคส **long BTC/USDT \$5,000**: ดู OBI ตอนนี่ว่าหนุนการเข้า long ใหม — ถ้า OBI เป็นบวกชัด (bid หนัก) ก็เป็นลมหนุนระยะสั้น **แต่ระวังว่ามันคือภาพนิ่ง** ที่ revert ได้ในไม่กี่วินาทีและถูก spoof หลอกได้ ใช้เป็นตัวจับจังหวะ ไม่ใช่เหตุผลเปิดไม้ค้างยาว

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

ดึง order book ของ BTC/USDT จาก Binance REST GET `/api/v3/depth?`

`symbol=BTCUSDT&limit=5` แล้วคำนวณ **OBI** สองแบบ: (1) ใช้แค่ best bid/ask, (2) ใช้ 5 ชั้นรวม (sum ปริมาณทั้ง 5) เทียบค่าทั้งสอง — คุณจะเห็นว่า best-level เด็งแรงกว่า ส่วน 5-level นิ่งกว่า ทำซ้ำทุก 1 วินาที 30 ครั้ง แล้วสังเกตว่า OBI เด็งไปมาเร็วแค่ไหน (= horizon สั้น)

ส่งต่อ → OBI นับแค่ "ของที่ยื่นรอ" แล้วของที่ "ลงมือจริง" (market order) ละ — ทำไมมันถึงมีข้อมูลมากกว่า และใครยอมจ่ายแพงเพื่อได้แบบนี้?

อ่านกระดาน

Reading the Book

Part 6: ทำไม Market Order สำคัญ — ใครมีข้อมูล

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์
จาก "ของที่ยื่นรอ" (OBI) สู่ "ของที่ลงมือจริง" (market order / Delta / CVD)

 อ่านกระดาน > [รู้ใครกดต้น & เชื่อได้แค่ไหน](#) > ตัดสินใจเข้า-ออก > ต่อยอด/คุมเสี่ยง

Part 6 — ทำไม Market Order สำคัญ

🔗 ต่อจากตอนก่อน

เพิ่งรู้มา: Part 5 สอน OBI = ภาพนิ่งของ "ของที่ยืนรอ" (limit/depth) ซึ่งถอนได้และถูก spoof หลอกได้ · **ตอนนี้จะเดิม:** หันไปดู "ของที่ลงมือจริง" — market order ที่ยอมจ่าย spread เพื่อได้ทันที จึง informative กว่า limit แล้ววัดมันด้วย Delta/CVD

🎯 อ่านจบ Part นี้คุณจะได้

- เข้าใจว่าทำไม **market order มีข้อมูลมากกว่า limit/cancel** (informativeness) — เพราะ "ยอมจ่ายเพื่อได้ทันที"
- รู้จัก **adverse selection**: ทำไมคนตั้ง limit ถึงเสี่ยงโดน informed trader (คนรู้ข้อมูล) กิน
- เข้าใจพฤติกรรม **non-Markovian**: คิวหมดยเพราะ market → ราคา *follow* / เพราะ cancel → ราคา *revert*
- วัด "แรง market order" ได้จริงด้วย **Delta (Δ) และ CVD** จากข้อมูล Binance aggTrade

ใครยอมจ่ายแพงเพื่อได้เดี๋ยวนี้ มักรู้อะไร

ลองนึก: ของชิ้นเดียวกัน คนหนึ่ง "ตั้งรอ" ขอซื้อราคาถูกลงหน่อย อีกคน "ควักจ่ายราคาเต็ม ขอเอาเดี๋ยวนี้" — ใครดูเหมือนมีเหตุผลแรงกว่า? คนที่ **ยอมข้าม spread จ่าย ask เต็ม ๆ เพื่อให้ได้ของทันที** มักเป็นคนที่ **เชื่อว่าราคากำลังจะวิ่งขึ้น** — เขายอมจ่าย "ค่าผ่านทาง" เพราะคิดว่ารออีกนิดจะแพงกว่านี้

นั่นคือเหตุผลที่ **market order เป็นสัญญาณที่ "informative"** ส่วน limit order ที่ตั้งรอ (ยกเลิกฟรีเมื่อไรก็ได้) เป็นสัญญาณที่ **อ่อน** — มันแค่ "ความตั้งใจ" ที่ถอนได้

เหตุการณ์	ต้นทุน/ความมุ่งมั่น	ความ informative
Market order (taker)	จ่าย spread + เสี่ยง slippage	สูง — ลงมือจริง เอาเดี๋ยวนี้
Limit order (provide)	ฟรี ถอนได้	ต่ำ — แค่ตั้งรอ
Cancel	ฟรี	ต่ำ — ถอนความตั้งใจ


Adverse selection — กับดักของคนตั้ง limit

คุณตั้ง limit buy ที่ best bid รอกินครึ่ง spread แต่... ใครจะมาเทรดกับคุณ? ถ้าคนที่มา "ขายชน" limit ของคุณ คือคนที่ **รู้ว่าราคากำลังจะลง** คุณก็เพิ่งซื้อของที่กำลังจะถูกลง — fill ของคุณคือ "ของเสีย" นี่คือ **adverse selection**: คุณมักได้ fill ในจังหวะที่ไม่ดีสำหรับคุณ

กำไรคาดหวังของ limit order (maker):

$$\begin{aligned} E[\text{กำไร}] &= (\text{ครึ่ง spread}) - E[\text{ราคาวิ่งสวน} \mid \text{ได้ fill}] \\ &= \text{edge ที่หวัง} - \text{ต้นทุน adverse selection} \end{aligned}$$

ถ้า adverse move > ครึ่ง spread → maker ขาดทุนแม้ได้ fill!




ภาพ 6.3 · maker ได้ fill ตอน "ดี" บ้าง "เสีย" บ้าง — informed trader ทำให้ฝั่งเสียหนัก

Non-Markovian — สาเหตุที่คิวหมดสำคัญกว่าตัวเลข

สมมติ best bid คิวหมดเกลี้ยง ราคากำลังจะขยับ — แต่ "หมดเพราะอะไร" สำคัญมาก:

- **หมดเพราะ market sell (M)** มากินจนเกลี้ยง → มีแรงขายจริงดันลง → ราคามักจะ **follow** (ลงต่อ)
- **หมดเพราะคน cancel (C)** ถอน limit ออกไปเอง → ไม่มีเงินเปลี่ยนมือ มักเป็นการขยับเชิงรับ → ราคามักจะ **revert** (เต็งกลับ)

นี่เรียกว่า **non-Markovian**: "สถานะปัจจุบัน" (คิวหมด) อย่างเดียวไม่พอ ต้องรู้ *ประวัติว่ามันหมดได้ยังไง* ด้วย — นี่คือเหตุผลหลักที่ OBI (ภาพนิ่ง) ไม่พอ และทำไม Part 7 (OFI) ต้องจับ "เหตุการณ์การเปลี่ยน"



ภาพ 6.2 · (หัวใจ Part นี้) สาเหตุที่คิวหมด ชั่วทิศต่อ — M → follow / C → revert

งานวิจัยรองรับ — และข้อควรระวังเรื่องตัวเลข

Lu & Abergel (2018) สร้างโมเดล LOB หลายชั้นแบบ queue-reactive (Markovian) บนข้อมูลจริงเพื่อออกแบบและ backtest กลยุทธ์ market making · stylized fact ที่ตระกูลโมเดลนี้ชี้ให้เห็นและเรายืมมาใช้คือ: เมื่อคิวที่ best หมดด้วย **market order** ราคา มักเคลื่อน **ต่อทิศเดิม** (continuation) ส่วนถ้าหมดด้วย **cancel** มักดึงกลับ · **หมายเหตุตัวเลข**: เลข continuation สูง ๆ (เช่นที่บางแหล่งอ้างราว ~80%+) **ไม่ใช่ค่าคงที่** — ขึ้นกับสินทรัพย์ / large-tick vs small-tick / นิยามและ calibration และไม่ใช่ headline result ที่ pin ได้กับเปเปอร์เดียว ควรตรวจกับ market ของคุณเอง

Stylized fact — sign autocorrelation: order flow มาเป็นชุด

ข้อเท็จจริงเชิงสถิติที่พบซ้ำ ๆ ทุกตลาด: **เครื่องหมาย (sign) ของ market order มี autocorrelation เป็นบวกและจางช้ามาก (long-range)** — พุดง่าย ๆ คือ buy มักตามด้วย buy, sell ตามด้วย sell **order flow** จึงมาเป็น **"ชุด"** ไม่ใช่สุ่มสลับ สาเหตุหลักคือรายใหญ่ทยอยหันไม้ใหญ่เป็นไม้เล็ก ๆ (order splitting) ปรากฏการณ์ "เหตุการณ์กระตุ้นเหตุการณ์ถัดไป" นี่เป็นรากของโมเดล **Hawkes process** (self-exciting) ที่ใช้จำลอง order flow — และเป็นอีกเหตุผลที่ market order ก้อนแรกเป็นเบาแสว่ายังมีของตามมาอีก ไม่ใช่จบในตัว

ถ้า "สุ่มสลับ" (ที่หลายคนคิด)



ของจริง: มาเป็น "ชุด" (order splitting)



ภาพ 6.5 · sign ของ market order ไม่ได้สลับแบบสุ่ม แต่ **มาเป็นชุด** (buy ตามด้วย buy) เพราะรายใหญ่หันไม้ — รากของ autocorr บวกและ Hawkes process

Delta (Δ) และ CVD — วัด "แรง market order" ได้จริง

เราวัด market order flow ได้ตรง ๆ ด้วย **Delta** = ปริมาณที่ taker ซื้อชน ลบด้วยปริมาณที่ taker ขายชน และสะสมเป็น **CVD (Cumulative Volume Delta)** เพื่อดูเทรนด์แรงซื้อ/ขาย:

$$\Delta \text{ (Delta)} = \text{BuyVol} - \text{SellVol} \leftarrow \text{นับ "ของที่เทรดไปแล้ว" (aggressor)}$$

$$\text{CVD}_t = \sum \Delta \text{ (running sum)} \leftarrow \text{เทรนด์แรงซื้อ/ขายสะสม}$$


การจำแนก aggressor (signed volume):

Binance aggTrade ให้ flag m (isBuyerMaker):

m = true → ผู้ซื้อเป็น maker → taker คือ "ขายชน" → Sell

m = false → ผู้ขายเป็น maker → taker คือ "ซื้อชน" → Buy

(ไม่ต้องเดาด้วย Lee-Ready เพราะ exchange บอก aggressor ให้ตรง ๆ)



ภาพ 6.4 · Δ แท่งเขียว(buy)/แดง(sell) + เส้น CVD สะสม

Binance-ready Orderflow Toolkit — ผูกศัพท์เทรดเดอร์ ↔ ศัพท์วิชาการ ↔ paper

ศัพท์เทรดเดอร์	ศัพท์วิชาการ	วัดอะไร	Paper รองรับ
Delta (Δ)	Trade imbalance / signed volume	flow ที่เทรดไปแล้ว (taker)	Lee & Ready (1991); Chordia-Subrahmanyam (2004)
Cumulative Delta (CVD)	Cumulative signed order flow	trend แรงซื้อ/ขายสะสม	Chordia-Roll-Subrahmanyam (2002)
Volume Imbalance	Queue / order-book imbalance	state ของ depth ที่ตั้งรอ	Gould & Bonart (2015)

ข้อมูล Binance ที่ใช้: @aggTrade stream (ได้ flag m = aggressor) สำหรับ Δ/CVD · @depth สำหรับ Volume Imbalance/OBI

Nuance จากงานวิจัย

(1) **OFI > Trade Imbalance**: Δ/CVD ใช้ได้ดี แต่จับเฉพาะ "ของที่เทรดไปแล้ว" — **OFI (Part 7)** รวม cancel และ limit ด้วย จึงมีข้อมูลมากกว่า นี่คือทางอัปเกรดที่ชี้ตรงไป Part 7 · (2) **พลังทำนายเสื่อมตามเวลา**: ทุกสัญญาณ orderflow มี horizon สั้น ต่อย้ายบทเรียน signal horizon จาก Part 4 · (3) **ทำไมถึงอ้าง Chordia**: Chordia & Subrahmanyam (2004) พบว่า **order imbalance รายวัน (signed volume)** ทำนาย return ช่วงถัดไปได้ — ส่วนหนึ่งเพราะ imbalance มี autocorrelation (ไหลต่อเนื่องหลายวัน) · ก่อนหน้านั้น Chordia, Roll & Subrahmanyam (2002) แสดงว่า imbalance ทั้งตลาดสัมพันธ์กับ **liquidity และ return รวม** อย่างแรง — สรุปคือ "แรงซื้อ-ขายสุทธิดันราคา" ไม่ใช่ความเชื่อรายย่อย แต่มีหลักฐานวิชาการระดับตลาดหุ้นรองรับมานาน (Δ/CVD ที่เราดูบนคริปโตคือเวอร์ชัน real-time ของ measure เดียวกัน)

กับดักมือใหม่

- เห็น best หหมดคิวแล้ว **เดาทิศทันที** — ต้องดู **สาเหตุ** (M หรือ C) ก่อน
- **CVD divergence $\neq$ กลับตัวเสมอ** — CVD ขึ้นแต่ราคาไม่ขึ้น อาจเป็น *absorption* (มีกำแพง limit ดูดแรงซื้อไว้) ไม่ใช่สัญญาณกลับตัวอัตโนมัติ
- จำแนก aggressor **ผิด** ทำให้ Δ ผิดทั้งแผง — ใช้ flag m ของ Binance ให้ถูก อย่าเดาเอง

เชื่อมโยงเล่มอื่น

"ใครมีข้อมูล" เป็นเลนส์เดียวกับเล่ม **eye** (mindset: อ่านว่าใครกำลังลงมือจริง) ส่วนแนวคิด adverse selection จะกลับมาเป็นหัวใจของ **Part 9–10 (Market Making)** — MM ต้อง skew quote เพื่อหนี informed flow และ **Part 7** จะเปลี่ยน " Δ/CVD " ให้กลายเป็น OFI ที่ใส่ลง regression วัด price impact (λ) ได้ (ตรงนี้เล่ม **math** เข้ามาเต็มตัว)

กับเคสของเรา

เคส **long BTC/USDT \$5,000**: เพิ่งเห็น market buy ก้อนใหญ่กระแทกเข้ามา (Δ พุ่ง, CVD ใต้) — ควร **ไล่ตาม** หรือ **รอ revert**? ดูสาเหตุ: ถ้าคิวหมดเพราะ market (M) และ flow มาเป็นชุด (sign autocorrelation) มักลากต่อ → ไล่ได้; ถ้า CVD ขึ้นแต่ราคาไม่ไป (absorption) หรือคิวหมดเพราะ cancel (C) → รอ revert อย่าไล่ยอด

🔪 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

เชื่อม Binance @aggTrade ของ BTC/USDT เก็บ 200 เทรด ตัดป้าย buy/sell ด้วย flag m คำนวณ Δ ต่อช่วงเวลา (เช่นทุก 5 วินาที) แล้ว **plot CVD** เทียบกับเส้น mid — สังเกตช่วงที่ CVD ไต่ขึ้นแต่ราคาไม่ขึ้นตาม (= candidate absorption) นั่นคือจุดที่ "เดา CVD ตรง ๆ" จะพลาด

ส่งต่อ → Δ /CVD จับแค่ market ที่เทรตไปแล้ว — ถ้ารวมทุกแรง (limit+cancel+market) เป็น "วิถีโการเปลี่ยน" แล้ววัดว่า มันดันราคาเท่าไรต่อหน่วย (Kyle's λ) ด้วย regression ได้ไหม?

อ่านกระดาน

Reading the Book

Part 7: Order Flow Imbalance & Price Impact — flow ต้นราคายังไง

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์
จากภาพนิ่ง (OBI) → วิถีโถการเปลี่ยน (OFI) → วัด price impact ด้วย Kyle's λ

 อ่านกระดาน > [รู้ใครกดต้น & เชื้อได้แค่ไหน](#) > ตัดสินใจเข้า-ออก > ต่อยอด/คุมเสี่ยง

Part 7 — OFI & Price Impact

🔗 ต่อจากตอนก่อน

เพิ่งรู้มา: Part 6 วัด "ของที่ลงมือจริง" ด้วย Δ/CVD แต่จับเฉพาะ market order ที่เทรดไปแล้ว · **ตอนนี้**
จะเดิม: ยกระดับเป็น OFI ที่รวมทุกแรง (limit+cancel+market) เป็น "วิถีโการเปลี่ยน" แล้ววัดด้วย regression ว่า flow หนึ่งหน่วยดันราคาเท่าไร = Kyle's λ

🎯 อ่านจบ Part นี้คุณจะได้


- แยก **OBI (state/ภาพนิ่ง)** ออกจาก **OFI (flow/การเปลี่ยน)** ได้ชัด (มีตารางเทียบ)
- คำนวณ OFI แบบ event-based ที่ best level ครบ 3 กรณี (ราคาขึ้น/เท่า/ลง)
- เข้าใจว่า **Kyle's λ** = ความชันของเส้น regression ΔP บน OFI — price impact ต่อหนึ่งหน่วย flow
- รู้จัก **multi-level OFI** (Cont 2023, รวมหลายชั้นด้วย PCA) และทำไมต้อง stationarize ก่อน regress

OBI = ภาพถ่าย / OFI = วิถีโ

Part 5 สอน OBI ซึ่งเป็น "ภาพถ่ายนิ่ง" ของกระดาน ณ วินาทีหนึ่ง — บอกว่าตอนนี้ฝั่งไหนหนัก แต่ภาพนิ่งบอกไม่ได้ว่ามันกำลัง *เปลี่ยนไปทางไหน*

OFI (Order Flow Imbalance) คือ "วิถีโการเปลี่ยน" — มันวัด *การเปลี่ยนแปลงสุทธิ* ของ depth ระหว่างสอง snapshot โดยรวมทั้ง 3 เหตุการณ์: limit เพิ่มเข้า, cancel ถอนออก, market กินออก ต่างจาก Δ/CVD (Part 6) ที่จับเฉพาะ market — OFI จับ *ทุกแรงที่ขยับกระดาน*

มิติ	OBI (Part 5)	OFI (Part 7)
วัดอะไร	state — ปริมาณที่ตั่งรอ ณ จุดเวลาหนึ่ง	flow — การเปลี่ยนสุทธิระหว่างสองช่วงเวลา
คำอุปมา	ภาพถ่ายนิ่ง	วิถีโการเปลี่ยน
รวมเหตุการณ์	แค่ snapshot (ไม่รู้สาเหตุ)	limit + cancel + market รวมกัน
ความสัมพันธ์กับราคา	correlation (เดาทิศ)	regression แรงดัน → ราคา $\Delta P = \lambda \cdot \text{OFI}$
จับ "การเปลี่ยน" ไหม	ไม่ — เป็นภาพนิ่ง	ใช่ — เป็นแกนกลาง



ภาพ 7.1 · OBI (state) เทียบ OFI (flow)

นิยาม OFI ที่ best level — 3 กรณี

OFI event-based (Cont-Kukanov-Stoikov) วัดการเปลี่ยน depth ที่ best bid/ask ระหว่าง snapshot ก่อน (n-1) กับตอนนี้ (n) โดยขึ้นกับว่า **ราคา best ขยับหรือไม่**:

ฝั่ง bid (e^b_n) — เทียบ P^b_n กับ P^b_{n-1} ก่อนหน้า:

ถ้า $P^b_n > P^b_{n-1} \rightarrow e^b = V^b_n$ (ราคา bid ขึ้น = แรงซื้อเข้า)

ถ้า $P^b_n = P^b_{n-1} \rightarrow e^b = V^b_n - V^b_{n-1}$ (ราคาเท่า = ดูปริมาณเปลี่ยน)

ถ้า $P^b_n < P^b_{n-1} \rightarrow e^b = -V^b_{n-1}$ (ราคา bid ลง = แรงขายกิน)

ฝั่ง ask (e^a_n) — สมมาตรกลับด้าน:

ถ้า $P^a_n < P^a_{n-1} \rightarrow e^a = V^a_n$

ถ้า $P^a_n = P^a_{n-1} \rightarrow e^a = V^a_n - V^a_{n-1}$

ถ้า $P^a_n > P^a_{n-1} \rightarrow e^a = -V^a_{n-1}$

$OFI_n = e^b_n - e^a_n$ (บวก = แรงดันขึ้น, ลบ = แรงดันลง)

Kyle's λ — price impact (แรงดันราคา) ต่อหนึ่งหน่วย flow

คำถามสำคัญ: OFI หนึ่งหน่วยดันราคาเท่าไร? ตอบด้วย **regression เชิงเส้น** ของการเปลี่ยน mid (ΔP) บน OFI ความชัน (slope) ที่ได้คือ **Kyle's λ** — "ค่าความลึก/แพงของตลาด" (price impact coefficient)

⚖ ความเป๊ะ: "Kyle's λ " ตัวจริง vs slope ที่เราวัด

ในเปเปอร์ต้นฉบับ Kyle (1985) λ เป็น ค่าดุลยภาพเชิงทฤษฎี ที่ MM ตั้งราคาป้องกัน insider — มีสูตรปิด $\lambda = \frac{1}{2} \cdot \sigma_v / \sigma_u$ (ความผันผวนของข่าวลับ ÷ ของ noise) และวัด flow เป็น "net signed market order" · ส่วนสิ่งที่เราคำนวณจริงในเล่มนี้คือ slope ของ regression ΔP บน OFI ตาม Cont-Kukanov-Stoikov (2014) ซึ่ง OFI รวม limit+cancel+market ไม่ใช่แค่ market order · นักปฏิบัติเรียกมันว่า "Kyle's λ " เพราะมัน เล่นบทเดียวกัน (price impact ต่อหน่วย flow) แต่จำไว้ว่ามันเป็น การประมาณเชิงสถิติ (contemporaneous, ไม่ใช่ causal) ไม่ใช่ λ ดุลยภาพของ Kyle เป๊ะ ๆ


$$\Delta P = \lambda \cdot \text{OFI} + \varepsilon \leftarrow \text{สมการ price impact (linear)}$$

λ = ความชันเส้น regression (OLS slope):

$$\lambda = \text{Cov}(\Delta P, \text{OFI}) / \text{Var}(\text{OFI}) \leftarrow \text{สูตร OLS ที่เล่ม math สอน}$$

λ สูง = ตลาดบาง (flow นิดเดียวดันราคาแรง)

λ ต่ำ = ตลาดลึก (flow มากแต่ราคาขยับน้อย — liquid)



ภาพ 7.2 · (ภาพสำคัญ) scatter ΔP บน OFI — เส้น regression ที่ความชัน = Kyle's λ

Multi-level OFI + การ stationarize


OFI ที่ best level เดียวอาจไม่พอ Cont, Cucuringu & Zhang (2023) รวม OFI หลายชั้น (multi-level) ซึ่งมักมี correlation สูงระหว่างกัน จึงใช้ PCA ยุบเหลือองค์ประกอบหลัก (integrated/PC1 OFI) ก่อนใส่ regression — เพิ่มพลังอธิบายได้

multi-level: $OFI^{(k)}$ สำหรับชั้น $k = 1..L \rightarrow$ integrated OFI = $PCA(OFI^{(1)}..OFI^{(L)})$ เอา PC1

stationarize ก่อน regress (กันผลลวง/spurious):

$OFI_{norm} = OFI / \text{DepthBar}$ (หารด้วย depth เฉลี่ยช่วงนั้น $\rightarrow$ สเกลคงที่)

พลังอธิบาย ΔP (R^2)



ภาพ 7.3 · multi-level OFI มัก explain ΔP ได้ดีกว่า best-level (เชิงสัมพันธ์ — ค่าจริงขึ้นกับตลาด)

งานวิจัยรองรับ — และข้อควรระวังเรื่องตัวเลข

Cont, Kukanov & Stoikov (2014) วาง OFI event-based และความสัมพันธ์เชิงเส้น $\Delta P = \lambda \cdot OFI$ ·

Cont, Cucuringu & Zhang (2023) ขยายเป็น multi-level + cross-impact ด้วย PCA ตัวเลขที่มักอ้างว่า OFI อธิบาย ΔP ได้ $R^2 \sim 65\%$ (สูงกว่า OBI/trade imbalance) นั้น **ขึ้นกับสินทรัพย์ / timeframe / จำนวนชั้น / วิธี stationarize** อย่ายึดเป็นค่าตายตัว — ให้ผู้อ่าน calibrate กับ market ตัวเองเสมอ

Cross-ref — square-root impact law (เสริม Kyle's λ)

สมการ $\Delta P = \lambda \cdot OFI$ เป็นภาพ **เชิงเส้นต่อช่วงสั้น ๆ** แต่เมื่อมองผลกระทบของ "ไม้ใหญ่ทั้งไม้"

(metaorder) งานเชิงประจักษ์ (Almgren et al.; สาย Bouchaud/CFM) พบกฎที่หนาทึบข้ามตลาด:

impact $\propto \sqrt{Q/V}$ — โดย Q = ขนาดไม้ใหญ่ที่ทยอยส่ง วัด **เทียบกับ volume เฉลี่ยของตลาด (V)** ไม่ใช่มูลค่าดิบ — ดันขนาด (เทียบ volume) ขึ้น 4 เท่า ราคาขยับเพิ่มแค่ ~ 2 เท่า ไม่ใช่ 4 เท่า (impact เหว่ลง concave) นี่ **เสริม Kyle's λ** ไม่ขัดกัน: λ คือความชันท้องถิ่นต่อหน่วย flow ส่วน square-root law อธิบายว่าผลรวมของไม้ใหญ่ "อึดตัว" เพราะ flow มาเป็นชุด (โยง sign autocorrelation จาก Part 6) และสภาพคล่องไหลกลับมามีระยะห่างที่เราทยอยเข้า — บทเรียน execution: หั่นไม้ทยอยเข้าถูกกว่ากระแทกทีเดียว

! กับดักมือใหม่

- **regress OFI ดิบโดยไม่ stationarize** → ได้ R^2 หลอก (spurious) เพราะ depth สเกลเปลี่ยนตามเวลา ต้อง normalize ด้วย DepthBar ก่อน
- สับสน OBI กับ OFI — **OBI=ภาพนิ่ง, OFI=การเปลี่ยน** ใส่ OBI ลงสมการ price impact ผิดที่
- เชื่อว่า λ คงที่ — λ เปลี่ยนตามสภาพ liquidity (เวลาข่าว/ตลาดบางก็พุ่ง)

🔗 เชื่อมโยงเล่มอื่น (เน้น math)

Part นี้คือจุดที่เล่ม **math** เชื่อมเต็มตัว: **Kyle's λ = OLS slope = $\text{Cov}(\Delta P, \text{OFI}) / \text{Var}(\text{OFI})$** ตรงกับบท ถอดถอยเชิงเส้น · **R^2 = สัดส่วนความแปรปรวนที่อธิบายได้** · **multi-level OFI = PCA** ยุบตัวแปร correlated ตรงกับบท PCA ทั้งหมดนี้นำไปต่อ **Part 13 (stat-arb ด้วย log-OFI)** และเป็นรากของ **Part 8 (VPIN)** ที่เปลี่ยนจาก "price impact" เป็น "toxic flow"

🎯 กับเคสของเรา

เคส **long BTC/USDT \$5,000**: ไม้ของเราจะดันราคา (impact) แค่ไหน? ประเมิน λ จาก regression — ถ้า λ สูง (ตลาดบาง/ช่วงข่าว) ไม้ \$5,000 จะขยับ mid มากและเสีย slippage; ถ้า λ ต่ำ (ตลาดลึก) กระแทกได้ถูกกว่า และจาก square-root law การ **หั่นไม้ทยอยเข้า** ช่วยลด impact รวมเทียบกับยิงทีเดียว

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

ดึง Binance @depth ของ BTC/USDT มาทำ snapshot ต่อเนื่อง คำนวณ OFI ที่ best level ต่อช่วง 1 วินาที และ ΔP (การเปลี่ยน mid) แล้ว **รัน regression สองชุด**: (1) $\Delta P \sim \text{OFI}$, (2) $\Delta P \sim \text{OBI}$ เทียบ R^2 ของทั้งสอง — คุณจะเห็นด้วยมือว่าทำไม "การเปลี่ยน (OFI)" อธิบายราคาได้ดีกว่า "ภาพนิ่ง (OBI)" ลองเพิ่มการ stationarize (หาร DepthBar) แล้วดูว่า R^2 เปลี่ยนไหม

ส่งต่อ → λ บอกว่า flow ดันราคาแค่ไหน — แต่ถ้า flow ลำเอียงฝั่งเดียวหนักจน MM ถอนตัวล่ะ? เมื่อ flow ไม่ใช่แค่ดันราคา แต่กลายเป็น toxic จนตลาดพัง ระวังไหม?

อ่านกระดาน

Reading the Book

Part 8: VPIN — Order Flow Toxicity (toxic flow)

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์

ปิดท้ายองค์ Flow: static(OBI) → flow(OFI) → **toxicity(VPIN)**

 อ่านกระดาน > [รู้ใครกดต้น & เชื่อได้แค่ไหน](#) > ตัดสินใจเข้า-ออก > ต่อยอด/คุมเสี่ยง

Part 8 — VPIN / Order Flow Toxicity

 ต่อจากตอนก่อน

เพ็ญรู้มา: Part 7 วัดว่า flow ต้นราคาแคไหนด้วย Kyle's λ ($\Delta P = \lambda \cdot OFI$) — มองที่ "price impact" · **ตอนนี้จะเดิม:** เปลี่ยนมุมจาก "price impact" เป็น "toxicity" — เมื่อ flow ลำเอียงฝั่งเดียวสะสมจน MM โดน adverse selection นักจกถอนตัว วัดด้วย VPIN บนนาฬิกาปริมาณ


 อ่านจบ Part นี้คุณจะได้

- เข้าใจ **volume clock**: ทำไมต้องวัดเวลาเป็น "ปริมาณ" ไม่ใช่ "วินาที"
- คำนวณ **VPIN** (Volume-synchronized Probability of Informed Trading) จาก volume buckets
- เข้าใจว่า toxicity = adverse selection สะสมของ MM และทำไม VPIN พุ่งก่อน flash crash
- รู้ **ข้อโต้แย้ง**: VPIN ไม่ใช่ทำนาย crash — ผลขึ้นกับ calibration อย่างมาก

นาฬิกาเดินตามปริมาณ ไม่ใช่เวลา

นาฬิกาปกติเดินทุก 1 วินาทีเท่ากันหมด — แต่ตลาดไม่ได้ "เกิดเหตุการณ์" สม่ำเสมอ บางวินาทีเงียบกริบ บางวินาที (ตอนข่าวออก) มีเทรดเป็นพัน ๆ ถ้าวัดทุกอย่างด้วย "เวลานาฬิกา" คุณจะเฉลี่ยช่วงพายุกับช่วงสงบเข้าด้วยกัน ทำให้พลาดสัญญาณ

VPIN ใช้ "นาฬิกาปริมาณ" (volume clock) — แทนที่จะนับ "ผ่านไป 1 นาที" มันนับ "ผ่านไปอีก V หน่วยปริมาณที่เทรด" หนึ่งช่อง (bucket) = ปริมาณคงที่ V เสมอ ช่วงตลาดคึก buckets จะเต็มเร็ว ช่วงเงียบจะเต็มช้า — เวลาจึง "ยืด/หด" ตามกิจกรรมจริง



ภาพ 8.1 · clock time (ช่องเท่ากัน) เทียบ volume clock (ปริมาณเท่ากัน)

📌 Stylized fact — volatility clustering: ทำไมต้องนาฬิกาปริมาณ

อีกข้อเท็จจริงเชิงสถิติที่พบทุกตลาด: **"ความผันผวนเกาะกลุ่ม" (volatility clustering)** — ช่วงที่ผันผวนสูงมักตามด้วยผันผวนสูง ช่วงสงบตามด้วยสงบ พายุไม่ได้กระจายสม่ำเสมอตามเวลานาฬิกา (เป็นที่มาของโมเดลตระกูล GARCH) นี่คือเหตุผลตรง ๆ ที่ VPIN เลือกใช้ **volume clock**: ช่วงพายุปริมาณเทรดพุ่ง buckets เต็มเร็ว นาฬิกาปริมาณจึง "ซุ่ม" เข้าช่วงอันตรายโดยอัตโนมัติ แทนที่จะเฉลี่ยมันจมไปกับช่วงสงบเหมือนนาฬิกาเวลา

🎲 "PIN" ใน VPIN มาจากไหน — บรรพบุรุษปี 1996

ก่อนจะมี VPIN มี **PIN (Probability of Informed Trading)** จาก **Easley, Kiefer, O'Hara & Paperman (1996)** ก่อน — โมเดลโครงสร้างที่มองว่าแต่ละวันสุ่มว่าจะมี "ข่าว" ใด (prob α) ข่าวดีหรือร้าย แล้ว order มาแบบ Poisson: noise traders ทั้งสองฝั่งอัตรา ε , ส่วน informed เพิ่มอัตรา μ ฝั่งที่ได้เปรียบ ประเมินค่าพารามิเตอร์ด้วย **MLE** แล้วได้ $PIN = \alpha\mu / (\alpha\mu + 2\varepsilon)$ = สัดส่วน flow ที่มาจากคนรู้ข่าว · จุดอ่อนของ PIN คือต้องนับ buy/sell รายวันแล้ว fit MLE — ซ้ำและหยาบเกินใช้ real-time · **VPIN (2012)** จึงเกิดมาแก้ตรงนี้: เปลี่ยนจากนาฬิกาเวลาเป็น **volume clock** และเลิกใช้ MLE หันมาใช้ bulk classification แทน — ได้ตัววัด toxicity ที่อัปเดตได้ทันเหตุการณ์ (นี่คือเหตุผลที่เชื่อมั่นคือ **"Volume-synchronized PIN"**)

Volume buckets และ bulk classification

เราเห็นกระแสเทรดเป็น buckets ปริมาณเท่ากัน (เช่น V = ปริมาณเฉลี่ยต่อวัน/50) ในแต่ละ bucket เราประมาณว่า **ปริมาณนั้นเป็นฝั่งซื้อกี่ส่วน ขายกี่ส่วน** ด้วย *bulk volume classification* (ใช้การเปลี่ยนราคาในช่วง bucket ผ่านฟังก์ชัน Φ = CDF ของ normal):

1 bucket = ปริมาณ V คงที่ (กำหนดล่วงหน้า)

แบ่งฝั่งใน bucket ด้วย bulk classification:


$V_{\text{buy}} = V \cdot \Phi(\Delta P / \sigma_{\Delta P})$ ← Φ = CDF ของ standard normal (ไม่ใช่ z-score)

$V_{\text{sell}} = V - V_{\text{buy}}$

(ΔP = การเปลี่ยนราคาในช่วง bucket, $\sigma_{\Delta P}$ = ส่วนเบี่ยงเบนของ ΔP)

$VPIN = (1 / (n \cdot V)) \cdot \sum_{i=1..n} |V_{\text{buy},i} - V_{\text{sell},i}|$


(เฉลี่ย imbalance |buy-sell| ข้าม n buckets ล่าสุด)



ภาพ 8.2 · ทุก bucket ปริมาณ V เท่ากัน แยกสัดส่วน buy/sell — $VPIN = \text{เฉลี่ย } |buy - sell|$

Toxicity (ความเป็นพิษของ flow) = adverse selection สะสม → เตือน crash

$VPIN$ สูง = flow "ลำเอียงไปฝั่งเดียวหนัก" ติดต่อกัน = น่าจะมี informed trader ลอยอยู่ = MM ที่ทำหน้าที่ตั้ง quote กำลังโดน **adverse selection** หนัก (โดนกินฝั่งเดียว) เมื่อ MM เจ็บมากพอ พวกเขาจะ **ถอนสภาพคล่อง** spread กว้างขึ้น และถาฮันพร้อมกัน → **flash crash**



ภาพ 8.3 · $VPIN$ พุ่งแล้วราคาร่วงจริง (#2) ก็มี — แต่ $VPIN$ พุ่งแล้วไม่ crash ก็มี (false alarm, #1) จึงเป็นมาตรวัดความเสี่ยง ไม่ใช่ปุ่มทำนาย

งานวิจัยรองรับ — และข้อโต้แย้งเรื่อง calibration

Easley, López de Prado & O'Hara (2012) เสนอ $VPIN$ และแสดงว่ามันสูงผิดปกติก่อน Flash Crash 6 พ.ค. 2010 งานสาย crypto (nowcasting Bitcoin crash with order imbalance) ก็พบสัญญาณคล้ายกัน แต่มีข้อโต้แย้งสำคัญ: นักวิจัยหลายกลุ่ม (เช่น Andersen-Bondarenko) ชี้ว่าพลังทำนายของ $VPIN$ อ่อนไหวต่อ calibration อย่างมาก — ขนาด bucket V , จำนวน buckets n , วิธี classify ฝั่ง ล้วนเปลี่ยนผลลัพธ์ และบางส่วนของสัญญาณอาจเป็นแค่ผลของ volume/volatility ทั่วไป ไม่ใช่ "informed trading" จริง อย่าใช้ $VPIN$ เป็นปุ่มทำนาย crash เด็ดขาด

Cross-ref — Detecting Toxic Flow (Cartea et al. 2023): แยก benign vs toxic สมัยใหม่กว่า VPIN

VPIN เป็นตัววัด toxicity รุ่นบุกเบิก (2012) แต่งานสมัยใหม่ไปไกลกว่านั้น **Cartea, Chang & Penalva (2023, "Detecting Toxic Flow")** เสนอกรอบจำแนกราย order/รายลูกค้าว่าเป็น **benign (flow ที่ MM รับผิดชอบไม่ทำร้าย) vs toxic (informed ที่ทำให้ MM เสีย)** โดยดูจากผลกระทบราคา หลัง เทรด (post-trade markout) แทนที่จะรวมเป็นค่ารวมฝั่งเดียวแบบ VPIN จุดต่าง: VPIN บอก "ภาพรวมตลาดเริ่ม toxic" ส่วนแนวทางนี้บอก "flow ก้อนไหน/รายไหน toxic" ละเอียดกว่า ตอบโจทย์ MM ที่จะ skew quote/ปฎิเสธ flow รายตัว — เป็นสะพานตรงไปองค์ **Market Making (Part 9–10)**

กับดักมือใหม่

- ใช้ VPIN เป็น "**ปุ่มทำนาย crash**" — มันเป็น *มาตรวัดความเสี่ยง/toxicity* ไม่ใช่สัญญาณซื้อขายตรง ๆ และมี false alarm
- คำนวณ VPIN ด้วย **เวลานาฬิกา** (time bars) — ผิดทั้งกระบวน! ต้องใช้ **volume clock** (volume buckets เท่านั้น)
- ลืม normalize/calibrate แล้วเทียบค่า VPIN ข้ามเหรียญ — ค่าดิบเทียบกันตรง ๆ ไม่ได้

เชื่อมโยงเล่มอื่น

VPIN ปิดเส้นเรื่อง **static(OBI) → flow(OFI) → toxicity(VPIN)**: OBI ดูภาพนิ่ง, OFI ดูการเปลี่ยน+price impact (λ), VPIN ดู "อันตราย" ของ flow แนวคิด **adverse selection** ที่สะสมใน VPIN คือต้นทุนเดียวกับที่ MM ต้องบริหารใน **Part 9–10 (Market Making)** และจะถูกใช้เป็น **kill switch** หยุด grid ใน **Part 12** ($VPIN > \theta \rightarrow$ ระวังไม้ทวนเทรด) ส่วนวิธีคิด volume clock เชื่อมกับการทำ feature ใน **Part โบนัส (ML)**

กับเคสของเรา

เคส **long BTC/USDT \$5,000**: ก่อนกดเข้า เช็ค VPIN — ถ้า **VPIN พุ่ง (toxic flow)** แปลว่ามี informed ลุยฝั่งเดียวและ MM กำลังจะถอน spread จะกว้างและเสี่ยง adverse selection สูง → **ชะลอการเข้า** รอให้ toxicity คลายก่อน (และอย่าใช้ VPIN เป็นสัญญาณซื้อขายตรง ๆ — ใช้เป็นไฟเตือนชะลอเท่านั้น)

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

ดึง Binance @aggTrade ของ BTC/USDT 1 ชั่วโมง หั่นเป็น **volume buckets** ขนาด V คงที่ (เลือก V ให้ได้ราว 50 buckets) ในแต่ละ bucket แยก buy/sell ด้วย bulk classification แล้วคำนวณ **VPIN แบบ rolling** (เฉลี่ย $n=50$ buckets ล่าสุด) plot เทียบราคา — จากนั้น **ลองเปลี่ยนขนาด V และ n** แล้วดูว่ากราฟ VPIN เปลี่ยนแค่ไหน นี่คือบทเรียนตรง ๆ ว่าทำไม calibration สำคัญ (และทำไมต้องระวังการ over-trust)

ส่งต่อ → จบองก์ "อ่าน Flow" (OBI → OFI → VPIN) — แล้วถ้าเราพลิกบทเป็นฝั่ง MM ที่ "ตั้ง quote กินสปรด" บ้างล่ะ? จะรับมือ adverse selection/inventory risk ที่เพิ่งเห็นใน VPIN ยังไง?

อ่านกระดาน

Reading the Book

Part 9: MM-1 พื้นฐาน — กินสปรดยังงใให้รอด

Order Flow & Microstructure สำหรับรายย่อย · องค์กร IV Market Making

อ่านจบแล้วเข้าใจกลไกกินสปรด, maker vs taker + rebate, inventory risk และสัญญาณ skew quote

 อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > **ตัดสินใจเข้า-ออก** > ต่อยอด/คุมเสี่ยง

Part 9 — MM-1 พื้นฐาน: กินสปรดยังไ

ต่อจากตอนก่อน

เพ็ญรู้มา: Part 8 สอนวัด "toxic flow" ด้วย VPIN — เมื่อ order flow ไม่สมดุล (toxic) คนที่เดิมสภาพคล่องจะโดน adverse selection หนัก · **ตอนนี้จะเดิม:** เปลี่ยนมุมมองจาก "คนเข้าไม้" มาเป็น "คนวาง quote" (market maker) — toxic flow ที่ Part 8 เดือนนั้นแหละคือศัตรูที่ทำให้ MM เก็บสปรดได้แต่ขาดทุนจาก inventory

อ่านจบ Part นี้คุณจะได้


- เข้าใจว่า market maker (MM = ผู้ดูแลสภาพคล่อง ตั้งราคาสองฝั่ง) ทำเงินจาก **"กินสปรด"** ได้อย่างไร — ตั้ง bid และ ask พร้อมกันแล้วเก็บส่วนต่าง
- แยก **maker vs taker** และรู้ว่าทำไม rebate ในตลาดคริปโตทำให้ MM ได้เปรียบ
- เข้าใจ **inventory risk** — ความเสี่ยงที่อันตรายที่สุดของ MM ไม่ใช่สปรดแคบ แต่คือสต็อกค้างมือ
- จับสัญญาณของ **skew quote** — เปรียบราคาทั้งสองฝั่งเพื่อระบายสต็อก (บุทางสู่สูตร Avellaneda-Stoikov ใน Part 10)

เริ่มจากร้านแลกเงินสนามบิน

นึกถึงร้านแลกเงินที่สนามบิน — เขาไม่ได้เก็งกำไรว่าค่าเงินจะขึ้นหรือลง เขาแค่ **"รับซื้อถูก ขายแพง"** ตลอดทั้งวัน คนเดินทางมาเรื่อย ๆ บางคนเอาดอลลาร์มาแลกบาท บางคนเอาบาทมาแลกดอลลาร์ ร้านอยู่ตรงกลางคอยจับคู่และเก็บส่วนต่างทุกครั้ง

Market maker ก็คือร้านแลกเงินบนกระดานเทรด — ตั้ง bid (รับซื้อ) ต่ำกว่า mid นิดหน่อย และตั้ง ask (ขาย) สูงกว่า mid นิดหน่อย ถ้ามีคนมา "กิน" ทั้งสองฝั่งสลับกัน MM ก็เก็บสปรดไปเรื่อย ๆ โดยไม่ต้องเดาทิศทางราคาเลย

แต่มีปัญหาหนึ่งที่ร้านแลกเงินก็เจอ — **ล้นซั๊กเต็มไปด้วยดอลลาร์ แต่ไม่มีคนเอาบาทมาแลกคืน** ถ้าดอลลาร์ราคาตกหว่านนั้น ร้านขาดทุนทันที นี่แหละคือ *inventory risk* หัวใจของทั้ง Part นี้




กลไกกินสเปรด: ทำเงินโดยไม่เดาทิศ

สมมติ BTC มี mid = 60,000 MM ตั้ง quote สองฝั่ง:

- **Bid 59,997** — รอรับซื้อ (เป็น limit order ฝั่งซื้อ → เป็น maker)
- **Ask 60,003** — รอขาย (เป็น limit order ฝั่งขาย → เป็น maker)

ถ้ามี taker คนหนึ่ง "ขายทันที" มาชน bid ของเรา → เราได้ BTC มาที่ 59,997 จากนั้นมี taker อีกคน "ซื้อทันที" มาชน ask ของเรา → เราขาย BTC ออกที่ 60,003 ครบรอบหนึ่ง **เราเก็บ 6 USDT** โดยที่ราคา BTC แทบไม่ขยับเลย



ภาพ 9.1 · กลไกกินสเปรด — ซื้อที่ bid ขายที่ ask ไม่ต้องเดาทิศ

PnL ต่อรอบ (ครบ buy→sell) = (ask - bid) = 60,003 - 59,997 = 6 USDT

ถ้ามี maker rebate r = (ask - bid) + 2· r (ได้ rebate ทั้งสองขา)

ตัวอย่าง rebate 0.002% = 6 + 2·(0.00002·60,000) = 6 + 2.4 = 8.4 USDT/รอบ

Maker vs Taker + Rebate คริปโต

หัวใจที่ทำให้ MM มีกำไรไม่ใช่แค่สเปรด แต่คือ **โครงสร้างค่าธรรมเนียม** ในตลาดส่วนใหญ่:

- **Maker** = คนตั้ง limit รอ (เติมสภาพคล่อง) → จ่าย fee ต่ำ บางตลาดถึงขั้น **ได้เงินคืน (rebate)**
- **Taker** = คนยิง market กินทันที (ดึงสภาพคล่องออก) → จ่าย fee สูงกว่า + จ่ายสปรด

มิติ	Maker (MM)	Taker
บทบาท	เติมสภาพคล่อง (limit)	กินสภาพคล่อง (market)
ค่าธรรมเนียม	ต่ำ / ได้ rebate	สูงกว่า
ได้ fill ทันทีไหม	ไม่ (queue risk)	ได้ทันที
ความเสี่ยงหลัก	adverse selection + inventory	slippage


📄 fee/rebate เปลี่ยนได้ — เช็คก่อนใช้จริง

โครงสร้าง maker/taker fee และ rebate ของ Binance/Bybit เปลี่ยนตามโปรโมชั่นและระดับ VIP เสมอ บางคู่ในบางช่วง maker fee = 0% หรือติดลบ (rebate) ตัวเลขในตัวอย่างเป็นเพียงการสาธิต — ก่อนรันจริงต้องเปิดหน้า fee schedule ของตลาดนั้นและคำนวณใหม่ทุกครั้ง เพราะ **edge ของ MM** รายย่อยบาง ๆ มาก ค่าธรรมเนียมที่ตลาดเคลื่อนไหวพลิกจากกำไรเป็นขาดทุนได้

Inventory risk: ศัตรูตัวจริงของ MM

กลับมาที่ร้านแลกเงิน — ถ้าทั้งวันมีแต่คนเอาดอลลาร์มาแลกบาท ไม่มีใครเอาบาทมาแลกคืน ล้นชักของร้านจะ **เต็มไปด้วยดอลลาร์ฝั่งเดียว** ตอนนี้ร้านไม่ได้เป็นกลางอีกแล้ว — ร้านกำลัง "ถือดอลลาร์" และถ้าดอลลาร์ตก ร้านขาดทุน

บนกระดานก็เหมือนกัน ถ้า flow ไม่สมดุล (มีคนขายชน bid ของเราเร็ว ๆ) เราจะ **สะสม inventory ฝั่ง long** เรื่อย ๆ — เก็บสปรดได้ก็จริง แต่ถ้าวราคาร่วงลงต่อ ขาดทุนจาก inventory จะกลับสปรดที่เก็บมาทั้งหมด



ภาพ 9.2 · inventory สะสมเมื่อ flow ไม่สมดุล

$PnL_{\text{รวม}} = PnL_{\text{spread}} + PnL_{\text{inventory}}$

$PnL_{\text{inventory}} = q \cdot \Delta p$ (q = สต็อกสุทธิ, Δp = ราคาเปลี่ยน)

ตัวอย่าง: $q = +10$ BTC, ราคาตก $\Delta p = -50 \rightarrow PnL_{\text{inv}} = 10 \cdot (-50) = -500$ USDT

สปรดที่เก็บมา $30 \text{ รอบ} \times 6 = +180 \rightarrow \text{รวมสุทธิ} = -320$ (ขาดทุน!)


⚠ กับดักมือใหม่ — "สปรดกว้าง = ปลอดภัย"

มือใหม่มัก "ตั้งสปรดกว้าง ๆ ไว้ก่อนจะได้กำไรเยอะต่อรอบ" — **ผิดมม!** สปรดกว้างทำให้ quote ของคุณ อยู่ไกล mid โอกาส fill ต่ำ และที่สำคัญกว่า: **คนที่ยอมมา fill quote ห่าง ๆ ของคุณ มักเป็นคนที่ "รู้ว่าราคากำลังจะวิ่งมาทางคุณ"** (adverse selection — Part 3/6) งานจริงของ MM ไม่ใช่ตั้งสปรดให้กว้าง แต่คือ **จัดการ inventory** ให้ล้นซั๊กไม่เอียงข้างเดียว สปรดเป็นแค่คำตอบแทน ความเสี่ยงตัวจริงคือสต็อกค้างมือ

สัญญาณ skew: เอียงราคาเพื่อระบายสต็อก

ถ้าล้นซั๊กเต็มไปด้วย BTC (long มากไป) MM ฉลาดจะทำอะไร? — "อยากขายมากกว่าซื้อ" วิธีง่ายที่สุดคือ เลื่อน quote ทั้งสองฝั่งลง: ลด ask ให้คนมาซื้อจากเราง่ายขึ้น (ระบาย BTC ออก) และลด bid ให้คนมาขายใส่เราง่ายขึ้น (ไม่อยากรับเพิ่ม) — นี่คือ **skew**

สังเกตว่า skew ไม่ได้แปลว่า "เดาว่าราคาจะลง" — มันแปลว่า "ฉันถือเยอะไป ขอเลื่อนราคายุติธรรมในใจฉันลงมาเพื่อจูงใจให้ตลาดช่วยระบายสต็อก" นี่คือ **เมล็ดพันธุ์ของ reservation price** ที่จะกลายเป็นสูตรเต็มใน Part 10



ภาพ 9.3 · skew quote — ถือ long มาก เลื่อน quote ลงเพื่อระบายสต็อก (ปูทาง Part 10)

สูตรสัญญาณ (เวอร์ชันง่าย ก่อนเข้า A-S เต็ม):

$bid_skew = mid - \delta/2 - k \cdot q$

$ask_skew = mid + \delta/2 - k \cdot q$

δ = สปรดฐาน, q = inventory สุทธิ, k = ความแรงของการ skew ($k > 0$)
 $q > 0$ (long) → ทั้ง bid, ask เลื่อนลง → อยากขายมากกว่าซื้อ
 $q < 0$ (short) → ทั้ง bid, ask เลื่อนขึ้น → อยากซื้อมากกว่าขาย

งานวิจัยรองรับ

แนวคิด "MM ต้องถ่วงดุล inventory ด้วยการเอียงราคา" ถูกวางรากฐานโดย **Ho & Stoll (1981)** ที่มองว่า dealer ปรับ quote ตามระดับสต็อกเพื่อคุมความเสี่ยง และ **Glosten & Milgrom (1985)** ที่อธิบายว่าสปรดส่วนหนึ่งมีไว้ป้องกัน adverse selection — ทั้งสองงานคือฐานที่ **Avellaneda & Stoikov (2008)** นำมาเขียนเป็นสูตร reservation price ใน Part 10 และต่อยอดสู่ยุค reinforcement learning ในเวลาต่อมา

เชื่อมโยงเล่มอื่น

PnL ของ MM = $\text{PnL}_{\text{spread}} + q \cdot \Delta p$ นั่นคือ **payoff ที่มี inventory เป็นตัวคูณความเสี่ยง** — ตรงกับมุมมองใน **Payoff Mastery (pm)** ที่ว่ากำไรขาดทุนต้องคิดบนตำแหน่งจริง ไม่ใช่แค่ราคา ส่วนเครื่องมือคำนวณ k , δ และการ optimize จะใช้ความรู้ regression/optimization จากเล่ม **math** เต็มตัวใน Part 10

กับเคสของเรา

ถ้าแทนที่จะใช้ market buy \$5,000 (เป็น taker จ่ายสปรด+fee ทันที) เราเปลี่ยนมา **วาง limit เข้า long แบบ MM** — เราจะได้สถานะ maker คืน rebate และเข้าได้ในราคาที่ดีกว่า mid แต่แลกมาด้วย **inventory risk**: ถ้าราคาวิ่งขึ้นเราจะถูก fill ฝั่ง bid เรื่อย ๆ สะสม BTC ขณะที่ราคายังร่วง — เก็บสปรดได้แต่ขาดทุนจาก inventory กลบหมด (Part 10 จะบอกว่าควร skew quote ยังไง)

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

จำลองด้วยมือ: สมมติ mid = 60,000 คงที่, สปรด $\delta = 6$, คุณตั้ง bid 59,997 / ask 60,003 ระหว่างวันมี taker มา fill **bid 7 ครั้ง และ ask 3 ครั้ง** (อย่างละ 1 BTC)

1. คำนวณ inventory สุทธิ q หลังจบวัน (เฉลย: $q = +7 - 3 = +4$ BTC)
2. คำนวณ PnL_spread ที่เก็บได้จากคู่ที่จับครบ — **1 รอบ = คู่ buy+sell ที่จับครบ** ดังนั้น fill 10 ครั้ง (bid 7 + ask 3) จับเป็นคู่ได้แค่ $\min(7,3) = 3$ รอบ ส่วน bid อีก 4 ครั้งค้างเป็น inventory ($3 \text{ รอบ} \times 6 = 18$ USDT)
3. ถัดตอนปิดราคาตก 50 USDT คำนวณ PnL_inventory = $q \cdot \Delta p (= 4 \cdot (-50) = -200)$ แล้วรวมสุทธิ
4. ลองใส่ skew $k = 1.5$: คำนวณ bid_skew/ask_skew ใหม่ตอน $q = +4$ แล้วอธิบายว่าทำไมมันช่วยลดความเสี่ยง

จากนั้นเปิด Binance ดู maker/taker fee จริงของคู่ BTC/USDT แล้วคำนวณว่าสปรด 6 USDT ยังเหลือกำไรหลังหัก fee ไหม

ส่งต่อ → รู้แล้วว่า skew คือกุญแจคุม inventory — แต่ควรเลื่อน quote ลง *เท่าไร* ถึงจะ optimal? Part 10 จะแปลงสัญญาณ skew ให้เป็นสูตร reservation price ของ Avellaneda-Stoikov

อ่านกระดาน

Reading the Book

Part 10: MM-2 Optimal — วาง quote ตรงไหนถึงดีที่สุด

Order Flow & Microstructure สำหรับรายย่อย · องค์กร IV Market Making

Avellaneda-Stoikov: reservation price, optimal spread, adverse selection, value function → ชูค

RL

 อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > **ตัดสินใจเข้า-ออก** > ต่อยอด/คุมเสี่ยง

Part 10 — MM-2 Optimal: Avellaneda-Stoikov

🔗 ต่อจากตอนก่อน

เพ็ญรัฐมา: Part 9 ให้สัญชาตญาณ skew — ถือ long มากก็เลื่อน quote ลงเพื่อระบายสต็อก แต่ยังเป็นแค่ "เอียงตามความรู้สึก" (สูตรง่าย $\text{bid} = \text{mid} - \delta/2 - k \cdot q$) · **ตอนนี้จะเติม:** แปลง $k \cdot q$ ที่เดาเอาให้เป็นสูตรที่อธิบายได้จริงด้วย Avellaneda-Stoikov — reservation price บอกว่าควรเลื่อน *เท่าไร* โดยคิดทั้งความผันผวน เวลาที่เหลือ และความกลัวความเสี่ยง

📖 อ่านจบ Part นี้คุณจะได้

- เข้าใจ **reservation price** = "ราคายุติธรรมในใจพ่อค้า" ที่ขยับตามสต็อก — หัวใจของ Avellaneda-Stoikov
- อ่านสูตร $r = s - q \cdot y \cdot \sigma^2 \cdot (T-t)$ ออกว่าแต่ละตัวแปลหมายถึงอะไรและทำไมมันสมเหตุสมผล
- เข้าใจ **optimal spread** ว่ามาจากการชั่งน้ำหนักระหว่างความเสี่ยง inventory กับโอกาส fill
- เห็นชัดว่า **naive MM (quote สมมาตรไม่ skew)** ตายเพราะ **adverse selection** ขณะ optimal รอด — ผ่านกราฟ P&L
- เห็นภาพ **เส้นทางวิวัฒนาการ** จาก Ho-Stoll → A-S → Guéant → reinforcement learning


ราคายุติธรรมในใจพ่อค้าขายร่ม

นึกถึงพ่อค้าขายร่มข้างถนน เช้านี้เขามีร่ม 50 คัน "ราคายุติธรรมในใจ" ของเขาคือ 100 บาท เขาจึงตั้งรับซื้อ 95 ขาย 105 — สมมาตรรอบ 100

ผ่านไปครึ่งวัน ขายดีมากจนเหลือร่มแค่ 5 คัน ฝนกำลังจะตก เขากลับของหมดก่อนปิดร้าน — "ราคายุติธรรมในใจ" ของเขา **ขยับขึ้นเป็น 110** โดยอัตโนมัติ เขาไม่อยากขายถูกแล้ว เขาตั้งขาย 115 รับซื้อ 105 (อยากซื้อร่มเข้าสต็อกคืน)

กลับกัน ถ้าเหลือร่ม **200 คัน** และใกล้ฟ้าจะเปิด เขากลับของค้าง "ราคาในใจ" จะ **ตกลงเหลือ 90** เขายอมขายถูกเพื่อระบายสต็อก

"ราคายุติธรรมในใจที่ขยับตามสต็อก" นี่แหละคือ reservation price — มันไม่ใช่ราคาดตลาด (mid) แต่เป็นราคาที่พ่อค้าใช้เป็นจุดศูนย์กลางในการตั้ง quote ของตัวเอง ยิ่งถือเยอะ ยิ่งดึงให้ต่ำกว่า mid เพื่อเร่งระบาย



ภาพ 10.1 · reservation price ถูกดึงออกจาก mid ตามทิศและขนาดของ inventory

สูตร reservation price

Avellaneda & Stoikov (2008) เขียน "ราคาในใจ" นี้เป็นสมการ:

$$r = s - q \cdot \gamma \cdot \sigma^2 \cdot (T - t)$$

r = reservation price (ราคายุติธรรมในใจ MM)

s = mid price ปัจจุบัน

q = inventory สุทธิ (long = บวก, short = ลบ)

γ = ความกลัวความเสี่ยง (risk aversion) — γ สูง = ชี้กแล้ว

σ^2 = ความผันผวน (variance ของราคา)

$(T - t)$ = เวลาที่เหลือก่อนปิดรอบ — ใกล้ปิดยิ่งใกล้ inventory น้อยลง

อ่านสูตรแบบไม่ต้องท่อง — แค่ว่า **"ตัวลบ" $q \cdot \gamma \cdot \sigma^2 \cdot (T-t)$ ดึง r ออกจาก mid เท่าไหร่:**

- **q บวกมาก (long เยอะ)** → ตัวลบใหญ่ → r ต่ำกว่า mid มาก → quote เอียงลง → แรงขายระบาย (ตรงกับพอดัรุ่มที่ของสั้น)
- **γ สูง (ชี้กแล้ว)** → ตัวลบใหญ่ → ยิ่งใกล้ยิ่งดึง r หนีจาก mid เร็ว
- **σ^2 สูง (ผันผวน)** → ถือ inventory อันตรายขึ้น → ดึง r หนีแรงขึ้น
- **$(T-t)$ เล็ก (ใกล้ปิด)** → ตัวลบเล็กลง → ใกล้หมดเวลาแล้ว ถือ inventory ไม่กี่วินาทีไม่น่ากลัว → r เข้าใกล้ mid อีกครั้ง

Optimal spread: กว้างเท่าไรถึงดี

มี r แล้วต้องตั้ง bid/ask ห่างจาก r เท่าไหร่? A-S ให้สูตร **optimal spread** ที่ซึ่งน้ำหนัก 2 แรง: ความเสี่ยง inventory (อยากกว้างไว้ปลอดภัย) กับ ความถี่ fill (อยากแคบไว้ได้เทรดบ่อย)

$$\delta_{\text{total}} = \gamma \cdot \sigma^2 \cdot (T - t) + (2/\gamma) \cdot \ln(1 + \gamma/k)$$

δ_{total} = สปรดรวมสองฝั่ง (bid+ask) — คนละตัวกับ δ ฐานใน Part 9


ก่อนแรก = ค่าชดเชยความเสี่ยง inventory (เหมือนใน r)

ก่อนสอง = ค่าชดเชยจาก order arrival — k คือความไวของ fill ต่อระยะ quote

$$\text{bid} = r - \delta_{\text{total}}/2$$

$$\text{ask} = r + \delta_{\text{total}}/2$$

จุดสำคัญที่มือใหม่มักพลาด: **bid/ask ของ A-S วางสมมาตรรอบ r ไม่ใช่รอบ mid** เพราะ r เอียงไปตาม inventory อยู่แล้ว ผลลัพธ์คือ quote สองฝั่งจริง ๆ ไม่สมมาตรรอบ mid — ฝั่งที่อยากระบายจะอยู่ใกล้ mid กว่า




ภาพ 10.2 · bid/ask สมมาตรรอบ r (ที่ถูกดึงต่ำกว่า mid เพราะ long)

ทำไม naive MM ถึงตาย — adverse selection

Naive MM = ตั้ง bid/ask สมมาตรรอบ mid เสมอ ไม่สนใจ inventory ฟังดูเป็นกลางดี แต่มันตายเพราะ 2 เหตุผลที่ทบกัน:

1. **Inventory ร่วงหนีไม่หยุด** — ไม่มีกลไก skew ดึงกลับ ตลาดเทรดเดียวจะอัด inventory ฝั่งเดียวจนพอร์ตระเบิด
2. **Adverse selection** — คนที่มา fill quote ของเรา "บ่อยกว่า" คือคนที่ถูกข้าง เวลาเรากำลังจะขึ้น คนแห่มากิน ask ของเรา (เราขายถูกให้เขา) เวลาเรากำลังจะลง คนแห่มาชน bid ของเรา (เรารับแพง) — **MM มักโดน fill ในจังหวะที่ผิดเสมอ**

Optimal MM ลู่อ adverse selection ด้วยการ skew (ผ่าน r): พอ inventory เริ่มเอียง r จะดึง quote ให้ฝั่งที่เสี่ยงอยู่ไกล mid ขึ้น ลดโอกาสโดน fill ซ้ำเติม นี่คือเหตุผลที่กราฟ P&L ต่างกันราวฟ้ากับเหว



ภาพ 10.3 · P&L optimal vs naive — naive ดูดีช่วงแรกแล้วระเบิดเพราะ adverse selection + inventory

! กับดักมือใหม่ — "เป็นกลางรอบ mid = ปลอดภัยสุด"

หลายคนคิดว่าการตั้ง quote สมมาตรรอบ mid คือ "ไม่เลือกข้าง = ปลอดภัย" — **ตรงกันข้าม** มันคือสูตรของการโดน adverse selection เต็ม ๆ เพราะคุณปล่อยให้ตลาดเลือกข้างให้คุณ (คนถูกข้างมา fill คุณก่อนเสมอ) ความปลอดภัยจริงมาจากการ **ยอมเอียง quote ตาม inventory** เพื่อบังคับให้สต็อกกลับเข้าศูนย์ — γ ไม่ใช่ "ความขลาด" แต่คือ "วินัยคุมความเสี่ยง" ที่ใส่เป็นตัวเลขในสมการ

Value function: ที่มาของสูตร (มองผ่าน ๆ พอ)

สูตร r และ δ ไม่ได้เดาเอา — มันมาจากการแก้ปัญหา optimization ที่ถามว่า "ตั้ง quote ยังไงให้ **มูลค่าคาดหวังของความมั่งคั่งสุดท้าย** สูงสุด โดยหักโทษความเสี่ยง" คณิตศาสตร์เบื้องหลังคือ *value function* $u(s, q, t)$ ที่แก้ผ่านสมการ HJB (Hamilton-Jacobi-Bellman)

แนวคิด (ไม่ต้องแก้เอง):

$$u(s, q, t) = \max E[-\exp(-\gamma \cdot \text{wealth สุดท้าย})]$$


$$\text{wealth สุดท้าย} = \text{เงินสด} + q \cdot (\text{ราคาเลิกกิจการ})$$

แก้ HJB $\rightarrow$ ได้ r และ δ_{total} ข้างต้นเป็นคำตอบ

ไม่ต้องแก้สมการเองได้ ขอแค่จับ **สัญชาตญาณ**: u ลงโทษ q ที่ใหญ่ (ผ่าน $-\exp(-\gamma \cdot \dots)$) ดังนั้นคำตอบที่ optimal จึงต้อง "พยายามดึง q กลับศูนย์เสมอ" — ซึ่งออกมาเป็นกลไก skew ที่เราเห็นใน r พอดี

จาก A-S สู่ยุค Reinforcement Learning

A-S สวยแต่ตั้งอยู่บนสมมติฐานที่สวยเกินจริง (ราคาเป็น Brownian, order arrival เป็น Poisson คงที่, ไม่มี market impact) โลกจริงไม่เป็นแบบนั้น เลยมีการต่อยอดเรื่อยมา:



ภาพ 10.4 · วิวัฒนาการ inventory model → A-S → closed-form → RL

ยุค **Reinforcement Learning** เปลี่ยนจาก "แก้สมการหา quote" เป็น "ให้เอเจนต์ลองตั้ง quote ในสภาพแวดล้อมจำลองล้านครั้งแล้วเรียนรู้นโยบายเอง" โดยมีฟังก์ชันรางวัลที่ลงโทษ inventory คล้ายเดิม:

RL objective: $\max E[\sum (PnL_t - \lambda \cdot q_t^2)]$

PnL_t = กำไรแต่ละก้าว, $\lambda \cdot q_t^2$ = โทษการถือ inventory (แทน y ใน A-S)

เอเจนต์เรียน policy $\pi(\text{state}) \rightarrow \text{action}$ (ตั้ง bid/ask offset) เอง

state = [inventory, spread, OBI, OFI, volatility, ...]

งานวิจัยรองรับ (A-S → RL)

Avellaneda & Stoikov (2008) คือต้นฉบับของ reservation price + optimal spread ต่อยอดจาก **Ho & Stoll (1981)** · **Guéant-Lehalle-Fernandez-Tapia (2013)** ให้คำตอบ closed-form ที่จัดการ inventory limit ได้ดีขึ้น · ยุคหลังมีงาน RL เช่น *Market Making with Deep RL from LOB* (arXiv 2305.15821) และ *Resolving Latency & Inventory Risk* (arXiv 2505.12465) ที่ให้เอเจนต์เรียน quoting policy จากข้อมูล LOB จริง — แต่ทั้งหมดยังตั้งบนหลักเดียวกัน: ลงโทษ inventory เพื่อสู้ adverse selection

เชื่อมโยงเล่นอื่น

สูตร A-S คือการ **optimize ภายใต้ความไม่แน่นอน** — ใช้เครื่องมือ calculus/optimization และแนวคิด variance/risk จากเล่ม **math** โดยตรง (HJB คือ optimization แบบ dynamic) ส่วนการมองกำไรหลังหักโทษความเสี่ยง ($PnL - \lambda q^2$) คือ **risk-adjusted payoff** ที่ตรงกับหัวใจของ **Payoff Mastery (pm)** — เทรดที่ดีไม่ใช่กำไรสูงสุด แต่คือกำไรต่อหน่วยความเสี่ยงที่ดีที่สุด

กับเคสของเรา

ในเคส \$5,000 long BTC ถ้าเราเล่นเป็น MM: สูตร A-S บอกตรง ๆ ว่าควรวาง bid/ask ตรงไหน — พอเราถูก fill ฝั่ง bid จน q เป็นบวก (สะสม BTC), r จะดึงต่ำกว่า mid อัตโนมัติ ทำให้ bid ฝั่งซื้อถอยห่าง (รับเพิ่มยากขึ้น) และ ask เข้าใกล้ mid (ระบายง่ายขึ้น) — เป็นวิธี **คุม inventory risk** จากการได้ **rebate** ที่ Part 9 เตือนไว้ ให้กลับเข้าศูนย์โดยไม่ต้องเดาทิศทางราคา

🔧 แบบฝึก (เขียนโค้ดสั้น ๆ ได้)

เขียนฟังก์ชันคำนวณ reservation price และ quote แล้วทดลองเล่นตัวแปร:

```
def quote(s, q, gamma, sigma, T_minus_t, kappa):
    r = s - q * gamma * sigma**2 * T_minus_t
    delta = gamma*sigma**2*T_minus_t +
    (2/gamma)*math.log(1+gamma/kappa)
    bid = r - delta/2
    ask = r + delta/2
    return r, bid, ask
```

1. เรียกด้วย $s=60000$, $q=0$, แล้วเทียบ $q=+10$ และ $q=-10$ — สังเกตว่า r เลื่อนไปทางไหน และ quote ผันไหนเข้าใกล้ mid
2. เพิ่ม γ จาก $0.1 \rightarrow 1.0$ ดูว่า quote กว้างขึ้นหรือแคบลง และ r หนีจาก mid เร็วขึ้นไหม
3. ลด $(T-t)$ ลงเรื่อย ๆ จนใกล้ 0 ดูว่า r เข้าใกล้ mid อีกครั้งไหม (ใกล้ปิดรอบ)
4. เขียน loop จำลอง fill ตาม Poisson เทียบ P&L ของ optimal (มี skew) กับ naive (สมมาตรรอบ mid) บนชุดราคาเทรดเดี่ยว — ดูว่า naive ระเบิดจริงไหม

ส่งต่อ → สูตรสวบนกระดานแล้ว แต่พอเอาไปรันจริงจะเจออะไร? Part 11 ประกอบสูตร A-S เป็น MM loop ที่รันได้ พร้อมเปิดโปง 3 กับดัก backtest ที่ทำให้กราฟสวยกลายเป็นขาดทุนจริง

อ่านกระดาน

Reading the Book

Part 11: MM-3 ลงมือจริง — จาก quote สู่ระบบรันได้

Order Flow & Microstructure สำหรับรายย่อย · องค์กร IV Market Making

MM loop, microprice, post-only, inventory limit + kill switch และกับดัก backtest 3 ข้อ

 อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > **ตัดสินใจเข้า-ออก** > ต่อยอด/คุมเสี่ยง

Part 11 — MM-3 ลงมือจริง + กับดัก backtest

🔗 ต่อจากตอนก่อน

เพ็ญรู้มา: Part 10 ให้สูตร Avellaneda-Stoikov คำนวณ reservation price + optimal spread ที่ optimal บนกระดาน · **ตอนนี้จะเดิม:** เอาสูตรนั้นมาประกอบเป็น MM loop ที่รันได้จริง (microprice, post-only, kill switch) แล้วเปิดโปง 3 กับดัก backtest — fill assumption, latency, market impact — ที่ทำให้กลยุทธ์ "optimal" บนกระดานเจ๊งจริง

🎯 อ่านจบ Part นี้คุณจะได้

- เห็นโครง **MM loop** ที่รันได้จริง: รับ L2 + trade stream → คำนวณ → ตั้ง/ยกเลิก quote วน
- รู้จัก **microprice** — ราคาอ้างอิงที่ดีกว่า mid เพราะถ่วงน้ำหนักด้วยความหนาแน่นสองฝั่ง
- ใช้ **post-only** เพื่อการันตีเป็น maker และตั้ง **inventory limit + kill switch** กันพอร์ตระเบิด
- รู้ทัน **กับดัก backtest 3 ข้อ** ที่ทำให้กราฟสวยกลายเป็นขาดทุนจริง: fill assumption, latency, market impact

backtest คือกระจกห้องลองเสื้อ


เคยลองเสื้อในห้องลองที่ห้างไหม? — กระจกเอียงนิด ไฟวอร์มนิด ทุกตัวดูดีไปหมด พอซื้อกลับบ้านมาลอง กระจกตัวเองถึงรู้ว่า "มันไม่เหมือนในห้องลองเลย"

Backtest ของกลยุทธ์ MM ก็คือกระจกห้องลองเสื้อ — มันถูกออกแบบ (โดยตั้งใจหรือไม่ตั้งใจ) ให้ผลลัพธ์ดูสวยกว่าความจริง เพราะมันตั้งสมมติฐานเข้าข้างตัวเองหลายอย่าง โดยเฉพาะเรื่อง "เราได้ fill ทุก quote ที่ราคาแตะ" ซึ่งในตลาดจริง **ไม่จริงเลย**

Part นี้แบ่งสองครึ่ง: ครึ่งแรกประกอบ "ร่างกาย" ของ MM ที่รันได้จริง ครึ่งหลังคือ "กระจกเงาความจริง" — สามกับดัก backtest ที่ต้องรู้ก่อนเอาเงินจริงไปเสี่ยง

MM loop: ร่างกายของระบบ

ระบบ MM ที่รันได้จริงคือลูบที่หมุนตลอดเวลา รับข้อมูลสองสาย (L2 order book + trade stream ผ่าน WebSocket) แล้วตัดสินใจตั้ง/ยกเลิก quote:



ถ้า kill switch ทำงาน → ข้ามขั้น 4, ยิ่ง market ปิด inventory, หยุด

ความปลอดภัย > ถ้าไร: เช็คความเสี่ยงก่อนตั้ง quote เสมอ

ภาพ 11.1 · MM loop — รับ stream → คำนวณ → เช็คความเสี่ยง → ตั้ง/ยกเลิก quote → วน

Microprice: ราคาอ้างอิงที่ดีกว่า mid


$mid = (bid + ask) / 2$ มองสองฝั่งเท่ากันเสมอ แต่ถ้าฝั่ง bid หนากว่าฝั่ง ask มาก ๆ ราคา "จริง ๆ" มีแนวโน้มถูกดึงเข้าหาฝั่งที่บาง (= ask) microprice แก่จุดนี้ด้วยการถ่วงน้ำหนักด้วยปริมาณฝั่งตรงข้าม:

$$microprice = (p_{bid} \cdot V_{ask} + p_{ask} \cdot V_{bid}) / (V_{bid} + V_{ask})$$

สังเกต: ฝั่งที่ "หนากว่า" จะดึง microprice เข้าหาฝั่งที่บาง (ฝั่งตรงข้าม)

$V_{bid} > V_{ask}$ (แรงซื้อหนา) → microprice ดึงเข้าหาฝั่งที่บาง (= ask) → มีแนวโน้มขึ้นเชิงสถิติระยะสั้น

ใช้ microprice แทน s ในสูตร reservation price ของ Part 10 ได้



ภาพ 11.1b · microprice ดึงเข้าหาฝั่งที่บาง (= ask) เมื่อ bid หนากว่า ask

Post-only, inventory limit, kill switch

เครื่องมือ	ทำอะไร	ทำไมขาดไม่ได้
post-only	limit ที่ยกเลิกอัตโนมัติถ้าจะกลายเป็น taker	การันตีเป็น maker เสมอ → ได้ rebate / ไม่จ่าย taker fee + spread โดยบังเอิญ
inventory limit	หยุดตั้ง quote ฝั่งที่ทำให้ q เกินเพดาน	กัน inventory รุ่งขึ้นฝั่งเดียวจนเกินที่รับความเสี่ยงไหว
kill switch	ปิด inventory ทันที + หยุดบอท เมื่อขาดทุน/ผันผวนเกินกำหนด	กันหายนะตอนตลาดเกิดเหตุผิดปกติ (flash crash, ข่าวแรง)

```
# pseudo-code: ก้อนความปลอดภัยใน MM loop
if abs(inventory) >= INV_LIMIT:
    skip_quote_on_growing_side() # ไม่เติมฝั่งที่ทำให้ q โตขึ้น
if pnl_drawdown > MAX_DD or vol > VOL_CAP:
    market_close_all(); halt() # kill switch
else:
    place_order(bid, post_only=True)
    place_order(ask, post_only=True)
```

กับดัก backtest 3 ข้อ (หัวใจของ Part)

นี่คือ "กระจกเงาความจริง" — สามเหตุผลที่กราฟ backtest สวยมักโกหก:

⚠ กับดัก 1 — Fill assumption (อันตรายที่สุด)

Backtest ส่วนใหญ่สมมติว่า "ถ้าราคาและ quote ของเรา = เราได้ fill" — ผิดมหันต์! ในความจริงคุณอยู่ **ท้ายคิว** (Part 1) ราคาต้องแตะ แล้วเทรดทะลุคิวข้างหน้าคุณหมด คุณถึงได้ fill และร้ายกว่านั้น: quote ที่ได้ fill ง่ายมักเป็นจังหวะ **adverse selection** (ราคากำลังวิ่งสวนคุณ) backtest ที่ assume fill ฟรีจึงนับกำไรที่ไม่มีจริง และมองข้ามการขาดทุนที่มีจริง

⚠ กับดัก 2 — Latency (ความหน่วง)


Backtest มองเห็นข้อมูลและตอบสนอง "ทันที 0 วินาที" แต่ของจริงมี latency ทั้งขารับข้อมูลและขาอิงคำสั่ง กว่า你会เห็น microprice ขยับแล้วยกเลิก quote เก่า ตลาดเคลื่อนไปแล้ว — **quote เก่าที่ยังค้างอยู่คือ quote ที่โดน "เก็บ" ในจังหวะที่แย่มากที่สุด** รายย่อยที่แข่ง latency กับ HFT คือเอาจักรยานไปแข่งกับรถแข่ง

⚠️ กีบดัก 3 — Market impact (เราคือส่วนหนึ่งของตลาด)

Backtest รันบนข้อมูลในอดีต **ที่ไม่มีตัวเราอยู่ในนั้น** มันสมมติว่า order ของเราไม่กระทบกระดานเลย — แต่ของจริง quote ของเราเปลี่ยน OBI, เปิดคิวคนอื่น, และถ้าเราต้องยิง market ปิด inventory เรา จะ walk the book ต้นราคาสวนตัวเอง (Part 2) ยิ่งไม้ใหญ่ ยิ่ง **impact** มาก **กำไรในกระดานหายไปกับ impact ที่ backtest มองไม่เห็น**

📄 cross-ref — ไม้ใหญ่ต้องทยอยส่ง ไม่ใช่ทีเดียว (optimal execution)

กีบดัก market impact ข้างบนโยงตรงกับงาน **Almgren & Chriss (2000) — optimal execution**: ถ้า ต้องเข้า/ออกไม้ใหญ่ (เช่นตอน kill switch ปิด inventory ก้อนโต) การยิงทีเดียวจะ walk the book ต้น ราคาสวนตัวเองหนัก — ทางที่ดีกว่าคือ **ซอยไม้ทยอยส่ง** ซึ่งน้ำหนักระหว่าง market impact (ยิ่งเร็วยิ่ง กระทบราคา) กับ timing risk (ยิ่งช้ายิ่งเสี่ยงราคาวิ่งหนี) · **Guéant (2017)** ต่อยอดเส้นนี้เข้ากับ A-S โดยตรง — รวม optimal market making กับ optimal execution เป็นกรอบเดียว (MM ที่คุม inventory limit จริง ๆ ต้องคิดทั้งการ วาง quote และการ ทยอยปิดสถานะ พร้อมกัน) เป็นสะพานไปองค์ "ต่อยอด/ คุมเสี่ยง"



ภาพ 11.2 · backtest สวอย vs ความจริง — fill assumption + latency + market impact กินกำไรหมด

บันได backtest → paper → live

อย่ากระโดดจาก backtest ไป live ตรง ๆ ให้ไต่บันได เพื่อให้ความจริงค่อย ๆ เผยตัว:

- **Backtest** — เร็ว ถูก แต่โกหกได้ (3 กีบดัก) ใช้คัดไอเดียที่แย่ชัด ๆ ออกเท่านั้น
- **Paper / forward test** — รันสด ๆ บนตลาดจริงด้วยเงินปลอม เห็น latency จริง เห็นว่า quote ได้ fill จริงไหม

- **Live ไม่เล็กสุด** — เงินจริงจำนวนน้อยมาก วัด **adverse fill rate (AFR)** และ PnL_{net} หลังหัก fee จริง ค่อยขยายถั่วรอด

$$\text{microprice} = (p_{bid} \cdot V_{ask} + p_{ask} \cdot V_{bid}) / (V_{bid} + V_{ask})$$

$$PnL_{net} = PnL_{spread} + q \cdot \Delta p + rebate - taker_fee_on_closes - slippage$$

$$AFR = adverse_fills / total_fills \text{ (ยิ่งสูง = โดน adverse selection เยอะ)}$$

งานวิจัยรองรับ

ความสำคัญของ queue position และ fill ที่ไม่ใช่ "แตะแล้วได้" สะท้อนในงานสาย queue dynamics เช่น **Lu & Abergel (2018)** และ *Importance of Order Sizes* (arXiv 2405.18594) ส่วนการต่อยอด A-S ให้รับมือ latency/inventory จริงมีใน *Resolving Latency & Inventory Risk in MM* (arXiv 2505.12465) และงาน RL บน LOB ที่ไม่นิ่ง (arXiv 2509.12456) — ทั้งหมดตอกย้ำว่า **ช่องว่างระหว่าง backtest กับ live คือ fill realism, latency และ impact** ไม่ใช่ความฉลาดของสูตร

เชื่อมโยงเล่มอื่น

microprice ใช้ OBI/depth จาก **Part 5** และ adverse selection จาก **Part 6** โดยตรง · PnL_{net} คือ payoff ที่หักต้นทุนจริงครบทุกชั้น ตรงกับวินัยของ **Payoff Mastery (pm)** ที่ย้ำว่าต้องคิดต้นทุนการเข้า-ออกจริง · ส่วน effective price ตอนปิด inventory (walk the book) คือต้นทุนเดียวกับที่เล่ม **arb** ใช้ คำนวณว่าโอกาส arb คุ่มจริงไหม

กับเคสของเรา

ถ้าจะรันบอต MM จริงกับเคส \$5,000 long BTC — กราฟ backtest ที่เก็บ rebate ได้สวยอาจโกหก เพราะมันสมมติว่าได้ fill ทุก quote ที่ราคาแตะ (กับดัก 1) ของจริงเราอยู่ท้ายคิวและมักโดน fill ในจังหวะ adverse · ก่อนเอา \$5,000 ลงจริง ต้องไต่บันได backtest → paper → live ไม่เล็กสุด แล้ววัด AFR กับ PnL_{net} หลังหัก fee จริง · และถ้าต้องปิด inventory ก่อนโต อย่างยิ่งที่เดียว — หอยยส่งตามแนว Almgren-Chriss ด้านบน

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

เป้าหมาย: "จับโกหก" ตัวเองให้ได้ก่อนเสียเงินจริง

1. ดู pseudo-code ลูปด้านล่าง หา **fill assumption ที่อันตราย** แล้วอธิบายว่าทำไมมันทำให้ backtest สวยเกินจริง
2. แก่ฟังก์ชัน fill ให้สมจริงขึ้น: fill ได้ก็ต่อเมื่อ volume ที่เทรดผ่านราคาดนั้น > คิวที่อยู่ข้างหน้าเรา
3. ใส่ latency จำลอง: หน่วงการเห็นข้อมูลและการยกเลิก quote สัก 100–300 ms แล้ววัด AFR ใหม่
4. เทียบ P&L_net 3 เวอร์ชัน: (ก) fill ฟรี (ข) fill ตามคิว (ค) fill ตามคิว + latency — ดูว่ากราฟต่ำลงที่ละชั้นจริงไหม

```
# pseudo-code มีกับดัก – หา fill assumption ที่ผิด
for tick in backtest_data:
    bid, ask = quote(microprice(tick), inventory, ...)
    if tick.low <= bid: # <-- กับดัก! แตะ = fill?
        inventory += 1; cash -= bid
    if tick.high >= ask: # <-- กับดักเดียวกัน
        inventory -= 1; cash += ask
# ของจริง: ต้องเช็คคิวข้างหน้า + latency + ไม่นับ fill ที่ราคาเพิ่งทะลุผ่านเฉย ๆ
```

ส่งต่อ → ถ้าวาง quote สองฝั่งที่ละคุ่มันคุ่มยากในตลาดจริง — จะกระจาย quote เป็นชั้น ๆ อัตโนมัติแล้วเอียงตามกระดานได้ไหม? Part 12 ยกระดับ grid trading ด้วย OBI/OFI และใช้ VPIN กันกริดแตก

อ่านกระดาน

Reading the Book

Part 12: Grid Trading กับกระดาน — ยกระดับ grid ด้วย order flow

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์
เปลี่ยน grid bot ตายตัวให้ "มองเห็นกระดาน" — เอียงตาม imbalance, หยุดเมื่อ toxic flow

 อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > **ตัดสินใจเข้า-ออก** > ต่อยอด/คุมเสี่ยง

Part 12 — Grid Trading กับกระดาน

ต่อจากตอนก่อน

เพ็ญรัฐมา: Part 11 ปิดดองก็ MM ด้วยการประกอบ quote loop ที่รันได้จริง — ใช้ **microprice** (ถ่วงน้ำหนักสองฝั่งดีกว่า mid) เป็นราคาอ้างอิง วาง post-only เก็บ rebate และมี inventory limit + kill switch กันพอร์ตแตก · **ตอนนี้จะเติม:** เอา quote loop นั้นมา "ตรึงราคาไว้ล่วงหน้าเป็นชั้น ๆ" = grid trading แล้วยกระดับด้วยกระดาน — เอียง grid ตาม OBI/OFI และใช้ VPIN เป็นเบรกกันเทรนด์เดียวล่างพอร์ต

อ่านจบ Part นี้คุณจะได้


- เข้าใจว่า **grid trading คือ market making ที่มี "กฎตายตัว"** — วาง bid/ask เป็นชั้น ๆ รอกินส่วนต่าง
- รู้จุดอ่อนคลาสสิกของ grid: **เทรนด์เดียวล่างพอร์ต** และ **กำไรต่อไม้ < fee×2**
- **เอียง (skew) grid ด้วย OBI/OFI** เพื่อหลบฝั่งที่กระดานกำลังกดดัน
- ใช้ **VPIN เป็นสวิตช์หยุด grid** ก่อนกระดานจะ "แตก" และตั้ง **spacing ไดนามิก** ตาม spread/volatility จริง

เริ่มจากตาข่ายจับปลาหลายชั้น

นึกถึงชาวประมงวาง **ตาข่ายหลายชั้นขวางลำน้ำ** — ปลาที่ว่ายไป-มาในระดับน้ำปกติจะติดตาข่ายเรื่อย ๆ ทีละตัว นั่นคือกำไรของ grid ในตลาด **sideway** (ราคาแกว่งขึ้นลงในกรอบ)


แต่ถ้า **น้ำหลาก** (เทรนด์แรงทิศเดียว) — ตาข่ายทุกชั้นจะถูกกระแสน้ำพัดไปกองรวมกันด้านเดียว แล้วขาดยับ นั่นคือเวลาที่ grid bot "ถือของฝั่งผิดเต็มมือ" แล้วล่างพอร์ต **กระดาน (order book) คือเครื่องวัดกระแสน้ำ** ที่ช่วยให้เรารู้ก่อนว่าน้ำกำลังจะหลาก

น้ำนิ่ง (sideway) → กำไร



ติดต่ายที่ละตัว = กินส่วนต่าง

น้ำไหล (trend) → ตายขายขาด




ถือของฝั่งผิดเต็มมือ = ล้างพอร์ต

ขั้นที่ 1 — grid คือ MM ที่มีกฎตายตัว

ใน Part 9–11 เราเรียน market making ที่ปรับ quote ตลอดเวลา **grid trading คือเวอร์ชันที่ "ล็อกราคา quote ไว้ล่วงหน้า" เป็นขั้น ๆ ห่างเท่ากัน ไม่ขยับตามทุก tick:**

- วาง **limit buy (bid)** เป็นบันไดลงด้านล่าง mid — เหมือน MM ฝั่งให้สภาพคล่องซื้อ
- วาง **limit sell (ask)** เป็นบันไดขึ้นด้านบน mid — ฝั่งให้สภาพคล่องขาย
- เมื่อราคาแกว่งลงมาโดน bid → ซื้อได้ แล้วตั้ง sell ที่ชั้นบนถัดไป → ขายปิดกินส่วนต่าง Δ_grid



ภาพ 12.1 · grid ladder — บันได bid/ask รอบ mid (ต่อจากเทมเพลตแม่)

! ความจริงรายย่อย — grid ที่ "ตาบอด" คือเครื่องเก็บ fee ให้ exchange


grid bot ทั่วไปไม่มองกระดานเลย — มันตั้งกินส่วนต่างไป-มาในตลาด sideways ดูสวย แต่มี 2 จุดตาย ที่คนส่วนใหญ่เจ็บ: (1) กำไรต่อไม้ < ค่าธรรมเนียม×2 — ทุกไม้ต้องจ่าย fee ทั้งขาเข้าและขาออก ถ้า Δ_{grid} แคบกว่า fee 2 เท่า คุณตั้งบ่อยแต่ยิ่งตั้งยิ่งจน (2) เทรนด์เดียวล้างพอร์ต — พอราคาวิ่งทางเดียว grid จะ "ซื้อตลอดทาง" สะสมของฝั่งผิดเต็มมือแล้วลอยตัวขาดทุนหนัก order book ช่วยแก้ทั้งสองข้อนี้ได้

ขั้นที่ 2 — เฝียง grid ด้วย OBI/OFI

grid ตายตัววางศูนย์กลางไว้ที่ mid เสมอ แต่ถ้ากระดานบอกว่า ฝั่งขายหนักกว่าฝั่งซื้อ (OBI ติดลบ / OFI ไหลออก) แปลว่ามีโอกาสราคาจะลงต่อ — เราควร เลื่อนศูนย์กลาง grid ลง เพื่อไม่ให้ bid ของเราโดนกินก่อนเวลาอันควร (หลีกเลี่ยง adverse selection จาก Part 6)

นี่คือการยืม **reservation price** จาก Avellaneda-Stoikov (Part 10) มาใช้: แทนที่จะวาง grid รอบ mid เฉยๆ เราวางรอบ "mid ที่ปรับด้วยแรงกระดาน"

ให้ชัดเรื่องทิศ: $OBI < 0$ (ขายหนัก) → P_{center} เลื่อนลง = ลดไม้ฝั่งซื้อไม่ให้โดนกินก่อนราคาวิ่งหนึ่ลง และในทางกลับกัน $OBI > 0$ (ซื้อหนัก) → P_{center} เลื่อนขึ้น ทั้งบนใด grid จึง "หนีฝั่งที่กระดานกำลังกดดัน" เสมอ — นี่คือการหมายเดียวกับ "เฝียงตามแรง (α)" ในสูตร ไม่ได้ขัดกัน




ภาพ 12.2 · เฝียง grid ตาม imbalance — เลื่อนศูนย์กลางหนีฝั่งที่กระดานกดดัน

ขั้นที่ 3 — VPIN เป็นสวิตช์หยุด grid

จาก Part 8 เราเรียนว่า **VPIN วัด toxicity ของ flow** — เมื่อ flow ข้างเดียวรุนแรง (มัก = มีคนรู้ข้อมูลกำลังลากราคา) VPIN จะพุ่งขึ้น นั่นคือสัญญาณว่า "น้ำกำลังหลาก" และ grid กำลังจะถูกพัดขาด

กฎง่าย ๆ: เมื่อ $VPIN > \theta$ (เกณฑ์) ให้ระงับการวางไม้ที่ "ทวนเทรนด์" — เช่น ถ้า flow ไหลขายแรง อย่าวาง buy ดักรับเพิ่ม ปล่อยให้ราคาลงไปก่อน แล้วค่อยกลับมาวาง grid ใหม่เมื่อ flow สงบ นี่คือการเกาะกัน "เทรนด์เดียวล้างพอร์ต"



ภาพ 12.3 · VPIN หยุด grid — ตัดไม้ทวนเทรดในช่วง toxic flow

สูตรหลัก

```
// 1) spacing ไดนามิก — เอาค่ามากกว่าระหว่าง spread เผลี่ย กับ volatility
 $\Delta_{\text{grid}} = \max( c1 \cdot \text{spread}, c2 \cdot \sigma \cdot \sqrt{\tau} )$ 
      c1, c2 = ตัวคูณกันชน (เช่น 1.5, 1.0)
       $\tau = \text{horizon} / \text{holding time}$  เป้าหมายของไม้ (กรอบเวลาที่คาดว่าจะถือก่อนปิด)

// 2) เลื่อนศูนย์กลาง grid ด้วย imbalance (ยืม reservation price)
 $P_{\text{center}}' = P_{\text{mid}} + \alpha \cdot \text{OBI} \cdot \Delta_{\text{grid}}$  ( $\alpha > 0$  = ตามแรง,  $\text{OBI} < 0$  เลื่อนลง)

// 3) สวิตช์ VPIN
ถ้า  $\text{VPIN} > \theta \rightarrow$  ระงับไม้ที่ทวนทิศ flow (กันเทรดเดี่ยวล้างพอร์ต)

// เงื่อนไขกำไรต่อไม้ (กับดักข้อ 1)
 $\Delta_{\text{grid}} > 2 \cdot \text{fee}_{\text{taker}}$  (หรือ  $2 \cdot \text{fee}_{\text{maker}}$  ถ้าใช้ post-only) — ไม่นั่นยิ่งตั้งยิ่งจน
```

พารามิเตอร์	ตายตัว (grid ดิบ)	มองกระดาน (grid + flow)
spacing Δ_{grid}	คงที่ (เช่น 0.5%)	$\max(\text{spread}, \sigma\sqrt{\tau})$ — กว้างเมื่อผันผวน
ศูนย์กลาง	mid เสมอ	P_{center}' เอียงตาม OBI/OFI
ช่วง toxic flow	วางต่อ → โดนลาก	$\text{VPIN} > \theta \rightarrow$ ระงับไม้ทวนเทรด
fee	มักลิม → ขาดทุนเจียบ	บังคับ $\Delta_{\text{grid}} > 2 \times \text{fee}$

งานวิจัยรองรับ

การเอียง quote ตาม inventory และ signal มีรากจาก **Avellaneda-Stoikov (2008)** ที่ derive reservation price $r = s - q \cdot \gamma \sigma^2 (T-t)$ — grid ที่เอียงด้วย OBI คือการนำหลักเดียวกันมาใช้กับ "แรงกระดาน" แทน inventory ส่วนการใช้ **VPIN (Easley-López de Prado-O'Hara 2012)** เป็นตัววัดความเสี่ยง toxic flow ก็คือการ "ปิดร้านชั่วคราว" ตามที่ MM มีอาชีพทำจริง อย่างไรก็ตาม ค่า θ และ α ต้อง **calibrate กับตลาด/timeframe เอง** ไม่มีเลขวิเศษตายตัว

เชื่อมโยงเล่มอื่น & ในซีรีส์

Part 12 มัด 3 เครื่องมือที่เรียนมารวมกัน: **OBI (Part 5)** เอียง grid, **OFI (Part 7)** ทำนายทิศแม่นยำขึ้น, **VPIN (Part 8)** เป็นเบรก และโครง MM ทั้งหมดมาจาก **Part 9–11** ในแง่คณิตศาสตร์ $\Delta_grid = \max(\dots)$ และ P_center' คือ optimization ภายใต้ความผันผวน (เชื่อม **math**) ส่วนการคิด P&L ต่อไม้และ inventory ที่สะสมก็คือ payoff จริงในเล่ม **pm/payoff** — อย่าลืมว่าราคาเข้า-ออก คือ bid/ask ไม่ใช่ mid

กับเคสของเรา

แทนที่จะ market buy BTC \$5,000 ไม้เดียว (จ่ายสปรด+slippage หมดในจังหวะเดียว) เราวาง **grid limit** หยอดเข้าเป็นชั้น ๆ **ได้ราคา** — ได้ราคาเฉลี่ยเข้าดีกว่าและได้สถานะ maker และเมื่อกระดานบอกว่า **OBI ติดลบ (ขายหนัก)** เราเลื่อนศูนย์กลาง grid ลงตาม เพื่อไม่ให้ bid โดนกินก่อนราคาร่วงหนัก ส่วน **VPIN > θ** สั่งหยุดวาง buy ดักรับช่วง toxic flow — หยอดสะสมจนครบ \$5,000 โดยไม่โดน adverse selection

แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

เลือกเหรียญหนึ่ง (เช่น ETH/USDT บน Binance) ดึงราคาย้อนหลัง 2 วัน: **วันที่ sideways** กับ **วันที่ trending** จำลอง grid 10 ชั้น spacing 0.4% แล้ว **หัก taker fee 0.04%** ทุกไม้ทั้งขาเข้า-ออก เทียบ P&L สองวัน — คุณจะเห็นว่า grid ดิบกำไรวัน sideways แต่ขาดทุนหนักวัน trending จากนั้นเพิ่มกฎ "ถ้า $OBI < -0.3$ หยุดวาง buy" แล้ววัดว่าวัน trending ขาดทุนน้อยลงไหม

ส่งต่อ → grid เอียงตามแรงกระดานได้แล้ว แต่ถ้าอยาก "รู้ทิศก่อนราคาขยับ" ต้องวัดแรง flow ให้เป็นตัวเลขทำนายได้ — Part 13 จะใช้ OFI เป็นสัญญาณจังหวะเข้า และทยอยอดข้ามเหรียญ (BTC ดัน ETH)

อ่านกระดาน

Reading the Book

Part 13: Statistical Arbitrage ด้วย OFI — ทำนายราคาด้วยแรง flow

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์
OFI มาก่อนราคา — แปลงให้หนึ่ง ทำ regression แล้วต่อยอดเป็น cross-asset (BTC ดัน ETH)

 อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > ตัดสินใจเข้า-ออก > **ต่อยอด/คุมเสี่ยง**

Part 13 — Statistical Arbitrage (อาร์บิทราจเชิงสถิติ) ด้วย OFI

🔗 ต่อจากตอนก่อน

เพ็ญรู้มา: Part 12 เอา grid (MM ที่ตรึงราคาเป็นชั้น) มาเอียงตาม OBI/OFI และใช้ VPIN เป็นเบรก — กระดานช่วย "ตั้งรับ" ให้ฉลาดขึ้น แต่ยังเป็นการรอให้ราคามาหา · **ตอนนี้จะเดิม:** พลิกจากตั้งรับเป็น "ทำนายเชิงรุก" — OFI มาก่อนราคา ถ้าแปลงให้นิ่งแล้วทำ regression เราจะรู้ทิศล่วงหน้าและต่อยอดข้ามเหรียญ (flow BTC ทำนายราคา ETH) ได้

🎯 อ่านจบ Part นี้คุณจะได้

- เข้าใจว่า **OFI (order flow imbalance) "มาก่อน"** การเปลี่ยนแปลงราคา — เป็น predictor ไม่ใช่ภาพสะท้อน
- รู้ว่าทำไมต้อง แปลง OFI ให้ **stationary (log/normalize)** ก่อนทำ regression ไม่จันได้ผลลวง (spurious)
- ทำ **lead-lag stat-arb (ราคาตาม flow)**: เข้าเทรดเมื่อราคาคาดการณ์จาก OFI เบนจากราคาจริงเกินต้นทุน
- ต่อยอดเป็น **cross-asset / cross-impact**: flow ของ BTC ทำนายราคา ETH ได้ (เมทริกซ์ γ)

เริ่มจากแรงดันน้ำในท่อ

นึกถึงน้ำในท่อประปา — ก่อนที่ **ระดับน้ำ** (ราคา) จะขยับ ต้องมี **แรงดัน** (flow) ดันมาก่อนเสมอ ถ้าคุณวัดได้แค่ระดับน้ำ คุณรู้ทีหลังเสมอ แต่ถ้าคุณวัด "แรงดัน" ได้ คุณรู้ **ก่อน** ว่าน้ำกำลังจะขึ้นหรือลง


OFI คือเกววัดแรงดันของกระดาน — มันรวมทั้ง limit ที่เดิมเข้า, cancel ที่ถอนออก, และ market ที่กิน เป็นตัวเลขเดียวที่บอก "แรงสุทธิ" ที่กำลังดันราคา และเมื่อ **ท่อหลายเส้นต่อกัน** (BTC, ETH, SOL อยู่ในระบบเดียวกัน) แรงดันในท่อใหญ่ย่อมส่งผลถึงท่อเล็ก — นั่นคือ cross-asset



วัดแรงดันได้ = รู้ก่อนว่าราคาจะ何去何

ขั้นที่ 1 — OFI นำหน้าราคา

จาก Part 7 เรารู้ว่า $\Delta P \approx \lambda \cdot \text{OFI}$ (Kyle's λ) — แต่สิ่งที่ทำให้มันเป็น stat-arb ได้คือ **ความล่าช้า (lag)**: OFI ที่ช่วงเวลานี้มักทำนาย ΔP ของช่วงถัดไปได้เล็กน้อย เพราะตลาดใช้เวลา "ย่อย" flow ไม่ทันที ถ้าราคา ณ ตอนนี้อยู่ยังไม่ขยับตามที่ OFI บอก นั่นคือช่องว่าง lead-lag ที่กินได้ (เข้าตามทิศ flow ก่อนราคาจะตามมา)




ภาพ 13.1 · OFI นำหน้าราคา — flow พุ่งก่อน ราคาขยับตามทีหลัง

ขั้นที่ 2 — แปลง OFI ให้นิ่งก่อน regression

นี่คือจุดที่รายย่อยส่วนใหญ่พลาด: **OFI ดิบมีหางหนา (fat tails) และไม่ stationary** — บางวินาที OFI กระโดดเป็นหมื่น บางวินาทีเกือบศูนย์ ถ้าเอาไป regress ตรง ๆ ค่า β จะถูกครอบงำด้วยค่าสุดโต่งไม่กี่ตัว ได้รับความสัมพันธ์ลวง (spurious regression)

วิธีแก้: **(1) ปีบทางด้วย $\log \text{sign}(\text{OFI}) \cdot \log(1+|\text{OFI}|)$** และ **(2) normalize ด้วย depth** เพื่อให้เทียบข้ามช่วงเวลา/ข้ามเหรียญได้ — ผลคือกระจายตัวเข้าใกล้ปกติและนิ่งขึ้น regression จึงเชื่อถือได้



ภาพ 13.2 · stationarize ก่อน/หลัง — log บีบหางหนาให้เข้าใกล้ปกติ

ขั้นที่ 3 — cross-asset / cross-impact (BTC → ETH)

เหรียญใหญ่ในคริปโตเคลื่อนพร้อมกันสูง — flow ที่ดัน BTC มัก "ลาก" ETH ตามในเสี้ยววินาทีถัดมา (cross-impact) เราขยาย regression จากตัวแปรเดียวเป็น **เมทริกซ์**: ราคาของเหรียญ i ขึ้นกับ OFI ของตัวเอง *บวก* OFI ของเหรียญอื่น ๆ ถ่วงด้วยสัมประสิทธิ์ y_{ij}

เมทริกซ์ cross-impact y_{ij}

	ofi BTC	ofi ETH	ofi SOL
Δp BTC	0.42	0.08	0.03
Δp ETH	0.21	0.38	0.05
Δp SOL	0.18	0.12	0.34

นอกแนวทแยง = แรงข้ามเหรียญ (BTC → ETH = 0.21)

ภาพ 13.3 · เมทริกซ์ y — flow ของ BTC ส่งผลถึงราคา ETH/SOL (ตัวเลขสาธิต ไม่ใช่ค่าจริง)

สูตรหลัก

```
// 1) แปลง OFI ให้นิ่ง (log + normalize ด้วย depth D)
```

```
ofi = sign(OFI) · log(1 + |OFI|) / D
```

```
// 2) cross-asset regression (เหรียญ i ขึ้นกับ flow ตัวเอง + ตัวอื่น)
```

```
 $\Delta p_i = \beta \cdot ofi_i + \sum_j y_{ij} \cdot ofi_j + \varepsilon$ 
```

```
// 3) สัญญาณ lead-lag / ราคาตาม flow (ราคาคาดการณ์ vs ราคาจริง)
```

Δp = ราคาที่โมเดลทำนาย ; เข้าเทรดเมื่อ $|\Delta p| > \text{cost}$
 $\text{cost} = \text{fee} \times 2 + \text{spread} + \text{slippage}$ (edge ต้องชนะต้นทุนก่อน)

! ความจริงรายย่อย — edge บางมาก ต้นทุนกินหมด

stat-arb ด้วย OFI เป็น **กลยุทธ์ที่รายย่อยทำได้จริงที่สุดในกลุ่ม advanced** (จะเทียบให้เห็นชัดใน Part 14) เพราะใช้ข้อมูล L2 ฟรีและไม่ต้องแข่ง latency ระดับ HFT — แต่ edge ต่อไม่เล็กมาก (มัก < 1 bps) ถ้า $\text{cost} (\text{fee} \times 2 + \text{spread} + \text{slippage})$ ไม่ต่ำกว่า edge คุณจะ "ทำนายถูกแต่ขาดทุน" และระวัง **spurious regression** จาก OFI ดิบ: ถ้าไม่ stationarize ก่อน R^2 ที่เห็นในอดีตจะหลอกคุณ พอรันจริงพังทันที

📄 งานวิจัยรองรับ

นิยาม OFI event-based มาจาก **Cont-Kukanov-Stoikov (2014)** ส่วนการขยายเป็น **multi-level + cross-impact** มาจาก **Cont-Cucuringu-Zhang (2023)** ซึ่งแสดงว่า OFI ข้ามหลักทรัพย์ช่วยอธิบายการเคลื่อนไหวราคาได้เพิ่ม และมีงาน **HF Stat-Arb with Stationarized OFI** ที่ยืนยันว่าการแปลงให้ stationary สำคัญต่อความสำเร็จของสัญญาณ *ข้อควรระวัง*: ค่า β, γ และ R^2 ขึ้นกับตลาด/timeframe และ **เสื่อมตามเวลา** ต้อง re-fit เสมอ

🔗 เชื่อมโยงเล่นอื่น & math

Part 13 คือการต่อยอด **OFI/Kyle's λ (Part 7)** ตรง ๆ ในเชิงคณิตศาสตร์นี่คือ **multivariate linear regression** เต็มตัว (เชื่อม **math**: OLS, R^2 , และเมทริกซ์ γ ก็คือ multi-output regression / สัมพันธ์กับ PCA ของ flow) การ stationarize ด้วย log เชื่อมกับบท log/returns ในเล่ม math ส่วนสัญญาณ $|\Delta p| > \text{cost}$ คือการเปรียบ payoff ที่คาดหวังกับต้นทุนจริง — หลักเดียวกับการหา edge ใน **arb** และคิด P&L ใน **pm**

🎯 กับเคสของเรา

ก่อนทยอยเข้า long BTC \$5,000 เราไม่เข้ามั่ว ๆ ตามใจ — เราใช้ **OFI ของ BTC เป็นสัญญาณจังหวะเข้า**: เมื่อ OFI (แปลงให้นิ่งแล้ว) ไหลเป็นบวกนำหน้าราคา แปลว่ามีแรงดันขึ้นกำลังมา → จังหวะวางไม้ฝั่งซื้อของ grid ให้หนักขึ้น แต่ถ้า OFI ไหลออกแรง → ชะลอ ปล่อยให้ราคาลงไปก่อน เป็นการ "จับจังหวะเข้า" ที่ละเอียดกว่า OBI static ใน Part 5 — แต่ต้องระวัง edge บางมาก ถ้า cost สูงกว่าก็ไม่คุ้มเข้าถึ

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

ดึง L2 depth + trade stream ของ **ETH/USDT** และ **BTC/USDT** พร้อมกันสัก 1 ชั่วโมง คำนวณ OFI ทุก ๆ 1 วินาที แล้วทำ regression สองแบบเทียบกัน: (ก) $\Delta p(\text{ETH}) \sim \text{ofi}(\text{ETH})$ กับ (ข) $\Delta p(\text{ETH}) \sim \text{ofi}(\text{ETH}) + \text{ofi}(\text{BTC})$ ดูว่า R^2 เพิ่มขึ้นไหมเมื่อใส่ flow ของ BTC เข้าไป จากนั้นลองไม่ stationarize vs stationarize แล้วสังเกตว่า β เสถียรต่างกันแค่ไหน

ส่งต่อ → OFI stat-arb มี edge บางที่ต้องชนะต้นทุนก่อน — แล้ว arb ชนิดอื่น (cross-exchange, latency, triangular) ที่ดู "ฟรี" บนจอ รายย่อยทำได้จริงไหม? Part 14 จะคิด effective price + ต้นทุนครบวงจร แล้วจัดอันดับความจริง

อ่านกระดาน

Reading the Book

Part 14: Cross-Exchange / Latency / Triangular Arb — arb จริงทำได้แค่ไหน

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์
spread บนจอ $\neq$ กำไร — คัดต้นทุนครบวงจรด้วย effective price แล้วดูตารางความจริงรายย่อย

 อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > ตัดสินใจเข้า-ออก > [ต่อยอด/คุณเสี่ยง](#)

Part 14 — Cross-Exchange / Latency / Triangular Arb

🔗 ต่อจากตอนก่อน

เพิ่งรู้มา: Part 13 ใช้ OFI ทำนายทิศทางค่าล่วงหน้าและทำ stat-arb ได้ แต่ตอกย้ำว่า **edge** บางมาก
ต้องชนะ cost (fee×2 + spread + slippage) ก่อน ไม่งั้น "ทำนายถูกแต่ขาดทุน" · **ตอนนี้จะเดิม:** ขยาย
 เรื่อง "ต้นทุนจริง" ให้ครบ — arb แบบ cross-exchange/latency/triangular ที่ดูฟรีบนจอ จริง ๆ ต้องคิด
 effective price (ไต่เล่ม) + ค่าถอน + เวลาโอน แล้วจะเห็นว่าทำไม OFI stat-arb ถึงเหมาะรายย่อยที่สุด


📌 อ่านจบ Part นี้คุณจะได้

- แยก arb 3 ชนิด: **cross-exchange** (สองตลาด), **latency** (แข่งความเร็ว), **triangular** (สามคู่
เหรียญ)
- คิด **effective price (ราคาเฉลี่ยจริงเมื่อไต่เล่ม) / depth** — ไม่ใช่ best price บนจอ
- คิด **ต้นทุนครบวงจร:** fee + ค่าถอน + slippage + เวลาโอน — ตัวพังกำไรตัวจริง
- เห็น **ตารางความจริงรายย่อย:** อันไหนทำได้ อันไหนอย่าแตะ และทำไม OFI stat-arb ถึงเหมาะ
ที่สุด

เริ่มจากซื้อทุเรียนตลาด A ขายตลาด B

ทุเรียนที่ตลาด A ลูกละ 100 บาท ตลาด B รับซื้อ 110 บาท — กำไร 10 บาทใช่ไหม? **ยังก่อน** คุณต้องจ่าย **ค่าธรรมเนียมของ** (ค่าถอน/ค่าโอน), **เสียเวลาชน** (ระหว่างชนราคาอาจเปลี่ยน), และถ้าคุณซื้อหลายลูก **ลูกท้าย ๆ**
ราคาแพงขึ้น (ไต่เล่ม) ส่วนตลาด B ก็รับซื้อถูกลงเรื่อย ๆ

นี่คือหัวใจของ arb จริง: **spread** บนจอเป็นแค่ "**ราคาตั้ง**" ของลูกแรก กำไรจริงต้องหักต้นทุนครบวงจรและคิด
 ที่ effective price




$$\text{กำไรจริง} = 10 - \text{ค่าธรรมเนียม} - \text{slippage} - \text{fee}$$

ขั้นที่ 1 — effective price: ราคาจริงเมื่อได้เล่ม

ถ้าคุณซื้อปริมาณ Q ที่มากกว่าของที่ best ask มีอยู่ คุณต้อง "กิน" ชั้นถัดไปที่แพงขึ้นเรื่อย ๆ (walk the book จาก Part 2) ราคาเฉลี่ยที่คุณได้จริงคือ **effective price** ซึ่งแพงกว่า best price เสมอ — และยิ่ง Q ใหญ่ ยิ่งแพง


ราคา



ภาพ 14.1 · effective price ได้เล่ม — ราคาเฉลี่ยจริงแพงกว่า best ask

ขั้นที่ 2 — cross-exchange: หัก fee สองฝั่งแล้วเหลืออะไร

cross-exchange arb คือซื้อที่ venue A (effective ask) ขายที่ venue B (effective bid) แต่กำไรบนจอมักหายหมดเมื่อหัก **fee ทั้งสองฝั่ง + ค่าถอน + slippage** และที่ร้ายกว่าคือ **เวลาโอนเหรียญข้าม chain** ที่ราคาอาจวิ่งหนีก่อนคุณขนของถึง




ภาพ 14.2 · cross-exchange 2 venue — gross gap สวย แต่หักต้นทุนแล้วมักติดลบ

ขั้นที่ 3 — triangular: วงสามคู่ในตลาดเดียว

triangular arb วนเงินผ่านสามคู่ในตลาดเดียวกัน เช่น $\text{USDT} \rightarrow \text{BTC} \rightarrow \text{ETH} \rightarrow \text{USDT}$ ถ้าผลคูณอัตราแลกเปลี่ยน $R > 1$ (หลังหัก fee สามขา) ก็มีกำไร ข้อดีคือ **ไม่ต้องโอนข้าม venue** (ตัดค่าถอน/เวลาโอนออก) แต่ต้องเร็วมากเพราะช่องปิดในเสี้ยววินาที และ fee สามขากินหนัก

ผูกกับสูตรให้ชัด: ในวง $USDT \rightarrow BTC \rightarrow ETH \rightarrow USDT$ **ขา "ซื้อ" ใช้ $1/P$** (จ่ายเงินอ้างอิงเพื่อได้เหรียญ) ส่วน **ขา "ขาย" ใช้ $\times P$** (ขายเหรียญกลับเป็นเงินอ้างอิง) — ขาที่ 1 ซื้อ BTC ด้วย USDT ใช้ $1/P_1$ (P_1 = ราคา BTC/USDT) ขาที่ 2 ซื้อ ETH ด้วย BTC ใช้ $1/P_2$ (P_2 = ราคา ETH/BTC) และขาที่ 3 ขาย ETH กลับเป็น USDT ใช้ $\times P_3$ (P_3 = ราคา ETH/USDT) — จึงได้ $R = (1/P_1) \cdot (1/P_2) \cdot P_3$ ก่อนหัก fee



ภาพ 14.3 · triangular — วนสามขาในตลาดเดียว เข้าเมื่อผลคูณอัตรา (หลัง fee) > 1

```
// effective price เมื่อโต้เล็ม (เฉลี่ยถ่วงปริมาณแต่ละชั้น)
P_eff(Q) =  $\sum p_k \cdot q_k / Q$  ( $q_k$  = ปริมาณที่กินในชั้น k)

// กำไรสุทธิ cross-exchange (ครบวงจร)
 $\Pi_{net} = (P_{sell,B} - P_{buy,A}) - fee - w_{withdraw} - slip$ 
 $P_{buy,A} = P_{eff}$  ฝั่งซื้อ ;  $P_{sell,B} = P_{eff}$  ฝั่งขาย

// triangular: มีกำไรเมื่อผลคูณอัตรา (หลัง fee 3 ขา)  $> 1$ 
 $R = (1/P_1) \cdot (1/P_2) \cdot P_3 \cdot (1-f)^3$  ; เข้าเมื่อ  $R > 1$ 
```

ตารางความจริงรายย่อย — อันไหนทำได้จริง

นี่คือหัวใจของ Part นี้ — เราจะ **ข้อสัจ** ว่ารายย่อยทำ arb แต่ละชนิดได้จริงแค่ไหน:

ชนิด arb	รายย่อย ทำได้?	ทำไม
Latency arb	✗ อย่า แตะ	แข่งความเร็วระดับไมโครวินาที — ต้อง colocation + โครงสร้าง HFT ที่ รายย่อยสู้ไม่ได้ ไม่ว่าจะมองกระดานเก่งแค่ไหน
Cross-exchange (spot)	⚠ ระวัง มาก	ทำได้บนกระดาน แต่ fee×2 + ค่าถอน + เวลาโอนข้าม chain มักกินกำไร หมด และเสี่ยงราคาวิ่งหนีระหว่างโอน
Triangular	⚠ ระวัง	ไม่ต้องโอนข้าม venue (ดีกว่า) แต่ fee สามขา กินหนัก ช่องปิดเร็ว ต้องเร็ว กว่าบอตทั่วไป
OFI stat-arb (Part 13)	✓ เหมาะ สุด	ใช้ L2 ฟรี ไม่แข่ง latency สุดขีด เป็น "ยกระดับกลยุทธ์เดิม" ด้วยกระดาน — แต่ edge บาง ต้องคุม cost เข้ม

⚠ ความจริงรายย่อย — spread บนจอ ≠ กำไร

เห็น "BTC ที่ Binance ถูกกว่า Bybit 0.1%" แล้วคิดว่าได้เงินฟรี — **นี่คือกับดักคลาสสิก** ตัวเลขนั้นคือ best price ของลูกแรก ไม่ใช่ effective price และยังไม่หัก fee สองฝั่ง ค่าถอน เวลาโอน กว่า คุณจะชนของถึง ราคา มักปิดช่องไปแล้ว **latency arb โดยเฉพาะ — อย่าลองเด็ดขาด** คุณกำลังแข่งกับบอตที่เร็วกว่าคุณล้านเท่า สิ่งที่รายย่อยทำได้จริงคือ OFI stat-arb ที่ใช้ "ความเข้าใจกระดาน" ไม่ใช่ "ความเร็วของเครื่อง"

📄 งานวิจัยรองรับ

แนวคิด effective price / market impact ของการโต้เล็มมาจากตระกูล market impact models (Kyle 1985 และงานต่อยอด) ส่วนการคิดต้นทุนการเทรดครบวงจร (transaction cost analysis) เป็นมาตรฐานในงาน execution ทุกแขนง สำหรับคริปโต **โครงสร้าง fee/rebate และค่าถอนของ Binance/Bybit เปลี่ยนตามโปรโมชั่น** — ก่อนคำนวณจริงให้เช็คหน้า fee schedule ปัจจุบันเสมอ เพราะมันคือตัวแปรที่ตัดสินว่ากำไรเป็นบวกหรือลบ

🔗 เชื่อมโยงเล่มอื่น — สะพานสู่เล่ม arb

Part 14 คือ **สะพานเชื่อมตรงสู่เล่ม arb**: เล่ม arb หา "โอกาส" ส่วนตรงไหนที่ effective price/depth บอกว่า **ต้นทุนจริงของ arb เท่าไหร่** คือสิ่งที่เล่มนี้เติมให้ $P_{eff}(Q)$ และ Π_{net} คือเครื่องมือที่ทำให้ตัวเลขในเล่ม arb "เป็นจริงในกระดาน" ในเชิง **math** นี่คือผลรวมถ่วงน้ำหนักและเงื่อนไข $R > 1$ ส่วนการคิดกำไรขาดทุนหลัง cost ทั้งหมดก็คือ payoff จริงในเล่ม **pm/payoff**

🎯 กับเคสของเรา

ก่อนกด long BTC \$5,000 เราเช็กก่อนว่าควรเข้าที่ exchange ไหน — **เทียบ effective price ผังซื้อข้าม venue** (Binance/Bybit) สำหรับขนาด \$5,000 จริง ไม่ใช่ดู best ask บนจอ เพราะได้เล่มแล้ว ราคาเฉลี่ยจริง (P_{eff}) อาจแพงกว่าและสลับอันดับ venue ได้ ส่วนช่องว่างราคาข้าม exchange ที่เห็น — หัก fee สองฝั่ง + ค่าถอน + เวลาโอนแล้วมัก **ไม่คุ้มขนของไปเก็บ arb** สิ่งที่คุ้มคือเลือก venue ที่ effective price ดีสุดสำหรับไม้เราเอง

🔪 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

ดึง order book L2 ของเหรียญเดียวกันจาก **สอง exchange** พร้อมกัน (เช่น Binance vs Bybit) คำนวณ P_{eff} ผังซื้อที่ A และ P_{eff} ผังขายที่ B สำหรับขนาด \$1,000 แล้วหัก taker fee สองฝั่ง + ค่าถอนโดยประมาณ นับดูว่าในช่อง 1 ชั่วโมงมีกี่วินาทีที่ $\Pi_{\text{net}} > 0$ **จริง** — คุณจะพบว่าน้อยมาก และส่วนใหญ่ปิดเร็วเกินกว่าจะคว้าทัน นี่คือบทพิสูจน์ว่าทำไมตารางความจริงถึงให้ cross-exchange แค่ว่า ⚠️

ส่งต่อ → เครื่องมือทั้ง 14 Part (spread, OBI, OFI, VPIN, MM, effective price) คือ "feature" ที่ย่อยมาแล้ว — ถ้าป้อนให้ deep learning อ่านกระดานแทนเรา จะทำนายจังหวะเข้าได้ไหม และทำไม ML ถึงเป็นปลายทางไม่ใช่จุดเริ่ม? Part โบนัสมีคำตอบ

อ่านกระดาน

Reading the Book

Part โบนัส: เครื่องจักรอ่านกระดาน — DeepLOB, Transformers

Order Flow & Microstructure สำหรับรายย่อย · เลนส์ execution ของซีรีส์

ML คือปลายทาง ไม่ใช่จุดเริ่ม — "feature ดี > โมเดลลิ่ง" และอย่าหุ้ม architecture แทนข้อมูล



 อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > ตัดสินใจเข้า-ออก > **ต่อยอด/คุมเสี่ยง**

Part โบนัส — เครื่องจักรอ่านกระดาน

ต่อจากตอนก่อน

เพ็ญรัฐมา: Part 14 จัดอันดับ arb ตาม "ความจริงรายย่อย" — latency อย่าแตะ, cross-exchange/triangular ระวัง, OFI stat-arb เหมาะสุดเพราะใช้ "ความเข้าใจกระดาน" ไม่ใช่ความเร็วเครื่อง · **ตอนนี้จะเดิม:** ปลายทางสุดของการอ่านกระดาน — ให้ deep learning (DeepLOB, Transformer) อ่านกระดานแทน แต่บทเรียนคือ "feature ดี > โมเดลเล็ก" และ ML คือยอดภูเขาที่ต้องมีค่ายฐาน microstructure ทั้ง 14 Part ก่อน


อ่านจบ Part นี้คุณจะได้

- เข้าใจ pipeline ของโมเดล deep learning อ่านกระดาน: **LOB** → **CNN** → **LSTM** → ทำนายทิศ mid (DeepLOB)
- รู้จัก **Transformer** สำหรับ **LOB** (TLOB/LiT) และจุดที่มันต่างจาก CNN+LSTM
- ซึมหลักสำคัญ: "feature ดี > โมเดลเล็ก" — OFI/imbalance ที่ออกแบบดีชนะ network ใหญ่ที่ป้อนข้อมูลดิบ
- เข้าใจว่า **ML คือปลายทาง ไม่ใช่จุดเริ่ม** — ต้องมีรากฐาน microstructure ทั้ง 14 Part ก่อน

เริ่มจากยอดภูเขา ไม่ใช่ค่ายฐาน

คนที่พิชิตยอดเอเวอเรสต์ไม่ได้เริ่มจากการกระโดดขึ้นยอดเลย — เขาเริ่มจาก **ค่ายฐาน** ปรับตัวกับความสูง ผักหายใจ แล้วค่อยไต่ขึ้นทีละแคมป์ **ML สำหรับอ่านกระดานคือ "ยอดภูเขา"** — สวยงาม แต่ถ้าคุณไม่มีค่ายฐาน (เข้าใจ spread, OBI, OFI, VPIN, market making) คุณจะรู้ด้วยซ้ำว่าโมเดลมันเรียนรู้อะไรหรือฟังตรงไหน

อีกอุปมา: **สายตาเทรดเดอร์ที่ฝึกดูกระดานมาเป็นล้านครั้ง** — neural network ก็คือการจำลองสายตานั่นด้วยข้อมูลมหาศาล แต่ "สายตา" จะแม่นยำได้ต้องป้อน **สิ่งที่มีความหมาย** ให้ดู ไม่ใช่ตัวเลขดิบมั่ว ๆ




ภาพ B.1 · ML คือยอดภูเขา — ต้องมีค่ายฐาน microstructure ก่อนถึงจะไต่ขึ้นได้

ขั้นที่ 1 — pipeline DeepLOB (CNN + LSTM)

DeepLOB รับ **snapshot** ของกระดานหลายชั้น **ต่อกันเป็นลำดับเวลา** (เมทริกซ์ขนาด $T \times 4L$: แต่ละชั้น L มีราคา/ปริมาณ ของ bid และ ask) แล้วส่งผ่าน:

- **CNN** — กวาดหา "ลวดลายเชิงพื้นที่" ในกระดาน (เช่น รูปทรง imbalance ข้ามชั้น) แทนการดูตัวเลขทีละตัว
- **LSTM** — จับ "ลำดับเวลา" ว่าลวดลายเปลี่ยนยังไงในไม่กี่วินาที
- **softmax 3 class** — ทำนายว่า mid ช่วงถัดไปจะ **ขึ้น** / **นิ่ง** / **ลง**



softmax 3 class (ทำนายทิศ mid ถัดไป)


ภาพ B.2 · pipeline LOB → CNN → LSTM → ทำนาย 3 class

ขั้นที่ 2 — Transformer สำหรับ LOB (TLOB/LiT)

Transformer ใช้ **attention** แทน convolution + recurrence — มันเรียนได้เองว่า "ชั้นไหน/เวลาไหนของกระดาน" สำคัญต่อการทำนาย โดยไม่ต้องไล่ลำดับทีละสแต็ปแบบ LSTM งานอย่าง **TLOB** และ **LiT** แสดงว่าสถาปัตยกรรมนี้แข่งขันได้และบางทีดีกว่าในบางชุดข้อมูล — **แต่** มันกินข้อมูลและ compute หนักกว่ามาก และ **ไม่ใช่** กระสุนเงิน

ขั้นที่ 3 — feature ดี > โมเดลเล็ก (หัวใจของ Part นี้)

นี่คือบทเรียนที่แพงที่สุดและคนข้ามบ่อยที่สุด: โมเดลลึกที่ป้อนข้อมูลดิบ มักแพ้โมเดลตื้นที่ป้อน feature ที่ออกแบบดี เพราะ OFI, imbalance, microprice ที่คุณเรียนมาทั้งเล่มคือ "ความรู้ microstructure" ที่ย่อยมาให้โมเดลแล้ว — network ไม่ต้องเสียพลังไป "ค้นพบใหม่" จากศูนย์



ภาพ B.3 · feature ดี > โมเดลลึก — ความรู้ microstructure ที่ย่อยมาแล้วมีค่ากว่า depth

สูตรหลัก

```
// อินพุต: ลำดับ snapshot กระดาน T ช่วงเวลา × 4L พียูเจอร์ต่อชั้น
X ∈ ℝ^{T × 4L} (p_bid, v_bid, p_ask, v_ask ของ L ชั้น)

// label: ทิศ mid ในอนาคต แบ่ง 3 class
y ∈ {ขึ้น, นิ่ง, ลง} (ใช้ threshold บนการเปลี่ยนของ mid)

// objective: ลด cross-entropy ของ softmax
min CrossEntropy( softmax(f(X)) , y )
    f = CNN+LSTM (DeepLOB) หรือ Transformer (TLOB/LiT)
```

⚠ ความจริงรายย่อย — กับดักของ ML กับกระดาน

(1) **หุ้ม architecture แทน feature/ข้อมูล** — เพิ่มเลเยอร์ไม่ช่วย ถ้า feature ห่วยหรือข้อมูลน้อย เริ่มที่ feature engineering ด้วยความรู้ microstructure ก่อนเสมอ (2) **ไม่กัน overfit** — LOB มี noise สูงและ regime เปลี่ยน โมเดลที่ "แม่นในอดีต" มักพังกับข้อมูลใหม่ ต้องแยก train/validation/test ตามเวลาอย่างเคร่งครัด และระวัง look-ahead bias (3) **คิดว่า ML แทนความเข้าใจได้** — ผิด ML ขยายความเข้าใจที่คุณมี ถ้าคุณไม่เข้าใจ OFI/imbalance คุณจะ debug โมเดลที่พังไม่เป็น ML คือปลายทาง ไม่ใช่จุดเริ่ม

งานวิจัยรองรับ

DeepLOB (Zhang et al. 2018, arXiv 1808.03668) เป็นงานวางมาตรฐาน CNN+LSTM อ่าน LOB ทำนายทิศ mid ส่วน **TLOB (arXiv 2502.15757)** และ **LiT** นำ Transformer/attention มาใช้ ส่วนงานคริปโตโดยตรง **Wang (2025, arXiv 2506.05764)** "Exploring Microstructural Dynamics in Cryptocurrency Limit Order Books" benchmark โมเดลตั้งแต่ logistic regression/XGBoost จนถึง DeepLOB/Conv1D-LSTM บนข้อมูล BTC/USDT ของ Bybit แล้วได้ข้อสรุปสำคัญ (ตรงซื้อจริง):

"Better Inputs Matter More Than Stacking Another Hidden Layer" — feature/การเตรียมข้อมูลที่ดีให้ผลมากกว่าการต่อ layer ลึกขึ้น เป็นบทเรียนตรงสำหรับรายย่อยที่อยากเริ่มทำโมเดลเอง · ข้อควรระวัง: ผลความแม่นยำในเปเปอร์มัก backtest บนข้อมูลเฉพาะตลาด/ช่วงเวลา — อย่าคาดหวังตัวเลขเดียวกันกับคริปโตที่ regime เปลี่ยนเร็ว และต้อง validate ด้วยข้อมูลของคุณเอง

cross-ref — forecasting power สูง ≠ สัญญาณเทรดได้จริง

Briola et al. (2024/25) "Deep Limit Order Book Forecasting: a microstructural guide" เป็นบทสรุปที่ตอกย้ำ message ของ Part นี้โดยตรง: โมเดล deep learning ทำนายทิศ LOB ได้ **"แม่นยำ" ในเชิงสถิติ** (forecasting power สูง) — **แต่นั้นไม่ได้แปลว่าเทรดแล้วกำไรจริง** เพราะพอเอาไปวัดเป็นสัญญาณเทรด ต้องเจอ **ต้นทุน (fee + spread + slippage), latency, และ edge ที่บางจนต้นทุนกลบ** — แบบเดียวกับ "ทำนายถูกแต่ขาดทุน" ของ OFI stat-arb ใน Part 13 บทเรียน: อย่าหลงตัวเลข accuracy/F1 ในเปเปอร์ ให้ประเมินทุกโมเดลด้วย **P&L หลังหักต้นทุนจริง** เสมอ — forecasting ≠ tradable signal

เชื่อมโยงเล่มอื่น & ปิดซีรีส์

Part โบนัสมัดทั้งซีรีส์เข้าด้วยกัน: **feature** ที่ป้อนโมเดลคือ OFI (Part 7), OBI (Part 5), microprice (Part 11), VPIN (Part 8) ที่เรียนมาทั้งหมด ในเชิง **math** นี้คือ softmax/cross-entropy, logistic regression, และ optimization ที่ต่อยอดจากบท regression/PCA โดยตรง บทเรียนสุดท้ายของทั้งเล่ม "อ่านกระดาน" คือ: **order book เป็นเครื่องมือยกระดับกลยุทธ์เดิม ไม่ใช่ระบบเบ็ดเสร็จ** — และ ML ก็เป็นเครื่องมือยกระดับ "ความเข้าใจกระดาน" ของคุณ ไม่ใช่ตัวแทนของมัน

กับเคสของเรา

คำถามสุดท้ายของเคส: ให้ ML ทำนายจังหวะเข้า long BTC \$5,000 แทนเราได้ไหม? **ได้ — แต่ไม่ใช่จุดเริ่ม** feature ที่จะป้อนโมเดลก็คือ OBI/OFI/VPIN/microprice/effective price ที่เราใช้ตัดสินใจมาทั้งเคส ML แค่ "ขยาย" สายตาที่ฝึกมาแล้ว ไม่ได้แทนมัน และต่อให้โมเดลทำนายทิศ mid แม่น ก็ยังต้องผ่านด่านเดิม — **edge ต้องชนะ cost จริง** ก่อนถึงจะเข้าไม่ได้กำไร ดังนั้นสำหรับเคสนี้ เครื่องมือ 14 Part ที่ผ่านมาคือสิ่งที่ลงมือทำได้เลย ML คือก้าวถัดไปเมื่อรากฐานแน่นแล้ว

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

เก็บข้อมูล L2 + trade ของ BTC/USDT สัก 2–3 ชั่วโมง สร้าง feature **OFI** (จาก Part 7) แล้วเทรน **logistic regression** ทำนายทิศ mid ถัดไป 3 class เทียบกับ baseline ง่าย ๆ คือ "เดาตาม sign(OFI)" ดูว่าโมเดลที่เรียนรู้ค่าน้ำหนักชนะการเดาตรง ๆ ไหม จากนั้น (ถ้าอยากท้าทาย) ลองป้อนข้อมูลกระดานดิบเข้า network เล็ก ๆ แล้วเทียบ — คุณจะสัมผัสได้ด้วยตัวเองว่า "feature ดี > โมเดลเล็ก" จริงแค่ไหน

ส่งต่อ → ครบทั้ง 14 Part + โบนัสแล้ว — ขั้นตอนต่อไปคือเอาทุกเครื่องมือมาร้อยเป็น "การอ่านกระดานจริง 1 รอบ" กับเคส long BTC \$5,000 ตั้งแต่เปิดจอ → ประเมิน → เข้า/ออก → คุมเสี่ยง ที่บท **Capstone**

— จบซีรีส์ "อ่านกระดาน" · ขอให้อ่านกระดานออก และเทรดอย่างมีต้นทุนที่รู้จริง —

อ่านกระดาน Reading the Book

บทปิด (Capstone): อ่านกระดานจริง 1 รอบ

Order Flow & Microstructure สำหรับรายย่อย · บทสังเคราะห์

รวมทั้ง 17 ตอนเป็น "ขั้นตอนตัดสินใจเดียว" — เปิดจอ → ประเมิน → เข้า/ออก → คมเสี่ยง

บทปิด — อ่านกระดานจริง 1 รอบ

 อ่านกระดาน > รู้ใครกดดัน > ตัดสินใจเข้า-ออก > ต่อยอด →  **รวมทุกด้าน**

ต่อจากทั้งหมด


เพ็ญรู้มา: ตลอดทั้ง 17 ตอน (Part 0–14 + โบนัส + ภาคสถิติ) เราสะสมเครื่องมือครบ — อ่านกระดาน (Part 0–2), spread/ความน่าเชื่อถือ (3–4), flow (5–8), market making (9–11), ต่อยอด (12–14) · **ตอนนี้** จะเติม: เอาทุกชิ้นมาประกอบเป็น **ลำดับการตัดสินใจเดียว** ที่เปิดจอลแล้วใช้ได้จริงกับเคสของเรา

ทั้งหมดไม่ได้เป็นหัวข้อแยก ๆ — มันคือ "checklist เดียว" ที่ไล่จากเปิดจอลจนปิดสถานะ บทนี้พาเดินผ่าน **กรณีศึกษาเดิมที่ตามมาทั้งหมด**:

กรณีศึกษา (running case)

คุณมีเงิน \$5,000 อยากเข้า long BTC/USDT ให้ได้ราคาดีที่สุด ไม่โดน adverse selection แล้วบริหารจนปิดสถานะ — จะตัดสินใจยังไงทีละขั้น?

ลำดับการตัดสินใจ (Decision Workflow)



ภาพ C.1 · อ่านกระดานจริง 1 รอบ — 6 ขั้นตอน รวมทุกตอนของเล่ม

เดินผ่านทีละขั้น (กับเคส \$5,000 long BTC)

- 1. spread/mid ปกติไหม** — ดู best bid/ask จริง (ไม่ใช่ last · **Part 0**) แล้วเช็คดูว่า spread กว้างผิดปกติไหม ด้วย z-score (**Part 3 + ภาคสถิติ**) ถ้า z สูง/ช่วงกว้าง/ตึก → spread แพง สภาพคล่องบาง → **รอ**
- 2. กระดานเชื่อได้ไหม + ผังไหนหนัก** — "กำแพง bid" ใต้ราคาเป็นแนวรับจริงหรือ spoof (**Part 4**)? OBI หนัก long ไหม แต่จำว่ามันคือภาพนิ่ง (**Part 5**)
- 3. flow หนักหรือสวน** — Δ/CVD บอก taker ผังไหนเด่น (**Part 6**), OFI บอกแรงดันสุทธิ + λ บอกว่าราคาจะขยับต่อหน่วย flow แค่ไหน (**Part 7**) ถ้า flow สวนทาง long → ทบทวน
- 4. flow toxic ไหม** — VPIN สูง = adverse selection หนัก/อาจมีคนรู้ข่าว (**Part 8**) → **ชะลอการเข้า**
- 5. เลือกวิธีเข้า** — ไม่ \$5,000 จะ walk the book แค่ไหน (**Part 2**) / impact λ (**Part 7**)? เลือก: market ที่เดียว (เร็ว แต่ slippage) · limit รอคิว (**Part 1** เสี่ยงไม่ fill) · ทอยแบบ grid (**Part 12**) · เป็น MM เก็บ rebate (**Part 9-11**) · ถ้าไม่ใหญ่เทียบสภาพคล่อง → ทอยส่งแบบ optimal execution
- 6. คุมเสี่ยง** — ตั้ง inventory limit + kill switch (**Part 11**), เพื่อ fat tails ของคริปโต (อย่าวางขนาดเท่ากับสมมติ normal · **ภาคสถิติ**), และจำว่า VPIN พุงที่หลัง = รับผิดชอบ

✓ Checklist ติดกระเป๋ — "ก่อนกดเข้าไม้"

1. spread/bps ปกติ? (z-score ไม่สูงผิดปกติ)
2. depth ที่เห็นเป็นของจริง ไม่ใช่ spoof?
3. OBI + OFI + Δ /CVD ไปทางเดียวกับไม้เราหรือสวน?
4. VPIN/flow ไม่ toxic?
5. วิธีเข้าเหมาะกับขนาดไม้ (taker/limit/grid/MM)? คิด slippage+fee แล้ว?
6. มี inventory limit + kill switch + เผื่อ fat tails?

ครบ 6 ข้อ = "อ่านกระดานเป็น" แล้วลงมืออย่างมีเหตุผล ไม่ใช่เดา

⚠ ย้ำหลักการของทั้งเล่ม

เครื่องมือทุกตัวบอก "ความน่าจะเป็น/ความเสี่ยง" ไม่ใช่คำทำนายที่แน่นอน · สัญญาณกระดาน อายุสั้น (วินาที) · และทุกอย่างต้องหัก **ต้นทุนจริง** (spread + slippage + fee) ก่อนถึงจะรู้ว่าคุ้ม — z สูง/forecasting ดี ≠ กำไร

➡ อ่านต่อในเล่มนี้ — องค์กร VI · Execution

ชั้น 5 ข้างบน ("ไม้ใหญ่ → ทอยส่ง") ทางออกเต็มเป็น **องค์กร VI** ของเล่มนี้ — ตอบคำถาม "ส่งไม้ใหญ่ยัง ใจไม่ให้ต้นทุนราคาตัวเอง":

- **EX-1** — ปัญหา Execution & Implementation Shortfall (trade-off เร็ว/ช้า, temporary vs permanent impact)
- **EX-2** — Almgren-Chriss & ตารางการทยอยส่ง (front-load, efficient frontier, TWAP/VWAP/IS-optimal)
- **EX-3** — ลงมือจริงรายย่อยคริปโต (slice parent → child, POV, ใช้ OBI/OFI/VPIN จับจังหวะ)

🔗 อ่านต่อ / ต่อยอด (นอกเล่ม)

ลึกกว่านั้น: **benign vs toxic flow** (Cartea 2023), **square-root impact law** (Bouchaud), **Obizhaeva-Wang** (execution บน LOB จริง) และตำรา O'Hara / Cartea-Jaimungal-Penalva / Guéant (ดูภาคผนวก "อ่านต่อ")

อ่านกระดาน

Reading the Book

องก์ VI · Execution — EX-1: ปัญหา Execution & Implementation Shortfall

Order Flow & Microstructure สำหรับรายย่อย · ฝั่ง taker ที่อยาก execute ดีที่สุด
ทำไมส่งไม้ใหญ่ทีเดียว "แพง" — และวัดต้นทุนซ้อนยังไง

EX-1 — ปัญหา Execution & Implementation Shortfall

✖ อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > **ตัดสินใจเข้า-ออก** > ต่อยอด/คุมเสี่ยง

🔗 ต่อจากเล่มหลัก

เพ็ญรู้มา: เล่มหลักจบที่ Capstone — เรา "อ่านกระดาน → รู้ flow → ตัดสินใจเข้า/วาง quote → คุมเสี่ยง" ได้แล้ว และ Capstone ชั้น 5 บอกว่า "ไม่ใหญ่ → ทอยส่ง" · **ตอนนี้จะเดิม:** เจาะ "ทอยส่งยังงี้" ให้เป็นวิชา — เริ่มจากเข้าใจก่อนว่าทำไมไม่ใหญ่ที่เดียวถึงแพง และจะ **วัด** ต้นทุนนั้นยังงี้

🎯 อ่านจบ Part นี้คุณจะได้

- เข้าใจว่า execution = "ฝั่งกลับ" ของ market making — เราเป็น taker ที่อยากได้ของโดย **จ่ายต้นทุนน้อยสุด**
- เห็น **trade-off หัวใจ:** ส่งเร็ว → market impact (ผลกระทบต่อราคาจากไม้เราเอง) สูง · ส่งช้า → timing risk (ความเสี่ยงราคาร่วงหนึ่ระหว่างรอ) สูง
- นิยาม **Implementation Shortfall (IS = ต้นทุนการลงมือจริง)** เทียบกับ arrival price
- แยก **temporary impact** (ตั้งกลับ) ออกจาก **permanent impact** (ถาวร)


เริ่มจากการเทน้ำลงแก้ว

นึกถึงการเทน้ำจากเหยือกลงแก้วให้ครบพอดี — **เทเร็วเกินไป น้ำกระเด็นล้น** (เสียของ) แต่ **เทช้าเกินไป น้ำในเหยือกกระเหย/มีอเมื่อย** (เสียเวลา/โอกาส) การส่งคำสั่งซื้อก้อนใหญ่ก็เหมือนกันปะ:

- **ส่งทีเดียว (เทเร็ว)** → คุณ "walk the book" (Part 2) ต้นราคาตัวเองขึ้น = **market impact** สูง
- **ทยอยช้า ๆ (เทช้า)** → ระหว่างที่ค่อย ๆ ซื้อ ราคาอาจร่วงหนึ่ขึ้นไปก่อน = **timing risk**

หัวใจของ execution คือ **หาจุดสมดุลระหว่างสองความเสี่ยงนี้** — ไม่มีคำตอบเดียว ขึ้นกับขนาดไม้ สภาพคล่อง และว่าคุณกลัวความเสี่ยงแค่ไหน

ส่งไม้ใหญ่ = เทน้ำลงแก้วให้พอดี



ภาพ EX1.1 · trade-off ของ execution — เร็วเสีย impact / ช้าเสีย timing risk

Implementation Shortfall — วัด "ต้นทุนซ่อน" ของการลงมือ

ตอนคุณ *ตัดสินใจ* จะซื้อ ราคาบนจอคือ **arrival price** (ราคา ณ จังหวะตัดสินใจ — มักใช้ mid ตอนนั้น) แต่กว่าจะซื้อครบจริง ราคาเฉลี่ยที่ได้มักแพงกว่านั้น **Implementation Shortfall (IS)** คือส่วนต่างนี้ — "กำไรบนกระดาน" หายไปเท่าไรตอนลงมือจริง

IS (ต่อ 1 หน่วย, ฝั่งซื้อ) = ราคาเฉลี่ยที่ได้จริง - arrival price

arrival price = mid ณ จังหวะ "ตัดสินใจ" (benchmark)

IS รวม = $\sum (\text{fill}_i - P_{\text{arrival}}) \cdot q_i + (\text{ส่วนที่ซื้อไม่ครบ}) \cdot (P_{\text{สุดท้าย}} - P_{\text{arrival}})$

└ ต้นทุน execution —┐ └ opportunity cost (ราคาหนีไปก่อนซื้อครบ) ┐

IS รวม 2 ก้อน: (1) **ต้นทุน execution** ที่จ่ายจริง (impact + spread + fee) และ (2) **opportunity cost** ถ้าทยอยช้าจนซื้อไม่ทันราคาที่หนีไป — สังเกตว่าสองก้อนนี้คือ trade-off เดียวกับการเทน้ำ




ภาพ EX1.2 · IS = market impact (เทเร็ว) + timing risk (เทช้า) — ลดอันหนึ่งมักเพิ่มอีกอัน

Temporary vs Permanent Impact

เวลาคุณกวาดซื้อ ราคาจะถูกดันขึ้น — แต่ impact มี 2 ส่วนที่ต่างกันมาก:

- **Temporary impact:** ราคาถูกดันขึ้นชั่วคราวเพราะคุณกินสภาพคล่อง พอคุณหยุด ผู้เล่นอื่นเต็ม limit กลับราคา **เต่งลงมาบางส่วน** (โยง resiliency, Part 4)
- **Permanent impact:** ส่วนที่ **ค้างอยู่ถาวร** เพราะตลาดตีความว่า "มีคนรู้อะไร" (โยง adverse selection — Part 3 ส่วนแยก spread, Part 8 toxicity) — ราคาไม่กลับมาที่เดิม



ภาพ EX1.3 · กวาดซื้อดันราคาขึ้น → หยุดแล้วเต่งกลับบางส่วน (temporary) เหลือส่วนค้าง (permanent)

🎯 กับเคสของเรา

เคสเดิม \$5,000 บน BTC (สภาพคล่องสูง) — impact แทบไม่มี สง market ก็พอ · แต่ลองนึกว่าไม้โตขึ้นเป็น \$50,000 บนเหรียญ alt สภาพคล่องปานกลาง ที่ depth ที่ best มีไม่กี่พันดอลลาร์ — สิ่งเดียวจะ walk the book ดันราคาตัวเองหลาย % ทันที นี่คือจุดที่ execution เริ่มสำคัญ และ IS คือเครื่องวัดที่เราเสียไปเท่าไร

📄 งานวิจัยรองรับ

คำว่า **Implementation Shortfall** มาจาก Perold (1988) · กรอบ trade-off impact ↔ risk และการแยก temporary/permanent impact เป็นรากฐานของ **Almgren & Chriss (2000)** ที่เราจะลงลึกใน EX-2 — และเชื่อมกับ square-root impact law (Part 7) ที่ว่า impact โตตาม $\sqrt{\text{ขนาดไม้}}$

🔗 เชื่อมโยงเล่มหลัก

Part 2 (walk the book/slippage) = ต้นกำเนิดของ market impact · **Part 7** (Kyle's λ) = impact ต่อหน่วย flow · **Part 4** (resiliency) = ทำไม temporary impact ถึงเต่งกลับ · **Part 6** (informativeness) = ทำไม permanent impact ถึงค้าง

⚠ กีบดักมือใหม่

- **ไม้เล็กไม่ต้องคิดเยอะ:** ถ้าไม้คุณเล็กเทียบ depth (เช่น \$100 บน BTC) impact ~ 0 — ส่ง market จบอย่า over-engineer
- **วัดจาก last price:** IS ต้องเทียบ arrival price (mid ตอนตัดสินใจ) ไม่ใช่ last หรือราคาปิด ไม่จันวัดผิด
- **ลืม opportunity cost:** หยอยช้าเพื่อลด impact แต่ถ้าราคาหนีไปก่อนซื้อครบ ก็ขาดทุนเหมือนกัน — สองด้านของเหรียญเดียว

🔪 แบบฝึก (ข้อมูลคริปโตฟรี)

เลือกเหรียญ alt สภาพคล่องปานกลาง ดึง order book snapshot — จด mid (= arrival price) · จำลอง market buy มูลค่า X ที่ใหญ่กว่า depth ที่ best · คำนวณ **AvgFill** (จาก Part 2) แล้วหา **IS = AvgFill - mid** เป็น % · ลองเพิ่ม X เป็น 2 เท่า ดูว่า IS โตเร็วแค่ไหน — จะเห็น "ความโค้ง" ของการ walk the book · *หมายเหตุ:* นี่เป็น convexity จาก snapshot เดียว ส่วน **square-root law** ตัวจริง (Part 7) เป็นกฎเชิงประจักษ์ของ metaorder ที่ทยอยส่งตามเวลา และวัดขนาดเทียบ **volume/ADV** ไม่ใช่มูลค่าดิบ — สองอย่างนี้คนละระดับกัน

ส่งต่อ → EX-2: ถ้ารู้ว่าเร็วเสีย impact/ช้าเสีย timing risk แล้ว — มี "ตารางการทยอยส่ง" ที่ optimal ไหม? (Almgren-Chriss)

อ่านกระดาน

Reading the Book

องก์ VI · Execution — EX-2: Almgren-Chriss & ตารางการทยอยส่ง

Order Flow & Microstructure สำหรับรายย่อย · จาก "trade-off" สู่ "ตารางส่งจริง"
ทำไมต้อง front-load — และ efficient frontier บอกอะไรเรา

EX-2 — Almgren-Chriss & ตารางการทยอยส่ง

🔗 อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > **ตัดสินใจเข้า-ออก** > ต่อยอด/คุมเสี่ยง

🔗 ต่อจาก EX-1

เพ็ญรัฐมา: ใน EX-1 เราเจอ **trade-off หัวใจ** — ส่งเร็วเสีย market impact / ส่งช้าเสีย timing risk — และวัดต้นทุนรวมเป็น **Implementation Shortfall (IS)** · **ตอนนี้จะเดิม:** ถ้ารู้ว่ามี trade-off แล้ว มี "ตารางการทยอยส่ง" (trade schedule) ที่ **optimal** ไหม? Almgren-Chriss (2000) ตอบคำถามนี้ด้วยคณิตศาสตร์ — และคำตอบสวยกว่าที่คิด

🎯 อ่านจบ Part นี้คุณจะได้

- เข้าใจโมเดล Almgren-Chriss: temporary impact $\propto$ **อัตราเทรด** · permanent impact $\propto$ **ปริมาณสะสม**
- เห็นว่า optimal schedule = minimize $E[\text{cost}] + \lambda \cdot \text{Var}[\text{cost}] \rightarrow$ ได้ trajectory แบบ **front-loaded**
- อ่าน **efficient frontier** (expected cost $\leftrightarrow$ variance) ได้ และรู้ว่า risk aversion λ เลื่อนเราไปจุดไหน
- เทียบ **TWAP / VWAP / IS-optimal** ว่าอันไหนเหมาะเมื่อไหร่

โมเดล: impact 2 แบบที่ซับซ้อนอย่าง

Almgren-Chriss แยก market impact ออกเป็น 2 ก้อนที่มีพฤติกรรมต่างกัน (ตรงกับ temporary vs permanent ใน EX-1):

- **Permanent impact $\propto$ ปริมาณสะสม** — ทุกหน่วยที่เราเทรดดันราคา "ฐาน" ค้างไว้ไม่ว่าจะส่งเร็วช้าก่อนนี้ **เท่ากันเสมอ** (ขึ้นกับขนาดไม้รวม X ไม่ใช่ความเร็ว) — เป็นต้นทุนที่ **หนีไม่ได้**
- **Temporary impact $\propto$ อัตราเทรด** — ยิ่งดันของเข้าตลาด "ต่อหน่วยเวลา" เร็ว ราคาเฉลี่ยช่วงนั้นยิ่งแพง แต่พอหยุด ราคาเด็งกลับ — ก้อนนี้คือสิ่งที่ **schedule ควบคุมได้**

สัญลักษณ์: y = ค่า permanent impact ต่อหน่วย · η = ค่า temporary impact · σ = ความผันผวน · λ = ความกลัวเสี่ยง

ขายไม้ X หน่วยใน T เวลา · $x(t)$ = จำนวนที่ "ยังถืออยู่" ตอนเวลา t ($x(0)=X$, $x(T)=0$)
 $v(t) = -dx/dt =$ อัตราเทรด (เร็วแค่ไหน)

ต้นทุนคาดหวัง $E[\text{cost}] = \frac{1}{2} \cdot \gamma \cdot X^2 + \eta \cdot \int v(t)^2 dt$

└ permanent (คงที่) └ temporary (ยิ่งเร็วยิ่งแพง) └

ความแปรปรวน $\text{Var}[\text{cost}] = \sigma^2 \cdot \int x(t)^2 dt \leftarrow$ (ภาษาคน: ยิ่งของค้างในมือเยอะ และค้างนาน ความเสี่ยงราคาแกว่งยิ่งทบ)

สังเกตหัวใจ: **permanent** ($\frac{1}{2}\gamma X^2$) **ไม่ขึ้นกับ schedule เลย** — เลือกยิ่งไงก็จ่ายเท่านี้ ดังนั้นเกมจริงคือ trade-off ระหว่าง **temporary impact** (อยากส่งช้าให้ v ต่ำ) กับ **variance** (อยากส่งเร็วให้ x ลดไว ไม่ต้องแบกความเสี่ยงนาน) — เหมือนเนื้อหาใน EX-1 เป๊ะ แต่คราวนี้เขียนเป็นสมการได้

คำตอบ optimal: ทำไมต้อง "front-load"

Almgren-Chriss แก้ปัญหา minimize $E[\text{cost}] + \lambda \cdot \text{Var}[\text{cost}]$ (λ = ระดับความกลัวความเสี่ยง) คำตอบของ trajectory ออกมาเป็นรูปปิดสวย ๆ:

$$x(t) = X \cdot \sinh(\kappa \cdot (T - t)) / \sinh(\kappa \cdot T)$$


โดย $\kappa = \sqrt{(\lambda \cdot \sigma^2 / \eta)}$ ← "ความรีบ" (urgency)

- λ มาก (กลัวเสี่ยง) → κ มาก → ขายไวตอนต้น (front-load)
- $\lambda \rightarrow 0$ (ไม่กลัวเสี่ยง) → $\kappa \rightarrow 0 \rightarrow x(t) = X \cdot (1 - t/T) =$ เส้นตรง = **TWAP**
- $1/\kappa =$ "half-life" ของไม้ — เวลาที่ใช้รีดของออกส่วนใหญ่

หมายเหตุความเป๊ะ: รูป $\kappa = \sqrt{(\lambda \sigma^2 / \eta)}$ นี้คือรูป **continuous-time limit** (เวลาแบ่งย่อยถี่มาก) — เวอร์ชันจริงแบบ discrete ของ Almgren-Chriss มีพจน์แกเล็ค ๆ ($\propto \gamma t$) บวกเข้ามา แต่ไม่เปลี่ยนภาพรวม จึงใช้รูปนี้เป็นกรอบคิดได้

ความหมายเชิงสัญชาตญาณ: ถ้าคุณกลัวว่าราคาจะวิ่งหนี (variance นรกกลัว) คุณควร **เทออกหนักช่วงแรก** แล้วค่อย ๆ เบาลง — เพราะของที่ยังถือคือความเสี่ยง รีบลดมันก่อน · แต่ถ้าไม่กลัวเสี่ยงเลย ก็ทยอยเท่า ๆ กัน (TWAP) เพื่อลด temporary impact ให้ต่ำสุด


ตารางการถือครอง $x(t)$: ของที่ "ยังเหลือต้องขาย"



ภาพ EX2.1 · AC เทหนักช่วงแรก (เส้นแดงดิ่งเร็ว) เพื่อลดความเสี่ยง ส่วน TWAP ทยอยเท่ากัน (เส้นน้ำเงินตรง)

Efficient frontier: เลือก "จุด" ที่ใช้สำหรับคุณ

λ แต่ละค่าให้ schedule หนึ่ง และ schedule นั้นมีคู่ตัวเลข (expected cost, variance) หนึ่งจุด ลากทุกจุดที่ *optimal* ได้เส้นโค้งเรียกว่า **efficient frontier** — แนวคิดเดียวกับ Markowitz ในพอร์ตหุ้น แต่นี่คือ frontier ของ "การ execute":



ภาพ EX2.2 · ทุกจุดบนเส้นเขียว "คุ้ม" หมด — เลือกตามว่าคุณกลัวเสี่ยงแค่ไหน ไม่มีจุดไหน "ถูกที่สุด" พร้อม "เสี่ยงต่ำสุด"

อ่าน frontier ยังไง: เลื่อนไป **ขวา** (TWAP) = จ่ายต้นทุนคาดหวังต่ำ แต่ยอมแบกความเสี่ยงราคาแกว่งสูง (เพราะถือนาน) · เลื่อนไป **ซ้าย** = รับผิดชอบต่อ ความเสี่ยงต่ำลง แต่จ่าย temporary impact แพงขึ้น · **ไม่มี "จุดที่ดีที่สุด" สากล** — ขึ้นกับ γ/λ ของคุณ (กลัวพลาดดีลแค่ไหน vs กลัวจ่ายแพงแค่ไหน)

TWAP / VWAP / IS-optimal — อันไหนเมื่อไหร่

กลยุทธ์	ส่งยังไง	เหมาะเมื่อ	จุดอ่อน
TWAP (time-weighted)	แบ่งเท่า ๆ กันตามเวลา (เส้นตรง)	ไม่กลัวเสี่ยง · อยากกด impact · ตลาด flow สม่าเสมอ	ถือนาน = เสี่ยงราคาหนี้ · คาดเดาง่าย โดน front-run
VWAP (volume-weighted)	ส่งหนักตอนตลาด volume เยอะ (กลมกลืนกับฝูง)	อยากซ่อนตัวในปริมาณตลาด · benchmark เป็น VWAP	ต้องเดา volume profile · เหรียญบางค้ายาก
IS-optimal (Almgren-Chriss)	front-load ตาม λ (เทหนักช่วงแรก)	กลัวราคาวิ่งหนี · มี view ทิศทาง · ไม่ใหญ่เทียบสภาพคล่อง	ต้องประมาณ η, σ, γ · พารามิเตอร์ผิด = schedule เพี้ยน

เส้นเชื่อม: **TWAP คือ IS-optimal ตอน $\lambda=0$** (ปลายขวาสุดของ frontier) — มันไม่ใช่คนละโลกกัน VWAP เป็นญาติที่เอา "รูปร่าง volume ของตลาด" มาเป็นตารางแทนเวลา ทั้งสามคือจุด/เส้นบนแผนที่เดียวกัน

🎯 กับเคสของเรา

เคสไม้ใหญ่ \$50,000 บนเหรียญ alt สภาพคล่องปานกลาง (จาก EX-1): สมมติ σ สูง (เหรียญแกว่งแรง) → $\lambda\sigma^2/\eta$ ใหญ่ → κ ใหญ่ → AC บอกให้ **front-load**: เทอจ 40% ในไตรมาสเวลาแรก แล้วค่อยเบา เพราะการถือ alt ผันผวนไว้นานคือความเสี่ยงที่แพงกว่า impact ที่ประหยัดได้ · ถ้าเป็น BTC สภาพคล่องลึก (η ต่ำ, σ ต่ำกว่า) → κ เล็ก → เข้าใกล้ TWAP ได้สบายขึ้น

📄 งานวิจัยรองรับ

Almgren & Chriss (2000) *Optimal Execution of Portfolio Transactions* คือต้นฉบับของ trajectory แบบ sinh และ efficient frontier นี้ · ต่อยอดจาก **Bertsimas & Lo (1998)** ที่เป็นเจ้าแรกที่วาง execution เป็นปัญหา **dynamic programming** (หา trade schedule ที่ minimize ต้นทุนคาดหวัง) — แต่เพราะมองแบบ **risk-neutral ล้วน** (ไม่ลงโทษ variance) คำตอบเลยออกมาเป็นการแบ่งเท่า ๆ กัน = TWAP · AC ก้าวต่อด้วยการ **เติมพจน์ $\lambda \cdot \text{Var}$** เข้าไป จึงได้ front-load และ efficient frontier · **Obizhaeva & Wang (2013)** เติมมิติ LOB จริง: สภาพคล่องไม่ฟื้นทันที (resiliency) — เชื่อมกับ Part 4 · ส่วน **square-root impact law** (Bouchaud และคณะ) จาก Part 7 เตือนว่า impact จริงมัก $\propto \sqrt{\text{ขนาด}}$ ไม่ใช่เชิงเส้นเป๊ะอย่างที่ AC สมมติ

🔗 เชื่อมโยงเล่มหลัก

Part 2 (walk the book) = ที่มาของ temporary impact · **Part 4** (resiliency/การถอน-เติม liquidity) = ทำไม impact เด้งกลับ และทำไม Obizhaeva-Wang ถึงสำคัญ · **Part 7** (Kyle's λ , square-root law) = วิธีประมาณ η จริง · **Part 8** (VPIN/toxicity) = ใช้จับว่าช่วงไหนตลาดอันตราย ควรชะลอ schedule

⚠️ กับดักที่ต้องระวัง

- **AC = กรอบคิด ไม่ใช่สูตรรันเป๊ะ**: รายย่อยประมาณ η, γ, σ ได้หยาบมาก — ใช้รูป trajectory เป็น "ทิศทาง" (front-load แค่นั้น) ไม่ใช่ตัวเลขศักดิ์สิทธิ์
- **impact จริงไม่เชิงเส้น**: AC สมมติ temporary $\propto v$ เชิงเส้น แต่ของจริงมัก $\sqrt{\cdot}$ (Part 7) — อย่าเชื่อ closed-form เกินไป
- **schedule คงที่ = เหยื่อ**: ส่งตามนาฬิกาเป๊ะ ๆ คาดเต่าง่าย โดน detect/front-run — EX-3 จะเพิ่มการใช้สัญญาณกระดานปรับจังหวะ child orders
- **λ ไม่ใช่ค่าคงที่ของจักรวาล**: มันคือ "ความกลัวเสี่ยง" ของ *คุณเอง* — ไม่มีค่าถูก/ผิด มีแต่เหมาะ/ไม่เหมาะกับสถานการณ์

🔧 แบบฝึก (ข้อมูลคริปโตฟรี)

เลือกเหรียญ 2 ตัว: ตัวสภาพคล่องลึก (เช่น BTC) กับตัวบาง (alt) — ประมาณ σ รายชั่วโมงของแต่ละตัว (Part ภาคสถิติ) แล้วถามตัวเอง: ตัวไหน $k=\sqrt{(\lambda\sigma^2/\eta)}$ ควรใหญ่กว่า? AC บอกให้ front-load ตัวไหนมากกว่า? · จากนั้นวาด schedule คร่าว ๆ ของไม้ \$10,000 บนแต่ละตัว เทียบกับ TWAP เส้นตรง

ส่งต่อ → **EX-3:** เอา trajectory นี้ไปลงมือจริงบนคริปโต — slice parent → child, ใช้ OBI/OFI/VPIN จับจังหวะ child orders, และตารางความจริงว่าไม้ขนาดไหน "ต้อง" slice จริง ๆ

อ่านกระดาน

Reading the Book

อังก VI · Execution — EX-3: ลงมือจริง (รายย่อยคริปโต)

Order Flow & Microstructure สำหรับรายย่อย · จากทฤษฎีสู่ปฎิบัติจริง
slice parent → child · ใช้สัญญาณกระดานจับจังหวะ · ไม่ขนาดไหน "ต้อง" slice

EX-3 — ลงมือจริง (รายย่อยคริปโต)

✖ อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > **ตัดสินใจเข้า-ออก** > ต่อยอด/คุมเสี่ยง

🔗 ต่อจาก EX-2


เพิ่มรู้มา: Almgren-Chriss ให้ "รูปร่าง" ตารางส่ง (front-load ตามความกลัวเสี่ยง) และ efficient frontier ให้เลือกจุดที่ใช้ · **ตอนนี้จะเดิม:** แล้วบนแอป Binance/Bybit กดยังไงจริง ๆ? เราจะแปลง trajectory เป็น **child orders** ที่ส่งได้จริง ใช้สัญญาณกระดานจากเล่มหลัก (OBI/OFI/VPIN) ปรับจังหวะ และที่สำคัญสุด — ตอบตรง ๆ ว่า **ไม้ขนาดไหนต้องทำ ขนาดไหนไม่ต้อง**

🎯 อ่านจบ Part นี้คุณจะได้

- แบ่ง parent order → child orders เป็น **TWAP / VWAP / POV (percentage of volume)** ได้
- เลือกได้ว่า child ควรเป็น **limit** (post ในคิว) หรือ **market** (จ่าย spread กินทันที)
- ใช้ **OBI/OFI (Part 5-7)** และ **VPIN (Part 8)** จับจังหวะว่า "ตอนนี้เร่ง child หรือชะลอดี"
- มี **ตารางความจริงรายย่อย:** ไม้เล็ก → market พอ · ไม้ใหญ่/เหวี่ยงบาง → ต้อง slice · HFT execution = เกินสนามเรา

parent → child: แบ่งไม้ใหญ่เป็นไม้เล็ก

หัวใจปฏิบัติคือแตก "parent order" (ไม้ใหญ่ที่ตั้งใจซื้อ) ออกเป็น "child orders" (ไม้ย่อยที่ทยอยส่งจริง) ตามรูปร่างที่ EX-2 บอก แล้วแต่ละ child เลือกได้ว่าจะ limit หรือ market:



ภาพ EX3.1 · ขนาด child ลดหลั่นแบบ front-loaded — ตัวเลขเป็นภาพประกอบเชิงสถิติ

3 วิธีกำหนด "ขนาด/จังหวะ" child ที่รายย่อยใช้ได้จริง:

วิธี	กฎการส่ง child	เหมาะกับ
TWAP	child เท่า ๆ กันทุก N นาที (เช่น \$5k ทุก 10 นาที)	ง่ายสุด · ทำมือได้ · flow สม่ำเสมอ
VWAP	child ใหญ่ตอนช่วงโม่งที่ตลาด volume เยอะ (ดู volume profile ย้อนหลัง)	อยากกลบกลืนฝูง · เหรียญที่มี จังหวะ volume ชัด
POV (percentage of volume)	ส่ง child = X% ของ volume ที่กำลังเทรดจริง (เช่น 10% ของ volume 1 นาที)	ปรับตามสภาพคล่อง real-time · ไม่ฝืนตลาดเกินไป

POV คือตัวที่ "ปลอดภัย" ที่สุดเชิงสัญชาตญาณสำหรับเหรียญบาง: ตลาดคึก → ส่งเยอะตาม · ตลาดเงียบ → ส่งน้อยลงเอง ไม่ไปดันราคาในช่วงสภาพคล่องหด

child เป็น limit หรือ market?

นี่คือจุดที่เล่มหลักทั้งเล่มมาบรรจบ — maker/taker (Part 3), คิว (Part 3), spread (Part 1):

- **Limit child (post-only):** วางในคิว รอคนมาชน → ได้ราคาดี/อาจได้ rebate แต่ **เสี่ยงไม่ได้คิว** ถ้าราคาริ่งหนี (กลายเป็น opportunity cost ที่ EX-1 เตือน)
- **Market child (taker):** กินทันที จ่าย spread + walk the book → **ได้ของแน่นอน** แต่จ่าย temporary impact เต็ม ๆ


กฎหมาย: ช่วงที่ไม่รีบและ OBI หนุนฝั่งเรา → ใช้ limit รอคิว · ช่วงที่ราคากำลังจะหนีหรือใกล้หมดเวลา → ยอมจ่ายเป็น market สรุปคือ **front ของ trajectory (รีบ) มักใช้ market มากกว่า, ปลาย (เหลือน้อย/มีเวลา) เอนไป limit**

ใช้สัญญาณกระดานจับจังหวะ child

ตรงนี้เป็นเล่มหลักจ่ายคืน: AC ให้ "ตารางฐาน" แต่เราเอาสัญญาณ real-time มา **ปรับจังหวะรอบ ๆ ตาราง** (ไม่ใช่ทั้งตาราง — แค่อะไร/ชะลอ child ถัดไป):

สัญญาณ (เล่มหลัก)	อ่านได้ว่า	ทำกับ child ถัดไป
OBI หนุนฝั่งซื้อ (Part 5)	แรงซื้อรออยู่เยอะ ราคามีแนวโน้มขยับขึ้น	เร่ง child / เอนไป market ก่อนราคาหนี
OFI เป็นบวกแรง (Part 6–7)	flow ผลักราคาขึ้นกำลังมา	เร่ง — อย่ารอช้าจนแพง
VPIN/toxicity พุ่ง (Part 8)	flow toxic — มี informed trader ราคาอาจ gap	ชะลอ / ถอน limit / รอให้สงบ อย่าเป็นเหยื่อ adverse selection
spread กว้างผิดปกติ (Part 1)	สภาพคล่องหด ตันทุน taker แพง	หลีกเลี่ยง market · ใช้ limit หรือรอ

ตาราง AC = เส้นฐาน · สัญญาณ = เร่ง/ชะลอรอบ ๆ




ภาพ EX3.2 · สัญญาณกระดานไม่ล้มตาราง — แคขยับ child ถัดไปให้เร็วขึ้น (flow หนุน) หรือช้าลง (toxic)

ตารางความจริงรายย่อย: ต้อง slice เมื่อไหร่

ส่วนที่ซื้อสัตย์ที่สุดขององค์กร — รายย่อยส่วนใหญ่ไม่ต้องทำ execution algo เลย มันสำคัญเฉพาะเมื่อไม้ใหญ่เทียบสภาพคล่อง:

สถานการณ์	ไม้เทียบ depth ผังตรงข้าม	ทำยังไง
ไม้เล็ก เหรียญสภาพคล่องลึก (BTC/ETH)	< ~10% ของ best levels	market ที่เดียวพอ — impact น้อยกว่าความยุ่งยาก
ไม้กลาง หรือเหรียญสภาพคล่องปานกลาง	กิน 2–5 ระดับราคา	slice ง่าย ๆ แบบ TWAP/POV 3–5 ไม้ก็ช่วยได้มาก
ไม้ใหญ่เทียบ depth / เหรียญ alt บาง	walk the book หลายระดับ	ต้อง slice จริงจัง + ใช้สัญญาณ + POV ตาม volume
HFT smart order routing ข้าม venue ระดับ ms	—	เก็นสนามรายย่อย — ไม่ต้องไปแข่ง

เลือกกลยุทธ์: ไม้ของฉันเทียบ depth เท่าไหร่?



ภาพ EX3.3 · flowchart เลือกกลยุทธ์ตามขนาดไม้เทียบสภาพคล่อง

📍 กับเคสของเรา — บิดวง

ไม้ \$50,000 บนเหรียญ alt สภาพคล่องปานกลาง: depth ผัง ask รวม 3 ระดับแรกมีแค่ ~\$15k → ไม้เราใหญ่กว่า depth = ช่องขวาสุดของ flowchart · แผน: แดกเป็น ~5 child แบบ front-loaded (EX-2), ส่งแบบ POV ~10–15% ของ volume, child ตัน ๆ เอนไป market (รีบลดความเสี่ยง) child ท้าย ๆ ใช้ limit รอคิว, และ ถ้า VPIN พุง → หยุดชั่วคราว รอ flow สงบ · นี่คือการตอบเต็มของคำถามที่เปิดใน EX-1 ว่า "ส่งไม้ใหญ่ยังไงไม่ให้ดันราคาตัวเอง"

งานวิจัยรองรับ

การ slice + ใช้ benchmark TWAP/VWAP/POV เป็นมาตรฐานอุตสาหกรรมที่ต่อยอดจาก **Almgren & Chriss (2000)** · **Obizhaeva & Wang (2013)** โมเดล execution บน LOB จริงที่สภาพคล่องฟื้นเป็น เวลา (resiliency) — คำตอบ optimal ตามตัวเปเปอร์จริง ๆ เป็นรูป **U: ยิ่งก้อนใหญ่ตอนเปิด-ปิด + หอย เรื่อย ๆ ตรงกลาง** (ไม่ใช่ POV เป๊ะ) แต่แก่นที่เราขี้มมาคือ "เพราะ liquidity ฟื้นเป็นเวลา จึงควรเทรด ตามจังหวะที่ตลาดพร้อมรับ" ซึ่ง POV เป็นวิธี approximate ที่รายย่อยทำได้จริง · การใช้ toxicity จับ จังหวะหลบอิงงานสาย **VPIN (Easley, López de Prado & O'Hara 2012)** และงาน detecting toxic flow ที่เล่มหลัก Part 8 อ้างถึง

เชื่อมโยงเล่มหลัก — องค์นี้ทำให้ทั้งเล่มมาบรรจบ

Part 1 (spread) · **Part 2** (walk the book/slippage) · **Part 3** (maker/taker, คิว → limit vs market child) · **Part 5–7** (OBI/OFI จับจังหวะเร่ง) · **Part 8** (VPIN จับ toxic เพื่อชะลอ) · **Part 11** (กับดัก latency/backtest) · **Capstone** (ชั้น 5 "ไม้ใหญ่หอยส่ง" ที่องค์นี้กางออกเต็ม)

กับดักที่ต้องระวัง (รายย่อยคริปโต)

- **front-run เอาจตัวเอง:** ส่ง child แบบคาดเดาได้ (เป๊ะทุก 10 นาที่ ขนาดเท่ากัน) บนเหรียญบาง บอ ตอาจจับทางได้ — สุ่ม jitter เวลา/ขนาดเล็กน้อย
- **fee สะสม:** แดก child เยอะเกิน = จ่าย taker fee หลายรอบ อาจกินกำไรที่ประหยัด impact ได้ — ใช้ post-only/limit ช่วยลด และอย่า slice ละเอียดเกินจำเป็น
- **เหรียญอิงบาง impact ยิ่งสูง:** alt เล็ก ๆ บางตัว ไม้ \$5k ก็ walk the book แล้ว — เช็ค depth จริง ก่อนเสมอ อย่าเชื่อกราฟราคาอย่างเดียว
- **latency รายย่อย:** เราช้ากว่า HFT เสมอ — อย่ายอกแบบกลยุทธ์ที่ต้องชนะเรื่องความเร็ว (Part 11) ใช้สัญญาณเชิงทิศทาง/จังหวะ ไม่ใช่ race
- **POV ต้องมีข้อมูล volume real-time:** ถ้าดูไม่ทันจริง ใช้ TWAP + เช็ค spread/VPIN ก่อนยิ่งก็ ปลอดภัยกว่าผืนทำ POV มั่ว ๆ

แบบฝึก (ข้อมูลคริปโตฟรี)

เลือกเหรียญ alt สภาพคล่องปานกลางบน Binance/Bybit · จด L2 snapshot: รวม depth ผัง ask 5 ระดับแรก · ถ้าจะซื้อ \$20,000 ลองคำนวณว่าถ้า market ที่เดียวจะ walk the book ไปกี่ระดับ (= IS จาก EX-1) · แล้วออกแบบแผน slice: กี่ child, TWAP หรือ POV, child ไหน limit/market · สุดท้ายเขียนกฎ "ถ้า VPIN/spread เป็นแบบนี้ จะชะลอ" — นี่คือ execution plan ฉบับรายย่อยของคุณเอง

จบองค์ VI · Execution — คุณครบวงจรแล้ว: อ่านกระดาน → รู้ flow → ตัดสินใจ → วาง quote → คมเสียง → execute
ไม่ใหญ่อย่างมีวิชา 🎯