

อ่านกระดาน

Reading the Book

Part โบนัส: เครื่องจักรอ่านกระดาน — DeepLOB, Transformers

Order Flow & Microstructure สำหรับรายย่อย · องค์กร V · ต่อยอด & คุมเสี่ยง (โบนัส)
ML คือปลายทาง ไม่ใช่จุดเริ่ม — "feature ดี > โมเดลลึก" และอย่าทรมาน architecture แทนข้อมูล

 อ่านกระดาน > รู้ใครกดดัน & เชื่อได้แค่ไหน > ตัดสินใจเข้า-ออก > **ต่อยอด/คุมเสี่ยง**

Part โบโน่ส — เครื่องจักรอ่านกระดาน

ต่อจากตอนก่อน

เพ็ญรู้มา: Part 14 จัดอันดับ arb ตาม "ความจริงรายย่อย" — latency อย่าตะเต, cross-exchange/triangular ระวัง, OFI stat-arb เหมาะสุดเพราะใช้ "ความเข้าใจกระดาน" ไม่ใช่ความเร็วเครื่อง · **ตอนนี้จะเดิม:** ปลายทางสุดของการอ่านกระดาน — ให้ deep learning (DeepLOB, Transformer) อ่านกระดานแทน แต่บทเรียนคือ "feature ดี > โมเดลลึก" และ ML คือยอดภูเขาที่ต้องมีค่ายฐาน microstructure ทั้ง 14 Part ก่อน


อ่านจบ Part นี้คุณจะได้

- เข้าใจ pipeline ของโมเดล deep learning อ่านกระดาน: **LOB** → **CNN** → **LSTM** → **ทำนายทิศ mid** (DeepLOB)
- รู้จัก **Transformer** สำหรับ **LOB** (TLOB/LiT) และจุดที่มันต่างจาก CNN+LSTM
- ซึมหลักสำคัญ: **"feature ดี > โมเดลลึก"** — OFI/imbalance ที่ออกแบบดีชนะ network ใหญ่ที่ป้อนข้อมูลดิบ
- เข้าใจว่า **ML คือปลายทาง ไม่ใช่จุดเริ่ม** — ต้องมีรากฐาน microstructure ทั้ง 14 Part ก่อน

เริ่มจากยอดภูเขา ไม่ใช่ค่ายฐาน

คนที่พิชิตยอดเอเวอเรสต์ไม่ได้เริ่มจากการกระโดดขึ้นยอดเลย — เขาเริ่มจาก **ค่ายฐาน** ปรับตัวกับความสูง ผึกหายใจ แล้วค่อยไต่ขึ้นทีละแคมป์ **ML สำหรับอ่านกระดานคือ "ยอดภูเขา"** — สวยงาม แต่ถ้าคุณไม่มีค่ายฐาน (เข้าใจ spread, OBI, OFI, VPIN, market making) คุณจะรู้ด้วยซ้ำว่าโมเดลมันเรียนรู้อะไรหรือพังตรงไหน

อีกอุปมา: **สายตาเทรตเตอร์ที่ฝึกดูกระดานมาเป็นล้านครั้ง** — neural network ก็คือการจำลองสายตานั่นด้วยข้อมูลมหาศาล แต่ "สายตา" จะแม่นยำได้ต้องป้อน **สิ่งที่มีความหมาย** ให้ดู ไม่ใช่ตัวเลขดิบมั่ว ๆ




ภาพ B.1 · ML คือยอดภูเขา — ต้องมีค่ายฐาน microstructure ก่อนถึงจะไต่ขึ้นได้

ขั้นที่ 1 — pipeline DeepLOB (CNN + LSTM)

DeepLOB รับ **snapshot** ของกระดานหลายชั้น ต่อกันเป็นลำดับเวลา (เมทริกซ์ขนาด $T \times 4L$: แต่ละชั้น L มี ราคา/ปริมาณ ของ bid และ ask) แล้วส่งผ่าน:

- **CNN** — กวาดหา "ลวดลายเชิงพื้นที่" ในกระดาน (เช่น รูปทรง imbalance ข้ามชั้น) แทนการดูตัวเลขทีละตัว
- **LSTM** — จับ "ลำดับเวลา" ว่าลวดลายเปลี่ยนยังไงในไม่กี่วินาที
- **softmax 3 class** — ทำนายว่า mid ช่วงถัดไปจะ **ขึ้น** / **นิ่ง** / **ลง**




ภาพ B.2 · pipeline LOB → CNN → LSTM → ทำนาย 3 class

ขั้นที่ 2 — Transformer สำหรับ LOB (TLOB/LiT)

Transformer ใช้ **attention** แทน convolution + recurrence — มันเรียนได้เองว่า "ชั้นไหน/เวลาไหน ของกระดาน" สำคัญต่อการทำนาย โดยไม่ต้องใส่ลำดับที่ละสลับแบบ LSTM งานอย่าง **TLOB** และ **LiT** แสดงว่าสถาปัตยกรรมนี้แข่งขันได้และบางทีดีกว่าในบางชุดข้อมูล — แต่ มันกินข้อมูลและ compute หนักกว่ามาก และ **ไม่ใช่** กระสุนเงิน

ขั้นที่ 3 — feature ดี > โมเดลลึก (หัวใจของ Part นี้)

นี่คือบทเรียนที่แพงที่สุดและคนข้ามบ่อยที่สุด: โมเดลลึกที่ป้อนข้อมูลดิบ มักแพ้โมเดลตื้นที่ป้อน feature ที่ออกแบบดี เพราะ OFI, imbalance, microprice ที่คุณเรียนมาทั้งเล่มคือ "ความรู้ microstructure" ที่ย่อยมาให้โมเดลแล้ว — network ไม่ต้องเสียพลังไป "ค้นพบใหม่" จากศูนย์



ภาพ B.3 · feature ดี > โมเดลลึก — ความรู้ microstructure ที่ย่อยมาแล้วมีค่ากว่า depth

สูตรหลัก

```
// อินพุต: ลำดับ snapshot กระดาน T ช่วงเวลา × 4L ฟีเจอร์ต่อชั้น
 $X \in \mathbb{R}^{T \times 4L}$  (p_bid, v_bid, p_ask, v_ask ของ L ชั้น)

// label: ทิศ mid ในอนาคต แบ่ง 3 class
 $y \in \{\text{ขึ้น, นิ่ง, ลง}\}$  (ใช้ threshold บนการเปลี่ยนของ mid)

// objective: ลด cross-entropy ของ softmax
min CrossEntropy( softmax(f(X)) , y )
    f = CNN+LSTM (DeepLOB) หรือ Transformer (TLOB/LiT)
```

⚠ ความจริงรายย่อย — กีบดักของ ML กับกระดาน

(1) หุ่น architecture แทน feature/ข้อมูล — เพิ่มเลเยอร์ไม่ช่วย ถ้า feature ห่วยหรือข้อมูลน้อย เริ่มที่ feature engineering ด้วยความรู้ microstructure ก่อนเสมอ **(2) ไม่เกิน overfit** — LOB มี noise สูงและ regime เปลี่ยน โมเดลที่ "แม่นยำในอดีต" มักพังกับข้อมูลใหม่ ต้องแยก train/validation/test ตามเวลาอย่างเคร่งครัด และระวัง look-ahead bias **(3) คิดว่า ML แทนความเข้าใจได้** — ผิด ML ขยายความเข้าใจที่คุณมี ถ้าคุณไม่เข้าใจ OFI/imbalance คุณจะ debug โมเดลที่พังไม่เป็น **ML คือปลายทาง ไม่ใช่จุดเริ่ม**

งานวิจัยรองรับ

DeepLOB (Zhang et al. 2018, arXiv 1808.03668) เป็นงานวางมาตรฐาน CNN+LSTM อ่าน LOB ทำนายทิศ mid ส่วน **TLOB (arXiv 2502.15757)** และ **LiT** นำ Transformer/attention มาใช้ ส่วนงานคริปโตโดยตรง **Wang (2025, arXiv 2506.05764)** "Exploring Microstructural Dynamics in Cryptocurrency Limit Order Books" benchmark โมเดลตั้งแต่ logistic regression/XGBoost จนถึง DeepLOB/Conv1D-LSTM บนข้อมูล BTC/USDT ของ Bybit แล้วได้ข้อสรุปสำคัญ (ตรงซื่อตรง): **"Better Inputs Matter More Than Stacking Another Hidden Layer"** — feature/การเตรียมข้อมูลที่ดีให้ผลมากกว่าการต่อ layer ลึกขึ้น เป็นบทเรียนตรงสำหรับรายย่อยที่อยากเริ่มทำโมเดลเอง · *ข้อควรระวัง*: ผลความแม่นยำในเปเปอร์มัก backtest บนข้อมูลเฉพาะตลาด/ช่วงเวลา — อย่าคาดหวังตัวเลขเดียวกันกับคริปโตที่ regime เปลี่ยนเร็ว และต้อง validate ด้วยข้อมูลของคุณเอง

cross-ref — forecasting power สูง ≠ สัญญาณเทรดได้จริง

Briola et al. (2024/25) "Deep Limit Order Book Forecasting: a microstructural guide" เป็นบทสรุปที่ตอกย้ำ message ของ Part นี้โดยตรง: โมเดล deep learning ทำนายทิศ LOB ได้ **"แม่นยำ" ในเชิงสถิติ** (forecasting power สูง) — **แต่นั้นไม่ได้แปลว่าเทรดแล้วกำไรจริง** เพราะพอเอาไปวัดเป็นสัญญาณเทรด ต้องเจอ **ต้นทุน (fee + spread + slippage), latency, และ edge ที่บางจนต้นทุนกลบ** — แบบเดียวกับ "ทำนายถูกแต่ขาดทุน" ของ OFI stat-arb ใน Part 13 บทเรียน: อย่าหลงตัวเลข accuracy/F1 ในเปเปอร์ ให้ประเมินทุกโมเดลด้วย **P&L หลังหักต้นทุนจริง** เสมอ — forecasting ≠ tradable signal

เชื่อมโยงเล่มอื่น & ปิดซีรีส์

Part โบนัสมัดทั้งซีรีส์เข้าด้วยกัน: **feature** ที่ป้อนโมเดลคือ OFI (Part 7), OBI (Part 5), microprice (Part 11), VPIN (Part 8) ที่เรียนมาทั้งหมด ในเชิง **math** นี้คือ softmax/cross-entropy, logistic regression, และ optimization ที่ต่อยอดจากบท regression/PCA โดยตรง บทเรียนสุดท้ายของทั้งเล่ม "อ่านกระดาน" คือ: **order book เป็นเครื่องมือยกระดับกลยุทธ์เดิม ไม่ใช่ระบบเบ็ดเสร็จ** — และ ML ก็เป็นเครื่องมือยกระดับ "ความเข้าใจกระดาน" ของคุณ ไม่ใช่ตัวแทนของมัน

🎯 กับเคสของเรา

คำถามสุดท้ายของเคส: ให้ ML ทำนายจังหวะเข้า long BTC \$5,000 แทนเราได้ไหม? **ได้ — แต่ไม่ใช่จุดเริ่ม** feature ที่จะป้อนโมเดลก็คือ OBI/OFI/VPIN/microprice/effective price ที่เราใช้ตัดสินใจมาทั้งเคส ML แค่ "ขยาย" สายตาที่ฝึกมาแล้ว ไม่ได้แทนมัน และต่อให้โมเดลทำนายทิศ mid แม่น ก็ยังต้องผ่านด่านเดิม — **edge ต้องชนะ cost จริง** ก่อนถึงจะเข้าไม่ได้กำไร ดังนั้นสำหรับเคสนี้ เครื่องมือ 14 Part ที่ผ่านมามีสิ่งที่ลงมือทำได้เลย ML คือก้าวถัดไปเมื่อรากฐานแน่นแล้ว

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

เก็บข้อมูล L2 + trade ของ BTC/USDT สัก 2–3 ชั่วโมง สร้าง feature **OFI** (จาก Part 7) แล้วเทรน **logistic regression** ทำนายทิศ mid ถัดไป 3 class เทียบกับ baseline ง่ายๆ คือ "เดาตาม $\text{sign}(\text{OFI})$ " ดูว่าโมเดลที่เรียนรู้ค่าน้ำหนักชนะการเดาตรง ๆ ไหม จากนั้น (ถ้าอยากท้าทาย) ลองป้อนข้อมูลกระดานดิบเข้า network เล็ก ๆ แล้วเทียบ — คุณจะสัมผัสได้ด้วยตัวเองว่า "feature ดี > โมเดลเล็ก" จริงแค่ไหน

ส่งต่อ → ครบทั้ง 14 Part + โบนัสแล้ว — ขั้นตอนต่อไปคือเอาทุกเครื่องมือมาร้อยเป็น "การอ่านกระดานจริง 1 รอบ" กับเคส long BTC \$5,000 ตั้งแต่เปิดจอ → ประเมิน → เข้า/ออก → คุมเสี่ยง ที่บท **Capstone**

— จบซีรีส์ "อ่านกระดาน" · ขอให้อ่านกระดานออก และเทรดอย่างมีต้นทุนที่รู้จริง —