

อ่านกระดาน Reading the Book

ภาคทบทวน: สถิติพื้นฐานสำหรับ Order Flow

Order Flow & Microstructure สำหรับรายย่อย · ภาคเครื่องมือ

mean · median · mode · variance · SD · z-score · t-score · normal & t-distribution

แนะนำอ่านก่อน Part 5–11 ถ้าสถิติยังไม่แน่น



ภาคทบทวน — สถิติพื้นฐานที่ Order Flow ต้องใช้

📌 อ่านจบภาคนี้คุณจะได้

- สรุป "กองตัวเลข" จากกระดาน (ขนาดออเดอร์ / spread / OFI) ด้วย **ค่ากลาง** (mean, median, mode) ได้ถูกต้อง
- วัด "ความผันผวน/ความกระจาย" ด้วย **variance & SD (σ)** — ตัวเดียวกับ σ ใน Avellaneda-Stoikov
- เทียบว่าค่าตอนนี้ "ผิดปกติแค่ไหน" ด้วย **z-score** — รากฐานของการ normalize OFI
- เข้าใจ **normal vs t-distribution** และรู้ว่าทำไม "คริปโตทางหนา" จึงสำคัญต่อการประเมินความเสี่ยง

ทำไม order flow trader ต้องรู้สถิติ

กระดานคือ "กระแสตัวเลข" มหาศาล — trade หลายพันไม้ต่อนาที, ขนาดออเดอร์, spread, OFI ที่แกว่งตลอด สถิติคือเครื่องมือ **3 อย่าง**: (1) **สรุป** กองตัวเลขเป็นค่าเดียว, (2) **วัดความกระจาย** ว่าเหวี่ยงแค่ไหน, (3) **เทียบ** ว่าค่าที่เห็นตอนนี้ "ปกติหรือผิดปกติ" ทุกอย่างในเล่มนี้ (OFI, VPIN, Kyle's λ , A-S) ตั้งอยู่บน 4 กลุ่มนี้

1. ค่ากลาง — Mean / Median / Mode

Mean (μ หรือ $\bar{x}$) = $(\sum x_i) / n$ ← ผลรวมหารจำนวน "ค่าเฉลี่ย"

($\sum$ = "บวกค่าทุกตัวเข้าด้วยกัน", n = จำนวนข้อมูล)

Median = ค่าตรงกลางเมื่อเรียงน้อย→มาก (ทนต่อค่าสุดโต่ง)


Mode = ค่าที่พบ "บ่อยที่สุด"

ตัวอย่างขนาด market order 5 ไม้ (BTC): 0.10, 0.15, 0.10, 0.20, 5.00 (ไม้สุดท้ายคือวาฟ)

Mean = $(0.10+0.15+0.10+0.20+5.00)/5 = 5.55/5 = 1.11 \text{ BTC}$ ← ถูกวาฟดึงสูงเกินจริง

Median = เรียง [0.10, 0.10, 0.15, 0.20, 5.00] → ตัวกลาง = **0.15 BTC** ← สะท้อน "ไม้ทั่วไป" ดีกว่า

Mode = 0.10 (พบ 2 ครั้ง) ← ขนาดยอดนิยม (มักเป็นเลขกลม)



ภาพ S.1 · ข้อมูลเบ้ขวา (right-skewed) — วาฟไม่ก็ไม่ได้ Mean ออกไปขวา

📌 ใช้ใน order flow ยังไง

ขนาดออเดอร์/ปริมาณในคริปโต **เบ้ขวาเสมอ** (วาฟทำให้มีหางขวายาว) → ใช้ **median** อธิบาย "ไม้ทั่วไป" ดีกว่า mean ส่วน **mode** ช่วยจับ "เลขกลมยอดนิยม" (0.1, 0.5, 1 BTC) ที่มักเป็นจุดวางออเดอร์ของคน — ส่วน **mean** เหมาะกับค่าที่สมมาตร เช่น mid-price ระยะสั้น (microprice = mean ถ่วงน้ำหนัก!)

2. ความกระจาย — Variance & Standard Deviation (σ)

ค่ากลางบอก "อยู่ตรงไหน" แต่ไม่บอก "เหวี่ยงแค่ไหน" — นั่นคือหน้าที่ของ variance (σ^2) และ SD (σ)

Variance (population) $\sigma^2 = \sum (x_i - \mu)^2 / N$

Variance (sample) $s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$ ← ใช้ $n-1$ เมื่อเป็น "ตัวอย่าง"

Standard Deviation $\sigma = \sqrt{\text{variance}}$ ← หน่วยเดียวกับข้อมูล

ประชากร (population) = มีข้อมูลครบทุกตัว → หารด้วย N · **ตัวอย่าง (sample)** = สุ่มมาแค่บางส่วน → หารด้วย $n-1$ (ชดเชยไม่ให้เป็นความกระจายต่ำเกินไป) ในทางปฏิบัติเรามักมีแค่ "ตัวอย่าง" จึงใช้ $n-1$

SD ใหญ่ = ข้อมูลเหวี่ยงมาก (ผันผวนสูง); SD เล็ก = เกาะกลุ่มใกล้ค่าเฉลี่ย

🔗 σ ตัวนี้คือตัวเดียวกับในเล่ม

σ (volatility) คือหัวใจของ **Avellaneda-Stoikov** (Part 10): reservation price $r = s - q \cdot \gamma \cdot \sigma^2 \cdot (T-t)$ โดย q = inventory ที่ถืออยู่, γ = ระดับความกลัวความเสี่ยง — ยิ่งราคา SD สูง (ผันผวน) MM ยิ่งกาง spread กว้าง · σ ยังโผล่เป็นตัวหารใน z-score (หวัชข้อถัดไป)

3. Z-score — "ค่านี้ผิดปกติกี่ SD"

z-score แปลงค่าดิบให้เป็น "ห่างจากค่าเฉลี่ยกี่เท่าของ SD" — ทำให้เทียบข้ามสเกล/ข้ามเหรียญได้

$$z = (x - \mu) / \sigma \quad z=0 \text{ คือค่าเฉลี่ยพอดี} \cdot z=+2 \text{ คือสูงกว่าเฉลี่ย 2 SD (หายาก)}$$

ตัวอย่าง: spread ปกติของ BTC เฉลี่ย $\mu=6$, $\sigma=1.5$ ตอนนี้ spread พุ่งเป็น 12


$$z = (12 - 6) / 1.5 = +4.0 \rightarrow \text{สูงกว่าค่าเฉลี่ยจน percentile} > 99.99\% \text{ (one-tailed)} = \text{ผิดปกติมาก} = \text{สัญญาณข่าว/สภาพคล่องหด}$$

✓ z-score คือหัวใจของการ "normalize"

ใน Part 7 เรา **stationarize OFI** ก่อน regression — วิธีหนึ่งคือทำ z-score (หักค่าเฉลี่ยทิ้ง หารด้วย SD กลิ้ง) เพื่อให้ OFI เทียบข้ามช่วงเวลา/เหรียญได้ · ใช้จับ "OBI/spread/CVD ผิดปกติ" ด้วย (เช่น $z > 2$ = เหตุการณ์หายาก ควรสนใจ)

4. Normal Distribution — เส้นโค้งระฆัง & กฎ 68-95-99.7

การแจกแจงปกติคือเส้นโค้งระฆังสมมาตรรอบ μ ภายใต้ normal: ~68% ของข้อมูลอยู่ใน $\pm 1\sigma$, ~95% ใน $\pm 2\sigma$, ~99.7% ใน $\pm 3\sigma$




ภาพ S.2 · เส้นโค้งปกติ + กฎ 68-95-99.7 — $z=+2$ ตรงกับขอบ $\pm 2\sigma$ (ครอบคลุม 95%)

📌 ใช้ใน order flow ยังไง

VPIN (Part 8) ใช้ **normal CDF (Φ)** ใน bulk volume classification: $V_{\text{buy}} = V \cdot \Phi(\Delta P / \sigma)$ — Φ (CDF) = พื้นที่ใต้โค้งสะสม = ความน่าจะเป็นที่จะได้ค่าน้อยกว่าค่านี้ จึงแปลงการเปลี่ยนราคาเป็น "สัดส่วนที่น่าจะเป็นฝั่งซื้อ" · **หมายเหตุ:** σ ในสูตรนี้คือ SD ของ "การเปลี่ยนราคาต่อ bucket" — คนละตัวกับ σ volatility ของ A-S

5. T-distribution & T-score — โลกจริง "หางหนา"

t-distribution หน้าตาเหมือนระฆัง แต่ **หางหนากว่า normal** (peak ต่ำกว่า แลกกกับปลายสองข้างที่หนากว่า — พื้นที่ใต้กราฟยังรวมได้ 1 เท่ากัน) ใช้เมื่อ **ไม่รู้ σ จริง** (ต้องประมาณจากข้อมูล) หรือ **กลุ่มตัวอย่างเล็ก** ยิ่ง degrees of freedom ($df = n-1$) มาก t ยิ่งเข้าใกล้ normal



ภาพ S.3 · t-distribution หางหนากว่า normal — ตรงกับพฤติกรรมราคาคริปโต

T-score ใช้ทดสอบว่า "ค่าเฉลี่ยตัวอย่างต่างจากค่าอ้างอิงอย่างมีนัยหรือเป็นแค่บังเอิญ":

$$t = (\bar{x} - \mu_0) / (s / \sqrt{n}) \quad df = n - 1$$

$|t|$ มาก (เช่น $> \sim 2$) → ต่างอย่างมีนัยสำคัญ (ไม่น่าใช่บังเอิญ)

📌 ใช้ใน order flow ยังไง

ตอน regress $\Delta P = \lambda \cdot OFI$ (Kyle's λ , Part 7) ค่า **t-stat ของ λ** บอกว่าความสัมพันธ์ "มีจริง" หรือ บังเอิญ (มักดู $|t| > 2$) — ในงาน order flow ข้อมูล n มักใหญ่มาก (หลายพันจุด) ที่ยังใช้ t เพราะ **"ไม่รู้ σ จริง ต้องประมาณจาก residual"** ไม่ใช่เพราะ n เล็ก · และ **fat tails** คือเหตุผลว่าทำไมต้องระวัง: คริปโตมีวันที่ราคากระชาก $\pm 10\%$ ซึ่ง normal บอกว่า "แทบเป็นไปไม่ได้" แต่เกิดจริงบ่อย — เชื่อมโดยตรงกับ VPIN/toxicity (Part 8) และ inventory risk ของ MM (Part 9–11)

⚠️ กับดักมือใหม่

- สมมติทุกอย่างเป็น **normal**: ราคาคริปโตทางหนา การใช้ normal จะ **ประเมิน tail risk ต่ำเกินไป** — เหตุการณ์ "3σ" เกิดบ่อยกว่าที่คิดมาก
- ใช้ **mean** กับข้อมูลเบ้: วาฟไม่ก็ไม้ทำให้ mean ขนาดออเดอร์เพี้ยน → ใช้ **median**
- **z-score / t สูง ≠ กำไร**: มันบอกว่า "ผิดปกติ/มีนัยทางสถิติ" ไม่ได้บอกทิศทางหรือว่าหักต้นทุนแล้วคุ้ม

สรุป — สถิติแต่ละตัวใช้ใน Part ไหน

สถิติ	บอกอะไร	ใช้ใน Part
Mean (ถ่วงน้ำหนัก)	ค่ากลาง / microprice	0, 11
Median / Mode	ขนาดออเดอร์ "ทั่วไป" / เลขยอดนิยม	2, 6
Variance / SD (σ)	ความผันผวน	3 (spread), 10 (A-S)
Z-score	normalize / จับค่าผิดปกติ	7 (OFI), 4 (spread/OBI)
Normal + CDF (Φ)	ความน่าจะเป็น / bulk classification	8 (VPIN)
t-score / t-dist	นัยสำคัญ regression / fat tails	7 (λ), 8, 9–11 (tail risk)

🔗 เชื่อมโยงเล่มอื่น

ภาคนี้คือเวอร์ชันย่อที่ปรับให้เข้ากับ order flow — คำว่า "regression" ที่โผล่ในหัวข้อ t ($\Delta P = \lambda \cdot \text{OFI}$) คือ **linear regression / OLS** ซึ่งมีพื้นฐานเต็ม (พร้อมการพิสูจน์ + ตัวอย่าง) ในซีรีส์ **math (คณิตศาสตร์สำหรับ Options)** ที่ z-score/normal ใช้ร่วมกันได้ทันที

🔧 แบบฝึก (ทำได้ด้วยข้อมูลคริปโตฟรี)

1. ดึง trade 200 ไม้ล่าสุดของ BTC/USDT (aggTrade) เก็บ "ขนาด" — คำนวณ mean, median, mode เทียบกัน → ดูว่าวาฟดึง mean ห่างจาก median แค่ไหน (เบ้ขวา)
2. เก็บ spread ทุก 1 วินาที 5 นาที — คำนวณ μ, σ แล้วหา z-score ของ spread ล่าสุด ถ้า $z > 2$ แปลว่าผิดปกติ
3. เก็บผลตอบแทนราย 1 นาที 1 วัน — พล็อต histogram เทียบเส้น normal ดูว่า "ทางหนา" จริงไหม (มีไม้สุดโต่งเกินที่ normal คาด)

มีเครื่องมือสถิติครบแล้ว → กลับไปลุย Part 5 (OBI) ถึง Part 11 (Market Making) ได้เต็มที่ →