

อ่านกระดาน

Reading the Book

Part 10: MM-2 Optimal — วาง quote ตรงไหนดีที่สุด

Order Flow & Microstructure สำหรับรายย่อย · องค์กร IV Market Making

Avellaneda-Stoikov: reservation price, optimal spread, adverse selection, value function → ยุค

RL



Part 10 — MM-2 Optimal: Avellaneda-Stoikov

📌 อ่านจบ Part นี้คุณจะได้

- เข้าใจ **reservation price** = "ราคายุติธรรมในใจพ่อค้า" ที่ขยับตามสต็อก — หัวใจของ Avellaneda-Stoikov
- อ่านสูตร $r = s - q \cdot y \cdot \sigma^2 \cdot (T-t)$ ออกว่าแต่ละตัวแปรหมายถึงอะไรและทำไมมันสมเหตุสมผล
- เข้าใจ **optimal spread** ว่ามาจากการชั่งน้ำหนักระหว่างความเสี่ยง inventory กับโอกาส fill
- เห็นชัดว่า **naive MM (quote สมมาตรไม่ skew)** ตายเพราะ **adverse selection** ขณะ optimal รอด — ผ่านกราฟ P&L
- เห็นภาพ **เส้นทางวิวัฒนาการ** จาก Ho-Stoll → A-S → Guéant → reinforcement learning


ราคายุติธรรมในใจพ่อค้าขายร่ม

นึกถึงพ่อค้าขายร่มข้างถนน เช้านี้เขามีร่ม 50 คัน "ราคายุติธรรมในใจ" ของเขา คือ 100 บาท เขาจึงตั้งรับซื้อ 95 ขาย 105 — สมมาตรรอบ 100

ผ่านไปครึ่งวัน ขายดีมากจนเหลือร่มแค่ 5 คัน ฝนกำลังจะตก เขากลับของหมดก่อนปิดร้าน — "ราคายุติธรรมในใจ" ของเขา **ขยับขึ้นเป็น 110** โดยอัตโนมัติ เขาไม่อยากขายถูกแล้ว เขาตั้งขาย 115 รับซื้อ 105 (อยากซื้อร่มเข้าสต็อกคืน)

กลับกัน ถ้าเหลือร่ม **200 คัน** และใกล้ฟ้าจะเปิด เขากลับของค้าง "ราคาในใจ" จะ **ตกลงเหลือ 90** เขายอมขายถูกเพื่อระบายสต็อก

"ราคายุติธรรมในใจที่ขยับตามสต็อก" นี้แหละคือ **reservation price** — มันไม่ใช่ราคารตลาด (mid) แต่เป็นราคาที่พ่อค้าใช้เป็นจุดศูนย์กลางในการตั้ง quote ของตัวเอง ยิ่งถือเยอะ ยิ่งตั้งให้ต่ำกว่า mid เพื่อเร่งระบาย



ภาพ 10.1 · reservation price ถูกดึงออกจาก mid ตามทิศและขนาดของ inventory

สูตร reservation price

Avellaneda & Stoikov (2008) เขียน "ราคาในใจ" นี้เป็นสมการ:

$$r = s - q \cdot \gamma \cdot \sigma^2 \cdot (T - t)$$

r = reservation price (ราคายุติธรรมในใจ MM)

s = mid price ปัจจุบัน

q = inventory สุทธิ (long = บวก, short = ลบ)

γ = ความกลัวความเสี่ยง (risk aversion) — γ สูง = ชี้กแล้ว

σ^2 = ความผันผวน (variance ของราคา)

$(T - t)$ = เวลาที่เหลือก่อนปิดรอบ — ใกล้ปิดยิ่งใกล้ inventory น้อยลง

อ่านสูตรแบบไม่ต้องท่อง — แค่ว่า **"ตัวลบ" $q \cdot \gamma \cdot \sigma^2 \cdot (T-t)$ ดึง r ออกจาก mid เท่าไหร่:**

- **q บวกมาก (long เยอะ)** → ตัวลบใหญ่ → r ต่ำกว่า mid มาก → quote เอียงลง → แรงขายระบาย (ตรงกับพ่อค้าร่มที่ของล้น)
- **γ สูง (ชี้กแล้ว)** → ตัวลบใหญ่ → ยิ่งใกล้ยิ่งดึง r หนีจาก mid เร็ว
- **σ^2 สูง (ผันผวน)** → ตัวลบใหญ่ → ยิ่งใกล้ยิ่งดึง r หนีจาก mid เร็ว
- **$(T-t)$ เล็ก (ใกล้ปิด)** → ตัวลบเล็ก → ใกล้หมดเวลาแล้ว ถือ inventory ไม่กี่วินาทีไม่น่ากลัว → r เข้าใกล้ mid อีกครั้ง

Optimal spread: กว้างเท่าไรถึงดี

มี r แล้วต้องตั้ง bid/ask ห่างจาก r เท่าไหร่? A-S ให้สูตร **optimal spread** ที่ซึ่งน้ำหนัก 2 แรง: ความเสี่ยง inventory (อยากกว้างไว้ปลอดภัย) กับ ความถี่ fill (อยากแคบไว้ได้เทรดบ่อย)

$$\delta_{\text{total}} = \gamma \cdot \sigma^2 \cdot (T - t) + (2/\gamma) \cdot \ln(1 + \gamma/k)$$


ก้อนแรก = ค่าชดเชยความเสี่ยง inventory (เหมือนใน r)

ก้อนสอง = ค่าชดเชยจาก order arrival - k คือความไวของ fill ต่อระยะ quote

$$\text{bid} = r - \delta_{\text{total}}/2$$

$$\text{ask} = r + \delta_{\text{total}}/2$$

จุดสำคัญที่มีมือใหม่มักพลาด: **bid/ask ของ A-S วางสมมาตรรอบ r ไม่ใช่รอบ mid** เพราะ r เอียงไปตาม inventory อยู่แล้ว ผลลัพธ์คือ quote สองฝั่งจริง ๆ ไม่สมมาตรรอบ mid — ฝั่งที่อยากระบายจะอยู่ใกล้ mid กว่า




ภาพ 10.1b · bid/ask สมมาตรรอบ r (ที่ถูกดึงต่ำกว่า mid เพราะ long)

ทำไม naive MM ถึงตาย — adverse selection

Naive MM = ตั้ง bid/ask สมมาตรรอบ mid เสมอ ไม่สนใจ inventory พังดูเป็นกลางดี แต่มันตายเพราะ 2 เหตุผลที่ทับกัน:

1. **Inventory ร่วงหนีไม่หยุด** — ไม่มีกลไก skew ดึงกลับ ตลาดเทรดเดียวจะอัด inventory ฝั่งเดียวจนพอร์ตระเบิด
2. **Adverse selection** — คนที่มา fill quote ของเรา "บ่อยกว่า" คือคนที่ถูกข้าง เวลาราคากำลังจะขึ้น คนแห่มากิน ask ของเรา (เราขายถูกให้เขา) เวลาราคากำลังจะลง คนแห่มาชน bid ของเรา (เรารับแพง) — **MM มักโดน fill ในจังหวะที่ผิดเสมอ**

Optimal MM สู้ adverse selection ด้วยการ skew (ผ่าน r): พอ inventory เริ่มเอียง r จะดึง quote ให้ฝั่งที่เสี่ยงอยู่ไกล mid ขึ้น ลดโอกาสโดน fill ซ้ำเติม นี่คือเหตุผลที่กราฟ P&L ต่างกันราวฟ้ากับเหว



ภาพ 10.2 · P&L optimal vs naive — naive ดูดีช่วงแรกแล้วระเบิดเพราะ adverse selection + inventory

⚠️ กับดักมือใหม่ — "เป็นกลางรอบ mid = ปลอดภัยสุด"

หลายคนคิดว่าการตั้ง quote สมมาตรรอบ mid คือ "ไม่เลือกข้าง = ปลอดภัย" — **ตรงกันข้าม** มันคือสูตรของการโดน adverse selection เต็ม ๆ เพราะคุณปล่อยให้ตลาดเลือกข้างให้คุณ (คนถูกข้างมา fill คุณก่อนเสมอ) ความปลอดภัยจริงมาจากการ **ยอมเอียง quote ตาม inventory** เพื่อบังคับให้สติกกลับเข้าศูนย์ — γ ไม่ใช่ "ความขลาด" แต่คือ "วินัยคุมความเสี่ยง" ที่ใส่เป็นตัวเลขในสมการ

Value function: ที่มาของสูตร (มองผ่าน ๆ พอ)

สูตร r และ δ ไม่ได้เดาเอา — มันมาจากการแก้ปัญหา optimization ที่ถามว่า "ตั้ง quote ยังไงให้ **มูลค่าคาดหวังของความมั่งคั่งสุดท้าย** สูงสุด โดยหักโทษความเสี่ยง" คณิตศาสตร์เบื้องหลังคือ *value function* $u(s, q, t)$ ที่แก้ผ่านสมการ HJB (Hamilton-Jacobi-Bellman)

แนวคิด (ไม่ต้องแก้เอง):

$$u(s, q, t) = \max E[-\exp(-\gamma \cdot \text{wealth สุดท้าย})]$$


$$\text{wealth สุดท้าย} = \text{เงินสด} + q \cdot (\text{ราคาเลิกกิจการ})$$

แก้ HJB → ได้ r และ δ_{total} ข้างต้นเป็นคำตอบ

ไม่ต้องแก้สมการเองได้ ขอแค่จับ **สัญชาตญาณ**: u ลงโทษ q ที่ใหญ่ (ผ่าน $-\exp(-\gamma \cdot \dots)$) ดังนั้นคำตอบที่ optimal จึงต้อง "พยายามดึง q กลับศูนย์เสมอ" — ซึ่งออกมาเป็นกลไก skew ที่เราเห็นใน r พอดี

จาก A-S สู่มุม Reinforcement Learning

A-S สวยแต่ตั้งอยู่บนสมมติฐานที่สวยเกินจริง (ราคาเป็น Brownian, order arrival เป็น Poisson คงที่, ไม่มี market impact) โลกจริงไม่เป็นแบบนั้น เลยมีการต่อยอดเรื่อยมา:



ภาพ 10.3 · วิวัฒนาการ inventory model → A-S → closed-form → RL

ยุค **Reinforcement Learning** เปลี่ยนจาก "แก้สมการหา quote" เป็น "ให้เอเจนต์ลองตั้ง quote ในสภาพแวดล้อมจำลองล้านครั้งแล้วเรียนรู้นโยบายเอง" โดยมีฟังก์ชันรางวัลที่ลงโทษ inventory คล้ายเดิม:

RL objective: $\max E[\sum (PnL_t - \lambda \cdot q_t^2)]$

PnL_t = กำไรแต่ละก้าว, $\lambda \cdot q_t^2$ = โทษการถือ inventory (แทน y ใน A-S)

เอเจนต์เรียน policy $\pi(\text{state}) \rightarrow \text{action}$ (ตั้ง bid/ask offset) เอง

state = [inventory, spread, OBI, OFI, volatility, ...]

📄 งานวิจัยรองรับ (A-S → RL)

Avellaneda & Stoikov (2008) คือต้นฉบับของ reservation price + optimal spread ต่อยอดจาก **Ho & Stoll (1981)** · **Guéant-Lehalle-Fernandez-Tapia (2013)** ให้คำตอบ closed-form ที่จัดการ inventory limit ได้ดีขึ้น · ยุคหลังมีงาน RL เช่น *Market Making with Deep RL from LOB* (arXiv 2305.15821) และ *Resolving Latency & Inventory Risk* (arXiv 2505.12465) ที่ให้เอเจนต์เรียน quoting policy จากข้อมูล LOB จริง — แต่ทั้งหมดยังตั้งบนหลักเดียวกัน: ลงโทษ inventory เพื่อสู้ adverse selection

🔗 เชื่อมโยงเล่มอื่น

สูตร A-S คือการ **optimize ภายใต้ความไม่แน่นอน** — ใช้เครื่องมือ calculus/optimization และแนวคิด variance/risk จากเล่ม **math** โดยตรง (HJB คือ optimization แบบ dynamic) ส่วนการมองกำไรหลังหักโทษความเสี่ยง ($PnL - \lambda q^2$) คือ **risk-adjusted payoff** ที่ตรงกับหัวใจของ **Payoff Mastery (pm)** — เทรตที่ดีไม่ใช่กำไรสูงสุด แต่คือกำไรต่อหน่วยความเสี่ยงที่ดีที่สุด

🔧 แบบฝึก (เขียนโค้ดสั้น ๆ ได้)

เขียนฟังก์ชันคำนวณ reservation price และ quote แล้วทดลองเล่นตัวแปร:

```
def quote(s, q, gamma, sigma, T_minus_t, kappa):
    r = s - q * gamma * sigma**2 * T_minus_t
    delta = gamma*sigma**2*T_minus_t +
    (2/gamma)*math.log(1+gamma/kappa)
    bid = r - delta/2
    ask = r + delta/2
    return r, bid, ask
```

1. เรียกด้วย $s=60000$, $q=0$, แล้วเทียบ $q=+10$ และ $q=-10$ — สังเกตว่า r เลื่อนไปทางไหน และ quote ผังไหนเข้าใกล้ mid
2. เพิ่ม γ จาก $0.1 \rightarrow 1.0$ ดูว่า quote กว้างขึ้นหรือแคบลง และ r ห่างจาก mid เร็วขึ้นไหม
3. ลด $(T-t)$ ลงเรื่อย ๆ จนใกล้ 0 ดูว่า r เข้าใกล้ mid อีกครั้งไหม (ใกล้ปิดรอบ)
4. เขียน loop จำลอง fill ตาม Poisson เทียบ P&L ของ optimal (มี skew) กับ naive (สมมาตรรอบ mid) บนชุดราคาเทรดเดี่ยว — ดูว่า naive ระเบิดจริงไหม

ต่อ Part 11: MM-3 ลงมือจริงคริปโต — จาก quote สู่ระบบรันได้ + กับดัก backtest →