

Practical Quant: Stat Arb ที่ใช้ได้จริง

Part I — บันได β : หา hedge ratio ยังไง (โลกที่ละคู่)

β (hedge ratio) คือหัวใจของทุก spread — Part นี้ค่อย ๆ ไต่บันได 4 ขั้นจาก OLS $\rightarrow$ TLS $\rightarrow$ Rolling $\rightarrow$ Kalman พร้อมตอบคำถามที่คนพลาดบ่อยสุด: **ทำไม OLS ที่ทุกคนใช้ ถึงใช้ได้แค่บางสถานการณ์** · ทั้งบทใช้ตัวอย่างเดียว (Coke–Pepsi) เดินไปด้วยกัน

 เส้นทางอ่าน

● **มือใหม่:** อ่านทุกกล่อง 🧑 (อ่านเป็นภาษาคน) + 📄 (ตัวอย่าง) + 🖋️ (ลองทำเอง) เรียงไป — ข้ามกล่องสูตร . fm ก่อนได้ · ● **มีพื้น:** เน้น §1.3 (super-consistency) + §1.5 (TLS พังเมื่อไร) · **เริ่มต้น:** §1.3 คือจุดพลิกความเข้าใจ

เริ่มจากคำถามเดียว: ถือขาไหนเท่าไร?

อ่านเป็นภาษาคนก่อน — hedge ratio คืออะไร

ลองนึกถึงการผสมเครื่องดื่ม: ถ้าจะให้รสคงที่ ทุกครั้งต้องผสม "น้ำเชื่อม 1 ส่วน ต่อ น้ำ 3 ส่วน" — อัตราส่วนนั้นสำคัญ ผสมผิดสัดส่วน รสเพี้ยนทันที

Stat arb ก็เหมือนกัน: เราถือหุ้น 2 ตัวสวนทางกัน (ซื้อตัวหนึ่ง ขายชอร์ตอีกตัว) เพื่อให้เหลือแค่ "ส่วนต่าง" (spread) ที่แกว่งไปมารอบค่าเฉลี่ย · **β คืออัตราส่วนผสมนั้น** — ซื้อ A 1 หุ้น ต้องชอร์ต B ก็หุ้น

ตลอด Part นี้เราจะใช้คู่ตัวอย่างเด่นเป็นตัวอย่าง — **Coca-Cola (KO)** กับ **PepsiCo (PEP)** สองบริษัทน้ำอัดลมที่ธุรกิจคล้ายกัน ราคา มักขยับไปด้วยกัน · ตัวอย่างคลาสสิกที่เข้าใจง่าย (ตัวเลขข้างหน้าเป็น *สมมติ* เพื่อสอน ไม่ใช่ราคาจริง)

$$\text{spread} = \text{ราคา_KO} - \beta \times \text{ราคา_PEP}$$

ถ้า $\beta = 1.3 \rightarrow$ ซื้อ KO 1 หุ้น ต้องชอร์ต PEP 1.3 หุ้น จึงจะได้ spread ที่ "สะอาด"

คำถามคือ — **เลข 1.3 นั้นมาจากไหน?** นั่นคือทั้งหมดของ Part นี้ และมันมีหลายวิธี ไล่เป็นบันได แต่ละขั้นแก้จุดอ่อนของขั้นก่อน:

ขั้น 0 : OLS β คงที่ ประมาณครั้งเดียว (ง่ายสุด · เริ่มที่นี่)

ขั้น 1 : TLS / PCA แก้ปัญหา "ทั้งสองขามี noise"

ขั้น 2 : Rolling OLS β เดินตามเวลาแบบหน้าต่างเลื่อน

ขั้น 3 : Kalman β เดินแบบจำอดีต + optimal ($\rightarrow$ เจาะลึก Part IV)

🚀 ทบทวนพื้นฐาน — 4 คำที่ต้องรู้จักก่อนไปต่อ

ก่อนลงรายละเอียดทีละขั้น นี่คือสรุปสั้น ๆ ว่าแต่ละคำหมายถึงอะไร — ถ้าอ่านรอบแรกแล้วงง กลับมาที่กล่องนี้ได้เสมอ

OLS (Ordinary Least Squares)

วิธีลากเส้นตรงผ่านกลุ่มจุดข้อมูล โดยให้เส้นนั้น "ใกล้จุดทุกจุดที่สุด" วัดความใกล้แบบ**แนวตั้งเท่านั้น** (สมมติว่าแกนนอนไม่มีความคลาดเคลื่อน) — ความชันของเส้นคือ β · เป็นวิธีพื้นฐานที่สุด เร็วที่สุด แต่มีสมมติฐานที่บางครั้งไม่จริง (§1.2–1.3)

EIV — Errors-in-Variables

ไม่ใช่วิธี — แต่คือชื่อของปัญหาที่เกิดขึ้นเมื่อ "ตัวแปรที่เราใช้ทำนาย" (แกนนอน) ก็มีความคลาดเคลื่อน/สัญญาณรบกวนปนอยู่ เหมือนวัดด้วยไม้บรรทัดที่สั้น · ผลคือ OLS จะประมาณ β ต่ำกว่าความจริงอย่างเป็นระบบ เรียกว่า *attenuation bias* (ลงรายละเอียดเต็มใน §1.2)

TLS (Total Least Squares) / Deming regression

วิธีลากเส้นแบบเดียวกับ OLS แต่วัดความใกล้แบบ**ตั้งฉากกับเส้น** — ยอมรับว่าทั้งสองแกนมีความคลาดเคลื่อนได้ · เป็นคำตอบสำหรับปัญหา EIV ข้างบน แต่ต้องแลกด้วยสมมติฐานใหม่ (§1.5)

Kalman Filter

วิธีประมาณ β ที่**อัปเดตทุกวันแบบอัตโนมัติ** โดยชั่งน้ำหนักระหว่าง "ความเชื่อเดิม" กับ "ข้อมูลใหม่ที่เพิ่งเห็น" — เหมือน rolling OLS เวอร์ชันฉลาดที่จำอดีตอย่างนุ่มนวลแทนที่จะตัดทิ้งดื้อ ๆ (§1.7 ปูพื้น, เจาะลึกจริงใน Part IV)

🔧 เช็กความเข้าใจ (ตอบในใจก่อนอ่านต่อ)

1. OLS กับ TLS ต่างกันตรงไหน? (ตรงที่วัดระยะห่างจากเส้นคนละแบบ — แนวตั้ง vs ตั้งฉาก)
2. EIV เป็น "วิธีแก้" หรือ "ชื่อปัญหา"? (ชื่อปัญหา — TLS/Kalman คือวิธีแก้)

3. Kalman ต่างจาก rolling OLS ตรงไหนแบบคร่าว ๆ? (Kalman ถ่วงน้ำหนักอดีตแบบนุ่มนวล ไม่ตัดทิ้งที่ขอบหน้าต่างเหมือน rolling)

เป้าหมายของ Part นี้ (อ่านก่อน)

ไม่ใช่ให้คุณ "ใช้ Kalman เป็น" (ใครก็ใช้เป็น — Part 0 บอกแล้วว่านั่นไม่ใช่ edge) แต่ให้คุณเข้าใจว่าแต่ละขั้นคืออะไร · ฟังเมื่อไร · เลือกใช้ตัวไหนเมื่อไร — เพราะเลือกผิดขั้น = ถือความเสี่ยงที่ไม่ได้ตั้งใจ

1.1 ชั้น 0 — OLS: จุดตั้งต้นที่ทุกคนเริ่ม

 อ่านเป็นภาษาคนก่อน

วาดกราฟกระจาย (scatter): แกนนอน = ราคา PEP · แกนตั้ง = ราคา KO · แต่ละวันเป็นจุดหนึ่งจุด · OLS คือการลากเส้นตรงเส้นเดียวที่ "ใกล้จุดทุกจุดที่สุด" — ความชันของเส้นนั้นคือ β และระยะที่จุดจริงห่างจากเส้น คือ spread (ส่วนที่เส้นอธิบายไม่ได้)

$$KO = \alpha + \beta \times PEP + \varepsilon$$

└ ε = spread ที่เราจะเทรด

$$\beta = \text{Cov}(KO, PEP) / \text{Var}(PEP) \leftarrow \text{สูตรลัดหา ความชัน}$$

เขียนโค้ดบรรทัดเดียวก็ได้ (เช่น `statsmodels.OLS`) มันเร็ว เข้าใจง่าย มีในทุกลไลบรารี · ในหลายกรณีก็พอใช้ — ปัญหาคือ "หลายกรณี" ไม่ใช่ "ทุกกรณี" และตรงนี้แหละที่มือใหม่พลาด

1.2 ทำไม OLS "ใช้ได้แค่บางสถานการณ์"

OLS มีจุดพึง 2 อย่างที่ต้องเข้าใจก่อนใช้จริง

จุดฟัง 1 — ไม่สมมาตร (asymmetric)

พูดให้เห็นภาพ

ถ้าคุณถาม OLS ว่า "KO ขยับตาม PEP เท่าไร" ได้เลขหนึ่ง · แต่ถ้าถามกลับว่า "PEP ขยับตาม KO เท่าไร" แล้วพลิกกลับหน่วย — คุณจะได้**คนละเลข** ทั้งที่มันควรเป็นความสัมพันธ์เดียวกัน!

เหตุผล: OLS ต้อง "เลือกข้าง" ว่าตัวไหนเป็นตัวแปรตาม (y) แล้วผลลัพธ์ก็ขึ้นกับการเลือกนั้น · แปลว่า β ที่ได้ ขึ้นกับว่าคุณวางตัวไหนเป็นแกนตั้ง — ซึ่งไม่ควรจะเป็นแบบนั้น

จุดฟัง 2 — Errors-in-Variables (EIV / attenuation bias)

อุปมา "ไม้บรรทัดสั้น"

OLS ตั้งสมมติฐานว่า **แกนนอน (PEP) วัดมาแม่นยำ** ไม่มี error เลย · แต่ในตลาดจริง ราคา PEP ก็มี noise (bid-ask, ซื้อขายไม่ต่อเนื่อง) เท่า ๆ กับ KO — เหมือนคุณวัดความยาวด้วย**ไม้บรรทัดที่สั้น**ทั้งสองแกน · ผลคือ OLS จะประมาณความชัน (β) **ต่ำกว่าจริงเสมอ** — เอนเข้าหา 0

$$\beta_{OLS} \approx \beta_{จริง} \times \frac{\text{Var}(\text{สัญญาณจริงของ PEP})}{\text{Var}(\text{สัญญาณจริง}) + \text{Var}(\text{noise ของ PEP})}$$

$$\text{Var}(\text{สัญญาณจริง}) + \text{Var}(\text{noise ของ PEP})$$

└─ ตัวคูณนี้ < 1 เสมอ เมื่อ PEP มี noise ─┘

ตัวอย่างเชิงตัวเลข (สมมติ เพื่อให้เห็นภาพ)

สมมติความสัมพันธ์จริง $\beta = 1.00$ และราคา PEP มี noise = 20% ของสัญญาณจริง:

$$\beta_{OLS} \approx 1.00 \times \left[1 / (1 + 0.20) \right] \approx 0.83$$

→ คุณคิดว่าต้องซอร์ต PEP 0.83 หุ้น แต่ที่ถูกคือ 1.00 → **hedge น้อยไป 17%** → spread ที่ไต่ยังแบกความเสี่ยงทิศทางค้างอยู่โดยไม่รู้ตัว

 ลองคิดเอง

ถ้า noise ของ PEP เพิ่มขึ้น 50% ของสัญญาณ — β ที่ OLS ให้จะเป็นเท่าไร? (เฉลย: $1.00 \times 1/(1+0.5) \approx 0.67 \rightarrow$ hedge น้อยไปถึง 1 ใน 3) · เห็นไหมว่ายิ่ง noise เยอะ OLS ยิ่งเพี้ยนหนัก

 เกร็ด: attenuation bias นี้ Ragnar Frisch ชี้ไว้ตั้งแต่ยุค 1930s — ไม่ใช่ของใหม่ แต่คนเทรดสมัยนี้ลืมนั่นบ่อยมาก

1.3 ★ จุดพลิกความเข้าใจ — "ราคา" กับ "ผลตอบแทน" ไม่เหมือนกัน

ตรงนี้เป็นเพชรของ Part I และเป็นคำตอบจริงว่าทำไม "OLS แย่" ถึงเป็นความเชื่อที่ถูกแค่ครั้งเดียว

 คำถามง่าย ๆ ที่ตอบยาก: คุณ regress อะไร?

คุณเอา ราคา (เช่น KO = 60 บาท) มา regress? หรือเอา ผลตอบแทน (วันนี้ KO +1.2%) มา regress? · ฟังดูเหมือนกัน แต่มันคนละโลก และถ้าเลือกผิด กลยุทธ์ฟังตั้งแต่บรรทัดแรก

★ ประเด็นหลักที่ต้องจำ

EIV/attenuation ที่เพิ่งเล่า (β เอนเข้า 0) เกิดกับ **return regression** (regress ผลตอบแทน) — แต่ **แทบไม่เกิด**กับ cointegration ที่ regress ราคา on ราคา เพราะปรากฏการณ์ชื่อ **super-consistency**

 **super-consistency คืออะไร (ภาษาคนล้วน)**

ปกติยิ่งเก็บข้อมูลเยอะ ค่าประมาณยิ่งแม่นยำขึ้น — แต่แม่นยำขึ้น "ช้า ๆ" · แต่เมื่อหุ้น 2 ตัว cointegrate กันจริง (ราคามันผูกกันแบบมีระยะห่างคงที่) OLS บนราคาจะลู่เข้าหา β จริง **เร็วมากผิดปกติ** — เร็วจน noise ที่ทำให้เกิด EIV ถูกกลบหายไปเองเมื่อข้อมูลมากพอ (Stock 1987)

พูดสั้น ๆ: **บนราคาที่ cointegrate กัน OLS "ดีเกินคาด"** — ข้อกังวลเรื่อง EIV ที่เพิ่งเรียน ใช้ไม่ได้ที่นี่

ราคา / Level (Cointegration)		ผลตอบแทน / Return (Correlation, Factor)
regress อะไร	ราคา on ราคา	ผลตอบแทน on ผลตอบแทน
β หมายถึง	อัตราส่วนที่ทำให้ส่วนต่าง นิ่ง (stationary)	ความไว/exposure ณ ขณะนั้น
ตอบคำถาม	"spread จะกลับไหม"	"ตอนนี้ฉัน neutral ต่อ factor ไหม"
OLS ใช้ได้ไหม	✅ ดี (super-consistent) · จะเนียนขึ้นใช้ FM-OLS/DOLS	⚠️ EIV จริง → TLS/PCA/Kalman ช่วย
ใช้ผิดแล้วพัง ยังงิ	ถ้าไม่ cointegrate = spurious regression	level ลอยห่างได้ แม้ return ขยับด้วยกัน

spurious regression — กับดักที่เข้ามาใหม่

ถ้าเอาราคา 2 ตัวที่ *ไม่* cointegrate จริงมา regress กัน — คอมจะรายงาน R^2 สูง ค่าสถิติดูดีไปหมด **เหมือนเจอขุมทอง** — แต่มันปลอมทั้งหมด · residual หนึ่ง "spread" ไม่มีวันกลับ มันลากออกไปเรื่อย ๆ จนพอร์ตพัง (Granger & Newbold 1974)

บทเรียน: R^2 สูงบนราคา $\neq$ เทรดได้ → ต้องทดสอบว่า residual หนึ่งจริงไหมเสมอ (นั่นคือ ADF test ใน Part II)

มุมที่ quant มองต่าง

คนทั่วไปเห็น: "OLS มี bias → OLS แย่ → ทิ้ง"

quant เห็น: bias มีจริงเฉพาะบางบริบท — OLS บนผลตอบแทนแย่ แต่ OLS บนราคาที่ cointegrate กลับดีเยี่ยม · คำถามที่ถูกไม่ใช่ "OLS ดีหรือแย่" แต่คือ "ฉันกำลัง regress ราคา หรือ ผลตอบแทน"

1.4 แปลง β เป็นออร์เดอร์จริง — 3 ความ "neutral" ที่สับสน

β เป็นแค่อัตราส่วน · พอถึงเวลากดส่งคำสั่งจริง ต้องแปลงเป็นจำนวนหุ้น และตรงนี้มี 3 คำที่คนปนกันจนฟัง

อยากให้ neutral แบบไหน	ทำยังไง	ได้ / ไม่ได้อะไร
Share-ratio	ถือ PEP จำนวน β หุ้น ต่อ KO 1 หุ้น (มาจาก cointegration)	✓ ทำให้ spread กลับ · ✗ มักไม่ dollar-neutral
Dollar-neutral	long กับ short มูลค่าเงินเท่ากัน	✓ คุมขนาดพอร์ต · ✗ ไม่การันตี spread กลับ
Beta-neutral	ไม่มี exposure สุทธิต่อตลาด/factor	= อาณาเขต Part III

🇹🇹 ตัวอย่างจับต้องได้ (สมมติ)

$\beta = 1.3 \cdot \text{ราคา KO} = 60 \cdot \text{ราคา PEP} = 170 \cdot \text{คุณซื้อ KO 100 หุ้น (1 board lot ไทย = 100)}$

Share-ratio: ซอร์ต PEP = $1.3 \times 100 = 130$ หุ้น

มูลค่า long KO = $100 \times 60 = 6,000$

มูลค่า short PEP = $130 \times 170 = 22,100$ ← ไม่เท่ากัน!

เห็นไหมว่า share-ratio ที่ถูกต้องสำหรับ spread **ไม่ได้** dollar-neutral เลย (6,000 vs 22,100) · ถ้าคุณฝืนปรับให้เท่ากัน คุณจะทำลายอัตราส่วนที่ทำให้ spread กลับ

📉 กับดัก: spread ที่แอบมีความเสี่ยงซ่อน

Share-ratio จาก cointegration โดยทั่วไป**ไม่** dollar-neutral และ**ไม่** market-neutral → "spread" ของคุณอาจแอบถือความเสี่ยงตลาดอยู่ · นี่คือการของ "factor bet ปЛОมตัว" ที่จะเจาะลึกใน Part III

หลักที่ต้องปัก

เลือกก่อนจะให้ neutral ต่ออะไร — แล้วจำนวนหุ้นจะตามมาเอง · ปกติเลือกได้ไม่ครบทั้งสาม · stat arb เลือก "**ให้ spread กลับ**" ก่อน แล้วค่อยคุมความเสี่ยงตลาดแยกต่างหาก (Part III)



ลองลิกหน้าจอเทรดจริง — กระดานไทย

- ปิดเป็นจำนวนเต็ม: $\beta \times \text{หุ้น}$ มักได้เศษ $\rightarrow$ ปิดเศษ = hedge เพี้ยนนิดหน่อยทุกครั้ง (เจ็บสุดตอนขา
ราคาสูง + ทุนน้อย เพราะไม่มี fractional share)
- board lot ไทย = 100 หุ้น: ต้องสั่งเป็นล็อต $\rightarrow \beta \times 100$ อาจไม่ลงตัวเป็นล็อต = จุดที่ทฤษฎีชนหน้า
จอจริง
- rebalance = ค่าคอมฯ: พอ β อัปเดต (rolling/Kalman) ต้องปรับจำนวนหุ้น เสียค่าคอมฯ ทุกครั้ง
(โยง Part VI/VIII)


1.5 ชั้น 1 — TLS / Deming รู้ · ใช้เป็น · รู้ว่าพึ่งตอนไหน

ถ้า EIV เกิดเพราะ OLS แก่งว่าแกนนอนไม่มี noise — ทางแก้คือใช้วิธีที่ยอมรับว่าทั้งสองแกนมี noise นั่นคือ TLS (Total Least Squares) / Deming regression

👤 อ่านเป็นภาษาคนก่อน — ต่างกันตรงวัดระยะ

ทั้ง OLS และ TLS ลากเส้นผ่านจุดเหมือนกัน แต่วัด "ความห่าง" ต่างกัน:

- OLS วัดระยะจากจุดถึงเส้นในแนวตั้ง (สมมติ error อยู่ทีแกนตั้งเท่านั้น)
- TLS วัดระยะตั้งฉากกับเส้น (ยอมรับ error ทั้งสองแกน) → สมมาตร + แก้ EIV



เชื่อมกับ PCA (จุดที่จะกลับมาใน Part III)

TLS ของ 2 สินทรัพย์ = ทิศที่ข้อมูลแกว่งมากที่สุด พอดี (เรียกว่า eigenvector ตัวแรก) → นี่คือการสะท้อนสู่ eigenportfolio / PCA hedge ที่ Avellaneda-Lee (2010) ใช้จริง และเป็นแกนของ Part III

✗ TLS พังเมื่อไร (ส่วนที่คนไม่สอน)

- เดลา ๑ ผิด → แย่กว่า OLS: TLS ไม่ได้ลบ bias — มันแค่แลก bias หนึ่งด้วยสมมติฐานหนึ่ง คือ "noise สองขาแรงเท่ากัน" ($\delta=1$) · ถ้าจริง ๆ ขาหนึ่ง noisy กว่ามาก TLS จะเพี้ยนกว่า OLS อีก
- ไวต่อ outlier: จุดที่หลุดโด่งจะดึงเส้นแรงกว่าปกติในบางเคส

✓ สรุปกฎเลือก OLS vs TLS (จำแค่นี้พอ)

- regress ราคา (cointegration) → ใช้ OLS ได้เลย ด้อยอยู่แล้ว (super-consistent)
- regress ผลตอบแทน (hedge/factor) → EIV จริง → TLS/PCA ช่วย ถ้าประเมิน δ ได้ · ประเมินไม่ได้ → ใช้ Kalman (ชั้น 3) จัดการให้ดีกว่า

1.6 ชั้น 2 — Rolling OLS: ให้ β เดินตามเวลา

อ่านเป็นภาษาคนก่อน

β จริงไม่ได้อยู่นิ่ง — ธุรกิจเปลี่ยน ความสัมพันธ์เปลี่ยน · วิธีง่ายสุดคือคำนวณ OLS ใหม่เรื่อย ๆ บน "หน้าต่าง" ข้อมูลล่าสุด (เช่น 60 วันหลังสุด) แล้วเลื่อนหน้าต่างไปทุกวัน · แต่ขนาดหน้าต่างมี tradeoff ที่ต้องเข้าใจ

หน้าต่างสั้น (เช่น 20 วัน)

-  ไว — ตาม β ที่เปลี่ยนทัน
-  กระทบ — β เดินตาม noise
-  rebalance บ่อย = ค่าคอมฯ พุง

หน้าต่างยาว (เช่น 120 วัน)

-  นิ่ง — β ไม่เดิน
-  ช้า — ตาม β ที่เปลี่ยนไม่ทัน
-  กระโดดตอนข้อมูลเก่าหลุดขอบหน้าต่าง

กับดัก look-ahead (มือใหม่พลาดบ่อยสุด)

ถ้าเฟลอคำนวณ β หรือ mean/std ของ spread โดยใช้ข้อมูลทั้งชุดรวมอนาคต = คุณกำลัง "รู้อนาคต" ตอนตัดสินใจ → backtest สวยหล่อ ๆ แต่ live พัง · **กฎเหล็ก:** ที่จุดเวลาใด ให้ใช้เฉพาะข้อมูลถึงจุดนั้นเท่านั้น

Rolling OLS คือสะพานสู่ขั้นสุดท้าย — เพราะจริง ๆ แล้ว **Kalman filter = rolling regression** เวอร์ชันฉลาด ที่ "จำ" อดีตอย่างเหมาะสมและถ่วงน้ำหนักแบบ optimal แทนที่จะตัดข้อมูลเก่าทิ้งดื้อ ๆ ที่ขอบหน้าต่าง

1.7 ชั้น 3 — Kalman: ยอดบันได → เจาะลึก Part IV

อ่านเป็นภาษาคนก่อน

Kalman อัปเดต β ทุกวันแบบ real-time โดยชั่งน้ำหนักระหว่าง "ความเชื่อเดิมเรื่อง β " กับ "ราคาที่เพิ่งเห็นวันนี้" — ใช้เฉพาะข้อมูลอดีต (ไม่รู้อนาคต) และนุ่มนวลกว่า rolling ที่กระตุก · **ปุ่มที่สำคัญที่สุดคืออัตราส่วน Q/R**: จะเชื่อความจำเดิม หรือเชื่อราคาล่าสุดแค่ไหน

state: $\beta_{\text{วันนี้}} = \beta_{\text{เมื่อวาน}} + \text{การเปลี่ยนแปลง}$
 observation: $\text{ราคาที่เห็น} = \beta \times \text{ราคาอีกขา} + \text{noise}$

$Q = \text{"}\beta \text{ เปลี่ยนเร็วแค่ไหน"}$ · $R = \text{"เชื่อราคาล่าสุดแค่ไหน"}$

ทำไมยังไม่ลงลึกตรงนี้

Kalman มีเรื่องต้องระวังเยอะ — จูน Q/R ยังไงไม่ให้ overfit · จะรู้ได้ยังไงว่า overfit · β ควรเป็น random walk จริงไหม — ทั้งหมดนี้เป็นหัวใจของ Part IV เต็ม ๆ ที่นี้แค่ให้เห็นว่ามันคือปลายทางของบันได β

สรุป Part I + สะพานสู่ Part II

✓ 3 อย่างที่ต้องจำจาก Part I

1. "OLS แยะ" ถูกครั้งเดียว — แยะกับผลตอบแทน (EIV) แต่ดีเยี่ยมกับ cointegration บนราคา (super-consistent)
2. แยก "ราคา" กับ "ผลตอบแทน" ให้ขาด — ราคา → "spread กลับใหม่" · ผลตอบแทน → "neutral ใหม่" · ปั่นกัน = spurious regression หรือ hedge หลอก
3. β เป็นแค่อัตราส่วน — เลือกก่อนว่าจะ neutral ต่ออะไร แล้วจำนวนหุ้นตามมา; ระวังความเสี่ยง ซ่อน + board lot

ตอนนี้เรามี β แล้ว และรู้ว่าเชื่อมันแค่ไหน — คำถามถัดไปคือ **คุณไปถึงคู่ควรเทรดตั้งแต่แรก?** ทุกคนใช้ correlation + cointegration test ชุดเดียวกัน สแกนหุ้นชุดเดียวกัน...

"ทุกคนมีเครื่องมือตัดคู่เหมือนกันเป๊ะ — แล้วเราจะต่างตรงไหน?"

📖 ศัพท์ใหม่ในตอนนี้

- **Hedge ratio (β)** — อัตราส่วนถือ 2 ขาเพื่อสร้าง spread (เหมือนสูตรผสมเครื่องดื่ม)
- **EIV / attenuation bias** — OLS ประมาณ β ต่ำไป เมื่อแกนนอนมี noise ("ไม้บรรทัดสั้น")
- **Super-consistency** — OLS บนราคาที่ cointegrate ลู่เข้าเร็วผิดปกติ → EIV หายไปเอง
- **Spurious regression** — regress ราคาที่ไม่ cointegrate ได้ผลดูดีแต่ปลอม
- **TLS / Deming** — regression ที่ยอมรับ noise ทั้ง 2 แกน (วัดระยะตั้งฉาก)
- **Share / Dollar / Beta-neutral** — 3 ความหมายของ "ปรับสมดุลขา" ที่ห้ามสับสน

อ้างอิงตอนนี้

- Stock, J.H. (1987) "Asymptotic Properties of Least Squares Estimators of Cointegrating Vectors", *Econometrica* — super-consistency
- Phillips, P.C.B. & Hansen, B.E. (1990) FM-OLS · Stock, J.H. & Watson, M.W. (1993) DOLS — ปรับ finite-sample
- Granger, C.W.J. & Newbold, P. (1974) "Spurious Regressions in Econometrics", *Journal of Econometrics*
- Deming, W.E. (1943) errors-in-variables regression · Golub & Van Loan — total least squares

 **ลงมือ:** notebook vol2-code/01_beta_ladder.ipynb — OLS vs TLS vs Rolling vs Kalman บนคู่เดียวกัน เทียบ β path ให้เห็นกับตา

ตัวเลขจริงจาก notebook (β จริง = 1.30, จำลอง 750 วัน, seed คงที่)

OLS บนราคา: $\beta = 1.2075$ (bias 0.0925) เทียบกับ OLS บน return: $\beta = 0.6760$ (bias 0.6240) — **bias แยกว่าถึง 6.7 เท่า** ตรงกับที่ super-consistency ทำนายไว้ · TLS ($\delta=1$) ได้ $\beta = 1.7642$ (bias 0.4642, overshoot เพราะเดา δ ผิด — ลอง $\delta=3$ แล้วดีขึ้นเหลือ bias 0.2375) · RMSE เทียบ β จริง ตลอดเส้นทาง: Rolling OLS window=30 → 2.0662, window=150 → 4.1350, ส่วน Kalman → **0.0144** (ดีกว่า rolling window ที่ดีที่สุดกว่า 140 เท่า)

↔ เชื่อมเล่ม 1: arb-part5 §18.1 (correlation vs cointegration — แนวคิด) · เล่ม A theory-part5 (cointegration, stationarity)