

Practical Quant: Stat Arb ที่ใช้ได้จริง

Part II — Correlation & Cointegration ที่ใช้จริง (+ Copula รายย่อย)

ทุกคนมี library · AI · ข้อมูลชุดเดียวกัน — Part นี้ให้ funnel คัดคู่จริง + ค่า cut-off ที่ใช้กันในงานวิจัย แล้วตอบคำถามหลัก: ถ้าเครื่องมือเหมือนกันหมด เราต่างตรงไหน · ปิดท้ายด้วย copula ที่รายย่อยทำได้

 เส้นทางอ่าน

● **มือใหม่:** อ่าน 🧑 ทุกกล่อง + ตาราง funnel §2.1 + 📊 ตัวอย่าง + สรุป ✓ · ● **มีพื้น:** เน้น §2.3 กับดัก multiple-testing + §2.4 copula/tail dependence · **เริ่มต้น:** ตาราง cut-off §2.1 เอาไปใช้ได้ทันที

คำถามที่ Part นี้ต้องตอบให้ได้

Part I เราหา β ของคุณได้แล้ว — แต่ก่อนหน้านี้ต้องตอบให้ได้ก่อนว่า **คุณโหนถึงคู่ควรเทรด?** เพราะถ้าเลือกคู่ผิด β สวยแค่ไหนก็ไม่ช่วย

 อ่านเป็นภาษาคนก่อน — correlation ต่างจาก cointegration ยังไง

เล่ม 1 (arb-part5 §18.1) อธิบายไว้แล้ว สรุปสั้น ๆ ด้วยภาพ:

- **Correlation** = "เดินไปทางเดียวกันไหม" — เหมือนคน 2 คนเดินขึ้นเขาพร้อมกัน แต่ระยะห่างระหว่างกันอาจถ่างออกเรื่อย ๆ ก็ได้
- **Cointegration** = "ระยะห่างคงที่ไหม" — เหมือนคน 2 คนที่ผูกเชือกเส้นเดียวกัน เดินห่างกันได้ชั่วคราว แต่เชือกดึงกลับเสมอ ← ตัวนี้แหละที่เทรดได้

เราจะไม่เขียนซ้ำทฤษฎีตรงนั้น · สิ่งที่ Part นี้ทำคือลงมือจริง: คุณต้องผ่านด่านอะไร · ค่าเท่าไรถึงผ่าน · และเมื่อทุกคนใช้ funnel เดียวกัน เราจะต่างยังไง

"เครื่องมือคัดคู่เป็นของฟรีที่ทุกคนมี — ความต่างอยู่ที่บ่อที่คุณสแกน และวินัยที่คุณคัดออก"

2.1 The Screening Funnel — ค่า cut-off ที่ใช้กันจริง

อ่านเป็นภาษาคนก่อน — funnel คืออะไร

นึกถึง**ด้านตรวจสอบนามบิน**ที่ต่อกันหลายชั้น: เช็คตัว → สแกนกระเป๋า → ตรวจร่างกาย · คุ้หน
ก็ต้องผ่านหลายด้านเช่นกัน — แต่ละด้านกรองผีคนละแบบ · **คู่ที่ผ่านทุกด้านเท่านั้นถึงจะเข้า**
รายการเทรด

นี่คือค่าที่พบบ่อยในงานวิจัยและงานจริง (ใช้เป็น **จุดตั้งต้น** ไม่ใช่กฎศักดิ์สิทธิ์):

ด้าน	ค่าที่ใช้กันจริง	ด้านนี้กรองอะไร / กับดัก
1. Correlation	ρ (ผลตอบแทน) > 0.8	กรองหยาบ ลดจำนวนคู่ที่ต้องตรวจ · ใน S&P500 มีเพียง ~872 คู่ที่ > 0.8 · ไม่ใช่ข้อพิสูจน์ว่าเทรดได้
2. ADF test (Engle-Granger)	$p < 0.05$ (เข้ม: < 0.01)	ทดสอบว่า spread "นิ่ง" (จะกลับ) จริงไหม · แต่ทดสอบ หลายร้อยคู่ = เจอผีเยอะ (\$2.3)
3. Hurst	H < 0.5 (ยิ่งต่ำยิ่งดี)	ยืนยันซ้ำว่า spread กลับจริง ไม่ใช่ ADF ผ่านโดยบังเอิญ
4. Half-life	ใช้ได้ราว ~1–30 วัน	สั้นไป = เทรดถี่ ค่าคอมฯ กิน · ยาวไป = ทุนถูกล็อกนาน + คู่มือเวลาพัง
5. Johansen	trace/max-eigen > critical	สำหรับตะกร้า >2 ตัว (เล่ม 1 ไม่มี)

Half-life คำนวณยังไง (แบบเข้าใจง่าย)

Half-life = "spread ใช้เวลากี่วันกว่าจะกลับ**ครึ่งทาง**สู่ค่าเฉลี่ย" · ยิ่งสั้น = ยางยืดดึงกลับแรง = เทรด
จบไว

1. regress: การเปลี่ยนแปลงวันนี้ = $a + b \times (\text{spread เมื่อวาน})$
2. Half-life = $\ln(2) / (-b) \leftarrow \ln(2) \approx 0.693$

ตัวอย่าง (สมมติ): ถ้า $-b = 0.10 \rightarrow HL = 0.693/0.10 \approx 7$ วัน → ดี เทรดได้

อ่านเป็น decision funnel ไม่ใช่ทองคำ

ทุกคู่ต้องผ่านหลายด้านพร้อมกัน — ADF ผ่าน และ $Hurst < 0.5$ และ half-life สมเหตุผล · ผ่านด้านเดียวไม่พอ เพราะแต่ละ test มีจุดบอดคนละแบบ การให้ยืนยันกันเองคือวิธีกันผีที่ถูกต้องที่สุด

ลองคิดเอง

ถ้าคู่หนึ่ง ADF ผ่าน ($p=0.03$) แต่ half-life = 90 วัน — ควรเทรดไหม? (เฉลย: ไม่ควร — 90 วันนานเกิน ทุนถูกล็อกและคู่มีเวลาพังสูง แม้ ADF ผ่านก็ตาม · นี่คือเหตุผลที่ต้องดูหลายด้าน ไม่ใช่ ADF ตัวเดียว)

2.2 "ทุกคนใช้เหมือนกัน แล้วต่างตรงไหน" — 5 จุด

funnel ข้างบนเป็นของสาธารณะ AI เขียนให้ได้ใน 5 นาที · ความต่างไม่ได้อยู่ที่ funnel — อยู่ที่ 5 อย่างนี้

จุดต่าง	ทำอะไร (และทำไมช่วย)
1. Universe	สแกนบ่อที่คนอื่นไม่สแกน (small-cap · ไทย/SEA · crypto) — funnel เดิม แต่ บ่อใหม่ ← จุดแข็งรายย่อย (ชั้น D)
2. Validation เข้มกว่า	ทดสอบ cointegration ซ้ำบนช่วงที่โมเดลไม่เคยเห็น (ไม่ fit ครั้งเดียวจบ) + รวมหลาย test กันผี
3. Parameter regime	จูน half-life band / cut-off ให้เข้ากับ <i>cost</i> ของตัวเอง — คนต้นทุนสูงต้องเลือกคู่ half-life สั้นกว่า
4. When-NOT-to-trade	ค่า cointegration เริ่มเสื่อม / half-life พุง = ถอย (โยง Part VII kill-switch) ← ชั้น C
5. Dependence ต่างจาก ฝูง	ใช้ copula จับความสัมพันธ์ที่เส้นตรงของฝูงพลาด (§2.4)

2.3 กับดักตัวจริง — ที่ทำให้ backtest สวายแต่ live พัง

กับดัก 1 — In-sample สวาย → out-of-sample พัง (อันดับ 1)

คู่ที่ cointegrate สวายในอดีต **ไม่** หารันตีว่าจะ cointegrate ต่อ — ความสัมพันธ์เสื่อมได้ (บริษัทเปลี่ยนธุรกิจ · ครอบรวม · วิฤตเฉพาะตัว) · ต้อง validate บนช่วงที่โมเดล *ไม่เคย* เห็นเสมอ

กับดัก 2 — Multiple testing (รายการสุดตอนสแกนเยอะ)

เข้าใจง่าย ๆ

ถ้าโยนเหรียญ 1 เหรียญ 5 ครั้งออกหัวหมด — น่าทึ่ง · แต่ถ้าให้คน 1,000 คนโยนคนละ 5 ครั้ง จะมีสัก 30 คนที่ออกหัวหมด **โดยบังเอิญ** — ไม่ได้เก่งอะไร · การสแกนคู่หุ้นก็เหมือนกัน ยิ่งสแกนเยอะ ยิ่งเจอ "คู่ที่ดี" โดยบังเอิญ

คาดหวังจำนวนผี $\approx$ (จำนวนคู่ที่ทดสอบ) $\times$ (ระดับนัยสำคัญ)
 $500 \text{ คู่} \times 0.05 = 25 \text{ คู่ "ผ่าน" แบบมั่ว ๆ}$ ทั้งที่ไม่มีความสัมพันธ์จริง

ทางแก้: ปรับ threshold ให้เข้มข้น (Bonferroni / FDR) หรือใช้ **deflated Sharpe** ที่หักจำนวนการทดสอบออก (López de Prado) — ลงลึก Part IX

กับดัก 3 & 4 — Look-ahead + Regime dependence

- **Look-ahead ตอนเลือกคู่:** เลือกคู่โดยดูข้อมูลทั้งชุด (รวมอนาคต) แล้ว backtest บนชุดเดิม = โกงตัวเอง
- **Regime dependence:** คู่ที่ cointegrate ในตลาดขาขึ้น อาจพังในวิฤต — มันไม่ใช่คุณสมบัติถาวร

มุมที่ quant มองต่าง

คนทั่วไปเห็น: "เจอคู่ที่ ADF $p = 0.001$ = เจอขุมทอง"

quant เห็น: ถ้าสแกนมาพันคู่ $p=0.001$ อาจเป็นแค่ผีตัวหนึ่ง — คำถามไม่ใช่ "p ต่ำแค่ไหน" แต่คือ "ฉันทดสอบมากี่ครั้งกว่าจะเจอมัน"

2.4 Copula สำหรับรายย่อย — จับสิ่งที่เส้นตรงมองไม่เห็น

อ่านเป็นภาษาคนก่อน — ทำไมต้องมีตัวนี้อีก

correlation/cointegration เป็นเครื่องมือเชิงเส้น — มันสรุปความสัมพันธ์เป็นตัวเลขเฉลี่ยตัวเดียว · แต่คู่หุ้นบางคู่เกาะกันแน่นเฉพาะตอนตลาดตก (แห่ขายพร้อมกัน) ส่วนตอนปกติต่างคนต่างไป · ตัวเลข correlation เดียวจับความต่างนี้ไม่ได้ — **copula** จับได้

copula แยก 2 อย่างออกจากกัน: **marginal** (แต่ละตัวมีพฤติกรรมยังไง) กับ **dependence** (มันเชื่อมกันยังไง) → ทำให้จับ "tail dependence" (เกาะกันตรงหางของการแจกแจง = ตอนสุดโต่ง) ได้

Copula	เกาะกันตรงไหน	ใช้เมื่อ
Gaussian / Frank	ไม่มีทางพิเศษ	เชื่อมกันปกติทั่ว ๆ ไป
Student-t	2 ทาง สมมาตร	เกาะแรงทั้งตอนขึ้น/ลง (คู่ในเชกเตอร์เดียว)
Clayton	ทางล่าง	เกาะแรงตอน ตลาดตก (crash together)
Gumbel / Joe	ทางบน	เกาะแรงตอน ตลาดขึ้น

Signal: Mispricing Index (MI) — ต่างจาก z-score ยังไง

สาย cointegration ใช้ z-score ของ spread · สาย copula ใช้ **conditional probability**: "ถ้า PEP อยู่ตรงนี้ ปกติ KO ควรอยู่ตรงไหน" แล้ววัดว่าของจริงเบี่ยงจากนั้นแค่ไหน

$$MI = P(KO \text{ อยู่ต่ำกว่านี้} \mid \text{เห็น PEP แล้ว}) - 0.5$$

$MI > 0 \rightarrow KO$ แพงเกินที่ควร (เทียบ PEP) $\rightarrow$ short KO / long PEP

$MI < 0 \rightarrow KO$ ถูกเกินที่ควร $\rightarrow$ long KO / short PEP

เครื่องมือรายย่อย (ฟรี/มาตรฐาน — ไม่ต้อง infra แพง)

- arbitragelab (Hudson & Thames) — มี **Mispricing Index Copula Strategy** สำเร็จรูป
- copulas / copulae / statsmodels — fit copula เอง
- QuantConnect tutorial "Pairs Trading: Copula vs Cointegration" — โค้ดรันได้ฟรี

✗ Copula พังเมื่อไร (ต้องเตือน)

- ต้อง fit **marginal** ให้ดีก่อน (ใช้ empirical CDF) — marginal ผิด copula ผิดตาม
- เลือก family มั่ว = overfit — อย่าลองทุก family แล้วเลือกอันที่ backtest สวยสุด
- tail-dependence **ไม่** ینگบนข้อมูลน้อย (ตรงทางมีจุดน้อยโดยธรรมชาติ)
- ต้อง **out-of-sample** เสมอ

2.5 ขีดจำกัดของโลกที่ละคู่ → สะพานสู่ Part III

สังเกตว่าทั้ง correlation · cointegration · copula — ทุกอย่างมองที่ละคู่ · แต่ทำไมหุ้น 2 ตัวถึงเดินด้วยกัน ตั้งแต่แรก? ไม่ใช่เพราะมี "ความสัมพันธ์พิเศษ" เฉพาะคู่ — แต่เพราะมันแชร์ **common factor** เดียวกัน (ตลาด · sector · style)

**"ถ้า co-movement มาจาก factor ร่วม — ทำไมต้องนั่งเลือกคู่ที่ละคู่?
ทำไมไม่หัก factor ที่ทิ้ง แล้วเทรดสิ่งที่เหลือทั้งกระดาน?"**

นั่นคือ Part III — ที่ pairwise กลายเป็นแค่กรณีพิเศษ และ edge (กับความเสี่ยงที่ซ่อนอยู่) เปลี่ยนหน้าตาไปเลย

ศัพท์ใหม่ในตอนนี้

- **Screening funnel** — ลำดับด่านคัดคู่ (correlation → ADF → Hurst → half-life → Johansen)
- **ADF test** — ทดสอบว่า spread นิ่ง (จะกลับ) จริงไหม
- **Half-life** — เวลาที่ spread กลับครึ่งทาง = $\ln(2)/\theta$
- **Hurst exponent** — วัดว่า mean-revert ($H < 0.5$) / สุ่ม (0.5) / trending (> 0.5)
- **Multiple testing** — ยิ่งทดสอบเยอะ ยิ่งเจอผีจากความบังเอิญ
- **Copula / Mispricing Index** — จับ tail dependence; สัญญาณ = $P(\text{เงื่อนไข}) - 0.5$

อ้างอิงตอนนี้

- Gatev, Goetzmann & Rouwenhorst (2006) — distance/correlation approach
- Rad, H., Low, R.K.Y. & Faff, R. (2016) "The profitability of pairs trading strategies: distance, cointegration and copula methods", *Quantitative Finance*
- Xie, W., Liew, R.Q., Wu, Y. & Zou, X. (2016) "Pairs Trading with Copulas" — MI method ต้นฉบับ
- Stübinger, J., Mangold, B. & Krauss, C. (2018) "Statistical arbitrage with vine copulas", *Quantitative Finance*

 **ลงมือ:** notebook vol2-code/02_cointegration_copula.ipynb — Engle-Granger + Johansen + half-life + copula/MI

ตัวเลขจริงจาก notebook

คู่ที่ cointegrate จริง: $\beta=1.400$, `coint()` p-value=0.0001 (PASS ถูกต้อง) · คู่ independent (spurious): `coint()` p-value=0.0376 — **false positive** ที่แม้แต่วิธีถูกก็ยังไม่พลาดได้ · ใช้ `adfuller()` ตรงกับ residual แทน (วิธีผิด) กับข้อมูลชุดเดียวกัน: p-value=0.0096 — มั่นใจผิด ๆ ยิ่งกว่าเดิม · ทดสอบ 300 คู่ที่ไม่สัมพันธ์กันจริงเลย: ทฤษฎีคาดหวัง $n \times \alpha = 15.0$ คู่ — `coint()` เจอ 12 คู่ (ใกล้เคียง) แต่ `adfuller()` บน residual เจอ **44 คู่ (เกือบ 3 เท่า)** · half-life จริง ($\theta=0.05$) = 13.86 วัน เทียบกับที่ประเมินได้ 7.26 วัน · Hurst ของสเปรตที่ mean-revert = 0.188 เทียบกับ random walk = 0.428 (แยกกันชัดเจนจาก 0.5)

↔ เชื่อมเล่ม 1: arb-part5 §18.1 (correlation vs cointegration) · เล่ม A theory-part5 (Engle-Granger/Johansen, backtest rigor)