

STATISTICAL ARBITRAGE · บทที่ 4

Hedge Ratio β

OLS · TLS · Kalman Filter — สามวิธีหา "อัตราส่วนที่ถูกต้อง"

ตัวอย่าง: Bybit $\leftrightarrow$ Lighter BTC Perpetual

แก่นของบทนี้

β คือตัวเลขที่ทำให้ $\varepsilon = \log(A) - \beta \cdot \log(B)$ เป็น stationary

วิธีหา β มีผลต่อ entry ratio และ P&L โดยตรง — OLS, TLS, และ Kalman ให้ β ต่างกัน

$$\beta_{\text{OLS}} = \text{Cov}(r_A, r_B) / \text{Var}(r_B)$$

4.1 ทำไมวิธีหา β จึงสำคัญ

จากบทที่ 1 เราทราบแล้วว่า $\beta \neq 1$ — แต่คำถามคือ **หา β ด้วยวิธีไหน?** วิธีต่างกันให้ β ต่างกัน และ β ที่ต่างกันหมายถึงอัตราส่วน trade ต่างกัน $\rightarrow$ P&L ต่างกัน

OLS

Ordinary Least Squares

เร็ว, simple, bias ถ้าทั้งสองตัวมี noise

TLS

Total Least Squares

Symmetric, เหมาะเมื่อทั้งคู่ noisy เท่ากัน

Kalman

Dynamic β

β เปลี่ยนตามเวลา, แม่นยำสุดแต่ซับซ้อนกว่า

4.2 OLS — วิธีที่ใช้บ่อยที่สุด

OLS หา β ที่ minimize ระยะทางแนวตั้ง (vertical residual) จากจุดข้อมูลถึงเส้น regression:



สูตร OLS B

$$\beta_{OLS} = \text{Cov}(r_A, r_B) / \text{Var}(r_B) = \Sigma(r_A - \bar{r}_A)(r_B - \bar{r}_B) / \Sigma(r_B - \bar{r}_B)^2$$

หรือถ้า regress $\log(P_A)$ บน $\log(P_B)$ โดยตรง (level regression):

$$\log(P_A) = \alpha + \beta \cdot \log(P_B) + \varepsilon \quad \beta_{OLS} = \text{slope ของ regression นี้}$$

OLS vs TLS — ต่างกันที่ "minimize อะไร"



OLS และ TLS ให้ β ต่างกัน — OLS ใช้ B เป็น "หลัก" (no noise), TLS สมมติทั้งคู่ noisy เท่ากัน

สูตร TLS (Total Least Squares)

$$\beta_{TLS} = [\text{Var}(r_A) - \text{Var}(r_B) + \sqrt{(\text{Var}(r_A) - \text{Var}(r_B))^2 + 4 \cdot \text{Cov}(r_A, r_B)^2}] / (2 \cdot \text{Cov}(r_A, r_B))$$

หรือใช้ SVD: $\beta_{TLS} = v_{12}/v_{22}$ (eigenvector ของ covariance matrix $[r_A, r_B]$)

เลือก OLS หรือ TLS?

สถานการณ์	แนะนำ	เหตุผล
B เป็น "benchmark" (spot price, reference)	OLS	B มี noise น้อยกว่า A — OLS assume B error-free
ทั้งสองตลาด liquidity ใกล้เคียงกัน	TLS	ทั้งคู่ noisy พอๆ กัน — symmetric
ต้องการ β เสถียร ปรับน้อย	OLS rolling	คำนวณง่าย เปลี่ยนได้ตามรอบ
β เปลี่ยนเร็ว ต้องการ adaptive	Kalman	อัปเดตทุก tick

4.3 Kalman Filter — Dynamic β ที่เปลี่ยนตามเวลา

OLS และ TLS สมมติว่า β คงที่ตลอด lookback window แต่ในตลาดจริง β อาจเปลี่ยนได้ Kalman Filter แก้ปัญหานี้โดยอัปเดต β ทุก time step:

KALMAN STATE SPACE MODEL

$\beta_t = \beta_{t-1} + w_t$ (state equation: β เดินแบบ random walk)

$r_{A,t} = \beta_t \cdot r_{B,t} + v_t$ (observation equation)


$w_t \sim N(0, Q)$ — process noise (ความเร็วที่ β เปลี่ยน)

$v_t \sim N(0, R)$ — observation noise (noise จากราคา)

Kalman Filter ทำงาน 2 ขั้นตอนซ้ำกันทุก time step:

ขั้น	สูตร	ความหมาย
Predict	$\beta_{t t-1} = \beta_{t-1}, P_{t t-1} = P_{t-1} + Q$	คาดว่า β ตอนนี้เป็นอะไร (ก่อนเห็นข้อมูล)
Update	$K = \frac{P \cdot r_B^2}{(r_B^2 \cdot P + R)}$ $\beta_t = \beta_{t t-1} + K \cdot (r_A - \beta_{t t-1} \cdot r_B)$ $P_t = (1 - K \cdot r_B^2) \cdot P$	ปรับ β ตามข้อมูลจริงที่เพิ่งเห็น

K คือ **Kalman Gain** — ถ้า Q สูง (β เปลี่ยนเร็ว) K ใหญ่ → เชื่อข้อมูลใหม่มาก ถ้า R สูง (noisy market) K เล็ก → เชื่อ model เก๋ามากกว่า



Rolling OLS กระโดดตาม window boundary — Kalman ค่อยๆ ปรับ $\rightarrow$ position ขยับน้อยกว่า

4.4 Lookback Window และการ Roll

สำหรับ OLS rolling หรือ Kalman Q/R tuning ต้องเลือก lookback ให้เหมาะกับ strategy:

Lookback	ข้อดี	ข้อเสีย	เหมาะกับ
7 วัน	Responsive ต่อ regime ใหม่	Noisy, β กระโดด	Fast intraday
30 วัน	สมดุล stability/responsiveness	Lag ช้า	Intraday-swing (แนะนำ)
90 วัน	Stable, noise น้อย	ปรับ regime เปลี่ยนช้ามาก	Position trade

Re-estimate β เมื่อไร?

- Daily: re-run OLS บน 30 วันล่าสุด ก่อนตลาดเปิด
- เมื่อ ϵ drift ต่อเนื่อง > 2 วัน $\rightarrow \beta$ เปลี่ยน re-estimate ทันที
- Kalman: ไม่ต้อง re-estimate — อัปเดต continuous ทุก bar

4.5 เลือก β Method ตามวัตถุประสงค์ (Objective-Driven Design)

แก่นความคิด

OLS/TLS/Kalman ไม่ใช่แค่ตัวเลือกที่ดีกว่ากัน — แต่ละตัวถูกออกแบบมาเพื่อวัตถุประสงค์ต่างกัน เลือกให้ตรงกับสิ่งที่ต้องการ

สามเส้นทาง: Objective-to- ϵ Mapping

วัตถุประสงค์	Model	ϵ target (variance)	แหล่งกำไรหลัก
Funding Rate Harvest Perp $\leftrightarrow$ Perp / Spot $\leftrightarrow$ Perp	Kalman Filter (dynamic β_t)	$\sigma^2 \rightarrow 0$ — กราฟแบนขนาน ศูนย์	Funding rate yield — เพิ่ม leverage ปลอดภัยได้เพราะ price risk ≈ 0
Hybrid: Spread + Funding Spot $\leftrightarrow$ Future / Pairs Trading	OLS/TLS (static β) + walk-forward	σ_{stat} "Optimal Substantial" — กว้างพอกว่า friction แต่ half-life สั้น	Capital gain จาก mean reversion และ basis/funding
Volatility Arbitrage Spot $\leftrightarrow$ Option (ขึ้นสูง)	GARCH(1,1) + Delta-Neutral hedge	Dynamic — ขึ้นกับ IV regime — กรอง vol clustering ด้วย GARCH	IV mispricing บน Options surface — นอกขอบเขตหนังสือนี้

อธิบายเชิงแนวคิด

Funding Rate Harvest — ต้องการ $\epsilon_t \rightarrow 0$

เป้าหมายคือ market-neutral perfect hedge: Kalman β_t ปรับทุก bar ตาม cost-of-carry จริง ทำให้ $\epsilon_t \approx 0$ ตลอดเวลา PnL ทั้งหมดมาจาก **funding rate เท่านั้น** ไม่ใช่ price movement ยิ่ง ϵ เล็กยิ่งดี — แสดงว่า hedge สมบูรณ์



Spread Arbitrage — ต้องการ ε_t เกว่งรอบ 0

OLS lock β จากอดีต — ความไม่สมบูรณ์ของ hedge นี้เองคือแหล่งกำไร ε_t ที่มี variance สูงหมายถึงโอกาสเทรดมาก เมื่อ ε เบี่ยงจาก mean $\rightarrow$ entry; เมื่อ revert กลับ $\rightarrow$ exit

ความเข้าใจผิดที่พบบ่อย

Kalman ไม่ได้ "ดีกว่า" OLS เสมอ — ถ้าใช้ Kalman กับ Spread Arb จะได้ $\varepsilon \rightarrow 0$ ซึ่งทำให้ไม่มีสัญญาณ เพราะ β_t ปรับตัวจนกำจัด spread ออกไปหมด ต้องเลือก method ให้ตรงกับ **สิ่งที่ต้องการให้ ε ทำ**

ε_t ตามเวลา: เป้าหมายต่างกันตามกลยุทธ์



ซ้าย: Kalman ε_t แบน — Funding Harvest ($\sigma^2 \rightarrow 0$) | ขวา: OLS ε_t เกว่ง — Hybrid/Spread Arb (σ_{stat} "Optimal")

Breakeven σ_{stat} — เส้นแบ่ง "Optimal Substantial Variance"

สำหรับ Hybrid Strategy สิ่งที่กำหนด "กว้างพอ" ของ σ_{stat} คือสมการ Breakeven จาก [บทที่ 19.7](#):

BREAKEVEN Σ CONDITION

$$\sigma_{\text{stat}} \geq \text{total_friction_cost} / (z_{\text{entry}} - z_{\text{exit}})$$

ถ้า σ_{stat} ต่ำกว่า threshold นี้ $\rightarrow$ gross spread ที่ entry ไม่ครอบคลุม friction $\rightarrow$ net_edge < 0
 $\rightarrow$ ห้ามเทรด

Optimal Substantial Variance — นิยามเชิงปฏิบัติ

σ_{stat} ที่ "พอเหมาะ" ต้องตอบ **สองเงื่อนไขพร้อมกัน**:

- **Lower bound:** $\sigma_{\text{stat}} \geq \text{total_cost} / (z_{\text{entry}} - z_{\text{exit}}) \rightarrow$ กว้างพอกว่า friction (breakeven condition)

- **Upper bound:** Half-life $\leq N$ bars $\rightarrow$ spread ไม่ค้างนานเกินไปจน margin cost กินกำไร

ช่วงระหว่าง lower–upper bound นี้คือ "Tradeable Window" ของกลยุทธ์ Hybrid

ตัวอย่าง Bybit↔Lighter (taker-taker): total_friction = 19.6 bps (ดู ch19)
 $z_{\text{entry}} = 2.0$, $z_{\text{exit}} = 0.5$ Breakeven $\sigma_{\text{stat}} = 19.6 / (2.0 - 0.5) = 13.1$ bps
 (0.131%) วัดได้จริง: $\sigma_{\text{stat}} = 30$ bps (0.30%) ส่วนเกิน = $30 - 13.1 = 16.9$ bps $\leftarrow$
 gross edge สุทธิต่อรอบ ☒ $\sigma_{\text{stat}} > \text{Breakeven } \sigma \rightarrow \text{trade ได้}$ ❌ ถ้า $\sigma_{\text{stat}} = 10$ bps
 $\rightarrow 10 < 13.1 \rightarrow$ ห้ามเทรด

Running Example: Bybit ↔ Lighter — สองเส้นทาง

กลยุทธ์ที่ 1 – Funding Rate Harvest (Kalman): ใช้ Kalman $\beta_t \rightarrow \varepsilon_t$ แบนราบ ≈ 0 Bybit funding rate $0.01\%/8h = 10$ bps/day คือ PnL ทั้งหมด price risk $\approx$ hedged ออกไปเกือบสมบูรณ์ กลยุทธ์ที่ 2 – Spread Arbitrage (OLS): ใช้ OLS $\beta = 1.002$ (ค่าคงที่จาก 30d window) ε_t แกว่ง $\pm 0.3\%$, Half-life 7.4h คือโอกาสเทรด entry เมื่อ $z\text{-score} > 2\sigma$, exit เมื่อ revert หนังสือเล่มนี้: $\rightarrow$ Spread Arb path (OLS/TLS) = running example หลัก (ch5–ch14) $\rightarrow$ Kalman สำหรับ Funding Harvest = ch15

4.6 การหา β ในทางปฏิบัติ — เลือกข้อมูล ประเมินคุณภาพ และข้อผิดพลาด

ก่อนลงรายละเอียดว่าใช้ method ไหน ต้องเข้าใจ **ตำแหน่งของ β** ในภาพใหญ่ก่อน — สิ่งที่เราต้องการสร้างจริงๆ ไม่ใช่ β แต่เป็น ε (**synthetic process**) ส่วน β คือแกนสำคัญที่สุดที่ทำให้สร้าง ε ได้ *ถูกสัดส่วน*

แก่นความคิด — B คือสูตรผสม, E คือของใหม่ที่เกิดจากการผสม

$$\varepsilon = F(A) - \beta \cdot F(B)$$

β คือ **อัตราส่วนผสม (mixing ratio / hedge ratio)** ที่ตอบว่า "ถ้ามี A 1 หน่วย ต้องใช้ B กี่หน่วยมาหักล้าง?" — ประโยคที่แม่นยำที่สุดคือ: **β คืออัตราส่วนที่ใช้ผสมสองสิ่ง เพื่อให้ได้ ε ที่มีคุณสมบัติเทรตได้**

β	สมการ ε	ความหมายของการผสม
$\beta = 1$	$\varepsilon = A - B$	ผสม 1:1 — ใช้ B เท่ากับ A
$\beta = 0.8$	$\varepsilon = A - 0.8B$	ใช้ B แค่ 0.8 เท่าของ A
$\beta = 1.3$	$\varepsilon = A - 1.3B$	ใช้ B มากกว่า A เพื่อหักล้าง exposure ให้พอดี

β กำหนดว่า process ใหม่จะ "หน้าตา" เป็นอย่างไร — มันไม่ใช่แค่ตัวเลขประกอบสูตร แต่เป็น**ตัวกำหนดโครงสร้างของ synthetic process**:

β ดี $\rightarrow \varepsilon$ ที่เทรตได้


common movement ถูกหักล้าง · ε นิ่งขึ้น · mean reversion ชัดขึ้น · เป็น risk-neutral จริง

β ผิด $\rightarrow$ process หลอก

ε drift · signal หลอก · กลายเป็น directional bet · position size ผิด · risk สูงกว่าที่คิด

β อยู่ตรงไหนใน Pipeline

β สำคัญมาก แต่ **ไม่ใช่ทุกอย่าง** — มันเป็นขั้นที่ 3 ของกระบวนการสร้าง process ต้องมี pair selection + transformation มาก่อน และมี diagnostics + execution gate ตามหลัง:



β เป็นขั้นที่ 3 — ขาดขั้นไหนก็สร้าง ϵ ที่เทรดได้จริงไม่ได้ บทที่ 4 โฟกัสที่ขั้น Beta

β เป็นแนวคิดทั่วไป — ใน option เรียกว่า Delta

หลักการ "หาอัตราส่วนที่ถูกต้องเพื่อสร้าง process ใหม่" ใช้ได้กับทุก asset class — ใน option process: $\epsilon = \text{Option} - \Delta \cdot \text{Underlying}$ โดย Δ (delta) ทำหน้าที่เป็น hedge ratio แทน β แนวคิดเดียวกัน: ไม่จำเป็นต้องผสม 1:1

ที่เหลือของ §4.6 เจาะ 3 เรื่องที่ทำให้ β **ใช้ได้จริง** ไม่ใช่แค่ตัวเลขสวยบน backtest: เลือกข้อมูลที่ถูก (§4.6.1) · เลือก method ตามสถานการณ์ (§4.6.2–4.6.3) · ประเมินคุณภาพและเสี่ยงกับดัก (§4.6.4–4.6.5)

4.6.1 regress ข้อมูลแบบไหน — Raw Price, Log Price หรือ Basis

แก่นความคิด

β ไม่มีค่าเดียวตายตัว — คำนวณขึ้นกับว่าคุณ regress **ราคาดิบ, log price, หรือ basis** สามแบบนี้ให้ β คนละตัวเลข และตอบคนละคำถาม

Input ที่ regress	สมการ ϵ	ใช้เมื่อ	β หมายถึงอะไร
Raw price	$\epsilon = P_A - \beta \cdot P_B$	scale ราคาใกล้เคียงกัน / ต้องการดูภาพ scatter	\$ ของ A ต่อ \$1 ของ B — ขึ้นกับ scale ราคา
Log price	$\epsilon = \log P_A - \beta \cdot \log P_B$	default — pairs ทั่วไป (ที่หนังสือเล่มนี้ใช้)	elasticity: %A ต่อ %B — scale-invariant

Basis / spread	$\varepsilon = \text{basis_A} - \beta \cdot \text{basis_B}$	funding arb, perp $\leftrightarrow$ perp, swap arb (บทที่ 21)	sensitivity ของ basis ขาหนึ่งต่ออีกขา
----------------	---	---	---------------------------------------

BTC/ETH — ทำไม $\beta = 0.0444$ จึงลอกตา

ภาพวิเคราะห์ BTC/ETH ที่นิยมแชร์กัน fit regression บน **ราคาดิบ**: $\text{ETH} = \alpha + \beta \cdot \text{BTC}$ ได้ $\beta = 0.0444$ ตัวเลขนี้แปลว่า "ETH ขยับ \$0.0444 ต่อทุก \$1 ที่ BTC ขยับ" — มันถูกในเชิงเลขคณิต แต่ **ขึ้นกับระดับราคา**: ถ้า BTC แลก scale (เช่น redenominate $\div 10$) β จะกลายเป็น 0.444 แทนที่ ทั้งที่ความสัมพันธ์จริงไม่เปลี่ยน

ถ้า regress **log price** แทน: $\log(\text{ETH}) = \alpha + \beta \cdot \log(\text{BTC})$ จะได้ β เป็น **elasticity** (สำหรับ crypto major มักใกล้ 1) — ค่านี้ไม่เปลี่ยนตาม scale ราคา จึงเอาไป calibrate ข้าม regime ได้ปลอดภัยกว่า หนังสือเล่มนี้ใช้สมการ $\varepsilon = \log P_A - \beta \cdot \log P_B$ เป็นมาตรฐานด้วยเหตุผลนี้

อย่าเอา raw-price β ไปใส่ position โดยตรง

$\beta = 0.0444$ เป็นแค่ slope บนกราฟ scatter — ไม่ใช่ hedge ratio ที่พร้อมใช้ ก่อนกำหนดขนาด position ต้องแปลงเป็น **dollar-neutral notional** ก่อนเสมอ (long \$X ของ A $\leftrightarrow$ short \$X ของ B) มิฉะนั้น position จะมี directional bias แฝงโดยไม่รู้ตัว

4.6.2 เมนูเต็มของวิธีหา β

§4.2–4.3 อธิบาย OLS / TLS / Kalman เชิงลึก — ตารางนี้รวมทุกวิธีไว้เป็น "เมนู" เดียวเพื่อเลือกใช้ตามสถานการณ์:

วิธี	ใช้เมื่อ	ข้อดี	ข้อเสีย
$\beta = 1$	สินทรัพย์เดียวกัน, exposure เท่ากัน (BTC perp $\leftrightarrow$ BTC perp)	ง่ายสุด, ไม่ overfit	หยาบ — venue ต่างกันเรื่อง funding/index/liquidity
Contract ratio	crack spread / product ที่มี ratio เชิงกลไกชัดเจน	mechanism ชัด ไม่ต้อง fit	ใช้ได้เฉพาะบางตลาด
OLS	pair 2 ตัวทั่วไป — baseline เริ่มต้น	ง่าย, เร็ว, ดีความได้	β คงที่ — อาจ outdate เมื่อ regime เปลี่ยน
Rolling OLS	ความสัมพันธ์เปลี่ยนตาม regime	adaptive กว่า OLS static	noisy ถ้า window สั้นเกิน

TLS	ทั้ง X และ Y มี noise พอๆ กัน	สมดุลงกว่า OLS (ดู §4.2)	ซับซ้อนขึ้น, ดีความยากกว่า
Kalman	β เปลี่ยนตลอดเวลา / Funding Harvest (§4.5)	dynamic, online update	overfit ง่าย, tune Q/R ยาก
Johansen	multi-leg / basket (≥ 3 ขา)	หา cointegrating vector หลายขาพร้อมกัน	overfit ง่าย, ต้องระวังเป็นพิเศษ
Greek (Delta/Vega)	options / volatility strategy	ตรงกับโครงสร้าง option	ต้อง update ตลอดเพราะ Greek เปลี่ยน

4.6.3 Roadmap — เริ่มจากง่าย ค่อยไปยาก

ข้อผิดพลาดที่พบบ่อยคือเริ่มจาก Kalman ทันทีเพราะ "ดูฉลาด" — แต่ Kalman มีพารามิเตอร์ให้ tune เยอะ จึง overfit ง่ายมากเมื่อข้อมูลยังน้อย ลำดับที่แนะนำสำหรับ scanner v1:

ขั้นบันได β — ไล่จาก baseline ไป dynamic



อย่ากระโดดไป Kalman ทันที — พิสูจน์ก่อนว่า $\beta=1$ หรือ OLS ยังไม่พอ จึงค่อยไต่ขั้นถัดไป

4.6.4 β ดีหรือไม่ดี ดูยังไง — Checklist 7 ข้อ

β ที่ดี **ไม่ใช่** β ที่ทำให้กราฟ backtest สวยที่สุด — แต่คือ β ที่ทำให้ process เทรดได้จริงและ robust ใช้ checklist นี้:

เกณฑ์ประเมิน β

1. ε stationary มากขึ้น — ADF p-value ต่ำลง / KPSS ดีขึ้น (บทที่ 5)
2. Half-life เหมาะกับ horizon — ไม่สั้นจนจับไม่ทัน ไม่ยาวจน margin cost กิน (บทที่ 3)
3. Crossing behavior ดี — ϕ อยู่ใน sweet spot ([บทที่ 5 §5.7](#))

4. **Residual ไม่ drift** — ε ไม่ค่อยๆ ไหลไปทางเดียว (ไม่มี trend แฝง)
5. **Net edge หลัง cost ยังเหลือ** — $\sigma_{\text{stat}} \geq \text{breakeven } \sigma$ (§4.5)
6. **Position ไม่กลายเป็น directional bet** — dollar-neutral จริง ไม่มี market exposure แฝง
7. **β เสถียรพอใน out-of-sample** — ผ่าน walk-forward validation (บทที่ 3 §3.9)

4.6.5 ข้อผิดพลาดที่พบบ่อย

7 กับดักเรื่องการหา β

1. ใช้ $\beta = 1$ กับทุกอย่าง — สะดวกแต่หยาบ; venue ต่างกันมักทำให้ ε มี bias
2. ใช้ราคาดิบแทน log price / basis — β กลายเป็นตัวเลขที่ขึ้นกับ scale (ดู §4.6.1)
3. หา β จากข้อมูลทั้งหมดรวมอนาคต — look-ahead bias; ต้อง fit บน train window เท่านั้น
4. ใช้ window ยาวเกินไป — β ตามไม่ทัน regime ใหม่
5. Rolling window สั้นเกินไป — β noisy กระโดด → position ขยับถี่จน friction กิน
6. เลือก β ที่ backtest สวยที่สุด — overfit; ต้องผ่าน OOS / paper validation ก่อน
7. ลืมแปลง β เป็น position size จริง — β บน regression $\neq$ notional ratio ที่ trade

```
import statsmodels.api as sm
import numpy as np

# regress บน LOG price
# (มาตรฐานของหนังสือ) — ใช้ข้อมูล train window เท่านั้น
y = np.log(train["price_A"])
x = np.log(train["price_B"])
model = sm.OLS(y, sm.add_constant(x)).fit()
alpha = model.params["const"]
beta = model.params.iloc[1]  # hedge ratio
epsilon = y - (alpha + beta * x)  # diagnostics ใช้ residual รวม alpha

# ตอนแปลงเป็น position จริง:
# alpha เป็นค่าคงที่ของ model ไม่ใช่ขา trade
# long  $\varepsilon \rightarrow$  long $X ของ A, short $X ของ B (dollar-neutral)
```

Running Example: BTC/ETH — จากภาพวิเคราะห์สู่ β ที่ใช้ได้จริง

ภาพวิเคราะห์ (regress ราคาดิบ ETH บน BTC): $\beta_{\text{raw}} = 0.0444 \leftarrow$ slope บน scatter — ขึ้นกับ scale ราคา Corr = 0.9745 ✓ ผ่าน correlation screen (≥ 0.70) AR(1) $\varphi = 0.9602$ Half-Life = 17.08 ชม. ($-\ln 2 / \ln 0.9602 \approx 17.06$ ✓) แปลงให้ถูกหลักของหนังสือ — regress log price: $\varepsilon = \log(\text{ETH}) - \beta_{\text{log}} \cdot \log(\text{BTC})$ $\beta_{\text{log}} \approx$ elasticity (crypto major มักใกล้ 1) — scale-invariant ผ่าน Checklist §4.6.4: 1. stationary — Half-life 17h $\rightarrow \varepsilon$ mean-reverting ✓ 3. crossing $\varphi=0.96$ — นอก intraday sweet spot $\rightarrow$ swing เท่านั้น (ch5 §5.7) 7. walk-forward — ต้อง re-check β ทุก window (ch3 §3.9) สรุป: ใช้

$\beta_{\log}$ + dollar-neutral notional $\rightarrow$ trade เป็น overnight swing อย่าใช้ β_{raw}
 $= 0.0444$ ใส่ position ตรงๆ

โจทย์ 4.6 — เลือกชนิดข้อมูลที่จะ regress

คุณจะทำ β ของสามคู่นี้:

- (ก) BTC perp บน Bybit $\leftrightarrow$ BTC perp บน Lighter
- (ข) PAXG (gold token) $\leftrightarrow$ XAUUSD spot
- (ค) ETH spot $\leftrightarrow$ ETH perpetual (เก็บ funding)

ถาม: แต่ละคู่ควร regress raw price, log price, หรือ basis?

► ดูคำตอบ

4.7 Pseudo-code

```
# OLS Beta
function beta_ols(r_A, r_B):
    return cov(r_A, r_B) / var(r_B)

# TLS Beta (via eigenvalue)
function beta_tls(r_A, r_B):
    C = cov_matrix([[r_A], [r_B]]) # 2x2
    eigenvalues, eigenvectors = eig(C)
    v = eigenvectors[:, argmin(eigenvalues)] # smallest eigenvalue
    return -v[0] / v[1]

# Kalman Filter Beta (one-step update)
function kalman_beta_update(beta, P, r_A, r_B, Q, R):
    # Predict
    P_pred = P + Q
    # Kalman gain
    K = P_pred * r_B / (r_B**2 * P_pred + R)
    # Update
    innovation = r_A - beta * r_B
    beta_new = beta + K * innovation
    P_new = (1 - K * r_B) * P_pred
    return beta_new, P_new
```

Running Example: β ของ Bybit ↔ Lighter BTC Perp

ข้อมูล: 30 วัน, log returns รายวันที่ OLS (30d window): $\beta_{OLS} = \text{Cov}(r_{\text{Bybit}}, r_{\text{Lighter}}) / \text{Var}(r_{\text{Lighter}}) = 0.00000412 / 0.00000410 = 1.0049$ TLS: $\beta_{TLS} = 1.0063$ (เล็กน้อยกว่า OLS) Kalman ($Q=1e-7$, $R=1e-5$, warmup 14 วัน): $\beta_{\text{Kalman}_t} \approx 1.003 \pm 0.002$ (เปลี่ยนช้าๆ) ผลกระทบต่อ position: Long Bybit \$100,000: OLS: Short Lighter \$100,490 TLS: Short Lighter \$100,630 Kalman: Short Lighter \$100,300 ต่างกัน \$300-\$630 – ดูเล็กน้อย แต่ถ้า trade 100x/เดือน = \$30,000-\$63,000 ต่างกัน

โจทย์ 4.5 — เลือก Method ให้ตรงวัตถุประสงค์

บริษัท Quant เปิดสองกลยุทธ์:

- (ก) ใช้ Kalman β_t และ target $\varepsilon_t \approx 0$
- (ข) ใช้ OLS β และ z-score entry/exit

ถาม: กลยุทธ์ไหนทำกำไรจาก funding rate? กลยุทธ์ไหนทำกำไรจาก price inefficiency?

► [ดูคำตอบ](#)

โจทย์ 4.1 — คำนวณ β_{OLS} จากข้อมูล

Log returns รายวัน 5 วัน:

วัน	r_Bybit (%)	r_Lighter (%)
1	+1.20	+1.15
2	-0.80	-0.75
3	+2.10	+2.05
4	-1.50	-1.48
5	+0.60	+0.58

ถาม: คำนวณ β_{OLS} (Bybit เป็น A, Lighter เป็น B)

► [ดูคำตอบ](#)

โจทย์ 4.2 — เลือกวิธีหา β

คุณ trade spread ระหว่าง BTC perpetual บน Binance (volume 10× ของ Lighter) กับ Lighter ทั้งสองตลาดมี liquidity ต่างกันมาก — Binance เป็น "price discovery" หลัก

ถาม: ควรใช้ OLS หรือ TLS? และ Binance ควรเป็น A หรือ B ใน regression?

► [ดูคำตอบ](#)

โจทย์ 4.3 — Kalman Q/R tuning

คุณตั้ง Kalman กับ $Q=1e-9$ (เล็กมาก) และ $R=1e-4$ (ใหญ่มาก)

สังเกตว่า β_{Kalman} แทบไม่เปลี่ยนแปลง แม้ตลาดจะเปลี่ยน

ถาม: อธิบายว่าเกิดอะไรขึ้น และควรปรับ Q หรือ R อย่างไร?

► **ดูคำตอบ**

Ch.4 Hedge Ratio β | ต่อไป → **Ch.5: Cointegration Tests**