

Hedge Ratio β

OLS · TLS · Kalman Filter — สามวิธีหา "อัตราส่วนที่ถูกต้อง"

ตัวอย่าง: Bybit $\leftrightarrow$ Lighter BTC Perpetual

แก่นของบทนี้

β คือตัวเลขที่ทำให้ $\varepsilon = \log(A) - \beta \cdot \log(B)$ เป็น stationary

วิธีหา β มีผลต่อ entry ratio และ P&L โดยตรง — OLS, TLS, และ Kalman ให้ β ต่างกัน

$$\beta_{OLS} = \text{Cov}(r_A, r_B) / \text{Var}(r_B)$$

4.1 ทำไมวิธีหา β จึงสำคัญ

จาก**บทที่ 1** เราทราบแล้วว่า $\beta \neq 1$ — แต่คำถามคือ **หา β ด้วยวิธีไหน?** วิธีต่างกันให้ β ต่างกัน และ β ที่ต่างกันหมายถึงอัตราส่วน trade ต่างกัน $\rightarrow$ P&L ต่างกัน

OLS

Ordinary Least Squares

เร็ว, simple, bias ถ้าทั้งสองตัวมี noise

TLS

Total Least Squares

Symmetric, เหมาะเมื่อทั้งคู่ noisy เท่ากัน

Kalman

Dynamic β

β เปลี่ยนตามเวลา, แม่นยำสุดแต่ซับซ้อนกว่า

4.2 OLS — วิธีที่ใช้บ่อยที่สุด

OLS หา β ที่ minimize ระยะทางแนวตั้ง (vertical residual) จากจุดข้อมูลถึงเส้น regression:

สูตร OLS B



$$\beta_{OLS} = \text{Cov}(r_A, r_B) / \text{Var}(r_B) = \Sigma(r_A - \bar{r}_A)(r_B - \bar{r}_B) / \Sigma(r_B - \bar{r}_B)^2$$

หรือถ้า regress $\log(P_A)$ บน $\log(P_B)$ โดยตรง (level regression):

$$\log(P_A) = \alpha + \beta \cdot \log(P_B) + \varepsilon \quad \beta_{OLS} = \text{slope ของ regression นี้}$$

หมายเหตุ: β จาก return regression และ β จาก price-level regression เป็นคนละค่ากัน — สำหรับ synthetic process $\varepsilon = \log(P_A) - \beta \cdot \log(P_B)$ ค่า β ที่เป็นหลัก (canonical) คือ slope ของ log-price regression

OLS vs TLS — ต่างกันที่ "minimize อะไร"



OLS และ TLS ให้ β ต่างกัน — OLS ใช้ B เป็น "หลัก" (no noise), TLS สมมติทั้งคู่ noisy เท่ากัน

สูตร TLS (Total Least Squares)

$$\beta_{TLS} = [\text{Var}(r_A) - \text{Var}(r_B) + \sqrt{(\text{Var}(r_A) - \text{Var}(r_B))^2 + 4 \cdot \text{Cov}(r_A, r_B)^2}] / (2 \cdot \text{Cov}(r_A, r_B)) \quad \text{หรือใช้ SVD: } \beta_{TLS} = v_{12}/v_{22} \text{ (eigenvector ของ covariance)}$$

```
matrix [r_A, r_B])
```

เลือก OLS หรือ TLS?

สถานการณ์	แนะนำ	เหตุผล
B เป็น "benchmark" (spot price, reference)	OLS	B มี noise น้อยกว่า A — OLS assume B error-free
ทั้งสองตลาด liquidity ใกล้เคียงกัน	TLS	ทั้งคู่ noisy พอๆ กัน — symmetric
ต้องการ β เสถียร ปรับน้อย	OLS rolling	คำนวณง่าย เปลี่ยนได้ตามรอบ
β เปลี่ยนเร็ว ต้องการ adaptive	Kalman	อัปเดตทุก tick

4.2b OLS เชิงลึก — จากหลักการแรกถึงการใช้งานจริง

OLS · Linear Regression · Linear Programming — คนละเรื่องกัน

สามคำนี้ใช้คำว่า "linear" ร่วมกันแต่มาจากคนละโดเมนกันโดยสิ้นเชิง:

	Linear Regression	OLS	Linear Programming (LP)
คืออะไร	Model — สมมติว่าความสัมพันธ์เป็นเส้นตรง	Method — วิธีหนึ่งที่ใช้ fit model	Optimization — หา solution ที่ดีที่สุดภายใต้ constraint
"Linear" หมายถึง	β เข้า model แบบ linear: $y = \alpha + \beta \cdot x$	—	objective + constraints เป็นเส้นตรง
สมการหลัก	$y = \alpha + \beta \cdot x + \varepsilon$	minimize $\sum \varepsilon^2$	minimize $c \cdot x$ s.t. $Ax \leq b$
ใช้ทำอะไร	อธิบายความสัมพันธ์ระหว่างตัวแปร	หา β ที่ดีที่สุดใน linear regression	จัดสรรทรัพยากร, portfolio weight

ความสัมพันธ์ที่มีจริง: OLS เป็น วิธีหนึ่ง ในการ fit Linear Regression — ไม่ใช่สิ่งเดียวกัน และ Linear Programming คือคนละโลกกันเลย ไม่เกี่ยวกับ regression เลย

Linear Regression (model) วิธี fit ที่ใช้ได้: — OLS $\rightarrow$ minimize $\sum \varepsilon^2$ $\leftarrow$ วิธีที่หนังสือนี้ใช้ (quadratic objective) — MLE $\rightarrow$ maximize likelihood — Ridge $\rightarrow$ minimize $\sum \varepsilon^2 + \lambda \sum \beta^2$ — LAD $\rightarrow$ minimize $\sum |\varepsilon|$ $\leftarrow$ แปลงเป็น LP ได้! แต่ OLS ไม่ใช่ LP

จุดที่สับสนบ่อย: OLS minimize $\sum \varepsilon^2$ ซึ่งเป็น quadratic objective — จึงเป็น *Quadratic Program (QP)* ไม่ใช่ Linear Program แม้จะอยู่ใน "linear regression"

หมายเหตุ: หนังสือเล่มนี้ใช้ OLS เท่านั้น — MLE/Ridge/LAD แสดงไว้เพื่อเทียบนิยามเท่านั้น ไม่ได้ใช้ใน practice

จุดประสงค์ของ OLS ใน STAT ARB

เราไม่ได้ทำ OLS เพื่อ "ทำนาย" ราคา A จาก B — เราทำ OLS เพื่อ แยก common movement ออกจาก idiosyncratic movement ส่วนที่เหลือหลังแยก (residual ε) คือสิ่งที่เราเทรด

$$\varepsilon_t = \log(P_{A,t}) - \alpha - \beta \cdot \log(P_{B,t})$$

สัญลักษณ์ที่ใช้ใน §4.2b — อ่านก่อนเริ่ม

สัญลักษณ์	ความหมาย	หมายเหตุ
y_t	$\log(P_{A,t})$ — ราคา A ในรูป log	dependent variable ที่ต้องการอธิบาย
x_t	$\log(P_{B,t})$ — ราคา B ในรูป log	independent variable ที่ใช้อธิบาย
α	intercept — ค่าคงที่ปรับระดับ	ไม่ใช่ค่า trade — เป็นแค่ constant ใน model
β	population slope (ค่าจริงไม่รู้)	เราประมาณ β จากข้อมูล — $\hat{\beta}$ คือ estimator
$\hat{\beta}$	sample estimate ของ β จาก OLS	ต่างกันทุก dataset — converges $\rightarrow \beta$ เมื่อ $N \rightarrow \infty$
ε_t	residual = $y_t - \alpha - \beta \cdot x_t$	สิ่งที่เทรด — ต้องการให้ mean-revert
ϕ	AR(1) coefficient ของ ε	บทที่ 3 เรียกค่าเดียวกันว่า b : $\varepsilon_t = a + b \cdot \varepsilon_{t-1} + \eta_t$
BLUE	Best Linear Unbiased Estimator	$\hat{\beta}$ เป็น BLUE ถ้า Gauss-Markov assumptions ถือ
Gauss-Markov	4 เงื่อนไขที่ทำให้ OLS เหมาะสมที่สุด	ε zero-mean, uncorrelated กับ x , homoskedastic, no autocorrelation
Homoskedastic	$\text{Var}(\varepsilon_t)$ คงที่ทุก t	ในราคาจริง $\text{Var}(\varepsilon)$ เปลี่ยนตาม vol — heteroskedastic

หมายเหตุ: ทำไมไม่ใช้ log price ไม่ใช่ raw price $\rightarrow$ ดู [§4.6.1](#) (สรุปสั้น: $\log \rightarrow \beta$ เป็น elasticity ไม่ขึ้นกับ scale ราคา)

OLS จากหลักการแรก — ทำไมต้อง minimize $\sum \varepsilon^2$

ปัญหา: กำหนด N คู่ราคา $(P_{A,1}, \dots, P_{A,N})$ และ $(P_{B,1}, \dots, P_{B,N})$ — หา α และ β ที่ทำให้ residual ε_t ชั่นๆ ลงๆ รอบ 0 น้อยที่สุด (ε มี variance ต่ำสุดที่เป็นไปได้)

ทำไมต้อง minimize $\sum \varepsilon^2$ ไม่ใช่ $\sum |\varepsilon|$?

- **เหตุผล 1 — penalize outlier มากกว่า:** $\varepsilon=3$ ให้ $\varepsilon^2=9$ แต่ $|\varepsilon|=3$ — squared ทำให้จุดที่ห่างจากเส้นมากถูก penalize หนักกว่า ทำให้เส้น regression ไม่เบี่ยงจากกลุ่มข้อมูลหลัก
- **เหตุผล 2 — มี closed-form solution:** $\sum \varepsilon^2$ เป็น differentiable ทุกจุด $\rightarrow$ หา derivative แล้วตั้งเป็น 0 ได้ $\rightarrow$ ได้สูตร $\beta = \text{Cov}/\text{Var}$ โดยตรง ส่วน $\sum |\varepsilon|$ ไม่ differentiable ที่ $\varepsilon=0$ $\rightarrow$ ต้องใช้ linear programming แก้
- **เหตุผล 3 — residual $\perp x$:** $\sum \varepsilon^2$ ทำให้ residual uncorrelated กับ x (Gauss-Markov) — สมบัตินี้สำคัญสำหรับ inference และ diagnostics

เขียนปัญหาเป็นสมการ:

ให้ $y_t = \log(P_{A,t})$ และ $x_t = \log(P_{B,t})$ $\varepsilon_t = y_t - \alpha - \beta \cdot x_t$ ← residual คือสิ่งที่เราสร้าง objective: minimize $S(\alpha, \beta) = \sum \varepsilon_t^2 = \sum (y_t - \alpha - \beta \cdot x_t)^2$ $t=1$

หา minimum โดยหา partial derivative เทียบเท่า 0:

$\partial S / \partial \alpha = -2 \cdot \sum (y_t - \alpha - \beta \cdot x_t) = 0 \rightarrow \sum y_t = N \cdot \alpha + \beta \cdot \sum x_t$
 $\partial S / \partial \beta = -2 \cdot \sum x_t \cdot (y_t - \alpha - \beta \cdot x_t) = 0 \rightarrow \sum x_t \cdot y_t = \alpha \cdot \sum x_t + \beta \cdot \sum x_t^2$ แก้ระบบสมการ (Normal Equations): $\beta = [N \cdot \sum (x_t \cdot y_t) - \sum x_t \cdot \sum y_t] / [N \cdot \sum x_t^2 - (\sum x_t)^2] = \text{Cov}(x, y) / \text{Var}(x)$ ← รูปกระทัดรัด ($x = \log P_B$) $\alpha = \bar{y} - \beta \cdot \bar{x}$ ← α เป็นตัวปรับระดับ

ความหมายของ β จาก OLS



$\beta = \text{Cov}(\log P_A, \log P_B) / \text{Var}(\log P_B)$

ตีความ: "ถ้า $\log(P_B)$ เพิ่มขึ้น 1 หน่วย ($\approx B$ ขยับ +1%) ค่าเฉลี่ยของ $\log(P_A)$ ที่ OLS คาดไว้ จะเพิ่มขึ้น β หน่วย"

หรือพูดในเชิง % $\approx$ "B ขยับ 1% $\rightarrow$ A คาดว่าขยับ $\beta\%$ "

ε_t = ส่วนที่ A ขยับ มากกว่า หรือ น้อยกว่า ที่ B อธิบายได้ — นี่คือ inefficiency ที่เราเจอ

OLS แยก y_t ออกเป็น 2 ส่วน: ส่วนที่ B อธิบาย + residual ε



OLS แยก $\log P_A$ ออกเป็น "ส่วนที่ B อธิบาย" + residual ε — ε ที่ดีควร mean-revert รอบ 0

คำนวณ OLS ทีละขั้นตอน — ตัวอย่างตัวเลข

สมมติมีข้อมูล log price รายวัน 6 วัน (ย่อให้คำนวณมือได้):

t	$\log P_B (x)$	$\log P_A (y)$	$x - \bar{x}$	$y - \bar{y}$	$(x - \bar{x})(y - \bar{y})$	$(x - \bar{x})^2$
1	10.000	7.225	-0.200	-0.125	0.0250	0.0400
2	10.050	7.265	-0.150	-0.085	0.0128	0.0225
3	10.100	7.285	-0.100	-0.065	0.0065	0.0100
4	10.200	7.385	+0.000	+0.035	0.0000	0.0000
5	10.350	7.435	+0.150	+0.085	0.0128	0.0225
6	10.500	7.505	+0.300	+0.155	0.0465	0.0900
รวม	61.200	44.100	—	—	$\Sigma = 0.1035$	$\Sigma = 0.1850$

ขั้น 1 — คำนวณ mean: $\bar{x} = 61.200/6 = 10.200$ ($\log P_B$ เฉลี่ย) $\bar{y} = 44.100/6 = 7.350$ ($\log P_A$ เฉลี่ย) ขั้น 2 — คำนวณ β (slope): $\beta = \Sigma(x - \bar{x})(y - \bar{y}) / \Sigma(x - \bar{x})^2 = 0.1035 / 0.1850 = 0.5595 \approx 0.56$ ขั้น 3 — คำนวณ α (intercept): $\alpha = \bar{y} - \beta \cdot \bar{x} = 7.350 - 0.5595 \times 10.200 = 7.350 - 5.707 = 1.643$ ขั้น 4 — คำนวณ ε_t สำหรับแต่ละ t: $\varepsilon_t = y_t - 1.643 - 0.5595 \cdot x_t$
 $t=1: \varepsilon = 7.225 - 1.643 - 0.5595 \times 10.000 = 7.225 - 1.643 - 5.595 = -0.013$
 $t=2: \varepsilon = 7.265 - 1.643 - 5.623 = -0.001$
 $t=3: \varepsilon = 7.285 - 1.643 - 5.651 = -0.009$
 $t=4: \varepsilon = 7.385 - 1.643 - 5.707 = +0.035$
 $t=5: \varepsilon = 7.435 - 1.643 - 5.791 = +0.001$
 $t=6: \varepsilon = 7.505 - 1.643 - 5.875 = -0.013$
 $\Sigma \varepsilon_t = -0.013 - 0.001 - 0.009 + 0.035 + 0.001 - 0.013 = 0.000$ ✓

สิ่งที่ OLS รับประกัน (Gauss-Markov Theorem)

Gauss-Markov: ถ้า ε มี zero-mean, ไม่ correlate กับ x , $\text{Var}(\varepsilon)$ คงที่ (homoskedastic), และไม่มี autocorrelation $\rightarrow \beta$ จาก OLS เป็น BLUE (Best Linear Unbiased Estimator) — ดีที่สุดในบรรดา estimator linear ที่ unbiased ทั้งหมด

- $\sum \varepsilon_t = 0$ เสมอ — residuals sum to zero
- $\sum (x_t \cdot \varepsilon_t) = 0$ — residual uncorrelated กับ x
- $\beta_{\text{OLS}} = \text{BLUE}$ (Best Linear Unbiased Estimator) ถ้า Gauss-Markov assumptions ถือ (ε i.i.d., homoskedastic)
- ในราคาจริง assumptions เหล่านี้มักฝ่าฝืน $\rightarrow$ ดู §4.2b-5 ข้อยกเว้น

OLS ใน Python — 3 วิธีทำ

```
### วิธี 1: statsmodels (แนะนำ — ได้ diagnostics ครบ)
import statsmodels.api as sm
import numpy as np

y = np.log(price_A) # log P_A — dependent variable
x = np.log(price_B) # log P_B — independent variable

# add constant  $\rightarrow$  fit  $\alpha$  and  $\beta$  together
X = sm.add_constant(x) # X = [1, x] (N×2 matrix)
model = sm.OLS(y, X).fit()

alpha = model.params.iloc[0] #  $\alpha$  (intercept) — iloc safe กับทุก statsmodels version
beta = model.params.iloc[1] #  $\beta$  (hedge ratio)
epsilon = model.resid #  $\varepsilon_t$  (residuals) — ใช้ทดสอบ stationarity

r2 = model.rsquared #  $R^2$  — explained variance
p_beta = model.pvalues[1] # p-value ของ  $\beta$  (ต้องการ  $\ll 0.05$ )
ci_beta = model.conf_int().iloc[1] # 95% CI ของ  $\beta$  [lower, upper]

print(f" $\beta = \{beta:.4f\}$  ( $p=\{p\_beta:.4f\}$ )")
print(f" $R^2 = \{r2:.4f\}$ ")
print(model.summary()) # สรุปครบ — AIC, residual std, t-stat

### วิธี 2: numpy (เร็ว ง่าย สำหรับ loop)
beta, alpha = np.polyfit(x, y, 1) # fit linear  $y = \beta \cdot x + \alpha$ 
epsilon = y - (alpha + beta * x)
```

```
### วิธี 3: สูตรโดยตรง (เข้าใจ mechanism)
beta = np.cov(y, x)[0,1] / np.var(x, ddof=1)
alpha = np.mean(y) - beta * np.mean(x)
epsilon = y - alpha - beta * x
```

เลือก window ข้อมูลอย่างไร

- **Train window:** ข้อมูล N วันล่าสุด (เช่น 30 วัน) — fit β บน window นี้เท่านั้น
- **อย่าใช้ข้อมูลอนาคต:** ห้าม fit β บน full dataset แล้วย้อนไปทดสอบ → look-ahead bias
- **Walk-forward:** fit β วันนี้ → ใช้ trade พรุ่งนี้ → roll window ไป 1 วัน → fit ใหม่ (ดู [บทที่ 3 §3.9](#))

ตรวจ ϵ ที่ได้ — 4 การทดสอบหลัก

หลังจาก fit OLS และได้ ϵ มาแล้ว ต้องตรวจว่า ϵ มีคุณสมบัติสำหรับ mean reversion trading:

R^2 คืออะไร — นิยามสั้น

$R^2 = 1 - \text{Var}(\epsilon) / \text{Var}(y)$ = สัดส่วน variance ของ y ที่ x อธิบายได้

$R^2=0$: x ไม่ช่วยอธิบาย y เลย | $R^2=1$: x อธิบาย y ได้สมบูรณ์ | $R^2=0.95$: x อธิบายได้ 95%

ใน Stat Arb ต้องการ R^2 สูง → แสดงว่า B อธิบาย A ได้ดี → ϵ เป็น idiosyncratic จริง ไม่ใช่ noise

การทดสอบ	วิธีทำ	ผ่านเมื่อ	ความหมาย
R^2 และ p-value	model.rsquared, model.pvalues[1]	$R^2 > 0.7, p < 0.05$	β มีนัยสำคัญ, B อธิบาย A ได้ดี
Residual plot	plot ϵ_t vs t	ϵ oscillate รอบ 0, ไม่ drift	ϵ mean-revert ตามที่ต้องการ
ADF / KPSS	statsmodels adfuller(epsilon)	ADF $p < 0.05$, KPSS $p > 0.05$	ϵ stationary (ดู บทที่ 5)
Half-life	AR(1) fit บน ϵ : $\epsilon_t = \phi \cdot \epsilon_{t-1} + u_t$ $\tau_{1/2} = -\ln(2)/\ln(\phi)$	$\tau_{1/2} \leq \text{target hold time}$	ϵ revert เร็วพอสำหรับกลยุทธ์ (บทที่ 3)

```
# ตรวจ  $\epsilon$  ครบชุด
from statsmodels.tsa.stattools import adfuller
import statsmodels.api as sm
```

```
# 1. ADF test
adf_result = adfuller(epsilon, maxlags=1)
print(f"ADF p-value: {adf_result[1]:.4f}") # ต้องการ < 0.05

# 2. AR(1) → Half-life
ar1 = sm.OLS(epsilon[1:], sm.add_constant(epsilon[:-1])).fit()
phi = ar1.params[1] # AR(1) coefficient
half_life = -np.log(2) / np.log(phi) # half-life (same unit as data freq)
print(f"φ = {phi:.4f}, Half-life = {half_life:.1f} bars")

# 3. σ_stat — sample estimator ของ σ/√(2k) (converges เมื่อ sample size N ใหญ่)
sigma_stat = np.std(epsilon) # use in z-score: z = (ε - mean) / sigma_stat
print(f"σ_stat = {sigma_stat:.4f} ({sigma_stat*100:.2f}%)")
```

Running Example: BTC/ETH — OLS ที่ละขั้น

ข้อมูล: log price รายชั่วโมง 30 วัน (720 bars) $y = \log(\text{ETH_price})$, $x = \log(\text{BTC_price})$ ขั้น 1 — fit OLS: $\text{model} = \text{OLS}(y, \text{add_constant}(x)).\text{fit}()$
 $\beta_{\log} = 1.183$ (elasticity — ETH ขยับ 1.183% ต่อทุก 1% ที่ BTC ขยับ) $\alpha = -4.021$ (intercept — level adjustment) $R^2 = 0.951$ ✓ BTC อธิบาย ETH ได้ 95.1% $p(\beta) = 0.000$ ✓ β มีนัยสำคัญสูง ขั้น 2 — สร้าง ε : $\varepsilon_t = \log(\text{ETH}_t) - (-4.021) - 1.183 \cdot \log(\text{BTC}_t)$ ขั้น 3 — ตรวจ ε : ADF p-value = 0.043 ✓ stationary (ตรงกับ ch5 §5.7) ϕ (AR1) = 0.9602 Half-life = $-\ln(2)/\ln(0.9602) \approx 17.1$ ชม. ✓ revert ใน ~17h $\sigma_{\text{stat}} = 0.021$ (2.1%)
 ขั้น 4 — ตัดสิน: ε mean-revert ✓ | stationary ✓ | Half-life 17h → trade เป็น overnight swing ✓ หมายเหตุ: $\beta_{\log} = 1.183 \neq \beta_{\text{raw}} = 0.0444 \rightarrow \beta_{\text{raw}}$ เป็น slope บน raw price (ETH/\$1 BTC) — ขึ้นกับ scale → $\beta_{\log}$ เป็น elasticity (ไม่ขึ้นกับ scale) — ใช้หนังสือเล่มนี้

ข้อจำกัดของ OLS — เรียงตามความรุนแรง

⚠ ข้อจำกัดที่ 1 — Look-ahead Bias (อันตรายที่สุด — ทำ backtest ดีหลอกตา)

ผิด: $\beta = \text{OLS}(\text{all_data}) \rightarrow$ ใช้ backtest ทั้ง dataset $\rightarrow \beta$ "รู้" อนาคต $\rightarrow$ ผล backtest ดีเกินจริงเสมอ ถูก: สำหรับแต่ละวัน t : $\beta_t = \text{OLS}(\text{data}[t-30 : t]) \leftarrow$ ใช้แค่อดีต 30 วัน เทรดวันที่ $t+1$ ด้วย $\beta_t \leftarrow$ ไม่รู้อนาคต

ดู walk-forward validation: [บทที่ 3 §3.9](#)

ข้อจำกัดที่ 2 — Spurious Regression เมื่อทั้งสองตัว non-stationary

$\log P_A$ และ $\log P_B$ เป็น $I(1)$ process (random walk) — ถ้า regress สอง $I(1)$ series ที่ *ไม่มี* cointegration จะได้ R^2 สูง, β มีนัยสำคัญ แต่ ε ยังคง non-stationary — ผลที่ได้ไม่มีความหมาย

กับดัก: OLS บอกว่า $R^2 = 0.90$, $p < 0.001$ ดูน่าเชื่อถือมาก แต่: ADF ของ ε ได้ $p = 0.45 \leftarrow$ non-stationary! $\rightarrow$ regression นี้ spurious — เทรดไม่ได้

แก้: ทดสอบ ADF/KPSS บน ε เสมอ — ผ่าน ADF ก่อนจึงใช้ β นั้น (ดู [บทที่ 5](#))

ข้อจำกัดที่ 3 — β คงที่ ไม่ adaptive

OLS สมมติว่า β ไม่เปลี่ยนแปลงตลอด lookback window แต่ในตลาดจริง β อาจ drift ตาม regime

สัญญาณ: rolling β (30d vs 60d) ต่างกัน $> 15\%$ $\rightarrow$ ใช้ Rolling OLS หรือ Kalman แทน (§4.3, §4.6.3)

ดูรายละเอียด window และ trap เพิ่มเติม: [§4.6.6](#)

ข้อจำกัดที่ 4 — Outliers ดึง β ให้ผิดทิศ

OLS minimize $\varepsilon^2 \rightarrow$ จุดที่อยู่ห่างจากเส้นมาก (outlier: crash, flash crash, pump) มี weight สูงเป็นพิเศษ $\rightarrow \beta$ ถูกดึงให้เข้าหา outlier

แก้: Winsorize ข้อมูลก่อน fit (clip return ที่ percentile 1–99) หรือใช้ Robust Regression (Huber/LAD) — แนวคิดเดียวกับ Robust Z-score ใน [บทที่ 10 §10.3](#)

ข้อจำกัดที่ 5 — Level vs Return ให้ β ต่างกันมาก

Level regression: $\log P_A = \alpha + \beta_{\text{level}} \cdot \log P_B + \varepsilon$
Return regression: $r_A = \alpha + \beta_{\text{return}} \cdot r_B + \varepsilon$ ($r = \log$ return) $\beta_{\text{level}} \neq \beta_{\text{return}}$ ในกรณีทั่วไป! ตัวอย่าง BTC/ETH: $\beta_{\text{level}} \approx 1.18$ vs $\beta_{\text{return}} \approx 0.85-0.95$ (แล้วแต่ period)

กฎ: สำหรับ $\varepsilon = \log P_A - \beta \cdot \log P_B \rightarrow$ ใช้ **level regression บน log price** ดูเหตุผลเพิ่มเติม: [§4.6.1](#)

ข้อจำกัดที่ 6 — Gauss-Markov Assumptions มักถูกละเมิดในราคาจริง

Assumption	ใน OLS standard	ในราคาจริง	ผลกระทบ + วิธีตรวจ
No autocorrelation	ϵ_t ไม่ correlate กับ ϵ_{t-1}	ϵ มักมี autocorrelation (ราคาติดต่อกัน)	SE ของ β ผิด → ใช้ Durbin-Watson test ($DW \approx 2 =$ ดี; $DW < 1.5 =$ autocorrelation สูง → ใช้ Newey-West SE)
Homoskedastic	$\text{Var}(\epsilon)$ คงที่ทุก t	$\text{Var}(\epsilon)$ เปลี่ยนตาม volatility (GARCH)	OLS inefficient ใน high-vol period → ใช้ WLS หรือ GARCH-adjusted
No endogeneity	x และ ϵ ไม่ correlate	P_A และ P_B ต่างก็มี measurement noise	β biased → TLS ดีกว่าใน symmetric-noise case (§4.2)

```
from statsmodels.stats.stattools import durbin_watson dw = durbin_watson(model.resid) print(f"Durbin-Watson: {dw:.3f}") # ต้องการใกล้ 2.0 (1.5-2.5 ยอมรับได้)
```

สรุป: ใช้ OLS เป็น baseline ไม่ใช่ oracle — ตรวจ ϵ เสมอ อย่าเชื่อแค่ R^2 และ p-value

สรุป OLS ใน 4 ประโยค

- 1. OLS หา β ที่ทำให้ residual ϵ มี variance ต่ำสุด (minimize $\sum \epsilon^2$)
- 2. $\beta = \text{Cov}(\log P_A, \log P_B) / \text{Var}(\log P_B)$ — ดีความว่า B อธิบาย A ได้กี่ %
- 3. ϵ ที่ได้คือ process ใหม่ที่เทรด — ต้องตรวจ ADF + half-life ก่อนใช้เสมอ
- 4. OLS ให้ β ที่ดีในหลายกรณี แต่ β คงที่ และ sensitive ต่อ window — ถ้า β drift ต้องไต่ขั้นขึ้นไป (Rolling OLS → Kalman)

โจทย์ 4.0 — OLS ที่ละขั้น + ตรวจ ϵ

ได้ข้อมูล log price รายวัน 4 วัน:

วัน	$\log P_B (x)$	$\log P_A (y)$
1	9.00	4.50

2	9.10	4.56
3	9.20	4.64
4	8.90	4.44

(ก) คำนวณ β_{OLS} และ α

(ข) คำนวณ ε สำหรับทุก t และตรวจว่า $\sum \varepsilon_t = 0$

(ค) ถ้า ADF test บน ε ให้ $p=0.31$ ควรทำอย่างไรต่อ?

► **ดูคำตอบ**

4.3 Kalman Filter — Dynamic β ที่เปลี่ยนตามเวลา

OLS และ TLS สมมติว่า β คงที่ตลอด lookback window แต่ในตลาดจริง β อาจเปลี่ยนได้ Kalman Filter แก้ปัญหานี้โดยอัปเดต β ทุก time step:

KALMAN STATE SPACE MODEL

$\beta_t = \beta_{t-1} + w_t$ (state equation: β เดินแบบ random walk)

$r_{A,t} = \beta_t \cdot r_{B,t} + v_t$ (observation equation)


$w_t \sim N(0, Q)$ — process noise (ความเร็วที่ β เปลี่ยน)

$v_t \sim N(0, R)$ — observation noise (noise จากราคา)

Kalman Filter ทำงาน 2 ขั้นตอนซ้ำกันทุก time step:

ขั้น	สูตร	ความหมาย
Predict	$\beta_{t t-1} = \beta_{t-1}, P_{t t-1} = P_{t-1} + Q$	คาดว่า β ตอนนี้เป็นอะไร (ก่อนเห็นข้อมูล)
Update	$K = P \cdot r_B / (r_B^T \cdot P + R)$ $\beta_t = \beta_{t t-1} + K \cdot (r_{A,t} - \beta_{t t-1} \cdot r_{B,t})$ $P_t = (1 - K \cdot r_B) \cdot P$	ปรับ β ตามข้อมูลจริงที่เพิ่งเห็น

K คือ **Kalman Gain** — ถ้า Q สูง (β เปลี่ยนเร็ว) K ใหญ่ $\rightarrow$ เชื่อข้อมูลใหม่มาก ถ้า R สูง (noisy market) K เล็ก $\rightarrow$ เชื่อ model เก๋ามากกว่า



Rolling OLS กระโดดตาม window boundary — Kalman ค่อยๆ ปรับ → position ขยับน้อยกว่า

4.4 Lookback Window และการ Roll

สำหรับ OLS rolling หรือ Kalman Q/R tuning ต้องเลือก lookback ให้เหมาะกับ strategy:

Lookback	ข้อดี	ข้อเสีย	เหมาะกับ
7 วัน	Responsive ต่อ regime ใหม่	Noisy, β กระโดด	Fast intraday
30 วัน	สมดุล stability/responsiveness	Lag ช้า	Intraday-swing (แนะนำ)
90 วัน	Stable, noise น้อย	ปรับ regime เปลี่ยนช้ามาก	Position trade

Re-estimate β เมื่อไร?

- Daily: re-run OLS บน 30 วันล่าสุด ก่อนตลาดเปิด
- เมื่อ ϵ drift ต่อเนื่อง > 2 วัน $\rightarrow \beta$ เปลี่ยน re-estimate ทันที
- Kalman: ไม่ต้อง re-estimate — อัปเดต continuous ทุก bar

4.5 เลือก β Method ตามวัตถุประสงค์ (Objective-Driven Design)

แก่นความคิด

OLS/TLS/Kalman ไม่ใช่แค่ตัวเลือกที่ดีกว่ากัน — แต่ละตัวถูกออกแบบมาเพื่อวัตถุประสงค์ต่างกัน เลือกให้ตรงกับสิ่งที่ต้องการ

สามเส้นทาง: Objective-to- ϵ Mapping

วัตถุประสงค์	Model	ϵ target (variance)	แหล่งกำไรหลัก
Funding Rate Harvest Perp $\leftrightarrow$ Perp / Spot $\leftrightarrow$ Perp	Kalman Filter (dynamic β_t)	$\sigma^2 \rightarrow 0$ — กราฟแบนขนาน ศูนย์	Funding rate yield — เพิ่ม leverage ปลอดภัยได้เพราะ price risk ≈ 0
Hybrid: Spread + Funding Spot $\leftrightarrow$ Future / Pairs Trading	OLS/TLS (static β) + walk-forward	σ_{stat} "Optimal Substantial" — กว้างพอกว่า friction แต่ half-life สั้น	Capital gain จาก mean reversion และ basis/funding
Volatility Arbitrage Spot $\leftrightarrow$ Option (ชั้นสูง)	GARCH(1,1) + Delta-Neutral hedge	Dynamic — ขึ้นกับ IV regime — กรอง vol clustering ด้วย GARCH	IV mispricing บน Options surface — นอกขอบเขตหนังสือนี้

อธิบายเชิงแนวคิด

Funding Rate Harvest — ต้องการ $\epsilon_t \rightarrow 0$

เป้าหมายคือ market-neutral perfect hedge: Kalman β_t ปรับทุก bar ตาม cost-of-carry จริง ทำให้ $\epsilon_t \approx 0$ ตลอดเวลา PnL ทั้งหมดมาจาก **funding rate เท่านั้น** ไม่ใช่ price movement ยิ่ง ϵ เล็กยิ่งดี — แสดงว่า hedge สมบูรณ์



Spread Arbitrage — ต้องการ ε_t เกว่งรอบ 0

OLS lock β จากอดีต — ความไม่สมบูรณ์ของ hedge นี้เองคือแหล่งกำไร ε_t ที่มี variance สูงหมายถึงโอกาสเทรดมาก เมื่อ ε เบี่ยงจาก mean $\rightarrow$ entry; เมื่อ revert กลับ $\rightarrow$ exit

ความเข้าใจผิดที่พบบ่อย

Kalman ไม่ได้ "ดีกว่า" OLS เสมอ — ถ้าใช้ Kalman กับ Spread Arb จะได้ $\varepsilon \rightarrow 0$ ซึ่งทำให้ไม่มีสัญญาณ เพราะ β_t ปรับตัวจนกำจัด spread ออกไปหมด ต้องเลือก method ให้ตรงกับ **สิ่งที่ต้องการให้ ε ทำ**

ε_t ตามเวลา: เป้าหมายต่างกันตามกลยุทธ์



ซ้าย: Kalman ε_t แบน — Funding Harvest ($\sigma^2 \rightarrow 0$) | ขวา: OLS ε_t เกว่ง — Hybrid/Spread Arb (σ_{stat} "Optimal")

Breakeven σ_{stat} — เส้นแบ่ง "Optimal Substantial Variance"

สำหรับ Hybrid Strategy สิ่งที่กำหนด "กว้างพอ" ของ σ_{stat} คือสมการ Breakeven จาก [บทที่ 19.7](#):

BREAKEVEN Σ CONDITION

$$\sigma_{\text{stat}} \geq \text{total_friction_cost} / (z_{\text{entry}} - z_{\text{exit}})$$

ถ้า σ_{stat} ต่ำกว่า threshold นี้ $\rightarrow$ gross spread ที่ entry ไม่ครอบคลุม friction $\rightarrow$ net_edge < 0
 $\rightarrow$ ห้ามเทรด

Optimal Substantial Variance — นิยามเชิงปฏิบัติ

σ_{stat} ที่ "พอเหมาะ" ต้องตอบ **สองเงื่อนไขพร้อมกัน**:

- **Lower bound:** $\sigma_{\text{stat}} \geq \text{total_cost} / (z_{\text{entry}} - z_{\text{exit}}) \rightarrow$ กว้างพอกว่า friction (breakeven condition)

- **Upper bound:** Half-life $\leq N$ bars $\rightarrow$ spread ไม่ค้างนานเกินไปจน margin cost กินกำไร

ช่วงระหว่าง lower–upper bound นี้คือ "Tradeable Window" ของกลยุทธ์ Hybrid

ตัวอย่าง Bybit↔Lighter (taker-taker): total_friction = 19.6 bps (ดู ch19)
 $z_{\text{entry}} = 2.0, z_{\text{exit}} = 0.5$ Breakeven $\sigma_{\text{stat}} = 19.6 / (2.0 - 0.5) = 13.1$ bps
 (0.131%) วัดได้จริง: $\sigma_{\text{stat}} = 30$ bps (0.30%) ส่วนเกิน = $30 - 13.1 = 16.9$ bps $\leftarrow$
 gross edge สุทธิต่อรอบ ☒ $\sigma_{\text{stat}} > \text{Breakeven } \sigma \rightarrow \text{trade ได้}$ ☒ ถ้า $\sigma_{\text{stat}} = 10$ bps
 $\rightarrow 10 < 13.1 \rightarrow$ ห้ามเทรด

Running Example: Bybit ↔ Lighter — สองเส้นทาง

กลยุทธ์ที่ 1 – Funding Rate Harvest (Kalman): ใช้ Kalman $\beta_t \rightarrow \varepsilon_t$ แบนราบ ≈ 0 Bybit funding rate $0.01\%/8h = 10$ bps/day คือ PnL ทั้งหมด price risk $\approx$ hedged ออกไปเกือบสมบูรณ์ กลยุทธ์ที่ 2 – Spread Arbitrage (OLS): ใช้ OLS $\beta = 1.002$ (ค่าคงที่จาก 30d window) ε_t แกว่ง $\pm 0.3\%$, Half-life 7.4h คือโอกาสเทรด entry เมื่อ $z\text{-score} > 2\sigma$, exit เมื่อ revert หนังสือเล่มนี้: $\rightarrow$ Spread Arb path (OLS/TLS) = running example หลัก (ch5–ch14) $\rightarrow$ Kalman สำหรับ Funding Harvest = ch15

4.6 การหา β ในทางปฏิบัติ — เลือกข้อมูล ประเมินคุณภาพ และข้อผิดพลาด

ก่อนลงรายละเอียดว่าใช้ method ไหน ต้องเข้าใจ **ตำแหน่งของ β** ในภาพใหญ่ก่อน — สิ่งที่เราต้องการสร้างจริงๆ ไม่ใช่ β แต่เป็น ε (**synthetic process**) ส่วน β คือแกนสำคัญที่สุดที่ทำให้สร้าง ε ได้ ถูกสัดส่วน

แก่นความคิด — B คือสูตรผสม, E คือของใหม่ที่เกิดจากการผสม

$$\varepsilon = F(A) - \beta \cdot F(B)$$

β คือ **อัตราส่วนผสม (mixing ratio / hedge ratio)** ที่ตอบว่า "ถ้ามี A 1 หน่วย ต้องใช้ B กี่หน่วยมาหักล้าง?" — ประโยคที่แม่นยำที่สุดคือ: **β คืออัตราส่วนที่ใช้ผสมสองสิ่ง เพื่อให้ได้ ε ที่มีคุณสมบัติเทรตได้**

β	สมการ ε	ความหมายของการผสม
$\beta = 1$	$\varepsilon = A - B$	ผสม 1:1 — ใช้ B เท่ากับ A
$\beta = 0.8$	$\varepsilon = A - 0.8B$	ใช้ B แค่ 0.8 เท่าของ A
$\beta = 1.3$	$\varepsilon = A - 1.3B$	ใช้ B มากกว่า A เพื่อหักล้าง exposure ให้พอดี

ตัวอย่างง่าย — ทำไมไม่ดูแค่ $A - B$

ให้ $A = \text{BTC basis บน Lighter}$, $B = \text{BTC basis บน Bybit}$ — เราไม่ดูแค่ผลต่างดิบ $A - B$ แต่ดู $\varepsilon = A - \beta B$ เพราะ β ตอบว่า "Bybit basis ควรถูกถ่วงน้ำหนักเท่าไร จึงหักล้าง Lighter basis ได้พอดี" ถ้าถ่วงผิดพลาดส่วนที่เหลือจะไม่ใช่อินิฟิเซียนซี แต่เป็น market move ที่หักล้างไม่หมด $\rightarrow$ signal หลอก

β กำหนดว่า process ใหม่จะ "หน้าตา" เป็นอย่างไร — มันไม่ใช่แค่ตัวเลขประกอบสูตร แต่เป็น**ตัวกำหนดโครงสร้างของ synthetic process**:

β ดี $\rightarrow \varepsilon$ ที่เทรตได้


common movement ถูกหักล้าง $\cdot \varepsilon$ นิ่งขึ้น $\cdot$ mean reversion ชัดขึ้น $\cdot$ เป็น risk-neutral จริง

β ผิด → process หลอก

ε drift · signal หลอก · กลายเป็น directional bet · position size ผิด · risk สูงกว่าที่คิด

β อยู่ตรงไหนใน Pipeline

β สำคัญมาก แต่ไม่ใช่ทุกอย่าง — มันเป็นขั้นที่ 3 ของกระบวนการสร้าง process ต้องมี pair selection + transformation มาก่อน และมี diagnostics + execution gate ตามหลัง:



β เป็นขั้นที่ 3 — ขาดขั้นไหนก็สร้าง ε ที่เทรดได้จริงไม่ได้ บทที่ 4 โฟกัสที่ขั้น Beta

β เป็นแนวคิดทั่วไป — ใน option เรียกว่า Delta

หลักการ "หาอัตราส่วนที่ถูกต้องเพื่อสร้าง process ใหม่" ใช้ได้กับทุก asset class — ใน option process: $\epsilon = \text{Option} - \Delta \cdot \text{Underlying}$ โดย Δ (delta) ทำหน้าที่เป็น hedge ratio แทน β แนวคิดเดียวกัน: ไม่จำเป็นต้องผสม 1:1

ที่เหลือของ §4.6 เจาะเรื่องที่ทำให้ β ใช้ได้จริง ไม่ใช่แค่ตัวเลขสวยบน backtest: เลือกข้อมูลที่ถูกต้อง (§4.6.1) · เข้าใจว่า β หักล้างอะไร (§4.6.2) · เลือก method ตามสถานการณ์ (§4.6.3–4.6.4) · ประเมินคุณภาพและเสี่ยงกับดัก (§4.6.5–4.6.6)

4.6.1 regress ข้อมูลแบบไหน — Raw Price, Log Price หรือ Basis

แก่นความคิด

β ไม่มีค่าตายตัว — ค่ามันขึ้นกับว่าคุณ regress ราคาดิบ, log price, หรือ basis สามแบบนี้ให้ β คนละตัวเลข และตอบคนละคำถาม

Input ที่ regress	สมการ ϵ	ใช้เมื่อ	β หมายถึงอะไร
Raw price	$\epsilon = P_A - \beta \cdot P_B$	scale ราคาใกล้เคียงกัน / ต้องการดูภาพ scatter	\$ ของ A ต่อ \$1 ของ B — ขึ้นกับ scale ราคา
Log price	$\epsilon = \log P_A - \beta \cdot \log P_B$	default — pairs ทั่วไป (ที่หนังสือเล่มนี้ใช้)	elasticity: %A ต่อ %B — scale-invariant
Basis / spread	$\epsilon = \text{basis}_A - \beta \cdot \text{basis}_B$	funding arb, perp $\leftrightarrow$ perp, swap arb (บทที่ 21)	sensitivity ของ basis ขาหนึ่งต่ออีกขา

BTC/ETH — ทำไม $\beta = 0.0444$ จึงลอกตา

ภาพวิเคราะห์ BTC/ETH ที่นิยมแชร์กัน fit regression บน **ราคาดิบ**: $\text{ETH} = \alpha + \beta \cdot \text{BTC}$ ได้ $\beta = 0.0444$ ตัวเลขนี้แปลว่า "ETH ขยับ \$0.0444 ต่อทุก \$1 ที่ BTC ขยับ" — มันถูกในเชิงเลขคณิต แต่ **ขึ้นกับระดับราคา**: ถ้า BTC แลก scale (เช่น redenominate $\div 10$) β จะกลายเป็น 0.444 แทนที่ ทั้งที่ความสัมพันธ์จริงไม่เปลี่ยน

ถ้า regress **log price** แทน: $\log(\text{ETH}) = \alpha + \beta \cdot \log(\text{BTC})$ จะได้ β เป็น **elasticity** (สำหรับ crypto major มักใกล้ 1) — ค่านี้ไม่เปลี่ยนตาม scale ราคา จึงเอาไป calibrate ข้าม regime ได้ปลอดภัยกว่า หนังสือเล่มนี้ใช้สมการ $\epsilon = \log P_A - \beta \cdot \log P_B$ เป็นมาตรฐานด้วยเหตุผลนี้

อย่าเอา raw-price β ไปใส่ position โดยตรง

$\beta = 0.0444$ เป็นแค่ slope บนกราฟ scatter — ต้องแปลงเป็น **กฎกำหนดขนาด position** ที่ทำให้ exposure ต่อ common factor หักล้างกัน (ดู §4.6.2) ข้อควรระวัง: hedge ที่ถูกต้อง **ไม่จำเป็น** ต้องเป็น dollar-neutral เป๊ะ — มันคือ **factor-neutral**

4.6.2 β หักล้าง exposure — ไม่ใช่ทำมูลค่าให้เท่ากัน

จุดที่หลายคนสับสน: $A - \beta B$ **ไม่ได้** แปลว่าต้องทำให้ βB มีค่า "เท่ากับ" A ตลอดเวลา — βB คือ **ส่วนของ A ที่ B อธิบายได้** ส่วนที่เหลือคือ ϵ

การแยกส่วน — $A = \text{ส่วนที่เคลื่อนตาม } B + \text{ส่วนผิดปกติ}$

$$A = \beta B + \epsilon$$

βB = "เส้น fair relationship" (ส่วนที่เคลื่อนตาม B) · ε = ส่วนผิดปกติที่เหลือหลังใช้ B อธิบาย A — βB ไม่ใช่ราคาที่ต้องเท่ากับ A เสมอ

สถานะ	ε	ความหมาย
$A = \beta B$	$\varepsilon = 0$	process อยู่ที่ equilibrium / mean
$A > \beta B$	$\varepsilon > 0$	A แพงกว่าที่ควรเป็นเมื่อเทียบกับ B
$A < \beta B$	$\varepsilon < 0$	A ถูกกว่าที่ควรเป็นเมื่อเทียบกับ B

แล้ว β ผิด ทำให้กลายเป็น directional ได้อย่างไร? สมมติ A และ B ถูกขับเคลื่อนด้วยแรงตลาดเดียวกัน (เช่น BTC market factor):

$A = \text{market_factor} + \text{noise_A}$ $B = \text{market_factor} + \text{noise_B}$ β ถูก: $\varepsilon = A - \beta B \approx \text{noise}$ ← market factor ถูกหักล้าง β ผิด: $\varepsilon = A - \beta B = \text{noise} + \text{market exposure}$ ที่ค้างอยู่ ← กลายเป็น directional โดยไม่รู้ตัว



ตัวอย่าง: A เคลื่อนไหวแรงกว่า B ราว 2 เท่า ($A \approx 2B$)

ใช้ $\varepsilon = A - 1 \cdot B$ → ยังเหลือ exposure ต่อ B เยอะ เพราะ A ขยับมากกว่าที่ 1B หักล้างได้

ใช้ $\varepsilon = A - 2 \cdot B$ → ส่วนที่เคลื่อนไหวร่วมกันถูกหักล้างพอดี

→ β ทำให้ ความไวต่อ common factor เท่ากัน ไม่ใช่ทำให้ มูลค่า เท่ากัน

β ถูก vs β ผิด — residual หน้าตาต่างกัน



β ที่ถูกต้องทำให้ ε เป็น residual ที่ mean-revert — β ผิดทำให้ ε ยังพก market exposure ค้างอยู่

แยก 2 คำให้ขาด — ในการเทรดจริงต้องไม่สับสนระหว่าง:

Value / Notional matching

Risk / Factor matching

นิยาม	มูลค่าเงินสองขาเท่ากัน	exposure ต่อ factor สองขาเท่ากัน
ตัวอย่าง	Long A \$10,000 / Short B \$10,000	Long A \$10,000 / Short B \$8,000 (ถ้า B ขยับแรงกว่า)
ให้อะไร	dollar-neutral	hedge ที่ถูกต้องจริง (factor-neutral)

กับดักที่ต้องระวัง

notional เท่ากัน **ไม่ได้แปลว่า** hedge ถูก · notional ไม่เท่ากัน **ไม่ได้แปลว่า** directional — สิ่งที่ตัดสินคือ exposure ต่อ common factor ถูกหักล้างหมดหรือยัง

Bybit ↔ Lighter — $\beta = 0.8$ หรือ 1.2 ไม่ได้แปลว่าตั้งใจ directional

A = basis_Lighter, B = basis_Bybit (BTC perp underlying เดียวกัน) เริ่มจาก $\beta = 1$ (underlying เดียวกัน → baseline) ถ้าข้อมูลบอกว่า basis ของ Lighter เคลื่อนแรง/ช้ากว่า Bybit: $\beta = 0.8$ หรือ $\beta = 1.2$ → ไม่ใช่การตั้งใจเปิด directional → เป็นการปรับ hedge ratio ให้เข้ากับพฤติกรรมจริงของ 2 ตลาด

ทำไมต้องทดสอบ — สมการแสดงที่มาของ exposure ที่เหลือ

เขียน spread change เป็นสมการ:

$$\Delta \varepsilon = (\text{exposure_A} - \beta \times \text{exposure_B}) \times \text{market_return} + \text{noise}$$

ถ้า β ถูกต้อง → $\text{exposure_A} - \beta \times \text{exposure_B} \approx 0 \rightarrow \varepsilon$ ไม่ขึ้นกับตลาด

ถ้า β ผิด → เทอมแรกไม่ใช่ศูนย์ → ε correlate กับ market_return → **directional bet ผ่ง**

β ที่เหมาะสมจึงต้องอยู่ที่:

$$\beta \approx \text{exposure_A} / \text{exposure_B}$$

เช่น BTC Lighter vs BTC Bybit — ถ้า Lighter sensitive ต่อ BTC มากกว่า Bybit $1.2\times \rightarrow \beta \approx 1.2$
ไม่ใช่ 1.0

6 วิธีตรวจว่า ε เป็น residual จริง ไม่ใช่ directional ผ่ง

Test 1 — Correlation กับ market return

$\text{corr}(\Delta\epsilon, \text{market_return})$

- $|r| < 0.20 \rightarrow$ ดี (ϵ แทบไม่ขึ้นกับทิศทางตลาด)
- $|r| > 0.50 \rightarrow \beta$ ยัง hedge ไม่ดี $\rightarrow$ ต้องปรับ β หรือเปลี่ยน pair

Test 2 — Factor regression

$\Delta\epsilon = \alpha + \gamma \cdot \text{market_return} + \text{error}$

- $\gamma \approx 0$ (p-value > 0.05) $\rightarrow$ hedged ดี — market exposure ถูกหักล้างแล้ว
- $|\gamma|$ ใหญ่ (t-stat > 2) $\rightarrow$ exposure ยังหลงเหลือ $\rightarrow \epsilon$ ไม่บริสุทธิ์

Test 3 — PnL แยกตามทิศทางตลาด

- แบ่ง: ตลาดขึ้น $> 1\%$ / ลง $> 1\%$ / Sideways ($\pm 1\%$)
- stat arb จริง $\rightarrow$ PnL กระจายสม่ำเสมอ ไม่ขึ้นกับทิศทาง
- PnL ดีเฉพาะ "ตลาดขึ้น" $\rightarrow$ กำไรมาจาก beta ไม่ใช่ spread reversion

Test 4 — Stationarity (จำเป็นแต่ไม่เพียงพอ)

- ADF / KPSS ต้องผ่าน — แต่ stationarity ไม่ได้พิสูจน์ว่า β ถูก
- ϵ stationary แต่ corr กับตลาดสูง $\rightarrow \beta$ ผิด directional ยังแฝงอยู่
- ϵ non-stationary และ corr สูง $\rightarrow$ pair ไม่ดีทั้งคู่

Test 5 — Half-life และ Crossing Rate

- $\tau_{1/2}$ ต้องอยู่ใน target horizon ([บทที่ 3](#))
- φ ควรอยู่ใน sweet spot 0.85–0.97 สำหรับ swing ([บทที่ 5 §5.7](#))
- ถ้า Test 1–3 ผ่านแต่ half-life ยาวเกิน $\rightarrow$ pair ดี แต่ยังไม่เหมาะ intraday

Test 6 — Rolling β Stability

- คำนวณ $\beta_{30d}, \beta_{60d}, \beta_{90d}$ — ควรใกล้เคียงกัน ($\pm 15\%$)
- β drift เร็ว $\rightarrow$ regime เปลี่ยน $\rightarrow \beta$ เก่าอาจใช้ไม่ได้แล้ว
- ถ้า β drift $\rightarrow$ เปลี่ยนไปใช้ Rolling OLS หรือ Kalman (§4.6.3)

10 สัญญาณเตือน — spread นี้อาจ directional พลอมตัว

1. $|\text{corr}(\Delta\epsilon, \text{market})| > 0.50$ — ϵ ยัง sensitive ต่อทิศทางตลาดอย่างมีนัย
2. $\gamma \neq 0$ อย่างมีนัย (t-stat > 2) ใน factor regression — market exposure ค้างอยู่

3. Sharpe ดีเฉพาะช่วงตลาดขึ้น (bull) — กำไรมาจาก beta ไม่ใช่ mean reversion
4. Drawdown ใหญ่ในระดับเดียวกับ long position เดียวขนาดเดียวกัน — hedge ไม่จริง
5. ε ไม่ผ่าน ADF — spread ไม่กลับ mean เลย
6. Half-life > target holding period — ไม่ทันเก็บกำไร
7. β drift > 20% ภายใน 30 วัน — regime เปลี่ยน β เก่าผิดแล้ว
8. ε correlate กับ implied vol / VIX — รับ volatility premium ปลอมตัวเป็น arb
9. PnL จาก sideways market < 30% ของกำไรรวม — ตลาดต้อง trend ถึงทำกำไร
10. β จาก regression ห่างจาก notional ratio > 30% โดยไม่มีเหตุผลเชิง factor

Checklist ปฏิบัติ — 8 ขั้นตอนก่อน go live

1. คำนวณ $\text{corr}(\Delta\varepsilon, \text{market_return}) \rightarrow$ ต้องการ $|r| < 0.20$
2. Run factor regression $\rightarrow$ ต้องการ $|y|$ ไม่ significant ($p > 0.05$)
3. แบ่ง PnL ตามทิศทางตลาด $\rightarrow$ กระจายสม่ำเสมอ ไม่ขึ้นกับทิศ
4. ตรวจสอบ ADF/KPSS $\rightarrow \varepsilon$ ต้อง stationary ([บทที่ 5](#))
5. คำนวณ half-life และ $\varphi \rightarrow$ อยู่ใน target horizon และ sweet spot
6. Plot rolling β (30d/60d/90d) $\rightarrow$ stability $\pm 15\%$
7. Walk-forward test $\rightarrow \varepsilon$ properties ยังดีใน out-of-sample ([บทที่ 3 §3.9](#))
8. ทบทวนหลัง macro event (Fed meeting / major shock) $\rightarrow \beta$ อาจต้อง recalibrate

Residual ที่ดีควรเหลือ "ความผิดปกติระหว่างสองขา" — ไม่ใช่ "ทิศทางตลาด" ที่ hedge ไม่หมด

ประโยคจำ

β ไม่ได้มีหน้าที่ทำให้ B "ราคาเท่ากับ" A — β มีหน้าที่ทำให้ B "หักล้าง exposure ของ A" ได้เหมาะสม

ถ้า β ดี สิ่งที่เหลือคือ residual · ถ้า β แย่ สิ่งที่เหลือคือ directional bet ที่ปลอมตัวเป็น stat arb

4.6.3 เมนูเต็มของวิธีหา β

§4.2–4.3 อธิบาย OLS / TLS / Kalman เชิงลึก — ตารางนี้รวมทุกวิธีไว้เป็น "เมนู" เดียวเพื่อเลือกใช้ตามสถานการณ์:

วิธี

ใช้เมื่อ


ข้อดี

ข้อเสีย

$\beta = 1$	สินทรัพย์เดียวกัน, exposure เท่ากัน (BTC perp $\leftrightarrow$ BTC perp)	ง่ายสุด, ไม่ overfit	หยาบ — venue ต่างกันเรื่อง funding/index/liquidity
Contract ratio	crack spread / product ที่ มี ratio เชิงกลไกชัดเจน	mechanism ชัด ไม่ ต้อง fit	ใช้ได้เฉพาะบางตลาด
OLS	pair 2 ตัวทั่วไป — baseline เริ่มต้น	ง่าย, เร็ว, ดีความได้	β คงที่ — อาจ outdate เมื่อ regime เปลี่ยน
Rolling OLS	ความสัมพันธ์เปลี่ยนตาม regime	adaptive กว่า OLS static	noisy ถ้า window สั้นเกิน
TLS	ทั้ง X และ Y มี noise พอๆ กัน	สมดุลกว่า OLS (ดู §4.2)	ซับซ้อนขึ้น, ดีความยากกว่า
Kalman	β เปลี่ยนตลอดเวลา / Funding Harvest (§4.5)	dynamic, online update	overfit ง่าย, tune Q/R ยาก
Johansen	multi-leg / basket (≥ 3 ขา)	หา cointegrating vector หลายขาพร้อม กัน	overfit ง่าย, ต้องระวังเป็นพิเศษ
Greek (Delta/Vega)	options / volatility strategy	ตรงกับโครงสร้าง option	ต้อง update ตลอดเพราะ Greek เปลี่ยน

4.6.4 Roadmap — เริ่มจากง่าย ค่อยไปยาก

ข้อผิดพลาดที่พบบ่อยคือเริ่มจาก Kalman ทันทีเพราะ "ดูฉลาด" — แต่ Kalman มีพารามิเตอร์ให้ tune เยอะ
จึง overfit ง่ายมากเมื่อข้อมูลยังน้อย ลำดับที่แนะนำสำหรับ scanner v1:



4.6.5 β ดีหรือไม่ดี ดูยังไง — Checklist 7 ข้อ

β ที่ดี ไม่ใช่ β ที่ทำให้กราฟ backtest สวยที่สุด — แต่คือ β ที่ทำให้ process เทรดได้จริงและ robust ใช้ checklist นี้:

เกณฑ์ประเมิน β

1. ϵ stationary มากขึ้น — ADF p-value ต่ำลง / KPSS ดีขึ้น ([บทที่ 5](#))
2. Half-life เหมาะกับ horizon — ไม่สั้นจนจับไม่ทัน ไม่ยาวจน margin cost กิน ([บทที่ 3](#))
3. Crossing behavior ดี — ϕ อยู่ใน sweet spot ([บทที่ 5 §5.7](#))
4. Residual ไม่ drift — ϵ ไม่ค่อยๆ ไหลไปทางเดียว (ไม่มี trend แฝง)
5. Net edge หลัง cost ยังเหลือ — $\sigma_{\text{stat}} \geq \text{breakeven } \sigma$ ([§4.5](#))
6. Position ไม่กลายเป็น directional bet — factor-neutral จริง: ϵ ไม่ correlate กับ underlying/market (ดู §4.6.2)
7. β เสถียรพอใน out-of-sample — ผ่าน walk-forward validation ([บทที่ 3 §3.9](#))

4.6.6 ข้อผิดพลาดที่พบบ่อย

7 กับดักเรื่องการหา β

1. ใช้ $\beta = 1$ กับทุกอย่าง — สะดวกแต่หยาบ; venue ต่างกันมักทำให้ ϵ มี bias
2. ใช้ราคาดิบแทน log price / basis — β กลายเป็นตัวเลขที่ขึ้นกับ scale (ดู §4.6.1)
3. หา β จากข้อมูลทั้งหมดรวมอนาคต — look-ahead bias; ต้อง fit บน train window เท่านั้น
4. ใช้ window ยาวเกินไป — β ตามไม่ทัน regime ใหม่
5. Rolling window สั้นเกินไป — β noisy กระโดด $\rightarrow$ position ขยับถี่จน friction กิน
6. เลือก β ที่ backtest สวยที่สุด — overfit; ต้องผ่าน OOS / paper validation ก่อน
7. ลืมแปลง β เป็น position size จริง — β บน regression $\neq$ notional ratio ที่ trade

```
import statsmodels.api as sm
import numpy as np

# regress บน LOG price
# (มาตรฐานของหนังสือ) — ใช้ข้อมูล train window เท่านั้น
y = np.log(train["price_A"])
x = np.log(train["price_B"])
model = sm.OLS(y, sm.add_constant(x)).fit()
alpha = model.params["const"]
beta = model.params.iloc[1]  # hedge ratio
epsilon = y - (alpha + beta * x)  # diagnostics ใช้ residual รวม alpha

# ตอนแปลงเป็น position
# จริง: alpha เป็นค่าคงที่ของ model ไม่ใช่ขา trade
# long  $\epsilon \rightarrow$  long $X ของ A, short $X ของ B (dollar-neutral)
```

Running Example: BTC/ETH — จากภาพวิเคราะห์สู่ β ที่ใช้ได้จริง

ภาพวิเคราะห์ (regress ราคาดิบ ETH บน BTC): $\beta_{\text{raw}} = 0.0444 \leftarrow$ slope บน scatter — ขึ้นกับ scale ราคา $\text{Corr} = 0.9745$ ✓ ผ่าน correlation screen (≥ 0.70) $\text{AR}(1)$ $\varphi = 0.9602$ Half-Life = 17.08 ชม. ($-\ln 2 / \ln 0.9602 \approx 17.06$ ✓) แปลงให้ถูกหลักของหนังสือ — regress log price: $\varepsilon = \log(\text{ETH}) - \beta_{\text{log}} \cdot \log(\text{BTC})$ $\beta_{\text{log}} \approx$ elasticity (crypto major มักใกล้ 1) — scale-invariant ผ่าน Checklist §4.6.5: 1. stationary — Half-life 17h $\rightarrow \varepsilon$ mean-reverting ✓ 3. crossing $\varphi=0.96$ — นอก intraday sweet spot $\rightarrow$ swing เท่านั้น (ch5 §5.7) 7. walk-forward — ต้อง re-check β ทุก window (ch3 §3.9) สรุป: ใช้ $\beta_{\text{log}} +$ dollar-neutral notional $\rightarrow$ trade เป็น overnight swing อย่าใช้ $\beta_{\text{raw}} = 0.0444$ ใส่ position ตรงๆ

โจทย์ 4.6 — เลือกชนิดข้อมูลที่จะ regress

คุณจะทำ β ของสามคู่นี้:

- (ก) BTC perp บน Bybit $\leftrightarrow$ BTC perp บน Lighter
- (ข) PAXG (gold token) $\leftrightarrow$ XAUUSD spot
- (ค) ETH spot $\leftrightarrow$ ETH perpetual (เก็บ funding)

ถาม: แต่ละคู่ควร regress raw price, log price, หรือ basis?

► คำตอบ

4.7 Pseudo-code

```
# OLS Beta
function beta_ols(r_A, r_B):
    return cov(r_A, r_B) / var(r_B)

# TLS Beta (via eigenvalue)
function beta_tls(r_A, r_B):
    C = cov_matrix([[r_A], [r_B]]) # 2x2
    eigenvalues, eigenvectors = eig(C)
    v = eigenvectors[:, argmin(eigenvalues)] # smallest eigenvalue
    return -v[0] / v[1]

# Kalman Filter Beta (one-step update)
function kalman_beta_update(beta, P, r_A, r_B, Q, R):
    # Predict
    P_pred = P + Q
    # Kalman gain
    K = P_pred * r_B / (r_B**2 * P_pred + R)
    # Update
    innovation = r_A - beta * r_B
    beta_new = beta + K * innovation
    P_new = (1 - K * r_B) * P_pred
    return beta_new, P_new
```

Running Example: β ของ Bybit $\leftrightarrow$ Lighter BTC Perp

ข้อมูล: 30 วัน, log returns รายวันที่ OLS (30d window): $\beta_{OLS} = \text{Cov}(r_{\text{Bybit}}, r_{\text{Lighter}}) / \text{Var}(r_{\text{Lighter}}) = 0.00000412 / 0.00000410 = 1.0049$ TLS: $\beta_{TLS} = 1.0063$ (เล็กน้อยกว่า OLS) Kalman ($Q=1e-7$, $R=1e-5$, warmup 14 วัน): $\beta_{\text{Kalman}_t} \approx 1.003 \pm 0.002$ (เปลี่ยนช้าๆ) ผลกระทบต่อ position: Long Bybit \$100,000: OLS: Short Lighter \$100,490 TLS: Short Lighter \$100,630 Kalman: Short Lighter \$100,300 ต่างกัน \$300-\$630 – ดูเล็กน้อย แต่ถ้า trade 100x/เดือน = \$30,000-\$63,000 ต่างกัน

โจทย์ 4.5 — เลือก Method ให้ตรงวัตถุประสงค์

บริษัท Quant เปิดสองกลยุทธ์:

- (ก) ใช้ Kalman β_t และ target $\varepsilon_t \approx 0$
- (ข) ใช้ OLS β และ z-score entry/exit

ถาม: กลยุทธ์ไหนทำกำไรจาก funding rate? กลยุทธ์ไหนทำกำไรจาก price inefficiency?

► ดูคำตอบ

โจทย์ 4.1 — คำนวณ β_{OLS} จากข้อมูล

Log returns รายวัน 5 วัน:

วัน	r_Bybit (%)	r_Lighter (%)
1	+1.20	+1.15
2	-0.80	-0.75
3	+2.10	+2.05
4	-1.50	-1.48
5	+0.60	+0.58

ถาม: คำนวณ β_{OLS} (Bybit เป็น A, Lighter เป็น B)

► ดูคำตอบ

โจทย์ 4.2 — เลือกวิธีหา β

คุณ trade spread ระหว่าง BTC perpetual บน Binance (volume 10× ของ Lighter) กับ Lighter ทั้งสองตลาดมี liquidity ต่างกันมาก — Binance เป็น "price discovery" หลัก

ถาม: ควรใช้ OLS หรือ TLS? และ Binance ควรเป็น A หรือ B ใน regression?

► ดูคำตอบ

โจทย์ 4.3 — Kalman Q/R tuning

คุณตั้ง Kalman กับ $Q=1e-9$ (เล็กมาก) และ $R=1e-4$ (ใหญ่มาก)

สังเกตว่า β_{Kalman} แทบไม่เปลี่ยนแปลง แม้ตลาดจะเปลี่ยน

ถาม: อธิบายว่าเกิดอะไรขึ้น และควรปรับ Q หรือ R อย่างไร?

► คำตอบ

Ch.4 Hedge Ratio β | ต่อไป → Ch.5: Cointegration Tests