

Jump-Diffusion OU: จัดการ Fat Tail ใน Spread

ตรวจจับ jump events และปรับกลยุทธ์เมื่อ spread กระโดดผิดปกติ

ตัวอย่างหลัก: Bybit BTC Perp ↔ Lighter BTC Perp

แก่นของบทนี้ — อ่านก่อน

spread เดินตาม OU แต่มี **jump discontinuity** แทรก — เหตุการณ์ผิดปกติที่ทำให้ spread กระโดดทันทีโดยไม่ผ่าน diffusion ปกติ ต้องตรวจจับและจัดการแยกต่างหาก


$$d\varepsilon = \kappa(\theta - \varepsilon)dt + \sigma dW + J \cdot dN$$

8.1 ทำไม OU ปกติไม่พอ

โมเดล OU มาตรฐาน $de = \kappa(\theta - e)dt + \sigma dW$ สมมติว่า residual กระจายตัวแบบ **Normal** — แต่ในความเป็นจริง spread ของสินทรัพย์ crypto มี **fat tail**: เหตุการณ์ที่ห่างจากค่าเฉลี่ย $4-6\sigma$ เกิดบ่อยกว่าที่ Normal distribution คาดไว้มาก

อาการของ fat tail ที่พบในทางปฏิบัติ

- Spread กระโดด $3-5\sigma$ ใน tick เดียว (ไม่ใช่ค่อยๆ เพิ่ม)
- Stop-loss ถูก trigger บ่อยกว่าที่ backtest คาดไว้
- Sharpe ratio ใน live trading ต่ำกว่า backtest อย่างมีนัยสำคัญ
- Kurtosis ของ residuals > 3 (leptokurtic)



Histogram ของ spread returns (แท่ง teal) vs Normal curve (เส้นประน้ำเงิน) — ทางซ้าย-ขวาหนากว่า Normal มาก

เมื่อ fat tail มีอยู่จริง โมเดล OU ล้วนๆ จะ **underestimate** ความน่าจะเป็นของเหตุการณ์รุนแรง ทำให้ sizing และ stop-loss ผิดพลาด

8.2 Jump-Diffusion SDE

เราขยาย OU model โดยเพิ่ม jump component เข้าไป:

JUMP-DIFFUSION OU — สมการหลัก

$$d\epsilon = \kappa(\theta - \epsilon)dt + \sigma dW + J \cdot dN$$

κ = mean-reversion speed (เหมือนเดิม)

θ = long-run mean (เหมือนเดิม)

σdW = diffusion term (Brownian motion ปกติ)

dN = Poisson process, $P(dN=1 \text{ ใน } dt) = \lambda \cdot dt$ — jump เกิดด้วย intensity λ

J = jump size (random variable, distribution ขึ้นกับโมเดล)

สัญชาตญาณ: ส่วนใหญ่ spread เดินแบบ OU ปกติ แต่ทุกครั้งที่ Poisson event เกิด (เฉลี่ยทุก $1/\lambda$ หน่วยเวลา) spread กระโดดทันที ด้วย random size J

Component	ความหมาย	ตัวอย่างค่า
κ (kappa)	ความเร็วในการกลับหา θ	0.5–5.0 ต่อวัน
σ (sigma)	Volatility ของ diffusion ส่วน	0.001–0.01
λ (lambda)	Jump intensity (jumps/วัน)	0.1–2.0
J (jump size)	ขนาดการกระโดด (สุ่ม)	$\pm 2-10\sigma$

8.3 Merton vs Kou Jump Model

มีสองโมเดลหลักสำหรับกำหนด distribution ของ jump size J :

Merton Jump Model (1976)

$J \sim N(\mu_J, \sigma_J^2)$ — กระจายแบบ Normal

Jump size สุ่มมาจาก Normal distribution — symmetric รอบ μ_J

ถ้า $\mu_J = 0$: jump ขึ้นและลงมีโอกาสเท่ากัน

ถ้า $\mu_J < 0$: jump มักลงมากกว่าขึ้น (เหมาะกับ crash scenario)

$J \sim N(\mu_J, \sigma_J^2)$ ตัวอย่าง: $\mu_J = 0, \sigma_J = 0.005 \rightarrow$ Jump ส่วนใหญ่อยู่ในช่วง $\pm 1\%$ ($\pm 2\sigma_J$)

Kou Double-Exponential Model (2002)

$J \sim$ Asymmetric double exponential — up jump และ down jump ต่างกัน

ด้วยความน่าจะเป็น p : jump ขึ้น ขนาด $\sim \text{Exp}(\eta_1)$ (exponential)

ด้วยความน่าจะเป็น $1-p$: jump ลง ขนาด $\sim \text{Exp}(\eta_2)$

ทำให้ tail ขึ้นและลง asymmetric ได้ตามจริง

$J = \{ +\text{Exp}(\eta_1) \text{ ด้วยความน่าจะเป็น } p, -\text{Exp}(\eta_2) \text{ ด้วยความน่าจะเป็น } 1-p \}$ ตัวอย่าง: $p=0.4, \eta_1=200, \eta_2=100 \rightarrow$ Down jump มักใหญ่กว่า up jump (tail ซ้ายหนักกว่า)

คุณสมบัติ	Merton	Kou
Distribution ของ J	Normal $N(\mu_J, \sigma_J^2)$	Double exponential (asymmetric)
Symmetry	Symmetric (ถ้า $\mu_J=0$)	Asymmetric ($p \neq 0.5$)
Parameters	λ, μ_J, σ_J (3 params)	$\lambda, p, \eta_1, \eta_2$ (4 params)
Tail behavior	Lighter tail	Heavier, asymmetric tail
Fit ดีเมื่อ	Jump ขึ้น-ลงสมมาตร	Crash มักใหญ่กว่า rally

เมื่อไรควรใช้ Kou แทน Merton?

- Spread มักกระโดด **ลง** แรงกว่ากระโดดขึ้น (เช่น leverage liquidation)
- ช่วง funding rate war ที่ขา bear รุนแรงกว่าขา bull
- เมื่อ backtest Merton แล้ว over-estimated $P(\text{positive jump})$

8.4 Lee-Mykland Jump Detection

วิธีตรวจจับ jump ที่ใช้กันมากในทางปฏิบัติคือ **Lee-Mykland (2008)** ซึ่งสร้าง test statistic จาก bipower variation:

LEE-MYKLAND TEST STATISTIC


$$L_t = (\varepsilon_t - \varepsilon_{t-1}) / \sigma_{BV}$$

σ_{BV} = bipower variation estimator (robust ต่อ jump ของตัวเอง)

ถ้า $|L_t| > c_{\text{threshold}}$ → detect jump ที่เวลา t

threshold $c = 4.0$ เป็นค่าที่ใช้บ่อย (corresponds to p-value ต่ำมาก)

ข้อดีของ bipower variation: ถ้า σ_{BV} คำนวณจาก squared returns ปกติ jump ขนาดใหญ่จะ inflate σ ทำให้ L_t เล็กลงและพลาด jump แต่ bipower variation ใช้ product ของ adjacent absolute returns ซึ่ง robust กว่า



Timeline ของ ε : ส่วนใหญ่ mean-revert ปกติ แต่มี jump spikes ที่ถูก flag ด้วย Lee-Mykland test

8.5 Pseudo-code: detect_jump()

ต่อไปนี้เป็น algorithm สำหรับตรวจจับ jump ด้วย bipower variation:

```
def detect_jump(residuals, window=30, threshold=4.0): """ ตรวจจับ jump ใน residual
series ด้วย Lee-Mykland test Parameters ----- residuals : array-like --  $\varepsilon_t$ 
series window : int -- rolling window สำหรับ bipower variation threshold : float --
 $|L_t| > \text{threshold} \rightarrow \text{jump}$  Returns ----- jumps : bool array -- True ที่ index ที่เป็น
jump L : float array -- test statistic  $L_t$  ทุก time step """ bipower =
compute_bipower_variation(residuals, window) # bipower variation: sum of  $|r_t| *
|r_{t-1}|$  (robust ต่อ jump) sigma_bv = sqrt(bipower / window) L = diff(residuals) /
sigma_bv #  $L_t = (\varepsilon_t - \varepsilon_{t-1}) / \text{sigma}_{BV}$  jumps = abs(L) > threshold return
jumps, L
def compute_bipower_variation(residuals, window): """  $BV_t = (\pi/2) *
\sum_{i=t-w}^{t-1} |r_i| * |r_{i-1}|$  """ r = diff(residuals) bv =
rolling_sum(abs(r[:-1]) * abs(r[1:]), window) return (pi / 2) * bv
```

หมายเหตุการ implement จริง

- ใช้ window=30 ถ้า data เป็น minute bars $\rightarrow$ window = 30 นาที
- threshold=4.0 เทียบเท่ากับ p-value < 0.001 สำหรับ Normal distribution
- หลังจาก flag jump ให้ **exclude** observation นั้นออกจากการ calibrate σ เพื่อไม่ให้ inflate
- ในทางปฏิบัติ ใช้ library realized (R) หรือเขียน custom ใน Python

8.6 วิธีจัดการ Jump ในกลยุทธ์

เมื่อตรวจพบ jump มี 3 approaches หลักที่ใช้กัน:

Approach 1 — หยุด Signal ชั่วคราว (Signal Pause)

เมื่อ detect_jump() = True → ไม่เปิด position ใหม่ชั่วคราว
รอให้ L_t กลับมามากกว่า threshold ก่อน (เช่น รอ 5–15 tick)

ข้อดี: ปลอดภัยสุด ไม่เข้าไปใน noise

ข้อเสีย: พลาด opportunity ถ้า jump เป็น "overreaction" ที่จะ revert

Approach 2 — ขยาย Stop-Loss (Wider Stop)

ปรับ stop-loss จาก $\pm 2\sigma$ เป็น $\pm 4\sigma$ ชั่วคราวเมื่อ jump detected
ยังเปิด position ได้ แต่ tolerance กว้างขึ้น

ข้อดี: ไม่ถูก stop out โดยไม่จำเป็น

ข้อเสีย: ถ้า jump ไม่ revert จะขาดทุนมากขึ้น

Approach 3 — ลด Position Size (Reduce Size)

ลด size ลง 50% เมื่ออยู่ใน "jump window" (เช่น 10 tick หลัง jump)
trade ต่อได้ แต่ risk น้อยลง

ข้อดี: balance ระหว่าง opportunity และ risk

ข้อเสีย: ซับซ้อนกว่า ต้องมี position sizing logic เพิ่ม

Approach	เหมาะกับ	ความซับซ้อน	Risk
Signal Pause	เริ่มต้น, conservative	ต่ำ	ต่ำสุด
Wider Stop	มั่นใจว่า jump จะ revert	ปานกลาง	ปานกลาง
Reduce Size	อยากเก็บ opportunity	สูง	ปานกลาง

8.7 Running Example: Bybit ↔ Lighter และ Funding Rate War

Running Example: Bybit BTCUSDT Perp ↔ Lighter BTCUSDT Perp — Jump Event

ช่วง **funding rate war**: Bybit ประกาศปรับ funding rate เป็น 0.09% ต่อ 8 ชั่วโมง (ปกติ 0.01%) เพื่อดึง short position

Fitted Jump Model Parameters (90-day calibration)

Model: Merton Jump-Diffusion ($J \sim N(\mu_J, \sigma_J^2)$) Estimated from Bybit↔Lighter BTCUSDT Perp, 90 วัน (tick data): $\lambda = 0.8$ jumps/day (≈ 1 jump ทุก 30h) $\mu_J = 0.0\%$ (symmetric – jumps ไม่ bias ทิศทาง) $\sigma_J = 4 \times \sigma_{\text{stat}} = 4 \times 0.003 = 0.012$ (1.2%) σ_{BV} (bipower variation ช่วงปกติ, 30-bar window): $\sigma_{\text{BV}} \approx 0.0018\text{--}0.0022$ per tick → ใช้ 0.002 ต่อ tick Probability check (Merton): $P(|J| > 5.5\sigma_{\text{stat}} \mid \text{jump occurs}) = P(|N(0, 4^2)| > 5.5) \approx 17\%$ $P(|\text{move}| > 5.5\sigma_{\text{stat}} \mid \text{no jump}) = P(|N(0, 1)| > 5.5) \approx 0.0000038\%$ Likelihood ratio: $17\% / 0.0000038\% \approx 4,500,000\times$ → unambiguously a jump

ผลกระทบต่อ spread:

- Bybit perp premium เพิ่มขึ้นทันทีจาก \$10 → \$80 ใน 2 นาที (8x)
- spread ε กระโดด $\sim 5.5\sigma_{\text{stat}} = 5.5 \times 0.003 = 0.0165$ (1.65%)
- $L_t = \Delta\varepsilon / \sigma_{\text{BV}} = 0.0165 / 0.002 = \mathbf{8.25} > \text{threshold } 4.0$ → confirmed jump

การ handle ที่เหมาะสม:

```
# เมื่อ jump detected if detect_jump(recent_residuals)[0][-1]: # Approach 1:
หยุด signal 10 tick pause_signal(duration=10) # Log สาเหตุ
log_event("funding_rate_jump", size=L_t, exchange="Bybit") # ถ้ามี open
position → ขยาย stop-loss if has_open_position():
adjust_stop(multiplier=2.0) #  $2\sigma \rightarrow 4\sigma$ 
```

หลัง 15 นาที spread กลับสู่ปกติบางส่วน (\$10 → \$35) แต่ไม่กลับไปที่ \$10 เพราะ funding rate ยังสูง — การ pause signal ช่วยหลีกเลี่ยงการเข้า position ในช่วงที่ spread ยัง elevated

โจทย์ท้ายบท

โจทย์ 8.1 — Jump vs Normal Volatility

Residual ε เปลี่ยนจาก 0.002 เป็น 0.012 ใน 1 tick ($dt = 1$ วินาที)

จากการ calibrate: $\sigma_{BV} = 0.002$ ต่อ tick

ถาม: คำนวณ L_t แล้วตัดสินว่าเป็น jump หรือ normal volatility (threshold = 4.0) พร้อมอธิบายว่าทำไม

► คำตอบ

โจทย์ 8.2 — Merton vs Kou: เลือกใช้เมื่อไร

จากข้อมูล historical spread ของ Bybit $\leftrightarrow$ Lighter พบว่า:

- Jump ลง (negative) เฉลี่ย -6.2σ
- Jump ขึ้น (positive) เฉลี่ย $+2.8\sigma$
- สัดส่วน: 60% down jump, 40% up jump

ถาม: ควรใช้ Merton หรือ Kou? เพราะอะไร?

► คำตอบ

โจทย์ 8.3 — Bybit Funding Rate 3x: ควรทำอย่างไร

Bybit ประกาศเพิ่ม funding rate จาก 0.01% เป็น 0.03% ต่อ 8 ชั่วโมง (3x)

ณ ขณะนี้คุณไม่มี open position และ `detect_jump()` ยังไม่ triggered

ถาม: ควร flag เหตุการณ์นี้เป็น (anticipated) jump แล้วทำอย่างไรในกลยุทธ์?

► คำตอบ

อ้างอิงสำคัญ (References)

- **Merton, R. C. (1976).** Option pricing when underlying stock returns are discontinuous. *Journal of Financial Economics*, 3(1–2), 125–144. — Merton jump-diffusion model พร้อม Gaussian jump size ที่ Ch.8 นำเสนอ
- **Kou, S. G. (2002).** A jump-diffusion model for option pricing. *Management Science*, 48(8), 1086–1101. — Kou double-exponential jump model; asymmetric jump sizes (upside vs downside) ที่เหมาะกับ crypto spreads
- **Lee, S. S., & Mykland, P. A. (2008).** Jumps in financial markets: A new nonparametric test and jump dynamics. *Review of Financial Studies*, 21(6), 2535–2563. — Lee-Mykland jump detection ด้วย bipower variation ที่ใช้ใน pseudo-code Ch.8
- **Barndorff-Nielsen, O. E., & Shephard, N. (2004).** Power and bipower variation with stochastic volatility and jumps. *Journal of Financial Econometrics*, 2(1), 1–37. — รากฐานทฤษฎีของ bipower variation สำหรับ jump detection