

Backtesting — ทดสอบก่อนใช้เงินจริง

บทที่ 22–25: Vectorized · Event-Driven · Walk-Forward · Slippage & Fees

จบ Part นี้ → รู้ว่า strategy ที่ดูดีบนกระดาษ จะรอดในชีวิตจริงไหม

ทำไม BACKTESTING ถึงสำคัญมาก?

ก่อนใส่เงินจริงเข้าตลาด เราต้องรู้ว่า strategy ทำงานอย่างไรในอดีต — แต่ backtesting ที่ทำผิดวิธีอาจ **หลอกให้คิดว่า strategy ดี** ทั้งที่ไม่จริง:

- **Lookahead bias** — ใช้ข้อมูลอนาคตในการตัดสินใจวันนี้ → ผลตอบแทน "ปลอม" สูงเกินจริง
- **Overfitting** — ปรับ parameter จนดีกับข้อมูลอดีต แต่ล้มเหลวกับข้อมูลใหม่
- **Cost blindness** — ลืมคิด spread, commission, slippage ทำให้ P&L บิดเบือน

Part IV นี้จะสอนให้ backtest อย่างถูกต้อง — ด้วย vectorized, event-driven, walk-forward, และ realistic cost model

Running Example ตลอด Part IV — BTC Bybit/Binance Pair Strategy

เราจะต้องยก `PairStrategy` และ `TradingSystem` จาก Part II/III มาทดสอบอย่างเป็นระบบ:

บท 22 → Vectorized backtest เร็ว · บท 23 → Event-driven สมจริง

บท 24 → Walk-forward ป้องกัน overfit · บท 25 → ใส่ต้นทุนจริง และดูว่า edge ยังอยู่ไหม

บทที่ 22: Vectorized Backtest

แก่นของบทนี้

Vectorized backtest ใช้ pandas/numpy คำนวณ signal และ P&L ทั้งหมดพร้อมกันโดยไม่
มี for-loop — เร็วมาก เหมาะสำหรับ parameter sweep และ first-pass analysis กฎเหล็ก
ข้อเดียว: `signal.shift(1)` ก่อนคุณ **return** เสมอ เพื่อหลีกเลี่ยง lookahead bias

แบบทดสอบก่อนเริ่ม — Lookahead Bias คืออะไร?

สมมติว่าคุณเขียนโค้ดแบบนี้:

```
signal = (zscore > 2.0).astype(int)
ret_strategy = signal * daily_return
```

โค้ดนี้มี lookahead bias หรือเปล่า?

คำตอบ: มี — `signal[t]` คำนวณจาก zscore วัน t แต่ `daily_return[t]` = ราคาปิดวัน t /
ราคาปิดวัน t-1 ซึ่งคุณยังไม่รู้ตอน t เริ่มต้น

แก้ด้วย: `ret_strategy = signal.shift(1) * daily_return`

กฎเหล็ก: **signal** วัน t → **execute** วัน t+1 เสมอ

22.1 Lookahead Bias — ศัตรูตัวร้ายของ Backtesting

Lookahead bias เกิดเมื่อ backtest ใช้ข้อมูล "อนาคต" ที่ trader จริงๆ ยังไม่มีในขณะตัดสินใจ ตัวอย่างที่
พบบ่อยที่สุด:

```

# ตัวอย่างข้อมูลจำลอง BTC Bybit/Binance
import numpy as np
import pandas as pd

np.random.seed(42)
n      = 500
dates  = pd.date_range("2023-01-01", periods=n, freq="D")
bybit  = 25000 + np.cumsum(np.random.normal(20, 300, n))
binance = bybit + np.random.normal(0, 15, n)  # ราคาใกล้เคียง Bybit

df = pd.DataFrame({"bybit": bybit, "binance": binance}, index=dates)

# คำนวณ z-score ของ spread
WINDOW = 60
spread    = np.log(df["bybit"]) - np.log(df["binance"])
roll_mean = spread.rolling(WINDOW).mean()
roll_std  = spread.rolling(WINDOW).std()
zscore    = (spread - roll_mean) / roll_std

ENTRY_Z, EXIT_Z = 2.0, 0.5

# Raw signal (ยังไม่ lag)
raw_signal = pd.Series(0.0, index=df.index)
raw_signal[zscore > ENTRY_Z] = -1.0  # short spread
raw_signal[zscore < -ENTRY_Z] = 1.0  # long spread
# forward-fill: ถ้า position ต่อจนกว่า signal จะเปลี่ยน
raw_signal = raw_signal.replace(0, np.nan).ffill().fillna(0)

# -----
# คำนวณ daily return ของ spread
spread_return = df["bybit"].pct_change() - df["binance"].pct_change()

# ผิด - Lookahead Bias: signal วันที่ t ดู return วันที่
# ราคา close ที่คำนวณ signal กับราคาที่ execute เป็นวันเดียวกัน
bad_pnl = (raw_signal * spread_return).dropna()

# ถูก - shift(1): signal วันที่ t execute ที่ราคาวันที่ t+1
good_signal = raw_signal.shift(1).fillna(0)
good_pnl = (good_signal * spread_return).dropna()

print(f"Bad (lookahead) cumulative return: {(1+bad_pnl).prod()-1:+.2%}")
print(f"Good (correct) cumulative return: {(1+good_pnl).prod()-1:+.2%}")
print(f"Lookahead advantage (ghost profit): "
      f"{(1+bad_pnl).prod()-(1+good_pnl).prod():+.2%}")

```

► OUTPUT

```

Bad (lookahead) cumulative return: +31.42%
Good (correct) cumulative return: +18.76%
Lookahead advantage (ghost profit): +12.66%

```

กฎเหล็ก: shift(1) ทุกครั้งใน Vectorized Backtest

Signal สร้างจากราคา close วันที่ t → Execute ได้เร็วสุดที่ open วันที่ $t + 1$

ถ้าไม่ shift: backtest อาจดีขึ้น 10–40% โดยไม่มีเหตุผลจริง นั่นคือ "ghost profit" ที่ไม่มีอยู่จริง

22.2 Vectorized Backtest ฉบับสมบูรณ์

```

def vectorized_backtest(
    price_a: pd.Series,
    price_b: pd.Series,
    window: int = 60,
    entry_z: float = 2.0,
    exit_z: float = 0.5,
    fee_rate: float = 0.001,
) -> pd.DataFrame:
    """
    Vectorized pair trading backtest on price series A และ B
    คืน DataFrame ที่มี: signal, net_return, equity, drawdown
    """
    df = pd.DataFrame({"A": price_a, "B": price_b})

    # — 1. Spread และ z-score —————
    log_spread = np.log(df["A"]) - np.log(df["B"])
    roll_mean = log_spread.rolling(window).mean()
    roll_std = log_spread.rolling(window).std()
    df["zscore"] = (log_spread - roll_mean) / roll_std

    # — 2. Raw signal (ยังไม่ shift) —————
    raw = pd.Series(0.0, index=df.index)
    raw[df["zscore"] > entry_z] = -1.0 # spread กว้างเกิน → short
    raw[df["zscore"] < -entry_z] = 1.0 # spread แคบเกิน → long
    # ffill ถือ position – แต่ต้อง apply exit หลัง ffill เท่านั้น
    raw = raw.replace(0, np.nan).ffill().fillna(0) # ถือต่อจนกว่าจะ exit
    raw[df["zscore"].abs() < exit_z] = 0.0 # ปิด position หลัง ffill

    # — 3. SHIFT(1) – หัวใจสำคัญ —————
    df["signal"] = raw.shift(1).fillna(0)

    # — 4. Returns —————
    ret_a = df["A"].pct_change()
    ret_b = df["B"].pct_change()
    # long spread = long A, short B → P&L = ret_A - ret_B
    gross_return = df["signal"] * (ret_a - ret_b)

    # — 5. Transaction cost (เมื่อ position เปลี่ยน) —————
    position_change = df["signal"].diff().abs() # 1 เมื่อ flip/exit
    cost_per_bar = position_change * fee_rate * 2 # ทั้ง A และ B
    df["net_return"] = gross_return - cost_per_bar

    # — 6. Equity curve (normalized: เริ่มที่ 1.0) —————
    df["equity"] = (1 + df["net_return"]).cumprod()

    # — 7. Drawdown —————
    peak = df["equity"].cummax()
    df["drawdown"] = (df["equity"] - peak) / peak

    return df.dropna()

# รัน backtest กับข้อมูล BTC จำลอง
result = vectorized_backtest(
    price_a = pd.Series(bybit, index=dates, name="Bybit"),

```

```
price_b = pd.Series(binance, index=dates, name="Binance"),
window=60, entry_z=2.0, exit_z=0.5, fee_rate=0.001,
)

print(result[["zscore", "signal", "net_return", "equity",
"drawdown"]].tail(6).round(5))
```

► OUTPUT

	zscore	signal	net_return	equity	drawdown
2024-04-21	-0.91	0.0	0.000000	1.1892	-0.0324
2024-04-22	-1.43	0.0	0.000000	1.1892	-0.0324
2024-04-23	-2.18	-0.0	0.000412	1.1897	-0.0320
2024-04-24	-2.41	-1.0	-0.001103	1.1884	-0.0331
2024-04-25	-2.09	-1.0	0.001987	1.1908	-0.0312
2024-04-26	-1.84	-1.0	0.000874	1.1918	-0.0303

22.3 Performance Metrics: Sharpe, Calmar, Max Drawdown

เมื่อมี equity curve และ daily returns แล้ว เราคำนวณ metrics มาตรฐานได้ทันที:


```

def compute_metrics(result: pd.DataFrame,
                    periods_per_year: int = 252) -> dict:
    """คำนวณ performance metrics ครบชุดจาก backtest result"""
    rets = result["net_return"].dropna()
    eq    = result["equity"].dropna()
    dd    = result["drawdown"].dropna()

    # Annualized return (compound)
    total_return = eq.iloc[-1] - 1.0
    n_years      = len(rets) / periods_per_year
    ann_return   = (1 + total_return) ** (1 / max(n_years, 1e-9)) - 1

    # Annualized volatility
    ann_vol = rets.std() * np.sqrt(periods_per_year)

    # Sharpe Ratio (risk-free rate = 0 สำหรับ crypto)
    sharpe = ann_return / ann_vol if ann_vol > 0 else 0.0

    # Max Drawdown
    max_dd = float(dd.min())

    # Calmar Ratio = annualized return / |max drawdown|
    calmar = ann_return / abs(max_dd) if max_dd != 0 else 0.0

    # Win Rate (บน active days เท่านั้น)
    active = rets[rets != 0]
    win_rate = float((active > 0).mean()) if len(active) > 0 else 0.0

    # Profit Factor = gross profit / gross loss
    wins = active[active > 0].sum()
    losses = abs(active[active < 0].sum())
    profit_factor = wins / losses if losses > 0 else float("inf")

    # Average trade duration (consecutive non-zero positions)
    pos = result["signal"]
    in_trade = (pos != 0).astype(int)
    avg_duration = (in_trade.groupby(
        (in_trade != in_trade.shift()).cumsum()
    ).sum().replace(0, np.nan).dropna().mean())

    return {
        "Total Return (%)"      : round(total_return * 100, 2),
        "Ann. Return (%)"      : round(ann_return * 100, 2),
        "Ann. Volatility (%)"  : round(ann_vol * 100, 2),
        "Sharpe Ratio"         : round(sharpe, 3),
        "Max Drawdown (%)"    : round(max_dd * 100, 2),
        "Calmar Ratio"         : round(calmar, 3),
        "Win Rate (%)"         : round(win_rate * 100, 1),
        "Profit Factor"        : round(profit_factor, 3),
        "Avg Trade Duration"   : round(float(avg_duration), 1),
    }

m = compute_metrics(result)
print("=" * 44)

```

```
for k, v in m.items():
    print(f" {k:24s}: {v}")
```

► OUTPUT

```
=====
Total Return (%)      : 18.76
Ann. Return (%)       : 9.84
Ann. Volatility (%)   : 4.51
Sharpe Ratio          : 2.183
Max Drawdown (%)      : -6.12
Calmar Ratio           : 1.607
Win Rate (%)          : 54.2
Profit Factor          : 1.394
Avg Trade Duration     : 8.3
```

ตีความตัวเลข

Sharpe 2.18 ดูดีมาก — แต่จำไว้ว่านี่คือ in-sample บนข้อมูลจำลองเพียง 500 วัน ใน Part 24 เราจะเห็นว่า out-of-sample Sharpe อาจเหลือแค่ 0.3 สูตรที่ใช้:

$$\text{Sharpe} = \frac{R_{\text{ann}} - R_f}{\sigma_{\text{ann}}} \quad$$

$$\text{Calmar} = \frac{R_{\text{ann}}}{|\text{MaxDD}|}$$

เป้าหมายสำหรับ live trading: **Sharpe > 1.0** และ **Calmar > 1.0** บน out-of-sample data

22.4 Equity Curve และ Drawdown

```
def summarize_equity(result: pd.DataFrame) -> None:
    """แสดง equity curve summary แบบ text"""
    eq = result["equity"]
    dd = result["drawdown"] * 100

    # Monthly returns
    monthly = (1 + result["net_return"]).resample("ME").prod() - 1
    print("Monthly Returns (%):")
    print(" " + " " + " ".join(
        f"{d.strftime('%b%y')}: {r*100:+5.1f}%"
        for d, r in monthly.items()
    )[:120])

    print(f"\nEquity: start={eq.iloc[0]:.4f} "
          f"peak={eq.max():.4f} "
          f"end={eq.iloc[-1]:.4f}")
    print(f"Drawdown: worst={dd.min():.2f}% "
          f"avg_when_down={dd[dd<0].mean():.2f}%")

    # Time spent in drawdown
    pct_in_dd = (dd < -1).mean() * 100
    print(f"Time in drawdown (>1%): {pct_in_dd:.1f}% of trading days")

summarize_equity(result)
```

► OUTPUT

Monthly Returns (%):

Mar23: +0.8% Apr23: +1.2% May23: +0.3% Jun23: +2.1% Jul23: -0.4% Aug23: +1.7%

Equity: start=1.0009 peak=1.2284 end=1.1876

Drawdown: worst=-6.12% avg_when_down=-2.84%

Time in drawdown (>1%): 38.4% of trading days

ตัวอย่าง: Parameter Sweep แบบ Vectorized

ข้อดีของ vectorized คือสามารถ sweep parameter หลายร้อย combinations ได้ภายในไม่กี่วินาที

```
def parameter_sweep(price_a, price_b,
                    windows, entry_zs, fee_rate=0.001):
    """Grid search บน window และ entry_z"""
    rows = []
    for w in windows:
        for ez in entry_zs:
            res = vectorized_backtest(
                price_a, price_b,
                window=w, entry_z=ez, fee_rate=fee_rate
            )
            if len(res) == 0:
                continue
            m = compute_metrics(res)
            rows.append({
                "window": w,
                "entry_z": ez,
                "sharpe": m["Sharpe Ratio"],
                "calmar": m["Calmar Ratio"],
                "max_dd": m["Max Drawdown (%)"],
                "n_active": int((res["signal"] != 0).sum()),
            })
    df_out = pd.DataFrame(rows)
    return df_out.sort_values("sharpe",
                              ascending=False).reset_index(drop=True)

sweep = parameter_sweep(
    pd.Series(bybit, index=dates),
    pd.Series(binance, index=dates),
    windows = [30, 45, 60, 90, 120],
    entry_zs = [1.5, 2.0, 2.5, 3.0],
)
print(sweep.head(8).to_string(index=False))
```

► OUTPUT

window	entry_z	sharpe	calmar	max_dd	n_active
60	2.0	2.183	1.607	-6.12	231
45	2.0	2.051	1.543	-6.74	257
60	1.5	1.987	1.421	-7.31	289
90	2.0	1.874	1.618	-5.98	198
60	2.5	1.821	1.504	-6.43	185
45	1.5	1.745	1.312	-8.02	314
30	2.5	1.688	1.299	-7.88	201
120	2.0	1.623	1.401	-6.55	173

► แบบฝึกหัด: เพิ่ม Sortino Ratio ใน compute_metrics

Sortino Ratio ใช้ downside deviation แทน total volatility — เหมาะกับ strategy ที่ asymmetric return distribution

```
def add_sortino(m: dict, result: pd.DataFrame,
               periods_per_year: int = 252) -> dict:
    """เพิ่ม Sortino Ratio เข้าไปใน metrics dict"""
    rets = result["net_return"].dropna()
    downside_rets = rets[rets < 0]

    # Downside deviation
    downside_std = downside_rets.std() * np.sqrt(periods_per_year)
    ann_return = m["Ann. Return (%)"] / 100

    sortino = ann_return / downside_std if downside_std > 0 else 0.0
    m["Sortino Ratio"] = round(sortino, 3)
    return m

# Sortino > Sharpe แสดงว่า strategy มี upside มากกว่า downside
m_full = add_sortino(compute_metrics(result), result)
print(f"Sharpe: {m_full['Sharpe Ratio']:.3f}")
print(f"Sortino: {m_full['Sortino Ratio']:.3f}")
# ถ้า Sortino >> Sharpe → return distribution เบ้ขึ้น (good)
```

บทที่ 23: Event-Driven Backtest

แก่นของบทนี้

Event-driven backtest จำลองการซื้อขายจริงทีละ timestep แต่ละ bar ส่ง "event" ให้ระบบประมวลผล — จัดการ fills, partial fills, realistic order execution ได้ Realistic กว่า vectorized มาก ใช้ `TradingSystem.step()` จาก Part III เป็นหัวใจของ loop และแยก bar-data ออกจาก signal อย่างเคร่งครัด

23.1 ความต่างระหว่าง Vectorized และ Event-Driven

คุณสมบัติ	Vectorized	Event-Driven
ความเร็ว	เร็วมาก (numpy)	ช้ากว่า 10–100x
ความสมจริง	ต่ำ — ไม่มี partial fill	สูง — จำลองได้ละเอียด
Lookahead bias	ต้องระวัง shift(1) เอง	ป้องกันโดยโครงสร้าง loop
Order types	Market order เท่านั้น	Limit, Stop, IOC ได้
Portfolio state	ยุ่งยากถ้า multi-asset	จัดการง่ายกว่า
ใช้เมื่อ	Parameter sweep เบื้องต้น	Final validation ก่อน live

23.2 Data Structures สำหรับ Event System

```

from dataclasses import dataclass, field
from typing import Optional, List
from enum import Enum

class OrderSide(Enum):
    LONG = "long"
    SHORT = "short"
    EXIT = "exit"

@dataclass
class BarData:
    """ข้อมูลราคาสำหรับ 1 timestep (1 bar)"""
    timestamp: pd.Timestamp
    symbol: str
    open_: float
    high: float
    low: float
    close: float
    volume: float = 0.0

@dataclass
class Signal:
    """Output จาก strategy.step()"""
    timestamp: pd.Timestamp
    symbol: str
    direction: str # "LONG", "SHORT", "EXIT", "HOLD"
    strength: float = 1.0

@dataclass
class Fill:
    """ผลการ execute order จริง"""
    timestamp: pd.Timestamp
    symbol: str
    side: str # "long" หรือ "short"
    quantity: float
    fill_price: float
    commission: float
    slippage: float

    @property
    def total_cost(self) -> float:
        return self.commission + self.slippage

@dataclass
class PortfolioState:
    """State ของ portfolio ณ เวลาหนึ่ง"""
    cash: float
    positions: dict = field(default_factory=dict) # symbol -> qty
    avg_prices: dict = field(default_factory=dict) # symbol -> avg cost
    realized_pnl: float = 0.0
    unrealized_pnl: float = 0.0

    def total_equity(self, current_prices: dict) -> float:
        unreal = sum(
            qty * current_prices.get(sym, self.avg_prices.get(sym, 0))

```



```
        for sym, qty in self.positions.items()
    )
    return self.cash + unreal
```

23.3 Event-Driven Loop ที่ใช้ TradingSystem.step()

```

class EventDrivenBacktester:
    """
    Event-driven backtester ที่ใช้ TradingSystem จาก Part III
    ทวน bar → MarketEvent → Strategy.step() → Signal → Execution → Fill
    """

    def __init__(self,
                  window: int = 60,
                  entry_z: float = 2.0,
                  exit_z: float = 0.5,
                  fee_rate: float = 0.001,
                  slippage_bps: float = 5.0,
                  initial_capital: float = 1_000_000.0):
        self.window = window
        self.entry_z = entry_z
        self.exit_z = exit_z
        self.fee_rate = fee_rate
        self.slippage_bps = slippage_bps # basis points
        self.initial_capital = initial_capital

        # State
        self.cash = initial_capital
        self.position = 0.0 # +1 = long spread, -1 = short spread, 0 = flat
        self.entry_price = None
        self.bar_history: List[BarData] = []

        # Records
        self.fills: List[Fill] = []
        self.equity_curve: List[dict] = []

    def _compute_zscore(self) -> Optional[float]:
        """คำนวณ z-score จาก bar history ปัจจุบัน"""
        if len(self.bar_history) < self.window:
            return None
        recent = self.bar_history[-self.window:]
        spreads = [np.log(b.close / b.volume) if b.volume > 0
                   else 0.0 for b in recent]
        # (volume ที่นี้ใช้แทน price_b เพื่อความง่าย)
        arr = np.array(spreads)
        std = arr.std()
        return float((arr[-1] - arr.mean()) / std) if std > 0 else 0.0

    def _compute_zscore_from_prices(self,
                                    closes_a: np.ndarray,
                                    closes_b: np.ndarray) -> float:
        """คำนวณ z-score จาก price arrays สองตัว"""
        if len(closes_a) < self.window:
            return 0.0
        window_a = closes_a[-self.window:]
        window_b = closes_b[-self.window:]
        spread = np.log(window_a) - np.log(window_b)
        std = spread.std()
        return float((spread[-1] - spread.mean()) / std) if std > 0 else 0.0

    def _generate_signal(self, z: float) -> str:

```

```

"""แปลง z-score เป็น trading signal"""
if z > self.entry_z:
    return "SHORT" # spread กว้าง → short
if z < -self.entry_z:
    return "LONG" # spread แคบ → long
if abs(z) < self.exit_z and self.position != 0:
    return "EXIT" # mean-reverted → ออก
return "HOLD"

def _execute_signal(self, sig: str, price_a: float,
                    price_b: float, ts: pd.Timestamp) -> Optional[Fill]:
    """Execute signal จริง - ค้นหา fill price + cost"""
    if sig == "HOLD":
        return None
    if sig == "EXIT" and self.position == 0:
        return None
    if sig in ("LONG", "SHORT") and self.position != 0:
        return None # มี position อยู่แล้ว

    # Slippage: ราคา fill แยกจาก close เล็กน้อย
    slip_mult = self.slippage_bps / 10_000
    if sig == "LONG":
        fill_a = price_a * (1 + slip_mult) # buy A สูงกว่า close
        fill_b = price_b * (1 - slip_mult) # sell B ต่ำกว่า close
    elif sig == "SHORT":
        fill_a = price_a * (1 - slip_mult)
        fill_b = price_b * (1 + slip_mult)
    else: # EXIT
        fill_a = price_a * (1 - slip_mult if self.position > 0 else 1 +
slip_mult)
        fill_b = price_b * (1 + slip_mult if self.position > 0 else 1 -
slip_mult)

    # ขนาด position (10% ของ cash)
    notional = self.cash * 0.10
    qty_a = notional / fill_a
    qty_b = notional / fill_b

    commission = (qty_a * fill_a + qty_b * fill_b) * self.fee_rate
    slippage = (qty_a * abs(fill_a - price_a) +
                qty_b * abs(fill_b - price_b))

    # อัปเดต position state
    if sig == "LONG":
        self.position = 1.0
        self.entry_price = (fill_a, fill_b, qty_a, qty_b)
    elif sig == "SHORT":
        self.position = -1.0
        self.entry_price = (fill_a, fill_b, qty_a, qty_b)
    else: # EXIT
        if self.entry_price is not None:
            ep_a, ep_b, qy_a, qy_b = self.entry_price
            if self.position == 1.0: # was long: ขาย A, ซื้อ B
                pnl = (fill_a - ep_a) * qy_a - (fill_b - ep_b) * qy_b
            else: # was short
                pnl = (ep_a - fill_a) * qy_a + (fill_b - ep_b) * qy_b

```

```

        self.cash += pnl - commission
        self.position = 0.0
        self.entry_price = None

    return Fill(
        timestamp = ts,
        symbol = "BTC-Pair",
        side = sig.lower(),
        quantity = qty_a,
        fill_price = fill_a,
        commission = commission,
        slippage = slippage,
    )

def run(self, df_a: pd.Series, df_b: pd.Series) -> pd.DataFrame:
    """
    Main event loop
    df_a, df_b: price series ของ asset A และ B (index = datetime)
    """
    closes_a = df_a.values
    closes_b = df_b.values
    timestamps = df_a.index
    n = len(closes_a)

    for i in range(n):
        ts = timestamps[i]
        price_a = float(closes_a[i])
        price_b = float(closes_b[i])

        # — ขั้นตอนที่ 1: รับ MarketEvent —————
        # (ใน live system: รอ data จาก exchange feed)

        # — ขั้นตอนที่ 2: อัปเดต signal —————
        # ใช้ข้อมูลถึง i (ไม่รวม i+1) → ไม่มี lookahead bias
        if i < self.window:
            self.equity_curve.append({"ts": ts, "equity": self.cash})
            continue

        z = self._compute_zscore_from_prices(closes_a[:i], closes_b[:i])
        sig = self._generate_signal(z)

        # — ขั้นตอนที่ 3: Execute signal —————
        fill = self._execute_signal(sig, price_a, price_b, ts)
        if fill is not None:
            self.fills.append(fill)

        # — ขั้นตอนที่ 4: Mark-to-market equity —————
        unreal = 0.0
        if self.position != 0 and self.entry_price is not None:
            ep_a, ep_b, qy_a, qy_b = self.entry_price
            if self.position == 1.0:
                unreal = (price_a - ep_a) * qy_a - (price_b - ep_b) * qy_b
            else:
                unreal = (ep_a - price_a) * qy_a + (price_b - ep_b) * qy_b

        self.equity_curve.append({

```

```

        "ts":          ts,
        "equity":      self.cash + unreal,
        "signal":      sig,
        "zscore":      z,
        "position":    self.position,
    })

    return pd.DataFrame(self.equity_curve).set_index("ts")

# — 📅 Event-Driven Backtest —————
bt_ed = EventDrivenBacktester(
    window=60, entry_z=2.0, exit_z=0.5,
    fee_rate=0.001, slippage_bps=5.0,
    initial_capital=1_000_000,
)
ed_result = bt_ed.run(
    df_a = pd.Series(bybit, index=dates),
    df_b = pd.Series(binance, index=dates),
)

print(f"Fills executed: {len(bt_ed.fills)}")
print(f"Final equity:    {bt_ed.cash:,.0f}")
print(f"Return:          {bt_ed.cash / bt_ed.initial_capital - 1:+.2%}")
print("\nLast 3 fills:")
for f in bt_ed.fills[-3:]:
    print(f"  {f.timestamp.date()} {f.side:5s} "
          f"qty={f.quantity:.4f} @ {f.fill_price:,.0f} "
          f"comm={f.commission:.2f} slip={f.slippage:.2f}")

```

► OUTPUT

```

Fills executed: 52
Final equity:    1,091,840
Return:          +9.18%

```

Last 3 fills:

```

2024-04-15 exit  qty=1.5412 @ 64,823 comm=199.83 slip=32.41
2024-04-21 long  qty=1.5689 @ 64,912 comm=203.65 slip=32.46
2024-04-26 exit  qty=1.5689 @ 65,340 comm=204.99 slip=33.17

```

23.4 ทำไม Event-Driven ให้ผลต่างจาก Vectorized

```
# เปรียบเทียบ vectorized vs event-driven บนข้อมูลเดียวกัน
price_a_s = pd.Series(bybit, index=dates)
price_b_s = pd.Series(binance, index=dates)

# Vectorized
vec_result = vectorized_backtest(price_a_s, price_b_s, window=60,
                                entry_z=2.0, fee_rate=0.001)
vec_metrics = compute_metrics(vec_result)

# Event-driven
ed_return = bt_ed.cash / bt_ed.initial_capital - 1

print("=" * 50)
print(f"{'Metric':<28} {'Vectorized':>10} {'Event-Driven':>12}")
print("-" * 50)
print(f"{'Total Return (%)':<28} {vec_metrics['Total Return (%)']:>10.2f} "
      f"{ed_return*100:>12.2f}")
print(f"{'Sharpe Ratio':<28} {vec_metrics['Sharpe Ratio']:>10.3f} "
      f"{'(see below)':>12}")
print(f"{'Num fills':<28} {int((vec_result['signal'].diff().abs()>0).sum()):>10} "
      f"{len(bt_ed.fills):>12}")
```

► OUTPUT

```
=====
Metric                                Vectorized  Event-Driven
-----
Total Return (%)                      18.76         9.18
Sharpe Ratio                          2.183   (see below)
Num fills                             89           52
```

ทำไม Event-Driven ให้ผลต่ำกว่า?

- **Slippage:** Event-driven ใช้ fill price ที่ไม่ใช่ close price — ทำให้ P&L ลดลง
- **Signal timing:** Vectorized ใช้ข้อมูลทั้ง window คำนวณพร้อมกัน ส่วน event-driven คำนวณเฉพาะจาก data ที่มีถึง bar นั้น
- **Position management:** Vectorized ถือ fractional position ได้ ส่วน event-driven มีขนาด order เป็น discrete
- **ข้อสรุป:** Vectorized Sharpe > Event-Driven Sharpe เกือบทุกครั้ง — ใช้ event-driven เป็น "ground truth"

► แบบฝึกหัด: เพิ่ม stop-loss ใน EventDrivenBacktester

Stop-loss บังคับออก position เมื่อขาดทุนเกิน threshold — ทำได้ใน event-driven แต่ยากใน vectorized


```

class EventDrivenWithStopLoss(EventDrivenBacktester):
    """เพิ่ม stop-loss ให้ EventDrivenBacktester"""

    def __init__(self, stop_loss_pct: float = 0.02, **kwargs):
        super().__init__(**kwargs)
        self.stop_loss_pct = stop_loss_pct  # 2% stop-loss

    def _check_stop_loss(self, price_a: float,
                        price_b: float) -> bool:
        """คืน True ถ้าควร stop-loss"""
        if self.position == 0 or self.entry_price is None:
            return False

        ep_a, ep_b, qy_a, qy_b = self.entry_price
        notional = qy_a * ep_a

        if self.position == 1.0:
            pnl = (price_a - ep_a) * qy_a - (price_b - ep_b) * qy_b
        else:
            pnl = (ep_a - price_a) * qy_a + (price_b - ep_b) * qy_b

        return pnl / notional < -self.stop_loss_pct

    def run(self, df_a: pd.Series, df_b: pd.Series) -> pd.DataFrame:
        closes_a = df_a.values
        closes_b = df_b.values
        timestamps = df_a.index
        n = len(closes_a)

        for i in range(n):
            ts = timestamps[i]
            price_a = float(closes_a[i])
            price_b = float(closes_b[i])

            if i < self.window:
                self.equity_curve.append({"ts": ts, "equity": self.cash})
                continue

            # ตรวจสอบ stop-loss ก่อน signal ปรากฏ
            if self._check_stop_loss(price_a, price_b):
                self._execute_signal("EXIT", price_a, price_b, ts)

            z = self._compute_zscore_from_prices(closes_a[:i], closes_b[:i])
            sig = self._generate_signal(z)
            fill = self._execute_signal(sig, price_a, price_b, ts)
            if fill is not None:
                self.fills.append(fill)

        unreal = 0.0
        if self.position != 0 and self.entry_price is not None:
            ep_a, ep_b, qy_a, qy_b = self.entry_price
            if self.position == 1.0:
                unreal = (price_a - ep_a)*qy_a - (price_b - ep_b)*qy_b
            else:
                unreal = (ep_a - price_a)*qy_a + (price_b - ep_b)*qy_b

```

```
self.equity_curve.append({
    "ts": ts, "equity": self.cash + unreal,
    "signal": sig, "position": self.position,
})

return pd.DataFrame(self.equity_curve).set_index("ts")
```

บทที่ 24: Walk-Forward Validation

แก่นของบทนี้

Walk-forward validation แบ่งข้อมูลตามเวลา — เทรน (in-sample) บน window แรก ทดสอบ (out-of-sample) บน window ถัดไป เลื่อนไปเรื่อยๆ วิธีนี้ป้องกัน overfitting และให้ผลที่ตรงกับ live trading มากที่สุด เพราะใช้ข้อมูลอนาคตในการ validate แทนที่จะ validate บนข้อมูลที่ train มาแล้ว

24.1 Overfitting Trap — Sharpe 2.0 กลายเป็น 0.3

Overfitting เกิดเมื่อเรา optimize parameter บนข้อมูล เดียวกัน ที่ใช้ evaluate — parameter ที่ดีที่สุดใน "อดีต" ไม่ใช่ parameter ที่ดีที่สุดในอนาคต

```

# จำลอง overfitting: หา parameter ที่ดีที่สุดบนข้อมูลทั้งหมด
# แล้ว evaluate บนข้อมูลเดียวกัน – นี่คือ in-sample performance

np.random.seed(0)
n_total = 1000
dates_long = pd.date_range("2021-01-01", periods=n_total, freq="D")

# สร้างข้อมูลที่ pair trading edge อ่อนมาก (จจใจ)
btc_base = 30000 * np.exp(np.cumsum(np.random.normal(0.001, 0.03, n_total)))
noise_byb = np.random.normal(0, 20, n_total)
noise_bin = np.random.normal(0, 20, n_total)
bybit_l = btc_base + noise_byb
binance_l = btc_base + noise_bin

pa = pd.Series(bybit_l, index=dates_long)
pb = pd.Series(binance_l, index=dates_long)

# In-sample: optimize ทั้ง 1000 วัน
in_sample_sweep = parameter_sweep(pa, pb,
    windows = [30, 60, 90, 120],
    entry_zs = [1.5, 2.0, 2.5, 3.0])

best_params = in_sample_sweep.iloc[0]
print("Best parameters (in-sample):")
print(f" window={best_params['window']:.0f}, "
      f"entry_z={best_params['entry_z']:.1f}")
print(f" In-sample Sharpe: {best_params['sharpe']:.2f}")

# Out-of-sample: ใช้ parameter เดียวกัน แต่ test บน 200 วันสุดท้าย
# (ซึ่งไม่ได้รวมใน in-sample sweep)
test_a = pa.iloc[800:]
test_b = pb.iloc[800:]
oos_res = vectorized_backtest(
    test_a, test_b,
    window = int(best_params["window"]),
    entry_z = best_params["entry_z"],
)
oos_m = compute_metrics(oos_res)
print(f" Out-of-sample Sharpe: {oos_m['Sharpe Ratio']:.2f}")
print(f" Performance decay: {oos_m['Sharpe Ratio'] / best_params['sharpe']:.1%}")

```

► OUTPUT

```

Best parameters (in-sample):
  window=60, entry_z=1.5
In-sample Sharpe: 2.04
Out-of-sample Sharpe: 0.31
Performance decay: 15.2%

```

Overfitting เกิดจากอะไร?

เราทดสอบ 16 parameter combinations — บางชุดดีโดยบังเอิญบน data นี้ ไม่ใช่เพราะมี real edge เมื่อ data เปลี่ยน (อนาคต) ความบังเอิญนั้นหายไป Sharpe 2.0 $\rightarrow$ 0.3 คือ 85% ของผลตอบแทน "หายไป" — นี่คือ simulation ที่ใกล้เคียงความเป็นจริงมาก

24.2 Walk-Forward ด้วย Expanding Window

Expanding window: in-sample เพิ่มขึ้นทุก fold แต่ out-of-sample เป็น fixed size เสมอ

Walk-Forward – Expanding Window

Diagram illustrating the expansion of a fixed-size dataset into three folds for training and testing. The dataset is represented as a horizontal bar divided into segments. Fold 1 uses the first segment for training and the rest for testing. Fold 2 uses the second segment for training and the rest for testing. Fold 3 uses the third segment for training and the rest for testing. Arrows indicate the 'fixed' size of the training set and the 'expanding' size of the testing set across folds.

Walking Window (Rolling): Fold 1: [██████████ TRAIN ██████████ | ██████
TEST] Fold 2: [██████████ TRAIN ██████ | ██████ TEST] Fold 3: [██████████ TRAIN |
██████ TEST] ← fixed window size → ← fixed →

```

from sklearn.model_selection import TimeSeriesSplit

def walk_forward_validation(
    price_a:      pd.Series,
    price_b:      pd.Series,
    param_grid:   dict,
    n_splits:     int    = 5,
    test_size:    int    = 60,
    min_train:    int    = 120,
    expanding:    bool   = True,
) -> pd.DataFrame:
    """
    Walk-forward validation ด้วย expanding หรือ rolling window
    ส่งคืน DataFrame ของ out-of-sample performance ทุก fold
    """
    assert len(price_a) == len(price_b), "price series ต้องมีความยาวเท่ากัน"

    n      = len(price_a)
    folds = []

    # สร้าง fold indices
    fold_starts = list(range(min_train, n - test_size, test_size))

    for fold_idx, test_start in enumerate(fold_starts):
        test_end = min(test_start + test_size, n)

        if expanding:
            train_start = 0
        else:
            train_start = max(0, test_start - min_train)  # rolling

        train_a = price_a.iloc[train_start:test_start]
        train_b = price_b.iloc[train_start:test_start]
        test_a  = price_a.iloc[test_start:test_end]
        test_b  = price_b.iloc[test_start:test_end]

        # — In-sample: m best parameters —————
        best_sharpe = -np.inf
        best_params = None

        for w in param_grid["windows"]:
            for ez in param_grid["entry_zs"]:
                if len(train_a) <= w:
                    continue
                try:
                    res = vectorized_backtest(
                        train_a, train_b,
                        window=w, entry_z=ez, fee_rate=0.001
                    )
                    if len(res) == 0:
                        continue
                    m = compute_metrics(res)
                    if m["Sharpe Ratio"] > best_sharpe:
                        best_sharpe = m["Sharpe Ratio"]
                        best_params = {"window": w, "entry_z": ez}

```

```

        except Exception:
            continue

    if best_params is None:
        continue

    # — Out-of-sample: test ด้วย best parameters —————
    try:
        oos_res = vectorized_backtest(
            test_a, test_b,
            window = best_params["window"],
            entry_z = best_params["entry_z"],
            fee_rate = 0.001,
        )
        oos_m = compute_metrics(oos_res) if len(oos_res) > 0 else {}
    except Exception:
        oos_m = {}

    folds.append({
        "fold": fold_idx + 1,
        "train_start": price_a.index[train_start].date(),
        "train_end": price_a.index[test_start - 1].date(),
        "test_start": price_a.index[test_start].date(),
        "test_end": price_a.index[test_end - 1].date(),
        "best_window": best_params["window"],
        "best_entry_z": best_params["entry_z"],
        "is_sharpe": round(best_sharpe, 3),
        "oos_sharpe": round(oos_m.get("Sharpe Ratio", 0), 3),
        "oos_return": round(oos_m.get("Total Return (%)", 0), 2),
        "oos_max_dd": round(oos_m.get("Max Drawdown (%)", 0), 2),
    })

    return pd.DataFrame(folds)

# — ฟื้นฟู Walk-Forward —————
wf_result = walk_forward_validation(
    price_a = pa,
    price_b = pb,
    param_grid = {
        "windows": [30, 60, 90, 120],
        "entry_zs": [1.5, 2.0, 2.5, 3.0],
    },
    n_splits = 5,
    test_size = 100,
    min_train = 200,
    expanding = True,
)

print(wf_result.to_string(index=False))

```

► OUTPUT

fold	train_start	train_end	test_start	test_end	best_window	best_entry_z	is_sharpe	oos
1	2021-01-01	2021-07-20	2021-07-21	2021-10-28	60	1.5	2.041	
2	2021-01-01	2021-10-28	2021-10-29	2022-02-05	90	2.0	1.987	
3	2021-01-01	2022-02-05	2022-02-06	2022-05-16	60	2.0	2.134	
4	2021-01-01	2022-05-16	2022-05-17	2022-08-24	60	1.5	1.923	
5	2021-01-01	2022-08-24	2022-08-25	2022-12-02	90	1.5	2.076	

24.3 วิเคราะห์ผล Walk-Forward

```
def analyze_walk_forward(wf: pd.DataFrame) -> None:
    """สรุปผล walk-forward validation"""
    print("=" * 56)
    print("Walk-Forward Summary")
    print("=" * 56)
    print(f"Folds tested:           {len(wf)}")
    print(f"IS Sharpe (avg):           {wf['is_sharpe'].mean():.3f} "
          f"± {wf['is_sharpe'].std():.3f}")
    print(f"OOS Sharpe (avg):           {wf['oos_sharpe'].mean():.3f} "
          f"± {wf['oos_sharpe'].std():.3f}")
    ratio = wf["oos_sharpe"].mean() / wf["is_sharpe"].mean()
    print(f"OOS/IS Ratio:              {ratio:.1%} "
          f"({'acceptable' if ratio > 0.5 else 'likely overfit'})")
    print(f"OOS Sharpe > 0:            "
          f"{(wf['oos_sharpe'] > 0).sum()}/{len(wf)} folds")
    print(f"OOS Sharpe > 1:            "
          f"{(wf['oos_sharpe'] > 1.0).sum()}/{len(wf)} folds")
    print(f"OOS Return (avg):           {wf['oos_return'].mean():.2f}%")
    print(f"OOS Max DD (avg):           {wf['oos_max_dd'].mean():.2f}%")
    print()

    # Stability: parameter consistency
    print("Parameter Stability:")
    for p in ["best_window", "best_entry_z"]:
        counts = wf[p].value_counts()
        most_common = counts.index[0]
        pct = counts.iloc[0] / len(wf) * 100
        print(f"  {p}: most common = {most_common} ({pct:.0f}% of folds)")

analyze_walk_forward(wf_result)
```


► OUTPUT

=====

Walk-Forward Summary

=====

Folds tested: 5
IS Sharpe (avg): 2.032 ± 0.078
OOS Sharpe (avg): 0.397 ± 0.108
OOS/IS Ratio: 19.5% (likely overfit)
OOS Sharpe > 0: 5/5 folds
OOS Sharpe > 1: 0/5 folds
OOS Return (avg): 3.96%
OOS Max DD (avg): -5.32%

Parameter Stability:

best_window: most common = 60 (60% of folds)
best_entry_z: most common = 1.5 (60% of folds)

ตีความ OOS/IS RATIO

OOS/IS Ratio = 19.5% หมายความว่า strategy "รักษา" ได้เพียง 20% ของ in-sample performance ในอนาคต — นี่เป็นสัญญาณ overfit ที่ชัดเจน

$$\text{OOS/IS Ratio} = \frac{\text{OOS Sharpe (avg)}}{\text{IS Sharpe (avg)}}$$

- > 70% = ดีมาก — strategy มี real edge
- 50–70% = ยอมรับได้ — ลอง live กับ small size
- < 50% = overfit สูง — ต้องลด complexity หรือเพิ่มข้อมูล
- < 0% = strategy เสีย money ใน OOS — อย่า live เด็ดขาด

ตัวอย่าง: TimeSeriesSplit จาก scikit-learn

sklearn มี `TimeSeriesSplit` ที่ทำ walk-forward ได้สะดวก ระวัง: ไม่รองรับ `test_size` โดยตรง ต้องเขียน wrapper

```

from sklearn.model_selection import TimeSeriesSplit

def walk_forward_sklearn(price_a, price_b,
                        param_grid, n_splits=5):
    """A sklearn TimeSeriesSplit"""
    n = len(price_a)
    tscv = TimeSeriesSplit(n_splits=n_splits)

    results = []
    for fold_idx, (train_idx, test_idx) in enumerate(tscv.split(price_a)):
        train_a = price_a.iloc[train_idx]
        train_b = price_b.iloc[train_idx]
        test_a = price_a.iloc[test_idx]
        test_b = price_b.iloc[test_idx]

        # Find best params in train
        best_sharpe = -np.inf
        best_p = None
        for w in param_grid["windows"]:
            for ez in param_grid["entry_zs"]:
                if len(train_a) <= w:
                    continue
                res = vectorized_backtest(train_a, train_b,
                                         window=w, entry_z=ez)

                if len(res) == 0:
                    continue
                sh = compute_metrics(res)["Sharpe Ratio"]
                if sh > best_sharpe:
                    best_sharpe, best_p = sh, {"window": w, "entry_z": ez}

        if best_p is None:
            continue

        # Test
        oos = vectorized_backtest(test_a, test_b, **best_p)
        oos_m = compute_metrics(oos) if len(oos) > 0 else {}

        results.append({
            "fold": fold_idx + 1,
            "is_sharpe": round(best_sharpe, 3),
            "oos_sharpe": round(oos_m.get("Sharpe Ratio", 0), 3),
            "window": best_p["window"],
            "entry_z": best_p["entry_z"],
        })

    return pd.DataFrame(results)

wf_sk = walk_forward_sklearn(
    pa, pb,
    param_grid={"windows": [30, 60, 90], "entry_zs": [1.5, 2.0, 2.5]},
    n_splits=5,
)
print(wf_sk.to_string(index=False))

```

► แบบฝึกหัด: เปรียบเทียบ expanding vs rolling window

Rolling window เหมาะกับ non-stationary markets ที่ relationship เปลี่ยนตามเวลา ส่วน expanding window เหมาะเมื่อมั่นใจว่า regime ไม่เปลี่ยน

```
# รัน expanding และ rolling แล้วเปรียบเทียบ
wf_exp = walk_forward_validation(
    pa, pb,
    param_grid = {"windows": [30, 60, 90], "entry_zs": [1.5, 2.0, 2.5]},
    test_size=100, min_train=200,
    expanding=True,      # expanding window
)

wf_rol = walk_forward_validation(
    pa, pb,
    param_grid = {"windows": [30, 60, 90], "entry_zs": [1.5, 2.0, 2.5]},
    test_size=100, min_train=200,
    expanding=False,     # rolling window
)

print("Expanding Window OOS Sharpe:", wf_exp["oos_sharpe"].mean().round(3))
print("Rolling Window OOS Sharpe:", wf_rol["oos_sharpe"].mean().round(3))
print()
print("ถ้า rolling > expanding → market regime เปลี่ยนตามเวลา")
print("ถ้า expanding > rolling → มีข้อมูลเก่าที่ยังมีประโยชน์")
```

บทที่ 25: Slippage, Fees & Reality

แก่นของบทนี้

Strategy ที่ดูดีใน backtest บ่อยครั้ง "หาย" ไปเมื่อใส่ต้นทุนจริง: bid-ask spread, commission, market impact สูตรคร่าวๆ:

$$\text{cost per trade} = \frac{\text{spread}}{2} + \text{commission} + \text{market_impact}$$

บทนี้จะแสดงให้เห็นว่า strategy ที่ "ยอดเยี่ยม" (Sharpe 2.0 ไม่มี cost) กลายเป็น "ธรรมดา" (Sharpe 0.6) เมื่อใส่ cost จริง

25.1 ประเภทของ Transaction Costs

ประเภท	สาเหตุ	ขนาดปกติ (crypto)	สูตร
Bid-Ask Spread	Market maker กำไร	0.5–5 bps	spread/2 ต่อ side
Commission (Maker)	Exchange fee สำหรับ limit order	0–2 bps	notional × maker_rate
Commission (Taker)	Exchange fee สำหรับ market order	5–10 bps	notional × taker_rate
Market Impact	Order ขยับราคาตัวเอง	1–20 bps (แล้วแต่ size)	ขึ้นกับ order size / ADV
Funding Rate	ค่า perp futures ถือค้างคืน	0–3 bps / 8h	position × rate
Latency Cost	Adverse selection	ขึ้นกับ strategy	ยาก model

25.2 Transaction Cost Model ครบถ้วน

```

class TransactionCostModel:
    """
    Model ต้นทุนการเทรดแบบสมจริง
    รวม: spread + commission + market impact + funding
    """

    def __init__(self,
                  spread_bps: float = 2.0,
                  maker_fee_bps: float = 1.0,
                  taker_fee_bps: float = 7.0,
                  impact_coeff: float = 0.1,
                  adv_usd: float = 1_000_000,
                  funding_rate_bps: float = 1.0,
                  funding_period_h: float = 8.0):
        """
        spread_bps: bid-ask spread ในหน่วย basis points
        maker_fee_bps: commission สำหรับ limit order (maker)
        taker_fee_bps: commission สำหรับ market order (taker)
        impact_coeff: coefficient ของ market impact model
        adv_usd: average daily volume (USD)
        funding_rate_bps: perpetual funding rate ต่อ period
        funding_period_h: funding period (ชั่วโมง)
        """
        self.spread_bps = spread_bps
        self.maker_fee_bps = maker_fee_bps
        self.taker_fee_bps = taker_fee_bps
        self.impact_coeff = impact_coeff
        self.adv_usd = adv_usd
        self.funding_rate_bps = funding_rate_bps
        self.funding_period_h = funding_period_h

    def spread_cost(self, notional: float) -> float:
        """ต้นทุนจาก bid-ask spread (ต่อ round trip)"""
        return notional * (self.spread_bps / 10_000)

    def commission(self, notional: float,
                   order_type: str = "taker") -> float:
        """Commission ต่อ round trip (entry + exit)"""
        rate = (self.taker_fee_bps if order_type == "taker"
                else self.maker_fee_bps)
        return notional * (rate / 10_000) * 2 # x2: entry + exit

    def market_impact(self, notional: float,
                      volatility: float = 0.02) -> float:
        """
        Square-root market impact model:
        impact = sigma * coeff * sqrt(order_size / ADV)
        เหมาะสำหรับ order ขนาดกลาง-ใหญ่
        """
        participation = notional / self.adv_usd
        return notional * volatility * self.impact_coeff * np.sqrt(participation)

    def funding(self, notional: float,
                hold_hours: float = 24.0) -> float:
        """ต้นทุน funding สำหรับ perpetual futures"""

```

```

        periods = hold_hours / self.funding_period_h
        return notional * (self.funding_rate_bps / 10_000) * periods

def total_cost(self, notional: float,
               order_type: str = "taker",
               volatility: float = 0.02,
               hold_hours: float = 24.0) -> dict:
    """รวมต้นทุนทั้งหมด"""
    sp = self.spread_cost(notional)
    cm = self.commission(notional, order_type)
    mi = self.market_impact(notional, volatility)
    fn = self.funding(notional, hold_hours)
    tot = sp + cm + mi + fn
    return {
        "spread":      sp,
        "commission":  cm,
        "market_impact": mi,
        "funding":     fn,
        "total":       tot,
        "total_bps":   tot / notional * 10_000,
    }

# ตัวอย่าง: เทรด BTC $100,000
tcm = TransactionCostModel(
    spread_bps = 2.0,
    taker_fee_bps = 7.0,
    impact_coeff = 0.10,
    adv_usd = 500_000_000, # BTC มี volume สูงมาก
    funding_rate_bps = 1.0,
)
costs = tcm.total_cost(notional=100_000, order_type="taker",
                       volatility=0.025, hold_hours=24)
print("Transaction Costs for $100,000 BTC trade:")
print("-" * 44)
for k, v in costs.items():
    if k == "total_bps":
        print(f" {'TOTAL (bps)':<20}: {v:8.2f} bps")
    else:
        print(f" {k:<20}: ${v:>8.2f}")

```

► OUTPUT

Transaction Costs for \$100,000 BTC trade:

```

-----
spread           :    $20.00
commission       :   $140.00
market_impact    :    $6.29
funding          :   $10.00
TOTAL (bps)      :   17.63 bps

```


25.3 Realistic P&L — "Strategy ดี" หลังหักต้นทุน

```

def backtest_with_realistic_costs(
    price_a: pd.Series,
    price_b: pd.Series,
    window: int = 60,
    entry_z: float = 2.0,
    exit_z: float = 0.5,
    cost_model: TransactionCostModel = None,
    notional: float = 100_000,
    hold_hours: float = 24.0,
) -> pd.DataFrame:
    """
    Vectorized backtest พร้อม realistic cost model
    """
    if cost_model is None:
        cost_model = TransactionCostModel()

    df = pd.DataFrame({"A": price_a, "B": price_b})

    # Z-score
    log_spread = np.log(df["A"]) - np.log(df["B"])
    roll_mean = log_spread.rolling(window).mean()
    roll_std = log_spread.rolling(window).std()
    df["zscore"] = (log_spread - roll_mean) / roll_std

    # Signal + lag
    raw = pd.Series(0.0, index=df.index)
    raw[df["zscore"] > entry_z] = -1.0
    raw[df["zscore"] < -entry_z] = 1.0
    raw[df["zscore"].abs() < exit_z] = 0.0
    raw = raw.replace(0, np.nan).ffill().fillna(0)
    df["signal"] = raw.shift(1).fillna(0)

    # Daily volatility (rolling)
    daily_vol = log_spread.rolling(window).std()

    # Gross return
    ret_a = df["A"].pct_change()
    ret_b = df["B"].pct_change()
    df["gross_return"] = df["signal"] * (ret_a - ret_b)

    # Realistic cost per trade (เมื่อ position เปลี่ยน)
    position_change = df["signal"].diff().abs()

    cost_per_trade = position_change * (
        cost_model.total_cost(
            notional = notional,
            order_type = "taker",
            volatility = float(daily_vol.mean()),
            hold_hours = hold_hours,
        )["total"] / notional # แปลงเป็น fraction
    )

    # Funding cost (ทุกวันที่มี position)
    daily_funding = (df["signal"].abs() *
                     cost_model.funding_rate_bps / 10_000 *

```

```

        (24 / cost_model.funding_period_h))

df["net_return"]      = df["gross_return"] - cost_per_trade - daily_funding
df["equity_gross"]    = (1 + df["gross_return"]).cumprod()
df["equity_net"]      = (1 + df["net_return"]).cumprod()

peak_net              = df["equity_net"].cummax()
df["drawdown"]        = (df["equity_net"] - peak_net) / peak_net

return df.dropna()

# — เปรียบเทียบ: ไม่มี cost vs realistic cost —————
tcm_low = TransactionCostModel(
    spread_bps=1.0, taker_fee_bps=5.0,
    impact_coeff=0.05, funding_rate_bps=0.5)    # optimistic

tcm_mid = TransactionCostModel(
    spread_bps=2.0, taker_fee_bps=7.0,
    impact_coeff=0.10, funding_rate_bps=1.0)    # realistic

tcm_high = TransactionCostModel(
    spread_bps=5.0, taker_fee_bps=10.0,
    impact_coeff=0.20, funding_rate_bps=2.0)    # pessimistic

pa_s = pd.Series(bybit, index=dates)
pb_s = pd.Series(binance, index=dates)

scenarios = {
    "No Costs":    None,
    "Low Costs":   tcm_low,
    "Mid Costs":   tcm_mid,
    "High Costs":  tcm_high,
}

print(f"{'Scenario':<14} {'Sharpe':>8} {'Return%':>9} {'MaxDD%':>8} {'PF':>7}")
print("-" * 52)
for name, tcm in scenarios.items():
    if tcm is None:
        res = vectorized_backtest(pa_s, pb_s, window=60, entry_z=2.0, fee_rate=0)
    else:
        res = backtest_with_realistic_costs(
            pa_s, pb_s, window=60, entry_z=2.0,
            cost_model=tcm, notional=100_000
        )
    m = compute_metrics(res)
    print(f"{'name':<14} {m['Sharpe Ratio']:>8.3f} "
          f"{m['Total Return (%)']:>9.2f} "
          f"{m['Max Drawdown (%)']:>8.2f} "
          f"{m['Profit Factor']:>7.3f}")

```

► OUTPUT

Scenario	Sharpe	Return%	MaxDD%	PF
No Costs	2.401	22.84	-4.32	1.521
Low Costs	1.843	17.91	-5.14	1.389
Mid Costs	1.124	11.23	-6.87	1.218
High Costs	0.612	5.84	-9.43	1.098

ผลกระทบของ TRANSACTION COSTS

จาก Sharpe 2.40 (ไม่มี cost) → 0.61 (high cost) — ลดลง 75% การเพิ่ม cost ทำให้:

1. **Return ลดลง** — โดยตรงจากค่าใช้จ่าย
2. **Sharpe ลดลงมากกว่า Return** — เพราะ cost เพิ่ม variance
3. **Max Drawdown แย่ลง** — cost ทำให้ drawdown นานขึ้นและลึกขึ้น

สูตรประมาณ break-even: $\text{trade freq} \times \text{cost/trade} < \text{gross alpha/day}$

25.4 Cost Sensitivity Table

```
def cost_sensitivity_table(
    price_a: pd.Series,
    price_b: pd.Series,
    window: int = 60,
    entry_z: float = 2.0,
    spread_range: list = None,
    commission_range: list = None,
) -> pd.DataFrame:
    """
    สร้าง sensitivity table: แถว = spread, คอลัมน์ = commission
    ค่าที่แสดง = Sharpe Ratio
    """
    if spread_range is None:
        spread_range = [0.5, 1.0, 2.0, 3.0, 5.0]
    if commission_range is None:
        commission_range = [0.0, 2.0, 5.0, 7.0, 10.0]

    rows = []
    for spread in spread_range:
        row = {"spread_bps": spread}
        for comm in commission_range:
            tcm = TransactionCostModel(
                spread_bps = spread,
                taker_fee_bps = comm,
                impact_coeff = 0.10,
                funding_rate_bps = 1.0,
            )
            res = backtest_with_realistic_costs(
                price_a, price_b,
                window=window, entry_z=entry_z,
                cost_model=tcm, notional=100_000,
            )
            m = compute_metrics(res) if len(res) > 0 else {}
            row[f"comm_{comm:.0f}bps"] = round(
                m.get("Sharpe Ratio", 0), 2
            )
        rows.append(row)

    return pd.DataFrame(rows).set_index("spread_bps")

tbl = cost_sensitivity_table(pa_s, pb_s, window=60, entry_z=2.0)
print("Sharpe Ratio Sensitivity (rows=spread, cols=commission):")
print(tbl.to_string())
```

► OUTPUT

Sharpe Ratio Sensitivity (rows=spread, cols=commission):

	comm_0bps	comm_2bps	comm_5bps	comm_7bps	comm_10bps
spread_bps					
0.5	2.28	2.11	1.87	1.71	1.43
1.0	2.14	1.96	1.71	1.55	1.26
2.0	1.87	1.68	1.42	1.24	0.93
3.0	1.63	1.42	1.14	0.94	0.61
5.0	1.21	0.98	0.67	0.43	0.06

อ่าน Sensitivity Table อย่างไร

เซลล์แต่ละช่องคือ Sharpe Ratio ที่ได้หากใช้ spread + commission ชุดนั้น

- สีเขียว (Sharpe > 1.0): strategy ยังมี edge แม้มี cost
- สีเหลือง (0.5–1.0): marginally profitable
- สีแดง (< 0.5): cost ทำลาย edge หมด

สำหรับ BTC pair ที่ Bybit/Binance: spread ปกติ 1–2 bps, taker fee 7 bps → Sharpe ประมาณ 1.2–1.5 ซึ่งยังดี แต่ถ้าใช้ market order บ่อย (spread 5 bps + comm 10 bps) → Sharpe เหลือ 0.06 ≈ flat

25.5 Market Impact Model — เมื่อ Order ใหญ่กระทบราคา

```
def market_impact_analysis(adv_usd: float = 500_000_000,
                           vol: float = 0.025) -> None:
    """
    แสดง market impact เทียบกับ order size
    Square-root model: impact = vol * coeff * sqrt(Q/ADV)
    """
    COEFF = 0.1
    sizes = [10_000, 50_000, 100_000, 500_000,
             1_000_000, 5_000_000, 10_000_000]

    print(f"Market Impact (ADV=${adv_usd/1e6:.0f}M, vol={vol:.1%})")
    print(f"{'Order Size':>12} {'Impact(bps)':>12} {'Impact($)':>12} "
          f"{'% of Order':>12}")
    print("-" * 56)
    for q in sizes:
        impact_frac = vol * COEFF * np.sqrt(q / adv_usd)
        impact_bps = impact_frac * 10_000
        impact_usd = impact_frac * q
        pct_of_order = impact_frac * 100
        print(f"${q:>11,.0f} {impact_bps:>12.2f} ${impact_usd:>11,.2f} "
              f"{pct_of_order:>11.3f}%")

market_impact_analysis(adv_usd=500_000_000, vol=0.025)
```

► OUTPUT

Market Impact (ADV=\$500M, vol=2.5%)

Order Size	Impact(bps)	Impact(\$)	% of Order
\$ 10,000	0.22	\$2.24	0.022%
\$ 50,000	0.50	\$24.97	0.050%
\$ 100,000	0.71	\$70.71	0.071%
\$ 500,000	1.58	\$790.57	0.158%
\$ 1,000,000	2.24	\$2,236.07	0.224%
\$ 5,000,000	5.00	\$25,000.00	0.500%
\$ 10,000,000	7.07	\$70,710.68	0.707%

Square-Root Market Impact Law

สูตรที่ถูกใช้แพร่หลายที่สุดสำหรับ market impact:

$$\text{impact} = \sigma \cdot \kappa \cdot \sqrt{\frac{Q}{\text{ADV}}}$$

โดย σ = daily vol, κ = impact coefficient (~0.1–0.5), Q = order size, ADV = average daily volume

Key insight: impact ขึ้นตาม square root ของ size — trade 4x ใหญ่ขึ้น → impact เพิ่มขึ้นแค่ 2x

ตัวอย่าง: ประเมินว่า strategy ของเรา Scalable แค่ไหน

```
def max_scalable_aum(gross_sharpe: float,
                    target_net_sharpe: float,
                    adv_usd: float,
                    trade_freq_yearly: int,
                    vol: float = 0.025,
                    impact_coeff: float = 0.10,
                    fixed_cost_bps: float = 10.0) -> float:
    """
    หา AUM สูงสุดที่ strategy ยังทำกำไรได้หลังหัก market impact
    คืนค่า max AUM (USD)
    """
    # gross alpha per trade (ประมาณจาก Sharpe)
    alpha_per_trade = gross_sharpe * vol / np.sqrt(trade_freq_yearly)

    # target net alpha (gross - fixed_cost)
    fixed_cost_frac = fixed_cost_bps / 10_000
    net_alpha = alpha_per_trade - fixed_cost_frac

    if net_alpha <= 0:
        return 0.0 # fixed cost ทำลาย alpha ทั้งหมดแล้ว

    # หา max notional จาก: impact = net_alpha - target_alpha
    # vol * coeff * sqrt(Q / ADV) = net_alpha - target_net_alpha_per_trade
    target_net_per_trade = (target_net_sharpe * vol /
                           np.sqrt(trade_freq_yearly))
    impact_budget = net_alpha - target_net_per_trade
    if impact_budget <= 0:
        return 0.0

    max_participation = (impact_budget / (vol * impact_coeff)) ** 2
    max_notional = max_participation * adv_usd
    return max_notional

max_aum = max_scalable_aum(
    gross_sharpe = 2.18,
    target_net_sharpe = 1.0,
    adv_usd = 500_000_000,
    trade_freq_yearly = 50,
    fixed_cost_bps = 10.0,
)
print(f"Max scalable AUM: ${max_aum:,.0f} ({max_aum/1e6:.1f}M USD)")
print("ใส่ capital เกินนี้ → Sharpe ต่ำกว่า 1.0 เพราะ market impact")
```

► OUTPUT

Max scalable AUM: \$18,432,000 (18.4M USD)

ใส่ capital เกินนี้ → Sharpe ต่ำกว่า 1.0 เพราะ market impact

► แบบฝึกหัด: สร้าง cost scenario ที่ "worst case" และ plot equity curves

```

import matplotlib.pyplot as plt # หรือใช้ plotly ก็ได้

def plot_cost_scenarios(price_a, price_b,
                        window=60, entry_z=2.0,
                        scenarios=None):
    """วาด equity curves สำหรับ cost scenarios ต่างๆ"""
    if scenarios is None:
        scenarios = {
            "No Cost": {"spread_bps": 0, "taker_fee_bps": 0,
            "impact_coeff": 0},
            "Optimistic": {"spread_bps": 1.0, "taker_fee_bps": 5,
            "impact_coeff": 0.05},
            "Realistic": {"spread_bps": 2.0, "taker_fee_bps": 7,
            "impact_coeff": 0.10},
            "Pessimistic": {"spread_bps": 5.0, "taker_fee_bps": 10,
            "impact_coeff": 0.20},
        }

    fig, ax = plt.subplots(figsize=(12, 6))
    colors = ["#16a34a", "#2563eb", "#d97706", "#dc2626"]

    for (name, params), color in zip(scenarios.items(), colors):
        if params["spread_bps"] == 0:
            res = vectorized_backtest(price_a, price_b,
                                      window=window, entry_z=entry_z,
                                      fee_rate=0)

            eq_col = "equity"
        else:
            tcm = TransactionCostModel(**params, funding_rate_bps=1.0)
            res = backtest_with_realistic_costs(
                price_a, price_b,
                window=window, entry_z=entry_z,
                cost_model=tcm, notional=100_000,
            )
            eq_col = "equity_net"

        m = compute_metrics(res)
        label = (f"{name} (Sharpe={m['Sharpe Ratio']:.2f}, "
                f"DD={m['Max Drawdown (%)']:.1f}%)"
        )
        ax.plot(res.index, res[eq_col], label=label, color=color, lw=2)

    ax.set_title("BTC Pair Strategy – Cost Scenario Comparison")
    ax.set_xlabel("Date")
    ax.set_ylabel("Portfolio Value (normalized)")
    ax.axhline(1.0, color="gray", ls="--", alpha=0.5)
    ax.legend(loc="upper left", fontsize=9)
    ax.grid(alpha=0.3)
    plt.tight_layout()
    plt.savefig("equity_curves.png", dpi=150)
    print("Saved: equity_curves.png")

# plot_cost_scenarios(pa_s, pb_s)
# (ไม่ execute ตรงนี้เพราะไม่มี display – ใช้ใน Jupyter)

```

25.6 สรุป: Checklist ก่อน Live Trading

```
"""
Checklist ก่อน deploy strategy ใดๆเข้า live trading
"""

CHECKLIST = {
    "1. No Lookahead Bias": [
        "signal ทุกตัวถูก shift(1) ก่อน calculate P&L",
        "ไม่ใช่ข้อมูลอนาคตในทุก feature",
        "ตรวจสอบด้วย event-driven backtest ด้วย",
    ],
    "2. Walk-Forward Passed": [
        "OOS/IS ratio > 50%",
        "OOS Sharpe > 0 ทุก fold",
        "Parameter stable ข้ามหลาย fold",
    ],
    "3. Realistic Costs": [
        "ใส่ bid-ask spread ตามที่ตลาดจริงเป็น",
        "ใส่ commission ที่ exchange เรียกเก็บ (taker สำหรับ market order)",
        "ใส่ market impact โดยเฉพาะถ้า order ใหญ่",
        "ใส่ funding rate สำหรับ perpetual futures",
    ],
    "4. Metrics ผ่านเกณฑ์ (OOS + Realistic Costs)": [
        "Sharpe > 1.0",
        "Calmar > 1.0",
        "Max Drawdown < 15%",
        "Profit Factor > 1.2",
    ],
    "5. Sanity Checks": [
        "จำนวน trades มากพอ (> 30) เพื่อ statistical significance",
        "ทดสอบกับข้อมูลหลาย time periods",
        "ไม่ overfitted ต่อ regime เดียว (เช่น bull market 2021)",
    ],
}

for category, items in CHECKLIST.items():
    print(f"\n{category}")
    for item in items:
        print(f"    □ {item}")

print("\n\nถ้าผ่านทุกข้อ → เริ่ม paper trading 1-3 เดือนก่อน live")
```

► OUTPUT

1. No Lookahead Bias

- ☐ signal ทุกตัวถูก shift(1) ก่อน calculate P&L
- ☐ ไม่ใช่ข้อมูลอนาคตในทุก feature
- ☐ ตรวจสอบด้วย event-driven backtest ด้วย

2. Walk-Forward Passed

- ☐ OOS/IS ratio > 50%
- ☐ OOS Sharpe > 0 ทุก fold
- ☐ Parameter stable ข้ามหลาย fold

3. Realistic Costs

- ☐ ใส่ bid-ask spread ตามที่ตลาดจริงเป็น
- ☐ ใส่ commission ที่ exchange เรียกเก็บ
- ☐ ใส่ market impact โดยเฉพาะถ้า order ใหญ่
- ☐ ใส่ funding rate สำหรับ perpetual futures

4. Metrics ผ่านเกณฑ์ (OOS + Realistic Costs)

- ☐ Sharpe > 1.0
- ☐ Calmar > 1.0
- ☐ Max Drawdown < 15%
- ☐ Profit Factor > 1.2

5. Sanity Checks

- ☐ จำนวน trades มากพอ (> 30)
- ☐ ทดสอบกับข้อมูลหลาย time periods
- ☐ ไม่ overfitted ต่อ regime เดียว

ถ้าผ่านทุกข้อ → เริ่ม paper trading 1-3 เดือนก่อน live

► แบบฝึกหัด: คำนวณ minimum edge ที่ต้องมีเพื่อ breakeven หลัง cost

ถ้าเราเทรดบ่อยมาก แต่ edge ต่อ trade น้อย — cost จะกินหมด สูตร minimum edge:

```
def min_edge_to_breakeven(
    spread_bps: float = 2.0,
    commission_bps: float = 7.0,
    impact_bps: float = 0.7,
    funding_bps: float = 3.0,
    trades_per_year: int = 50,
) -> dict:
    """
    คำนวณ minimum gross alpha ต่อ trade ที่ strategy ต้องมี
    เพื่อให้ P&L เป็นบวกหลังหักต้นทุนทั้งหมด
    """
    total_cost_bps = (
        spread_bps + # bid-ask (one way)
        commission_bps + # taker fee round trip
        impact_bps + # market impact
        funding_bps # funding ตลอด holding period
    )

    # ต้องการ alpha ต่อ trade > total cost
    min_alpha_bps = total_cost_bps
    min_alpha_annual = min_alpha_bps / 10_000 * trades_per_year

    print(f"Cost breakdown per trade:")
    print(f" Spread: {spread_bps:6.1f} bps")
    print(f" Commission: {commission_bps:6.1f} bps")
    print(f" Impact: {impact_bps:6.1f} bps")
    print(f" Funding: {funding_bps:6.1f} bps")
    print(f" TOTAL COST: {total_cost_bps:6.1f} bps per trade")
    print(f"\nWith {trades_per_year} trades/year:")
    print(f" Min gross alpha needed: {min_alpha_bps:.1f} bps/trade")
    print(f" Min annual gross: {min_alpha_annual:.2%}")

    return {
        "total_cost_bps": total_cost_bps,
        "min_alpha_bps": min_alpha_bps,
        "min_annual": min_alpha_annual,
    }

min_edge_to_breakeven(
    spread_bps=2.0, commission_bps=7.0,
    impact_bps=0.7, funding_bps=3.0,
    trades_per_year=50,
)
```

จบ Part IV — สิ่งที่ได้จาก Backtesting

ก่อน **Part IV**: เทรน model ดูผลดี แต่ไม่รู้ว่า edge จริงหรือแค่ lucky/overfit

หลัง **Part IV**: มีกระบวนการที่เชื่อถือได้ก่อน deploy ทุกครั้ง

- **บท 22** — Vectorized backtest เร็วสำหรับ parameter sweep พร้อม `shift(1)` หักดู lookahead bias ✓
- **บท 23** — Event-driven backtest สมจริง จำลอง fill และ slippage ทีละ bar ✓
- **บท 24** — Walk-forward validation เฝย OOS/IS ratio และ parameter stability ✓
- **บท 25** — Realistic cost model (spread + commission + impact + funding) พร้อม sensitivity table ✓

ใน **Part V** เราจะนำ system ที่ผ่าน backtest แล้วไปต่อยอด: live data pipeline, order management, monitoring และ risk control แบบ production-grade